




Stoer Numerische Mathematik

Josef Stoer

Numerische Mathematik 1

Eine Einführung – unter Berücksichtigung
von Vorlesungen von F.L. Bauer

Neunte Auflage
Mit 11 Abbildungen

 Springer

Prof. Dr. Josef Stoer
Universität Würzburg
Institut für Angewandte Mathematik und Statistik
Am Hubland
97074 Würzburg, Deutschland
e-mail: jstoer@mathematik.uni-wuerzburg.de

Bis zur 4. Auflage (1983) erschienen als Band 105 der Reihe *Heidelberger Taschenbücher*

Mathematics Subject Classification (2000): 65-01, 65B05, 65B15, 65D05, 65D07, 65D30, 65D32, 65F05, 65F20, 65F25, 65F35, 65F50, 65G05, 65H05, 65H10, 65K05

Bibliografische Information Der Deutschen Bibliothek

Die Deutsche Bibliothek verzeichnet diese Publikation in der Deutschen Nationalbibliografie; detaillierte bibliografische Daten sind im Internet über <http://dnb.ddb.de> abrufbar.

ISBN 3-540-21395-3 Springer Berlin Heidelberg New York

ISBN 3-540-66154-9 8. Aufl. Springer-Verlag Berlin Heidelberg New York

Dieses Werk ist urheberrechtlich geschützt. Die dadurch begründeten Rechte, insbesondere die der Übersetzung, des Nachdrucks, des Vortrags, der Entnahme von Abbildungen und Tabellen, der Funk-sendung, der Mikroverfilmung oder der Vervielfältigung auf anderen Wegen und der Speicherung in Datenverarbeitungsanlagen, bleiben, auch bei nur auszugsweiser Verwertung, vorbehalten. Eine Vervielfältigung dieses Werkes oder von Teilen dieses Werkes ist auch im Einzelfall nur in den Grenzen der gesetzlichen Bestimmungen des Urheberrechtsgesetzes der Bundesrepublik Deutschland vom 9. September 1965 in der jeweils geltenden Fassung zulässig. Sie ist grundsätzlich vergütungspflichtig. Zuwiderhandlungen unterliegen den Strafbestimmungen des Urheberrechtsgesetzes.

Springer ist ein Unternehmen von Springer Science+Business Media

springer.de

© Springer-Verlag Berlin Heidelberg 1972, 1976, 1979, 1983, 1989, 1993, 1994, 1999, 2005
Printed in Germany

Die Wiedergabe von Gebrauchsnamen, Handelsnamen, Warenbezeichnungen usw. in diesem Werk berechtigt auch ohne besondere Kennzeichnung nicht zu der Annahme, daß solche Namen im Sinne der Warenzeichen- und Markenschutz-Gesetzgebung als frei zu betrachten wären und daher von jedermann benutzt werden dürften.

Satz: Datenerstellung durch den Autor unter Verwendung eines Springer T_EX-Makropakets
Herstellung: LE-T_EX Jelonek, Schmidt & Vöckler GbR, Leipzig
Einbandgestaltung: *design & production* GmbH, Heidelberg

Gedruckt auf säurefreiem Papier SPIN: 10953105 44/3142YL - 5 4 3 2 1 0

Vorwort zur neunten Auflage

Die neue Auflage diene dazu, die Darstellung der diskreten Fouriertransformation formal abzurunden: Insbesondere wurde jetzt auch ihre wichtige Rolle bei der Berechnung von Faltungsprodukten gebührend berücksichtigt. Faltungen kommen ja nicht nur als solche in vielen Anwendungen z. B. in der Signalverarbeitung vor; auch die Effizienz vieler neuerer numerischer Verfahren beruht darauf, daß sie intern die Methoden der schnellen Fouriertransformation zur Berechnung von Faltungen verwenden.

Bekanntlich ist die Korrektur von Druckfehlern eine schier endlose Aufgabe: Die Hinweise von Herrn Professor Sadegh Jorjkar von der Universität Teheran auf einige besonders langlebige Exemplare dieser Spezies waren deshalb sehr willkommen und ich möchte ihm an dieser Stelle dafür danken.

Nicht zuletzt danke ich den Mitarbeiterinnen und Mitarbeitern des Springer-Verlages für die mittlerweile lange und sehr gute Zusammenarbeit.

Würzburg, im Juli 2004

J. Stoer

Vorwort zur ersten Auflage

Dieses Buch gibt den Stoff des ersten Teils einer zweisemestrigen Einführungsvorlesung in die Numerische Mathematik wieder, die der Verfasser in den letzten Jahren an mehreren Hochschulen halten konnte. Neben der Beschreibung der theoretischen Grundlagen der Probleme und Methoden der numerischen Mathematik waren folgende Ziele für die Auswahl des Stoffes und seine Darstellung maßgeblich: Von den vielen Methoden der numerischen Mathematik sollten hauptsächlich diejenigen behandelt werden, die sich auch leicht auf Digitalrechnern realisieren lassen. Dementsprechend wird auf die algorithmische Beschreibung der Verfahren großer Wert gelegt – kritische Teile von Algorithmen werden häufig in Algol 60 beschrieben. Wenn mehrere Methoden zur Lösung eines Problems vorgestellt werden, wird gleichzeitig nach Möglichkeit versucht, diese Methoden bezüglich ihrer praktischen Brauchbarkeit zu vergleichen und die Grenzen ihrer Anwendbarkeit anzugeben. Bei diesen Vergleichen sollten nicht nur die Anzahl der Operationen, Konvergenzeigenschaften usw. eine Rolle spielen, wichtiger ist es, die numerische Stabilität der Algorithmen zu vergleichen, um einen Einblick in die Gründe für die Zuverlässigkeit oder Unzuverlässigkeit von Verfahren zu geben. Das Einleitungskapitel über Fehleranalyse spielt dabei eine besondere Rolle: In ihm werden die Begriffe der numerischen Stabilität und Gutartigkeit von Algorithmen, die nach Meinung des Verfassers im Zentrum der numerischen Mathematik stehen, präzisiert und ihre Wichtigkeit genauer, als dies vielfach noch üblich ist, begründet und dargestellt. Nicht zuletzt dienen zahlreiche Beispiele und Übungsaufgaben dazu, die numerischen und theoretischen Eigenschaften von Verfahren zu illustrieren.

Da eine auch nur annähernd vollständige Aufzählung und Beschreibung brauchbarer Methoden weder möglich noch beabsich-

tigt war, sei der interessierte Leser auf folgende Zeitschriften hingewiesen, in denen er zahlreiche weitere Algorithmen teilweise sogar in der Form von Algol- oder Fortran-Programmen beschrieben findet: Numerische Mathematik, Communications of the ACM, Journal of the ACM, The Computer Journal, Computing, Mathematics of Computation, BIT, SIAM Journal on Numerical Analysis, Zeitschrift für Angewandte Mathematik und Mechanik. Wegen ihrer Zuverlässigkeit werden insbesondere die Algol-Programme empfohlen, die in der Zeitschrift „Numerische Mathematik“ im Rahmen der sog. „Handbook Series“ erscheinen.

An Inhalt und Aufbau der diesem Buch zugrunde liegenden Vorlesung haben viele mitgewirkt. Insbesondere möchte ich dankbar den Einfluß von Professor Dr. F. L. Bauer und Professor Dr. R. Baumann anerkennen, auf deren Vorlesungsausarbeitungen ich mich stützen konnte. Darüber hinaus haben sie zusammen mit den Herren Professor Dr. R. Bulirsch und Dr. Chr. Reinsch mit wertvollen Verbesserungsvorschlägen zur Klärung einer Reihe von kritischen Punkten beigetragen.

Eine vorläufige Fassung des Buches entstand 1970 in Form eines Skriptums der Universität Würzburg unter der maßgeblichen Mitwirkung meiner Mitarbeiter Dipl.-Math. K. Butendeich, Dipl.-Phys. G. Schuller und Dipl.-Math. Dr. J. Zowe. Für ihre Einsatzbereitschaft, mit der sie bei der Redaktion der verschiedenen Fassungen des Manuskripts mithalfen, möchte ich ihnen besonders herzlich danken. Nicht zuletzt gilt mein besonderer Dank Frau I. Brugger, die mit großer Gewissenhaftigkeit und Geduld die umfangreichen Schreibarbeiten ausführte.

Würzburg, im November 1971

J. Stoer

Inhaltsverzeichnis

1	Fehleranalyse	1
1.1	Zahldarstellung	2
1.2	Rundungsfehler und Gleitpunktrechnung	5
1.3	Fehlerfortpflanzung	9
1.4	Beispiele	22
1.5	Intervallrechnung, statistische Rundungsfehlerabschätzungen	29
	Übungsaufgaben zu Kapitel 1	34
	Literatur zu Kapitel 1 und weitere Literatur	37
2	Interpolation	41
2.1	Interpolation durch Polynome	42
2.1.1	Theoretische Grundlagen. Die Interpolationsformel von Lagrange	42
2.1.2	Der Algorithmus von Neville	44
2.1.3	Die Newtonsche Interpolationsformel. Dividierte Differenzen	48
2.1.4	Das Restglied bei der Polynominterpolation	53
2.1.5	Hermite-Interpolation	56
2.2	Interpolation mit rationalen Funktionen	63
2.2.1	Allgemeine Eigenschaften der rationalen Interpolation	63
2.2.2	Inverse und reziproke Differenzen. Der Thielesche Kettenbruch	68
2.2.3	Neville-artige Algorithmen	72
2.2.4	Anwendungen und Vergleich der beschriebenen Algorithmen	77
2.3	Trigonometrische Interpolation	79
2.3.1	Theoretische Grundlagen	79
2.3.2	Algorithmen zur schnellen Fouriertransformation	88

2.3.3	Die Algorithmen von Goertzel und Reinsch	95
2.3.4	Die näherungsweise Berechnung von Fourierkoeffizienten. Abminderungsfaktoren .	99
2.4	Spline-Interpolation	104
2.4.1	Theoretische Grundlagen	104
2.4.2	Die Berechnung von kubischen Splinefunktionen .	108
2.4.3	Konvergenzeigenschaften kubischer Splinefunktionen	114
2.4.4	B-Splines	119
2.4.5	Die Berechnung von B-Splines	125
2.4.6	Multi-Resolutions-Verfahren und B-Splines . . .	130
	Übungsaufgaben zu Kapitel 2	143
	Literatur zu Kapitel 2	152
3	Integration von Funktionen	155
3.1	Elementare Integrationsformeln. Fehlerabschätzungen	156
3.2	Die Peanosche Fehlerdarstellung	162
3.3	Die Euler-Maclaurinsche Summenformel	166
3.4	Anwendung der Extrapolation auf die Integration .	169
3.5	Allgemeines über Extrapolationsverfahren	174
3.6	Die Gaußsche Integrationsmethode	180
3.7	Integrale mit Singularitäten	190
	Übungsaufgaben zu Kapitel 3	193
	Literatur zu Kapitel 3	196
4	Lineare Gleichungssysteme	199
4.1	Gauß-Elimination. Dreieckszerlegung einer Matrix	200
4.2	Der Gauß-Jordan-Algorithmus	210
4.3	Das Cholesky-Verfahren	214
4.4	Fehlerabschätzungen	217
4.5	Rundungsfehleranalyse der Gaußschen Eliminationsmethode	226
4.6	Rundungsfehlereinfluß bei der Auflösung von gestaffelten Gleichungssystemen	232
4.7	Orthogonalisierungsverfahren. Die Verfahren von Householder und Schmidt . . .	234
4.8	Ausgleichsrechnung	242
4.8.1	Das lineare Ausgleichsproblem. Die Normalgleichungen	244
4.8.2	Orthogonalisierungsverfahren zur Lösung des linearen Ausgleichsproblems	246

4.8.3	Die Kondition des linearen Ausgleichsproblems . . .	247
4.8.4	Nichtlineare Ausgleichsprobleme	253
4.8.5	Die Pseudoinverse einer Matrix	255
4.9	Modifikationstechniken	258
4.10	Lineare Minimierungsprobleme. Die Simplexmethode	267
4.11	Phase I der Simplexmethode	281
4.12	Exkurs: Eliminationsverfahren	
	für dünn besetzte Matrizen	284
	Übungsaufgaben zu Kapitel 4	293
	Literatur zu Kapitel 4	298
5	Verfahren zur Nullstellenbestimmung.	
	Minimierungsmethoden	301
5.1	Entwicklung von Iterationsverfahren	302
5.2	Allgemeine Konvergenzsätze	305
5.3	Die Konvergenz des allgemeinen Newton-Verfahrens	311
5.4	Ein modifiziertes Newton-Verfahren	315
5.4.1	Über die Konvergenz von Minimierungsverfahren .	316
5.4.2	Anwendung auf das modifizierte Newton-Verfahren	321
5.4.3	Hinweise zur praktischen Realisierung	
	des modifizierten Newton-Verfahrens.	
	Ein Rang-1-Verfahren von Broyden	325
5.5	Nullstellenbestimmung für Polynome.	
	Das Newtonsche Verfahren	329
5.6	Sturmsche Ketten und Bisektionsverfahren	341
5.7	Das Verfahren von Bairstow	346
5.8	Die Empfindlichkeit der Nullstellen von Polynomen	348
5.9	Interpolationsmethoden	
	zur Bestimmung von Nullstellen	351
5.10	Die Δ^2 -Methode von Aitken	357
5.11	Minimierungsprobleme ohne Nebenbedingungen .	361
	Übungsaufgaben zu Kapitel 5	370
	Literatur zu Kapitel 5	373
	Namen- und Sachverzeichnis	377

1 Fehleranalyse

Eine der wichtigsten Aufgaben der numerischen Mathematik ist es, die Genauigkeit eines Rechenresultats zu beurteilen. Es gibt verschiedene Arten von Fehlern, die diese Genauigkeit begrenzen, man unterscheidet:

- a) Fehler in den Eingabedaten der Rechnung,
- b) Rundungsfehler,
- c) Approximationsfehler.

Fehler in den Eingangsdaten lassen sich nicht vermeiden, wenn z. B. die Eingangsdaten Meßwerte von nur beschränkter Genauigkeit sind. Rundungsfehler entstehen, wenn man, wie es in aller Regel geschieht, nur mit Zahlen einer endlichen aber festen Stellenzahl rechnet.

Approximationsfehler hängen mit den Rechenmethoden zusammen: Viele Methoden liefern selbst bei rundungsfehlerfreier Rechnung nicht die eigentlich gesuchte Lösung eines gegebenen Problems P , sondern nur die Lösung eines einfacheren Problems $\tilde{P}$, das P approximiert.

Beispiel: Das Problem P der Berechnung der Zahl e mit Hilfe der unendlichen Reihe

$$e = 1 + \frac{1}{1!} + \frac{1}{2!} + \frac{1}{3!} + \dots$$

approximiert man durch ein einfacheres Problem $\tilde{P}$, wenn man nur endlich viele Glieder dieser Reihe summiert.

Den dabei entstehenden Approximationsfehler nennt man oft auch Abbrechfehler (truncation error, manchmal werden damit aber auch nur die Rundungsfehler bezeichnet, die man beim Abschneiden einer Zahl nach einer bestimmten Stelle begeht).

Häufig erhält man das approximierende Problem $\tilde{P}$ durch „Diskretisierung“ des ursprünglichen Problems P : z. B. approximiert man Integrale durch endliche Summen, Differentialquotienten durch Differenzenquotienten usw. In diesem Zusammenhang bezeichnet man den Approximationsfehler auch als Diskretisierungsfehler.

In diesem Kapitel werden wir die Auswirkung der Eingangs- und Rundungsfehler einer Rechnung auf das Endresultat untersuchen. Approximationsfehler werden wir bei der Behandlung der einzelnen Methoden diskutieren. Eine systematische Behandlung von Rundungsfehlern findet man bei Sterbenz (1974).

1.1 Zahldarstellung

Aufgrund ihrer verschiedenen Zahldarstellung kann man zwei Arten von Rechengeräten unterscheiden

- a) Analogrechner,
- b) Digitalrechner.


Beispiele für Analogrechner sind der Rechenschieber, das Planimeter sowie die elektronischen Analogrechner. Bei diesen Geräten werden Zahlen direkt durch physikalische Größen (wie die Länge eines Stabes oder die Größe einer Spannung) ersetzt und das mathematische Problem durch ein physikalisches simuliert, dessen Lösung in einem Experiment gemessen wird und so indirekt die Lösung des mathematischen Problems ergibt.

Beispiel: Auf den Skalen eines Rechenschiebers werden Zahlen durch Strecken der Länge $k \cdot \ln(x)$ dargestellt. Ihre Multiplikation wird daher durch Aneinanderlegen entsprechend langer Stäbe simuliert und das Resultat der Multiplikation als Ergebnis einer Längenmessung abgelesen.

Dementsprechend ist die Genauigkeit von Analogrechnern durch die physikalische Meßgenauigkeit begrenzt.

Bei Digitalrechnern wird eine Zahl ähnlich der normalen Dezimaldarstellung durch eine endliche Folge diskreter physikalischer Größen repräsentiert. Typische Vertreter sind die gewöhnlichen Tischrechenmaschinen und die elektronischen Digitalrechner.

Beispiel:



Jeder Ziffer entspricht eine physikalische Größe, etwa der Ziffer 8 die Spannung 8 Volt. Da z. B. im Dezimalsystem höchstens 10 verschiedene Ziffern darzustellen sind, sind an die Genauigkeit der Darstellung der Ziffern durch physikalische Größen keine so hohen Ansprüche zu stellen wie

bei einem Analogrechner (beispielsweise könnte man für die Darstellung der Ziffer 8 Spannungen zwischen 7.8 und 8.2 V tolerieren): Die Genauigkeit der Digitalrechner ist in diesem Sinne *nicht* durch die physikalische Meßgenauigkeit beschränkt.

Aus technischen Gründen stützen sich die meisten modernen elektronischen Digitalrechner nicht auf die übliche Darstellung der Zahlen im Dezimalsystem, sondern auf das Dualsystem, in dem die Koeffizienten α_i der Dualzerlegung

$$x = \pm(\alpha_n 2^n + \alpha_{n-1} 2^{n-1} + \dots + \alpha_0 2^0 + \alpha_{-1} 2^{-1} + \alpha_{-2} 2^{-2} + \dots),$$

$$\alpha_i = 0 \quad \text{oder} \quad \alpha_i = 1,$$

von x zur Darstellung benutzt werden. Um Verwechslungen mit der Dezimaldarstellung von Zahlen zu vermeiden, bezeichnet man im Dualsystem die Ziffern 0 und 1 durch die Ziffern **0** bzw. **L**

Beispiel: Die Zahl $x = 18.5$ besitzt entsprechend der Zerlegung

$$18.5 = 1 \cdot 2^4 + 0 \cdot 2^3 + 0 \cdot 2^2 + 1 \cdot 2^1 + 0 \cdot 2^0 + 1 \cdot 2^{-1}$$

die Dualdarstellung

L00L0.L

Der gewohnteren Zahldarstellung wegen verwenden wir vorwiegend das Dezimalsystem, weisen jedoch an den entsprechenden Stellen auf Unterschiede zum Dualsystem hin.

Wie das Beispiel $3.999\dots = 4$ zeigt, ist die Dezimaldarstellung einer reellen Zahl x nicht notwendig eindeutig. Um solche Mehrdeutigkeiten auszuschließen, soll im folgenden unter der Dezimaldarstellung einer Zahl im Zweifelsfall stets die endliche Darstellung gemeint sein. Ähnliches gilt für Dualdarstellungen.

Bei Digitalrechnern steht für die interne Darstellung einer Zahl nur eine feste endliche Anzahl n ($=$ Wortlänge) von Dezimalstellen (Dualstellen) zur Verfügung, die durch die Konstruktion der Maschine festgelegt ist und, wenn überhaupt, nur auf ganze Vielfache $2n, 3n, \dots$ (doppelte, dreifache ... Wortlänge) von n erweitert werden kann. Die Wortlänge von n Stellen kann auf verschiedene Weise zur Darstellung einer Zahl benutzt werden.

Bei der *Festpunktdarstellung* sind zusätzlich zur Zahl n auch die Zahlen n_1 und n_2 der Stellen vor bzw. nach dem Dezimalpunkt fixiert, $n = n_1 + n_2$ (in der Regel ist $n_1 = 0$ oder $n_1 = n$).

Beispiel: Für $n = 10$, $n_1 = 4$, $n_2 = 6$ hat man die Darstellungen

$$\begin{array}{l} 30.421 \rightarrow \boxed{0030} \boxed{421000} \\ 0.0437 \rightarrow \underbrace{\boxed{0000}}_{n_1} \underbrace{\boxed{043700}}_{n_2} \end{array}$$

Bei dieser Darstellung ist die Lage des (Dezimal-, Dual-) Punktes festgelegt. Nur sehr einfache Rechner, insbesondere für kaufmännische Rechnungen, beschränken sich heute noch auf die Festpunktdarstellung von Zahlen. Viel häufiger und bedeutsamer, insbesondere für wissenschaftliche Rechnungen, sind Rechner, in denen die *Gleitpunktdarstellung* von Zahlen realisiert ist. Hier liegt der Punkt nicht für alle Zahlen fest, und man muß dementsprechend bei jeder Zahl angeben, an der wievielten Stelle nach der ersten Ziffer der Darstellung der Punkt liegt. Dazu dient der sog. *Exponent*: Man nutzt aus, daß sich jede reelle Zahl x in der Form

$$(1.1.1) \quad x = a \cdot 10^b \quad (\text{bzw. } x = a \cdot 2^b) \quad \text{mit } |a| < 1, b \text{ ganz}$$

schreiben läßt, etwa $30.421 = 0.30421 \cdot 10^2$. Durch den *Exponenten* b wird die Lage des Dezimalpunktes in der *Mantisse* a angegeben. Mit Rutishauser wird häufig die Basis des Exponenten tiefgestellt („halblogarithmische Schreibweise“):

$$0.30421_{10}2$$

und analog im Dualsystem

$$0.L00L0L_2L0L$$

für die Zahl 18.5. Natürlich stehen in jedem Rechner für die Gleitpunktdarstellung von Zahlen nur eine endliche feste Anzahl t bzw. e von (Dezimal-, Dual-) Stellen für die Darstellung der Mantisse bzw. des Exponenten zur Verfügung, $n = t + e$.

Beispiel: Für $t = 4$, $e = 2$ besitzt die Zahl 5420 im Dezimalsystem die Gleitpunktdarstellung

$$0.\boxed{5420}_{10}\boxed{04} \quad \text{oder kurz} \quad \boxed{5420}\boxed{04}.$$

Die Gleitpunktdarstellung einer Zahl ist i. a. nicht eindeutig. Z. B. hat man im letzten Beispiel wegen $5420 = 0.542_{10}4 = 0.0542_{10}5$ auch die Gleitpunktdarstellung

$$0.\boxed{0542}_{10}\boxed{05} \quad \text{oder} \quad \boxed{0542}\boxed{05}.$$

Normalisiert heißt diejenige Gleitpunktdarstellung einer Zahl, für die die erste Ziffer der Mantisse von 0 (bzw. 0) verschieden ist. In (1.1.1) gilt dann

$|a| \geq 10^{-1}$ bzw. im Dualsystem $|a| \geq 2^{-1}$. Als *wesentliche Stellen* einer Zahl werden alle Ziffern der Mantisse ohne die führenden Nullen bezeichnet.

Wir wollen uns im folgenden nur noch mit der normalisierten Gleitpunktdarstellung und der zugehörigen Gleitpunktrechnung befassen. Die Zahlen t und e bestimmen (zusammen mit der Basis $B = 10$ oder $B = 2$) der Zahldarstellung die Menge $A \subseteq \mathbb{R}$ von reellen Zahlen, die in der Maschine exakt dargestellt werden können, ihre Elemente heißen *Maschinenzahlen*.

Bei den heutigen Digitalrechnern ist die normalisierte Gleitpunktdarstellung die Regel, es gibt jedoch auch Vorschläge, unnormalisierte Gleitpunktrechnung zu verwenden, bei der nur die wesentlichen Ziffern einer Zahl mitgeführt werden [Ashenurst und Metropolis (1959)].

1.2 Rundungsfehler und Gleitpunktrechnung

Die Menge A der in einer Maschine darstellbaren Zahlen ist endlich. Damit erhebt sich die Frage, wie man eine Zahl $x \notin A$, die keine Maschinenzahl ist, durch eine Maschinenzahl $g \in A$ approximieren kann. Dieses Problem stellt sich nicht nur bei der Eingabe von Daten in einen Rechner, sondern auch innerhalb des Rechners während des Ablaufs einer Rechnung. Wie einfachste Beispiele zeigen, kann nämlich das Resultat $x \pm y$, $x \cdot y$, x/y selbst der einfachen arithmetischen Operationen nicht zu A gehören, obwohl beide Operanden $x, y \in A$ Maschinenzahlen sind. Von einer vernünftigen Approximation einer Zahl $x \notin A$ durch eine Maschinenzahl $\text{rd}(x) \in A$ wird man verlangen

$$(1.2.1) \quad |x - \text{rd}(x)| \leq |x - g| \quad \text{für alle } g \in A.$$

Man erhält ein solches $\text{rd}(x)$ gewöhnlich durch *Rundung*.

Beispiel 1: ($t = 4$)

$$\text{rd}(0.14285_{10}0) = 0.1429_{10}0$$

$$\text{rd}(3.14159_{10}0) = 3.142_{10}1$$

$$\text{rd}(0.142842_{10}2) = 0.1428_{10}2$$

Allgemein kann man bei t -stelliger Dezimalrechnung $\text{rd}(x)$ so finden: Man stellt zunächst $x \notin A$ in normalisierter Form $x = a \cdot 10^b$ (1.1.1), $|a| \geq 10^{-1}$, dar. Die Dezimaldarstellung von $|a|$ sei

$$|a| = 0.\alpha_1\alpha_2 \dots \alpha_t\alpha_{t+1} \dots, \quad 0 \leq \alpha_i \leq 9, \quad \alpha_1 \neq 0.$$

Man bildet damit

$$a' := \begin{cases} 0.\alpha_1\alpha_2 \dots \alpha_t & \text{falls } 0 \leq \alpha_{t+1} \leq 4 \\ 0.\alpha_1\alpha_2 \dots \alpha_t + 10^{-t} & \text{falls } \alpha_{t+1} \geq 5 \end{cases}$$

d. h. man erhöht a_t um 1, falls die $(t+1)$ -te Ziffer $a_{t+1} \geq 5$ ist, und schneidet nach der t -ten Ziffer ab. Schließlich setzt man

$$\tilde{\text{rd}}(x) := \text{sign}(x) \cdot a' \cdot 10^b.$$

Offensichtlich gilt für den relativen Fehler von $\tilde{\text{rd}}(x)$

$$\left| \frac{\tilde{\text{rd}}(x) - x}{x} \right| \leq \frac{5 \cdot 10^{-(t+1)}}{|a|} \leq 5 \cdot 10^{-t}$$

wegen $|a| \geq 10^{-1}$, oder mit der Abkürzung $\text{eps} := 5 \cdot 10^{-t}$,

$$(1.2.2) \quad \tilde{\text{rd}}(x) = x(1 + \varepsilon) \quad \text{mit} \quad |\varepsilon| \leq \text{eps}.$$

Die Zahl $\text{eps} = 5 \cdot 10^{-t}$ heißt *Maschinengenauigkeit*. Für das Dualsystem kann man $\tilde{\text{rd}}(x)$ analog definieren: Ausgehend von der Zerlegung $x = a \cdot 2^b$ mit $2^{-1} \leq |a| < 1$ und der Dualdarstellung

$$|a| = 0.\alpha_1 \dots \alpha_t \alpha_{t+1} \dots, \quad \alpha_i = 0 \quad \text{oder} \quad \alpha_i = \mathbf{L}$$

von $|a|$ bildet man

$$a' := \begin{cases} 0.\alpha_1 \dots \alpha_t & \text{falls} \quad \alpha_{t+1} = 0 \\ 0.\alpha_1 \dots \alpha_t + 2^{-t} & \text{falls} \quad \alpha_{t+1} = \mathbf{L} \end{cases}$$

$$\tilde{\text{rd}}(x) := \text{sign}(x) \cdot a' \cdot 2^b.$$

Auch hier gilt (1.2.2), wenn man die Maschinengenauigkeit durch $\text{eps} := 2^{-t}$ definiert.

Sofern $\tilde{\text{rd}}(x) \in A$ eine Maschinenzahl ist, besitzt $\tilde{\text{rd}}$ die Eigenschaft (1.2.1) einer korrekten Rundung rd , so daß man $\text{rd}(x) := \tilde{\text{rd}}(x)$ für alle x mit $\text{rd}(x) \in A$ definieren kann. Leider gibt es aber wegen der endlichen Anzahl e der für die Exponentendarstellung vorgesehenen Stellen immer Zahlen $x \notin A$ mit $\tilde{\text{rd}}(x) \notin A$.

Beispiel 2: ($t = 4$, $e = 2$)

- a) $\tilde{\text{rd}}(0.31794_{10}110) = 0.3179_{10}110 \notin A$
- b) $\tilde{\text{rd}}(0.99997_{10}99) = 0.1000_{10}100 \notin A$
- c) $\tilde{\text{rd}}(0.012345_{10}-99) = 0.1235_{10}-100 \notin A$
- d) $\tilde{\text{rd}}(0.54321_{10}-110) = 0.5432_{10}-110 \notin A$

In den Fällen a) und b) ist der Exponent zu groß: *Exponentenüberlauf*. Fall b) ist besonders pathologisch: Hier tritt der Exponentenüberlauf erst nach dem Aufrunden ein. Die Fälle c) und d) sind Beispiele für *Exponentenunterlauf*, der Exponent der darzustellenden Zahl ist zu klein. In den Fällen c) und d) kann man sich durch die Definitionen

$$(1.2.3) \quad \begin{aligned} \text{rd}(0.012345_{10} - 99) &:= 0.0123_{10} - 99 \in A \\ \text{rd}(0.54321_{10} - 110) &:= 0 \in A \end{aligned}$$

vor einem Exponentenunterlauf retten, doch dann gilt für rd statt $\tilde{\text{rd}}$ nicht mehr (1.2.2), der relative Fehler von $\text{rd}(x)$ kann größer als eps sein! Alle Rechenanlagen melden einen Exponentenüberlauf als Fehler. Ein Exponentenunterlauf wird (in der Regel) nicht als Fehler gemeldet, sondern es wird $\text{rd}(x)$ ähnlich wie in Beispiel (1.2.3) gebildet. In den übrigen Fällen, $\tilde{\text{rd}}(x) \in A$, wird gewöhnlich (nicht bei allen Anlagen!) $\text{rd}(x) := \tilde{\text{rd}}(x)$ als Rundung genommen.

Da Exponentenüber- und -unterläufe verhältnismäßig seltene Ereignisse sind (bei den heutigen Anlagen ist e ausreichend groß), die man überdies durch geeignete Umskalierung der Daten vermeiden kann, wollen wir für die folgende Diskussion die idealisierte Annahme $e = \infty$ machen, so daß für die Rundungsabbildung $\text{rd} := \tilde{\text{rd}}$ gilt

$$(1.2.4) \quad \begin{aligned} \text{rd} : \mathbb{R} &\rightarrow A, \\ \text{rd}(x) &= x(1 + \varepsilon) \text{ mit } |\varepsilon| \leq \text{eps} \quad \text{für alle } x \in \mathbb{R}. \end{aligned}$$

Dementsprechend wird bei den künftigen Beispielen nur noch die Mantissenlänge t angegeben. Man beachte, daß für $e \neq \infty$ einige der folgenden Aussagen über Rundungsfehler im Falle von Exponentenüber- oder -unterlauf nicht gelten.

Da das Resultat einer arithmetischen Operation $x \pm y$, $x \times y$, x/y nicht eine Maschinenzahl sein muß, selbst wenn es die Operanden x und y sind, kann man nicht erwarten, daß diese Operationen auf einem Rechner exakt realisiert sind. Statt der exakten Operationen $+$, $-$, $\times$, $/$ werden Ersatzoperationen $+^*$, $-^*$, $\times^*$, $/^*$, sog. *Gleitpunktoperationen*, angeboten, die die arithmetischen Operationen möglichst gut approximieren [v. Neumann and Goldstein (1947)]. Solche Ersatzoperationen kann man etwa mit Hilfe der Rundung so definieren:

$$(1.2.5) \quad \begin{aligned} x +^* y &:= \text{rd}(x + y) \\ x -^* y &:= \text{rd}(x - y) \\ x \times^* y &:= \text{rd}(x \times y) \\ x /^* y &:= \text{rd}(x/y) \end{aligned} \quad \text{für } x, y \in A.$$

Es gilt dann wegen (1.2.4)

$$(1.2.6) \quad \begin{aligned} x +^* y &= (x + y)(1 + \varepsilon_1) \\ x -^* y &= (x - y)(1 + \varepsilon_2) \\ x \times^* y &= (x \times y)(1 + \varepsilon_3) \\ x /^* y &= (x/y)(1 + \varepsilon_4) \end{aligned} \quad |\varepsilon_i| \leq \text{eps}.$$

Bei den heutigen Anlagen sind die Gleitpunktoperationen $\pm^*$, ... häufig nicht genau durch (1.2.5) definiert, doch in aller Regel so, daß trotzdem (1.2.6) mit eventuell etwas schlechteren Schranken $|\varepsilon_i| \leq k \cdot \text{eps}$, $k \geq 1$ eine kleine Zahl, gilt. Da dies für das folgende unwesentlich ist, nehmen wir der Einfachheit halber an, daß die Gleitpunktoperationen durch (1.2.5) definiert sind und deshalb die Eigenschaft (1.2.6) haben.

Es sei darauf hingewiesen, daß die Gleitpunktoperationen nicht den üblichen Gesetzen der arithmetischen Operationen genügen. So ist z. B.

$$x +^* y = x, \text{ falls } |y| < \frac{\text{eps}}{B}|x|, \quad x, y \in A,$$

wobei B die Basis des Zahlensystems ist. Die Maschinengenauigkeit eps kann man z. B. als die kleinste positive Maschinenzahl g mit $1 +^* g > 1$ definieren,

$$\text{eps} = \min\{g \in A \mid 1 +^* g > 1 \text{ und } g > 0\}.$$

Ferner sind für die Gleitpunktoperationen die Assoziativ- und Distributivgesetze falsch:

Beispiel 3: ($t = 8$) Für

$$a := 0.23371258_{10} - 4$$

$$b := 0.33678429_{102}$$

$$c := -0.33677811_{102}$$

gilt

$$a +^* (b +^* c) = 0.23371258_{10} - 4 +^* 0.61800000_{10} - 3$$

$$= 0.64137126_{10} - 3,$$

$$(a +^* b) +^* c = 0.33678452_{102} -^* 0.33677811_{102}$$

$$= 0.64100000_{10} - 3.$$

Das exakte Resultat ist

$$a + b + c = 0.641371258_{10} - 3.$$

Man achte auf den Fall der *Auslöschung* bei der Subtraktion von Zahlen $x, y \in A$, die das gleiche Vorzeichen haben: Dieser Fall liegt vor, wenn die Zahlen x, y , wie in dem Beispiel

$$x = 0.315876_{101}$$

$$y = 0.314289_{101}$$

Darstellungen (1.1.1) mit dem gleichen Exponenten besitzen und eine oder mehrere führende Ziffern in den Mantissen übereinstimmen. Bei der Subtraktion $x - y$ tritt „Auslöschung“ der gemeinsamen führenden Ziffern der Mantisse ein, das exakte Resultat $x - y$ läßt sich als Maschinenzahl darstellen, sofern x und y Maschinenzahlen waren, so daß bei der Ausführung

der Subtraktion kein *neuer* Rundungsfehler anfällt: $x -^* y = x - y$. In diesem Sinne ist die Subtraktion im Falle der Auslöschung eine sehr harmlose Operation. Wir werden jedoch im nächsten Abschnitt sehen, daß im Falle von Auslöschung eine außerordentlich gefährliche Situation vorliegt, was die Fortpflanzung der *alten* Fehler angeht, die man bei der Berechnung von x und y bereits *vor* Ausführung der Subtraktion $x - y$ begangen hat.

Für das Ergebnis von Gleitpunktrechnungen hat sich eine bequeme aber etwas unpräzise Schreibweise eingebürgert, die wir im folgenden öfters benutzen wollen: Steht für einen arithmetischen Ausdruck E fest, wie er berechnet werden soll (dies wird evtl. durch geeignete Klammerung vorgeschrieben), so wird durch $gl(E)$ der Wert des Ausdrucks bezeichnet, den man bei Gleitpunktrechnung erhält.

Beispiel 4:

$$gl(x \times y) := x \times^* y$$

$$gl(a + (b + c)) := a +^* (b +^* c)$$

$$gl((a + b) + c) := (a +^* b) +^* c$$

Man benutzt diese Schreibweise auch in Fällen wie $gl(\sqrt{x})$, $gl(\cos(x))$ etc., wenn auf einer Rechenanlage die betreffenden Funktionen $\sqrt{}$, $\cos \dots$ durch Ersatzfunktionen $\sqrt{^*}$, $\cos^*$ realisiert sind, $gl(\sqrt{x}) := \sqrt{x}^*$ usw.

Die arithmetischen Operationen $+$, $-$, $\times$, $/$ sowie alle einfachen Funktionen, wie etwa $\sqrt{}$, $\cos$, für die Gleitpunkt-Ersatzfunktionen vorliegen, heißen im folgenden *elementare Operationen*.

1.3 Fehlerfortpflanzung

Im letzten Abschnitt sahen wir bereits (s. Beispiel 3), daß zwei verschiedene, mathematisch äquivalente Methoden, $(a + b) + c$, $a + (b + c)$, zur Auswertung des Ausdruckes $a + b + c$ bei Gleitpunktrechnung zu unterschiedlichen Resultaten führen können. Es ist deshalb aus numerischen Gründen wichtig, genau zwischen verschiedenen mathematisch äquivalenten Formulierungen einer Rechenmethode zu unterscheiden: Wir bezeichnen als *Algorithmus* eine der Reihenfolge nach eindeutig festgelegte Sequenz von endlich vielen „elementaren“ Operationen (wie sie etwa in einem Rechner-Programm gegeben ist), mit denen man aus gewissen Eingabedaten die Lösung eines Problems berechnen kann.

Wir wollen den Begriff eines Algorithmus etwas formalisieren und dazu annehmen, daß das Problem darin besteht, aus endlich vielen Eingabedaten, gewissen reellen Zahlen $x_1, \dots, x_n$, nur endlich viele Resultatdaten, nämlich weitere reelle Zahlen $y_1, \dots, y_m$, zu berechnen. Ein Problem dieser Art zu

lösen heißt, den Wert $y = \varphi(x)$ einer gewissen Funktion $\varphi : D \rightarrow \mathbb{R}^m$, $D \subseteq \mathbb{R}^n$ zu bestimmen, wobei $y \in \mathbb{R}^m$, $x \in \mathbb{R}^n$ und φ durch m reelle Funktionen φ_i

$$y_i = \varphi_i(x_1, \dots, x_n), \quad i = 1, \dots, m,$$

gegeben ist. Ein Algorithmus ist eine eindeutige Rechenvorschrift zur Berechnung von $\varphi(x)$. In jedem Stadium des Algorithmus sind Zwischenergebnisse gegeben, die wir, etwa im i -ten Stadium uns durch einen reellen Vektor

$$x^{(i)} = \begin{bmatrix} x_1^{(i)} \\ \vdots \\ x_{n_i}^{(i)} \end{bmatrix} \in \mathbb{R}^{n_i}$$

der Länge n_i repräsentiert denken. Der Übergang zum nächsten Stadium $i + 1$ wird durch eine *elementare Abbildung*

$$\varphi^{(i)} : D_i \rightarrow D_{i+1}, \quad D_k \subseteq \mathbb{R}^{n_k},$$

vermittelt, $x^{(i+1)} = \varphi^{(i)}(x^{(i)})$. Die elementaren Abbildungen $\varphi^{(i)}$ sind eindeutig durch den Algorithmus bestimmt, wenn man von trivialen Mehrdeutigkeiten absieht, die von Permutationen der Komponenten der Vektoren $x^{(k)}$ herrühren, d. h. von der im Prinzip willkürlichen Anordnung der Zwischenresultate eines Rechenstadiums in einem Vektor.

Die endliche Sequenz der elementaren Operationen eines Algorithmus entspricht einer Zerlegung von φ in elementare Abbildungen

$$\varphi^{(i)} : D_i \rightarrow D_{i+1}, \quad i = 0, 1, \dots, r, \quad D_j \subseteq \mathbb{R}^{n_j} \quad \text{mit} \quad (1.3.1)$$

$$\varphi = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \dots \circ \varphi^{(0)}, \quad D_0 = D, \quad D_{r+1} \subseteq \mathbb{R}^{n_{r+1}} = \mathbb{R}^m.$$

Beispiel 1: Für die Berechnung von $y = \varphi(a, b, c) := a + b + c$ hat man die beiden Algorithmen

$$\eta := a + b, \quad y := c + \eta, \quad \text{bzw.} \quad \eta := b + c, \quad y := a + \eta.$$

Die Zerlegungen (1.3.1) sind hier gegeben durch

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a + b \\ c \end{bmatrix} \in \mathbb{R}^2, \quad \varphi^{(1)}(u, v) := u + v \in \mathbb{R},$$

bzw.

$$\varphi^{(0)}(a, b, c) := \begin{bmatrix} a \\ b + c \end{bmatrix} \in \mathbb{R}^2, \quad \varphi^{(1)}(u, v) := u + v \in \mathbb{R}.$$

Beispiel 2: Wegen $a^2 - b^2 = (a + b)(a - b)$ hat man für die Berechnung von $\varphi(a, b) := a^2 - b^2$ die beiden Algorithmen:

$$\begin{array}{ll} \text{Algorithmus 1:} & \eta_1 := a \times a, \\ & \eta_2 := b \times b, \\ & y := \eta_1 - \eta_2, \end{array} \quad \begin{array}{ll} \text{Algorithmus 2:} & \eta_1 := a + b, \\ & \eta_2 := a - b, \\ & y := \eta_1 \times \eta_2. \end{array}$$

Die zugehörigen Zerlegungen (1.3.1) sind gegeben durch

Algorithmus 1:

$$\varphi^{(0)}(a, b) := \begin{bmatrix} a^2 \\ b \end{bmatrix}, \quad \varphi^{(1)}(u, v) := \begin{bmatrix} u \\ v^2 \end{bmatrix}, \quad \varphi^{(2)}(u, v) := u - v.$$

Algorithmus 2:

$$\varphi^{(0)}(a, b) := \begin{bmatrix} a \\ b \\ a + b \end{bmatrix}, \quad \varphi^{(1)}(a, b, v) := \begin{bmatrix} v \\ a - b \end{bmatrix}, \quad \varphi^{(2)}(u, v) := u \cdot v.$$

Wir wollen nun die Gründe dafür untersuchen, weshalb verschiedene Algorithmen zur Lösung eines Problems i. a. unterschiedliche Resultate liefern, um Kriterien für die Beurteilung der Güte von Algorithmen zu gewinnen. Dabei spielt die Fortpflanzung der Rundungsfehler eine wichtige Rolle, wie wir zunächst an dem Beispiel der mehrfachen Summe $y = a + b + c$ sehen werden (s. Beispiel 3 von 1.2). Bei Gleitpunktrechnung erhält man statt y einen Näherungswert $\tilde{y} = \text{gl}((a + b) + c)$, für den wegen (1.2.6) gilt

$$\begin{aligned} \eta &:= \text{gl}(a + b) = (a + b)(1 + \varepsilon_1) \\ \tilde{y} &:= \text{gl}(\eta + c) = (\eta + c)(1 + \varepsilon_2) \\ &= [(a + b)(1 + \varepsilon_1) + c](1 + \varepsilon_2) \\ &= (a + b + c) \left[1 + \frac{a + b}{a + b + c} \varepsilon_1 (1 + \varepsilon_2) + \varepsilon_2 \right]. \end{aligned}$$

Für den relativen Fehler $\varepsilon_y := (\tilde{y} - y)/y$ von $\tilde{y}$ gilt daher

$$\varepsilon_y = \frac{a + b}{a + b + c} \varepsilon_1 (1 + \varepsilon_2) + \varepsilon_2$$

oder in erster Näherung bei Vernachlässigung von Termen höherer Ordnung wie $\varepsilon_1 \varepsilon_2$

$$\varepsilon_y \doteq \frac{a + b}{a + b + c} \varepsilon_1 + 1 \cdot \varepsilon_2.$$

Die Verstärkungsfaktoren $(a + b)/(a + b + c)$ bzw. 1 geben an, wie stark sich die Rundungsfehler $\varepsilon_1, \varepsilon_2$ im relativen Fehler ε_y des Resultats auswirken. Der kritische Faktor ist $(a + b)/(a + b + c)$: Je nachdem, ob $|a + b|$ oder $|b + c|$ kleiner ist, ist es günstiger („numerisch stabiler“) die Summe $a + b + c$ nach der Formel $(a + b) + c$ bzw. $a + (b + c)$ zu bilden.

Im Beispiel des letzten Abschnittes ist

$$\frac{a+b}{a+b+c} = \frac{0.33 \dots_{10} 2}{0.64 \dots_{10} 3} \approx \frac{1}{2} 10^5,$$

$$\frac{b+c}{a+b+c} = \frac{0.618 \dots_{10} 3}{0.64 \dots_{10} 3} \approx 0.97,$$

was die höhere Genauigkeit von $\text{gl}(a + (b + c))$ erklärt.

Diese Methode, die Fortpflanzung spezieller Fehler durch Vernachlässigung von Größen höherer Ordnung zu studieren, läßt sich systematisch zu einer *differentiellen Fehleranalyse* des Algorithmus (1.3.1)

$$\varphi = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \dots \circ \varphi^{(0)}$$

zur Berechnung von $\varphi(x)$ ausbauen. Dazu müssen wir untersuchen, wie sich die Eingangsfehler Δx von x und die im Laufe des Algorithmus begangenen Rundungsfehler auf das Endresultat $y = \varphi(x)$ auswirken. Wir wollen dies zunächst nur für die Eingangsfehler Δx ausführen und die dabei gewonnenen Ergebnisse später auf die Fortpflanzung der Rundungsfehler anwenden. Wir setzen dazu voraus, daß die Funktion

$$\varphi : D \rightarrow \mathbb{R}^m, \quad \varphi(x) = \begin{bmatrix} \varphi_1(x_1, \dots, x_n) \\ \vdots \\ \varphi_m(x_1, \dots, x_n) \end{bmatrix}$$

auf einer offenen Teilmenge D des $\mathbb{R}^n$ definiert ist und die Komponentenfunktion φ_i , $i = 1, \dots, m$, von φ auf D stetig differenzierbar sind. Sei $\tilde{x}$ ein Näherungswert für x . Mit

$$\Delta x_j := \tilde{x}_j - x_j, \quad \Delta x := \tilde{x} - x,$$

bezeichnen wir dann den *absoluten Fehler* von $\tilde{x}_i$ bzw. $\tilde{x}$ und als *relativen Fehler* von $\tilde{x}_i$ die Größen

$$\varepsilon_{x_i} := \frac{\tilde{x}_i - x_i}{x_i}, \quad \text{falls } x_i \neq 0.$$

Ersetzt man die Eingabedaten x durch $\tilde{x}$, so erhält man als Resultat $\tilde{y} := \varphi(\tilde{x})$ statt $y = \varphi(x)$. Durch Taylor-Entwicklung ergibt sich unter Vernachlässigung von Größen höherer Ordnung

$$\begin{aligned} \Delta y_i &:= \tilde{y}_i - y_i = \varphi_i(\tilde{x}) - \varphi_i(x) \doteq \sum_{j=1}^n \frac{\partial \varphi_i(x)}{\partial x_j} (\tilde{x}_j - x_j) \\ (1.3.2) \quad &= \sum_{j=1}^n \frac{\partial \varphi_i(x)}{\partial x_j} \Delta x_j, \quad i = 1, \dots, m, \end{aligned}$$

oder in Matrixschreibweise

$$(1.3.3) \quad \Delta y = \begin{bmatrix} \Delta y_1 \\ \vdots \\ \Delta y_m \end{bmatrix} \doteq \begin{bmatrix} \frac{\partial \varphi_1}{\partial x_1} & \cdots & \frac{\partial \varphi_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial \varphi_m}{\partial x_1} & \cdots & \frac{\partial \varphi_m}{\partial x_n} \end{bmatrix} \begin{bmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{bmatrix} = D\varphi(x)\Delta x$$

mit der Funktionalmatrix $D\varphi(x)$.

Dabei soll „ $\doteq$ “ statt „ $=$ “ andeuten, daß die betr. Gleichungen nur in erster Näherung richtig sind. Der Proportionalitätsfaktor $\partial \varphi_i(x)/\partial x_j$ in (1.3.2) mißt die Empfindlichkeit, mit der y_i auf absolute Änderungen Δx_j von x_j reagiert.

Ist $y_i \neq 0$ und $x_j \neq 0$ für alle i und j , so folgt aus (1.3.2) eine Fehlerfortpflanzungsformel für die relativen Fehler:

$$(1.3.4) \quad \varepsilon_{y_i} \doteq \sum_{j=1}^n \frac{x_j}{\varphi_i(x)} \cdot \frac{\partial \varphi_i(x)}{\partial x_j} \cdot \varepsilon_{x_j}$$

Wiederum gibt der Faktor $(x_j/\varphi_i)\partial \varphi_i/\partial x_j$ an, wie stark sich ein relativer Fehler in x_j auf den relativen Fehler von y_i auswirkt. Die Verstärkungsfaktoren $(x_j/\varphi_i)\partial \varphi_i/\partial x_j$ für die relativen Fehler haben den Vorteil, daß sie von der Skalierung der y_i und x_j unabhängig sind. Sind sie groß, spricht man von einem *schlecht konditionierten*, andernfalls von einem *gut konditionierten* Problem. Bei schlecht konditionierten Problemen bewirken kleine relative Fehler in den Eingangsdaten x große relative Fehler in den Resultaten $y = \varphi(x)$. Die hier gegebene Definition der Konditionszahlen hat den Nachteil, daß sie nur für nichtverschwindende y_i, x_j sinnvoll ist. Außerdem ist sie für viele Zwecke zu unpraktisch (die Kondition von φ wird durch $m \cdot n$ Zahlen beschrieben). Es werden deshalb auch andere einfachere Definitionen für die Kondition eines Problems gegeben. So ist es z.B. in der linearen Algebra vielfach üblich, Zahlen c , für die bzgl. einer geeigneten Norm $\|\cdot\|$ gilt

$$\frac{\|\varphi(\tilde{x}) - \varphi(x)\|}{\|\varphi(x)\|} \leq c \cdot \frac{\|\tilde{x} - x\|}{\|x\|}$$

als Konditionszahlen zu bezeichnen (s. Abschnitt 4.4).

Beispiel 3: Für $y = \varphi(a, b, c) := a + b + c$ hat man nach (1.3.4):

$$\varepsilon_y \doteq \frac{a}{a+b+c} \varepsilon_a + \frac{b}{a+b+c} \varepsilon_b + \frac{c}{a+b+c} \varepsilon_c.$$

Das Problem ist gut konditioniert, falls jeder Summand a, b, c klein gegenüber $a + b + c$ ist.

Beispiel 4: Sei $y = \varphi(p, q) := -p + \sqrt{p^2 + q}$. Es ist

$$\frac{\partial \varphi}{\partial p} = -1 + \frac{p}{\sqrt{p^2 + q}} = \frac{-y}{\sqrt{p^2 + q}}, \quad \frac{\partial \varphi}{\partial q} = \frac{1}{2\sqrt{p^2 + q}},$$

so daß

$$\varepsilon_y \doteq \frac{-p}{\sqrt{p^2 + q}} \varepsilon_p + \frac{q}{2y\sqrt{p^2 + q}} \varepsilon_q = -\frac{p}{\sqrt{p^2 + q}} \varepsilon_p + \frac{p + \sqrt{p^2 + q}}{2\sqrt{p^2 + q}} \varepsilon_q.$$

Wegen

$$\left| \frac{p}{\sqrt{p^2 + q}} \right| \leq 1, \quad \left| \frac{p + \sqrt{p^2 + q}}{2\sqrt{p^2 + q}} \right| \leq 1 \quad \text{für } q > 0,$$

ist φ gut konditioniert, falls $q > 0$, und schlecht konditioniert, falls etwa $q \approx -p^2$.

Für die arithmetischen Operationen erhält man aus (1.3.4) die Fehlerfortpflanzungsformeln (für $x \neq 0$, $y \neq 0$)

(1.3.5)

1. $\varphi(x, y) := x \cdot y : \quad \varepsilon_{xy} \doteq \varepsilon_x + \varepsilon_y,$
2. $\varphi(x, y) := x/y : \quad \varepsilon_{x/y} \doteq \varepsilon_x - \varepsilon_y,$
3. $\varphi(x, y) := x \pm y : \quad \varepsilon_{x \pm y} = \frac{x}{x \pm y} \varepsilon_x \pm \frac{y}{x \pm y} \varepsilon_y, \quad \text{falls } x \pm y \neq 0,$
4. $\varphi(x) := \sqrt{x} : \quad \varepsilon_{\sqrt{x}} \doteq \frac{1}{2} \varepsilon_x.$

Es folgt, daß das Multiplizieren, Dividieren und Wurzelziehen keine gefährlichen Operationen sind: Die relativen Fehler der Eingabedaten pflanzen sich nicht stark in das Resultat fort. Dasselbe Situation liegt bei der Addition vor, sofern die Summanden x und y gleiches Vorzeichen haben: Die Konditionszahlen $x/(x + y)$, $y/(x + y)$ liegen zwischen 0 und 1 und ihre Summe ist 1, somit gilt

$$|\varepsilon_{x+y}| \leq \max \{ |\varepsilon_x|, |\varepsilon_y| \}.$$

Ist ein Summand klein gegenüber dem anderen und ist er mit einem großen relativen Fehler behaftet, so hat trotzdem das Resultat $x + y$ nach (1.3.5) nur einen kleinen relativen Fehler, wenn der größere Summand einen kleinen relativen Fehler hat. Man spricht dann von *Fehlerdämpfung*. Wenn dagegen bei der Addition die Summanden x und y verschiedenes Vorzeichen haben, ist mindestens einer der Faktoren $|x/(x + y)|$, $|y/(x + y)|$ größer als 1, und es wird mindestens einer der relativen Fehler ε_x , ε_y verstärkt. Diese Verstärkung ist dann besonders groß, wenn $x \approx -y$ und damit Auslöschung bei Bildung von $x + y$ auftritt.

Wir wollen nun die allgemeine Formel (1.3.3) benutzen, um die Fortpflanzung von Rundungsfehlern bei einem gegebenen Algorithmus zu studieren. Ein Algorithmus zur Berechnung der Funktion $\varphi : D \rightarrow \mathbb{R}^m$, $D \subseteq \mathbb{R}^n$, für gegebenes $x = (x_1, \dots, x_n) \in D$ entspricht einer bestimmten Zerlegung der Abbildung φ in elementare Abbildungen $\varphi^{(i)}$ (1.3.1) und führt von $x^{(0)} := x$ über eine Kette von Zwischenergebnissen

$$(1.3.6) \quad x = x^{(0)} \rightarrow \varphi^{(0)}(x^{(0)}) = x^{(1)} \rightarrow \dots \rightarrow \varphi^{(r)}(x^{(r)}) = x^{(r+1)} = y$$

zum Resultat y . Wir nehmen für die folgende Diskussion wieder an, daß jedes $\varphi^{(i)}$ stetig differenzierbar ist und bezeichnen mit $\psi^{(i)}$ die „Restabbildung“

$$\psi^{(i)} = \varphi^{(r)} \circ \varphi^{(r-1)} \circ \dots \circ \varphi^{(i)} : D_i \rightarrow \mathbb{R}^m, \quad i = 0, 1, 2, \dots, r.$$

Es ist dann $\psi^{(0)} \equiv \varphi$. Mit $D\varphi^{(i)}$ bzw. $D\psi^{(i)}$ bezeichnen wir die Funktionalmatrizen der Abbildungen $\varphi^{(i)}$ bzw. $\psi^{(i)}$. Bekanntlich multiplizieren sich die Funktionalmatrizen, wenn man Abbildungen zusammensetzt

$$D(f \circ g)(x) = Df(g(x))Dg(x).$$

Also gilt für $i = 0, 1, 2, \dots, r$

$$(1.3.7) \quad \begin{aligned} D\varphi(x) &= D\varphi^{(r)}(x^{(r)})D\varphi^{(r-1)}(x^{(r-1)}) \dots D\varphi^{(0)}(x), \\ D\psi^{(i)}(x^{(i)}) &= D\varphi^{(r)}(x^{(r)})D\varphi^{(r-1)}(x^{(r-1)}) \dots D\varphi^{(i)}(x^{(i)}). \end{aligned}$$

In Gleitpunktarithmetik erhält man unter dem Einfluß der Eingangsfehler Δx und der Rundungsfehler statt der exakten Zwischenresultate $x^{(i)}$ Näherungswerte $\tilde{x}^{(i+1)} = \text{gl}(\varphi^{(i)}(\tilde{x}^{(i)}))$. Für die Fehler $\Delta x^{(i)} = \tilde{x}^{(i)} - x^{(i)}$ gilt daher

$$(1.3.8) \quad \Delta x^{(i+1)} = [\text{gl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)})] + [\varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)})].$$

Nun ist wegen (1.3.3) in erster Näherung

$$(1.3.9) \quad \varphi^{(i)}(\tilde{x}^{(i)}) - \varphi^{(i)}(x^{(i)}) \doteq D\varphi^{(i)}(x^{(i)}) \cdot \Delta x^{(i)}.$$

Wenn die elementaren Abbildungen $\varphi^{(i)}$ so beschaffen sind, daß man ähnlich wie bei den elementaren arithmetischen Operationen (s. (1.2.6)) bei der Gleitpunktauswertung von $\varphi^{(i)}$ das gerundete exakte Resultat erhält, so gilt

$$(1.3.10) \quad \text{gl}(\varphi^{(i)}(u)) = \text{rd}(\varphi^{(i)}(u)).$$

Man beachte, daß die Abbildung $\varphi^{(i)} : D_i \rightarrow D_{i+1} \subseteq \mathbb{R}^{n_{i+1}}$ durch einen Vektor

$$\varphi^{(i)}(u) = \begin{bmatrix} \varphi_1^{(i)}(u) \\ \vdots \\ \varphi_{n_{i+1}}^{(i)}(u) \end{bmatrix}$$

von reellen Funktionen $\varphi_j^{(i)} : D_i \rightarrow \mathbb{R}$ gegeben und (1.3.10) komponentenweise zu lesen ist:

$$(1.3.11) \quad \begin{aligned} \text{gl}(\varphi_j^{(i)}(u)) &= \text{rd}(\varphi_j^{(i)}(u)) = (1 + \varepsilon_j) \cdot \varphi_j^{(i)}(u), \\ |\varepsilon_j| &\leq \text{eps}, \quad j = 1, 2, \dots, n_{i+1}. \end{aligned}$$

Dabei ist ε_j der bei der Berechnung der j -ten Komponente von $\varphi^{(i)}$ in Gleitpunktarithmetik auftretende *neue* relative Rundungsfehler.

(1.3.10) läßt sich also in Form

$$\text{gl}(\varphi^{(i)}(u)) = (I + E_{i+1}) \cdot \varphi^{(i)}(u)$$

mit der Einheitsmatrix I und der diagonalen Fehlermatrix

$$E_{i+1} := \begin{bmatrix} \varepsilon_1 & & & 0 \\ & \varepsilon_2 & & \\ & & \ddots & \\ & & & \ddots \\ 0 & & & & \varepsilon_{n_{i+1}} \end{bmatrix}, \quad |\varepsilon_j| \leq \text{eps}$$

schreiben. Damit läßt sich die erste Klammer in (1.3.8) umformen:

$$\text{gl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) = E_{i+1} \cdot \varphi^{(i)}(\tilde{x}^{(i)}).$$

Da $\tilde{x}^{(i)}$ in erster Näherung gleich $x^{(i)}$ ist, gilt ebenso in erster Näherung

$$(1.3.12) \quad \begin{aligned} \text{gl}(\varphi^{(i)}(\tilde{x}^{(i)})) - \varphi^{(i)}(\tilde{x}^{(i)}) &\doteq E_{i+1} \varphi^{(i)}(x^{(i)}) \\ &= E_{i+1} x^{(i+1)} =: \alpha_{i+1}. \end{aligned}$$

α_{i+1} läßt sich als der bei der Auswertung von $\varphi^{(i)}$ in Gleitpunktarithmetik *neu entstehende* absolute Rundungsfehler, die Diagonalelemente von E_{i+1} als die entsprechenden relativen Rundungsfehler interpretieren. Für $\Delta x^{(i+1)}$ gilt daher wegen (1.3.8), (1.3.9) und (1.3.12) in erster Näherung

$$\Delta x^{(i+1)} \doteq \alpha_{i+1} + D\varphi^{(i)}(x^{(i)})\Delta x^{(i)} = E_{i+1} \cdot x^{(i+1)} + D\varphi^{(i)}(x^{(i)})\Delta x^{(i)},$$

wobei $\Delta x^{(0)} := \Delta x$. Man erhält daraus

$$\Delta x^{(1)} \doteq D\varphi^{(0)}\Delta x + \alpha_1$$

$$\Delta x^{(2)} \doteq D\varphi^{(1)}[D\varphi^{(0)}\Delta x + \alpha_1] + \alpha_2$$

$$\Delta y = \Delta x^{(r+1)} \doteq D\varphi^{(r)} \dots D\varphi^{(0)}\Delta x + D\varphi^{(r)} \dots D\varphi^{(1)}\alpha_1 + \dots + \alpha_{r+1}.$$

Wegen (1.3.7) bekommt man so schließlich für den Einfluß des Eingangsfehlers Δx und der Rundungsfehler α_i auf das Resultat $y = x^{(r+1)} = \varphi(x)$ die Formeln

(1.3.13)

$$\begin{aligned}\Delta y &\doteq D\varphi(x)\Delta x + D\psi^{(1)}(x^{(1)})\alpha_1 + \cdots + D\psi^{(r)}(x^{(r)})\alpha_r + \alpha_{r+1} \\ &= D\varphi(x)\Delta x + D\psi^{(1)}(x^{(1)})E_1x^{(1)} + \cdots + D\psi^{(r)}(x^{(r)})E_rx^{(r)} + \\ &\quad + E_{r+1}y\end{aligned}$$

Die Größe der Funktionalmatrix $D\psi^{(i)}$ der Restabbildung $\psi^{(i)}$ ist also entscheidend für den Einfluß des bei der Berechnung von $x^{(i)}$ begangenen neuen Rundungsfehlers α_i bzw. E_i .

Beispiel 5: Für die in Beispiel 2 eingeführten Algorithmen zur Berechnung von $y = \varphi(a, b) = a^2 - b^2$ hat man

Algorithmus 1:

$$\begin{aligned}x &= x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a^2 \\ b \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} a^2 \\ b^2 \end{bmatrix}, \quad x^{(3)} = y = a^2 - b^2, \\ \psi^{(1)}(u, v) &= u - v^2, \quad \psi^{(2)}(u, v) = u - v, \\ D\varphi(x) &= (2a, -2b), \\ D\psi^{(1)}(x^{(1)}) &= (1, -2b), \quad D\psi^{(2)}(x^{(2)}) = (1, -1), \\ \alpha_1 &= \begin{bmatrix} \varepsilon_1 a^2 \\ 0 \end{bmatrix}, \quad E_1 = \begin{bmatrix} \varepsilon_1 & 0 \\ 0 & 0 \end{bmatrix}, \quad \alpha_2 = \begin{bmatrix} 0 \\ \varepsilon_2 b^2 \end{bmatrix}, \quad E_2 = \begin{bmatrix} 0 & 0 \\ 0 & \varepsilon_2 \end{bmatrix}, \\ \alpha_3 &= \varepsilon_3(a^2 - b^2), \quad |\varepsilon_i| \leq \text{eps} \quad \text{für } i = 1, 2, 3.\end{aligned}$$

wegen

$$\begin{bmatrix} a \times^* a \\ b \end{bmatrix} - \begin{bmatrix} a^2 \\ b \end{bmatrix} = \begin{bmatrix} \varepsilon_1 a^2 \\ 0 \end{bmatrix}, \quad \begin{bmatrix} a^2 \\ b \times^* b \end{bmatrix} - \begin{bmatrix} a^2 \\ b^2 \end{bmatrix} = \begin{bmatrix} 0 \\ \varepsilon_2 b^2 \end{bmatrix}$$

und $(a^2 -^* b^2) - (a^2 - b^2) = \varepsilon_3(a^2 - b^2)$. Für (1.3.13) erhält man mit $\Delta x = \begin{bmatrix} \Delta a \\ \Delta b \end{bmatrix}$

$$(1.3.14) \quad \Delta y \doteq 2a\Delta a - 2b\Delta b + a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3.$$

Für *Algorithmus 2* erhält man analog

$$\begin{aligned}x &= x^{(0)} = \begin{bmatrix} a \\ b \end{bmatrix}, \quad x^{(1)} = \begin{bmatrix} a \\ b \\ a + b \end{bmatrix}, \quad x^{(2)} = \begin{bmatrix} a + b \\ a - b \end{bmatrix}, \quad x^{(3)} = y = a^2 - b^2, \\ \psi^{(1)}(a, b, u) &:= u(a - b), \quad \psi^{(2)}(u, v) = u \cdot v, \\ D\varphi(x) &= (2a, -2b), \quad D\psi^{(1)}(x^{(1)}) = (a + b, -a - b, a - b), \\ D\psi^{(2)}(x^{(2)}) &= (a - b, a + b), \\ \alpha_1 &= \begin{bmatrix} 0 \\ 0 \\ \varepsilon_1(a + b) \end{bmatrix}, \quad E_1 = \begin{bmatrix} 0 & & \\ & 0 & \\ & & \varepsilon_1 \end{bmatrix}, \\ \alpha_2 &= \begin{bmatrix} 0 \\ \varepsilon_1(a - b) \end{bmatrix}, \quad E_2 = \begin{bmatrix} 0 & \\ & \varepsilon_2 \end{bmatrix}, \\ \alpha_3 &= \varepsilon_3(a^2 - b^2), \quad E_3 = \varepsilon_3, \quad |\varepsilon_i| \leq \text{eps},\end{aligned}$$

und damit aus (1.3.13)

$$(1.3.15) \quad \Delta y \doteq 2a\Delta a - 2b\Delta b + (a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3).$$

Wählt man einen anderen Algorithmus, d. h. eine andere Zerlegung von φ in Elementarabbildungen $\varphi^{(i)}$, so ändert sich zwar $D\varphi$ nicht, wohl aber i. a. die Matrizen $D\psi^{(i)}$, die die Fortpflanzung der Rundungsfehler messen, und damit auch der gesamte Einfluß aller Rundungsfehler, der durch

$$(1.3.16) \quad D\psi^{(1)}\alpha_1 + \dots + D\psi^{(r)}\alpha_r + \alpha_{r+1}$$

gegeben ist.

Man nennt einen Algorithmus *numerisch stabiler* als einen zweiten Algorithmus zur Berechnung von $\varphi(x)$, falls der Gesamteinfluß der Rundungsfehler bei dem ersten Algorithmus kleiner ist als bei dem zweiten.

Beispiel: Der gesamte Rundungsfehlereinfluß von Algorithmus 1 in Beispiel 2 ist wegen (1.3.14)

$$(1.3.17) \quad |a^2\varepsilon_1 - b^2\varepsilon_2 + (a^2 - b^2)\varepsilon_3| \leq (a^2 + b^2 + |a^2 - b^2|)\text{eps},$$

der von Algorithmus 2 wegen (1.3.15)

$$(1.3.18) \quad |(a^2 - b^2)(\varepsilon_1 + \varepsilon_2 + \varepsilon_3)| \leq 3\text{eps}|a^2 - b^2|.$$

Genau für $1/3 \leq |a/b|^2 \leq 3$ gilt $3|a^2 - b^2| \leq a^2 + b^2 + |a^2 - b^2|$: Algorithmus 2 ist deshalb für $1/3 < |a/b|^2 < 3$ numerisch stabiler als Algorithmus 1, für die übrigen a, b ist Algorithmus 1 numerisch stabiler.

Z. B. erhält man für $a := 0.3237$, $b := 0.3134$ bei 4-stelliger Rechnung ($t = 4$):

Algorithmus 1: $a \times^* a = 0.1048$, $b \times^* b = 0.9882_{10-1}$,

$$(a \times^* a) -^* (b \times^* b) = 0.6580_{10-2},$$

Algorithmus 2: $a +^* b = 0.6371$, $a -^* b = 0.1030_{10-1}$,

$$(a \times^* b) \times^* (a -^* b) = 0.6562_{10-2},$$

Exaktes Resultat: $a^2 - b^2 = 0.656213_{10-2}$.

In der Fehlerfortpflanzungsformel (1.3.13) gilt unabhängig von dem benutzten Algorithmus zur Berechnung von $y = \varphi(x)$ für den letzten Term die Abschätzung¹

$$|E_{r+1}y| \leq \text{eps}|y|.$$

Bei jedem Algorithmus muß man mindestens mit einem Fehler Δy dieser Größenordnung $\text{eps}|y|$ rechnen. Weiter beachte man, daß bei Verwendung einer t -stelligen Maschine allein durch das Runden der Eingabedaten $x = (x_1, \dots, x_n)^T$ auf t Stellen ein Eingangsfehler $\Delta^{(0)}x$ mit

¹ Betragszeichen für Vektoren, Matrizen etc. sind komponentenweise zu verstehen, z. B. $|y| = (|y_1|, \dots, |y_m|)^T$.

$$|\Delta^{(0)}x| \leq \text{eps}|x|$$

entsteht, es sei denn, die Eingabedaten, etwa nicht zu große ganze Zahlen, sind bereits Maschinenzahlen und damit exakt darstellbar. Aus diesem Grunde muß man bei jedem Algorithmus zur Berechnung von $y = \varphi(x)$ ebenfalls mindestens mit einem weiteren Fehler der Größenordnung $|D\varphi(x)| |x| \text{eps}$ rechnen, so daß insgesamt bei *jedem* Algorithmus mit einem Fehler der Größe

$$(1.3.19) \quad \Delta^{(0)}y := \text{eps}[|D\varphi(x)| |x| + |y|]$$

zu rechnen ist. $\Delta^{(0)}y$ heißt der *unvermeidbare Fehler* von y . Da man ohnehin mit einem Fehler dieser Größenordnung zu rechnen hat, wäre es unbillig, von einem Rundungsfehler α_i bzw. E_i eines Algorithmus zu verlangen, daß sein Beitrag zum Gesamtfehler wesentlich kleiner als $\Delta^{(0)}$ ist. Wir nennen deshalb einen Rundungsfehler α_i bzw. E_i eines Algorithmus *harmlos*, falls in (1.3.13) sein Beitrag zum Gesamtfehler Δy höchstens dieselbe Größenordnung wie der unvermeidbare Fehler $\Delta^{(0)}y$ (1.3.19) besitzt:

$$|D\psi^{(i)}(x^{(i)})\alpha_i| = |D\psi^{(i)}(x^{(i)})E_ix^{(i)}| \approx \Delta^{(0)}y.$$

Wenn alle Rundungsfehler eines Algorithmus harmlos sind, heißt der Algorithmus *gutartig* (vgl. Bauer (1965)). Eine der wichtigsten Aufgaben der numerischen Mathematik ist es, gutartige Algorithmen zu finden.

Beispiel 6: Beide Algorithmen von Beispiel 2 sind für alle a und b gutartig. Für den unvermeidbaren Fehler $\Delta^{(0)}y$ hat man nämlich

$$\Delta^{(0)}y = \text{eps}([2|a|, 2|b|] \begin{bmatrix} |a| \\ |b| \end{bmatrix} + |a^2 - b^2|) = \text{eps}(2(a^2 + b^2) + |a^2 - b^2|).$$

Ein Vergleich mit (1.3.17), (1.3.18) zeigt sogar, daß der *gesamte* Rundungsfehlereinfluß beider Algorithmen dem Betrage nach höchstens gleich $\Delta^{(0)}y$ ist.

Einfache weitere Beispiele für die eingeführten Begriffe findet man im nächsten Abschnitt.

Der Begriff der Gutartigkeit von Algorithmen ist zentral; die Terminologie ist hier aber, insbesondere bei der Definition der numerischen Stabilität, fließend und oft wenig präzise. So nennt man häufig einen Algorithmus schlechthin „numerisch stabil“, wenn er sich wie ein gutartiger Algorithmus verhält. In diesem Buch verwenden wir den Begriff „numerisch stabil“ nur zum Vergleich zweier Algorithmen, unabhängig davon ob diese Algorithmen gutartig sind oder nicht.

Wir wollen noch auf eine typische Situation hinweisen, in der sich der Begriff der Gutartigkeit bewährt. Häufig verwendet man *zweistufige Algorithmen*

$$x \rightarrow z = \tilde{\varphi}(x) \rightarrow y = \tilde{\psi}(z) = \varphi(x)$$

zur Berechnung einer Funktion $y = \varphi(x)$, $\varphi = \tilde{\psi} \circ \tilde{\varphi}$, die man durch Hintereinanderschalten zweier anderer Algorithmen (Unterprogramme !) zur Berechnung von $z = \tilde{\varphi}(x)$ und von $y = \tilde{\psi}(z)$ erhält. Wir wollen zeigen, daß dies nicht notwendig zu einem gutartigen Algorithmus zur Berechnung von $y = \varphi(x)$ führt, selbst wenn man gutartige Algorithmen zur Berechnung von $z = \tilde{\varphi}(x)$ und $y = \tilde{\psi}(z)$ benutzt. In der Tat erhält man bei der Berechnung von z in Gleitpunktarithmetik bestenfalls einen Näherungswert $\tilde{z}$ mit einem absoluten Fehler $\alpha_z = \tilde{z} - z$ des Betrages

$$|\alpha_z| \approx |z| \text{eps}.$$

Allein dieser Fehler steuert zum absoluten Fehler von y den Anteil $D\tilde{\psi}(z)\alpha_z$ bei, dessen Betrag die Größe $|D\tilde{\psi}(z)||z|\text{eps}$ erreichen kann. Der zweistufige Algorithmus wird sicher *nicht* gutartig sein, falls dieser Betrag sehr viel größer als der unvermeidliche Fehler (1.3.19) $\Delta^{(0)}y$ von y ist,

$$|D\tilde{\psi}(z)||z|\text{eps} \gg \Delta^{(0)}y = (|D\varphi(x)||x| + |y|)\text{eps}.$$

Es kommt hier nur auf die Größenordnung von $|D\tilde{\psi}(z)||z|$ im Vergleich zu $|D\varphi(x)||x|$ an, d. h. (vgl. (1.3.4) auf die *Kondition* der Abbildung $\tilde{\psi}$ im Vergleich mit der Kondition der Abbildung φ : Der Stufenalgorithmus ist nicht gutartig, falls die Kondition von $\tilde{\psi}$ sehr viel schlechter als die von φ ist. Da die Abschätzung nur die *Abbildungen* φ und $\tilde{\psi}$ involviert, gelten diese Aussagen unabhängig davon, welche Teilalgorithmen man zur Berechnung von $z = \tilde{\varphi}(x)$ und von $y = \tilde{\psi}(z)$ verwendet. Man sollte deshalb unbedingt Stufenalgorithmen vermeiden, in denen Zwischenresultate z berechnet werden, von denen das Endresultat y empfindlicher abhängt als von den Eingangsdaten x .

Ein Mittel dazu, für einen Algorithmus die Gutartigkeit nachzuweisen, ist die sog. *backward-analysis*, die von Wilkinson zur Analyse der Algorithmen der linearen Algebra benutzt wurde. Bei dieser Technik wird zunächst versucht zu zeigen, daß das Resultat $\tilde{y} = y + \Delta y$ eines Algorithmus zur Berechnung von $y = \varphi(x)$, das man in Gleitarithmetik bei der Auswertung von $\varphi(x)$ erhält, sich in der Form $\tilde{y} = \varphi(x + \Delta x)$ schreiben läßt und damit als Resultat einer exakten Rechnung mit abgeänderten Eingabedaten $x + \Delta x$ interpretiert werden kann. Kann man zusätzlich zeigen, daß Δx höchstens dieselbe Größenordnung wie $|\Delta^{(0)}x| \leq \text{eps}|x|$ hat, so ist damit die Gutartigkeit des Algorithmus gezeigt.

Zum Schluß soll noch kurz anhand eines Beispiels dargestellt werden, wie man das Fehlerverhalten eines Algorithmus statt durch (1.3.13) auch

mit Hilfe eines *Graphen* veranschaulichen kann, wie von Bauer (1974) vorgeschlagen wurde. Die Algorithmen 1 und 2 von Beispiel 2 werden so durch die Graphen von Fig. 1 beschrieben.




Fig. 1. Graphendarstellung der Fehlerfortpflanzung von Algorithmen

Die Knoten entsprechen den Zwischenresultaten. Knoten i wird mit Knoten j durch eine gerichtete Kante verbunden, falls das Zwischenresultat von Knoten i direkt in das Zwischenresultat von Knoten j eingeht. Dementsprechend entsteht an jedem Knoten ein neuer relativer Rundungsfehler, der neben den betreffenden Knoten geschrieben wird. Die Zahlen an den Kanten geben die Verstärkungsfaktoren für die relativen Fehler an. Z. B. kann man vom Graphen des Algorithmus 1 folgende Beziehungen ablesen:

$$\varepsilon_{\eta_1} = 1 \cdot \varepsilon_a + 1 \cdot \varepsilon_a + \varepsilon_1, \quad \varepsilon_{\eta_2} = 1 \cdot \varepsilon_b + 1 \cdot \varepsilon_b + \varepsilon_2,$$

$$\varepsilon_y = \frac{\eta_1}{\eta_1 - \eta_2} \cdot \varepsilon_{\eta_1} - \frac{\eta_2}{\eta_1 - \eta_2} \cdot \varepsilon_{\eta_2} + \varepsilon_3.$$

Will man den Faktor wissen, mit dem multipliziert der Rundungsfehler von Knoten i zum relativen Fehler des Zwischenresultats von Knoten j beiträgt, hat man für jeden gerichteten Weg von i nach j die Kantenfaktoren zu multiplizieren und diese Produkte zu summieren. Z. B. besagt der Graph von Algorithmus 2, daß zum Fehler ε_y der Eingangsfehler ε_a den Beitrag

$$\left(\frac{a}{a+b} \cdot 1 + \frac{a}{a-b} \cdot 1 \right) \cdot \varepsilon_a$$

liefert.

1.4 Beispiele

Beispiel 1 schließt sich an Beispiel 4 des letzten Abschnittes an. Es sei $p > 0, q > 0, p \gg q$ gegeben. Man bestimme die Wurzel

$$y = -p + \sqrt{p^2 + q}$$

kleinsten Betrages der quadratischen Gleichung

$$y^2 + 2py - q = 0.$$

Eingangsdaten: p, q . Resultat: $y = \varphi(p, q) = -p + \sqrt{p^2 + q}$.

Im letzten Abschnitt sahen wir, daß das Problem $\varphi(p, q)$ zu berechnen, für $p > 0, q > 0$ gut konditioniert ist, und die relativen Eingangsfehler $\varepsilon_p, \varepsilon_q$ zum relativen Fehler des Resultates y folgenden Beitrag leisten

$$\frac{-p}{\sqrt{p^2 + q}} \varepsilon_p + \frac{q}{2y\sqrt{p^2 + q}} \varepsilon_q = \frac{-p}{\sqrt{p^2 + q}} \varepsilon_p + \frac{p + \sqrt{p^2 + q}}{2\sqrt{p^2 + q}} \varepsilon_q.$$

Wegen

$$\left| \frac{p}{\sqrt{p^2 + q}} \right| \leq 1, \quad \left| \frac{p + \sqrt{p^2 + q}}{2\sqrt{p^2 + q}} \right| \leq 1$$

genügt der unvermeidbare Fehler $\Delta^{(0)}y$ des Resultates $y = \varphi(p, q)$ den Ungleichungen

$$\text{eps} \leq \varepsilon_y^{(0)} := \frac{\Delta^{(0)}y}{y} \leq 3 \text{ eps}.$$

Wir untersuchen zwei Algorithmen zur Berechnung von $y = \varphi(p, q)$,

Algorithmus 1:

$$\begin{aligned} s &:= p^2, \\ t &:= s + q, \\ u &:= \sqrt{t}, \\ y &:= -p + u. \end{aligned}$$

Wie man sieht, tritt wegen $p \gg q$ bei $y := -p + u$ Auslöschung auf und es steht zu erwarten, daß der Rundungsfehler

$$\Delta u := \varepsilon \cdot \sqrt{t} = \varepsilon \cdot \sqrt{p^2 + q}.$$

der bei der Gleitpunktberechnung der Quadratwurzel

$$\text{gl}(\sqrt{t}) = \sqrt{t} \cdot (1 + \varepsilon), \quad |\varepsilon| \leq \text{eps},$$

neu entsteht, verstärkt wird. In der Tat verursacht dieser Fehler folgenden relativen Fehler von y :

$$\varepsilon_y \doteq \frac{1}{y} \Delta u = \frac{\sqrt{p^2 + q}}{-p + \sqrt{p^2 + q}} \cdot \varepsilon = \frac{1}{q} (p\sqrt{p^2 + q} + p^2 + q) \varepsilon = k \cdot \varepsilon.$$

Wegen $p, q > 0$ gilt für den Verstärkungsfaktor k die Abschätzung

$$k > \frac{2p^2}{q} > 0.$$

Er kann für $p \gg q$ sehr groß sein und zeigt, daß der vorgeschlagene Algorithmus nicht gutartig ist, weil allein der Einfluß des Rundungsfehlers ε , der bei der Berechnung von $\sqrt{p^2 + q}$ anfällt, viel größer als der relative unvermeidbare Fehler $\varepsilon_y^{(0)}$ ist.

Algorithmus 2:

$$\begin{aligned} s &:= p^2, \\ t &:= s + q, \\ u &:= \sqrt{t}, \\ v &:= p + u, \\ y &:= q/v. \end{aligned}$$

Bei diesem Algorithmus tritt bei der Berechnung von v keine Auslöschung auf. Der bei der Berechnung von $u = \sqrt{t}$ entstehende Rundungsfehler $\Delta u = \varepsilon \sqrt{p^2 + q}$ steuert, durch die entsprechende Restabbildung $\psi(u)$

$$u \rightarrow p + u \rightarrow \frac{q}{p + u} =: \psi(u)$$

verstärkt, folgenden Betrag zum relativen Fehler ε_y von y bei:

$$\begin{aligned} \frac{1}{y} \frac{\partial \varphi}{\partial u} \Delta u &= \frac{-q}{y(p + u)^2} \cdot \Delta u \\ &= \frac{-q\sqrt{p^2 + q}}{\left(-p + \sqrt{p^2 + q}\right)\left(p + \sqrt{p^2 + q}\right)^2} \cdot \varepsilon \\ &= -\frac{\sqrt{p^2 + q}}{p + \sqrt{p^2 + q}} \cdot \varepsilon = k \cdot \varepsilon. \end{aligned}$$

Der Verstärkungsfaktor k ist klein, $|k| < 1$, Algorithmus 2 ist gutartig.

Das folgende *Zahlenbeispiel* illustriert den Unterschied zwischen den Algorithmen 1 und 2 (wie bei weiteren numerischen Beispielen mit 40 Binär-Mantissenstellen gerechnet, was etwa 12 Dezimalstellen entspricht; unrichtige Ziffern sind unterstrichen):

$$p = 1000, q = 0.018\,000\,000\,081$$

Resultat für y nach Algorithmus 1: $0.900\,030\,136\,108_{10}-5$

Resultat für y nach Algorithmus 2: $0.899\,999\,999\,999_{10}-5$

Exakter Wert von y : $0.900\,000\,000\,000_{10}-5$

Beispiel 2: Mit Hilfe der Formel

$$\cos(m+1)x = 2 \cos x \cos mx - \cos(m-1)x, \quad m = 1, 2, \dots, k-1,$$

kann man $\cos kx$ für festes x und ganzzahliges k rekursiv berechnen. Man hat dazu nur einmal mit $c := \cos x$ eine trigonometrische Funktion auszuwerten. Sei nun $|x| \neq 0$ eine kleine Zahl. Bei der Berechnung von c entstehe ein kleiner Rundungsfehler,

$$\tilde{c} = (1 + \varepsilon) \cos x, \quad |\varepsilon| \leq \text{eps}.$$

Wie wirkt sich dieser Rundungsfehler auf $\cos kx$ aus?

Antwort: $\cos kx$ hängt in folgender Weise von c ab:

$$\cos kx = \cos(k \arccos c) =: f(c).$$

Wegen

$$\frac{df}{dc} = \frac{k \sin kx}{\sin x}$$

bewirkt der absolute Fehler $\varepsilon \cos x$ von c in erster Näherung einen absoluten Fehler

$$(1.4.1) \quad \Delta \cos kx \doteq \varepsilon \frac{\cos x}{\sin x} k \sin kx = \varepsilon k \operatorname{ctg} x \sin kx$$

in $\cos kx$.

Der unvermeidbare Fehler $\Delta^{(0)} c_k$ (1.3.19) des Resultats $c_k := \cos kx$ ist dagegen

$$\Delta^{(0)} c_k = \text{eps}[k|x \sin kx| + |\cos kx|].$$

Ein Vergleich mit (1.4.1) zeigt, daß $\Delta \cos kx$ für kleines $|x|$ wesentlich größer als $\Delta^{(0)} c_k$ sein kann: Der Algorithmus ist für solche x nicht gutartig.

Beispiel 3: Für eine gegebene Zahl x und eine „große“ ganze Zahl k sollen $\cos kx$ und $\sin kx$ rekursiv mit Hilfe der Formeln

$$\cos mx := \cos x \cos(m-1)x - \sin x \sin(m-1)x,$$

$$\sin mx := \sin x \cos(m-1)x + \cos x \sin(m-1)x, \quad m = 1, 2, \dots, k,$$

berechnet werden.

Wie wirken sich kleine Fehler $\varepsilon_c \cos x$, $\varepsilon_s \sin x$ bei der Berechnung von $\cos x$, $\sin x$ auf die Endresultate $\cos kx$, $\sin kx$ aus? Setzt man zur Abkürzung $c_m := \cos mx$, $s_m := \sin mx$, $c := \cos x$, $s := \sin x$, so ist in Matrixschreibweise mit der unitären Matrix

$$U := \begin{bmatrix} c & -s \\ s & c \end{bmatrix},$$

die einer Drehung um den Winkel x entspricht,

$$\begin{bmatrix} c_m \\ s_m \end{bmatrix} = U \begin{bmatrix} c_{m-1} \\ s_{m-1} \end{bmatrix}, \quad m = 1, \dots, k,$$

und daher

$$\begin{bmatrix} c_k \\ s_k \end{bmatrix} = U^k \begin{bmatrix} c_0 \\ s_0 \end{bmatrix} = U^k \cdot \begin{bmatrix} 1 \\ 0 \end{bmatrix}.$$

Nun ist

$$\frac{\partial U}{\partial c} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \frac{\partial U}{\partial s} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} =: A$$

und daher

$$\begin{aligned} \frac{\partial}{\partial c} U^k &= k U^{k-1}, \\ \frac{\partial}{\partial s} U^k &= A U^{k-1} + U A U^{k-2} + \dots + U^{k-1} A = k A U^{k-1}, \end{aligned}$$

weil A mit U vertauschbar ist. Da U einer Drehung im $\mathbb{R}^2$ um den Winkel x entspricht, ist schließlich

$$\begin{aligned} \frac{\partial}{\partial c} U^k &= k \begin{bmatrix} \cos(k-1)x & -\sin(k-1)x \\ \sin(k-1)x & \cos(k-1)x \end{bmatrix}, \\ \frac{\partial}{\partial s} U^k &= k \begin{bmatrix} -\sin(k-1)x & -\cos(k-1)x \\ \cos(k-1)x & -\sin(k-1)x \end{bmatrix}. \end{aligned}$$

Die relativen Fehler ε_c , ε_s von $c = \cos x$ und $s = \sin x$ bewirken daher bei $\cos kx$, $\sin kx$ folgende absolute Fehler:

$$\begin{aligned} (1.4.2) \quad \begin{bmatrix} \Delta c_k \\ \Delta s_k \end{bmatrix} &\doteq \begin{bmatrix} \frac{\partial}{\partial c} U^k \\ \frac{\partial}{\partial s} U^k \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \cdot \varepsilon_c \cos x + \begin{bmatrix} \frac{\partial}{\partial s} U^k \\ \frac{\partial}{\partial c} U^k \end{bmatrix} \begin{bmatrix} 1 \\ 0 \end{bmatrix} \cdot \varepsilon_s \sin x \\ &= \varepsilon_c k \cos x \begin{bmatrix} \cos(k-1)x \\ \sin(k-1)x \end{bmatrix} + \varepsilon_s k \sin x \begin{bmatrix} -\sin(k-1)x \\ \cos(k-1)x \end{bmatrix}. \end{aligned}$$

Die unvermeidbaren Fehler (1.3.19) $\Delta^{(0)} c_k$ und $\Delta^{(0)} s_k$ von $c_k = \cos kx$ und $s_k = \sin kx$ sind dagegen

$$\begin{aligned} (1.4.3) \quad \Delta^{(0)} c_k &= [k|x \sin kx| + |\cos kx|] \text{eps}, \\ \Delta^{(0)} s_k &= [k|x \cos kx| + |\sin kx|] \text{eps}. \end{aligned}$$

Ein Vergleich mit (1.4.2) zeigt, daß für großes k und $|k \cdot x| \approx 1$ im Gegensatz zum Rundungsfehler ε_s der Einfluß von ε_c auf die Resultate wesentlich größer als die unvermeidbaren Fehler sind. Der Algorithmus ist nicht gutartig, obwohl er als Algorithmus zur Berechnung von c_k allein numerisch stabiler als der Algorithmus von Beispiel 2 ist.

Beispiel 4: Die numerische Stabilität des Algorithmus in Beispiel 3 zur Berechnung von $c_m = \cos mx$, $s_m = \sin mx$, $m = 1, 2, \dots$, für kleines $|x|$ läßt sich weiter verbessern: Es ist

$$\begin{aligned} \cos(m+1)x &= \cos x \cos mx - \sin x \sin mx, \\ \sin(m+1)x &= \sin x \cos mx + \cos x \sin mx, \end{aligned}$$

und es gilt daher für die Differenzen dc_{m+1} und ds_{m+1} aufeinanderfolgender cos- und sin-Werte

$$\begin{aligned} dc_{m+1} &:= \cos(m+1)x - \cos mx \\ &= 2(\cos x - 1) \cos mx - \sin x \sin mx - \cos x \cos mx + \cos mx \\ &= -4 \left(\sin^2 \frac{x}{2} \right) \cos mx + [\cos mx - \cos(m-1)x], \\ ds_{m+1} &:= \sin(m+1)x - \sin mx \\ &= 2(\cos x - 1) \sin mx + \sin x \cos mx - \cos x \sin mx + \sin mx \\ &= -4 \left(\sin^2 \frac{x}{2} \right) \sin mx + [\sin mx - \sin(m-1)x]. \end{aligned}$$

Dies führt zu folgendem Algorithmus zur Berechnung von c_k, s_k für $x > 0$:

$$\begin{aligned} dc_1 &:= -2 \sin^2 \frac{x}{2}, \quad t := 2 dc_1, \\ ds_1 &:= \sqrt{-dc_1(2 + dc_1)}, \\ s_0 &:= 0, \quad c_0 := 1, \end{aligned}$$

und für $m := 1, 2, \dots, k$:

$$\begin{aligned} c_m &:= c_{m-1} + dc_m, & dc_{m+1} &:= t \cdot c_m + dc_m, \\ s_m &:= s_{m-1} + ds_m, & ds_{m+1} &:= t \cdot s_m + ds_m. \end{aligned}$$

Für die Fehleranalyse beachten wir, daß die Werte c_k und s_k Funktionen von $s = \sin(x/2)$ sind:

$$\begin{aligned} c_k &= \cos(2k \arcsin s) =: \varphi_1(s), \\ s_k &= \sin(2k \arcsin s) =: \varphi_2(s). \end{aligned}$$

Ein Fehler $\Delta_s = \varepsilon_s \sin(x/2)$ bei der Berechnung von s bewirkt daher in erster Näherung folgende Fehler in c_k, s_k :

$$\begin{aligned} \Delta c_k &\doteq \frac{\partial \varphi_1}{\partial s} \varepsilon_s \sin \frac{x}{2} = \varepsilon_s \frac{-2k \sin kx}{\cos \frac{x}{2}} \sin \frac{x}{2} \\ &= -2k \operatorname{tg} \frac{x}{2} \sin kx \cdot \varepsilon_s, \\ \Delta s_k &\doteq \frac{\partial \varphi_2}{\partial s} \varepsilon_s \sin \frac{x}{2} = 2k \operatorname{tg} \frac{x}{2} \cos kx \cdot \varepsilon_s. \end{aligned}$$

Ein Vergleich mit den unvermeidbaren Fehlern (1.4.3) zeigt, daß der Fehler ε_s für kleines $|x|$ harmlos ist.

Zahlenbeispiel: $x = 0.001, k = 1000$

Algorithmus	Resultat für $\cos kx$	relativer Fehler
Beispiel 2	0.540 302 <u>121 124</u>	-0.34_{10-6}
Beispiel 3	0.540 302 305 <u>776</u>	-0.17_{10-9}
Beispiel 4	0.540 302 305 <u>865</u>	-0.58_{10-11}
Exakter Wert:	0.540 302 305 868 140 ...	

Beispiel 5: Dieses Beispiel nimmt einige Resultate vorweg, die bei der Analyse der Algorithmen zur Gleichungsauflösung in Abschnitt 4.5 nützlich sind. Gegeben seien die Zahlen $c, a_1, \dots, a_n, b_1, \dots, b_{n-1}$ mit $a_n \neq 0$. Gesucht ist die Lösung β_n der linearen Gleichung

$$(1.4.4) \quad c - a_1 b_1 - \dots - a_{n-1} b_{n-1} - a_n \beta_n = 0.$$

Bei Gleitpunktrechnung erhält man statt der exakten Lösung β_n einen Näherungswert

$$(1.4.5) \quad b_n = \text{gl} \left(\frac{c - a_1 b_1 - \dots - a_{n-1} b_{n-1}}{a_n} \right)$$

auf die folgende Weise:

$$s_0 := c;$$

$$\text{für } j := 1, 2, \dots, n-1$$

$$(1.4.6) \quad s_j := \text{gl}(s_{j-1} - a_j b_j) = (s_{j-1} - a_j b_j (1 + \mu_j))(1 + \alpha_j),$$

$$b_n := \text{gl}(s_{n-1}/a_n) = (1 + \delta) s_{n-1}/a_n,$$

mit $|\mu_j|, |\alpha_j|, |\delta| \leq \text{eps}$. Häufig ist in den Anwendungen $a_n = 1$, in diesem Fall ist $\delta = 0$, wegen $b_n := s_{n-1}$. Wir wollen zwei verschiedene nützliche Abschätzungen für das *Residuum*

$$r := c - a_1 b_1 - \dots - a_n b_n$$

geben. Durch Summation der aus (1.4.6) folgenden Gleichungen

$$s_0 - c = 0,$$

$$\begin{aligned} s_j - (s_{j-1} - a_j b_j) &= s_j - \left(\frac{s_j}{1 + \alpha_j} + a_j b_j \mu_j \right) \\ &= s_j \frac{\alpha_j}{1 + \alpha_j} - a_j b_j \mu_j, \quad j = 1, 2, \dots, n-1, \end{aligned}$$

$$a_n b_n - s_{n-1} = \delta s_{n-1},$$

erhält man

$$r = c - \sum_{i=1}^n a_i b_i = \sum_{j=1}^{n-1} \left(-s_j \frac{\alpha_j}{1 + \alpha_j} + a_j b_j \mu_j \right) - \delta s_{n-1}$$

und damit die erste der gesuchten Abschätzungen

$$(1.4.7) \quad |r| \leq \frac{\text{eps}}{1 - \text{eps}} [\delta' \cdot |s_{n-1}| + \sum_{j=1}^{n-1} (|s_j| + |a_j b_j|)],$$

$$\delta' := \begin{cases} 0 & \text{falls } a_n = 1, \\ 1 & \text{sonst.} \end{cases}$$

Die folgende Abschätzung ist gröber als (1.4.7). Aus (1.4.6) folgt

$$(1.4.8) \quad b_n = \left[c \prod_{k=1}^{n-1} (1 + \alpha_k) - \sum_{j=1}^{n-1} a_j b_j (1 + \mu_j) \prod_{k=j}^{n-1} (1 + \alpha_k) \right] \frac{1 + \delta}{a_n}.$$

Durch Auflösen nach c erhält man

$$(1.4.9) \quad c = \sum_{j=1}^{n-1} a_j b_j (1 + \mu_j) \prod_{k=1}^{j-1} (1 + \alpha_k)^{-1} + a_n b_n (1 + \delta)^{-1} \prod_{k=1}^{n-1} (1 + \alpha_k)^{-1}.$$

Durch vollständige Induktion nach m zeigt man nun leicht, daß aus

$$(1 + \sigma) = \prod_{k=1}^m (1 + \sigma_k)^{\pm 1}, \quad |\sigma_k| \leq \text{eps}, \quad m \cdot \text{eps} < 1$$

folgt

$$|\sigma| \leq \frac{m \cdot \text{eps}}{1 - m \cdot \text{eps}}.$$

Wegen (1.4.9) ergibt dies die Existenz von Zahlen ε_j mit

$$(1.4.10) \quad c = \sum_{j=1}^{n-1} a_j b_j (1 + j \cdot \varepsilon_j) + a_n b_n (1 + (n-1 + \delta') \varepsilon_n),$$

$$|\varepsilon_j| \leq \frac{\text{eps}}{1 - n \cdot \text{eps}}, \quad \delta' := \begin{cases} 0 & \text{falls } a_n = 1, \\ 1 & \text{sonst,} \end{cases}$$

so daß für $r = c - a_1 b_1 - a_2 b_2 - \dots - a_n b_n$ gilt

$$(1.4.11) \quad |r| \leq \frac{\text{eps}}{1 - n \cdot \text{eps}} \left[\sum_{j=1}^{n-1} j |a_j b_j| + (n-1 + \delta') |a_n b_n| \right].$$

Aus (1.4.8) folgt insbesondere die Gutartigkeit unseres Algorithmus zur Berechnung von β_n . In erster Näherung liefert nämlich z. B. der Rundungsfehler α_m folgenden Beitrag zum absoluten Fehler von β_n

$$[(c - a_1 b_1 - a_2 b_2 - \dots - a_m b_m) / a_n] \alpha_m.$$

Dieser Beitrag ist höchstens gleich dem Einfluß

$$\left| \frac{c \cdot \varepsilon_c - a_1 b_1 \varepsilon_{a_1} - \dots - a_m b_m \varepsilon_{\alpha_m}}{a_n} \right| \leq \text{eps} \frac{|c| + \sum_{i=1}^m |a_i b_i|}{|a_n|},$$

den allein Eingangsfehler $\varepsilon_c, \varepsilon_{a_i}$ von c bzw. $a_i, i = 1, \dots, m$, mit $|\varepsilon_c|, |\varepsilon_{a_i}| \leq \text{eps}$ haben. Ähnlich kann man für die übrigen Rundungsfehler μ_k und δ argumentieren.

Gewöhnlich zeigt man die Gutartigkeit dadurch, daß man (1.4.10) im Sinne der backward-analysis interpretiert: Das berechnete b_n ist exakte Lösung der Gleichung

$$c - \bar{a}_1 b_1 - \dots - \bar{a}_n b_n = 0,$$

deren Koeffizienten

$$\bar{a}_j := a_j (1 + j \cdot \varepsilon_j), \quad 1 \leq j \leq n-1,$$

$$\bar{a}_j := a_j (1 + (n-1 + \delta') \varepsilon_n)$$

gegenüber den a_j nur leicht abgeändert sind.

Bei dieser Art von Analyse hat man die Schwierigkeit, erklären zu müssen, für wie große n Fehler der Form $n\varepsilon$, $|\varepsilon| \leq \text{eps}$, noch als Fehler von der Größenordnung der Maschinengenauigkeit eps gelten sollen.

1.5 Intervallrechnung, statistische Rundungsfehlerabschätzungen

Den Einfluß weniger Rundungsfehler kann man noch mit den Methoden von 1.3 abschätzen. Bei einem typischen Algorithmus ist jedoch die Zahl der arithmetischen Operationen und damit die Zahl der einzelnen Rundungsfehler zu groß, um auf diese Weise den Einfluß aller Rundungsfehler bestimmen zu können.

In dieser Situation bieten sich die Techniken der *Intervallrechnung* an, um sichere obere Schranken für den Fehler des Resultats unter dem Einfluß *aller* Eingangs- und Rundungsfehler zu erhalten. Die Intervallrechnung geht davon aus, daß man die exakten Werte der reellen Zahlen $a \in \mathbb{R}$, die im Algorithmus, sei es als Eingangsdaten oder als Zwischen- oder Endresultate auftreten, in der Regel nicht kennt, sondern höchstens kleine Intervalle $\tilde{a} = [a', a'']$, die a enthalten, $a \in \tilde{a}$. Deshalb rechnet man in der Intervallrechnung statt mit reellen Zahlen systematisch mit Intervallen

$$\tilde{a} = [a', a''],$$

die durch Maschinenzahlen $a', a'' \in A$ begrenzt sind. Die arithmetischen Operationen $\oplus \in \{\oplus, \ominus, \otimes, \oslash\}$ zwischen zwei Intervallen werden dabei so definiert, daß sie mit den entsprechenden arithmetischen Operationen $\star \in \{+, -, \times, /\}$ *verträglich* sind. D. h., $\tilde{c} := \tilde{a} \oplus \tilde{b}$ wird als das kleinste durch Maschinenzahlen begrenzte Intervall definiert mit

$$\tilde{c} \supset \{a \star b \mid a \in \tilde{a} \text{ und } b \in \tilde{b}\}.$$

Im Fall der Addition führt dies zu der Definition

$$[c', c''] = [a', a''] \oplus [b', b'']$$

mit

$$\begin{aligned} c' &:= \max\{\gamma' \in A \mid \gamma' \leq a' + b'\}, \\ c'' &:= \min\{\gamma'' \in A \mid \gamma'' \geq a'' + b''\}, \end{aligned}$$

und im Fall der Multiplikation $\otimes$ ist für $a' > 0$, $b' > 0$ das Produkt

$$[c', c''] = [a', a''] \otimes [b', b'']$$

gegeben durch

$$c' := \max\{\gamma' \in A \mid \gamma' \leq a' \times b'\},$$

$$c'' := \min\{\gamma'' \in A \mid \gamma'' \geq a'' \times b''\}.$$

Wenn man auf diese Weise in einem Algorithmus jede Größe durch ein Intervall und jede Gleitpunktoperation durch die entsprechende Intervalloperation ersetzt, erhält man *Intervallalgorithmen*. Als Resultate liefern sie Intervalle, die die gesuchten exakten Resultate sicher enthalten. Eingangsdaten dieser Algorithmen sind natürlich ebenfalls Intervalle, die so groß gewählt werden, daß sie die exakten Daten unter Berücksichtigung von Eingangsfehlern enthalten.

Das Instrument der Intervallrechnung sollte man aber nicht unkritisch einsetzen: Man wird in der Regel viel zu pessimistische Fehlerschranken erhalten wenn man lediglich in den üblichen Algorithmen alle Gleitpunktopoperationen durch Intervalloperationen ersetzt, weil dabei keine Rücksicht genommen wird, wie bestimmte früher gemachte Fehler in die Berechnung eines neuen Resultats eingehen. So kommt es relativ häufig vor, daß ein bestimmter Rundungsfehler ε einige Zwischenresultate $u_1, \dots, u_n$ eines Algorithmus empfindlich beeinflußt,

$$\left| \frac{\partial u_i}{\partial \varepsilon} \right| \gg 1 \quad \text{für } i = 1, \dots, n,$$

nicht aber das Endresultat $y = f(u_1, \dots, u_n)$,

$$\left| \frac{\partial y}{\partial \varepsilon} \right| \leq 1,$$

das aus den sehr ungenauen Zwischenresultaten $u_1, \dots, u_n$ berechnet wird (es liegt dann ein Fall von *Fehlerdämpfung* vor).

Beispiel 1: Der Wert $y = \phi(x)$ des Polynoms

$$\phi(x) = x^3 - 3x^2 + 3x \equiv ((x - 3) \cdot x + 3) \cdot x$$

kann man mit folgendem Algorithmus berechnen (Horner-Schema, siehe (5.5.1))

$$u := x - 3,$$

$$v := u \times x,$$

$$w := v + 3,$$

$$y := w \times x.$$

Weiß man, daß x in dem Intervall $\tilde{x} := [0.9, 1.1]$ liegt, so erhält man bei einfacher Intervallrechnung

$$\tilde{u} = \tilde{x} \ominus [3, 3] = [-2.1, -1.9],$$

$$\tilde{v} = \tilde{u} \otimes \tilde{x} = [-2.31, -1.71],$$

$$\tilde{w} = \tilde{v} \oplus [3, 3] = [0.69, 1.29],$$

$$\tilde{y} = \tilde{w} \otimes \tilde{x} = [0.621, 1.419].$$

Das Intervall $\tilde{y}$ ist viel zu groß, wenn man es mit dem Intervall

$$\{\phi(x) | x \in \tilde{x}\} = [0.999, 1.001]$$

vergleicht, das den wirklichen Einfluß eines Fehlers in x auf $\phi(x)$ beschreibt.

Beispiel 2: Bei Beispiel 1 würde schon die grobe 2-stellige Gleitpunktarithmetik realistischere Resultate liefern

	$x = 0.9$	$x = 1.1$
u	-2.1	-1.9
v	-1.9	-2.1
w	1.1	0.9
y	0.99	0.99

Für einen erfolgreichen Einsatz der Intervallrechnung reicht es deshalb nicht aus, Intervallvarianten der üblichen Algorithmen zu verwenden. Man muß stattdessen neue Algorithmen entwickeln, für die die Fortpflanzung der Rundungsfehler für die Intervallrechnung günstiger ist, so daß es zu keinen groben Überschätzungen der Fehlerintervalle kommt.

Beispiel 3: Im Beispiel 1 genügt eine einfache Umformung von $\varphi(x)$:

$$y = \varphi(x) = 1 + (x - 1)^3.$$

Dies führt bei dem gleichen Anfangsintervall $\tilde{x} = [0.9, 1.1]$ wie bei Beispiel 1 zu einem neuen Intervallalgorithmus, der jetzt sogar das optimale Resultat liefert:

$$\begin{aligned}\tilde{u}_1 &:= \tilde{x} \ominus [1, 1] = [-0.1, 0.1], \\ \tilde{u}_2 &:= \tilde{u}_1 \otimes \tilde{u}_1 = [-0.01, 0.01], \\ \tilde{u}_3 &:= \tilde{u}_2 \otimes \tilde{u}_1 = [-0.001, 0.001], \\ \tilde{y} &:= \tilde{u}_3 \oplus [1, 1] = [0.999, 1.001].\end{aligned}$$

Bei Verwendung der üblichen Gleitpunktarithmetik erhält man keine signifikanten Unterschiede zwischen den Algorithmen der Beispiele 1 und 3: Bei 2-stelliger Rechnung bekommt man praktisch die gleichen Resultate wie in Beispiel 2:

	$x = 0.9$	$x = 1.1$
u_1	-0.1	0.1
u_2	0.01	0.01
u_3	-0.001	0.001
y	1.0	1.0

Für eine eingehende Behandlung der Intervallarithmetik sei auf die Literatur verwiesen, z.B. Moore (1966) und Kulisch (1969). Für die Programmierung von Intervallalgorithmen stehen mittlerweile einschlägige Programmiersprachen zur Verfügung, z.B. die Erweiterung PASCAL-XSC von PASCAL [s. Klatte et al. (1991)].

Grundlage von *statistischen* Rundungsfehlerabschätzungen (siehe Rademacher(1948)), ist die Annahme, daß die relativen Rundungsfehler ε (siehe (1.2.6)), die bei den elementaren arithmetischen Operationen entstehen als *Zufallsvariable* mit Werten im Intervall $[-\text{eps}, \text{eps}]$ aufgefaßt werden können. Darüber hinaus nimmt man an, daß diese elementaren Zufallsvariablen ε unabhängig sind, wenn sie zu verschiedenen Elementaroperationen gehören. Mit μ_ε bezeichnen wir den Mittelwert, mit σ_ε die Streuung (σ_ε^2 die Varianz) der Zufallsvariablen ε . Für sie gelten mit dem Erwartungswert-Operator E die aus der mathematischen Statistik bekannten Beziehungen

$$\mu_\varepsilon = E(\varepsilon), \quad \sigma_\varepsilon^2 = E(\varepsilon - E(\varepsilon))^2 = E(\varepsilon^2) - (E(\varepsilon))^2 = \mu_{\varepsilon^2} - \mu_\varepsilon^2.$$

Unter der weiteren Annahme, daß die Zufallsvariable ε auf dem Intervall $[-\text{eps}, \text{eps}]$ *gleichverteilt* ist, erhält man die expliziten Formeln

$$(1.5.1) \quad \mu_\varepsilon = E(\varepsilon) = 0, \quad \sigma_\varepsilon^2 = E(\varepsilon^2) = \frac{1}{2\text{eps}} \int_{-\text{eps}}^{\text{eps}} t^2 dt = \frac{1}{3} \text{eps}^2 =: \bar{\varepsilon}^2.$$

Eine genauere Untersuchung zeigt jedoch (siehe Sterbenz (1974)), daß die Annahme der Gleichverteilung nicht ganz richtig ist. Man sollte deshalb nicht vergessen, daß man mit dieser Annahme ideale Rundungsfehler modelliert, die das Verhalten der tatsächlichen elementaren Rundungsfehler in Rechnern zwar sehr gut, aber nur näherungsweise beschreiben. Um bessere Ansätze als (1.5.1) für μ_ε und σ_ε^2 zu erhalten, wird man gegebenenfalls auf empirische Untersuchungen zurückgreifen müssen.

Die Resultate x eines Algorithmus werden unter dem Einfluß der Rundungsfehler selbst Zufallsvariable mit Erwartungswert μ_x und Varianz σ_x^2 sein, für die ebenfalls gilt

$$\sigma_x^2 = E(x - E(x))^2 = E(x^2) - (E(x))^2 = \mu_{x^2} - \mu_x^2.$$

Die Fortpflanzung früherer Rundungsfehler unter den Elementaroperationen werden für beliebige Zufallsvariable x, y und Zahlen $\alpha, \beta \in \mathbb{R}$ durch folgende Regeln beschrieben

$$(1.5.2) \quad \begin{aligned} \mu_{\alpha x \pm \beta y} &= E(\alpha x \pm \beta y) = \alpha E(x) \pm \beta E(y) = \alpha \mu_x \pm \beta \mu_y, \\ \sigma_{\alpha x \pm \beta y}^2 &= E((\alpha x \pm \beta y)^2) - (E(\alpha x \pm \beta y))^2 \\ &= \alpha^2 E(x - E(x))^2 + \beta^2 E(y - E(y))^2 = \alpha^2 \sigma_x^2 + \beta^2 \sigma_y^2. \end{aligned}$$

Die erste dieser Formeln gilt für beliebige Zufallsvariable wegen der Linearität des Erwartungswert-Operators E . Die zweite gilt nur für *unabhängige* Zufallsvariable x, y , da hier die Beziehung $E(x \cdot y) = E(x) \cdot E(y)$ zum Beweis benötigt wird. Ebenso erhält man für unabhängige Zufallsvariable x, y

$$\begin{aligned}
 \mu_{x \times y} &= E(x \times y) = E(x)E(y) = \mu_x \mu_y, \\
 (1.5.3) \quad \sigma_{x \times y}^2 &= E[x \times y - E(x)E(y)]^2 = \mu_{x^2} \mu_{y^2} - \mu_x^2 \mu_y^2 \\
 &= \sigma_x^2 \sigma_y^2 + \mu_x^2 \sigma_y^2 + \mu_y^2 \sigma_x^2.
 \end{aligned}$$

Beispiel: Für die Berechnung von $y = a^2 - b^2$ (siehe Beispiel 2 in 1.3) findet man unter Verwendung von (1.5.1), $E(a) = a$, $\sigma_a^2 = 0$, $E(b) = b$, $\sigma_b^2 = 0$ und von (1.5.2), (1.5.3)

$$\eta_1 = a^2(1 + \varepsilon_1), \quad E(\eta_1) = a^2, \quad \sigma_{\eta_1}^2 = a^4 \bar{\varepsilon}^2,$$

$$\eta_2 = b^2(1 + \varepsilon_2), \quad E(\eta_2) = b^2, \quad \sigma_{\eta_2}^2 = b^4 \bar{\varepsilon}^2,$$

$$y = (\eta_1 - \eta_2)(1 + \varepsilon_3), \quad E(y) = E(\eta_1 - \eta_2)E(1 + \varepsilon_3) = a^2 - b^2,$$

($\eta_1, \eta_2, \varepsilon_3$ werden hier als unabhängige Zufallsvariable angenommen),

$$\begin{aligned}
 \sigma_y^2 &= \sigma_{\eta_1 - \eta_2}^2 \sigma_{1 + \varepsilon_3}^2 + \mu_{\eta_1 - \eta_2}^2 \sigma_{1 + \varepsilon_3}^2 + \mu_{1 + \varepsilon_3}^2 \sigma_{\eta_1 - \eta_2}^2 \\
 &= (\sigma_{\eta_1}^2 + \sigma_{\eta_2}^2) \bar{\varepsilon}^2 + (a^2 - b^2)^2 \bar{\varepsilon}^2 + 1(\sigma_{\eta_1}^2 + \sigma_{\eta_2}^2) \\
 &= (a^4 + b^4) \bar{\varepsilon}^4 + [(a^2 - b^2)^2 + a^4 + b^4] \bar{\varepsilon}^2.
 \end{aligned}$$

Bei Vernachlässigung von $\bar{\varepsilon}^4$ gegenüber $\bar{\varepsilon}^2$ erhält man in erster Ordnung die Formel

$$\sigma_y^2 \doteq ((a^2 - b^2)^2 + a^4 + b^4) \bar{\varepsilon}^2.$$

Für $a := 0.3237$, $b = 0.3134$, $\text{eps} = 5 \times 10^{-4}$ (siehe Beispiel 5 in 1.3) finden wir die Streuung

$$\sigma_y \doteq 0.144 \bar{\varepsilon} = 0.000\,0415,$$

die die gleiche Größenordnung wie der wahre Fehler $\Delta y = 0.000\,01787$ besitzt, den wir bei 4-stelliger Rechnung erhalten. Man vergleiche σ_y mit der Fehlerschranke 0.000 10478, die von (1.3.17) geliefert wird.

Wir bezeichnen mit $M(x)$ die Menge aller Größen, die bei einem gegebenen Algorithmus direkt oder indirekt in die Berechnung von x eingegangen sind. Falls $M(x) \cap M(y) \neq \emptyset$, werden die Zufallsvariablen x und y im allgemeinen abhängig sein. Die exakte statistische Rundungsfehlerabschätzung wird bei einem Algorithmus aber extrem schwierig, wenn man Abhängigkeiten berücksichtigen will. Sie motiviert die folgenden weiteren Voraussetzungen, die die Analyse erheblich vereinfachen:

(1.5.4)

- Die Operanden jeder arithmetischen Operation sind unabhängige Zufallsvariable.
- Bei der Berechnung der Varianzen werden nur die Terme niedrigster Ordnung in eps berücksichtigt.

(c) *Alle Varianzen sind so klein, daß für jede arithmetische Operation $\star$ in erster Näherung gilt*

$$E(x \star y) \doteq E(x) \star E(y) = \mu_x \star \mu_y.$$

Wenn man zusätzlich die Erwartungswerte μ_x von x durch x ersetzt und relative Varianzen $\varepsilon_x^2 := \sigma_x^2 / \mu_x^2 \approx \sigma_x^2 / x^2$ einführt, erhält man aus (1.5.2), (1.5.3) (vergleiche 1.2.6), (1.3.5)) die Formeln

$$(1.5.5) \quad \begin{aligned} z = \text{gl}(x \pm y) : \quad \varepsilon_z^2 &\doteq \left(\frac{x}{z}\right)^2 \varepsilon_x^2 + \left(\frac{y}{z}\right)^2 \varepsilon_y^2 + \bar{\varepsilon}^2, \\ z = \text{gl}(x \pm y) : \quad \varepsilon_z^2 &\doteq \varepsilon_x^2 + \varepsilon_y^2 + \bar{\varepsilon}^2, \\ z = \text{gl}(x/y) : \quad \varepsilon_z^2 &\doteq \varepsilon_x^2 + \varepsilon_y^2 + \bar{\varepsilon}^2. \end{aligned}$$

Man beachte aber, daß diese Relationen nur unter der Annahme (1.5.4), insbesondere (1.5.4a) gültig sind.

Es ist möglich, diese Formeln im Verlauf eines Algorithmus mitzube rechnen. Man erhält so Schätzwerte für die relativen Varianzen der Endresultate. Wie in der Intervallrechnung führt dies zu modifizierten Algorithmen, die mit Paaren (x, ε_x^2) von Größen arbeiten, die über elementare Operationen entsprechend (1.5.5) oder analogen Formeln zusammenhängen. Fehler-schranken für die Endresultate r erhält man dann aus den relativen Varianzen ε_r^2 mit Hilfe der weiteren Annahme, daß die Endvariablen r *normalverteilt* sind. Diese Annahme ist in der Regel gerechtfertigt, weil die Verteilung von r und von Zwischenresultaten x umso besser durch eine Normalverteilung approximiert wird, je mehr unabhängige Rundungsfehler in ihre Berechnung eingeflossen sind. Unter dieser Normalitätsannahme folgt jedenfalls, daß der relative Fehler eines Resultats r mit der Wahrscheinlichkeit 0.9 dem Betrag nach höchstens gleich $2\varepsilon_r$ ist.

Übungsaufgaben zu Kapitel 1

1. Man zeige, daß bei t -stelliger dezimaler Gleitpunktrechnung analog zu (1.2.2) gilt

$$\text{rd}(a) = \frac{a}{1 + \varepsilon} \quad \text{mit} \quad |\varepsilon| \leq 5 \cdot 10^{-t}.$$

(Daher gilt neben (1.2.6) auch $\text{gl}(a * b) = (a * b) / (1 + \varepsilon)$ mit $|\varepsilon| \leq 5 \cdot 10^{-t}$ für alle arithmetischen Operationen $*$ = +, −, /.)

2. a, b, c seien Festkommazahlen mit N Dezimalstellen hinter dem Komma und $0 < a, b, c < 1$. Das Produkt $a * b$ sei wie folgt erklärt: Zu $a \cdot b$ wird

$10^{-N}/2$ addiert, danach werden $(n+1)$ -te und die folgenden Dezimalstellen weggelassen.

a) Man gebe eine Schranke für $|(a * b) * c - abc|$ an.

b) Um wieviele Einheiten der N -ten Stelle können sich $(a * b) * c$ und $a * (b * c)$ unterscheiden ?

3. Bei der Gleitpunktberechnung von $\sum_{i=1}^n a_i$ kann ein beliebig großer relativer Fehler auftreten, der jedoch beschränkt bleibt, falls alle a_i das gleiche Vorzeichen haben. Man leite unter Vernachlässigung von Gliedern höherer Ordnung eine grobe Schranke für ihn her.

4. Die folgenden Ausdrücke sollen so umgeformt werden, daß ihre Auswertung gutartig wird:

$$\begin{aligned} \frac{1}{1+2x} - \frac{1-x}{1+x} & \quad \text{für } |x| \ll 1, \\ \sqrt{x + \frac{1}{x}} - \sqrt{x - \frac{1}{x}} & \quad \text{für } x \gg 1, \\ \frac{1 - \cos x}{x} & \quad \text{für } x \neq 0, |x| \ll 1. \end{aligned}$$

5. Für die Auswertung der Funktion $\arcsin y$ in t -stelliger dezimaler Gleitpunktarithmetik stehe ein Programm zur Verfügung, das für $|y| \leq 1$ den Funktionswert mit einem relativen Fehler ε liefert, wobei $|\varepsilon| \leq 5 \cdot 10^{-t}$ ist. Entsprechend der Identität

$$\arctan x = \arcsin \frac{x}{\sqrt{1+x^2}}$$

könnte dieses Programm auch zur Auswertung von $\arctan x$ eingesetzt werden. Man untersuche durch eine Abschätzung des relativen Fehlers, für welche Werte x diese Methode $\arctan$ zu berechnen, gutartig ist.

6. Zu gegebenem z kann $\tan z/2$ mittels der Formel

$$\tan \frac{z}{2} = \pm \left(\frac{1 - \cos z}{1 + \cos z} \right)^{1/2}$$

berechnet werden. Ist die Auswertung dieser Formel für $z \approx 0$ und $z \approx \pi/2$ gutartig ? Gegebenenfalls gebe man gutartige Methoden an.

7. Es soll ein Verfahren zur Berechnung der Funktion

$$f(\varphi, k_c) := \frac{1}{\sqrt{\cos^2 \varphi + k_c^2 \sin^2 \varphi}}$$

für $0 \leq \varphi \leq \pi/2$, $0 < k_c \leq 1$ angegeben werden. Die Methode

$$k^2 := 1 - k_c^2, \quad f(\varphi, k_c) := \frac{1}{\sqrt{1 - k^2 \sin^2 \varphi}},$$

vermeidet die Auswertung von $\cos \varphi$ und ist somit schneller. Man vergleiche diese Methode mit der direkten Auswertung des gegebenen Ausdrucks für $f(\varphi, k_c)$ im Hinblick auf die Gutartigkeit.

8. Für die lineare Funktion $f(x) := a + b \cdot x$ mit $a \neq 0$, $b \neq 0$ soll die erste Ableitung $f'(0) = b$ mit Hilfe der Differenzenformel

$$D_h f(0) = \frac{f(h) - f(-h)}{2h}$$

in dualer Gleitpunktarithmetik berechnet werden. Dabei seien a und b gegebene Gleitpunktzahlen, h sei eine Potenz von 2, so daß die Multiplikation mit h und die Division durch $2h$ exakt ausgeführt werden. Man gebe eine Schranke für den relativen Fehler von $D_h f(0)$ an. Wie verhält sich diese Schranke für $h \rightarrow 0$?

9. Die Quadratwurzel $\pm(u + iv)$ einer komplexen Zahl $x + iy$ mit $y \neq 0$ kann nach den Formeln

$$u = \pm \sqrt{\frac{x + \sqrt{x^2 + y^2}}{2}}$$

$$v = \frac{y}{2u}$$

berechnet werden. Man vergleiche die Fälle $x \geq 0$ und $x < 0$ im Hinblick auf Gutartigkeit und ändere die Formeln nötigenfalls ab, um sie gutartig zu machen.

10. Zu den Meßwerten $x_1, \dots, x_n$ soll ein Schätzwert S^2 für die Varianz berechnet werden. Welche der Formeln

$$S^2 = \frac{1}{n-1} \left(\sum_{i=1}^n x_i^2 - n\bar{x}^2 \right),$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 \quad \text{mit} \quad \bar{x} := \frac{1}{n} \sum_{i=1}^n x_i$$

ist numerisch stabiler?

11. Die Koeffizienten a_r, b_r ($r = 0, \dots, n$) seien für festes x wie folgt miteinander verknüpft:

$$(*) \quad \begin{aligned} b_n &:= a_n, \\ b_r &:= x b_{r+1} + a_r, \quad r = n-1, n-2, \dots, 0. \end{aligned}$$

a) Man zeige, daß für die Polynome

$$A(z) := \sum_{r=0}^n a_r z^r, \quad B(z) := \sum_{r=1}^n b_r z^{r-1}$$

gilt:

$$A(z) = (z - x) \cdot B(z) + b_0.$$

- b) $A(x) = b_0$ soll nach der Rekursion (*) für festes x in Gleitpunktarithmetik berechnet werden, das Resultat sei b'_0 . Man zeige unter Verwendung der Formeln (vgl. Aufg. 1)

$$\text{gl}(u + v) = \frac{u + v}{1 + \sigma}, \quad |\sigma| \leq \text{eps},$$

$$\text{gl}(u \cdot v) = \frac{u \cdot v}{1 + \pi}, \quad |\pi| \leq \text{eps},$$

daß für b'_0 die Abschätzung

$$|A(x) - b'_0| \leq \frac{\text{eps}}{1 - \text{eps}} (2e_0 - |b'_0|)$$

gilt, wo e_0 durch folgende Rekursion gewonnen wird:

$$e_n := |a_n|/2,$$

$$e_r := |x|a_{r+1} + |b'_r|, \quad r = n-1, n-2, \dots, 0.$$

Hinweis: Mit

$$b'_n := a_n,$$

und

$$p_r := \text{gl}(xb'_{r+1}) = \frac{xb'_{r+1}}{1 + \pi_{r+1}},$$

$$b_r := \text{gl}(p_r + a_r) = \frac{p_r + a_r}{1 + \sigma_r} = xb'_{r+1} + a_r + \delta_r,$$

zeige man zunächst für $r = n-1, \dots, 0$

$$\delta_r = -xb'_{r+1} \frac{\pi_{r+1}}{1 + \pi_{r+1}} - \sigma_r b'_r,$$

zeige dann, $b'_0 = \sum_{k=0}^n (a_k + \delta_k)x^k$, $\delta_n := 0$, und schätze $\sum_0^n |\delta_k||x|^k$ ab.

Literatur zu Kapitel 1 und weitere allgemeine Literatur

- Ashenhurst, R.L., Metropolis, N. (1959): Unnormalized floating-point arithmetic. J. Assoc. Comput. Mach. **6**, 415–428.
- Bauer, F.L. (1974): Computational graphs and rounding error. SIAM J. Numer. Anal. **11**, 87–96.
- Bauer, F.L., Heinhold, J., Samelson, K., Sauer, R. (1965): *Moderne Rechenanlagen*. Stuttgart: Teubner.
- Henrici, P. (1963): *Error propagation for difference methods*. New York: Wiley.
- Klatte, R., Kulisch, N., Neaga, M., Ratz, D., Ullrich, Ch. (1991): *PASCAL-XSC-Sprachbeschreibung mit Beispielen*. Berlin-Heidelberg-New York: Springer.

- Knuth, D.E. (1969): *The art of computer programming. Vol. 2. Seminumerical algorithms*. Reading, Mass.: Addison-Wesley.
- Kulisch, U. (1969): Grundzüge der Intervallrechnung. In: D. Laugwitz (Hrsg.): *Überblicke Mathematik* **2**, 51–98. Mannheim: Bibliographisches Institut.
- Moore, R.E. (1966): *Interval analysis*. Englewood Cliffs, N.J.: Prentice-Hall.
- Neumann, J. von, Goldstein, H.H. (1947): Numerical inverting of matrices. Bull. Amer. Math. Soc. **53**, 1021–1099.
- Rademacher, H.A. (1948): On the accumulation of errors in processes of integration on high-speed calculating machines. Proceedings of a symposium on large-scale digital calculating machinery. Ann. Comput. Labor. Harvard Univ. **16**, 176–185.
- Scarborough, J.B. (1950): *Numerical mathematical analysis*. 2nd edition. Baltimore: Johns Hopkins Press.
- Stenzel, P.H. (1974): *Floating point computation*. Englewood Cliffs, N.J.: Prentice-Hall.
- Wilkinson, J.H. (1960): Error analysis of floating-point computation. Numer. Math. **2**, 219–340.
- Wilkinson, J.H. (1963, 1969): *Rounding errors in algebraic processes*. New York: Wiley. Deutsche Übersetzung: *Rundungsfehler*. Heidelberger Taschenbücher, Band 44, Berlin-Heidelberg-New York: Springer.
- Wilkinson, J.H. (1965): *The algebraic eigenvalue problem*. Oxford: Clarendon Press.

Weitere Literatur, die auch Material für die übrigen Kapitel enthält:

- Ciarlet, P.G., Lions, J.L., Eds. (1990, 1991): *Handbook of numerical analysis*. Vol. I: *Finite difference methods (Part I)*, *Solution of equations in $\mathbb{R}^n$ (Part I)*. Vol. II: *Finite element methods (Part I)*. Amsterdam: North Holland.
- Conte, S.D., de Boor, C. (1980): *Elementary numerical analysis, an algorithmic approach*, 3d edition. New York: McGraw-Hill.
- Dahlquist, G., Björck, Å. (1974): *Numerical methods*. Englewood Cliffs, N.J.: Prentice Hall.
- Deuffhard, P., Hohmann, A. (1991): *Numerische Mathematik. Eine algorithmisch orientierte Einführung*. Berlin, New York: de Gruyter.
- Forsythe, G.E., Malcolm, M.A., Moler C.B. (1977): *Computer methods for mathematical computations*. Englewood Cliffs, N.J.: Prentice Hall.
- Fröberg, C.E. (1985): *Numerical mathematics*. Menlo Park, Calif.: Benjamin/Cummings.
- Gregory, R.T., Young, D.M. (1972, 1973): *A survey of numerical mathematics*. Vols. 1, 2. Reading, Mass.: Addison-Wesley.
- Hämmerlin, G., Hoffmann, K.-H. (1991): *Numerische Mathematik*. 2. Aufl., Berlin-Heidelberg-New York: Springer.
- Henrici, P. (1964): *Elements of numerical analysis*. New York: John Wiley.
- Hildebrand, F.B. (1974): *Introduction to numerical analysis*, 2d edition. New York: McGraw-Hill.

- Householder, A.S. (1953): *Principles of numerical analysis*. New York: McGraw-Hill.
- Isaacson, E., Keller, H.B. (1966): *Analysis of numerical methods*, New York: John Wiley. Deutsche Übersetzung: *Analyse numerischer Verfahren*, Frankfurt: Harri Deutsch 1973.
- Locher, F. (1952): *Numerische Mathematik für Informatiker*. Berlin-Heidelberg-New York: Springer.
- Press, W.H., Flannery, B.P., Teukolsky, S.A., Vetterling, W.T. (1990): *Numerical recipes. The art of scientific computing*. Cambridge University Press.
- Ralston, A., Rabinowitz, P. (1978): *A first course in numerical analysis*. New York: McGraw-Hill.
- Rutishauser, H. (1976): *Vorlesungen über Numerische Mathematik*. Bd. 1, 2, Basel: Birkhäuser.
- Schaback, R., Werner, H. (1991): *Numerische Mathematik*. 4. Aufl., Berlin-Heidelberg-New York: Springer.
- Schwarz, H.-R. (1986): *Numerische Mathematik*. Stuttgart: Teubner.
- Schwetlick, H., Kretschmar, H. (1991): *Numerische Verfahren für Naturwissenschaftler und Ingenieure*. Leipzig: Fachbuchverlag.
- Stiefel, E. (1976): *Einführung in die Numerische Mathematik*. 5. Aufl., Stuttgart: Teubner.
- Stummel, F., Hainer, K. (1971): *Praktische Mathematik*. Stuttgart: Teubner.
- Todd, J. (1962): *A survey of numerical analysis*. New York: McGraw-Hill.
- Todd, J. (1978): *Basic numerical mathematics, Vol. 1. Numerical analysis*. Basel: Birkhäuser.
- Todd, J. (1977): *Basic numerical mathematics, Vol. 2. Numerical algebra*. Basel: Birkhäuser 1977.

2 Interpolation

Gegeben sei eine Funktion einer Variablen x

$$\Phi(x; a_0, \dots, a_n),$$

die von $n + 1$ weiteren reellen oder komplexen Parametern $a_0, \dots, a_n$ abhängt. Ein Interpolationsproblem für Φ liegt dann vor, wenn die Parameter a_i so bestimmt werden sollen, daß für $n + 1$ gegebene Paare von reellen oder komplexen Zahlen (x_i, f_i) , $i = 0, \dots, n$, mit $x_i \neq x_k$ für $i \neq k$ gilt

$$\Phi(x_i; a_0, \dots, a_n) = f_i, \quad i = 0, \dots, n.$$

Die Paare (x_i, f_i) werden als *Stützpunkte* bezeichnet; die x_i heißen *Stützabszissen*, die f_i *Stützordinaten*. Manchmal werden auch Werte der Ableitungen von Φ an den Stützabszissen x_i vorgeschrieben.

Ein *lineares Interpolationsproblem* liegt vor, wenn Φ linear von den Parametern a_i abhängt:

$$\Phi(x; a_0, \dots, a_n) \equiv a_0 \Phi_0(x) + a_1 \Phi_1(x) + \dots + a_n \Phi_n(x).$$

Zu diesen linearen Problemen gehören das Problem der *Interpolation durch Polynome* (Abschnitt 2.1)

$$\Phi(x; a_0, \dots, a_n) \equiv a_0 + a_1 x + a_2 x^2 + \dots + a_n x^n$$

und der *trigonometrischen Interpolation* (Abschnitt 2.3)

$$\Phi(x; a_0, \dots, a_n) \equiv a_0 + a_1 e^{xi} + a_2 e^{2xi} + \dots + a_n e^{nxi} \quad (i^2 = -1).$$

Während die Polynominterpolation früher häufig zur Interpolation von Funktionswerten aus Tafelwerken benutzt wurde, ist diese Anwendung seit dem Aufkommen der modernen elektronischen Digitalrechner selten geworden.

Sie ist nach wie vor wichtig, um Formeln für die numerische Integration von Funktionen abzuleiten. Neuerdings benutzt man sie und die rationale Interpolation (s. u.) häufig im Rahmen von Algorithmen, die die Konvergenz

gewisser Folgen beschleunigen (Richardson-Verfahren, Extrapolationsalgorithmen). Diese Verfahren sind für die Integration von Funktionen und von Differentialgleichungen wichtig (s. Abschnitte 3.3 und 3.4).

Die trigonometrische Interpolation wird in ausgedehntem Maße zur numerischen Fourieranalyse von Zeitreihen und anderer zyklischer Phänomene benutzt. In diesem Zusammenhang sind besonders die Methoden der schnellen Fouriertransformation (Abschnitt 2.3.2) wichtig.

Ebenfalls zu den linearen Interpolationsproblemen gehört die sog. „*Spline-Interpolation*“, bei der (im Fall der kubischen Spline-Interpolation) Funktionen Φ benutzt werden, die 2 mal stetig differenzierbar für $x \in [x_0, x_n]$ sind, und in jedem Teilintervall $[x_i, x_{i+1}]$ einer Partition $x_0 < x_1 < \dots < x_n$ mit einem Polynom 3. Grades übereinstimmen.

Die Spline-Interpolation wird unter anderem für graphische Zwecke verwandt zur Gewinnung von Kurven, die „möglichst glatt“ durch vorgegebene Punkte (x_i, f_i) gehen, und für die Approximation komplizierter Funktionen. In steigendem Maße werden Splinefunktionen auch bei der numerischen Behandlung von gewöhnlichen und partiellen Differentialgleichungen und bei der Analyse von Signalen eingesetzt.

Zu den nichtlinearen Interpolationsproblemen gehören die Interpolation durch *rationale Funktionen*

$$\Phi(x; a_0, \dots, a_n, b_0, \dots, b_m) \equiv \frac{a_0 + a_1x + \dots + a_nx^n}{b_0 + b_1x + \dots + b_mx^m},$$

und durch *Exponentialsummen*

$$\Phi(x; a_0, \dots, a_n, \lambda_0, \dots, \lambda_n) \equiv a_0e^{\lambda_0x} + a_1e^{\lambda_1x} + \dots + a_ne^{\lambda_nx}.$$

Rationale Interpolation spielt eine Rolle bei der genauen Approximation der elementaren transzendenten Funktionen durch rationale Funktionen, die auf einem Digitalrechner leicht berechnet werden können. Sie wird ebenfalls im Rahmen von konvergenzbeschleunigenden Algorithmen verwandt. Die Exponentialsummen-Interpolation wird häufig in der Physik und Chemie zur Analyse von Zerfallsreihen benutzt.

2.1 Interpolation durch Polynome

2.1.1 Theoretische Grundlagen. Die Interpolationsformel von Lagrange

Mit Π_n bezeichnen wir im folgenden die Menge aller reellen oder komplexen Polynome P mit Grad $P \leq n$:

$$P(x) = a_0 + a_1x + \cdots + a_nx^n.$$

Wir zeigen zunächst:

(2.1.1.1) **Satz:** Zu beliebigen $n + 1$ Stützpunkten

$$(x_i, f_i), \quad i = 0, \dots, n,$$

mit $x_i \neq x_k$ für $i \neq k$ gibt es genau ein Polynom $P \in \Pi_n$ mit

$$P(x_i) = f_i \text{ für } i = 0, 1, \dots, n.$$

Beweis: a) Eindeutigkeit. Wäre für zwei Polynome $P_1, P_2 \in \Pi_n$

$$P_1(x_i) = P_2(x_i) = f_i, \quad i = 0, 1, \dots, n,$$

so hätte das Polynom $P := P_1 - P_2 \in \Pi_n$ höchstens den Grad n und mindestens $n + 1$ verschiedene Nullstellen $x_i, i = 0, \dots, n$, d.h. P muß identisch verschwinden und es gilt $P_1 \equiv P_2$.

b) Existenz. Wir geben das interpolierende Polynom P explizit an. Dazu konstruieren wir nach Lagrange spezielle Interpolationspolynome $L_i \in \Pi_n$, $i = 0, \dots, n$, mit den Eigenschaften

$$(2.1.1.2) \quad L_i(x_k) = \delta_{ik} = \begin{cases} 1 & \text{für } i = k, \\ 0 & \text{für } i \neq k. \end{cases}$$

Offenbar erfüllen folgende Polynome diese Forderungen:

$$(2.1.1.3) \quad \begin{aligned} L_i(x) &:= \frac{(x - x_0) \cdots (x - x_{i-1})(x - x_{i+1}) \cdots (x - x_n)}{(x_i - x_0) \cdots (x_i - x_{i-1})(x_i - x_{i+1}) \cdots (x_i - x_n)} \\ &\equiv \frac{\omega(x)}{(x - x_i)\omega'(x_i)} \quad \text{mit } \omega(x) := \prod_{i=0}^n (x - x_i). \end{aligned}$$

Wegen a) sind die L_i durch (2.1.1.2) eindeutig bestimmt.

Mit Hilfe der L_i kann man nun die Lösung P des Interpolationsproblems direkt angeben (*Lagrangesche Interpolationsformel*):

$$(2.1.1.4) \quad P(x) \equiv \sum_{i=0}^n f_i L_i(x) = \sum_{i=0}^n f_i \prod_{\substack{k \neq i \\ k=0}}^n \frac{x - x_k}{x_i - x_k}. \quad \square$$

Diese Formel zeigt, daß P linear von den Stützwerten f_i abhängt. Für praktische Rechnungen ist sie weniger geeignet, falls n eine größere Zahl ist. Sie ist jedoch nützlich, wenn man viele Interpolationsprobleme mit den

gleichen Stützabszissen x_i , $i = 0, \dots, n$, aber verschiedenen Sätzen von Stützwerten f_i lösen will.

Beispiel: Gegeben für $n = 2$:

$$\begin{array}{c|ccc} x_i & 0 & 1 & 3 \\ \hline f_i & 1 & 3 & 2 \end{array}$$

Gesucht: $P(2)$, wobei $P \in \Pi_2$, $P(x_i) = f_i$ für $i = 0, 1, 2$.

Lösung:

$$L_0(x) \equiv \frac{(x-1)(x-3)}{(0-1)(0-3)}, \quad L_1(x) \equiv \frac{(x-0)(x-3)}{(1-0)(1-3)}, \quad L_2(x) \equiv \frac{(x-0)(x-1)}{(3-0)(3-1)},$$

$$P(2) = 1 \cdot L_0(2) + 3 \cdot L_1(2) + 2 \cdot L_2(2) = 1 \cdot \frac{-1}{3} + 3 \cdot 1 + 2 \cdot \frac{1}{3} = \frac{10}{3}.$$

2.1.2 Der Algorithmus von Neville

Die Lösung des vollen Interpolationsproblems für $n+1$ Stützpunkte kann man schrittweise aus den Lösungen für weniger als $n+1$ Punkte aufbauen. Diese Idee liegt den Verfahren der beiden folgenden Abschnitte zugrunde.

Wir bezeichnen bei gegebenen Stützpunkten (x_i, f_i) , $i = 0, 1, \dots$, mit

$$P_{i_0 i_1 \dots i_k} \in \Pi_k$$

dasjenige Polynom aus Π_k mit der Eigenschaft

$$P_{i_0 i_1 \dots i_k}(x_{i_j}) = f_{i_j}, \quad j = 0, 1, \dots, k.$$

Es gilt dann die Rekursionsformel

$$(2.1.2.1a) \quad P_i(x) \equiv f_i,$$

$$(2.1.2.1b) \quad P_{i_0 i_1 \dots i_k}(x) \equiv \frac{(x - x_{i_0})P_{i_1 i_2 \dots i_k}(x) - (x - x_{i_k})P_{i_0 i_1 \dots i_{k-1}}(x)}{x_{i_k} - x_{i_0}}.$$

Beweis: (2.1.2.1a) ist trivial. Wir bezeichnen nun mit $R(x)$ die rechte Seite von (2.1.2.1b) und zeigen, daß R die Eigenschaften von $P_{i_0 i_1 \dots i_k}$ besitzt. Natürlich ist $\text{Grad } R \leq k$. Ferner haben wir nach Definition von $P_{i_1 \dots i_k}$ und $P_{i_0 \dots i_{k-1}}$

$$\begin{aligned} R(x_{i_0}) &= P_{i_0 \dots i_{k-1}}(x_{i_0}) = f_{i_0}, \\ R(x_{i_k}) &= P_{i_1 \dots i_k}(x_{i_k}) = f_{i_k}, \end{aligned}$$

und für $j = 1, 2, \dots, k-1$

$$R(x_{ij}) = \frac{(x_{ij} - x_{i_0})f_{ij} - (x_{ij} - x_{i_k})f_{i_k}}{x_{i_k} - x_{i_0}} = f_{ij}.$$

Wegen der Eindeutigkeit der Polynominterpolation (Satz 2.1.1.1) gilt daher $R = P_{i_0 i_1 \dots i_k}$. $\square$

Der Algorithmus von Neville besteht darin, mit Hilfe von (2.1.2.1) das folgende symmetrische Tableau zu konstruieren, das die Werte der interpolierenden Polynome $P_{i,i+1,\dots,i+k}$ an einer festen Stelle x enthält:

$$(2.1.2.2) \quad \begin{array}{c|cccc} & k=0 & 1 & 2 & 3 \\ \hline x_0 & f_0 = P_0(x) & & & \\ & & P_{01}(x) & & \\ x_1 & f_1 = P_1(x) & & P_{012}(x) & \\ & & P_{12}(x) & \ddots & P_{0123}(x) \\ x_2 & f_2 = P_2(x) & & P_{123}(x) & \\ & & P_{23}(x) & \ddots & \\ x_3 & f_3 = P_3(x) & & & \end{array}$$

Die 0-te Spalte ($k=0$) enthält die Stützordinaten f_i , die Elemente der übrigen Spalten ($k \geq 1$) können aus ihren zwei linken Nachbarn berechnet werden, beispielsweise

$$P_{123}(x) = \frac{(x - x_1)P_{23}(x) - (x - x_3)P_{12}(x)}{x_3 - x_1}.$$

Beispiel: Berechne $P_{012}(2)$ mit denselben Stützpunkten wie im Beispiel von Abschnitt 2.1.1.

$$\begin{array}{c|ccc} x_0 = 0 & f_0 = P_0(2) = 1 & & \\ x_1 = 1 & f_1 = P_1(2) = 3 & P_{01}(2) = 5 & \\ x_2 = 3 & f_2 = P_2(2) = 2 & P_{12}(2) = \frac{5}{2} & P_{012}(2) = \frac{10}{3} \end{array}$$

wegen

$$\begin{aligned} P_{01}(2) &= \frac{(2-0) \cdot 3 - (2-1) \cdot 1}{1-0} = 5, \\ P_{12}(2) &= \frac{(2-1) \cdot 2 - (2-3) \cdot 3}{3-1} = \frac{5}{2}, \\ P_{012}(2) &= \frac{(2-0) \cdot 5/2 - (2-3) \cdot 5}{3-0} = \frac{10}{3}. \end{aligned}$$

Den Nevilleschen Algorithmus kann man auch verwenden, um die Polynome $P_{i,i+1,\dots,i+k}$ selbst, d. h. ihre Koeffizienten zu bestimmen. Dafür ist er aber nicht besonders gut geeignet. Für diese Aufgabe, ein bestimmtes Polynom an der Spitze von (2.1.2.2) zu bestimmen, gibt es sparsamere Algorithmen. Auch wenn die Werte eines einzigen Polynoms, etwa $P_{01\dots k}$, an mehreren festen Stellen x benötigt werden, sind andere Algorithmen vorzuziehen (s. Abschnitt 2.1.3).

Häufig verwendet man in den Anwendungen die Abkürzung

$$(2.1.2.3) \quad T_{i+k,k} := P_{i,i+1,\dots,i+k}$$

Mit dieser Schreibweise wird aus (2.1.2.2) das Tableau:

$$(2.1.2.4) \quad \begin{array}{c|c} x_0 & f_0 = T_{00} \\ & T_{11} \\ x_1 & f_1 = T_{10} & T_{22} \\ & T_{21} & \searrow & T_{33} \\ x_2 & f_2 = T_{20} & \searrow & T_{32} \\ & T_{31} & \nearrow \\ x_3 & f_3 = T_{30} & \nearrow \end{array}$$

Nach Hinzufügung eines Stützpunktes x_i , f_i können die Elemente der neuen Schrägzeile $T_{i,0}, T_{i,1}, \dots, T_{i,i}$ aus der letzten Schrägzeile berechnet werden entsprechend den folgenden Rekursionsformeln (s.(2.1.2.1)):

$$(2.1.2.5a) \quad T_{i,0} := f_i$$

$$(2.1.2.5b) \quad T_{i,k} := \frac{(x - x_{i-k})T_{i,k-1} - (x - x_i)T_{i-1,k-1}}{x_i - x_{i-k}}$$

$$= T_{i,k-1} + \frac{T_{i,k-1} - T_{i-1,k-1}}{\frac{x - x_{i-k}}{x - x_i} - 1}, \quad 1 \leq k \leq i, \quad i \geq 0.$$

In ALGOL läßt sich dieser Algorithmus wie folgt formulieren:

for $i := 0$ **step** 1 **until** n **do**

begin $t[i] := f[i]$;

for $j := i - 1$ **step** -1 **until** 0 **do**

$t[j] := t[j + 1] + (t[j + 1] - t[j]) \times (x - x[i]) / (x[i] - x[j])$

end ;

Am Ende der inneren Schleife gilt $t[j] = T_{i,i-j}$, $0 \leq j \leq i$, so daß nach Beendigung des Programms $t[0]$ den Wert $T_{nn} = P_{0,1,\dots,n}(x)$ liefert.

Die durch den Algorithmus (2.1.2.5) erreichte Genauigkeit des interpolierten Polynomwertes läßt sich noch geringfügig verbessern: Für $i = 0, 1, \dots$ seien die Größen Q_{ik} , D_{ik} definiert durch

$$\left. \begin{aligned} Q_{i0} &:= D_{i0} := f_i, \\ Q_{ik} &:= T_{ik} - T_{i,k-1} \\ D_{ik} &:= T_{ik} - T_{i-1,k-1} \end{aligned} \right\} \quad 1 \leq k \leq i,$$

Aus (2.1.2.5) gewinnt man die Rekursionsformeln
(2.1.2.6)

$$\left. \begin{aligned} Q_{ik} &:= (D_{i,k-1} - Q_{i-1,k-1}) \frac{x_i - x}{x_{i-k} - x_i} \\ D_{ik} &:= (D_{i,k-1} - Q_{i-1,k-1}) \frac{x_{i-k} - x}{x_{i-k} - x_i} \end{aligned} \right\} \quad 1 \leq k \leq i, \quad i = 0, 1, \dots,$$

mit denen ausgehend von $Q_{i0} := D_{i0} := f_i$ das Tableau der Q_{ik} , D_{ik} berechnet werden kann. Daraus erhält man anschließend

$$P_{nn} := f_n + \sum_{k=1}^n Q_{nk}.$$

Wenn die Werte der f_i nur wenig voneinander verschieden sind, wie das z. B. bei der Tafel-Interpolation und der Anwendung auf Extrapolationsverfahren oft der Fall ist, sind die Größen Q_{ik} klein im Vergleich zu den f_i . Man wird deshalb zur Vermeidung von unnötigen Rundungsfehlern zunächst die „Korrekturen“ $Q_{n1}, \dots, Q_{nn}$ aufsummieren und erst dann ihre Summe zu f_n addieren (im Gegensatz zu (2.1.2.5)).

Speziell für $x = 0$ wird die Rekursion (2.1.2.5) – bzw. die beschriebene Variante – später in den sog. Extrapolationsalgorithmen angewandt. In diesem Spezialfall erhält man:

$$(2.1.2.7) \quad \begin{aligned} \text{a) } T_{i0} &:= f_i \\ \text{b) } T_{ik} &:= T_{i,k-1} + \frac{T_{i,k-1} - T_{i-1,k-1}}{\frac{x_{i-k}}{x_i} - 1}, \quad 1 \leq k \leq i. \end{aligned}$$

Der *Algorithmus von Aitken*, den wir aus historischen Gründen erwähnen, besteht darin, mit Hilfe von (2.1.2.1) folgendes unsymmetrische Tableau spaltenweise zu berechnen:

$$\begin{array}{ccccccc}
 x_0 & f_0 & = & P_0(x) & & & \\
 x_1 & f_1 & = & P_1(x) & P_{01}(x) & & \\
 x_2 & f_2 & = & P_2(x) & P_{02}(x) & P_{012}(x) & \\
 x_3 & f_3 & = & P_3(x) & P_{03}(x) & P_{013}(x) & P_{0123}(x) \\
 \cdot & \cdot & & \cdot & \cdot & \cdot & \cdot
 \end{array}$$

Die erste Spalte enthält wieder die Stützordinaten f_i , jeder weitere Wert wird aus dem linken Nachbarn und dem ersten Element der linken Nachbarspalte berechnet.

2.1.3 Die Newtonsche Interpolationsformel. Dividierte Differenzen

Das Verfahren von Neville ist unpraktisch, wenn man die *Koeffizienten* eines bestimmten interpolierenden Polynoms, oder dieses Polynom auch nur an *mehreren* Stellen ξ_j ausrechnen will. In diesem Fall ist der *Newtonsche Algorithmus* vorzuziehen. Nach Newton arbeitet man mit dem Ansatz

$$\begin{aligned}
 P(x) &\equiv P_{01\dots n}(x) \\
 (2.1.3.1) \quad &= a_0 + a_1(x - x_0) + a_2(x - x_0)(x - x_1) + \dots \\
 &\quad + a_n(x - x_0) \dots (x - x_{n-1})
 \end{aligned}$$

für das interpolierende Polynom $P \in \Pi_n$ mit $P(x_i) = f_i$, $i = 0, 1, \dots, n$. Man beachte, daß man (2.1.3.1) für $x = \xi$ mit einem Horner-artigen Schema (s. (5.5.1)) auswerten kann:

$$P(\xi) = (\dots(a_n(\xi - x_{n-1}) + a_{n-1})(\xi - x_{n-2}) + \dots + a_1)(\xi - x_0) + a_0.$$

Die Koeffizienten a_i könnten nacheinander aus den Beziehungen

$$\begin{aligned}
 f_0 &= P(x_0) = a_0 \\
 f_1 &= P(x_1) = a_0 + a_1(x_1 - x_0) \\
 f_2 &= P(x_2) = a_0 + a_1(x_2 - x_0) + a_2(x_2 - x_0)(x_2 - x_1) \\
 &\dots
 \end{aligned}$$

bestimmt werden. Dies erfordert n Divisionen und $n(n-1)$ Multiplikationen. Es gibt aber ein billigeres Verfahren, das lediglich $n(n+1)/2$ Divisionen erfordert und dabei zusätzliche nützliche Nebenresultate liefert.

Man geht von der Beobachtung aus, daß sich $P_{i_0 i_1 \dots i_{k-1}}(x)$ und $P_{i_0 i_1 \dots i_k}(x)$ um ein Polynom vom Grad k mit den k Nullstellen $x_{i_0}, x_{i_1}, \dots, x_{i_{k-1}}$ unterscheidet, da beide Polynome an diesen Stellen den gleichen Wert annehmen. Bezeichnet man daher mit

$$(2.1.3.2) \quad f_{i_0 i_1 \dots i_k}$$

den eindeutig bestimmten (s. Satz (2.1.1.1)) Koeffizienten von x^k des Polynoms $P_{i_0, \dots, i_k}(x)$, so gilt

$$(2.1.3.3) \quad P_{i_0 i_1 \dots i_k}(x) = P_{i_0 i_1 \dots i_{k-1}}(x) + f_{i_0 i_1 \dots i_k}(x - x_{i_0})(x - x_{i_1}) \cdots (x - x_{i_{k-1}}).$$

(Man beachte, daß (2.1.3.2) im Einklang steht mit der Definition des konstanten interpolierenden Polynoms $P_i(x) = f_i$.) Wir erhalten als Konsequenz die Newtonsche Darstellung

$$(2.1.3.4) \quad \begin{aligned} P_{i_0 i_1 \dots i_k}(x) = & f_{i_0} + f_{i_0 i_1}(x - x_{i_0}) + \cdots \\ & + f_{i_0 i_1 \dots i_k}(x - x_{i_0})(x - x_{i_1}) \cdots (x - x_{i_{k-1}}) \end{aligned}$$

des interpolierenden Polynoms $P_{i_0 i_1 \dots i_k}$. Die Zahlen $f_{i_0 i_1 \dots i_k}$ nennt man *k-te dividierte Differenzen*, weil für sie entsprechend der Nevilleschen Formel (2.1.2.1 b) die Rekursionsformel

$$(2.1.3.5) \quad f_{i_0 i_1 \dots i_k} = \frac{f_{i_1 \dots i_k} - f_{i_0 \dots i_{k-1}}}{x_{i_k} - x_{i_0}}$$

gilt. Dies ergibt ein Vergleich der Koeffizienten von x^k auf beiden Seiten von (2.1.2.1 b).

Da das Polynom $P_{i_0 i_1 \dots i_k}(x)$ durch die Stützstellen (x_{i_j}, f_{i_j}) , $j = 0, \dots, k$, eindeutig bestimmt ist (Satz (2.1.1.1)), ändert es sich bei beliebiger Permutation der Indizes $i_0, i_1, \dots, i_k$ nicht, also auch nicht der Koeffizient $f_{i_0 \dots i_k}$ von x^k :

(2.1.3.6) **Satz:** *Die dividierten Differenzen sind invariant gegenüber Permutationen der Indizes $i_0, i_1, \dots, i_k$: Für eine beliebige Permutation*

$$(j_0, j_1, \dots, j_k) = (i_{s_0}, i_{s_1}, \dots, i_{s_k})$$

der Indizes $i_0, i_1, \dots, i_k$ gilt

$$f_{j_0 j_1 \dots j_k} = f_{i_0 i_1 \dots i_k}.$$

Gewöhnlich interessiert man sich für die dividierten Differenzen

$$f_{i, i+1, \dots, i+k}$$

mit aufeinanderfolgenden Indizes, die man in einem sog. *Differenzenschema* anordnet (vgl. (2.1.2.2)):

$$(2.1.3.7) \quad \begin{array}{c|cccc} & k=0 & k=1 & k=2 & \dots \\ \hline x_0 & f_0 & & & \\ & & f_{01} & & \\ x_1 & f_1 & & f_{012} & \\ & & f_{12} & \vdots & \ddots \\ x_2 & f_2 & \vdots & & \\ \vdots & \vdots & & & \end{array}$$

Man kann es ausgehend von der ersten Spalte ($k=0$) spaltenweise mittels (2.1.3.5) berechnen: Bei der Berechnung von

$$f_{i,i+1,\dots,i+k} = \frac{f_{i+1,\dots,i+k} - f_{i,\dots,i+k-1}}{x_{i+k} - x_i}$$

benötigt man nur die beiden linken Nachbarn von $f_{i,i+1,\dots,i+k}$. Beispielsweise hat man

$$f_{01} = \frac{f_1 - f_0}{x_1 - x_0}, \quad f_{12} = \frac{f_2 - f_1}{x_2 - x_1}, \quad f_{012} = \frac{f_{12} - f_{01}}{x_2 - x_0}$$

Wegen (2.1.3.4) kann man aus der obersten Schrägzeile von (2.1.3.7) sofort die Koeffizienten der Newton-Darstellung von $P_{01\dots n}(x)$ ablesen:

$$P_{01\dots n}(x) = f_0 + f_{01}(x - x_0) + \dots + f_{01\dots n}(x - x_0)(x - x_1) \cdots (x - x_{n-1}).$$

Beispiel: Mit den Zahlen des Beispiels aus 2.1.1, 2.1.2 erhält man das Differenzenschema

$$\begin{array}{l|ll} x_0 = 0 & f_0 = 1 & \\ & & f_{01} = 2 \\ x_1 = 1 & f_1 = 3 & f_{012} = -\frac{5}{6} \\ & & f_{12} = -\frac{1}{2} \\ x_2 = 3 & f_2 = 2 & \end{array}$$

und damit

$$P_{012}(x) = 1 + 2 \cdot (x - 0) - \frac{5}{6}(x - 0)(x - 1),$$

$$P_{012}(2) = (-\frac{5}{6} \cdot (2 - 1) + 2)(2 - 0) + 1 = \frac{10}{3}.$$

Die Differenzen $a_k = f_{01\dots k}$ können aus den Stützpunkten (x_k, f_k) , $k = 0, 1, \dots, n$, mit folgendem ALGOL-Programm bestimmt werden, das in (2.1.3.7) beginnend mit $f_{00} := f_0$ eine aufsteigende Schrägzeile $f_i, f_{i-1,i}, \dots, f_{01\dots i}$ ($t[j] = f_{j,j+1,\dots,i}$) nach der anderen berechnet:

```

for i := 0 step 1 until n do
  begin t[i] := f[i];
    for j := i - 1 step -1 until 0 do
      t[j] := (t[j + 1] - t[j]) / (x[i] - x[j]);
    a[i] := t[0]
  end ;

```

Danach kann das Interpolationspolynom (2.1.3.1) an jeder gewünschten Stelle x ausgewertet werden:

```
p := a[n];
for i := n - 1 step -1 until 0 do
    p := p × (x - x[i]) + a[i];
```

Es sei bemerkt, daß die behandelten Methoden bei einer beliebigen Permutation der Stützpunkte (x_i, f_i) , $i = 0, \dots, n$ alle das gleiche interpolierende Polynom $P_{i_0 \dots i_n}(x) = P_{01 \dots n}(x)$ liefern würden, wenn man Rundungsfehlerfrei rechnen könnte. Den Rundungsfehlereinfluß kann man jedoch häufig durch einen Trick vermindern. Nimmt man an, daß die x_i der Größe nach geordnet sind, $x_0 < x_1 < \dots < x_n$, so kann die Wahl der folgenden Permutation $(i_0, i_1, \dots, i_n)$ zu einem numerisch stabileren Algorithmus zur Berechnung von $P(\xi) := P_{01 \dots n}(\xi)$ an der Stelle ξ führen:

$$|\xi - x_{i_0}| = \min\{|\xi - x_i| \mid i = 0, 1, \dots, n\}$$

$$|\xi - x_{i_k}| = \min\{|\xi - x_i| \mid i = 0, 1, \dots, n \text{ mit } i \neq i_j \text{ für } 0 \leq j \leq k-1\},$$

d. h. x_{i_0} ist die Stützabszisse, die am nächsten bei ξ liegt, x_{i_1} die zweitnächste usw.. Bei der Wahl dieser Permutation tritt sehr wahrscheinlich bei der Horner-artigen Berechnung von

(2.1.3.8)

$$\begin{aligned} P(\xi) &= P_{i_0 i_1 \dots i_n}(\xi) \\ &= f_{i_0} + f_{i_0 i_1}(\xi - x_{i_0}) + \dots + f_{i_0 i_1 \dots i_n}(\xi - x_{i_0}) \dots (\xi - x_{i_{n-1}}) \\ &= (\dots (f_{i_0 i_1 \dots i_n}(\xi - x_{i_{n-1}}) + f_{i_0 i_1 \dots i_{n-1}}) \dots + f_{i_0 i_1})(\xi - x_{i_0}) + f_{i_0} \end{aligned}$$

Rundungsfehlerldämpfung ein. Wegen $x_0 < x_1 < \dots < x_n$ folgt sofort

$$\{i_0, i_1, \dots, i_k\} = \{i \mid \min_{j \leq k} i_j \leq i \leq \max_{j \leq k} i_j\}, \text{ für } k \leq n,$$

so daß $(i_0, i_1, \dots, i_k)$ eine Permutation der Indizes $(l, l+1, \dots, l+k)$ ist, wobei

$$l := \min\{i_j \mid j \leq k\}, \quad l+k := \max\{i_j \mid j \leq k\}.$$

Man findet deshalb die dividierten Differenzen $f_{i_0 i_1 \dots i_k} = f_{l, l+1, \dots, l+k}$ längs eines Zickzack-Weges in dem Differenzenschema (2.1.3.7).

Beispiel: Für $\xi = 2$ erhält man im letzten Beispiel die Permutation

$$i_0 = 1, \quad i_1 = 2, \quad i_2 = 0.$$

Der zugehörige Pfad ist im folgenden Differenzenschema markiert:

$$\begin{array}{ll}
 x_0 = 0 & f_0 = 1 \\
 & f_{01} = 2 \\
 x_1 = 1 & \underline{f_1 = 3} \qquad \underline{f_{012} = -\frac{5}{6}} \\
 & \underline{f_{12} = -\frac{1}{2}} \\
 x_2 = 3 & f_2 = 2
 \end{array}$$

Man erhält so die Newtondarstellung

$$\begin{aligned}
 P_{120}(x) &= 3 - \frac{1}{2}(x-1) - \frac{5}{6}(x-1)(x-3) \\
 P_{120}(2) &= (-\frac{5}{6}(2-3) - \frac{1}{2}(2-1) + 3 = \frac{10}{3}.
 \end{aligned}$$

Die dividierten Differenzen hängen lediglich von den Stützpunkten (x_i, f_i) ab. Häufig sind die f_i die Funktionswerte $f(x_i) = f_i$ einer Funktion $f(x)$, die man durch Interpolation approximieren will. In diesem Fall können die dividierten Differenzen $f_{i_0 i_1 \dots i_k}$ als Funktionen der Argumente x_{i_j} aufgefasst werden, für die die historische Bezeichnung

$$f[x_{i_0}, x_{i_1}, \dots, x_{i_k}]$$

üblich ist. Für sie gelten entsprechend (2.1.3.5) Formeln wie

$$\begin{aligned}
 f[x_0] &= f(x_0) \\
 f[x_0, x_1] &= \frac{f[x_1] - f[x_0]}{x_1 - x_0} = \frac{f(x_1) - f(x_0)}{x_1 - x_0} \\
 f[x_0, x_1, x_2] &= \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0} \\
 &= \frac{f(x_0)(x_1 - x_2) + f(x_1)(x_2 - x_0) + f(x_2)(x_0 - x_1)}{(x_1 - x_0)(x_2 - x_1)(x_0 - x_2)}.
 \end{aligned}$$

Aus (2.1.3.6) folgt sofort

(2.1.3.9) **Satz:** Die dividierten Differenzen $f[x_{i_0}, \dots, x_{i_k}]$ sind symmetrische Funktionen ihrer Argumente, d. h. sie sind invariant bei Permutationen der $x_{i_0}, \dots, x_{i_k}$.

Ist die Funktion $f(x)$ selbst wieder ein Polynom, so gilt der

(2.1.3.10) **Satz:** Ist $f(x)$ ein Polynom N -ten Grades und ist

$$f_i = f(x_i), \quad i = 0, 1, \dots,$$

so gilt $f[x_0, \dots, x_k] = 0$ für $k > N$.

Beweis: Nach (2.1.3.2) ist $f[x_0, \dots, x_k]$ der höchste Koeffizient des Polynoms $P_{01\dots k}(x)$. Nun gilt $P_{01\dots k}(x) \equiv f(x)$ für $k \geq N$ wegen der Eindeutigkeit der Interpolation, also $f[x_0, \dots, x_k] = 0$ für $k > N$. $\square$

Beispiel: $f(x) = x^2$

x_i	$k = 0$	1	2	3	4
0	0				
1	1	1			
2	4	3	1	0	
3	9	5	1	0	0
4	16	7			

2.1.4 Das Restglied bei der Polynominterpolation

Nimmt man wieder an, daß die Stützwerte f_i von einer Funktion $f(x)$ herrühren, die man „interpolieren“ möchte,

$$f_i = f(x_i), \quad i = 0, 1, \dots, n,$$

so erhebt sich die Frage, wie gut das interpolierende Polynom $P(x) = P_{0\dots n}(x) \in \Pi_n$ mit

$$P(x_i) = f_i, \quad i = 0, 1, \dots, n,$$

$f(x)$ an den Stellen x wiedergibt, die von den Stützstellen x_i verschieden sind. Es ist klar, daß der Fehler

$$f(x) - P(x)$$

für $x \neq x_i$, $i = 0, 1, 2, \dots$, bei geeigneter Wahl von f beliebig groß werden kann, wenn man keine weiteren Forderungen an f als $f(x_i) = f_i$ für $0 \leq i \leq n$ stellt. Unter zusätzlichen Bedingungen für f sind jedoch Fehlerabschätzungen möglich:

(2.1.4.1) **Satz:** Ist f $(n+1)$ -mal differenzierbar, so gibt es zu jedem $\bar{x}$ eine Zahl ξ aus dem kleinsten Intervall $I[x_0, \dots, x_n, \bar{x}]$, das alle x_i und $\bar{x}$ enthält, so daß

$$f(\bar{x}) - P_{01\dots n}(\bar{x}) = \frac{\omega(\bar{x})f^{(n+1)}(\xi)}{(n+1)!}$$

gilt, wobei $\omega(x) := (x - x_0)(x - x_1) \cdots (x - x_n)$.

Beweis: Mit $P(x) := P_{01\dots n}(x)$ betrachten wir für ein beliebiges festes $\bar{x} \neq x_i$, $i = 0, 1, \dots, n$ (für $\bar{x} = x_i$ ist nichts zu zeigen) die Funktion

$$F(x) := f(x) - P(x) - K\omega(x)$$

und bestimmen K so, daß F an der Stelle $x = \bar{x}$ verschwindet. Dann besitzt $F(x)$ in $I[x_0, \dots, x_n, \bar{x}]$ mindestens die $n + 2$ Nullstellen

$$x_0, \dots, x_n, \bar{x}.$$

Nach dem Satz von Rolle besitzt deshalb $F'(x)$ dort mindestens $n + 1$ Nullstellen, $F''(x)$ mindestens n Nullstellen, $\dots$, und schließlich $F^{(n+1)}(x)$ mindestens eine Nullstelle $\xi \in I[x_0, \dots, x_n, \bar{x}]$. Nun ist aber $P^{(n+1)}(x) \equiv 0$, also

$$F^{(n+1)}(\xi) = f^{(n+1)}(\xi) - K(n+1)! = 0$$

oder

$$K = \frac{f^{(n+1)}(\xi)}{(n+1)!}.$$

Daraus folgt die Behauptung

$$f(\bar{x}) - P(\bar{x}) = K\omega(\bar{x}) = \frac{\omega(\bar{x})}{(n+1)!} f^{(n+1)}(\xi). \quad \square$$

Eine andere Restgliedform ergibt sich aus der Newtonschen Interpolationsformel (2.1.3.4). Wählt man nämlich zusätzlich zu den $n + 1$ Stützpunkten

$$(x_i, f_i) : f_i = f(x_i), \quad i = 0, 1, \dots, n,$$

einen $(n + 2)$ -ten Stützpunkt

$$(x_{n+1}, f_{n+1}) : \quad x_{n+1} := \bar{x}, \quad f_{n+1} := f(\bar{x}) \\ \bar{x} \neq x_i, \quad i = 0, \dots, n,$$

so folgt

$$f(\bar{x}) = P_{0\dots n+1}(\bar{x}) = P_{0\dots n}(\bar{x}) + f[x_0, \dots, x_n, \bar{x}]\omega(\bar{x})$$

oder

$$(2.1.4.2) \quad f(\bar{x}) - P_{0\dots n}(\bar{x}) = \omega(\bar{x})f[x_0, \dots, x_n, \bar{x}].$$

Durch Vergleich mit der Abschätzung von Satz (2.1.4.1) folgt

$$f[x_0, \dots, x_n, \bar{x}] = \frac{f^{(n+1)}(\xi)}{(n+1)!} \text{ für ein } \xi \in I[x_0, \dots, x_n, \bar{x}],$$

und damit gilt allgemein

$$(2.1.4.3) \quad f[x_0, \dots, x_n] = \frac{f^{(n)}(\xi)}{n!} \text{ für ein } \xi \in I[x_0, \dots, x_n]$$

für die n -te dividierte Differenz $f[x_0, \dots, x_n]$.

Beispiel: $f(x) = \sin x$:

$$x_i = \frac{\pi}{10} \cdot i, \quad i = 0, 1, 2, 3, 4, 5, \quad n = 5,$$

$$\sin x - P(x) = (x - x_0)(x - x_1) \dots (x - x_5) \frac{-\sin \xi}{720}, \quad \xi = \xi(x),$$

$$|\sin x - P(x)| \leq \frac{1}{720} |(x - x_0)(x - x_1) \dots (x - x_5)| = \frac{|\omega(x)|}{720}.$$

Außerhalb des Intervalls $I[x_0, \dots, x_n]$ wächst $|\omega(x)|$ sehr schnell an. Eine Verwendung des Interpolationspolynoms P zur Approximation von f an einer Stelle $\bar{x}$ außerhalb des Intervalls $I[x_0, \dots, x_n]$ – man spricht dann von *Extrapolation* – sollte deshalb nach Möglichkeit vermieden werden.

Andererseits sollte man nicht annehmen, daß man bei der Interpolation von f an mehr und mehr Stellen innerhalb eines festen Intervalls $[a, b] = I[x_0, \dots, x_n]$ immer bessere Approximationen an f auf $[a, b]$ erhält. Sei etwa eine reelle Funktion f gegeben, die auf einem festen Intervall $[a, b]$ definiert ist. Zu jeder Intervalleinteilung $\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$ gibt es ein interpolierendes Polynom $P_\Delta \in \Pi_n$ mit $P_\Delta(x_i) = f_i$ für $x_i \in \Delta$. Eine Folge Δ_m

$$\Delta_m = \{a = x_0^{(m)} < x_1^{(m)} < \dots < x_{n_m}^{(m)} = b\}$$

gibt zu einer Folge von interpolierenden Polynomen P_{Δ_m} Anlaß. Man könnte nun meinen, daß die Polynome P_{Δ_m} gegen f konvergieren, sofern nur die Feinheit

$$\|\Delta_m\| := \max_i |x_{i+1}^{(m)} - x_i^{(m)}|$$

für $m \rightarrow \infty$ gegen 0 konvergiert. Dies ist im allgemeinen falsch. Es gilt sogar der

(2.1.4.4) **Satz (Faber):** *Zu jeder Folge von Intervalleinteilungen Δ_m von $[a, b]$ kann man eine auf $[a, b]$ stetige Funktion f finden, so daß die Polynome $P_{\Delta_m}(x)$ für $m \rightarrow \infty$ auf $[a, b]$ nicht gleichmäßig gegen $f(x)$ konvergieren.*

Lediglich für ganze Funktionen f gilt für alle Zerlegungen Δ_m von $[a, b]$ mit $\|\Delta_m\| \rightarrow 0$, daß die P_{Δ_m} gleichmäßig auf $[a, b]$ gegen f konvergieren. Zu jeder stetigen Funktion f gibt es aber individuelle Folgen Δ_m , so daß P_{Δ_m} gegen f konvergiert. Eine feste Wahl der Δ_m , etwa äquidistante Intervalleinteilungen, $x_i^{(m)} = a + i(b-a)/m$, $i = 0, \dots, m$, garantiert nicht einmal die punktweise Konvergenz für nicht-ganze Funktionen, z. B. nicht für

$$f(x) = \frac{1}{1+x^2}, \quad [a, b] = [-5, 5];$$

$$f(x) = \sqrt{x}, \quad [a, b] = [0, 1].$$

2.1.5 Hermite-Interpolation

Gegeben seien für $i = 0, 1, \dots, m$, $k = 0, 1, \dots, n_i - 1$, reelle Zahlen x_i und $f_i^{(k)}$ mit

$$x_0 < x_1 < \dots < x_m.$$

Das *Hermite'sche Interpolationsproblem* bezüglich dieser Daten besteht darin, ein Polynom P vom Grad $P \leq n$, $P \in \Pi_n$, mit $n+1 := \sum_{i=0}^m n_i$ zu bestimmen, das folgende Interpolationseigenschaften besitzt

$$(2.1.5.1) \quad P^{(k)}(x_i) = f_i^{(k)}, \quad i = 0, 1, \dots, m, \quad k = 0, 1, \dots, n_i - 1.$$

Im Unterschied zur gewöhnlichen Polynominterpolation, die man als Spezialfall $n_i = 1$ erhält, werden für das gesuchte Polynom nicht nur die Funktionswerte an den Stützabszissen x_i sondern auch die ersten $n_i - 1$ Ableitungen vorgeschrieben. Die Bedingungen (2.1.5.1) stellen $\sum n_i = n + 1$ Bedingungen für die gesuchten $n + 1$ Koeffizienten von P dar, so daß die eindeutige Lösbarkeit des Problems zu erwarten ist:

(2.1.5.2) **Satz:** Zu beliebigen Zahlen $x_0 < x_1 < \dots < x_m$ und $f_i^{(k)}$, $i = 0, 1, \dots, m$, $k = 0, 1, \dots, n_i - 1$, gibt es genau ein Polynom $P \in \Pi_n$ mit $n + 1 := \sum_{i=0}^m n_i$, das (2.1.5.1) erfüllt.

Beweis: Wir zeigen zunächst die Eindeutigkeit. Für zwei Polynome $P_1, P_2 \in \Pi_n$ mit (2.1.5.1) gilt für das Differenzpolynom $Q(x) := P_1(x) - P_2(x)$

$$Q^{(k)}(x_i) = 0 \text{ für } k = 0, 1, \dots, n_i - 1, \quad i = 0, 1, \dots, m.$$

Also ist x_i eine mindestens n_i -fache Nullstelle von Q , so daß Q mindestens $\sum n_i = n + 1$ Nullstellen (entsprechend ihrer Vielfachheit gezählt) besitzt. Da $Q \in \Pi_n$ höchstens den Grad n hat, muß Q identisch verschwinden.

Die Existenz folgt aus der Eindeutigkeit: Denn (2.1.5.1) stellt ein lineares Gleichungssystem von $n + 1$ Gleichungen für die $n + 1$ unbekannten Koeffizienten c_i von $P(x) = c_0 + c_1x + \dots + c_nx^n$ dar. Die Matrix dieses Gleichungssystems ist nichtsingulär wegen der eben bewiesenen Eindeutigkeit. Also besitzt das lineare Gleichungssystem (2.1.5.1) für beliebige $f_i^{(k)}$ eine eindeutig bestimmte Lösung. $\square$

Es ist möglich, auch für die Hermite-Interpolation analog zur Lagrange'schen Interpolationsformel (2.1.1.4) das interpolierende Polynom $P \in \Pi_n$ mit (2.1.5.1) explizit anzugeben. Es gilt

$$(2.1.5.3) \quad P(x) = \sum_{i=0}^m \sum_{k=0}^{n_i-1} f_i^{(k)} L_{ik}(x).$$

Dabei sind die verallgemeinerten Lagrangepolynome $L_{ik} \in \Pi_n$ auf folgende Weise erklärt: mit den Hilfspolynomen $l_{ik} \in \Pi_n$ [vgl. (2.1.1.3)]

$$l_{ik}(x) := \frac{(x - x_i)^k}{k!} \prod_{\substack{j=0 \\ j \neq i}}^m \left(\frac{x - x_j}{x_i - x_j} \right)^{n_j}, \quad 0 \leq i \leq m, \quad 0 \leq k \leq n_i,$$

definiert man die L_{ik} ausgehend von

$$L_{i, n_i-1}(x) := l_{i, n_i-1}(x), \quad i = 0, 1, \dots, m,$$

für $k = n_i - 2, n_i - 3, \dots, 0$ rekursiv durch

$$L_{ik}(x) := l_{ik}(x) - \sum_{v=k+1}^{n_i-1} l_{ik}^{(v)}(x_i) L_{iv}(x).$$

Durch Induktion zeigt man leicht für $k = n_i - 1, n_i - 2, \dots, 0$

$$L_{ik}^{(\sigma)}(x_j) = \begin{cases} 1, & \text{falls } i = j \text{ und } k = \sigma, \\ 0, & \text{sonst,} \end{cases}$$

so daß in der Tat das Polynom P (2.1.5.3) die Interpolationseigenschaften (2.1.5.1) besitzt.

Um Methoden vom Neville- bzw. Newton-Typ (s. Abschnitte 2.1.2, 2.1.3) zur Bestimmung von P zu beschreiben, ist es zweckmäßig, dividierte Differenzen $f[t_0, t_1, \dots, t_n]$ zu verallgemeinern und sie auch für Abszissen mit Wiederholungen, $t_0 \leq t_1 \leq \dots \leq t_n$, zu definieren. Dies ist insbesondere für die Einführung der B -Splines in Abschnitt 2.4.4 wichtig. Dazu wiederholen wir zunächst in der Folge der Abszissen $x_0 < x_1 < \dots < x_m$ in (2.1.5.1) jedes x_i n_i -mal,

$$\underbrace{x_0 = \dots = x_0}_{n_0} < \underbrace{x_1 = \dots = x_1}_{n_1} < \dots < \underbrace{x_m = \dots = x_m}_{n_m},$$

und bezeichnen die Elemente dieser Folge von $n+1 = \sum_{i=0}^m n_i$ Zahlen der Reihe nach mit

$$t_0 = x_0 \leq t_1 \leq \dots \leq t_n = x_m.$$

Die t_j , $j = 0, 1, \dots, n$, nennen wir *virtuelle Abszissen*.

Wir wollen nun in der Formulierung des Hermiteschen Interpolationsproblems (2.1.5.1) die „wahren“ Abszissen x_i und die ganzen Zahlen n_i , $i = 0, 1, \dots, m$, durch die virtuellen Abszissen t_j , $j = 0, 1, \dots, n$,

ersetzen. Dies ist möglich, weil die virtuellen Abszissen offensichtlich die x_i und n_i , $i = 0, 1, \dots, m$ eindeutig bestimmen. Um die Abhängigkeit des Interpolationspolynoms $P(\cdot)$ von $t_0, t_1, \dots, t_n$ anzudeuten, schreiben wir statt $P(\cdot)$ im folgenden auch $P_{01\dots n}(\cdot)$. Ferner ist es zweckmäßig, in (2.1.5.1) ausführlicher $f^{(r)}(x_i)$ statt $f_i^{(r)}$ zu schreiben. Das Interpolationspolynom $P_{01\dots n}$ ist eindeutig durch die $n + 1 = \sum_{i=0}^m n_i$ Interpolationsbedingungen (2.1.5.1) bestimmt: ihre Anzahl ist gleich der Anzahl der Indexpaare (i, k) mit $i = 0, 1, \dots, m$, $k = 0, 1, \dots, n_i - 1$, und damit gleich der Anzahl der virtuellen Abszissen t_j . Folgende Beobachtung ist wesentlich: Wenn man die Interpolationsbedingungen (2.1.5.1) entsprechend der folgenden Anordnung der Indexpaare (i, k) ,

$$(0, 0), (0, 1), \dots, (0, n_0 - 1), (1, 0), \dots, (1, n_1 - 1), \dots, (m, n_m - 1),$$

linear ordnet, dann erhalten diese Bedingungen die Form

$$(2.1.5.4) \quad P_{01\dots n}^{(s_j-1)}(t_j) = f^{(s_j-1)}(t_j), \quad j = 0, 1, \dots, n.$$

Hier gibt die ganze Zahl s_j , $j = 0, 1, \dots, n$, an, wie oft der Wert von t_j in der Teilfolge

$$t_0 \leq t_1 \leq \dots \leq t_j,$$

der virtuellen Abszissen, die mit t_j endet, vorkommt. Die Äquivalenz von (2.1.5.1) und (2.1.5.4) folgt sofort aus

$$x_0 = t_0 = t_1 = \dots = t_{n_0-1} < x_1 = t_{n_0} = \dots = t_{n_0+n_1-1} < \dots,$$

und der Definition der s_j ,

$$s_0 = 1, s_1 = 2, \dots, s_{n_0-1} = n_0; s_{n_0} = 1, \dots, s_{n_0+n_1-1} = n_1; \dots$$

Wir wollen nun (2.1.5.4) verwenden, um das Existenz- und Eindeutigkeitsresultat von Satz (2.1.5.2) algebraisch mittels einer Verallgemeinerung der bekannten Vandermonde-Matrizen zu formulieren. Man nutzt aus, daß sich jedes Polynom $P(t) \in \Pi_n$ eindeutig in der Form

$$P(t) = \sum_{j=0}^n b_j \frac{t^j}{j!} = \Pi(t) b, \quad b := [b_0, b_1, \dots, b_n]^T,$$

schreiben läßt. Hier ist $\Pi(t)$ der Zeilenvektor

$$\Pi(t) := \left[1, t, \dots, \frac{t^n}{n!} \right].$$

Wegen Satz (2.1.5.2) und (2.1.5.4) besitzt das lineare Gleichungssystem

$$\Pi^{(s_j-1)}(t_j) b = f^{(s_j-1)}(t_j), \quad j = 0, 1, \dots, n,$$

eine eindeutig bestimmte Lösung b . Das folgende Korollar ist deshalb zu Satz (2.1.5.2) äquivalent:

(2.1.5.5) Korollar. Für jede nichtabnehmende endliche Folge von $n + 1$ reellen Zahlen

$$t_0 \leq t_1 \leq \dots \leq t_n$$

ist die $(n + 1) \times (n + 1)$ Matrix

$$V_n(t_0, t_1, \dots, t_n) := \begin{bmatrix} \Pi^{(s_0-1)}(t_0) \\ \Pi^{(s_1-1)}(t_1) \\ \dots \\ \Pi^{(s_n-1)}(t_n) \end{bmatrix}$$

nichtsingulär.

Falls die Zahlen t_j alle verschieden sind (dann ist $s_j = 1$ für alle j), gibt es eine einfache Beziehung zwischen der Matrix $V_n(t_0, t_1, \dots, t_n)$ und der Vandermonde-Matrix:

$$V_n(t_0, t_1, \dots, t_n) = \begin{bmatrix} 1 & t_0 & \dots & t_0^n \\ \vdots & \vdots & & \vdots \\ 1 & t_n & \dots & t_n^n \end{bmatrix} \begin{bmatrix} 1! & & & \\ & 2! & & \\ & & \ddots & \\ & & & n! \end{bmatrix}^{-1}.$$

Beispiel 1: Für $t_0 = t_1 < t_2$ findet man

$$V_2(t_0, t_1, t_2) = \begin{bmatrix} 1 & t_0 & \frac{t_0^2}{2} \\ 0 & 1 & t_1 \\ 1 & t_2 & \frac{t_2^2}{2} \end{bmatrix}.$$

Zur Vorbereitung eines Interpolationsverfahrens vom Neville-Typ ordnen wir jedem Segment

$$t_i \leq t_{i+1} \leq \dots \leq t_{i+k}, \quad 0 \leq i \leq i+k \leq n,$$

der virtuellen Abszissen die Lösung $P_{i,i+1,\dots,i+k} \in \Pi_k$ des partiellen Hermite'schen Interpolationsproblems zu, das zu diesem Segment gehört, nämlich die Lösung [s. (2.1.5.4)] von

$$P_{i,i+1,\dots,i+k}^{(s_j-1)}(t_j) = f^{(s_j-1)}(t_j), \quad j = i, i+1, \dots, i+k.$$

Natürlich sind hier die ganzen Zahlen s_j , $i \leq j \leq i+k$, relativ zu dem Segment definiert: s_j ($j = i, i+1, i+k$) gibt an, wie oft der Wert von t_j in dem Teilsegment $t_i \leq t_{i+1} \leq \dots \leq t_j$ vorkommt.

Beispiel 2: Zu dem Hermiteschen Interpolationsproblem mit $n_0 = 2$, $n_1 = 3$ und

$$\begin{aligned} x_0 = 0, \quad f_0^{(0)} = -1, \quad f_0^{(1)} = -2, \\ x_1 = 1, \quad f_1^{(0)} = 0, \quad f_1^{(1)} = 10, \quad f_1^{(2)} = 40, \end{aligned}$$

gehören die virtuellen Abszissen t_j , $j = 0, 1, \dots, 4$, mit

$$t_0 = t_1 := x_0 = 0, \quad t_2 = t_3 = t_4 := x_1 = 1.$$

Zu dem Segment $t_1 \leq t_2 \leq t_3$, d. h. $i = 1$ und $k = 2$, gehören

$$t_1 = x_0 < t_2 = t_3 = x_1, \quad s_1 = s_2 = 1, \quad s_3 = 2$$

und das Polynom $P_{123}(x) \in \Pi_2$ mit den Interpolationseigenschaften

$$\begin{aligned} P_{123}^{(s_1-1)}(t_1) &= P_{123}(0) = f^{(s_1-1)}(t_1) = f^{(0)}(0) = -1, \\ P_{123}^{(s_2-1)}(t_2) &= P_{123}(1) = f^{(s_2-1)}(t_2) = f^{(0)}(1) = 0, \\ P_{123}^{(s_3-1)}(t_3) &= P'_{123}(1) = f^{(s_3-1)}(t_3) = f^{(1)}(1) = 10. \end{aligned}$$

Dies illustriert (2.1.5.4).

Mit diesen Bezeichnungen gelten folgende Analoga der Nevilleschen Formeln (2.1.2.1): Falls $t_i = t_{i+1} = \dots = t_{i+k} = x_l$

$$(2.1.5.6a) \quad P_{i,i+1,\dots,i+k}(x) = \sum_{r=0}^k \frac{f_l^{(r)}}{r!} (x - x_l)^r,$$

und für $t_i < t_{i+k}$

$$(2.1.5.6b) \quad P_{i,i+1,\dots,i+k}(x) = \frac{(x - t_i)P_{i+1,\dots,i+k}(x) - (x - t_{i+k})P_{i,i+1,\dots,i+k-1}(x)}{t_{i+k} - t_i}.$$

Die erste dieser Formeln folgt sofort aus der Definition (2.1.5.4), die zweite zeigt man genau so wie (2.1.2.1)b): Man verifiziert, daß die rechte Seite $R(x)$ von (2.1.5.6b) dieselben Interpolationsbedingungen (2.1.5.4) erfüllt wie $P_{i,i+1,\dots,i+k}(x)$, die nach Satz (2.1.5.2) nur eine eindeutige Lösung zulassen. Der einfache Beweis sei dem Leser überlassen. $\square$

Wir definieren nun wie in (2.1.3.2) die *verallgemeinerte dividierte Differenz*

$$f[t_i, t_{i+1}, \dots, t_{i+k}]$$

als den Koeffizienten von x^k des Polynoms $P_{i,i+1,\dots,i+k}(x) \in \Pi_k$. Für sie gelten die folgenden Formeln (vgl. (2.1.3.5)), die man sofort aus (2.1.5.6) durch Vergleich der Koeffizienten von x^k erhält: Falls $t_i = \dots = t_{i+k} = x_l$,

$$(2.1.5.7a) \quad f[t_i, t_{i+1}, \dots, t_{i+k}] = \frac{1}{k!} f_l^{(k)},$$

und für $t_i < t_{i+k}$

(2.1.5.7b)

$$f[t_i, t_{i+1}, \dots, t_{i+k}] = \frac{f[t_{i+1}, \dots, t_{i+k}] - f[t_i, t_{i+1}, \dots, t_{i+k-1}]}{t_{i+k} - t_i}.$$

Mit Hilfe der verallgemeinerten dividierten Differenzen

$$a_k := f[t_0, t_1, \dots, t_k], \quad k = 0, 1, \dots, n,$$

läßt sich schließlich die Lösung $P(x) = P_{01\dots n}(x) \in \Pi_n$ der Hermiteischen Interpolationsaufgabe (2.1.5.1) explizit in seiner Newtonschen Form (vgl. (2.1.3.1)) angeben:

$$(2.1.5.8) \quad \begin{aligned} P_{01\dots n}(x) = & a_0 + a_1(x - t_0) + a_2(x - t_0)(x - t_1) + \dots \\ & + a_n(x - t_0)(x - t_1) \cdots (x - t_{n-1}). \end{aligned}$$

Diese Formel folgt sofort aus der Überlegung, daß das Polynom

$$Q(x) := P_{01\dots n}(x) - P_{01\dots(n-1)}(x) = f[t_0, t_1, \dots, t_n]x^n + \dots$$

höchstens den Grad n und wegen (2.1.5.1), (2.1.5.4) für $i \leq m-1$ die Zahl x_i als n_i -fache Nullstelle und x_m als $(n_m - 1)$ -fache Nullstelle besitzt. Die gleichen Nullstellen mit den gleichen Vielfachheiten besitzt das Polynom n -ten Grades

$$(x - t_0)(x - t_1) \cdots (x - t_{n-1}).$$

Daraus folgt sofort

$$Q(x) = f[t_0, t_1, \dots, t_n](x - t_0)(x - t_1) \cdots (x - t_{n-1})$$

und damit (2.1.5.8). □

Beispiel 3: Wir erläutern die Berechnung der verallgemeinerten dividierten Differenzen anhand der Zahlen von Beispiel 2 ($m = 1, n_0 = 2, n_1 = 3$):

$$\begin{array}{ll} t_0 = 0 & -1^* = f[t_0] \\ & -2^* = f[t_0, t_1] \\ t_1 = 0 & -1^* = f[t_1] \quad 3 = f[t_0, t_1, t_2] \\ & 1 = f[t_1, t_2] \quad 6 = f[t_0, \dots, t_3] \\ t_2 = 1 & 0^* = f[t_2] \quad 9 = f[t_1, t_2, t_3] \quad 5 = f[t_0, \dots, t_4] \\ & 10^* = f[t_2, t_3] \quad 11 = f[t_1, \dots, t_4] \\ t_3 = 1 & 0^* = f[t_3] \quad 20^* = f[t_2, t_3, t_4] \\ & 10^* = f[t_3, t_4] \\ t_4 = 1 & 0^* = f[t_4] \end{array}$$

Die mit * gekennzeichneten Werte sind über (2.1.5.7a) aus den Daten berechnet worden, die übrigen mittels (2.1.5.7b). Die Koeffizienten des interpolierenden Polynoms P stehen wieder in der obersten Schrägzeile:

$$\begin{aligned}
 P(x) &= -1 - 2(x-0) + 3(x-0)(x-0) + 6(x-0)(x-0)(x-1) \\
 &\quad + 5(x-0)(x-0)(x-1)(x-1) \\
 &= -1 - 2x + 3x^2 + 6x^2(x-1) + 5x^2(x-1)^2.
 \end{aligned}$$

Den Interpolationsfehler kann man bei der Hermite-Interpolation genau so abschätzen wie bei der gewöhnlichen Polynominterpolation. Man beweist den folgenden Satz analog zu Satz (2.1.4.1):

(2.1.5.9) **Satz:** Sei f auf $[a, b]$ $n+1$ mal differenzierbar und $x_0 < x_1 < \dots < x_m$, $x_i \in [a, b]$. Das Polynom $P(x)$ besitze höchstens den Grad n und erfülle die $n+1$ Interpolationsbedingungen

$$P^{(k)}(x_i) = f^{(k)}(x_i), \quad i = 0, 1, \dots, m, \quad k = 0, 1, \dots, n_i - 1,$$

wobei $\sum_{i=0}^m n_i = n+1$. Dann gibt es zu jedem $\bar{x} \in [a, b]$ ein $\bar{\xi}$ aus dem kleinsten Intervall $I[x_0, \dots, x_m, \bar{x}]$, das alle x_i und $\bar{x}$ enthält, mit

$$f(\bar{x}) - P(\bar{x}) = \frac{\omega(\bar{x}) f^{(n+1)}(\bar{\xi})}{(n+1)!},$$

wobei $\omega(x) := (x-x_0)^{n_0}(x-x_1)^{n_1} \dots (x-x_m)^{n_m}$.

Man benutzt die Hermite-Interpolation häufig, um zu einer gegebenen Zerlegung

$$\Delta : a = x_0 < x_1 < \dots < x_m = b$$

eines Intervalls $[a, b]$ eine genügend oft differenzierbare Funktion $f: [a, b] \rightarrow \mathbb{R}$ durch eine Funktion φ aus einem Hermiteschen Funktionenraum $H_{\Delta}^{(\nu)}$ zu approximieren. Dabei wird unter $H_{\Delta}^{(\nu)}$ die Menge aller Funktionen $\varphi: [a, b] \rightarrow \mathbb{R}$ mit folgenden Eigenschaften verstanden

- (2.1.5.10) 1) $\varphi \in C^{\nu-1}[a, b]$: φ ist $\nu-1$ mal stetig differenzierbar auf $[a, b]$.
 2) Auf jedem Teilintervall $I_i := [x_i, x_{i+1}]$, $i = 0, 1, \dots, m-1$, stimmt φ mit einem Polynom höchstens $(2\nu-1)$ -ten Grades überein, $\varphi|_{I_i} \in \Pi_{2\nu-1}$.

φ ist also stückweise aus Polynomen $(2\nu-1)$ -ten Grades so zusammengesetzt, daß φ an den „Knoten“ x_i noch $\nu-1$ mal stetig differenzierbar ist.

Eine Funktion $f \in C^{\nu-1}[a, b]$ kann man auf folgende Weise mittels Hermitescher Interpolation durch ein $\varphi \in H_{\Delta}^{(\nu)}$ approximieren: Man wähle die Teilpolynome $P_i = \varphi|_{I_i}$ von φ aus $\Pi_{2\nu-1}$ so, daß die P_i für $i = 0, 1, \dots, m-1$ die Interpolationsbedingungen

$$P_i^{(k)}(x_i) = f^{(k)}(x_i), \quad P_i^{(k)}(x_{i+1}) = f^{(k)}(x_{i+1}), \quad k = 0, 1, \dots, \nu-1,$$

erfüllen. Falls $f \in C^{2\nu}[a, b]$, approximieren die resultierenden P_i die Funktion f für $x \in I_i$ wegen (2.1.5.9) bis auf einen Fehler

$$(2.1.5.11) \quad |f(x) - P_i(x)| \leq \frac{|(x - x_i)(x - x_{i+1})|^\nu}{(2\nu)!} \max_{\xi \in I_i} |f^{(2\nu)}(\xi)|$$

$$\leq \frac{|x_{i+1} - x_i|^{2\nu}}{2^{2\nu} \cdot (2\nu)!} \max_{\xi \in I_i} |f^{(2\nu)}(\xi)|.$$

Es gilt also für f und die aus den P_i stückweise zusammengesetzte Funktion $\varphi \in H_\Delta^{(\nu)}$

$$(2.1.5.12) \quad \|f - \varphi\|_\infty := \max_{x \in [a, b]} |f(x) - \varphi(x)| \leq \frac{1}{2^{2\nu} (2\nu)!} \|f^{(2\nu)}\|_\infty \|\Delta\|^{2\nu}$$

gilt, wobei

$$\|\Delta\| = \max_{0 \leq i \leq m-1} |x_{i+1} - x_i|$$

die Feinheit der Zerlegung Δ ist: Der Approximationsfehler geht also mit der (2ν) -ten Potenz der Feinheit $\|\Delta_j\|$ gegen 0, wenn man $[a, b]$ durch eine Folge von Zerlegungen Δ_j mit $\|\Delta_j\| \rightarrow 0$, teilt.

Man kann dieses Resultat noch verschärfen und zeigen, daß auch die ersten ν Ableitungen von φ noch die entsprechenden Ableitungen von f gut approximieren: Ciarlet, Schultz und Varga (1967)) konnten für $f \in C^{2\nu}[a, b]$ zeigen

(2.1.5.13)

$$|f^{(k)}(x) - P_i^{(k)}(x)| \leq \frac{|(x - x_i)(x - x_{i+1})|^{\nu-k}}{k!(2\nu - 2k)!} (x_{i+1} - x_i)^k \max_{\xi \in I_i} |f^{(2\nu)}(\xi)|$$

für alle $x \in I_i$, $i = 0, 1, \dots, m-1$, $k = 0, 1, \dots, \nu$, und deshalb

$$(2.1.5.14) \quad \|f^{(k)} - \varphi^{(k)}\|_\infty \leq \frac{\|\Delta\|^{2\nu-k}}{2^{2\nu-2k} k! (2\nu - 2k)!} \|f^{(2\nu)}\|_\infty$$

für $k = 0, 1, \dots, \nu$.

2.2 Interpolation mit rationalen Funktionen

2.2.1 Allgemeine Eigenschaften der rationalen Interpolation

Gegeben seien wieder Stützpunkte (x_i, f_i) , $i = 0, 1, \dots$, mit $x_i \neq x_k$ für $i \neq k$. Wir wollen versuchen, zur Interpolation rationale Funktionen

$$\Phi^{\mu, \nu}(x) \equiv \frac{P^{\mu, \nu}(x)}{Q^{\mu, \nu}(x)} \equiv \frac{a_0 + a_1 x + \dots + a_\mu x^\mu}{b_0 + b_1 x + \dots + b_\nu x^\nu}$$

heranzuziehen, deren Zählergrad höchstens μ und deren Nennergrad höchstens ν ist. $\Phi^{\mu,\nu}$ ist durch seine $\mu + \nu + 2$ Koeffizienten

$$a_0, a_1, \dots, a_\mu, b_0, b_1, \dots, b_\nu$$

gegeben. Andererseits sind diese Koeffizienten durch $\Phi^{\mu,\nu}$ offenbar nur bis auf einen gemeinsamen Faktor $\rho \neq 0$ bestimmt. Es liegt deshalb nahe, für $\Phi^{\mu,\nu}$ durch $\mu + \nu + 1$ Interpolationsbedingungen

$$(2.2.1.1) \quad \Phi^{\mu,\nu}(x_i) = f_i, \quad i = 0, 1, \dots, \mu + \nu,$$

zu verlangen. Wir bezeichnen diese Aufgabe mit $A^{\mu,\nu}$. Die Koeffizienten a_r, b_s einer Lösung $\Phi^{\mu,\nu}$ von $A^{\mu,\nu}$ lösen sicher auch das homogene lineare Gleichungssystem

$$(2.2.1.2) \quad P^{\mu,\nu}(x_i) - f_i Q^{\mu,\nu}(x_i) = 0, \quad i = 0, 1, \dots, \mu + \nu,$$

oder ausgeschrieben

$$a_0 + a_1 x_i + \dots + a_\mu x_i^\mu - f_i (b_0 + b_1 x_i + \dots + b_\nu x_i^\nu) = 0, \quad i = 0, 1, \dots, \mu + \nu.$$

Dieses System bezeichnen wir mit $S^{\mu,\nu}$.

Auf den ersten Blick scheint die Ersetzung von $A^{\mu,\nu}$ durch $S^{\mu,\nu}$ unproblematisch zu sein. Ein Beispiel soll zeigen, daß dies leider nicht zutrifft und im Gegensatz zur Polynominterpolation bei der rationalen Interpolation kompliziertere Verhältnisse vorliegen.

Beispiel: Für die Stützpunkte

$$\begin{array}{cccc} x_i : & 0 & 1 & 2 \\ f_i : & 1 & 2 & 2 \end{array}$$

und $\mu = \nu = 1$ findet man als Lösung von $S^{1,1}$

$$\begin{aligned} a_0 - 1 \cdot b_0 &= 0, \\ a_0 + a_1 - 2(b_0 + b_1) &= 0, \\ a_0 + 2a_1 - 2(b_0 + 2b_1) &= 0, \end{aligned}$$

die bis auf einen Faktor $\neq 0$ eindeutig bestimmt ist, die Koeffizienten

$$a_0 = 0, \quad b_0 = 0, \quad a_1 = 2, \quad b_1 = 1$$

und damit den rationalen Ausdruck

$$\Phi^{1,1}(x) \equiv \frac{2x}{x},$$

der für $x = 0$ die unbestimmte Form $0/0$ annimmt. Durch Kürzen des gemeinsamen Faktors x erhält man den rationalen Ausdruck

$$\tilde{\Phi}^{1,1}(x) \equiv 2,$$

der natürlich die gleiche rationale Funktion darstellt wie $\Phi^{1,1}$, nämlich die konstante Funktion mit Wert 2. Diese Funktion verfehlt den Stützpunkt $(x_0, f_0) = (0, 1)$. Da jede Lösung von $A^{1,1}$ auch $S^{1,1}$ lösen muß und $S^{1,1}$ keine andere Lösung als $\Phi^{1,1}$ besitzt, ist $A^{1,1}$ unlösbar: (x_0, f_0) ist ein *unerreichbarer Punkt*.

Das letzte Beispiel zeigt, daß die rationale Interpolationsaufgabe $A^{\mu,\nu}$ nicht immer lösbar ist. Zwar löst jede Lösung von $A^{\mu,\nu}$ auch $S^{\mu,\nu}$, aber nicht notwendig umgekehrt. Um dies näher zu untersuchen, müssen wir zwischen einer rationalen Funktion und ihren Darstellungen durch verschiedene rationale Ausdrücke unterscheiden, die man durch Kürzen bzw. Erweitern auseinander erhält. Dabei verstehen wir unter einem *rationalen Ausdruck* $\Phi(x) := P(x)/Q(x)$ ein Paar von Polynomen $(P(x), Q(x))$ mit $Q(x) \neq 0$, wobei wir zwei rationale Ausdrücke als gleich ansehen, wenn die entsprechenden Polynompaare sich nur um einen konstanten Faktor unterscheiden.

Wir sagen, daß zwei rationale Ausdrücke

$$\Phi_1(x) := \frac{P_1(x)}{Q_1(x)}, \quad \Phi_2(x) := \frac{P_2(x)}{Q_2(x)}, \quad \text{mit } Q_1(x) \neq 0, Q_2(x) \neq 0$$

äquivalent sind, in Zeichen

$$\Phi_1 \sim \Phi_2,$$

wenn

$$P_1(x)Q_2(x) \equiv P_2(x)Q_1(x),$$

d. h. wenn man sie durch Kürzen oder Erweitern ineinander überführen kann und sie deshalb die gleiche *rationale Funktion* darstellen.

Mit $\tilde{\Phi}$ bezeichnen wir den eindeutig bestimmten zu Φ äquivalenten rationalen Ausdruck, dessen Zähler und Nenner minimalen Grad haben und deshalb teilerfremd sind. Wir sagen schließlich, daß ein rationaler Ausdruck $\Phi^{\mu,\nu}$ Lösung von $S^{\mu,\nu}$ ist, wenn seine Koeffizienten Lösung von $S^{\mu,\nu}$ sind.

Wenn $\Phi^{\mu,\nu}$ Lösung von $A^{\mu,\nu}$ ist, so ist $\Phi^{\mu,\nu}$ auch Lösung von $S^{\mu,\nu}$. Die Umkehrung bereitet Schwierigkeiten. Zunächst gilt:

(2.2.1.3) **Satz:** a) $S^{\mu,\nu}$ hat stets nichttriviale Lösungen, und jede gehört zu einem rationalen Ausdruck

$$\Phi^{\mu,\nu} \equiv \frac{P^{\mu,\nu}(x)}{Q^{\mu,\nu}(x)} \quad \text{mit } Q^{\mu,\nu}(x) \neq 0.$$

b) Wenn Φ_1 und Φ_2 Lösungen von $S^{\mu,\nu}$ sind, so gilt $\Phi_1 \sim \Phi_2$, d. h. sie bestimmen dieselbe rationale Funktion.

Beweis: a) $S^{\mu,\nu}$ besitzt als homogenes lineares Gleichungssystem mit $\mu + \nu + 1$ Gleichungen für $\mu + \nu + 2$ Unbekannte stets nichttriviale Lösungen

$$(a_0, a_1, \dots, a_\mu, b_0, \dots, b_\nu) \neq (0, \dots, 0, 0, \dots, 0).$$

Nimmt man an, daß für eine solche Lösung

$$Q^{\mu,\nu}(x) \equiv b_0 + b_1x + \dots + b_\nu x^\nu \equiv 0$$

gilt, so folgt für $P^{\mu,\nu}(x) \equiv a_0 + a_1x + \dots + a_\mu x^\mu$

$$P^{\mu,\nu}(x_i) = 0 \text{ für } i = 0, 1, \dots, \mu + \nu,$$

d. h. das Polynom $P^{\mu,\nu}$ von höchstens μ -tem Grad hat mindestens $\mu + 1 \leq \mu + \nu + 1$ verschiedene Nullstellen. Also ist $P^{\mu,\nu}(x) \equiv 0$ im Widerspruch zu

$$(a_0, a_1, \dots, a_\mu, b_0, \dots, b_\nu) \neq (0, \dots, 0).$$

b) Sind $\Phi_1(x) \equiv P_1(x)/Q_1(x)$ und $\Phi_2(x) \equiv P_2(x)/Q_2(x)$ beide Lösungen von $S^{\mu,\nu}$, so folgen sofort für das Polynom

$$P(x) := P_1(x)Q_2(x) - P_2(x)Q_1(x)$$

für $i = 0, 1, \dots, \mu + \nu$, die Beziehungen

$$\begin{aligned} P(x_i) &= P_1(x_i)Q_2(x_i) - P_2(x_i)Q_1(x_i) \\ &= f_i Q_1(x_i)Q_2(x_i) - f_i Q_2(x_i)Q_1(x_i) \\ &= 0, \end{aligned}$$

sowie $\text{Grad } P \leq \mu + \nu$. Also verschwindet $P(x)$ identisch $\Phi_1(x) \sim \Phi_2(x)$. $\square$

Ist nun $\Phi^{\mu,\nu}(x) \equiv P^{\mu,\nu}(x)/Q^{\mu,\nu}(x)$ Lösung von $S^{\mu,\nu}$, so können für jedes $i \in \{0, 1, \dots, \mu + \nu\}$ nur zwei Fälle eintreten:

- 1) $Q^{\mu,\nu}(x_i) \neq 0$,
- 2) $Q^{\mu,\nu}(x_i) = 0$.

Im ersten Fall ist $\Phi^{\mu,\nu}(x_i) = f_i$. Im zweiten folgt zunächst wegen $S^{\mu,\nu}$

$$P^{\mu,\nu}(x_i) = 0,$$

d. h. der rationale Ausdruck $\Phi^{\mu,\nu}$ ist durch den Faktor $x - x_i$ kürzbar und deshalb nicht teilerfremd. Dies zeigt

(2.2.1.4) Falls $S^{\mu,\nu}$ eine Lösung $\Phi^{\mu,\nu}(x)$ besitzt, die teilerfremd ist, treten keine unerreichbaren Punkte auf: $A^{\mu,\nu}$ ist lösbar.

Darüber hinaus gilt

(2.2.1.5) **Satz:** 1. $\Phi^{\mu,\nu}$ sei eine Lösung von $S^{\mu,\nu}$ und $\tilde{\Phi}^{\mu,\nu}$ der zu $\Phi^{\mu,\nu}$ äquivalente teilerfremde rationale Ausdruck. Dann ist $A^{\mu,\nu}$ genau dann lösbar, wenn auch $\tilde{\Phi}^{\mu,\nu}$ das System $S^{\mu,\nu}$ löst.

2. Falls $S^{\mu,\nu}$ maximalen Rang hat, ist $A^{\mu,\nu}$ genau dann lösbar, wenn die Lösung $\Phi^{\mu,\nu}$ von $S^{\mu,\nu}$ teilerfremd ist.

Beweis: 1. Falls $\tilde{\Phi}^{\mu,\nu}$ das System $S^{\mu,\nu}$ löst, dann ist $A^{\mu,\nu}$ wegen (2.2.1.4) lösbar. Andernfalls ist $A^{\mu,\nu}$ unlösbar, denn jeder rationale Ausdruck $\Phi^{\mu,\nu}$ der zu einer Lösung von $A^{\mu,\nu}$ gehört, also auch $\tilde{\Phi}^{\mu,\nu}$, löst $S^{\mu,\nu}$.

2. Das Resultat folgt aus Teil 1, weil die Koeffizienten der rationalen Ausdrücke, die ein Systems $S^{\mu,\nu}$ maximalen Ranges lösen, bis auf gemeinsamen konstanten Faktor $\neq 0$ eindeutig bestimmt sind. $\square$

Daß es sich beim Auftreten unerreichbarer Punkte um Entartungserscheinungen handelt, zeigen folgende Überlegungen.

Wir sagen, daß sich die Stützpunkte (x_i, f_i) , $i = 0, 1, \dots, \sigma$, in *spezieller Lage* befinden, falls sie bereits durch einen rationalen Ausdruck vom Typ $\Phi^{\kappa,\lambda}$ mit $\kappa + \lambda < \sigma$ interpoliert werden können, d. h. wenn man zur Interpolation weniger Freiheitsgrade (nämlich nur $\kappa + \lambda + 1$) benötigt als es die Anzahl $\sigma + 1$ der Stützpunkte erwarten läßt. Es gilt

(2.2.1.6) **Satz:** Die erreichbaren Stützpunkte eines unlösbaren Interpolationsproblems $A^{\mu,\nu}$ befinden sich in spezieller Lage.

Beweis: Seien $i_1, \dots, i_\alpha$ die Indizes, die den unerreichbaren Stützpunkten von $A^{\mu,\nu}$ entsprechen, und sei $\Phi^{\mu,\nu}$ eine Lösung von $S^{\mu,\nu}$. Wir sahen oben, daß dann Zähler- und Nennerpolynom von $\Phi^{\mu,\nu}$ einen gemeinsamen Faktor

$$(x - x_{i_1}) \cdots (x - x_{i_\alpha})$$

besitzen. Kürzen führt daher zu einem rationalen Ausdruck $\Phi^{\kappa,\lambda}$ mit $\kappa = \mu - \alpha$, $\lambda = \nu - \alpha$, der das Interpolationsproblem $A^{\kappa,\lambda}$ löst, das aus den $\mu + \nu + 1 - \alpha$ erreichbaren Punkten von $A^{\mu,\nu}$ besteht. Wegen

$$\kappa + \lambda + 1 = \mu + \nu + 1 - 2\alpha < \mu + \nu + 1 - \alpha$$


befinden sich die erreichbaren Punkte von $A^{\mu,\nu}$ in spezieller Lage. $\square$

Weitere Untersuchungen findet man bei Milne (1950) und Maehly und Witzgall (1960).

Da man diese Entartungen durch kleinste Änderungen der Stützpunkte aufheben kann und ihr Auftreten daher sehr unwahrscheinlich ist, nehmen

wir im folgenden an, daß keine dieser Ausnahmen vorliegt, also keine un-erreichbaren Punkte auftreten und die Systeme $S^{\mu,\nu}$ Höchststrang besitzen.


Die zu besprechenden Algorithmen zur Lösung von $A^{\mu,\nu}$ bzw. $S^{\mu,\nu}$ sind rekursiver Natur, in denen die Grade μ bzw. ν jeweils um 1 erhöht werden. Entsprechend den beiden Freiheitsgraden μ und ν kann man die von dem betreffenden Algorithmus benutzten (μ, ν) -Kombinationen durch einen Weg in der (μ, ν) -Ebene kennzeichnen:



Wir unterscheiden zwei Typen von Algorithmen. Beim ersten wird analog zum Newtonschen Interpolationsverfahren zunächst ein Differenzenschema berechnet, mit dessen Hilfe die Koeffizienten eines interpolierenden rationalen Ausdrucks gewonnen werden. Der zweite Algorithmus entspricht dem Neville-Aitken-Algorithmus. Er verknüpft die $\Phi^{\mu,\nu}$ direkt miteinander.

2.2.2 Inverse und reziproke Differenzen. Der Thielesche Kettenbruch

Die in diesem Abschnitt zu besprechenden Algorithmen dienen dazu, die rationalen Ausdrücke längs der Hauptdiagonalen der μ, ν -Ebene zu berechnen:



(2.2.2.1)

Dazu berechnet man ausgehend von den Stützpunkten (x_i, f_i) , $i = 0, 1, \dots$ zunächst eine Tafel von sog. *inversen Differenzen*:

i	x_i	f_i			
0	x_0	f_0			
1	x_1	f_1	$\varphi(x_0, x_1)$		
2	x_2	f_2	$\varphi(x_0, x_2)$	$\varphi(x_0, x_1, x_2)$	
3	x_3	f_3	$\varphi(x_0, x_3)$	$\varphi(x_0, x_1, x_3)$	$\varphi(x_0, x_1, x_2, x_3)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$

Diese sind definiert durch die Formeln

(2.2.2.2)

$$\varphi(x_i, x_j) = \frac{x_i - x_j}{f_i - f_j},$$

$$\varphi(x_i, x_j, x_k) = \frac{x_j - x_k}{\varphi(x_i, x_j) - \varphi(x_i, x_k)},$$

$$\varphi(x_i, \dots, x_l, x_m, x_n) = \frac{x_m - x_n}{\varphi(x_i, \dots, x_l, x_m) - \varphi(x_i, \dots, x_l, x_n)}.$$

Dabei kann es vorkommen, daß gewisse Differenzen ∞ werden, weil die Nenner in (2.2.2.2) verschwinden.

Die inversen Differenzen sind *keine* symmetrischen Funktionen ihrer Argumente.

Im folgenden bezeichnen wir mit P^μ , Q^ν jeweils Polynome mit Grad $P^\mu \leq \mu$, Grad $Q^\nu \leq \nu$. Wir versuchen nun, mit Hilfe der inversen Differenzen einen rationalen Ausdruck

$$\Phi^{n,n}(x) = \frac{P^n(x)}{Q^n(x)}$$

zu bestimmen mit

$$\Phi^{n,n}(x_i) = f_i \text{ für } i = 0, 1, \dots, 2n.$$

Daraus folgt zunächst:

$$\begin{aligned} \frac{P^n(x)}{Q^n(x)} &= f_0 + \frac{P^n(x)}{Q^n(x)} - \frac{P^n(x_0)}{Q^n(x_0)} \\ &= f_0 + (x - x_0) \frac{P^{n-1}(x)}{Q^n(x)} = f_0 + \frac{(x - x_0)}{Q^n(x)/P^{n-1}(x)}. \end{aligned}$$

Der rationale Ausdruck $Q^n(x)/P^{n-1}(x)$ erfüllt also die Beziehungen

$$\frac{Q^n(x_i)}{P^{n-1}(x_i)} = \frac{x_i - x_0}{f_i - f_0} = \varphi(x_0, x_i)$$

für $i = 1, 2, \dots, 2n$. Es folgt wiederum

$$\begin{aligned}\frac{Q^n(x)}{P^{n-1}(x)} &= \varphi(x_0, x_1) + \frac{Q^n(x)}{P^{n-1}(x)} - \frac{Q^n(x_1)}{P^{n-1}(x_1)} \\ &= \varphi(x_0, x_1) + (x - x_1) \frac{Q^{n-1}(x)}{P^{n-1}(x)} \\ &= \varphi(x_0, x_1) + \frac{x - x_1}{P^{n-1}(x)/Q^{n-1}(x)}\end{aligned}$$

und deshalb

$$\frac{P^{n-1}(x_i)}{Q^{n-1}(x_i)} = \frac{x_i - x_1}{\varphi(x_0, x_i) - \varphi(x_0, x_1)} = \varphi(x_0, x_1, x_i), \quad i = 2, 3, \dots, 2n.$$

Führt man auf diese Weise fort, so erhält man für $\Phi^{n,n}(x)$ den Ausdruck

$$\begin{aligned}\Phi^{n,n}(x) &= \frac{P^n(x)}{Q^n(x)} = f_0 + \frac{x - x_0}{Q^n(x)/P^{n-1}(x)} \\ &= f_0 + \frac{x - x_0}{\varphi(x_0, x_1) + \frac{x - x_1}{P^{n-1}(x)/Q^{n-1}(x)}} = \dots \\ &= f_0 + \frac{x - x_0}{\varphi(x_0, x_1) + \frac{x - x_1}{\varphi(x_0, x_1, x_2) + \dots + \frac{x - x_{2n-1}}{\varphi(x_0, \dots, x_{2n})}}}.\end{aligned}$$

$\Phi^{n,n}(x)$ ist somit in der Form eines *Kettenbruchs* dargestellt:

$$\begin{aligned}(2.2.2.3) \quad \Phi^{n,n}(x) &= f_0 + \frac{x - x_0}{\varphi(x_0, x_1)} + \frac{x - x_1}{\varphi(x_0, x_1, x_2)} + \dots \\ &\quad + \frac{x - x_{2n-1}}{\varphi(x_0, x_1, \dots, x_{2n})}.\end{aligned}$$

Man prüft leicht nach, daß die Teilbrüche dieses Kettenbruchs gerade die rationalen Ausdrücke $\Phi^{\mu,\mu}(x)$ bzw. $\Phi^{\mu+1,\mu}(x)$, $\mu = 0, 1, \dots, n-1$ mit der Eigenschaft (2.2.1.1) sind, die im Tableau (2.2.2.1) markiert sind, also

$$\Phi^{0,0}(x) = f_0,$$

$$\Phi^{1,0}(x) = f_0 + \frac{x - x_0}{\varphi(x_0, x_1)},$$

$$\Phi^{1,1}(x) = f_0 + \frac{x - x_0}{\varphi(x_0, x_1)} + \frac{x - x_1}{\varphi(x_0, x_1, x_2)}, \quad \text{usw.}$$

Beispiel:

i	x_i	f_i	$\varphi(x_0, x_i)$	$\varphi(x_0, x_1, x_i)$	$\varphi(x_0, x_1, x_2, x_i)$
0	0	0			
1	1	-1	-1		
2	2	$-\frac{2}{3}$	-3	$-\frac{1}{2}$	
3	3	9	$\frac{1}{3}$	$\frac{3}{2}$	$\frac{1}{2}$

$$\Phi^{2,1}(x) = 0 + \underline{x\sqrt{-1}} + \underline{x-1\sqrt{-1/2}} + \underline{x-2\sqrt{1/2}} = (4x^2 - 9x)/(-2x + 7).$$

Wegen der fehlenden Symmetrie der inversen Differenzen nimmt man häufig stattdessen die sog. *reziproken Differenzen*

$$\rho(x_i, x_{i+1}, \dots, x_{i+k}),$$

die durch die Rekursionsformeln

(2.2.2.4)

$$\rho(x_i) := f_i,$$

$$\rho(x_i, x_{i+1}) := \frac{x_i - x_{i+1}}{f_i - f_{i+1}},$$

...

$$\rho(x_i, x_{i+1}, \dots, x_{i+k}) := \frac{x_i - x_{i+k}}{\rho(x_i, \dots, x_{i+k-1}) - \rho(x_{i+1}, \dots, x_{i+k})} + \rho(x_{i+1}, \dots, x_{i+k-1})$$

definiert sind. Man kann zeigen, daß die reziproken Differenzen symmetrische Funktionen der Argumente sind. Für einen Beweis siehe etwa Milne-Thompson (1951). Sie hängen mit den inversen Differenzen auf folgende Weise zusammen:

(2.2.2.5) **Satz:** Für $p = 1, 2, \dots$ gilt (mit $\rho(x_0, \dots, x_{p-2}) := 0$ für $p = 1$)

$$\rho(x_0, x_1, \dots, x_p) = \rho(x_0, \dots, x_p) - \rho(x_0, \dots, x_{p-2}).$$

Beweis: Durch vollständige Induktion nach p . Für $p = 1$ ist (2.2.2.5) trivial. Wenn (2.2.2.5) für ein p richtig ist, dann gilt

$$\begin{aligned} \rho(x_0, x_1, \dots, x_{p+1}) &= \frac{x_p - x_{p+1}}{\rho(x_0, \dots, x_p) - \rho(x_0, \dots, x_{p-1}, x_{p+1})} \\ &= \frac{x_p - x_{p+1}}{\rho(x_0, \dots, x_p) - \rho(x_0, \dots, x_{p-1}, x_{p+1})}. \end{aligned}$$

Wegen (2.2.2.4) gilt aber

$$\frac{x_p - x_{p+1}}{\rho(x_p, x_0, \dots, x_{p-1}) - \rho(x_0, \dots, x_{p-1}, x_{p+1})} \\ = \rho(x_p, x_0, \dots, x_{p-1}, x_{p+1}) - \rho(x_0, \dots, x_{p-1}).$$

Aus der Symmetrie der $\rho(\dots)$ folgt daher

$$\varphi(x_0, x_1, \dots, x_{p+1}) = \rho(x_0, \dots, x_{p+1}) - \rho(x_0, \dots, x_{p-1}),$$

was zu zeigen war. $\square$

Die reziproken Differenzen ordnet man in einer Tafel wie folgt an:

$$(2.2.2.6) \quad \begin{array}{c|c|c|c|c} x_0 & f_0 & & & \\ x_1 & f_1 & \underline{\rho(x_0, x_1)} & & \\ x_2 & f_2 & \rho(x_1, x_2) & \underline{\rho(x_0, x_1, x_2)} & \\ x_3 & f_3 & \rho(x_2, x_3) & \rho(x_1, x_2, x_3) & \underline{\rho(x_0, x_1, x_2, x_3)} \\ \vdots & \vdots & \vdots & \vdots & \vdots \end{array}$$

Aus (2.2.2.3) wird bei Verwendung reziproker Differenzen wegen (2.2.2.5) der sog. *Thielesche Kettenbruch*:

(2.2.2.7)

$$\Phi^{n,n}(x) = f_0 + \frac{x - x_0}{\rho(x_0, x_1)} + \frac{x - x_1}{\rho(x_0, x_1, x_2) - \rho(x_0)} + \dots \\ + \frac{x - x_{2n-1}}{\rho(x_0, \dots, x_{2n}) - \rho(x_0, \dots, x_{2n-2})}.$$

2.2.3 Neville-artige Algorithmen

Wir wollen nun einen Algorithmus zur rationalen Interpolation herleiten, der dem Nevilleschen Algorithmus zur Polynominterpolation entspricht. Es sei daran erinnert, daß wir am Ende von 2.2.1 generell vorausgesetzt haben, daß keine Entartungsfälle vorliegen.

Wir bezeichnen mit

$$\Phi_s^{\mu,v}(x) \equiv \frac{P_s^{\mu,v}(x)}{Q_s^{\mu,v}(x)}$$

den rationalen Ausdruck mit

$$\Phi_s^{\mu,v}(x_i) = f_i \text{ für } i = s, s+1, \dots, s+\mu+v.$$

Dabei sind $P_s^{\mu,v}$, $Q_s^{\mu,v}$ Polynome mit Grad $P_s^{\mu,v} \leq \mu$ und Grad $Q_s^{\mu,v} \leq v$; ihre höchsten Koeffizienten nennen wir $p_s^{\mu,v}$ bzw. $q_s^{\mu,v}$:

$$P_s^{\mu,\nu}(x) = p_s^{\mu,\nu} x^\mu + \dots, \quad Q_s^{\mu,\nu}(x) = q_s^{\mu,\nu} x^\nu + \dots$$

Wir schreiben zur Abkürzung

$$\alpha_i := x - x_i, \quad T_s^{\mu,\nu}(x, y) := P_s^{\mu,\nu}(x) - y \cdot Q_s^{\mu,\nu}(x),$$

es gilt also

$$T_s^{\mu,\nu}(x_i, f_i) = 0, \quad i = s, s+1, \dots, s+\mu+\nu.$$

(2.2.3.1) **Satz:** Mit den Startwerten

$$P_s^{0,0}(x) = f_s, \quad Q_s^{0,0}(x) = 1,$$

gelten die folgenden Rekursionsformeln:

a) Übergang $(\mu-1, \nu) \rightarrow (\mu, \nu)$:

$$P_s^{\mu,\nu}(x) = \alpha_s q_s^{\mu-1,\nu} P_{s+1}^{\mu-1,\nu}(x) - \alpha_{s+\mu+\nu} q_{s+1}^{\mu-1,\nu} P_s^{\mu-1,\nu}(x),$$

$$Q_s^{\mu,\nu}(x) = \alpha_s q_s^{\mu-1,\nu} Q_{s+1}^{\mu-1,\nu}(x) - \alpha_{s+\mu+\nu} q_{s+1}^{\mu-1,\nu} Q_s^{\mu-1,\nu}(x).$$

b) Übergang $(\mu, \nu-1) \rightarrow (\mu, \nu)$:

$$P_s^{\mu,\nu}(x) = \alpha_s p_s^{\mu,\nu-1} P_{s+1}^{\mu,\nu-1}(x) - \alpha_{s+\mu+\nu} p_{s+1}^{\mu,\nu-1} P_s^{\mu,\nu-1}(x),$$

$$Q_s^{\mu,\nu}(x) = \alpha_s p_s^{\mu,\nu-1} Q_{s+1}^{\mu,\nu-1}(x) - \alpha_{s+\mu+\nu} p_{s+1}^{\mu,\nu-1} Q_s^{\mu,\nu-1}(x).$$

Beweis: Wir zeigen nur a), der Beweis für b) verläuft analog. Dazu nehmen wir an, daß die rationalen Ausdrücke $\Phi_s^{\mu-1,\nu}$ und $\Phi_{s+1}^{\mu-1,\nu}$ die Interpolationsforderungen erfüllen, d. h.

$$(2.2.3.2) \quad \begin{aligned} T_s^{\mu-1,\nu}(x_i, f_i) &= 0 \text{ für } i = s, \dots, s+\mu+\nu-1, \\ T_{s+1}^{\mu-1,\nu}(x_i, f_i) &= 0 \text{ für } i = s+1, \dots, s+\mu+\nu. \end{aligned}$$

Definiert man $P_s^{\mu,\nu}(x)$, $Q_s^{\mu,\nu}(x)$ durch (2.2.3.1)a) so gilt $\text{Grad } P_s^{\mu,\nu} \leq \mu$ und $\text{Grad } Q_s^{\mu,\nu} \leq \nu$, weil der Koeffizient von $x^{\nu+1}$ verschwindet. Ferner ist

$$T_s^{\mu,\nu}(x, y) = \alpha_s q_s^{\mu-1,\nu} T_{s+1}^{\mu-1,\nu}(x, y) - \alpha_{s+\mu+\nu} q_{s+1}^{\mu-1,\nu} T_s^{\mu-1,\nu}(x, y).$$

Daraus folgt mit (2.2.3.2)

$$T_s^{\mu,\nu}(x_i, f_i) = 0 \text{ für } i = s, \dots, s+\mu+\nu.$$

Unter der generellen Voraussetzung, daß für keine Kombination (μ, ν, s) unerreichbare Punkte auftreten, erhalten wir also in (2.2.3.1) a) tatsächlich Zähler und Nenner von $\Phi_s^{\mu,\nu}$. $\square$

In den Rekursionsformeln von (2.2.3.1) treten leider noch die Koeffizienten $p_s^{\mu-1, \nu-1}$, $q_s^{\mu-1, \nu}$ usw. auf, sie liefern deshalb noch keinen effizienten Algorithmus zur Berechnung von $\Phi_s^{m, n}(x)$ für ein festes gegebenes x . Man kann diese Koeffizienten jedoch eliminieren, dazu dient der folgende Satz.

(2.2.3.3) **Satz:** *Es gilt*

$$a) \quad \Phi_s^{\mu-1, \nu}(x) - \Phi_{s+1}^{\mu-1, \nu-1}(x) = k_1 \frac{(x - x_{s+1}) \cdots (x - x_{s+\mu+\nu-1})}{Q_s^{\mu-1, \nu}(x) Q_{s+1}^{\mu-1, \nu-1}(x)}$$

mit $k_1 = -p_{s+1}^{\mu-1, \nu-1} q_s^{\mu-1, \nu}$, und

$$b) \quad \Phi_{s+1}^{\mu-1, \nu}(x) - \Phi_{s+1}^{\mu-1, \nu-1}(x) = k_2 \frac{(x - x_{s+1}) \cdots (x - x_{s+\mu+\nu-1})}{Q_{s+1}^{\mu-1, \nu}(x) Q_{s+1}^{\mu-1, \nu-1}(x)}$$

mit $k_2 = -p_{s+1}^{\mu-1, \nu-1} q_{s+1}^{\mu-1, \nu}$.

Beweis: Zum Beweis von a) beachte man, daß der Zähler von

$$\begin{aligned} \Phi_s^{\mu-1, \nu}(x) - \Phi_{s+1}^{\mu-1, \nu-1}(x) &= \\ &= \frac{P_s^{\mu-1, \nu}(x) Q_{s+1}^{\mu-1, \nu-1}(x) - P_{s+1}^{\mu-1, \nu-1}(x) Q_s^{\mu-1, \nu}(x)}{Q_s^{\mu-1, \nu}(x) Q_{s+1}^{\mu-1, \nu-1}(x)} \end{aligned}$$

ein Polynom höchstens $(\mu - 1 + \nu)$ -ten Grades ist, dessen höchster Koeffizient gerade $-p_{s+1}^{\mu-1, \nu-1} q_s^{\mu-1, \nu} = k_1$ ist und das nach Definition von $\Phi_s^{\mu-1, \nu}$ und $\Phi_{s+1}^{\mu-1, \nu-1}$ an den $\mu + \nu - 1$ Stellen

$$x_i, \quad i = s + 1, s + 2, \dots, s + \mu + \nu - 1$$

verschwindet. Es hat daher die Form

$$k_1 (x - x_{s+1}) \cdots (x - x_{s+\mu+\nu-1}),$$

so daß a) gilt. Teil b) wird analog bewiesen. □

(2.2.3.4) **Satz:** *Für $\mu \geq 1$, $\nu \geq 1$ gelten die Rekursionsformeln*

$$a) \quad \Phi_s^{\mu, \nu}(x) = \Phi_{s+1}^{\mu-1, \nu}(x) + \frac{\Phi_{s+1}^{\mu-1, \nu}(x) - \Phi_s^{\mu-1, \nu}(x)}{\frac{\alpha_s}{\alpha_{s+\mu+\nu}} \left[1 - \underbrace{\frac{\Phi_{s+1}^{\mu-1, \nu}(x) - \Phi_s^{\mu-1, \nu}(x)}{\Phi_{s+1}^{\mu-1, \nu-1}(x) - \Phi_{s+1}^{\mu-1, \nu-1}(x)}}_* \right] - 1}$$

$$b) \quad \Phi_s^{\mu, \nu}(x) = \Phi_{s+1}^{\mu, \nu-1}(x) + \frac{\Phi_{s+1}^{\mu, \nu-1}(x) - \Phi_s^{\mu, \nu-1}(x)}{\frac{\alpha_s}{\alpha_{s+\mu+\nu}} \left[1 - \frac{\Phi_{s+1}^{\mu, \nu-1}(x) - \Phi_s^{\mu, \nu-1}(x)}{\Phi_{s+1}^{\mu, \nu-1}(x) - \Phi_{s+1}^{\mu-1, \nu-1}(x)} \right] - 1}$$

Beweis: a) Nach (2.2.3.1)a) hat man

$$\Phi_s^{\mu,\nu}(x) = \frac{\alpha_s q_s^{\mu-1,\nu} P_{s+1}^{\mu-1,\nu}(x) - \alpha_{s+\mu+\nu} q_{s+1}^{\mu-1,\nu} P_s^{\mu-1,\nu}(x)}{\alpha_s q_s^{\mu-1,\nu} Q_{s+1}^{\mu-1,\nu}(x) - \alpha_{s+\mu+\nu} q_{s+1}^{\mu-1,\nu} Q_s^{\mu-1,\nu}(x)}.$$

Wir nehmen an, daß $p_{s+1}^{\mu-1,\nu-1} \neq 0$ ist, erweitern diesen Bruch mit

$$\frac{-p_{s+1}^{\mu-1,\nu-1}(x-x_{s+1})(x-x_{s+2})\cdots(x-x_{s+\mu+\nu-1})}{Q_{s+1}^{\mu-1,\nu}(x)Q_s^{\mu-1,\nu}(x)Q_{s+1}^{\mu-1,\nu-1}(x)}$$

und erhalten unter Beachtung von (2.2.3.3)


$$(2.2.3.5) \quad \Phi_s^{\mu,\nu}(x) = \frac{\alpha_s \Phi_{s+1}^{\mu-1,\nu}(x) [\quad]_1 - \alpha_{s+\mu+\nu} \Phi_s^{\mu-1,\nu}(x) [\quad]_2}{\alpha_s [\quad]_1 - \alpha_{s+\mu+\nu} [\quad]_2}$$

mit

$$\begin{aligned} [\quad]_1 &= \Phi_s^{\mu-1,\nu}(x) - \Phi_{s+1}^{\mu-1,\nu-1}(x), \\ [\quad]_2 &= \Phi_{s+1}^{\mu-1,\nu}(x) - \Phi_{s+1}^{\mu-1,\nu-1}(x). \end{aligned}$$

Durch einfache Umformung folgt daraus die Formel a). b) läßt sich analog herleiten. $\square$

Man kann nun mit den Formeln (2.2.3.4)a) und b) nacheinander rationale Ausdrücke (für festes x) berechnen, deren Zähler- und Nennergrad abwechselnd um 1 steigen, was in der (μ, ν) -Tafel einem Zick-Zack-Weg entspricht:



Dazu benötigt man allerdings noch spezielle Formeln für Schritte auf dem linken und dem oberen Rand der Tafel:

Solange für $\nu = 0$ nur μ erhöht wird, handelt es sich um reine Polynominterpolation. Man rechnet dann mit den Nevilleschen Formeln (s. (2.1.2.1))

$$\Phi_s^{0,0}(x) := f_s,$$

$$\Phi_s^{\mu,0}(x) := \frac{\alpha_s \Phi_{s+1}^{\mu-1,0} - \alpha_{s+\mu} \Phi_s^{\mu-1,0}(x)}{\alpha_s - \alpha_{s+\mu}}, \quad \mu = 1, 2, \dots,$$

die für $\nu = 0$ mit unter (2.2.3.4)a) fallen, wenn man dort den mit (*) gekennzeichneten Quotienten durch Null ersetzt, d. h. formal $\Phi_{s+1}^{\mu-1,-1} := \infty$ setzt.

Wird für $\mu = 0$ nur ν erhöht, so kann man dies offenbar auf Polynominterpolation mit den Stützpunkten $(x_i, 1/f_i)$ zurückführen und deshalb mit den Formeln

$$\Phi_s^{0,0}(x) := f_s,$$

$$(2.2.3.7) \quad \Phi_s^{0,\nu}(x) := \frac{\alpha_s - \alpha_{s+\nu}}{\frac{\alpha_s}{\Phi_{s+1}^{0,\nu-1}(x)} - \frac{\alpha_{s+\nu}}{\Phi_s^{0,\nu-1}(x)}}, \quad \nu = 1, 2, \dots,$$

rechnen, die in (2.2.3.4)b) enthalten sind, wenn man dort $\Phi_{s+1}^{-1,\nu-1}(x) := 0$ setzt.

Für die praktische Anwendung der Formeln (2.2.3.4) hat sich die (μ, ν) -Sequenz

$$(0, 0) \rightarrow (0, 1) \rightarrow (1, 1) \rightarrow (1, 2) \rightarrow (2, 2) \rightarrow \dots$$

als besonders günstig erwiesen (punktierter Linie in (2.2.3.6)). Das gilt insbesondere für das wichtige Anwendungsgebiet der Extrapolationsverfahren (s. 3.4, 3.5, 7.2.3, 7.2.14), bei denen man nur an den Werten $\Phi_s^{\mu,\nu}(x)$ für $x = 0$ interessiert ist. Verwendet man diese (μ, ν) -Sequenz, so genügt die Angabe von $\mu + \nu$ statt μ und ν und man schreibt kürzer

$$T_{i,k} := \Phi_s^{\mu,\nu}(x) \text{ mit } i = s + \mu + \nu, \quad k = \mu + \nu.$$

Aus den Formeln (2.2.3.4) a) und b) sowie (2.2.3.7) wird dann der Algorithmus

$$(2.2.3.8) \quad \begin{aligned} T_{i,0} &:= f_i, & T_{i,-1} &:= 0, \\ T_{i,k} &:= T_{i,k-1} + \frac{T_{i,k-1} - T_{i-1,k-1}}{\frac{x - x_{i-k}}{x - x_i} \left[1 - \frac{T_{i,k-1} - T_{i-1,k-1}}{T_{i,k-1} - T_{i-1,k-2}} \right] - 1} \end{aligned}$$

für $1 \leq k \leq i, i = 0, 1, \dots$. Man beachte, daß sich diese Rekursionsformel nur durch die eckige Klammer von der entsprechenden Formel (2.1.2.5) für die Polynominterpolation unterscheidet, wo die Klammer durch 1 ersetzt ist.

Ordnet man die Werte $T_{i,k}$ wie folgt in einem Tableau an, so sind durch die Rekursionsformel immer die 4 Ecken eines Rhombus miteinander verknüpft:

$$\begin{array}{ccccccc}
 (\mu, \nu) = & (0, 0) & (0, 1) & (1, 1) & (1, 2) & \dots \\
 \hline
 & f_0 = T_{0,0} & & & & \\
 0 = T_{0,-1} & & T_{1,1} & & & \\
 & f_1 = T_{1,0} & & T_{2,2} & & \\
 (2.2.3.9) \quad 0 = T_{1,-1} & & T_{2,1} & \longrightarrow & T_{3,3} & \\
 & f_2 = T_{2,0} & & T_{3,2} & \nearrow & \vdots \quad \ddots \\
 0 = T_{2,-1} & & T_{3,1} & & \vdots & \\
 & f_3 = T_{3,0} & & \vdots & & \\
 & \vdots & & \vdots & &
 \end{array}$$

2.2.4 Anwendungen und Vergleich der beschriebenen Algorithmen

Interpolationsformeln werden benutzt, um eine an gewissen Stellen x_i , z. B. durch eine Tafel, gegebene Funktion $f(x)$ mit Hilfe der Werte $f_i = f(x_i)$ auch an anderen Stellen $x \neq x_i$ näherungsweise zu bestimmen. Für gewöhnlich gibt die Interpolation mit Polynomen genügend genaue Resultate. Anders ist es, wenn die Stelle x , für die man einen Näherungswert für $f(x)$ durch Interpolation bestimmen will, in der Nähe eines Pols von $f(x)$ liegt, z. B. wenn $\operatorname{tg} x$ für ein nahe bei $\frac{\pi}{2}$ gelegenes x bestimmt werden soll. In solchen Fällen liefert die Polynominterpolation völlig ungenügende Werte, während die rationale Interpolation wegen ihrer größeren Flexibilität (Möglichkeit von Polen einer rationalen Funktion) durchaus befriedigende Resultate liefert.

Beispiel (entnommen aus Bulirsch und Rutishauser (1968)):

Für die Funktion $f(x) = \operatorname{ctg} x$ liegen in einer Tafel die Werte für $\operatorname{ctg} 1^\circ$, $\operatorname{ctg} 2^\circ$, ... vor. Durch Interpolation soll daraus ein Näherungswert für $\operatorname{ctg} 2^\circ 30'$ berechnet werden.

Polynom-Interpolation 4. Ordnung nach den Formeln (2.1.2.5) ergibt das Tableau

x_i	$f_i = \text{ctg}(x_i)$		
1°	57.28996163		
		14.30939911	
2°	28.63625328	21.47137102	
		23.85869499	22.36661762
3°	19.08113669	23.26186421	22.63519158
		21.47137190	23.08281486
4°	14.30066626	22.18756808	
		18.60658719	
5°	11.43005230		

Rationale Interpolation mit $(\mu, \nu) = (2, 2)$ nach den Formeln (2.2.3.8) ergibt demgegenüber:

1°	57.28996163		
		22.90760673	
2°	28.63625328	22.90341624	
		22.90201805	22.90369573
3°	19.08113669	22.90411487	22.90376552
		22.91041916	22.90384141
4°	14.30066626	22.90201975	
		22.94418151	
5°	11.43005230		

Der exakte Wert ist $\text{ctg } 2^\circ 30' = 22.9037655484 \dots$ (ungenauere Ziffern sind unterstrichen).

Interessiert man sich für die Koeffizienten der interpolierenden rationalen Funktion, so sind die Methoden aus 2.2.2 (inverse Differenzen etc.) vorzuziehen. Interessieren aber nur die Werte der interpolierenden Funktionen für ein bestimmtes x , so ist der durch die Formeln (2.2.3.4) gegebene Neville-artige Algorithmus vorteilhafter. Insbesondere liegt diese Situation bei der Anwendung dieses Algorithmus innerhalb der modernen Extrapolationsverfahren zur Konvergenzbeschleunigung vor (s. Abschnitte 3.4, 3.5, 7.2.3, 7.2.14). Es hat sich gezeigt, daß Extrapolation mit rationalen Funktionen durchweg bessere Resultate liefert, als die auf der Polynominterpolation beruhenden Extrapolationsmethoden. Aus diesem Grunde sind die Extrapolationsformeln (2.2.3.8) von besonderer Bedeutung für die Praxis.

2.3 Trigonometrische Interpolation

2.3.1 Theoretische Grundlagen

Die trigonometrische Interpolation benutzt man zur Analyse periodischer Vorgänge, etwa der Periode 2π . Gegeben seien wieder N Stützpunkte (x_k, f_k) , $k = 0, 1, \dots, N-1$. Wenn die Stützordinaten $f_k = f(x_k) \in \mathbb{C}$ Werte einer 2π -periodischen Funktion sind, $f(x \pm 2\pi) = f(x)$ für alle $x \in \mathbb{R}$, können wir ohne Einschränkung der Allgemeinheit

$$0 \leq x_0 < x_1 < \dots < x_{N-1} < 2\pi$$

voraussetzen. Da die elementaren trigonometrischen Funktionen $\cos hx$ und $\sin hx$ für ganzes h alle die Periode 2π besitzen, liegt es nahe, geeignete Linearkombinationen $\psi(x)$ von N dieser Funktionen zur Interpolation der N Stützpunkte zu verwenden, $\psi(x_k) = f_k$ für $k = 0, 1, \dots, N-1$. Es stellt sich als zweckmäßig heraus, für ungerades $N = 2M+1$ einen trigonometrischen Ausdruck der Form

$$(2.3.1.1a) \quad \Psi(x) := \frac{A_0}{2} + \sum_{h=1}^M (A_h \cos hx + B_h \sin hx)$$

und für gerades $N = 2M$ einen der Form

$$(2.3.1.1b) \quad \Psi(x) := \frac{A_0}{2} + \sum_{h=1}^{M-1} (A_h \cos hx + B_h \sin hx) + \frac{A_M}{2} \cos Mx$$

zu nehmen.

Die Formeln werden bei komplexer Rechnung durchsichtiger. Für komplexe Zahlen $c = a + ib \in \mathbb{C}$, a, b reell, i die imaginäre Einheit, bezeichne $\bar{c} := a - ib$ die konjugiert komplexe Zahl, a den Realteil, b den Imaginärteil und $|c| := (c\bar{c})^{1/2} = (a^2 + b^2)^{1/2}$ den Betrag von c .

Zusätzliche Vereinfachungen ergeben sich für den Fall einer äquidistanten Einteilung des Intervalls $[0, 2\pi]$,

$$x_k := 2\pi k/N, \quad k = 0, 1, \dots, N-1,$$

auf den wir uns im folgenden beschränken. In diesem Fall ist die Interpolation durch trigonometrische Ausdrücke $\psi(x)$ (2.3.1.1) äquivalent zu dem Problem, ein interpolierendes *trigonometrisches Polynom* der *Ordnung* N (sie gibt die Zahl der Koeffizienten an)

$$(2.3.1.2) \quad p(x) := \beta_0 + \beta_1 e^{ix} + \beta_2 e^{2ix} + \dots + \beta_{N-1} e^{(N-1)ix},$$

mit

$$p(x_k) = f_k, \quad k = 0, 1, \dots, N-1,$$

zu bestimmen. Dies folgt leicht aus der Moivreschen Formel

$$e^{ikx} = \cos kx + i \sin kx$$

und der Definition der x_k ,

$$e^{-hix_k} = e^{-2\pi i h k / N} = e^{2\pi i (N-h)k / N} = e^{(N-h)ix_k},$$

so daß

$$(2.3.1.3) \quad \cos hx_k = \frac{e^{hix_k} + e^{(N-h)ix_k}}{2}, \quad \sin hx_k = \frac{e^{hix_k} - e^{(N-h)ix_k}}{2i}.$$

Ersetzt man in $\psi(x)$ (2.3.1.1) für $x = x_k$ die Terme $\cos hx_k$ und $\sin hx_k$ durch (2.3.1.3) und ordnet man die Summanden nach Potenzen von e^{ix_k} um, so findet man ein trigonometrisches Polynom $p(x)$ (2.3.1.2) mit $p(x_k) = \psi(x_k)$ für $k = 0, 1, \dots, N-1$, dessen Koeffizienten β_j mit den Koeffizienten A_h, B_h folgendermaßen zusammenhängen:

(2.3.1.4) (a) Für ungerades $N = 2M + 1$ gilt

$$\beta_0 = \frac{A_0}{2}, \quad \beta_j = \frac{1}{2}(A_j - iB_j), \quad \beta_{N-j} = \frac{1}{2}(A_j + iB_j), \quad j = 1, \dots, M,$$

$$A_0 = 2\beta_0, \quad A_h = \beta_h + \beta_{N-h}, \quad B_h = i(\beta_h - \beta_{N-h}), \quad h = 1, \dots, M.$$

(b) Für gerades $N = 2M$ gilt

$$\beta_0 = \frac{A_0}{2}, \quad \beta_j = \frac{1}{2}(A_j - iB_j), \quad \beta_{N-j} = \frac{1}{2}(A_j + iB_j), \quad j = 1, \dots, M-1,$$

$$\beta_M = \frac{A_M}{2},$$

$$A_0 = 2\beta_0, \quad A_h = \beta_h + \beta_{N-h}, \quad B_h = i(\beta_h - \beta_{N-h}), \quad h = 1, \dots, M-1,$$

$$A_M = 2\beta_M.$$

Entsprechend der Herleitung von (2.3.1.4) stimmen der trigonometrische Ausdruck $\psi(x)$ und das entsprechende trigonometrische Polynom $p(x)$ an den Stützabszissen $x = x_k = 2\pi k/N$, $k = 0, \dots, N-1$, überein, im allgemeinen jedoch nicht für $x \neq x_k$. Die Interpolationsprobleme für $\psi(x)$ und $p(x)$ sind deshalb nur in dem Sinne äquivalent, daß die Lösung eines Problems vermöge (2.3.1.4) sofort eine Lösung des anderen Problems liefert.

Die trigonometrischen Polynome $p(x)$ (2.3.1.2) besitzen eine einfachere Struktur als die trigonometrischen Ausdrücke $\psi(x)$ (2.3.1.1). Mit den Abkürzungen

$$\omega := e^{ix}, \quad \omega_k := e^{ix_k} = e^{2k\pi i/N},$$

$$P(\omega) := \beta_0 + \beta_1\omega + \dots + \beta_{N-1}\omega^{N-1},$$

ist es wegen $\omega_j \neq \omega_k$ für $j \neq k$, $0 \leq j, k \leq N-1$, klar, daß das oben betrachtete trigonometrische Interpolationsproblem mit einem Interpolationsproblem für Polynome identisch ist, nämlich ein (komplexes) Polynom P mit Grad $P \leq N-1$ und

$$P(\omega_k) = f_k, \quad k = 0, 1, \dots, N-1,$$

zu finden. Aus Satz (2.1.1.1) folgt daher sofort

(2.3.1.5) **Satz:** Zu beliebigen Stützpunkten (x_k, f_k) , $k = 0, 1, \dots, N-1$, mit komplexem f_k und $x_k := 2\pi k/N$, gibt es genau ein trigonometrisches Polynom

$$p(x) = \beta_0 + \beta_1 e^{ix} + \dots + \beta_{N-1} e^{(N-1)ix}$$

mit $p(x_k) = f_k$ für $k = 0, 1, \dots, N-1$.

Die Koeffizienten β_j des interpolierenden trigonometrischen Polynoms können explizit angegeben werden. Wir benötigen dazu einige Eigenschaften der ω_k . Zunächst gilt für $0 \leq j, h \leq N-1$

$$(2.3.1.6) \quad \omega_h^j = \omega_j^h, \quad \omega_h^{-j} = \overline{\omega_h^j},$$

und insbesondere die wichtige Formel

$$(2.3.1.7) \quad \sum_{k=0}^{N-1} \omega_k^j \omega_k^{-h} = \begin{cases} N & \text{für } j = h, \\ 0 & \text{für } j \neq h. \end{cases}$$

Beweis: ω_{j-h} ist eine Nullstelle des Polynoms

$$\omega^N - 1 = (\omega - 1)(\omega^{N-1} + \omega^{N-2} + \dots + 1),$$

so daß entweder $\omega_{j-h} = 1$, also $j = h$ gilt, oder

$$\sum_{k=0}^{N-1} \omega_k^j \omega_k^{-h} = \sum_{k=0}^{N-1} \omega_k^{j-h} = \sum_{k=0}^{N-1} \omega_{j-h}^k = 0. \quad \square$$

Führt man auf dem N -dimensionalen komplexen Vektorraum $\mathbb{C}^N$ aller N -Tupel $u = (u_0, u_1, \dots, u_{N-1})$ von komplexen Zahlen u_k das übliche Skalarprodukt ein durch

$$[u, v] := \sum_{j=0}^{N-1} u_j \bar{v}_j,$$

so besagt (2.3.1.7), daß die speziellen N -Vektoren

$$w^{(j)} := (\omega_0^j, \omega_1^j, \dots, \omega_{N-1}^j), \quad j = 0, 1, \dots, N-1,$$

eine *Orthogonalbasis* des $\mathbb{C}^N$ bilden,

$$(2.3.1.8) \quad [w^{(j)}, w^{(h)}] = \begin{cases} N & \text{für } j = h \\ 0 & \text{für } j \neq h. \end{cases}$$

Insbesondere haben die Vektoren $w^{(j)}$ alle die Länge $[w^{(j)}, w^{(j)}]^{1/2} = \sqrt{N}$. Die Beziehungen (2.3.1.7) heißen daher auch *Orthogonalitätsrelationen*. Mit ihrer Hilfe kann man eine explizite Formel für die Koeffizienten β_j von $p(x)$ herleiten:

(2.3.1.9) **Satz:** Für das trigonometrische Polynom $p(x) = \sum_{j=0}^{N-1} \beta_j e^{jix}$ gilt

$$p(x_k) = f_k, \quad k = 0, 1, \dots, N-1,$$

für komplexes f_k und $x_k = 2\pi k/N$ genau dann, wenn

$$(2.3.1.10) \quad \beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k \omega_k^{-j} = \frac{1}{N} \sum_{k=0}^{N-1} f_k e^{-2\pi i j k / N}, \quad j = 0, \dots, N-1.$$

Beweis: Aus $f_k = p(x_k)$ folgt für den N -Vektor $f := (f_0, f_1, \dots, f_{N-1})$

$$f = \sum_{j=0}^{N-1} \beta_j w^{(j)},$$

so daß

$$\begin{aligned} \sum_{k=0}^{N-1} f_k \omega_k^{-j} &= [f, w^{(j)}] = [\beta_0 w^{(0)} + \beta_1 w^{(1)} + \dots + \beta_{N-1} w^{(N-1)}, w^{(j)}] \\ &= N \beta_j. \end{aligned} \quad \square$$

Die Abschnittspolynome

$$p_s(x) := \beta_0 + \beta_1 e^{ix} + \dots + \beta_s e^{s ix}, \quad s \leq N-1,$$

des interpolierenden trigonometrischen Polynoms $p(x)$ haben eine interessante Minimaleigenschaft:

(2.3.1.11) **Satz:** Für jedes $s = 0, 1, \dots, N-1$ minimiert unter allen trigonometrischen Polynomen q der Form

$$q(x) = \gamma_0 + \gamma_1 e^{ix} + \dots + \gamma_s e^{s ix}$$

gerade das s -te Abschnittspolynom $p_s(x)$ von $p(x)$ die „Fehlerquadratsumme“

$$S(q) := \sum_{k=0}^{N-1} |f_k - q(x_k)|^2.$$

Insbesondere ist $S(p) = 0$. Das Abschnittspolynom $p_s(x)$ ist durch diese Minimaleigenschaft eindeutig bestimmt.

Beweis: Mit den N -Vektoren

$$p_s := (p_s(x_0), \dots, p_s(x_{N-1})), \quad q := (q(x_0), \dots, q(x_{N-1}))$$

gilt

$$S(q) = [f - q, f - q].$$

Nun ist wegen (2.3.1.9) $[f, w^{(j)}] = N\beta_j$ für $j = 0, \dots, N-1$ und daher

$$[f - p_s, w^{(j)}] = [f - \sum_{h=0}^s \beta_h w^{(h)}, w^{(j)}] = N\beta_j - N\beta_j = 0, \quad j = 0, 1, \dots, s,$$

sowie

$$[f - p_s, p_s - q] = \sum_{j=0}^s [f - p_s, (\beta_j - \gamma_j)w^{(j)}] = 0.$$

Damit gilt aber

$$\begin{aligned} S(q) &= [f - q, f - q] \\ &= [(f - p_s) + (p_s - q), (f - p_s) + (p_s - q)] \\ &= [f - p_s, f - p_s] + [p_s - q, p_s - q] \\ &\geq [f - p_s, f - p_s] \\ &= S(p_s) \end{aligned}$$

mit Gleichheit nur für $[p_s - q, p_s - q] = 0$, d. h. für $q = p_s$. Wegen des Eindeutigkeitsatzes (2.3.1.5) folgt dann $p_s(x) = q(x)$. $\square$

Wir kehren nun zu den trigonometrischen Ausdrücken (2.3.1.1) zurück. Für sie gilt das folgende Analogon der Sätze (2.3.1.5) und (2.3.1.9):

(2.3.1.12) **Satz:** Die trigonometrischen Ausdrücke (2.3.1.1),

$$\Psi(x) := \frac{A_0}{2} + \sum_{h=1}^M (A_h \cos hx + B_h \sin hx)$$

$$\Psi(x) := \frac{A_0}{2} + \sum_{h=1}^{M-1} (A_h \cos hx + B_h \sin hx) + \frac{A_M}{2} \cos Mx,$$

mit $N = 2M + 1$ bzw. $N = 2M$ genügen

$$\Psi(x_k) = f_k, \quad k = 0, 1, \dots, N-1,$$

für $x_k = 2\pi k/N$ genau dann, wenn für ihre Koeffizienten gilt

$$A_h = \frac{2}{N} \sum_{k=0}^{N-1} f_k \cos hx_k = \frac{2}{N} \sum_{k=0}^{N-1} f_k \cos \frac{2\pi hk}{N}$$

$$B_h = \frac{2}{N} \sum_{k=0}^{N-1} f_k \sin hx_k = \frac{2}{N} \sum_{k=0}^{N-1} f_k \sin \frac{2\pi hk}{N}$$

Beweis: Für die Koeffizienten A_h, B_h gilt nach (2.3.1.4), (2.3.1.9)

$$A_h = \beta_h + \beta_{N-h} = \frac{1}{N} \sum_{k=0}^{N-1} f_k (e^{-hi x_k} + e^{-(N-h)i x_k}),$$

$$B_h = i(\beta_h - \beta_{N-h}) = \frac{i}{N} \sum_{k=0}^{N-1} f_k (e^{-hi x_k} - e^{-(N-h)i x_k}).$$

Die Formeln des Satzes folgen damit aus (2.3.1.3). □

Man beachte, daß für reelle Stützordinaten f_k auch die A_h, B_h in (2.3.1.12) reell sind.

Wir wollen die Abbildung

$$(f_0, f_1, \dots, f_{N-1}) \mapsto \beta = (\beta_0, \beta_1, \dots, \beta_{N-1}),$$

die durch (2.3.1.10) gegeben ist, näher studieren und schreiben sie zunächst mit der Abkürzung $\varepsilon := e^{2\pi i/N}$ in der Form

$$\beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k \varepsilon^{-jk}, \quad j = 0, 1, \dots, N-1.$$

Läßt man hier den Index j alle ganzen Zahlen durchlaufen, $j \in \mathbb{Z}$, so folgt wegen $\varepsilon^N = 1$ sofort

$$\beta_j = \beta_{j+N} \text{ für alle } j \in \mathbb{Z}.$$

Dies legt es nahe, die Menge

$$\mathbb{F}_N := \{(f_k)_{k \in \mathbb{Z}} \mid f_k \in \mathbb{C}, f_{k+N} = f_k \text{ für alle } k \in \mathbb{Z}\}$$

aller N -periodischen Folgen $f = (\dots, f_{-1}, f_0, f_1, \dots)$ komplexer Zahlen einzuführen. Dann beschreibt die (2.3.1.10) entsprechende Formel

$$\beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k \varepsilon^{-jk}, \quad j \in \mathbb{Z},$$

eine lineare Abbildung $\mathcal{F}$ von $\mathbb{F}_N$ in sich, $f \mapsto \beta := \mathcal{F}(f)$, die *diskrete Fouriertransformation (DFT)* heit. Wir wollen ihre wichtigsten Eigenschaften beschreiben. Dabei wird uns folgende Bemerkung helfen:

(2.3.1.13) Fr alle $f \in \mathbb{F}_N$ und $r \in \mathbb{Z}$ sind die Summen

$$S_k := \sum_{j=0}^{N-1} f_{j-k} \varepsilon^{r(j-k)}, \quad k \in \mathbb{Z},$$

von k *unabhngig*.

Dies folgt aus

$$S_k - S_{k-1} = f_k \varepsilon^{-rk} - f_{N-k} \varepsilon^{r(N-k)} = 0.$$

Wegen Satz 2.3.1.9 besitzt $\mathcal{F}$ eine Inverse $\beta \mapsto f = \mathcal{F}^{-1}(\beta)$, die der *Fouriersynthese* entspricht, nmlich der Berechnung eines trigonometrischen Polynoms $p(x)$ (2.3.1.2) an den quidistanten Stellen $x_k = 2\pi k/N$,

$$f_k = \sum_{j=0}^{N-1} \beta_j e^{2\pi i j k / N} = \sum_{j=0}^{N-1} \beta_j \varepsilon^{jk}, \quad k \in \mathbb{Z}.$$

Hier kann k wieder alle ganzen Zahlen durchlaufen, so da $f_k = f_{k+N}$ und $(f_k)_{k \in \mathbb{Z}} \in \mathbb{F}_N$. Wegen $\hat{f}_k = \sum_{j=0}^{N-1} \bar{\beta}_j \varepsilon^{-jk}$ kann man $\mathcal{F}^{-1}$ durch $\mathcal{F}$ ausdrcken,

$$(2.3.1.14) \quad f = \mathcal{F}^{-1}(\beta) = N \overline{\mathcal{F}(\bar{\beta})}.$$

Man kann deshalb zur Fouriersynthese die gleichen Algorithmen wie zur Berechnung von $\mathcal{F}$ verwenden, z.B. die Methoden der schnellen Fouriertransformation, die im nchsten Abschnitt 2.3.2 beschrieben werden.

Fr Anwendungen besonders wichtig ist die *Faltung* $f * g \in \mathbb{F}_N$ zweier Elemente f und g aus $\mathbb{F}_N$, die durch

$$(2.3.1.15) \quad (f * g)_j := \sum_{k=0}^{N-1} f_k g_{j-k}, \quad j \in \mathbb{Z},$$

definiert ist und offensichtlich wieder in $\mathbb{F}_N$ liegt. Fr ihre Fouriertransformierte $\mathcal{F}(f * g)$ gilt die wichtige Formel

$$(2.3.1.16) \quad (\mathcal{F}(f * g))_j = N(\mathcal{F}(f))_j \cdot (\mathcal{F}(g))_j, \quad j \in \mathbb{Z}$$

oder kürzer, $\mathcal{F}(f * g) = N\mathcal{F}(f) \circ \mathcal{F}(g)$, wenn man $f \circ g$ in $\mathbb{F}_N$ als komponentenweises Produkt erklärt, $(f \circ g)_j := f_j \cdot g_j$, $j \in \mathbb{Z}$. Es folgt

$$(2.3.1.17) \quad f * g = N\mathcal{F}^{-1}(\mathcal{F}(f) \circ \mathcal{F}(g)),$$

so daß man in $\mathbb{F}_N$ die Faltung mit Hilfe von drei Fouriertransformationen und N Multiplikationen berechnen kann. Dieses Verfahren ist außerordentlich effizient, wenn man zur Berechnung von $\mathcal{F}$ die Methoden der schnellen Fouriertransformation verwendet (s. Abschnitt 2.3.2).

Beweis von (2.3.1.16): Aus der Definition von $f * g$ folgt für $r \in \mathbb{Z}$

$$\begin{aligned} N(\mathcal{F}(f * g))_r &= \sum_{j=0}^{N-1} \sum_{k=0}^{N-1} f_k \varepsilon^{-rk} g_{j-k} \varepsilon^{-r(j-k)} \\ &= \sum_{k=0}^{N-1} f_k \varepsilon^{-rk} \cdot \sum_{j=0}^{N-1} g_{j-k} \varepsilon^{-r(j-k)} \\ &= \sum_{k=0}^{N-1} f_k \varepsilon^{-rk} \cdot \sum_{j=0}^{N-1} g_j \varepsilon^{-rj} \\ &= N^2(\mathcal{F}(f))_r \cdot (\mathcal{F}(g))_r. \end{aligned}$$

Im Beweis der vorletzten Zeile wurde (2.3.1.13) verwandt. $\square$

In den Anwendungen wird in der Regel die Faltung $c = a * b$ zweier Vektoren

$$a = (a_0, a_1, \dots, a_{N_a-1}), \quad b = (b_0, b_1, \dots, b_{N_b-1})$$

der Längen N_a bzw. N_b als der Vektor

$$c = (c_0, c_1, \dots, c_{N-1})$$

der Länge $N := N_a + N_b - 1$ mit den Komponenten

$$(2.3.1.18) \quad c_j := \sum_{k=\max\{0, j-N_b+1\}}^{\min\{j, N_a-1\}} a_k b_{j-k}, \quad j = 0, 1, \dots, N-1,$$

definiert. Die kompliziert erscheinenden oberen bzw. unteren Schranken bei der Summation stellen nur sicher, daß nur wohldefinierte Werte der a_k, b_{j-k} verwendet werden.

Die Faltung von Vektoren spielt in der Signalverarbeitung und in der Statistik bei der Zeitreihenanalyse eine wichtige Rolle. Ein innermathematisches Beispiel liefert die Multiplikation zweier Polynome

$$a(x) = a_0 + a_1x + \dots + a_{N_a-1}x^{N_a-1}, \quad b(x) = b_0 + b_1x + \dots + b_{N_b-1}x^{N_b-1}$$

vom Grad $N_a - 1$ bzw. $N_b - 1$. Die Koeffizienten c_j des Produktpolynoms $c(x) := a(x)b(x)$,

$$c(x) = c_0 + c_1x + \cdots + c_{N-1}x^{N-1}, \quad N = N_a + N_b - 1,$$

sind durch (2.3.1.18) gegeben.

Der Zusammenhang der Faltung von Vektoren mit der Faltung im $\mathbb{F}_N$ ist einfach: Zunächst erweitert man die Vektoren a und b der Längen N_a bzw. N_b zu Vektoren der Länge $N = N_a + N_b - 1$, indem man sie durch zusätzliche Nullkomponenten auffüllt (engl.: padding), d.h. man setzt

$$\begin{aligned} a_j &:= 0 & \text{für } N_a \leq j \leq N - 1, \\ b_j &:= 0 & \text{für } N_b \leq j \leq N - 1. \end{aligned}$$

Sie werden anschließend N -periodisch zu Elementen $\hat{a}, \hat{b} \in \mathbb{F}_N$ fortgesetzt. Ihre Faltung $\hat{c} := \hat{a} * \hat{b}$ im Sinne von (2.3.1.15) liefert dann genau die Koeffizienten c_j , die durch (2.3.1.18) definiert sind:

$$\hat{c}_j = (\hat{a} * \hat{b})_j = c_j, \quad j = 0, 1, \dots, N - 1.$$

Beweis: Sei $0 \leq j \leq N - 1 = N_a + N_b - 2$ und $\hat{c} = \hat{a} * \hat{b}$. Dann gilt zunächst

$$\hat{c}_j = \sum_{k=0}^{N-1} \hat{a}_k \hat{b}_{j-k} = \sum_{k=0}^{N_a-1} a_k \hat{b}_{j-k}$$

wegen

$$\hat{a}_k = \begin{cases} 0 & \text{für } N_a \leq k \leq N - 1, \\ a_k & \text{für } 0 \leq k < N_a. \end{cases}$$

Schließlich folgt aus

$$\hat{b}_j = \hat{b}_{j-N} = \begin{cases} 0 & \text{für } N_b \leq j \leq N - 1, \\ b_j & \text{für } 0 \leq j < N_b, \end{cases}$$

die Behauptung

$$\hat{c}_j = \sum_{k=\max\{0, j-N_b+1\}}^{\min\{j, N_a-1\}} a_k b_{j-k} = c_j. \quad \square$$

Man kann deshalb auch die Faltung von Vektoren wegen (2.3.1.17) mit Hilfe von drei Fouriertransformationen in $\mathbb{F}_N$, $N = N_a + N_b - 1$, und N Multiplikationen berechnen.

2.3.2 Algorithmen zur schnellen Fouriertransformation

Die Interpolation von Stützpunkten (x_k, f_k) , $k = 0, 1, \dots, N-1$, $x_k = 2\pi k/N$ äquidistant, durch ein trigonometrisches Polynom $p(x) = \sum_{j=0}^{N-1} \beta_j e^{jix}$, und damit die diskrete Fouriertransformation, führt auf Summen der Form (s. Satz (2.3.1.9))

$$(2.3.2.1) \quad \beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k e^{-2\pi i j k / N}, \quad j = 0, 1, \dots, N-1.$$

Die Berechnung solcher Summen ist in der Fourieranalysis von großer Wichtigkeit. Summen dieser Art erhält man auch bei der diskreten Approximation (an äquidistanten Stellen s) von *Fourierintegralen*

$$H(s) = \int_{-\infty}^{\infty} f(t) e^{-2\pi i s t} dt,$$

die in vielen Anwendungen vorkommen. Die direkte Auswertung aller N Summen (2.3.2.1) erfordert $O(N^2)$ Multiplikationen, so daß sie für sehr großes N völlig ungeeignet ist. Es ist deshalb von größter praktischer Bedeutung, daß von Cooley und Tukey (1965) erstmals ein Verfahren gefunden wurde, das zur Berechnung aller Summen (2.3.2.1) (für spezielle Werte von N) lediglich $O(N \log N)$ Multiplikationen benötigt. Verfahren dieser Art sind unter den Namen *schnelle Fouriertransformation* und *FFT-Verfahren* (*Fast-Fourier-Transform*) bekannt. Eine eingehende Beschreibung dieser Methoden findet man z. B. bei Brigham (1974) und Bloomfield (1976).

Es gibt zwei Zugänge zu diesen Methoden: neben dem ursprünglichen Ansatz von Cooley und Tukey ist ein weiteres Verfahren unter dem Namen *Sande-Tukey-Verfahren* bekannt geworden, das von Gentleman und Sande (1966) beschrieben wurde. Beide Verfahren beruhen auf der Darstellung von $N = N_1 N_2 \cdots N_n$ als Produkt kleiner ganzer Zahlen N_m und beide reduzieren das Problem (2.3.2.1) der Größe N auf kleinere Probleme der Größe N_m . Die Verfahren arbeiten am besten für

$$N = 2^n, \quad n > 0 \text{ ganz},$$

und auf diesen Spezialfall wollen wir uns beschränken.

Wir beschreiben zunächst das Verfahren von Sande und Tukey. Mit der Abkürzung

$$\varepsilon_m := e^{-2\pi i / 2^m}$$

läßt sich (2.3.2.1) in der Form

$$(2.3.2.2) \quad N\beta_j = \sum_{k=0}^{N-1} f_k \varepsilon_n^{jk}, \quad j = 0, 1, \dots, N-1,$$

schreiben. Bei der Methode von Sande und Tukey betrachtet man diese Summen getrennt für gerades $j = 2h$ und ungerades $j = 2h + 1$, faßt in beiden Summen für $k = 0, 1, \dots, M - 1$, wobei $M := N/2$, die „komplementären“ Terme $f_k \varepsilon_n^{jk}$ und $f_{k+M} \varepsilon_n^{j(k+M)}$ zusammen und reduziert so die Summen (2.3.2.2) auf entsprechende Summen halber Länge. Wegen $\varepsilon_n^2 = \varepsilon_{n-1}$, $\varepsilon_n^M = -1$ erhält man so

$$\begin{aligned} N\beta_{2h} &= \sum_{k=0}^{N-1} f_k \varepsilon_n^{2hk} = \sum_{k=0}^{M-1} (f_k + f_{k+M}) \varepsilon_{n-1}^{hk} =: \sum_{k=0}^{M-1} f'_k \varepsilon_{n-1}^{hk} \\ N\beta_{2h+1} &= \sum_{k=0}^{N-1} f_k \varepsilon_n^{(2h+1)k} = \sum_{k=0}^{M-1} ((f_k - f_{k+M}) \varepsilon_n^k) \varepsilon_{n-1}^{hk} =: \sum_{k=0}^{M-1} f''_k \varepsilon_{n-1}^{hk} \end{aligned}$$

für $h = 0, 1, \dots, M - 1$.

Diese Summen der Länge $M = N/2$ lassen sich auf die gleiche Weise weiter verkürzen usw. Man erhält so in Verallgemeinerung von (2.3.2.2), (2.3.2.3) für $m = n, n - 1, \dots, 0$ mit den Abkürzungen $M := 2^{m-1}$, $R := 2^{n-m}$ die Beziehungen

$$(2.3.2.4) \quad N\beta_{jR+m} = \sum_{k=0}^{2M-1} f_{r,k}^{(m)} \varepsilon_m^{jk}, \quad r = 0, 1, \dots, R - 1, \quad j = 0, 1, \dots, 2M - 1,$$

wobei die $f_{r,k}^{(m)}$ ausgehend von den Startwerten

$$(2.3.2.5) \quad f_{0,k}^{(n)} := f_k, \quad k = 0, 1, \dots, N - 1,$$

rekursiv definiert sind durch

$$(2.3.2.6) \quad \left. \begin{aligned} f_{r,k}^{(m-1)} &= f_{r,k}^{(m)} + f_{r,k+M}^{(m)} \\ f_{r+R,k}^{(m-1)} &= (f_{r,k}^{(m)} - f_{r,k+M}^{(m)}) \varepsilon_m^k \end{aligned} \right\} \begin{cases} m = n, n - 1, \dots, 1, \\ r = 0, 1, \dots, R - 1, \\ k = 0, 1, \dots, M - 1. \end{cases}$$

Beweis: durch Induktion nach m . (2.3.2.4) ist richtig für $m = n$ ($M = N/2$, $R = 1$) wegen (2.3.2.2) und (2.3.2.5). Sei nun (2.3.2.4) richtig für ein $m \leq n$, und sei $M' := M/2 = 2^{m-2}$, $R' := 2R = 2^{n-m+1}$. Es folgt dann für $j = 2h$ bzw. $j = 2h + 1$ durch Zusammenfassen komplementärer Terme in (2.3.2.4) wegen (2.3.2.6)

$$\begin{aligned}
N\beta_{hR'+r} &= N\beta_{jR+r} = \sum_{k=0}^{M-1} (f_{r,k}^{(m)} + f_{r,k+M}^{(m)}) \varepsilon_m^{jk} = \sum_{k=0}^{2M'-1} f_{r,k}^{(m-1)} \varepsilon_{m-1}^{hk}, \\
N\beta_{hR'+r+R} &= N\beta_{jR+r} = \sum_{k=0}^{M-1} (f_{r,k}^{(m)} - f_{r,k+M}^{(m)}) \varepsilon_m^{jk} \\
&= \sum_{k=0}^{M-1} (f_{r,k}^{(m)} - f_{r,k+M}^{(m)}) \varepsilon_m^k \varepsilon_{m-1}^{hk} = \sum_{k=0}^{2M'-1} f_{r+R,k}^{(m-1)} \varepsilon_{m-1}^{hk}
\end{aligned}$$

für $r = 0, 1, \dots, R-1, j = 0, 1, \dots, 2M-1$. $\square$

Ausgehend von den Startwerten (2.3.2.5) liefern die Rekursionsformeln (2.3.2.6) des Sande-Tukey-Verfahrens so schließlich für $m = 0$ ($M = 1/2$, $R = N$) wegen (2.3.2.4) die gesuchten

$$\beta_r = \frac{1}{N} f_{r,0}^{(0)}, \quad r = 0, 1, \dots, N-1.$$

Die Programmierung des Verfahrens ist leicht, wenn zwei arrays der Länge N zur gleichzeitigen Speicherung der alten Werte $f_{*,*}^{(m)}$ und der neuen Werte $f_{*,*}^{(m-1)}$ zur Verfügung stehen, die in (2.3.2.6) erzeugt werden. Für sehr großes N kann dies zu Schwierigkeiten führen. Es ist deshalb wichtig, daß man zur Realisierung des Verfahrens mit nur einem linearen array $\tilde{f}[0 : N-1]$ zur Speicherung der N Größen $f_{r,k}^{(m)}$, $r = 0, 1, \dots, R-1, k = 0, 1, \dots, 2M-1$ auskommt, wenn man nach Auswertung von (2.3.2.6) $f_{r,k}^{(m)}$ und $f_{r,k+M}^{(m)}$ mit $f_{r,k}^{(m-1)}$ und $f_{r+R,k}^{(m-1)}$ überschreibt. Dies läuft darauf hinaus, daß man $f_{r,k}^{(m)} = \tilde{f}[\tau(m, r, k)]$ als τ -te Komponente von $\tilde{f}[\]$ speichert, wobei $\tau = \tau(m, r, k)$ eine Indexabbildung τ ist, die den Bedingungen

$$\begin{aligned}
(2.3.2.7) \quad & \tau(m-1, r, k) = \tau(m, r, k) \\
& \tau(m-1, r+2^{n-m}, k) = \tau(m, r, k+2^{m-1})
\end{aligned}$$

für $m = n, n-1, \dots, 1, r = 0, 1, \dots, 2^{n-m}-1$ und $k = 0, 1, \dots, 2^{m-1}-1$ genügen muß. Als Startwerte nimmt man

$$(2.3.2.8) \quad \tau(n, 0, k) := k \quad \text{für } k = 0, 1, \dots, N-1,$$

was der Speicherung der f_k in ihrer natürlichen Ordnung entspricht,

$$\tilde{f}[k] := f_k, \quad k = 0, 1, \dots, N-1.$$

Eine explizite Formel für die Indexabbildung $\tau(m, r, k)$ erhält man mit Hilfe der Binärdarstellung der ganzen Zahlen t mit $0 \leq t < 2^n$

$$t = \alpha_0 + \alpha_1 \cdot 2 + \cdots + \alpha_{n-1} \cdot 2^{n-1}, \quad \alpha_j = 0, 1 \quad \text{für } j = 0, 1, \dots, n-1.$$

Dazu bezeichnen wir mit

$$(2.3.2.9) \quad \rho(t) := \alpha_{n-1} + \alpha_{n-2} \cdot 2 + \cdots + \alpha_0 \cdot 2^{n-1}$$

die ganze Zahl mit $0 \leq \rho(t) < 2^n$, die man aus t durch die *Bit-Umkehrabbildung* (*bit-reversal*) ρ erhält. Offensichtlich beschreibt ρ eine selbstinverse Permutation, d. h. $\rho(\rho(t)) = t$. Mit diesen Bezeichnungen gilt für die Indexabbildung

$$(2.3.2.10) \quad \tau(m, r, k) = k + \rho(r)$$

für alle $m = n, n-1, \dots, 0$, $r = 0, 1, \dots, 2^{n-m} - 1$ und $k = 0, 1, \dots, 2^m - 1$.

Beweis: Die Behauptung ist für $m = n$ wegen (2.3.2.8) richtig. Wenn sie für ein m mit $n \geq m > 0$ richtig ist, dann auch für $m-1$. Dies kann man so zeigen: Jedes $k = 0, 1, \dots, 2^{m-1} - 1$ und jedes $r = 0, 1, \dots, 2^{n-m} - 1$ besitzen eine Binärdarstellung der Form ($\alpha_j = 0, 1$)

$$\begin{aligned} k &= \alpha_0 + \alpha_1 \cdot 2 + \cdots + \alpha_{m-2} \cdot 2^{m-2} + 0 \cdot 2^{m-1}, \\ r &= \alpha_n + \alpha_{n-1} \cdot 2 + \cdots + \alpha_m \cdot 2^{n-m-1} + 0 \cdot 2^{n-m}. \end{aligned}$$

Es gilt deshalb (vgl. (2.3.2.7))

$$\begin{aligned} k + \rho(r + 2^{n-m}) &= k + 2^{m-1} + \rho(r) \\ &= \alpha_0 + \alpha_1 \cdot 2 + \cdots + \alpha_{m-2} \cdot 2^{m-2} + 1 \cdot 2^{m-1} \\ &\quad + \alpha_m \cdot 2^m + \cdots + \alpha_{n-1} \cdot 2^{n-1}. \end{aligned}$$

Daraus folgt die Behauptung. □

Für $m = 0$ folgt insbesondere aus (2.3.2.10)

$$(2.3.2.11) \quad \tau(0, r, 0) = \rho(r) \quad r = 0, 1, \dots, N-1.$$

Das folgende Pseudo-ALGOL-Programm für das Sande-Tukey-Verfahren beruht auf (2.3.2.6) und verwendet die Speicherabbildung $\tau(m, r, k)$:


```

for  $m := n$  step  $-1$  until  $1$  do
  begin for  $k := 0$  step  $1$  until  $2^{m-1} - 1$  do
    begin  $e := \varepsilon_m^k$ ;
      for  $\tilde{r} := 0$  step  $2^m$  until  $2^n - 1$  do
        begin
           $u := \tilde{f}[\tilde{r} + k]; \quad v := \tilde{f}[\tilde{r} + k + 2^{m-1}];$ 
           $\tilde{f}[\tilde{r} + k] := u + v; \quad \tilde{f}[\tilde{r} + k + 2^{m-1}] := (u - v) \times e$ 
        end
      end
    end
  end ;

```

Initialisiert man den array $\tilde{f}$ entsprechend (2.3.2.8), $\tilde{f}[k] := f_k, k = 0, 1, \dots, N - 1$, so gilt nach Verlassen des Programms wegen (2.3.2.4) und (2.3.2.11)

$$\tilde{f}[\rho(r)] = N\beta_r, \quad r = 0, 1, \dots, N - 1.$$

Man erhält die β_j (bis auf den Faktor N) durch eine Permutation der Komponenten von $\tilde{f}$.

Zur Herleitung des Verfahrens von Cooley und Tukey (1965) geht man von den Interpolationseigenschaften [Satz (2.3.1.9)]

$$p(x_k) = f_k, \quad k = 0, 1, \dots, N - 1, \quad x_k := 2\pi k/N,$$

des trigonometrischen Polynoms $p(x) := \beta_0 + \beta_1 e^{ix} + \dots + \beta_{N-1} e^{(N-1)ix}$ der Ordnung N aus. Sei wieder $N = 2^n$. Ferner seien $q(x)$ und $r(x)$ diejenigen trigonometrischen Polynome der halben Ordnung $M := N/2$ mit

$$q(x_{2h}) = f_{2h}, \quad r(x_{2h}) = f_{2h+1}, \quad h = 0, 1, \dots, M - 1.$$

Dann interpoliert $q(x)$ alle *geradzahlig* indizierten Stützpunkte und $\hat{r}(x) := r(x - 2\pi/N) = r(x - \pi/M)$ alle Stützpunkte (x_k, f_k) mit *ungeradem* Index k . Wegen

$$e^{Mix_k} = e^{2\pi i M k / N} = e^{\pi i k} = \begin{cases} 1 & \text{für gerades } k, \\ -1 & \text{für ungerades } k, \end{cases}$$

interpoliert daher das trigonometrische Polynom

$$(2.3.2.12) \quad \tilde{p}(x) := q(x) \left(\frac{1 + e^{Mix}}{2} \right) + r(x - \pi/M) \left(\frac{1 - e^{Mix}}{2} \right)$$

der Ordnung $2M = N$ alle Stützpunkte $(x_k, f_k), k = 0, 1, \dots, N - 1$, stimmt also mit $p(x)$ überein [Satz (2.3.1.5)]. Wir haben so die Bestimmung von $p(x)$ auf die Bestimmung zweier anderer trigonometrischer Polynome halber

Ordnung zurückgeführt. Dieses Vorgehen kann man natürlich wiederholen. Man bekommt so ein n -stufiges Rekursionsverfahren. Für $m \leq n$ setzen wir wieder $M := 2^{m-1}$ und $R := 2^{n-m}$. Schritt m des Verfahrens besteht dann darin, R trigonometrische Polynome der Form ($r = 0, 1, \dots, R-1$)

$$(2.3.2.13) \quad p_r^{(m)}(x) = \beta_{r,0}^{(m)} + \beta_{r,1}^{(m)} e^{ix} + \dots + \beta_{r,2M-1}^{(m)} e^{(2M-1)ix},$$

mit den Interpolationseigenschaften

$$(2.3.2.14) \quad p_r^{(m)}(x_{Rh}) = f_{Rh+r}, \quad h = 0, 1, \dots, 2M-1, \quad r = 0, 1, \dots, R-1,$$

aus $2R$ trigonometrischen Polynomen $p_r^{(m-1)}(x)$, $r = 0, 1, \dots, 2R-1$, der Ordnung M mittels der Rekursionsformel (2.3.2.12) zu bestimmen,

$$2p_r^{(m)}(x) = p_r^{(m-1)}(x) \cdot (1 + e^{Mix}) + p_{R+r}^{(m-1)}(x - \pi/M) \cdot (1 - e^{Mix}).$$

Dies liefert folgende Rekursion für die Koeffizienten dieser trigonometrischen Polynome

$$(2.3.2.15) \quad \left. \begin{aligned} 2\beta_{r,j}^{(m)} &= \beta_{r,j}^{(m-1)} + \beta_{R+r,j}^{(m-1)} \varepsilon_m^j \\ 2\beta_{r,M+j}^{(m)} &= \beta_{r,j}^{(m-1)} - \beta_{R+r,j}^{(m-1)} \varepsilon_m^j \end{aligned} \right\} \begin{cases} r = 0, 1, \dots, R-1, \\ j = 0, 1, \dots, M-1, \end{cases}$$

wobei wieder $\varepsilon_m := \exp(-2\pi i/2^m) = \exp(-\pi i/M)$. Wegen (2.3.2.14) gilt für die Startwerte der Rekursion

$$\beta_{k,0}^{(0)} := f_k, \quad k = 0, 1, \dots, N-1,$$

und sie liefert für $m = n$ schließlich die gesuchten

$$\beta_j := \beta_{0,j}^{(n)}, \quad j = 0, 1, \dots, N-1.$$

Zur praktischen Realisierung dieses Verfahrens benötigt man wieder nur einen linearen array $\tilde{\beta}[0 : N-1]$ zur Speicherung der Koeffizienten $\beta_{r,j}^{(m)}$, wenn man nach der Auswertung von (2.3.2.15) $\beta_{r,j}^{(m-1)}$ und $\beta_{R+r,j}^{(m-1)}$ durch $\beta_{r,j}^{(m)}$ bzw. $\beta_{r,M+j}^{(m)}$ überschreibt. Dies läuft auf die Benutzung der gleichen Indexabbildung $\tau(m, r, k)$ (2.3.2.10) hinaus,

$$\tilde{\beta}[\tau(m, r, k)] = \beta_{r,k}^{(m)},$$

wie sie oben definiert wurde. Insbesondere ist

$$\tau(0, k, 0) = \rho(k), \quad \tau(n, 0, k) = k \quad \text{für } k = 0, 1, \dots, N-1.$$

Wir haben also jetzt wegen der veränderten Laufrichtung der Rekursion (2.3.2.15) gegenüber (2.3.2.6) die Komponenten des *Startvektors* $\tilde{\beta}[\]$ entsprechend $\rho(\)$ zu permutieren

$$\tilde{\beta}[\rho(k)] := f_k, \quad k = 0, 1, \dots, N-1.$$

Das folgende Pseudo-ALGOL-Programm des Cooley-Tukey Algorithmus liefert dann schließlich

$$\tilde{\beta}[k] = N\beta_k, \quad k = 0, 1, \dots, N-1,$$

in der natürlichen Anordnung. [Der Faktor $N = 2^n$ erklärt sich daraus, daß in dem Programm der Faktor 2 in (2.3.2.15) fortgelassen wurde.]

```

for  $m := 1$  step 1 until  $n$  do
  begin for  $j := 0$  step 1 until  $2^{m-1} - 1$  do
    begin  $e := \varepsilon_m^j$ ;
      for  $\bar{r} := 0$  step  $2^m$  until  $2^n - 1$  do
        begin  $u := \tilde{\beta}[\bar{r} + j]$ ;  $v := \tilde{\beta}[\bar{r} + j + 2^{m-1}] \times e$ ;
           $\tilde{\beta}[\bar{r} + j] := u + v$ ;  $\tilde{\beta}[\bar{r} + j + 2^{m-1}] := u - v$ 
        end
      end
    end
  end ;

```

Falls alle f_k reell sind und $N = 2M$ gerade ist, läßt sich die Berechnung der Ausdrücke (2.3.2.1) ebenfalls vereinfachen. Setzt man

$$g_h := f_{2h} + i f_{2h+1}, \quad h = 0, 1, \dots, M-1,$$

sowie

$$\gamma_j := \frac{1}{M} \sum_{h=0}^{M-1} g_h e^{-2\pi i j h / M}, \quad j = 0, 1, \dots, M-1,$$

so kann man die β_j mit Hilfe der γ_j , $j = 0, 1, \dots, M-1$, berechnen. Es gilt nämlich mit $\gamma_M := \gamma_0$

(2.3.2.16)

$$\begin{aligned} \beta_j &= \frac{1}{4}(\gamma_j + \bar{\gamma}_{M-j}) + \frac{1}{4i}(\gamma_j - \bar{\gamma}_{M-j})e^{-2\pi i j / N}, \quad j = 0, 1, \dots, M \\ \beta_{N-j} &= \bar{\beta}_j, \quad j = 1, 2, \dots, M-1. \end{aligned}$$

Beweis: Man bestätigt leicht anhand der Definition der γ_h

$$\begin{aligned} \frac{1}{4}(\gamma_j + \bar{\gamma}_{M-j}) &= \frac{1}{N} \sum_{h=0}^{M-1} f_{2h} e^{-2\pi i j 2h / N}, \\ \frac{1}{4i}(\gamma_j - \bar{\gamma}_{M-j}) &= \frac{1}{N} \sum_{h=0}^{M-1} f_{2h+1} e^{-2\pi i j (2h+1) / N + 2\pi i j / N}, \end{aligned}$$

woraus sofort (2.3.2.16) folgt. □

Die Berechnung von Summen

$$A_j := \frac{2}{N} \sum_{k=0}^{N-1} f_k \cos \frac{2\pi jk}{N}, \quad B_j := \frac{2}{N} \sum_{k=0}^{N-1} f_k \sin \frac{2\pi jk}{N}, \quad j = 0, 1, \dots, M,$$

für reelles f_k , $N = 2M$, an denen man häufig interessiert ist (s. Satz (2.3.1.12)), führt man mittels (2.3.1.4) auf die Berechnung der β_j (2.3.2.1) zurück.

2.3.3 Die Algorithmen von Goertzel und Reinsch

Bei der *Fouriersynthese*, nämlich der Auswertung der trigonometrischen Ausdrücke $\Psi(x)$ in (2.3.1.1) oder der trigonometrischen Polynome $p(x)$ (2.3.1.2) für ein *beliebiges* Argument² $x = \xi$, hat man Summen der Form

$$\sum_{k=0}^{N-1} y_k \cos k\xi, \quad \sum_{k=1}^{N-1} y_k \sin k\xi$$

für gegebene Zahlen ξ und y_k , $k = 0, \dots, N-1$, zu berechnen. Es liegt nahe, dabei die Funktionswerte $\cos k\xi$, $\sin k\xi$, $k = 0, 1, \dots$, rekursiv zu bestimmen, doch sollte man auf die numerische Stabilität achten.

So kann man für beliebiges N solche Summen leicht mit Hilfe eines von Goertzel (1958) angegebenen Algorithmus berechnen, der jedoch leider nicht gutartig ist. Goertzels Algorithmus beruht auf folgendem

(2.3.3.1) **Satz:** Für $\xi \neq r\pi$, $r = 0, \pm 1, \pm 2, \dots$, gelten für die Größen

$$U_j := \frac{1}{\sin \xi} \sum_{k=j}^{N-1} y_k \sin(k-j+1)\xi, \quad j = 0, 1, \dots, N-1,$$

$$U_N := U_{N+1} := 0,$$

die Rekursionsformeln

$$(2.3.3.1a) \quad U_j = y_j + 2U_{j+1} \cos \xi - U_{j+2}, \quad j = N-1, N-2, \dots, 0.$$

Insbesondere gilt

$$(2.3.3.1b) \quad \sum_{k=1}^{N-1} y_k \sin k\xi = U_1 \sin \xi,$$

$$(2.3.3.1c) \quad \sum_{k=0}^{N-1} y_k \cos k\xi = y_0 + U_1 \cos \xi - U_2.$$

² Für äquidistante Argumente $\xi = \xi_k = 2\pi k/N$, $k = 0, 1, \dots, N-1$, sind die Methoden der schnellen Fouriertransformation [s. Abschnitt 2.3.2] sehr viel effektiver.

Beweis: b) folgt sofort aus der Definition von U_1 . Zum Beweis von a) sei für ein j mit $0 \leq j \leq N-1$

$$A := y_j + 2U_{j+1} \cos \xi - U_{j+2}.$$

Es ist dann

$$\begin{aligned} A &= y_j + \frac{1}{\sin \xi} \left\{ 2 \cos \xi \sum_{k=j+1}^{N-1} y_k \sin(k-j)\xi - \sum_{k=j+2}^{N-1} y_k \sin(k-j-1)\xi \right\} \\ &= y_j + \frac{1}{\sin \xi} \sum_{k=j+1}^{N-1} y_k [2 \cos \xi \sin(k-j)\xi - \sin(k-j-1)\xi]. \end{aligned}$$

Wegen $2 \cos \xi \sin(k-j)\xi = \sin(k-j+1)\xi + \sin(k-j-1)\xi$ folgt

$$A = \frac{1}{\sin \xi} \left[y_j \sin \xi + \sum_{k=j+1}^{N-1} y_k \sin(k-j+1)\xi \right] = U_j.$$

Formel c) wird ebenso bewiesen unter Verwendung von

$$U_2 = \frac{1}{\sin \xi} \sum_{k=2}^{N-1} y_k \sin(k-1)\xi = \frac{1}{\sin \xi} \sum_{k=1}^{N-1} y_k \sin(k-1)\xi,$$

und

$$\sin(k-1)\xi = \cos \xi \sin k\xi - \sin \xi \cos k\xi. \quad \square$$

Die Anwendung der Formeln von Satz (2.3.3.1) liefert Goertzel's Algorithmus zur Berechnung der Summen $s1 = \sum_{k=0}^{N-1} y_k \cos k\xi$, $s2 = \sum_{k=1}^{N-1} y_k \sin k\xi$:

$$U_N := U_{N+1} := 0; \quad c := \cos \xi; \quad cc := 2 \cdot c;$$

$$\text{für } j := N-1, N-2, \dots, 1:$$

$$U_j := y_j + cc \cdot U_{j+1} - U_{j+2};$$

$$s1 := y_0 + U_1 \cdot c - U_2;$$

$$s2 := U_1 \cdot \sin \xi;$$

Leider ist dieser Algorithmus für kleines $|\xi| \ll 1$ nicht gutartig. Nach Berechnung von $c := \cos \xi$ hängt die Größe $s1 = \sum_{k=0}^{N-1} y_k \cos k\xi$ nur noch von c und den y_k ab, $s1 = \varphi(c, y_0, \dots, y_{N-1})$:

$$\varphi(c, y_0, \dots, y_{N-1}) = \sum_{k=0}^{N-1} y_k \cos(k \arccos c).$$

Wie in Abschnitt 1.2 sei $\text{eps} = 5 \cdot 10^{-t}$ die relative Maschinengenauigkeit. Der Rundungsfehler $\Delta c = \varepsilon_c c$, $|\varepsilon_c| \leq \text{eps}$, den man bei der Berechnung von c begeht, bewirkt in erster Näherung folgenden absoluten Fehler in $s1$:

$$\begin{aligned}\Delta_{cs}1 &\doteq \frac{\partial \varphi}{\partial c} \Delta c = \frac{\varepsilon_c \cos \xi}{\sin \xi} \sum_{k=0}^{N-1} k y_k \sin k\xi \\ &= \varepsilon_c \operatorname{ctg} \xi \sum_{k=0}^{N-1} k y_k \sin k\xi.\end{aligned}$$

Ein Fehler $\Delta \xi = \varepsilon_\xi \xi$, $|\varepsilon_\xi| \leq \text{eps}$, in ξ würde dagegen nur den absoluten Fehler

$$\begin{aligned}\Delta_{\xi} s1 &\doteq \frac{\partial}{\partial \xi} \left(\sum_{k=0}^{N-1} y_k \cos k\xi \right) \cdot \Delta \xi \\ &= -\varepsilon_\xi \xi \sum_{k=0}^{N-1} k y_k \sin k\xi\end{aligned}$$

in $s1$ bewirken. Für kleines $|\xi|$ ist wegen $\operatorname{ctg} \xi \approx 1/\xi$ der Einfluß des bei der Berechnung von c begangenen Rundungsfehlers um Größenordnungen schlimmer als der eines entsprechenden Fehlers in ξ . Der Algorithmus ist daher nicht gutartig.

Von Reinsch stammt eine gutartige Variante (s. Bulirsch und Stoer (1968)). Er unterscheidet zwei Fälle: a) $\cos \xi > 0$ und b) $\cos \xi \leq 0$.

a) $\cos \xi > 0$: Mit $\delta U_j := U_j - U_{j+1}$ ist wegen (2.3.3.1a)

$$\begin{aligned}\delta U_j &= U_j - U_{j+1} = y_j + (2 \cos \xi - 2)U_{j+1} + U_{j+1} - U_{j+2} \\ &= y_j + \lambda U_{j+1} + \delta U_{j+1}.\end{aligned}$$

Dabei ist $\lambda := 2(\cos \xi - 1) = -4 \sin^2(\xi/2)$. Man hat somit in diesem Fall den Algorithmus:

$$\begin{aligned}\lambda &:= -4 \sin^2(\xi/2); \\ U_{N+1} &:= \delta U_N := 0; \\ \text{für } j &:= N-1, N-2, \dots, 0: \\ &\quad U_{j+1} := \delta U_{j+1} + U_{j+2}; \\ &\quad \delta U_j := \lambda \cdot U_{j+1} + \delta U_{j+1} + y_j; \\ s1 &:= \delta U_0 - \lambda \cdot U_1/2; \\ s2 &:= U_1 \cdot \sin \xi;\end{aligned}$$

Dieser Algorithmus ist gutartig bzgl. der Fortpflanzung des Rundungsfehlers $\Delta\lambda = \varepsilon_\lambda \lambda$, $|\varepsilon_\lambda| \leq \text{eps}$, bei der Berechnung von λ . Er liefert nur folgenden Beitrag $\Delta_\lambda s1$ zum Fehler von $s1$:

$$\begin{aligned}\Delta_\lambda s1 &\doteq \frac{\partial s1}{\partial \lambda} \Delta\lambda = \varepsilon_\lambda \lambda \frac{\partial s1}{\partial \xi} \bigg/ \frac{\partial \lambda}{\partial \xi} \\ &= -\varepsilon_\lambda \frac{\sin^2(\xi/2)}{\sin(\xi/2) \cdot \cos(\xi/2)} \cdot \sum_{k=0}^{N-1} k y_k \sin k\xi \\ &= -\varepsilon_\lambda \left(\operatorname{tg} \frac{\xi}{2} \right) \sum_{k=0}^{N-1} k y_k \sin k\xi.\end{aligned}$$

Für $\cos \xi > 0$ ist $|\operatorname{tg}(\xi/2)| < 1$, insbesondere ist $|\operatorname{tg}(\xi/2)|$ für kleines $|\xi|$ klein!

b) $\cos \xi \leq 0$: Mit $\delta U_j := U_j + U_{j+1}$ hat man jetzt

$$\begin{aligned}\delta U_j &= U_j + U_{j+1} = y_j + (2 \cos \xi + 2)U_{j+1} - U_{j+1} - U_{j+2} \\ &= y_j + \lambda U_{j+1} - \delta U_{j+1},\end{aligned}$$

wobei nun $\lambda := 2(\cos \xi + 1) = 4 \cos^2(\xi/2)$ ist. Man hat jetzt den Algorithmus:

$$\begin{aligned}\lambda &:= 4 \cos^2(\xi/2); \\ U_{N+1} &:= \delta U_N := 0; \\ \text{für } j &:= N-1, N-2, \dots, 0: \\ &\quad U_{j+1} := \delta U_{j+1} - U_{j+2}; \\ &\quad \delta U_j := \lambda \cdot U_{j+1} - \delta U_{j+1} + y_j; \\ s1 &:= \delta U_0 - U_1 \cdot \lambda/2; \\ s2 &:= U_1 \cdot \sin \xi;\end{aligned}$$

Wiederum bestätigt man, daß ein Rundungsfehler $\Delta\lambda = \varepsilon_\lambda \lambda$, $|\varepsilon_\lambda| \leq \text{eps}$, bei der Berechnung von λ nur folgenden Fehler in $s1$ bewirkt:

$$\Delta_\lambda s1 \doteq \varepsilon_\lambda \left(\operatorname{ctg} \frac{\xi}{2} \right) \sum_{k=0}^{N-1} k y_k \sin k\xi.$$

Für $\cos \xi \leq 0$ ist $|\operatorname{ctg}(\xi/2)| \leq 1$ klein, also ist der Algorithmus gutartig, was die Fortpflanzung des Fehlers ε_λ betrifft.

2.3.4 Die näherungsweise Berechnung von Fourierkoeffizienten. Abminderungsfaktoren

Sei $\mathcal{H}$ die Menge aller absolutstetigen³ 2π -periodischen reellen Funktionen $f: \mathbb{R} \rightarrow \mathbb{R}$. Es ist bekannt (s. z. B. Achieser (1953)), daß sich jede Funktion $f \in \mathcal{H}$ in eine für alle $x \in \mathbb{R}$ gegen $f(x)$ konvergente Fourierreihe

$$(2.3.4.1) \quad f(x) = \sum_{j=-\infty}^{\infty} c_j e^{jix}$$

mit den Koeffizienten

$$(2.3.4.2) \quad c_j = c_j(f) := \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-jix} dx, \quad j = 0, \pm 1, \pm 2, \dots,$$

entwickeln läßt. Häufig kennt man in der Praxis von der Funktion f nur die Werte $f_k := f(x_k)$ an äquidistanten Stellen $x_k := 2\pi k/N$, k ganz, wobei N eine gegebene feste ganze Zahl ist. Es stellt sich das Problem, unter diesen Einschränkungen noch vernünftige Näherungswerte für die Fourierkoeffizienten $c_j(f)$ zu berechnen. Die Methoden der trigonometrischen Interpolation lassen sich bei der Lösung dieses Problems folgendermaßen verwenden:

Nach Satz (2.3.1.9) gelten für die Koeffizienten β_j des interpolierenden trigonometrischen Polynoms

$$p(x) = \beta_0 + \beta_1 e^{ix} + \dots + \beta_{N-1} e^{(N-1)ix}$$

mit $p(x_k) = f_k$ für $k = 0, \pm 1, \pm 2, \dots$, die Formeln

$$\beta_j = \frac{1}{N} \sum_{k=0}^{N-1} f_k e^{-jix_k}, \quad j = 0, 1, \dots, N-1.$$

Wegen $f_0 = f_N$ läßt sich β_j als eine Trapezsumme [(s. (3.1.7))]

$$\beta_j = \frac{1}{N} \left[\frac{f_0}{2} + f_1 e^{-jix_1} + \dots + f_{N-1} e^{-jix_{N-1}} + \frac{f_N}{2} e^{-jix_N} \right]$$

zur näherungsweisen Berechnung des Integrals (2.3.4.2) auffassen, so daß es nahe liegt, die Summen

³ Eine reelle Funktion $f: [a, b] \rightarrow \mathbb{R}$ heißt *absolutstetig* auf $[a, b]$, falls es zu jedem $\varepsilon > 0$ ein $\delta > 0$ gibt, so daß $\sum_i |f(b_i) - f(a_i)| < \varepsilon$ für alle $a_i, b_i, a \leq a_1 < b_1 < a_2 < b_2 < \dots < b_n \leq b$ mit $\sum_i |b_i - a_i| \leq \delta$ gilt. Diese Funktionen sind für fast alle $x \in [a, b]$ differenzierbar und es gilt $f(x) = f(a) + \int_a^x f'(t) dt$ für $x \in [a, b]$. Für absolutstetige f, g gelten die Regeln der partiellen Integration, $\int_a^b f(x)g'(x) dx = f(x)g(x) \Big|_a^b - \int_a^b f'(x)g(x) dx$.

$$(2.3.4.3) \quad \beta_j(f) = \beta_j := \frac{1}{N} \sum_{k=0}^{N-1} f_k e^{-jix_k}$$

für alle $j = 0, \pm 1, \dots$, als Näherungswerte für die gesuchten $c_j(f)$ zu nehmen. Dieses Vorgehen hat zumindest den Vorteil, daß man die Summen $\beta_j(f)$ sehr effektiv z. B. mit Hilfe des Algorithmus von Cooley und Tukey (s. 2.3.2) berechnen kann. Andererseits ist $\beta_j(f)$ zumindest für großes j eine schlechte Approximation für $c_j(f)$, denn offensichtlich gilt $\beta_{j+kN} = \beta_j$ für alle ganzen Zahlen j und k , während $\lim_{|j| \rightarrow \infty} c_j = 0$ gilt. Für die Funktionen $f \in \mathcal{H}$ folgt letzteres sofort aus der Konvergenz der Fourierreihe

$$f(0) = \sum_{j=-\infty}^{\infty} c_j.$$

Näherhin hängt das asymptotische Verhalten der $c_j(f)$ von den Differenzierbarkeitseigenschaften von f ab:

(2.3.4.4) **Satz:** Falls f eine absolutstetige r -te Ableitung $f^{(r)}$ besitzt, gilt

$$|c_j| = O\left(\frac{1}{|j|^{r+1}}\right).$$

Beweis: Wegen der Periodizität von f findet man durch partielle Integration

$$\begin{aligned} c_j &= \frac{1}{2\pi} \int_0^{2\pi} f(x) e^{-jix} dx \\ &= \frac{1}{2\pi ji} \int_0^{2\pi} f'(x) e^{-jix} dx \\ &= \dots \\ &= \frac{1}{2\pi (ji)^r} \int_0^{2\pi} f^{(r)}(x) e^{-jix} dx \\ &= \frac{1}{2\pi (ji)^{r+1}} \int_0^{2\pi} e^{-jix} df^{(r)}(x). \end{aligned}$$

Daraus folgt die Behauptung. □

Um zumindest Näherungswerte mit dem richtigen asymptotischen Verhalten für die gesuchten $c_j(f)$ zu erhalten, liegt folgende Idee nahe: Man bestimme zu den gegebenen Werten f_k , $k = 0, \pm 1, \pm 2, \dots$, durch ein Interpolations- oder allgemeiner ein Approximationsverfahren eine

möglichst einfache Funktion $g \in \mathcal{H}$, die f in einem gewissen Sinne approximiert (z.B. f an den Stellen x_k interpoliert, $g(x_k) = f_k$, $k = 0, \pm 1, \dots$) und dieselbe Differenzierbarkeitsordnung wie f besitzt. Als Näherungswerte für die gesuchten $c_j(f)$ nehme man dann die Fourierkoeffizienten $c_j(g)$ von g . Es ist nun überraschend, daß man für sehr allgemeine Approximationsverfahren die gesuchten $c_j(g)$ auf einfache Weise direkt aus den Koeffizienten $\beta_j(f)$ (2.3.4.3) berechnen kann: Es gibt nämlich für diese Approximationsverfahren Konstanten τ_j , $j = 0, \pm 1, \dots$, die nur von N und dem Approximationsverfahren aber nicht von der Folge f_k , $k = 0, \pm 1, \dots$, abhängen, mit der Eigenschaft

$$c_j(g) = \tau_j \beta_j(f), \quad j = 0, \pm 1, \dots$$

Diese Konstanten heißen *Abminderungsfaktoren*.

Um den Begriff „Approximationsverfahren“ zu präzisieren, führen wir zusätzlich zu der Menge $\mathcal{H}$ aller absolutstetigen 2π -periodischen reellen Funktionen $f : \mathbb{R} \rightarrow \mathbb{R}$ noch die Menge

$$\mathbb{F} = \{(f_k)_{k \in \mathbb{Z}} \mid f_k \in \mathbb{R}, f_{k+N} = f_k \text{ für alle } k \in \mathbb{Z}\}, \quad \mathbb{Z} := \{k \mid k \text{ ganz}\},$$

aller N -periodischen reellen Zahlenfolgen

$$f = (\dots, f_{-1}, f_0, f_1, \dots)$$

ein. (Der Einfachheit halber benutzen wir dieselbe Bezeichnung f auch für die der Funktion $f \in \mathcal{H}$ zugeordnete Folge $(f_k)_{k \in \mathbb{Z}}$ mit $f_k = f(x_k)$. Die jeweilige Bedeutung folgt aus dem Zusammenhang.) Das Approximationsverfahren ordnet jeder Folge $f \in \mathbb{F}$ eine Funktion $g = P(f)$ aus $\mathcal{H}$ zu und wird somit durch eine Abbildung $P : \mathbb{F} \rightarrow \mathcal{H}$ beschrieben. In $\mathcal{H}$ und $\mathbb{F}$ kann man die Addition von Elementen und Multiplikation mit einem Skalar auf die übliche Weise erklären, so daß $\mathcal{H}$ und $\mathbb{F}$ als reelle Vektorräume aufgefaßt werden können. Der Vektorraum $\mathbb{F}$ hat die Dimension N , eine Basis ist z.B. gegeben durch die speziellen Folgen

$$(2.3.4.5) \quad e^{(k)} = (e_j^{(k)})_{j \in \mathbb{Z}}, \quad k = 0, 1, \dots, N-1,$$

mit

$$e_j^{(k)} := \begin{cases} 1 & \text{falls } k \equiv j \pmod{N}, \\ 0 & \text{sonst.} \end{cases}$$

Zusätzlich führen wir in $\mathbb{F}$ und $\mathcal{H}$ Translationsoperatoren $E : \mathbb{F} \rightarrow \mathbb{F}$ bzw. $E : \mathcal{H} \rightarrow \mathcal{H}$ ein (wir bezeichnen sie der Einfachheit halber mit demselben Buchstaben) durch

$$\begin{aligned} (Ef)_k &:= f_{k-1} && \text{für alle } k \in \mathbb{Z}, \text{ falls } f \in \mathbb{F}, \\ (Eg)(x) &:= g(x-h) && \text{für alle } x \in \mathbb{R}, \text{ falls } g \in \mathcal{H}, h := 2\pi/N = x_1. \end{aligned}$$

Der Approximationsoperator $P : \mathbb{F} \rightarrow \mathcal{H}$ heißt schließlich *translationsinvariant*, falls $P(E(f)) = E(P(f))$ für alle $f \in \mathbb{F}$ (d. h. der „verschobenen“ Folge wird die entsprechend „verschobene“ Funktion zugeordnet). Aus $P(E(f)) = E(P(f))$ folgt natürlich sofort $P(E^k(f)) = E^k(P(f))$, wobei $E^2 = E \circ E$, $E^3 = E \circ E \circ E$, usw. Damit können wir folgenden Satz beweisen, der von Gautschi und Reinsch stammt (weitere Einzelheiten s. Gautschi (1972)):

(2.3.4.6) **Satz:** Zu einem Approximationsverfahren $P : \mathbb{F} \rightarrow \mathcal{H}$ gibt es von $f \in \mathbb{F}$ unabhängige Zahlen (Abminderungsfaktoren) τ_j , $j \in \mathbb{Z}$, mit

$$(2.3.4.7) \quad c_j(Pf) = \tau_j \beta_j(f) \quad \text{für alle } j \in \mathbb{Z} \text{ und alle } f \in \mathbb{F}$$

genau dann, wenn P linear und translationsinvariant ist.

Beweis: 1) Sei zunächst P linear und translationsinvariant. Jedes $f \in \mathbb{F}$ besitzt in der Basis (2.3.4.5) die Darstellung

$$f = \sum_{k=0}^{N-1} f_k e^{(k)} = \sum_{k=0}^{N-1} f_k E^k e^{(0)}.$$

Es folgt wegen der Linearität und Translationsinvarianz von P

$$g := Pf = \sum_{k=0}^{N-1} f_k E^k P e^{(0)},$$

also

$$g(x) = \sum_{k=0}^{N-1} f_k \eta_0(x - x_k),$$

wenn $\eta_0 := P e^{(0)}$ die der Folge $e^{(0)}$ durch P zugeordnete Funktion ist. Es folgt wegen der Periodizität von g sofort

$$\begin{aligned} c_j(Pf) = c_j(g) &= \sum_{k=0}^{N-1} \frac{f_k}{2\pi} \int_0^{2\pi} \eta_0(x - x_k) e^{-jix} dx \\ &= \sum_{k=0}^{N-1} \frac{f_k}{2\pi} e^{-jix_k} \int_0^{2\pi} \eta_0(x) e^{-jix} dx \\ &= \tau_j \beta_j(f) \end{aligned}$$

mit

$$(2.3.4.8) \quad \tau_j := N c_j(\eta_0).$$

Die Faktoren τ_j hängen offensichtlich nur von N und der Approximationsmethode P ab.

2) Sei umgekehrt (2.3.4.7) erfüllt und $f \in \mathbb{F}$ beliebig. Da alle Funktionen aus $\mathcal{K}$ durch ihre Fourierreihen dargestellt werden, folgt wegen $Pf \in \mathcal{K}$ und (2.3.4.7) für Pf die Darstellung

$$(2.3.4.9) \quad (Pf)(x) = \sum_{j=-\infty}^{\infty} c_j(Pf)e^{jix} = \sum_{j=-\infty}^{\infty} \tau_j \beta_j(f)e^{jix}.$$

Offensichtlich gilt nun nach Definition von $\beta_j(f)$ (2.3.4.3) für $f, g \in \mathbb{F}$

$$\beta_j(f+g) = \beta_j(f) + \beta_j(g)$$

sowie

$$\beta_j(Ef) = \frac{1}{N} \sum_{k=0}^{N-1} f_{k-1} e^{-jix_k} = \frac{1}{N} e^{-jih} \sum_{k=0}^{N-1} f_k e^{-jix_k} = e^{-jih} \cdot \beta_j(f).$$

So folgen aus (2.3.4.9) sofort die Linearität und Translationsinvarianz von P :

$$(P(E(f)))(x) = \sum_{j=-\infty}^{\infty} \tau_j \beta_j(f) e^{jit(x-h)} = (Pf)(x-h) = (E(P(f)))(x). \quad \square$$

Als Nebenresultat haben wir die explizite Formel (2.3.4.8) für die Abminderungsfaktoren erhalten. Eine andere Methode, zu einem gegebenen Approximationsoperator P die Abminderungsfaktoren τ_j zu bestimmen, besteht in der Auswertung der Formel

$$(2.3.4.10) \quad \tau_j = \frac{c_j(Pf)}{\beta_j(f)}$$

für ein geeignetes $f \in \mathbb{F}$.

Beispiel 1: Für eine gegebene Folge $f \in \mathbb{F}$ sei $g := Pf$ diejenige stetige Funktion g mit $g(x_k) = f_k$ für $k = 0, k \in \mathbb{Z}$, die auf jedem Teilintervall $[x_k, x_{k+1}]$ linear ist. Offensichtlich ist für $f \in \mathbb{F}$ die Funktion $g = Pf$ absolutstetig und 2π -periodisch, also $Pf \in \mathcal{K}$. Ferner sieht man sofort, daß P linear und translationsinvariant ist und deshalb Abminderungsfaktoren existieren (Satz (2.3.4.6)). Für die spezielle Folge $f = e^{(0)}$ (2.3.4.5) hat man

$$\begin{aligned} \beta_j(f) &= \frac{1}{N} \\ Pf(x) &= \begin{cases} 1 - \frac{1}{h}|x - x_{kN}| & \text{falls } |x - x_{kN}| \leq h, k = 0, \pm 1, \dots \\ 0 & \text{sonst} \end{cases} \\ c_j(Pf) &= \frac{1}{2\pi} \int_0^{2\pi} Pf(x) e^{-jix} dx = \frac{1}{2\pi} \int_{-h}^h \left(1 - \frac{|x|}{h}\right) e^{-jix} dx. \end{aligned}$$

Wegen der Symmetrieeigenschaften des Integranden folgt

$$c_j(Pf) = \frac{1}{\pi} \int_0^h \left(1 - \frac{x}{h}\right) \cos jx \, dx = \frac{2}{j^2 \pi h} \sin^2\left(\frac{jh}{2}\right).$$

Mit $h = 2\pi/N$ folgt aus (2.3.4.10) für die Abminderungsfaktoren

$$\tau_j = \left(\frac{\sin z}{z}\right)^2 \quad \text{mit } z := \frac{\pi j}{N}, \quad j = 0, \pm 1, \dots$$

Beispiel 2: $g = Pf$ sei die kubische periodische Splinefunktion (s. Abschnitt 2.4) mit $g(x_k) = f_k$, $k \in \mathbb{Z}$. Auch in diesem Fall ist P linear und translationsinvariant. Für die τ_j findet man im Prinzip wie eben

$$\tau_j = \left(\frac{\sin z}{z}\right)^4 \frac{3}{1 + 2 \cos^2 z}, \quad \text{wobei } z := \frac{\pi j}{N}.$$

2.4 Spline-Interpolation

Man wendet die Spline-Interpolation hauptsächlich dazu an, um gegebene Punkte – etwa für zeichnerische Zwecke – durch eine „möglichst glatte“ Kurve zu verbinden. Innerhalb der numerischen Mathematik werden Splinefunktionen neuerdings auch als Ansatzfunktionen im Rayleigh-Ritz-Galerkin-Verfahren zur Lösung von Randwertproblemen für gewöhnliche oder partielle Differentialgleichungen verwandt. Eine eingehende Behandlung von Splinefunktionen findet man in Greville (1969), Schultz (1973), Böhmer (1974) und de Boor (1972, 1978).

2.4.1 Theoretische Grundlagen

Durch $\Delta := \{a = x_0 < x_1 < \dots < x_n = b\}$ sei eine Unterteilung des Intervalls $[a, b]$ gegeben.

(2.4.1.1) **Def:** Unter einer zu Δ gehörigen kubischen Spline-Funktion S_Δ versteht man eine reelle Funktion $S_\Delta : [a, b] \rightarrow \mathbb{R}$ mit den Eigenschaften

- $S_\Delta \in C^2[a, b]$: S_Δ ist auf $[a, b]$ zweimal stetig differenzierbar.
- Auf jedem Teilintervall $[x_i, x_{i+1}]$, $i = 0, 1, \dots, n-1$, stimmt S_Δ mit einem kubischen Polynom überein.

Eine Splinefunktion ist somit stückweise aus n kubischen Polynomen so zusammengesetzt, daß die Funktion S_Δ selbst und ihre beiden ersten

Ableitungen an den *Knoten* x_i , $i = 1, 2, \dots, n-1$, keine Sprungstellen besitzen.

Splinefunktionen sind vielfach verallgemeinert worden, so sind z.B. Splinefunktionen k -ten Grades $(k-1)$ -mal differenzierbare Funktionen, die stückweise aus Polynomen k -ten Grades zusammengesetzt sind. Diese Funktionen teilen viele Eigenschaften mit kubischen Splinefunktionen [s. Greville (1969), de Boor (1972)]. In den folgenden beiden Abschnitten beschränken wir uns der Einfachheit halber auf den kubischen Fall. Allgemeiner stückweise Polynomfunktionen werden erst in den Abschnitten 2.4.4 und 2.4.5 behandelt, Grundzüge ihrer Anwendungen in der Signal-Verarbeitung werden im letzten Abschnitt 2.4.6 beschrieben.

Ist ferner $Y := (y_0, y_1, \dots, y_n)$ eine Familie von $n+1$ reellen Zahlen, so bezeichnen wir mit $S_\Delta(Y; \cdot)$ eine interpolierende Splinefunktion S_Δ mit $S_\Delta(Y; x_i) = y_i$ für $i = 0, 1, \dots, n$. Durch Y allein ist $S_\Delta(Y; \cdot)$ noch nicht eindeutig bestimmt, weil man, grob gesprochen, noch zwei Freiheitsgrade offen hat, so daß man zwei geeignete Zusatzforderungen stellen kann, um Eindeutigkeit zu erzwingen. Insbesondere ist es üblich, eine der folgenden drei Zusatzbedingungen zu verlangen:

(2.4.1.2)

- a) $S''_\Delta(Y; a) = S''_\Delta(Y; b) = 0$,
- b) $S^{(k)}_\Delta(Y; a) = S^{(k)}_\Delta(Y; b)$ für $k = 0, 1, 2$: $S_\Delta(Y; \cdot)$ ist periodisch,
- c) $f'(a) = S'_\Delta(Y; a)$, $f'(b) = S'_\Delta(Y; b)$.

Für die Bedingung (2.4.1.2b) ist natürlich $y_0 = y_n$ vorausgesetzt. Wir werden zeigen, daß jede dieser drei Bedingungen die Eindeutigkeit von $S_\Delta(Y; \cdot)$ sichert.

Wir führen zunächst einige weitere Bezeichnungen und Begriffe ein. Für ganzes $m > 0$ sei

$$(2.4.1.3) \quad \mathcal{H}^m[a, b]$$

die Menge aller reellen Funktionen f auf $[a, b]$ bezeichnet, für die die $m-1$ -te Ableitung $f^{(m-1)}$ auf $[a, b]$ noch absolutstetig⁴ ist und $f^{(m)} \in L^2[a, b]$.⁵ Unter

$$\mathcal{H}_p^m[a, b]$$

verstehen wir die Menge aller Funktionen aus $\mathcal{H}^m[a, b]$ mit $f^{(k)}(a) = f^{(k)}(b)$ für $k = 0, 1, \dots, m-1$. Diese Funktionen heißen auch *periodisch*,

⁴ s. Fußnote 2 in Abschnitt 2.3.4.

⁵ $L^2[a, b]$ ist die Menge aller reellen Funktionen, die auf $[a, b]$ quadratisch integrierbar sind, d. h. $\int_a^b |f(t)|^2 dt$ existiert und ist endlich.

weil sie Restriktionen von Funktionen der Periode $b - a$ auf das Intervall $[a, b]$ sind.

Man beachte, daß $S_\Delta \in \mathcal{K}^3[a, b]$ gilt, und $S_\Delta(Y; \cdot) \in \mathcal{K}_p^3[a, b]$ im Falle von (2.4.1.2b).

Für Funktionen $f \in \mathcal{K}^2(a, b)$ bezeichnen wir schließlich mit $\|f\|^2$ die Größe

$$\|f\|^2 := \int_a^b |f''(x)|^2 dx.$$

Man beachte, daß $\|f\|$ nur eine Seminorm ist, es gibt Funktionen $f(x) \not\equiv 0$ mit $\|f\| = 0$, z. B. alle linearen Funktionen $f(x) \equiv cx + d$.

Wir zeigen zunächst eine fundamentale Identität, die von Holladay stammt, [s. z. B. Ahlberg, Nilson und Walsh (1967)]:

(2.4.1.4) **Satz:** Ist $f \in \mathcal{K}^2(a, b)$, $\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$ eine Unterteilung von $[a, b]$ und S_Δ eine Splinefunktion zu Δ , so gilt

$$\begin{aligned} \|f - S_\Delta\|^2 &= \|f\|^2 - \|S_\Delta\|^2 - \\ &\quad - 2 \left[(f'(x) - S'_\Delta(x)) S''_\Delta(x) \Big|_a^b - \sum_{i=1}^n (f(x) - S_\Delta(x)) S'''_\Delta \Big|_{x_{i-1}^+}^{x_i^-} \right]. \end{aligned}$$

Wie in der Integralrechnung bedeutet hier $g(x)|_v^u := g(u) - g(v)$. Man beachte ferner, daß $S'''_\Delta(x)$ stückweise konstant ist mit den Knoten $x_1, \dots, x_{n-1}$ als möglichen Sprungstellen: Deshalb erscheinen in der obigen Formel an den Stellen x_i und x_{i-1} die links- und rechtsseitigen Grenzwerte x_i^- bzw. x_{i-1}^+ .

Beweis: Es ist nach Definition von $\|\cdot\|$

$$\begin{aligned} \|f - S_\Delta\|^2 &= \int_a^b |f''(x) - S''_\Delta(x)|^2 dx \\ &= \|f\|^2 - 2 \int_a^b f''(x) S''_\Delta(x) dx + \|S_\Delta\|^2 \\ &= \|f\|^2 - 2 \int_a^b (f''(x) - S''_\Delta(x)) S''_\Delta(x) dx - \|S_\Delta\|^2. \end{aligned}$$

Partielle Integration ergibt für $i = 1, 2, \dots, n$

$$\begin{aligned} \int_{x_{i-1}}^{x_i} (f''(x) - S''_\Delta(x)) S''_\Delta(x) dx &= (f'(x) - S'_\Delta(x)) S''_\Delta(x) \Big|_{x_{i-1}}^{x_i} \\ &\quad - \int_{x_{i-1}}^{x_i} (f'(x) - S'_\Delta(x)) S'''_\Delta(x) dx \end{aligned}$$

$$\begin{aligned}
&= (f'(x) - S'_\Delta(x))S''_\Delta(x)|_{x_{i-1}}^{x_i} - (f(x) - S_\Delta(x))S'''_\Delta(x)|_{x_{i-1}^+}^{x_i^-} \\
&\quad + \int_{x_{i-1}}^{x_i} (f(x) - S_\Delta(x))S''_\Delta(x) dx.
\end{aligned}$$

Nun ist $S^{(4)}(x) \equiv 0$ auf den Teilintervallen (x_{i-1}, x_i) , und f' , S'_Δ , S''_Δ sind stetig auf $[a, b]$. Man erhält daher die Behauptung des Satzes durch Addition dieser Beziehungen für $i = 1, 2, \dots, n$ wegen

$$\sum_{i=1}^n (f'(x) - S'_\Delta(x))S''_\Delta(x)|_{x_{i-1}}^{x_i} = (f'(x) - S'_\Delta(x))S''_\Delta(x)|_a^b. \quad \square$$

Mit Hilfes dieses Satzes kann man nun leicht die wichtige *Minimum-Norm-Eigenschaft* der Splinefunktionen nachweisen:

(2.4.1.5) **Satz:** Gegeben sei eine Partition $\Delta := \{a = x_0 < x_1 < \dots < x_n = b\}$ des Intervalls $[a, b]$, Werte $Y := \{y_0, \dots, y_n\}$ und eine Funktion $f \in \mathcal{K}^2(a, b)$ mit $f(x_i) = y_i$ für $i = 0, 1, \dots, n$. Dann gilt die Ungleichung $\|f\| \geq \|S_\Delta(Y; \cdot)\|$; genauerhin gilt

$$\|f - S_\Delta(Y; \cdot)\|^2 = \|f\|^2 - \|S_\Delta(Y; \cdot)\|^2 \geq 0$$

für jede Splinefunktion $S_\Delta(Y; \cdot)$, die zusätzlich eine der folgenden drei Bedingungen erfüllt [vgl. (2.4.1.2)]

- a) $S''_\Delta(Y; a) = S''_\Delta(Y; b) = 0$,
- b) $f \in \mathcal{K}_p^2[a, b]$, $S_\Delta(Y; \cdot)$ periodisch,
- c) $f'(a) = S'_\Delta(Y; a)$, $f'(b) = S'_\Delta(Y; b)$.

In jedem dieser Fälle ist die Splinefunktion $S_\Delta(Y; \cdot)$ eindeutig bestimmt.

Die Existenz solcher Splinefunktionen wird in 2.4.2 gezeigt.

Beweis: In jedem der Fälle a), b), c) verschwindet in der Identität von (2.4.1.4) der Ausdruck

$$(f'(x) - S'_\Delta(x))S''_\Delta(x)|_a^b - \sum_{i=1}^n (f(x) - S_\Delta(x))S'''_\Delta(x)|_{x_{i-1}^+}^{x_i^-} = 0,$$

falls $S_\Delta \equiv S_\Delta(Y; \cdot)$. Die Eindeutigkeit von $S_\Delta(Y; \cdot)$ folgt so: Gäbe es eine weitere Splinefunktion $\bar{S}_\Delta(Y; \cdot)$ mit den angegebenen Eigenschaften, so wäre $f(x) := \bar{S}_\Delta(Y; x)$ eine Funktion f der im Satz betrachteten Art. Es ist daher

$$\|\bar{S}_\Delta(Y; \cdot) - S_\Delta(Y; \cdot)\|^2 = \|\bar{S}_\Delta(Y; \cdot)\|^2 - \|S_\Delta(Y; \cdot)\|^2 \geq 0$$

und somit, da $S_\Delta(Y; \cdot)$ und $\bar{S}_\Delta(Y; \cdot)$ vertauscht werden können,

$$\|\bar{S}_\Delta(Y; \cdot) - S_\Delta(Y; \cdot)\|^2 = \int_a^b |\bar{S}_\Delta''(Y; x) - S_\Delta''(Y; x)|^2 dx = 0.$$

Da $\bar{S}_\Delta''(Y; \cdot)$ und $S_\Delta''(Y; \cdot)$ beide stetig sind, folgt $\bar{S}_\Delta''(Y; x) \equiv S_\Delta''(Y; x)$, und daher durch Integration

$$\bar{S}_\Delta(Y; x) \equiv S_\Delta(Y; x) + cx + d.$$

Wegen $\bar{S}_\Delta(Y; x) = S_\Delta(Y; x)$ für $x = a, b$ folgt sofort $c = d = 0$ und damit die Eindeutigkeit, $\bar{S}_\Delta(Y; \cdot) = S_\Delta(Y; \cdot)$. $\square$

Satz (2.4.1.5) beschreibt eine Minimaleigenschaft der Splinefunktionen. Beispielsweise minimiert im Falle a) unter allen Funktionen f aus $\mathcal{K}^2(a, b)$ mit $f(x_i) = y_i$, $i = 0, 1, \dots, n$, gerade die Splinefunktion $S_\Delta(Y; \cdot)$ mit $S_\Delta''(Y; x) = 0$ für $x = a, b$ das Integral

$$\|f\|^2 = \int_a^b |f''(x)|^2 dx.$$

Man nennt deshalb die Splinefunktionen mit (2.4.1.2a) auch *natürliche* Splinefunktionen (in den Fällen b) und c) gelten analoge Minimalaussagen). Da $|f''(x)|$ die Krümmung von f an der Stelle x approximiert⁶, kann man $\|f\|$ als Maß der Gesamtkrümmung ansehen. Die Minimaleigenschaft besagt deshalb, daß unter allen auf $[a, b]$ 2mal stetig differenzierbaren Funktionen f mit $f(x_i) = y_i$ für $i = 0, 1, \dots, n$, die natürliche Splinefunktion $S_\Delta(Y; \cdot)$ die „glatteste“ Funktion in dem Sinne ist, daß sie die kleinste Gesamtkrümmung besitzt.

2.4.2 Die Berechnung von kubischen Splinefunktionen

In diesem Abschnitt werden Methoden zur Berechnung der Splinefunktionen $S_\Delta(Y; \cdot)$ beschrieben, die eine der Nebenbedingungen (2.4.1.2) erfüllen. Insbesondere wird sich dabei auch die Existenz der Splinefunktionen zeigen, deren Eindeutigkeit bereits in Satz (2.4.1.5) bewiesen wurde.

Für das folgende sei $\Delta = \{x_i \mid i = 0, 1, \dots, n\}$ eine feste Zerlegung des Intervalls $[a, b]$ mit $a = x_0 < x_1 < \dots < x_n = b$ und $Y = \{y_i \mid i = 0, 1, \dots, n\}$ eine Menge von $n + 1$ reellen Zahlen. Ferner sei

⁶ Die exakte Krümmung $\kappa(x) = f''(x)/(1 + f'(x)^2)^{3/2}$ an der Stelle x ist für kleines $|f'(x)|$ näherungsweise gleich $f''(x)$.

$$h_{j+1} := x_{j+1} - x_j, \quad j = 0, 1, \dots, n-1.$$

Als Momente M_j ,

$$(2.4.2.1) \quad M_j := S''_{\Delta}(Y; x_j), \quad j = 0, 1, \dots, n,$$

bezeichnen wir die zweiten Ableitungen der gesuchten Splinefunktion $S_{\Delta}(Y; \cdot)$ an den Knoten $x_j \in \Delta$. Wir wollen zeigen, daß sich die M_j als Lösung eines linearen Gleichungssystems berechnen lassen und daß man mit Hilfe der M_j allein die interessierende Splinefunktion $S_{\Delta}(Y; \cdot)$ angeben kann.

Zur Herleitung von Bestimmungsgleichungen für die M_j beachte man zunächst, daß $S''_{\Delta}(Y; \cdot)$ in jedem Intervall $[x_j, x_{j+1}]$, $j = 0, \dots, n-1$, eine lineare Funktion ist, die man mit Hilfe der M_j beschreiben kann:

$$S''_{\Delta}(Y; x) = M_j \frac{x_{j+1} - x}{h_{j+1}} + M_{j+1} \frac{x - x_j}{h_{j+1}} \quad \text{für } x \in [x_j, x_{j+1}].$$

Durch Integration erhält man für $x \in [x_j, x_{j+1}]$, $j = 0, 1, \dots, n-1$:

(2.4.2.2)

$$S'_{\Delta}(Y; x) = -M_j \frac{(x_{j+1} - x)^2}{2h_{j+1}} + M_{j+1} \frac{(x - x_j)^2}{2h_{j+1}} + A_j,$$

$$S_{\Delta}(Y; x) = M_j \frac{(x_{j+1} - x)^3}{6h_{j+1}} + M_{j+1} \frac{(x - x_j)^3}{6h_{j+1}} + A_j(x - x_j) + B_j,$$

mit gewissen Integrationskonstanten A_j, B_j .

Wegen $S_{\Delta}(Y; x_j) = y_j$, $S_{\Delta}(Y; x_{j+1}) = y_{j+1}$ erhält man für A_j und B_j die Gleichungen

$$M_j \frac{h_{j+1}^2}{6} + B_j = y_j,$$

$$M_{j+1} \frac{h_{j+1}^2}{6} + A_j h_{j+1} + B_j = y_{j+1},$$

und daher

$$(2.4.2.3) \quad B_j = y_j - M_j \frac{h_{j+1}^2}{6},$$

$$A_j = \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{h_{j+1}}{6}(M_{j+1} - M_j).$$

Für $S_{\Delta}(Y; \cdot)$ selbst bekommt man so für $x \in [x_j, x_{j+1}]$ die Darstellung

$$(2.4.2.4) \quad S_{\Delta}(Y; x) = \alpha_j + \beta_j(x - x_j) + \gamma_j(x - x_j)^2 + \delta_j(x - x_j)^3$$

mit

$$\begin{aligned}\alpha_j &:= y_j, & \gamma_j &:= \frac{M_j}{2}, \\ \beta_j &:= S'_\Delta(Y; x_j) = -\frac{M_j h_{j+1}}{2} + A_j \\ &= \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{2M_j + M_{j+1}}{6} h_{j+1}, \\ \delta_j &:= \frac{S'''_\Delta(Y; x_j^+)}{6} = \frac{M_{j+1} - M_j}{6h_{j+1}}.\end{aligned}$$

Damit ist $S_\Delta(Y; \cdot)$ mit Hilfe der M_j ausgedrückt und es bleibt nur noch das Problem, die Momente zu berechnen. Wenn man die Stetigkeit von $S'_\Delta(Y; \cdot)$ an den Stellen $x = x_j$, $j = 1, 2, \dots, n-1$, ausnutzt, erhält man $n-1$ Bestimmungsgleichungen. Setzt man die Werte (2.4.2.3) für A_j und B_j in (2.4.2.2) ein, so erhält man zunächst für $x \in [x_j, x_{j+1}]$ die Darstellung

$$\begin{aligned}S'_\Delta(Y; x) &= -M_j \frac{(x_{j+1} - x)^2}{2h_{j+1}} + M_{j+1} \frac{(x - x_j)^2}{2h_{j+1}} \\ &\quad + \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{h_{j+1}}{6} (M_{j+1} - M_j).\end{aligned}$$

Also gilt für $j = 1, 2, \dots, n-1$,

$$\begin{aligned}S'_\Delta(Y; x_j^-) &= \frac{y_j - y_{j-1}}{h_j} + \frac{h_j}{3} M_j + \frac{h_j}{6} M_{j-1}, \\ S'_\Delta(Y; x_j^+) &= \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{h_{j+1}}{3} M_j - \frac{h_{j+1}}{6} M_{j+1},\end{aligned}$$

und daher wegen $S'_\Delta(Y; x_j^+) = S'_\Delta(Y; x_j^-)$

$$(2.4.2.5) \quad \frac{h_j}{6} M_{j-1} + \frac{h_j + h_{j+1}}{3} M_j + \frac{h_{j+1}}{6} M_{j+1} = \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{y_j - y_{j-1}}{h_j}$$

für $j = 1, 2, \dots, n-1$. Dies sind $n-1$ Bedingungen für die $n+1$ Unbekannten $M_0, M_1, \dots, M_n$. Je zwei weitere Bedingungen erhält man aus (2.4.1.2).

$$\text{Fall a):} \quad S''_\Delta(Y; a) = M_0 = 0 = M_n = S''_\Delta(Y; b),$$

$$\text{Fall b):} \quad S''_\Delta(Y; a) = S''_\Delta(Y; b) \Rightarrow M_0 = M_n,$$

$$\begin{aligned}S'_\Delta(Y; a) = S'_\Delta(Y; b) &\Rightarrow \frac{h_n}{6} M_{n-1} + \frac{h_n + h_1}{3} M_n + \frac{h_1}{6} M_1 \\ &= \frac{y_1 - y_n}{h_1} - \frac{y_n - y_{n-1}}{h_n}.\end{aligned}$$

Letztere Bedingung ist mit (2.4.2.5) für $j = n$ identisch, wenn man

$$h_{n+1} := h_1, \quad M_{n+1} := M_1, \quad y_{n+1} := y_1,$$

setzt. Man beachte, daß $y_n = y_0$ in (2.4.1.2b) verlangt wird.

$$\text{Fall c): } S'_\Delta(Y; a) = y'_0 \Rightarrow \frac{h_1}{3} M_0 + \frac{h_1}{6} M_1 = \frac{y_1 - y_0}{h_1} - y'_0,$$

$$S'_\Delta(Y; b) = y'_n \Rightarrow \frac{h_n}{6} M_{n-1} + \frac{h_n}{3} M_n = y'_n - \frac{y_n - y_{n-1}}{h_n}.$$

Die letzten Gleichungen sowie die Gleichungen (2.4.2.5) lassen sich übersichtlicher in der Form

$$\mu_j M_{j-1} + 2M_j + \lambda_j M_{j+1} = d_j, \quad j = 1, 2, \dots, n-1$$

schreiben, wenn man für $j = 1, 2, \dots, n-1$ folgende Abkürzungen einführt:

$$(2.4.2.6) \quad \begin{aligned} \lambda_j &:= \frac{h_{j+1}}{h_j + h_{j+1}}, & \mu_j &:= 1 - \lambda_j = \frac{h_j}{h_j + h_{j+1}}, \\ d_j &:= \frac{6}{h_j + h_{j+1}} \left\{ \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{y_j - y_{j-1}}{h_j} \right\}. \end{aligned}$$

Definiert man zusätzlich im Fall a)

$$(2.4.2.7) \quad \lambda_0 := 0, \quad d_0 := 0, \quad \mu_n := 0, \quad d_n := 0,$$

bzw. im Fall c)

$$(2.4.2.8) \quad \begin{aligned} \lambda_0 &:= 1, & d_0 &:= \frac{6}{h_1} \left(\frac{y_1 - y_0}{h_1} - y'_0 \right), \\ \mu_n &:= 1, & d_n &:= \frac{6}{h_n} \left(y'_n - \frac{y_n - y_{n-1}}{h_n} \right), \end{aligned}$$

so erhält man in den Fällen a) und c) folgende Bestimmungsgleichungen für die Momente M_i , die man am übersichtlichsten mit Hilfe von Matrizen und Vektoren schreibt:

$$(2.4.2.9) \quad \begin{bmatrix} 2 & \lambda_0 & & & 0 \\ \mu_1 & 2 & \lambda_1 & & \\ & \mu_2 & \cdot & \cdot & \\ & & \cdot & \cdot & \cdot \\ 0 & & & 2 & \lambda_{n-1} \\ & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ \cdot \\ \cdot \\ \cdot \\ M_n \end{bmatrix} = \begin{bmatrix} d_0 \\ d_1 \\ \cdot \\ \cdot \\ \cdot \\ d_n \end{bmatrix}.$$

Im periodischen Fall b) erhält man mit den zusätzlichen Abkürzungen

$$(2.4.2.10) \quad \lambda_n := \frac{h_1}{h_n + h_1}, \quad \mu_n := 1 - \lambda_n = \frac{h_n}{h_n + h_1},$$

$$d_n := \frac{6}{h_n + h_1} \left\{ \frac{y_1 - y_n}{h_1} - \frac{y_n - y_{n-1}}{h_n} \right\},$$

das folgende Gleichungssystem für $M_1, M_2, \dots, M_n = M_0$:

$$(2.4.2.11) \quad \begin{bmatrix} 2 & \lambda_1 & & & \mu_1 \\ \mu_2 & 2 & \lambda_2 & & \\ & \mu_3 & \cdot & \cdot & \\ & & \cdot & \cdot & \\ & & & 2 & \lambda_{n-1} \\ \lambda_n & & & \mu_n & 2 \end{bmatrix} \begin{bmatrix} M_1 \\ M_2 \\ \cdot \\ \cdot \\ \cdot \\ M_n \end{bmatrix} = \begin{bmatrix} d_1 \\ d_2 \\ \cdot \\ \cdot \\ \cdot \\ d_n \end{bmatrix}.$$

Die Koeffizienten λ_i, μ_i, d_i in (2.4.2.9), (2.4.2.11) sind dabei durch (2.4.2.6), (2.4.2.7), (2.4.2.8) bzw. (2.4.2.10) wohlbestimmt. Insbesondere beachte man, daß in (2.4.2.9) und (2.4.2.11) für alle λ_i, μ_i gilt

$$(2.4.2.12) \quad \lambda_i \geq 0, \quad \mu_i \geq 0, \quad \lambda_i + \mu_i = 1,$$

und daß die λ_i, μ_i nur von der Zerlegung Δ abhängen und nicht von den $y_i \in Y$ (und den y'_0, y'_n im Fall c)). Dies kann man zum Beweis des folgenden Satzes benutzen.

(2.4.2.13) **Satz:** Die Matrizen der Gleichungssysteme (2.4.2.9) und (2.4.2.11) sind für jede Zerlegung Δ von $[a, b]$ nichtsingulär.

Damit sind diese Gleichungen für beliebige rechte Seiten eindeutig lösbar und das Problem der Splineinterpolation besitzt in den Fällen a), b), c) von (2.4.1.2) stets eine eindeutig bestimmte Lösung.

Beweis: Sei A die $(n+1) \times (n+1)$ -Matrix

$$A = \begin{bmatrix} 2 & \lambda_0 & & & 0 \\ \mu_1 & 2 & \lambda_1 & & \\ & \mu_2 & \cdot & \cdot & \\ & & \cdot & \cdot & \\ & & & 2 & \lambda_{n-1} \\ 0 & & & \mu_n & 2 \end{bmatrix}$$

des Gleichungssystems (2.4.2.9). Sie besitzt folgende Eigenschaft: Für jedes Paar von Vektoren $z = (z_0, \dots, z_n)^T, w = (w_0, \dots, w_n)^T \in \mathbb{R}^{n+1}$ gilt

$$(2.4.2.14) \quad Az = w \quad \Rightarrow \quad \max_i |z_i| \leq \max_i |w_i|.$$

Dazu sei r so gewählt, daß $|z_r| = \max_i |z_i|$. Wegen $Az = w$ ist

$$\mu_r z_{r-1} + 2z_r + \lambda_r z_{r+1} = w_r \quad (\mu_0 := \lambda_n := 0).$$

Nach Definition von r und wegen $\mu_r + \lambda_r = 1$ ist also

$$\begin{aligned} \max_i |w_i| &\geq |w_r| \geq 2|z_r| - \mu_r |z_{r-1}| - \lambda_r |z_{r+1}| \\ &\geq 2|z_r| - \mu_r |z_r| - \lambda_r |z_r| \\ &= (2 - \mu_r - \lambda_r) |z_r| \\ &= |z_r| = \max_i |z_i|. \end{aligned}$$

Wäre nun A singulär, dann gäbe es eine Lösung $z \neq 0$ von $Az = 0$. Dann führt (2.4.2.14) zu dem Widerspruch

$$0 < \max_i |z_i| \leq 0.$$

Die Nichtsingularität der Matrix von (2.4.2.11) zeigt man analog. $\square$

Die Gleichungen (2.4.2.9) werden durch Elimination gelöst: Man subtrahiert zunächst das $\mu_1/2$ -fache der ersten Gleichung von der zweiten, um μ_1 zu eliminieren, dann ein geeignetes Vielfaches der so erhaltenen zweiten Gleichung von der dritten, um μ_2 zu eliminieren, usw. Man erhält so ein gestaffeltes System von Gleichungen das sofort gelöst werden kann [dieses Verfahren ist das Gaußsche Eliminationsverfahren, angewandt auf (2.4.2.9); vgl. Abschnitt 4.1]:

$$\begin{aligned} q_0 &:= -\lambda_0/2; \quad u_0 := d_0/2; \quad \lambda_n := 0; \\ \text{für } k &:= 1, 2, \dots, n: \\ p_k &:= \mu_k q_{k-1} + 2; \\ q_k &:= -\lambda_k/p_k; \\ u_k &:= (d_k - \mu_k u_{k-1})/p_k; \\ M_n &:= u_n; \\ \text{für } k &:= n-1, n-2, \dots, 0: \\ M_k &:= q_k M_{k+1} + u_k; \end{aligned} \tag{2.4.2.15}$$

[Man kann zeigen, daß $p_k > 0$ gilt, so daß (2.4.2.15) wohldefiniert ist; s. Aufgabe 25]. Im Fall b) kann man (2.4.2.11) nach dem gleichen Prinzip lösen, allerdings nicht ganz so einfach.

Ein ALGOL-Programm, das von Reinsch stammt, findet man in Bulirsch und Rutishauser (1968).

Zusätzliche Resultate findet der Leser in Greville (1969) und de Boor (1972), weitere ALGOL-Programme bei Herriot und Reinsch (1971), und FORTRAN-Programme bei de Boor (1978). Diese Literatur enthält auch

Informationen und Algorithmen für Splinefunktionen vom Grad $k \geq 3$ und für B-Splines, die hier in den Abschnitten 2.4.4 und 2.4.5 behandelt werden.

2.4.3 Konvergenzeigenschaften kubischer Splinefunktionen

Interpolierende Polynome konvergieren im allgemeinen nicht gegen die Funktion f , die sie interpolieren, selbst wenn die Feinheit der Partition Δ gegen Null strebt (s. Abschnitt 2.1.4). Im Gegensatz dazu konvergieren interpolierende Splinefunktionen unter schwachen Bedingungen für f und die Partition Δ gegen die Funktion f , wenn die Feinheit von Δ beliebig klein wird.

Wir zeigen zunächst, daß die Momente (2.4.2.1) einer f interpolierenden Splinefunktion gegen die zweiten Ableitungen der Funktion f konvergieren. Dazu betrachten wir eine feste Partition $\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$ von $[a, b]$, und den Vektor

$$M = \begin{bmatrix} M_0 \\ \vdots \\ M_n \end{bmatrix}$$

der Momente $M_j = S''_{\Delta}(Y; x_j)$ der Splinefunktion mit $y_j = f(x_j)$ für $j = 0, 1, \dots, n$, und (vgl. (2.4.1.2c))

$$S'_{\Delta}(Y; a) = f'(a), \quad S'_{\Delta}(Y; b) = f'(b).$$

Der Vektor M genügt der Gleichung (2.4.2.9), die wir in Matrixform schreiben,

$$AM = d.$$

Die Komponenten d_j von d sind dabei durch (2.4.2.6) und (2.4.2.8) gegeben. Seien nun F und r die Vektoren

$$F := \begin{bmatrix} f''(x_0) \\ f''(x_1) \\ \vdots \\ f''(x_n) \end{bmatrix}, \quad r := d - AF = A(M - F).$$

Mit $\|z\| := \max_i |z_i|$ für Vektoren z und

$$(2.4.3.1) \quad \|\Delta\| := \max |x_{j+1} - x_j|$$

für die *Feinheit* von Δ , zeigen wir zunächst die Abschätzung

(2.4.3.2) Falls $f \in C^4[a, b]$ und $|f^{(4)}(x)| \leq L$ für $x \in [a, b]$, dann gilt

$$\|M - F\| \leq \|r\| \leq \frac{3}{4}L\|\Delta\|^2.$$

Beweis: Es ist $r_0 = d_0 - 2f''(x_0) - f''(x_1)$ und deshalb wegen (2.4.2.8)

$$r_0 = \frac{6}{h_1} \left(\frac{y_1 - y_0}{h_1} - y'_0 \right) - 2f''(x_0) - f''(x_1).$$

Taylorentwicklung von $y_1 = f(x_1)$ und $f''(x_1)$ um x_0 ergibt

$$\begin{aligned} r_0 &= \frac{6}{h_1} \left[f'(x_0) + \frac{h_1}{2} f''(x_0) + \frac{h_1^2}{6} f'''(x_0) + \frac{h_1^3}{24} f^{(4)}(\tau_1) - f'(x_0) \right] \\ &\quad - 2f''(x_0) - \left[f''(x_0) + h_1 f'''(x_0) + \frac{h_1^2}{2} f^{(4)}(\tau_2) \right] \\ &= \frac{h_1^2}{4} f^{(4)}(\tau_1) - \frac{h_1^2}{2} f^{(4)}(\tau_2) \end{aligned}$$

mit $\tau_1, \tau_2 \in (x_0, x_1)$. Also ist

$$|r_0| \leq \frac{3}{4}L\|\Delta\|^2.$$

Analog erhält man für

$$r_n = d_n - f''(x_{n-1}) - 2f''(x_n)$$

die Abschätzung

$$|r_n| \leq \frac{3}{4}L\|\Delta\|^2.$$

Wir betrachten nun die übrigen Komponenten von $r = d - AF$,

$$\begin{aligned} r_j &= d_j - \mu_j f''(x_{j-1}) - 2f''(x_j) - \lambda_j f''(x_{j+1}) \\ &= \frac{6}{h_j + h_{j+1}} \left[\frac{y_{j+1} - y_j}{h_{j+1}} - \frac{y_j - y_{j-1}}{h_j} \right] \\ &\quad - \frac{h_j}{h_j + h_{j+1}} f''(x_{j-1}) - 2f''(x_j) - \frac{h_{j+1}}{h_j + h_{j+1}} f''(x_{j+1}). \end{aligned}$$

Taylorentwicklung um x_j ergibt

$$\begin{aligned}
r_j &= \frac{6}{h_j + h_{j+1}} \left[f'(x_j) + \frac{h_{j+1}}{2} f''(x_j) + \frac{h_{j+1}^2}{6} f'''(x_j) + \frac{h_{j+1}^3}{24} f^{(4)}(\tau_1) \right. \\
&\quad \left. - f'(x_j) + \frac{h_j}{2} f''(x_j) - \frac{h_j^2}{6} f'''(x_j) + \frac{h_j^3}{24} f^{(4)}(\tau_2) \right] \\
&\quad - \frac{h_j}{h_j + h_{j+1}} \left[f''(x_j) - h_j f'''(x_j) + \frac{h_j^2}{2} f^{(4)}(\tau_3) \right] - 2f''(x_j) \\
&\quad - \frac{h_j}{h_j + h_{j+1}} \left[f''(x_j) + h_{j+1} f'''(x_j) + \frac{h_{j+1}^2}{2} f^{(4)}(\tau_4) \right] \\
&= \frac{1}{h_j + h_{j+1}} \left[\frac{h_{j+1}^3}{4} f^{(4)}(\tau_1) + \frac{h_j^3}{4} f^{(4)}(\tau_2) - \frac{h_j^3}{2} f^{(4)}(\tau_3) \right. \\
&\quad \left. - \frac{h_{j+1}^3}{2} f^{(4)}(\tau_4) \right].
\end{aligned}$$

Dabei ist $\tau_i \in [x_{j-1}, x_{j+1}]$ für $i = 1, 2, 3, 4$. Also gilt für $j = 1, 2, \dots, n-1$

$$|r_j| \leq \frac{3}{4} L \frac{1}{h_j + h_{j+1}} [h_{j+1}^3 + h_j^3] \leq \frac{3}{4} L \|\Delta\|^2.$$

Insgesamt folgt

$$\|r\| \leq \frac{3}{4} L \|\Delta\|^2$$

und daraus wegen $r = A(M - F)$ und (2.4.2.14)

$$\|M - F\| \leq \|r\| \leq \frac{3}{4} L \|\Delta\|^2. \quad \square$$

Allgemein gilt

(2.4.3.3) **Satz:** Sei $f \in C^4[a, b]$ und $|f^{(4)}(x)| \leq L$ für $x \in [a, b]$. Sei weiter $\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$ eine Partition von $[a, b]$ und K eine Konstante mit

$$\frac{\|\Delta\|}{|x_{j+1} - x_j|} \leq K \quad \text{für } j = 0, 1, \dots, n-1.$$

Sei schließlich S_Δ die interpolierende Splinefunktion mit $S_\Delta(x_j) = f(x_j)$ für $j = 0, 1, \dots, n$, und $S'_\Delta(x) = f'(x)$ für $x = a, b$. Dann gibt es von Δ unabhängige Konstanten $c_k (\leq 2)$, so daß für $x \in [a, b]$ gilt

$$|f^{(k)}(x) - S_\Delta^{(k)}(x)| \leq \begin{cases} c_k L \|\Delta\|^{4-k} & \text{für } k = 0, 1, 2, \\ c_3 L K \|\Delta\| & \text{für } k = 3. \end{cases}$$

Man beachte, daß $K \geq 1$ eine Schranke für die Ungleichförmigkeit der Partition Δ ist und nur die Schranke für die dritten Ableitungen von K abhängt.

Beweis: Wir zeigen die Behauptung des Satzes zunächst für $k = 3$. Für $x \in [x_{j-1}, x_j]$ ist

$$\begin{aligned} S_{\Delta}'''(x) - f'''(x) &= \frac{M_j - M_{j-1}}{h_j} - f'''(x) \\ &= \frac{M_j - f''(x_j)}{h_j} - \frac{M_{j-1} - f''(x_{j-1})}{h_j} \\ &\quad + \frac{f''(x_j) - f''(x) - [f''(x_{j-1}) - f''(x)]}{h_j} - f'''(x). \end{aligned}$$

Durch Taylorentwicklung um x erhält man wegen (2.4.3.2)

$$\begin{aligned} |S_{\Delta}'''(x) - f'''(x)| &\leq \frac{3}{2}L \frac{\|\Delta\|^2}{h_j} + \frac{1}{h_j} \left| (x_j - x)f'''(x) + \frac{(x_j - x)^2}{2} f^{(4)}(\eta_1) \right. \\ &\quad \left. - (x_{j-1} - x)f'''(x) - \frac{(x_{j-1} - x)^2}{2} f^{(4)}(\eta_2) - h_j f'''(x) \right| \\ &\leq \frac{3}{2}L \frac{\|\Delta\|^2}{h_j} + \frac{L}{2} \frac{\|\Delta\|^2}{h_j}, \quad \eta_1, \eta_2 \in [x_{j-1}, x_j] \\ &= 2L \frac{\|\Delta\|^2}{h_j} \leq 2LK \|\Delta\|, \end{aligned}$$

da nach Voraussetzung $\|\Delta\|/h_j \leq K$ für alle j gilt.

Die Behauptung des Satzes für $k = 2$ erhält man auf folgende Weise: Für jedes $x \in (a, b)$ gibt es einen nächsten Knoten $x_j = x_j(x)$, o.B.d.A. sei $x \leq x_j(x) = x_j$, so daß $x \in [x_{j-1}, x_j]$ und $|x_j(x) - x| \leq h_j/2$. Es folgt daher aus

$$f''(x) - S_{\Delta}''(x) = f''(x_j(x)) - S_{\Delta}''(x_j(x)) + \int_{x_j(x)}^x (f'''(t) - S_{\Delta}'''(t)) dt.$$

mit Hilfe der eben bewiesenen Abschätzungen sofort

$$\begin{aligned} |f''(x) - S_{\Delta}''(x)| &\leq \frac{3}{4}L \|\Delta\|^2 + \frac{1}{2}h_j \cdot 2L \frac{\|\Delta\|^2}{h_j} \\ &\leq \frac{7}{4}L \|\Delta\|^2, \quad x \in [a, b]. \end{aligned}$$

Als nächstes betrachten wir den Fall $k = 1$. Wegen

$$f(x_{j-1}) = S_{\Delta}(x_{j-1}), \quad f(x_j) = S_{\Delta}(x_j)$$

existieren nach dem Satz von Rolle außer den Randpunkten $\xi_0 := a$, $\xi_{n+1} := b$ weitere n Punkte $\xi_j \in (x_{j-1}, x_j)$, $j = 1, 2, \dots, n$, mit

$$f'(\xi_j) = S'_{\Delta}(\xi_j), \quad j = 0, 1, \dots, n+1.$$

Es gibt also für jedes $x \in [a, b]$ ein nächstes $\xi_j = \xi_j(x)$ mit

$$|\xi_j(x) - x| < \|\Delta\|.$$

Für $x \in [a, b]$ gilt daher

$$f'(x) - S'_{\Delta}(x) = \int_{\xi_j(x)}^x (f''(t) - S''_{\Delta}(t)) dt,$$

so daß für alle $x \in [a, b]$

$$|f'(x) - S'_{\Delta}(x)| \leq \frac{7}{4} L \|\Delta\|^2 \cdot \|\Delta\| = \frac{7}{4} L \|\Delta\|^3.$$

Für den Fall $k = 0$ folgt schließlich auf dieselbe Weise

$$f(x) - S_{\Delta}(x) = \int_{x_j(x)}^x (f'(t) - S'_{\Delta}(t)) dt,$$

so daß für alle $x \in [a, b]$ gilt

$$|f(x) - S_{\Delta}(x)| \leq \frac{7}{4} L \|\Delta\|^3 \cdot \frac{1}{2} \|\Delta\| = \frac{7}{8} L \|\Delta\|^4.$$

Damit ist der Satz bewiesen.⁷

□

Natürlich ergibt dieser Satz für Folgen

$$\Delta_m = \{a = x_0^{(m)} < x_1^{(m)} < \dots < x_n^{(m)} = b\}$$

von Partitionen von $[a, b]$ mit $\lim_m \|\Delta_m\| = 0$ und

$$\sup_{m,j} \frac{\|\Delta_m\|}{|x_{j+1}^{(m)} - x_j^{(m)}|} \leq K < +\infty,$$

daß die entsprechenden Splinefunktionen S_{Δ_m} und ihre ersten drei Ableitungen gleichmäßig auf $[a, b]$ gegen f und die entsprechenden Ableitungen von f konvergieren. Man beachte, daß sogar die dritte Ableitung f''' gleichmäßig durch die stückweise konstanten Funktionen S'''_{Δ_m} approximiert wird.

⁷ Eine schärfere Abschätzung $|f^{(k)}(x) - S_{\Delta}^{(k)}(x)| \leq c_k L \|\Delta\|^{4-k}$, $k = 0, 1, 2, 3$, mit $c_0 = 5/384$, $c_1 = 1/24$, $c_2 = 3/8$, $c_3 = (K + K^{-1})/2$ wurde von Hall und Meyer (1976) bewiesen. Dabei sind c_0 und c_1 optimal.

2.4.4 B-Splines

Splinefunktionen sind Beispiele von stückweisen Polynomfunktionen zu einer Unterteilung

$$\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$$

des Intervalls $[a, b]$ durch Abszissen oder *Knoten* x_i . Allgemein nennen wir eine Funktion $f: [a, b] \rightarrow \mathbb{R}$ eine *stückweise Polynomfunktion* der *Ordnung* r und des *Grades* $r - 1$ zur Partition Δ , wenn f auf jedem offenen Teilintervall (x_i, x_{i+1}) , $i = 0, \dots, n - 1$, mit einem Polynom $p_i(x)$ vom Grad $\leq r - 1$ übereinstimmt. Um die Zuordnung von f zu der Sequenz $(p_0(x), p_1(x), \dots, p_{n-1}(x))$ von Polynomen eindeutig zu machen, definieren wir f an den Knoten x_i , $i = 0, \dots, n - 1$ so, daß f rechtsseitig stetig wird, $f(x_i) := f(x_i + 0)$, $0 \leq i \leq n - 1$, und $f(x_n) = f(b) := f(x_n - 0)$ gilt.

Beispielsweise sind die früher eingeführten Splinefunktionen S_Δ vom Grad k stückweise Polynomfunktionen der Ordnung $k + 1$, die an den inneren Knoten x_i , $1 \leq i \leq n - 1$, von Δ mindestens $(k - 1)$ -mal differenzierbar sind. Mit $S_{\Delta,k}$ bezeichnen wir die Menge aller Splinefunktionen vom Grad k . Diese Menge ist ein reeller Vektorraum der Dimension $n + k$, wie man leicht durch Abzählen der Freiheitsgrade bestätigt: Das Polynom $S_\Delta|[x_0, x_1]$ ist durch seine $k + 1$ Koeffizienten eindeutig bestimmt; nach Wahl dieses Polynoms sind für das nächste Polynom $S_\Delta|[x_1, x_2]$ die Werte der ersten $k - 1$ Ableitungen in x_1 bestimmt ($= k$ Bedingungen), so daß für die Wahl von $S_\Delta|[x_1, x_2]$ nur 1 Freiheitsgrad verbleibt. Das Gleiche gilt für die Wahl der weiteren Polynome $S_\Delta|[x_i, x_{i+1}]$, $i = 2, \dots, n - 1$. Insgesamt sieht man so $\dim S_{\Delta,k} = k + 1 + (n - 1) \cdot 1 = k + n$.

B-Splines sind spezielle stückweise Polynomfunktionen mit bemerkenswerten Eigenschaften: Sie sind nichtnegativ und nur auf wenigen benachbarten Intervallen $[x_i, x_{i+1}]$ von Null verschieden. Insbesondere werden wir sehen, daß man eine auch für die numerische Rechnung brauchbare Basis von $S_{\Delta,k}$ angeben kann, die aus B-Splines besteht.

Um die Definition von B-Splines vorzubereiten, führen wir zunächst zu einem reellen Parameter x die Funktion $f_x: \mathbb{R} \rightarrow \mathbb{R}$,

$$f_x(t) := (t - x)_+ := \max(t - x, 0) = \begin{cases} t - x & \text{für } t > x, \\ 0 & \text{für } t \leq x, \end{cases}$$

und ihre Potenzen $f_x^r, f_x^r(t) := (t - x)_+^r$, $r \geq 0$, ein, wobei wir f_x^0 durch

$$f_x^0(t) := \begin{cases} 1 & \text{für } t > x, \\ 0 & \text{für } t \leq x, \end{cases}$$

definieren. Die Funktion $f_x^r(\cdot)$ ist stückweise aus zwei Polynomen vom Grad $\leq r$ zusammengesetzt, nämlich dem 0-Polynom $P_0(t) := 0$ für $t \leq x$ und dem Polynom $P_1(t) := (t - x)^r$ für $t > x$. Man beachte, daß $f_x^r(t)$ von dem reellen Parameter x abhängt und so definiert ist, daß diese Funktion als Funktion von x für festes t rechtsseitig stetig ist. Ferner ist $f_x^r(t)$ für $r \geq 1$ sowohl nach x wie nach t $(r - 1)$ -mal stetig differenzierbar.

Weiter erinnern wir daran, daß unter bestimmten Bedingungen für beliebige Segmente $t_i \leq t_{i+1} \leq \dots \leq t_{i+r}$ reeller Zahlen t_j die verallgemeinerte dividierte Differenz $f[t_i, t_{i+1}, \dots, t_{i+r}]$ einer reellen Funktion $f(t)$, $f: \mathbb{R} \rightarrow \mathbb{R}$, auch dann erklärt ist, wenn die t_j nicht alle verschieden sind [s. Abschnitt 2.1.5 und (2.1.5.7)]. Einzige Voraussetzung dafür ist, daß die Funktion f an den Stellen $t = t_j$, $i \leq j \leq i + r$, $s_j - 1$ -mal differenzierbar ist, falls der Wert von t_j in dem Teilsegment $t_i \leq t_{i+1} \leq \dots \leq t_j$, das mit t_j endet, s_j -mal vorkommt. Nach (2.1.5.7) gilt dann (2.4.4.1)

$$f[t_i, \dots, t_{i+r}] := \frac{f^{(r)}(t_i)}{r!}, \quad \text{falls } t_i = t_{i+r},$$

$$f[t_i, \dots, t_{i+r}] := \frac{f[t_{i+1}, \dots, t_{i+r}] - f[t_i, \dots, t_{i+r-1}]}{t_{i+r} - t_i}, \quad \text{sonst.}$$

Es folgt sofort aus (2.4.4.1) durch Induktion über r , daß die verallgemeinerten dividierten Differenzen von f Linearkombinationen ihrer Ableitungen in den Punkten t_j sind:

$$(2.4.4.2) \quad f[t_i, t_{i+1}, \dots, t_{i+r}] = \sum_{j=i}^{i+r} \alpha_j f^{(s_j-1)}(t_j),$$

wobei insbesondere $\alpha_{i+r} \neq 0$ gilt.

Sei nun $r \geq 1$ eine ganze Zahl und $\mathbf{t} = (t_i)_{i \in \mathbb{Z}}$ irgendeine unendliche nichtabnehmende Folge reeller Zahlen mit

$$\inf t_i = -\infty, \quad \sup t_i = +\infty, \quad t_i < t_{i+r} \text{ für alle } i.$$

Dann definiert man als i -ten B-Spline der Ordnung r zur Folge $\mathbf{t}$ die Funktion

$$(2.4.4.3) \quad B_{i,r,\mathbf{t}}(x) := (t_{i+r} - t_i) f_x^{r-1}[t_i, t_{i+1}, \dots, t_{i+r}],$$

für die wir auch kurz B_i , oder $B_{i,r}$ schreiben, wenn keine Mißverständnisse zu befürchten sind [s. Fig. 2 für einfache Beispiele].

Die Funktion $B_{i,r,\mathbf{t}}(x)$ ist zunächst für $x \neq t_i, t_{i+1}, \dots, t_{i+r}$ wohldefiniert und nach (2.4.4.2), (2.4.4.3) eine Linearkombination der Funktionen

$$(2.4.4.4a) \quad (t_j - x)_+^{r-s_j}, \quad i \leq j \leq i + r,$$

wobei s_j wieder angibt, wie oft der Wert von t_j in dem Teilsegment

$t_i \leq t_{i+1} \leq \dots \leq t_j$ vorkommt. Kommt der Wert von t_j insgesamt n_j -mal in dem vollen Segment $t_i \leq t_{i+1} \leq \dots \leq t_{i+r}$ vor, so gibt es nach Definition der s_j zu jeder ganzen Zahl σ mit $1 \leq \sigma \leq n_j$ genau einen Index $l = l(\sigma)$ mit

$$t_l = t_j, \quad s_l = \sigma, \quad i \leq l \leq i + r.$$

Also läßt sich $B_{i,r,t}(x)$ auch als Linearkombination der Funktionen

$$(2.4.4.4b) \quad (t_j - x)_+^s, \quad r - n_j \leq s \leq r - 1, \quad i \leq j \leq i + r,$$

schreiben.

Die Funktion $B_{i,r,t}(x)$ stimmt daher auf jedem der offenen Intervalle der Menge

$$(-\infty, t_i) \cup \{(t_j, t_{j+1}), i \leq j < i + r \text{ \& } t_j < t_{j+1}\} \cup (t_{i+r}, +\infty)$$

mit einem Polynom vom Grade $\leq r - 1$ überein. Also ist sie eine stückweise Polynomfunktion der Ordnung r zu der Unterteilung der reellen Achse, die durch die t_k mit $k \in T_{i,r}$ gegeben ist, wobei

$$T_{i,r} := \{j \mid i \leq j < i + r \text{ \& } t_j < t_{j+1}\} \cup \{i + r\}.$$

Die Funktion $B_{i,r,t}(x)$ kann nur an den Knoten $x = t_j$ mit $i \leq j \leq i + r$ Sprungstellen besitzen. Sie ist aber stets rechtsseitig stetig, weil die Funktionen $(t_j - x)_+^s$, die in (2.4.4.4) vorkommen, alle rechtsseitig stetige Funktionen in x sind, auch für $s = 0$. Zu einer gegebenen Folge $\mathbf{t} = (t_j)$ ist wegen (2.4.4.4) der B-Spline $B_{i,r}(x) \equiv B_{i,r,t}(x)$ in $x = t_j \in \mathbf{t}$ $(r - n_j - 1)$ -mal differenzierbar, falls der Wert von t_j n_j -mal unter den $t_i, t_{i+1}, \dots, t_{i+r}$ vorkommt (für $n_j = r$ besitzt $B_{i,r,t}$ eine Sprungstelle in $x = t_j$). Man kann deshalb die Differenzierbarkeitsordnung der $B_{i,r,t}(x)$ in $x = t_j$ mit Hilfe der Anzahl der Wiederholungen von t_j in $\mathbf{t}$ steuern.

Wir notieren einige wichtige Eigenschaften der B-Splines:

(2.4.4.5) **Satz:** a) Für $x \notin [t_i, t_{i+r}]$ gilt $B_{i,r,t}(x) = 0$.

b) Für $t_i < x < t_{i+r}$ gilt $B_{i,r,t}(x) > 0$.

c) Für jedes $x \in \mathbb{R}$ gilt

$$\sum_i B_{i,r,t}(x) = 1,$$

und die angegebene Summe enthält nur endlich viele Terme $\neq 0$.

Diese Aussagen besagen unter anderem, daß die Funktionen $B_{i,r} \equiv B_{i,r,t}(x)$ nichtnegative Gewichtsfunktionen mit der Summe 1 sind, die das Intervall $[t_i, t_{i+r}]$ als Träger besitzen,

$$\text{supp } B_{i,r} := \overline{\{x \mid B_{i,r}(x) \neq 0\}} = [t_i, t_{i+r}],$$

und die $B_{i,r}$ eine „Partition der Einheit“ bilden.

Beispiel: Für $r = 5$ und eine Folge $\mathbf{t}$ mit $\dots \leq t_0 < t_1 = t_2 = t_3 < t_4 = t_5 < t_6 \leq \dots$ ist der B-Spline $B_{1,5}$ der Ordnung 5 eine stückweise Polynomfunktion des Grades 4 bezüglich der Partition $t_3 < t_5 < t_6$ von $\mathbb{R}$. Für $x = t_3, t_5, t_6$ besitzt $B_{1,5}(x)$ wegen $n_3 = 3, n_5 = 2, n_6 = 1$ stetige Ableitungen bis zur Ordnung 1, 2 bzw. 3.




Fig. 2. Einige einfache B-Splines

Beweis: a) Für $x < t_i \leq t \leq t_{i+r}$ ist $f_x^{r-1}(t) = (t-x)^{r-1}$ ein Polynom $(r-1)$ -ten Grades in t , für das nach Satz (2.1.3.10) die r -te dividierte Differenz verschwindet,

$$f_x^{r-1}[t_i, t_{i+1}, \dots, t_{i+r}] = 0 \implies B_{i,r}(x) = 0.$$

Für $t_i \leq t \leq t_{i+r} < x$ ist dagegen $f_x^{r-1}(t) = (t-x)_+^{r-1} = 0$, so daß ebenfalls $B_{i,r}(x) = 0$ gilt.

b) Für $r = 1$ und $t_i < x < t_{i+1}$ folgt dies aus der Definition von $B_{i,1}$

$$B_{i,1}(x) = (t_{i+1} - x)_+^0 - (t_i - x)_+^0 = 1 - 0 = 1.$$

Für $r > 1, t_i < x < t_{i+r}$ wird $B_{i,r}(x) > 0$ später mit Hilfe einer Rekursionsformel (2.4.5.2) für die Funktionen $N_{i,r} := B_{i,r}/(t_{i+r} - t_i)$ gezeigt.

c) Zu jedem $x \in \mathbb{R}$ gibt es genau ein j mit $t_j \leq x < t_{j+1}$. Sei zunächst $t_j < x < t_{j+1}$. Dann gilt wegen a) $B_{i,r}(x) = 0$ für alle i, r mit $i+r \leq j$ und für alle $i \geq j+1$, so daß

$$\sum_i B_{i,r}(x) = \sum_{i=j-r+1}^j B_{i,r}(x).$$

Wegen (2.4.4.1) gilt aber

$$B_{i,r}(x) = f_x^{r-1}[t_{i+1}, t_{i+2}, \dots, t_{i+r}] - f_x^{r-1}[t_i, t_{i+1}, \dots, t_{i+r-1}],$$

so daß

$$\sum_i B_{i,r}(x) = f_x^{r-1}[t_{j+1}, \dots, t_{j+r}] - f_x^{r-1}[t_{j-r+1}, \dots, t_j] = 1 - 0.$$

Dies gilt, weil die Funktion $f_x^{r-1}(t) = (t-x)^{r-1}$ für $t_j < x < t_{j+1} \leq t \leq t_{j+r}$ ein Polynom $(r-1)$ -ten Grades in t ist, für das $f_x^{r-1}[t_{j+1}, \dots, t_{j+r}] = 1$ wegen (2.1.4.3) gilt, und weil für $t_{j-r+1} \leq t \leq t_j < x < t_{j+1}$ die Funktion $f_x^{(r-1)}(t) = (t-x)_+^{r-1} = 0$ verschwindet.

Für $x = t_j < t_{j+1}$ folgt die Behauptung aus dem eben Bewiesenen und der rechtsseitigen Stetigkeit von $B_{i,r}$,

$$B_{i,r}(t_j) = \lim_{y \downarrow t_j} B_{i,r}(y). \quad \square$$

Wir kehren nun zu den Räumen $S_{\Delta,k}$ der Splinefunktionen k -ten Grades zurück und konstruieren eine Folge $\mathbf{t} = (t_j)$ derart, daß die B-Splines $B_{i,k+1,\mathbf{t}}(x)$ der Ordnung $k+1$ eine Basis von $S_{\Delta,k}$ bilden. Dazu ordnen wir der Partition

$$\Delta = \{a = x_0 < x_1 < \dots < x_n = b\}$$

irgendeine unendliche Folge $\mathbf{t} = (t_j)_{j \in \mathbb{Z}}$ zu mit

$$\begin{aligned} t_j &< t_{j+k+1} \quad \text{für alle } j, \\ t_{-k} &\leq \dots \leq t_0 := x_0 < t_1 := x_1 < \dots < t_n := x_n. \end{aligned}$$

Im folgenden spielt nur die Teilfolge

$$t_{-k}, t_{-k+1}, \dots, t_{n+k}$$

eine Rolle. Der folgende wichtige Satz stammt von Curry und Schoenberg (1966):

(2.4.4.6) Theorem. Die Restriktionen $B_{i,k+1,\mathbf{t}}|_{[a,b]}$ der $n+k$ B-Splines $B_i \equiv B_{i,k+1,\mathbf{t}}$, $i = -k, -k+1, \dots, n-1$, auf $[a,b]$ bilden eine Basis von $S_{\Delta,k}$.

Beweis: Jeder B-Spline B_i , $-k \leq i \leq n-1$, stimmt mit einem Polynom vom Grade $\leq k$ auf den Teilintervallen $[x_j, x_{j+1}]$ von $[a,b]$ überein. Ferner besitzt er Ableitungen bis zur Ordnung $k-n_j = k-1$ in den inneren Knoten $t_j = x_j$, $j = 1, 2, \dots, n-1$, von Δ , weil diese t_j nur einmal in $\mathbf{t}$ vorkommen, $n_j = 1$. Dies zeigt $B_i|_{[a,b]} \in S_{\Delta,k}$ für alle $i = -k, \dots, n-1$. Andererseits haben wir bereits gesehen, daß $S_{\Delta,k} = n+k$ die Dimension $n+k$ besitzt. Also bleibt nur noch zu zeigen, daß die Funktionen B_i , $-k \leq i \leq n-1$ auf $[a,b]$ linear unabhängig sind.

Angenommen, es gebe Konstante a_i , so daß $\sum_{i=-k}^{n-1} a_i B_i(x) = 0$ für alle $x \in [a, b]$. Wir betrachten zunächst das erste Teilintervall $[x_0, x_1]$ von $[a, b]$. Aus Satz (2.4.4.5)(a) folgt dann

$$\sum_{i=-k}^0 a_i B_i(x) = 0 \quad \text{für } x \in [x_0, x_1]$$

wegen $B_i|_{[x_0, x_1]} = 0$ für $i \geq 1$. Wir zeigen nun die lineare Unabhängigkeit der B-Splines $B_{-k}, \dots, B_0$ auf $[x_0, x_1]$, so daß $a_{-k} = a_{-k+1} = \dots = a_0 = 0$.

Nun gilt für $x \in [x_0, x_1]$

$$\text{span}\{B_{-k}(x), \dots, B_0(x)\} = \text{span}\{(t_1 - x)^{k+1-s_1}, \dots, (t_{k+1} - x)^{k+1-s_{k+1}}\},$$

falls der Wert von t_j genau s_j -mal in dem Segment $t_{-k} \leq t_{-k+1} \leq \dots \leq t_j$ vorkommt. Dies zeigt man leicht durch Induktion, weil wegen (2.4.4.2), (2.4.4.4a) jedes $B_i(x)$, $-k \leq i \leq 0$, mit einer Konstanten $\alpha_{i+k+1} \neq 0$ folgende Form besitzt:

$$B_i(x) = \alpha_1(t_1 - x)^{k+1-s_1} + \dots + \alpha_{i+k+1}(t_{i+k+1} - x)^{k+1-s_{i+k+1}}.$$

Also genügt es, die lineare Unabhängigkeit der Funktionen

$$(t_1 - x)^{k-(s_1-1)}, \dots, (t_{k+1} - x)^{k-(s_{k+1}-1)}$$

auf $[x_0, x_1]$ zu zeigen, oder die damit äquivalente lineare Unabhängigkeit der normalisierten Funktionen

$$(2.4.4.7) \quad p^{(s_j-1)}(t_j - x), \quad j = 1, 2, \dots, k+1,$$

mit

$$p(t) := \frac{1}{k!} t^k.$$

Angenommen es gibt Konstante $c_1, c_2, \dots, c_{k+1}$ mit

$$\sum_{j=1}^{k+1} c_j p^{(s_j-1)}(t_j - x) = 0 \quad \text{für alle } x \in [x_0, x_1].$$

Die Taylorreihenentwicklung um t_j liefert dann ein Polynom

$$\sum_{j=1}^{k+1} c_j \sum_{l=0}^k p^{(l+s_j-1)}(t_j) \frac{(-x)^l}{l!} = 0 \quad \text{für } x \in [x_0, x_1],$$

das auf $[x_0, x_1]$ verschwindet, so daß es das Null-Polynom sein muß. Es folgt für alle $l = 0, 1, \dots, k$

$$\sum_{j=1}^{k+1} c_j p^{(l+s_j-1)}(t_j) = 0$$

und daraus

$$\sum_{j=1}^{k+1} c_j \Pi^{(s_j-1)}(t_j) = 0,$$

wobei $\Pi(t)$ der folgende Zeilenvektor ist:

$$\begin{aligned} \Pi(t) &:= \left[p^{(k)}(t), p^{(k-1)}(t), \dots, p(t) \right] \\ &= \left[1, t, \dots, \frac{t^k}{k!} \right]. \end{aligned}$$

Nun sind aber wegen Korollar (2.1.5.5)] die Vektoren $\Pi^{(s_j-1)}(t_j)$, $j = 1, 2, \dots, k+1$, linear unabhängig (wegen der eindeutigen Lösbarkeit des Hermiteischen Interpolationsproblems bezüglich der Sequenz $t_1 \leq t_2 \leq \dots \leq t_{k+1}$ von virtuellen Abszissen). Also folgt $c_1 = \dots = c_{k+1} = 0$ und deshalb auch $a_i = 0$ für $i = -k, -k+1, \dots, 0$.

Durch Anwendung der gleichen Argumente auf jedes weitere Teilintervall $[x_j, x_{j+1}]$ von $[a, b]$, $j = 1, 2, \dots, n-1$, findet man schließlich $a_i = 0$ für alle $i = -k, -k+1, \dots, n-1$. Also sind alle B_i , $-k \leq i \leq n-1$ auf $[a, b]$ linear unabhängige Funktionen, ihre Restriktionen auf $[a, b]$ bilden daher eine Basis von $S_{\Delta, k}$. $\square$

2.4.5 Die Berechnung von B-Splines

B-Splines können mit Hilfe einer einfachen Rekursionsformel berechnet werden. Um diese Formel herzuleiten, benötigen wir eine Verallgemeinerung der Leibnizschen Formel für dividierte Differenzen

(2.4.5.1) **(Leibniz Formel)** Sei $t_i \leq t_{i+1} \leq \dots \leq t_{i+k}$. Falls $f(t) = g(t)h(t)$ Produkt zweier Funktionen ist, die hinreichend oft für die $t = t_j$, $j = i, i+1, \dots, i+k$, differenzierbar sind, so daß $g[t_i, t_{i+1}, \dots, t_{i+k}]$ und $h[t_i, t_{i+1}, \dots, t_{i+k}]$ definiert sind [s. (2.4.4.1)], dann gilt

$$f[t_i, t_{i+1}, \dots, t_{i+k}] = \sum_{r=i}^{i+k} g[t_i, t_{i+1}, \dots, t_r] h[t_r, t_{r+1}, \dots, t_{i+k}].$$

Beweis: Wegen (2.1.5.7) interpolieren die Polynome

$$\sum_{r=i}^{i+k} g[t_i, \dots, t_r] (t - t_i) \cdots (t - t_{r-1}),$$

$$\sum_{s=i}^{i+k} h[t_s, \dots, t_{i+k}](t - t_{s+1}) \cdots (t - t_{i+k})$$

die Funktionen g bzw. h an den Stellen $t = t_i, t_{i+1}, \dots, t_{i+k}$ (im Sinne der Hermite-Interpolation, s. Abschnitt 2.1.5, falls die $t_i, \dots, t_{i+k}$ nicht alle verschieden sind). Also interpoliert auch das Produktpolynom

$$F(t) := \sum_{r=i}^{i+k} g[t_i, \dots, t_r](t - t_i) \cdots (t - t_{r-1}) \\ \cdot \sum_{s=i}^{i+k} h[t_s, \dots, t_{i+k}](t - t_{s+1}) \cdots (t - t_{i+k})$$

für $t = t_i, \dots, t_{i+k}$ die Funktion $f(t)$. Nun läßt sich aber dieses Produkt als Summe zweier Polynome in t schreiben

$$F(t) = \sum_{r,s=i}^{i+k} \cdots = \sum_{r \leq s} \cdots + \sum_{r > s} \cdots = P_1(t) + P_2(t),$$

wobei jeder Term der zweiten Summe $\sum_{r > s} \cdots$ das Polynom $\prod_{j=i}^{i+k} (t - t_j)$ als Faktor enthält, so daß $P_2(t)$ die 0-Funktion für $t = t_i, \dots, t_{i+k}$ interpoliert. Daher interpoliert auch das Polynom $P_1(t)$, das höchstens den Grad k besitzt, die Funktion $f(t)$ für $t = t_i, \dots, t_{i+k}$, so daß $P_1(t)$ die eindeutig bestimmte (Hermite-) Interpolierende von f vom Grad $\leq k$ ist.

Nach (2.1.5.7) besitzt P_1 den höchsten Koeffizienten $f[t_i, \dots, t_{i+k}]$. Ein Vergleich der Koeffizienten von t^k in der Summendarstellung $P_1(t) = \sum_{r \leq s} \cdots$ von $P_1(t)$ liefert die gewünschte Formel

$$f[t_i, \dots, t_{i+k}] = \sum_{r=i}^{i+k} g[t_i, \dots, t_r] h[t_r, \dots, t_{i+k}]. \quad \square$$

Mit Hilfe von (2.4.5.1) können wir nun eine Rekursionsformel für die B-Splines $B_{i,r}(x) \equiv B_{i,r,t}(x)$ (2.4.4.3) herleiten. Dazu ist es zweckmäßig, die Funktionen $B_{i,r}(x)$ anders zu normieren und stattdessen die Funktionen

$$N_{i,r}(x) := \frac{B_{i,r}(x)}{t_{i+r} - t_i} \equiv f_x^{r-1}[t_i, t_{i+1}, \dots, t_{i+r}]$$

einzuführen. Für sie gilt folgende einfache Rekursionsformel für $r \geq 2$ und $t_i < t_{i+r}$:

$$(2.4.5.2) \quad N_{i,r}(x) = \frac{x - t_i}{t_{i+r} - t_i} N_{i,r-1}(x) + \frac{t_{i+r} - x}{t_{i+r} - t_i} N_{i+1,r-1}(x).$$

Beweis: Sei zunächst $x \neq t_j$ für alle j . Wir wenden die Leibnizformel (2.4.5.1) auf das Produkt

$$f_x^{r-1} \equiv (t-x)_+^{r-1} \equiv (t-x)(t-x)_+^{r-2} \equiv g(t)f_x^{r-2}(t)$$

an und erhalten wegen

$$g[t_i] = t_i - x, \quad g[t_i, t_{i+1}] = 1, \quad g[t_i, \dots, t_j] = 0 \quad \text{für } j > i+1,$$

(dies folgt aus (2.1.4.3): $g(t)$ ist ein lineares Polynom in t) die Beziehung

$$\begin{aligned} f_x^{r-1}[t_i, \dots, t_{i+r}] &= (t_i - x)f_x^{r-2}[t_i, \dots, t_{i+r}] + 1 \cdot f_x^{r-2}[t_{i+1}, \dots, t_{i+r}] \\ &= \frac{(t_i - x)}{t_{i+r} - t_i} (f_x^{r-2}[t_{i+1}, \dots, t_{i+r}] - f_x^{r-2}[t_i, \dots, t_{i+r-1}]) \\ &\quad + 1 \cdot f_x^{r-2}[t_{i+1}, \dots, t_{i+r}] \\ &= \frac{x - t_i}{t_{i+r} - t_i} f_x^{r-2}[t_i, \dots, t_{i+r-1}] + \frac{t_{i+r} - x}{t_{i+r} - t_{i+1}} f_x^{r-2}[t_{i+1}, \dots, t_{i+r}], \end{aligned}$$

was (2.4.5.2) für $x \neq t_i, \dots, t_{i+r}$ zeigt. Daß damit (2.4.5.2) auch für alle x gilt, folgt wegen $t_i < t_{i+r}$ aus der rechtsseitigen Stetigkeit der $B_{i,r}(x)$. $\square$

Wir können jetzt den Beweis von (2.4.4.5),b) nachholen: Nach (2.4.5.2) ist $N_{i,r}(x)$ für $t_i < x < t_{i+r}$ konvexe Linearkombination von $N_{i,r-1}(x)$ und $N_{i+1,r-1}(x)$ mit positiven Gewichten $\lambda_i(x) = (x - t_i)/(t_{i+r} - t_i) > 0$ und $1 - \lambda_i(x) > 0$. Nun haben $N_{i,r}(x)$ und $B_{i,r}(x)$ das gleiche Vorzeichen, und wir wissen bereits, daß $B_{i,1}(x) = 0$ für $x \notin [t_i, t_{i+1}]$ und $B_{i,1}(x) > 0$ für $t_i < x < t_{i+1}$ gilt. Durch Induktion bezüglich r mit Hilfe von (2.4.5.2) folgt daher $B_{i,r}(x) > 0$ für $t_i < x < t_{i+r}$. $\square$

Die zu (2.4.5.2) äquivalente Formel (falls $t_i < t_{i+r-1}$ und $t_{i+1} < t_{i+r}$)

$$(2.4.5.3) \quad B_{i,r}(x) = \frac{x - t_i}{t_{i+r-1} - t_i} B_{i,r-1}(x) + \frac{t_{i+r} - x}{t_{i+r} - t_{i+1}} B_{i+1,r-1}(x)$$

stellt den Wert $B_{i,r}(x)$ als positive Linearkombination der Werte von $B_{i,r-1}(x)$ und $B_{i+1,r-1}(x)$ dar. Man kann sie benutzen, um die Werte aller Splinefunktionen $B_{i,r,t}(x) = B_{i,r,t}(x)$ für jedes feste x zu berechnen.

Um dies zu zeigen nehmen wir an, daß es ein $t_j \in \mathbf{t}$ mit $t_j \leq x < t_{j+1}$ gibt, denn sonst gilt sicher $B_{i,r}(x) = 0$ für alle i, r , für die $B_{i,r,t}$ definiert ist. Ferner ist wegen (2.4.4.5)a) $B_{i,r}(x) = 0$ für alle i, r mit $x \notin [t_i, t_{i+r}]$, d.h. für $i \leq j - r$ und für $i \geq j + 1$. In dem folgenden Tableau aller $B_{i,r} := B_{i,r}(x)$ verschwindet $B_{i,r}$ an den mit 0 bezeichneten Stellen:

$$(2.4.5.4) \quad \begin{array}{ccccc} 0 & 0 & 0 & 0 & \dots \\ 0 & 0 & 0 & B_{j-3,4} & \dots \\ 0 & 0 & B_{j-2,3} & B_{j-2,4} & \dots \\ 0 & B_{j-1,2} & B_{j-1,3} & B_{j-1,4} & \dots \\ B_{j,1} & B_{j,2} & B_{j,3} & B_{j,4} & \dots \\ 0 & 0 & 0 & 0 & \dots \\ \vdots & \vdots & \vdots & \vdots & \end{array}$$

Wegen $t_j \leq x < t_{j+1}$ gilt definitionsgemäß $B_{j,1} = B_{j,1}(x) = 1$. Ausgehend von der ersten Spalte von (2.4.5.4) können die übrigen Spalten mittels (2.4.5.3) berechnet werden. Jedes $B_{i,r}$ erhält man aus seinen beiden linken Nachbarn $B_{i,r-1}$ und $B_{i+1,r-1}$ entsprechend dem folgenden Schema

$$\begin{array}{ccc} B_{i,r-1} & \rightarrow & B_{i,r} \\ & \nearrow & \\ B_{i+1,r-1} & & \end{array}$$

Da bei diesem Verfahren nur nichtnegative Vielfache nichtnegativer Zahlen addiert werden, ist das Verfahren numerisch sehr stabil.

Beispiel: Für $t_i = i$, $i = 0, 1, \dots$, und $x = 3.5 \in [t_3, t_4]$ erhält man folgendes Tableau der $B_{i,r} = B_{i,r}(x)$

$r =$		1	2	3	4
$i = 0$		0	0	0	1/48
$i = 1$		0	0	1/8	23/48
$i = 2$		0	1/2	6/8	23/48
$i = 3$		1	1/2	1/8	1/48
$i = 4$		0	0	0	0

Zum Beispiel erhält man $B_{2,4}$ aus

$$B_{2,4} = B_{2,4}(3.5) = \frac{3.5 - 2}{5 - 2} \cdot \frac{6}{8} + \frac{6 - 3.5}{6 - 3} \cdot \frac{1}{8} = \frac{23}{48}.$$

Wir betrachten nun Interpolationsprobleme für Splinefunktionen, nämlich das Problem eine Splinefunktion $S \in S_{\Delta,k}$ zu bestimmen, die an bestimmten Stellen vorgeschriebene Werte annimmt. Da der Vektorraum $S_{\Delta,k}$ eine Basis von B-Splines besitzt (s. das Ende von Abschnitt 2.4.4), ist dieses Problem ein Spezialfall der Interpolation durch Linearkombinationen von B-Splines: Sei $r \geq 1$ eine ganze Zahl, $\mathbf{t} = (t_i)_{1 \leq i \leq N+r}$ irgend eine Folge mit

$$t_1 \leq t_2 \leq \dots \leq t_{N+r}$$

und $t_i < t_{i+r}$ für alle $i = 1, 2, \dots, N$, und seien $B_i(x) \equiv B_{i,r,\mathbf{t}}(x)$, $i = 1, \dots, N$, die zugehörigen B-Splines. Mit

$$\mathcal{S}_{r,t} = \left\{ \sum_{i=1}^N \alpha_i B_i(x) \mid \alpha_i \in \mathbb{R} \right\}$$

bezeichnen wir den Vektorraum, der von den B_i , $i = 1, \dots, N$, aufgespannt wird. Wegen Korollar (2.4.4.6) besitzt er die Dimension $\dim \mathcal{S}_{r,t} = N$. Seien schließlich N Stützpunkte (ξ_j, f_j) , $j = 1, \dots, N$, mit

$$\xi_1 < \xi_2 < \dots < \xi_N$$

gegeben. Das Interpolationsproblem besteht dann darin, eine Funktion $S \in \mathcal{S}_{r,t}$ zu bestimmen, die den Interpolationsbedingungen

$$(2.4.5.5) \quad S(\xi_j) = f_j, \quad j = 1, \dots, N,$$

genügt. Da sich jede Funktion $S \in \mathcal{S}_{r,t}$ als Linearkombination der B_i , $i = 1, \dots, N$, schreiben läßt, ist dieses Problem damit äquivalent, das folgende lineare Gleichungssystem

$$(2.4.5.6) \quad \sum_{i=1}^N \alpha_i B_i(\xi_j) = f_j, \quad j = 1, \dots, N,$$

zu lösen. Seine Matrix

$$A = \begin{bmatrix} B_1(\xi_1) & \dots & B_N(\xi_1) \\ \vdots & & \vdots \\ B_1(\xi_N) & \dots & B_N(\xi_N) \end{bmatrix}$$

besitzt Bandstruktur: Da der Träger der Funktion $B_i(x) = B_{i,r,t}(x)$ nach (2.4.4.5) gerade das Intervall $[t_i, t_{i+r}]$ ist, verschwinden in der j -ten Zeile von A alle Elemente $B_i(\xi_j)$ mit $t_{i+r} < \xi_j$ oder $t_i > \xi_j$, so daß in jeder Zeile höchstens r Elemente von 0 verschieden sind. Die Elemente $B_i(\xi_j)$ der Matrix können wir mit dem oben angegebenen Algorithmus zur Bestimmung der B-Splines berechnen. Das Gleichungssystem (und damit die Interpolationsaufgabe) ist eindeutig lösbar, falls die Matrix A nichtsingulär ist. Dafür haben Schoenberg und Whitney (1953) ein einfaches Kriterium angegeben, das wir ohne Beweis zitieren:

(2.4.5.7) **Satz:** Die Matrix $A = (B_i(\xi_j))$ von (2.4.5.6) ist genau dann nicht-singulär, falls die Diagonalelemente von A nicht verschwinden, $B_i(\xi_i) \neq 0$ für $i = 1, 2, \dots, N$.

Man kann ferner zeigen [Karlin (1968)], daß die Matrix A total positiv in folgendem Sinne ist: alle $r \times r$ -Untermatrizen B von A der Form

$$B = (a_{i_p, j_q})_{p,q=1}^r \quad \text{mit } r \geq 1, \quad i_1 < i_2 < \dots < i_r, \quad j_1 < j_2 < \dots < j_r,$$

haben eine nichtnegative Determinante, $\det(B) \geq 0$. Falls A nichtsingulär ist, kann man deshalb zur Lösung von (2.4.5.6) die Gauss-Elimination ohne Pivotsuche (s. Abschnitt 4.1) anwenden [de Boor und Pinkus (1977)], wobei sich weitere Einsparungen ergeben, weil A Bandstruktur besitzt.

Bezüglich weiterer Eigenschaften von B-Splines, Anwendungen und Algorithmen sei auf die Literatur verwiesen, insbesondere auf de Boor (1978), wo man auch zahlreiche FORTRAN-Programme findet.

2.4.6 Multi-Resolutions-Verfahren und B-Splines

B-Splines spielen auch in *Multi-Resolutions-Verfahren* zur Approximation von reell- oder komplexwertigen $f : \mathbb{R} \rightarrow \mathbb{C}$ eine wichtige Rolle. Wir betrachten im folgenden nur quadratisch integrierbare Funktionen f , $\int_{-\infty}^{\infty} |f(x)|^2 dx < \infty$. Die Menge aller solcher Funktionen bildet bekanntlich einen euklidischen Vektorraum $L_2(\mathbb{R})$ bezüglich des Skalarprodukts

$$\langle f, g \rangle := \int_{-\infty}^{\infty} f(x) \overline{g(x)} dx$$

und der zugehörigen euklidischen Norm $\|f\| := \langle f, f \rangle^{1/2}$ (sie bildet sogar einen Hilbertraum). Mit ℓ_2 bezeichnen wir die Menge aller Folgen $(c_k)_{k \in \mathbb{Z}}$ komplexer Zahlen c_k mit $\sum_{k \in \mathbb{Z}} |c_k|^2 < \infty$.

Bei der Multi-Resolutions-Analyse (MRA) von Funktionen $f \in L_2(\mathbb{R})$ spielen abgeschlossene lineare Teilräume V_j , $j \in \mathbb{Z}$, von $L_2(\mathbb{R})$ mit folgenden Eigenschaften eine zentrale Rolle:

$$(S1) \quad V_j \subset V_{j+1}, \quad j \in \mathbb{Z},$$

$$(S2) \quad f(x) \in V_j \Leftrightarrow f(2x) \in V_{j+1}, \quad j \in \mathbb{Z},$$

$$(S3) \quad f(x) \in V_j \Leftrightarrow f(x + 2^{-j}) \in V_j, \quad j \in \mathbb{Z},$$

$$(S4) \quad \overline{\bigcup_{j \in \mathbb{Z}} V_j} = L_2(\mathbb{R}),$$

$$(S5) \quad \bigcap_{j \in \mathbb{Z}} V_j = \{0\}.$$

Solche Teilräume werden in der Regel durch eine Funktion $\Phi(x) \in L_2(\mathbb{R})$ auf folgende Weise erzeugt: Durch Translation und Dilatation von Φ gewinnt man zunächst die weiteren Funktionen

$$\Phi_{j,k}(x) := 2^{j/2} \Phi(2^j x - k), \quad j, k \in \mathbb{Z}.$$

Der Raum V_j wird dann als der abgeschlossene lineare Teilraum von $L_2(\mathbb{R})$ definiert, der von den $\Phi_{j,k}$, $k \in \mathbb{Z}$, erzeugt wird,

$$V_j := \overline{\text{span}\{\Phi_{j,k} \mid k \in \mathbb{Z}\}} = \overline{\left\{ \sum_{|k| \leq n} c_k \Phi_{j,k} \mid c_k \in \mathbb{C}, n \geq 0 \right\}}.$$

Offensichtlich sind dann (S2) und (S3) erfüllt.

(2.4.6.1) **Def.** Die Funktion $\Phi \in L_2(\mathbb{R})$ heißt Skalierungsfunktion, wenn die zugehörigen V_j die Bedingungen (S1) – (S5) erfüllen und überdies die $\Phi_{0,k}$, $k \in \mathbb{Z}$, eine sog. Riesz-Basis von V_0 bilden, d. h. falls es positive Konstanten $0 < A \leq B$ gibt mit

$$A \sum_{k \in \mathbb{Z}} |c_k|^2 \leq \left\| \sum_{k \in \mathbb{Z}} c_k \Phi_{0,k} \right\|^2 \leq B \sum_{k \in \mathbb{Z}} |c_k|^2$$

für alle Folgen $(c_k)_{k \in \mathbb{Z}} \in \ell_2$ (dann bilden auch die Funktionen $\Phi_{j,k}$, $k \in \mathbb{Z}$, für jedes $j \in \mathbb{Z}$ eine Riesz-Basis von V_j).

Ist Φ eine Skalierungsfunktion, läßt sich für jedes $j \in \mathbb{Z}$ jedes $f \in V_j$ als eine in $L_2(\mathbb{R})$ konvergente Reihe

$$(2.4.6.2) \quad f = \sum_{k \in \mathbb{Z}} c_{j,k} \Phi_{j,k}$$

mit eindeutig bestimmten Koeffizienten $c_{j,k}$, $k \in \mathbb{Z}$, mit $(c_{j,k})_{k \in \mathbb{Z}} \in \ell_2$ schreiben.

Ferner ist für eine Skalierungsfunktion Φ die Bedingung (S1) damit äquivalent, daß Φ einer sog. *Zwei-Stufen-Formel*

$$(2.4.6.3) \quad \Phi(x) = \sum_{k \in \mathbb{Z}} h_k \Phi_{1,k}(x) = \sqrt{2} \sum_{k \in \mathbb{Z}} h_k \Phi(2x - k)$$

mit Koeffizienten $(h_k) \in \ell_2$ genügt. Denn (2.4.6.3) ist mit $\Phi \in V_0 \subset V_1$ äquivalent. Damit gilt aber auch $V_j \subset V_{j+1}$ für jedes $j \in \mathbb{Z}$ wegen

$$\begin{aligned} \Phi_{j,l}(x) &= 2^{j/2} \Phi(2^j x - l) = 2^{j/2} \sqrt{2} \sum_{k \in \mathbb{Z}} h_k \Phi(2^{j+1} x - 2l - k) \\ &= \sum_{k \in \mathbb{Z}} h_k \Phi_{j+1,k+2l}(x). \end{aligned}$$

Beispiel: Ein besonders einfaches Beispiel einer Skalierungsfunktion ist die sog. *Haar-Funktion*

$$(2.4.6.4) \quad \Phi(x) := \begin{cases} 1, & \text{für } 0 \leq x < 1, \\ 0, & \text{sonst.} \end{cases}$$

Sie genügt der einfachen Zwei-Stufen-Formel

$$\Phi(x) = \Phi(2x) + \Phi(2x - 1).$$

Einige der $\Phi_{j,k}$ sind in Figur 3 abgebildet.




Fig. 3. Einige Derivate $\Phi_{j,k}$ der Haar-Funktion

Skalierungsfunktionen und die von ihnen erzeugten Räume V_j spielen in der modernen Signal- und Bildverarbeitung eine große Rolle: Jede Funktion $f \in V_j = \sum_k c_{j,k} \Phi_{j,k}$ kann als eine „gerasterte“ Funktion (z. B. ein abgetastetes Signal, oder, in zwei Dimensionen, ein gescanntes Bild) endlicher Auflösung aufgefaßt werden, bei der gerade noch Details der „Feinheit“ 2^{-j} aufgelöst sind (dies illustrieren z. B. die V_j , die zur Haar-Funktion gehören). In den Anwendungen will man häufig eine Funktion f „hoher Auflösung“ (d. h. ein $f \in V_j$ mit großem j) durch eine Funktion $\hat{f}$ geringerer Auflösung (d. h. ein $\hat{f} \in V_k$ mit $k < j$) ohne unnötige Genauigkeitsverluste approximieren. Dies ist das Ziel von *Multi-Resolutions-Verfahren*, deren Prinzipien wir in diesem Abschnitt beschreiben. Dazu wollen wir zunächst weitere Skalierungsfunktionen kennen lernen.

Die Haar-Funktion Φ ist der einfachste B-Spline der Ordnung $r = 1$ bezüglich der speziellen Folge $\mathbf{t} := (k)_{k \in \mathbb{Z}}$ aller ganzen Zahlen. Die Definition (2.4.4.3) zeigt nämlich

$$B_{0,1,\mathbf{t}}(x) = f_x^0[0, 1] = (1 - x)_+^0 - (0 - x)_+^0 = \Phi(x).$$

Gleichzeitig sieht man für alle $k \in \mathbb{Z}$

$$B_{k,1,\mathbf{t}}(x) = f_x^0[k, k + 1] = B_{0,1,\mathbf{t}}(x - k) = \Phi(x - k) = \Phi_{0,k}.$$

Dies legt es nahe, allgemein B-Splines

$$(2.4.6.5) \quad M_r(x) := B_{0,r,t}(x) = rf_x^{r-1}[0, 1, \dots, r]$$

beliebiger Ordnung $r \geq 1$ als Skalierungsfunktionen in Betracht zu ziehen, die ebenfalls sämtliche B-Splines

$$B_{k,r,t}(x) = rf_x^{r-1}[k, k+1, \dots, k+r], \quad k \in \mathbb{Z},$$

durch Translation erzeugen, $B_{k,r,t}(x) = B_{0,r,t}(x-k) = M_r(x-k)$. Nach Definition ist $M_r(x) = B_{0,r,t}(x)$ eine $r-2$ mal stetig differenzierbare Funktion. Mit wachsendem r werden also die Skalierungsfunktionen $\Phi := M_r$ immer glatter.

Beispiele. Für niedrige Ordnungen r findet man folgende B-Splines: $M_1(x)$ ist die Haar-Funktion (2.4.6.4) und für $r = 2, 3$ gilt:

$$M_2(x) = \begin{cases} x & \text{für } 0 \leq x \leq 1, \\ 2-x & \text{für } 1 \leq x \leq 2, \\ 0 & \text{sonst.} \end{cases}$$

$$M_3(x) = \frac{1}{2} \begin{cases} x^2 & \text{für } 0 \leq x \leq 1, \\ -2x^2 + 6x - 3 & \text{für } 1 \leq x \leq 2, \\ (3-x)^2 & \text{für } 2 \leq x \leq 3, \\ 0 & \text{sonst.} \end{cases}$$

Die translatierte Funktion $H(x) := M_2(x+1)$ von $M_2(x)$,

$$(2.4.6.6) \quad H(x) = \begin{cases} 1-|x| & \text{für } -1 \leq x \leq 1 \\ 0 & \text{sonst,} \end{cases}$$

ist unter dem Namen *Hut-Funktion* bekannt.

Diese Formeln sind Spezialfälle der folgenden allgemeinen Darstellung von $M_r(x)$ für beliebiges $r \geq 1$:

$$(2.4.6.7) \quad M_r(x) = \frac{1}{(r-1)!} \sum_{l=0}^r (-1)^l \binom{r}{l} (x-l)_+^{r-1}.$$

Man bestätigt diese Formel sofort durch vollständige Induktion nach k anhand der Rekursionsformel (2.1.3.5) für die dividierten Differenzen

$$f_x^{r-1}[i, i+1, \dots, i+k] = \frac{1}{k} \left(f_x^{r-1}[i+1, \dots, i+k] - f_x^{r-1}[i, \dots, i+k-1] \right),$$

wenn man $f_x^{r-1}(t) = (t-x)_+^{r-1}$ berücksichtigt.

Wir wollen deshalb die Eigenschaften der M_r als Skalierungsfunktionen näher studieren, uns aber dabei der Einfachheit halber auf B-Splines niedriger Ordnung beschränken (eine Behandlung des allgemeinen Falls findet man in Chui (1992)).

Im folgenden beschreiben wir Multi-Resolutions-Verfahren näher. Ein Ziel dieser Verfahren ist es, eine gegebene „hoch aufgelöste“ Funktion

$v_{j+1} \in V_{j+1}$ möglichst gut durch eine Funktion geringerer Auflösung zu approximieren, etwa durch ein $v_j \in V_j$ mit

$$\|v_{j+1} - v_j\| = \min_{v \in V_j} \|v_{j+1} - v\|.$$

Da dann $v_{j+1} - v_j$ orthogonal zu V_j ist, spielen in diesem Zusammenhang auch die Orthogonalräume W_j von V_j in V_{j+1} eine Rolle,

$$W_j := \{w \in V_{j+1} \mid \langle w, v \rangle = 0 \text{ für alle } v \in V_j\}, \quad j \in \mathbb{Z}.$$

Wir schreiben dann kurz $V_{j+1} = V_j \oplus W_j$, weil jedes $v_{j+1} \in V_{j+1}$ eine eindeutige Zerlegung $v_{j+1} = v_j + w_j$ in zueinander orthogonale Funktionen $v_j \in V_j$ und $w_j \in W_j$ besitzt.

Die Räume W_j sind untereinander orthogonal, $W_j \perp W_k$ für $j \neq k$ (d. h. $\langle v, w \rangle = 0$ für $v \in W_j$, $w \in W_k$). Dies folgt für $j < k$ sofort aus $W_j \subset V_{j+1} \subset V_k$ und $W_k \perp V_k$. Wegen (S4) und (S5) folgt weiter

$$L_2(\mathbb{R}) = \bigoplus_{j \in \mathbb{Z}} W_j = \cdots \oplus W_{-1} \oplus W_0 \oplus W_1 \oplus \cdots.$$

In Multi-Resolutions-Verfahren werden für ein gegebenes $v_{j+1} \in V_{j+1}$ für $m \leq j$ die Orthogonalzerlegungen $v_{m+1} = v_m + w_m$, $v_m \in V_m$, $w_m \in W_m$, entsprechend dem folgenden Schema berechnet:

$$(2.4.6.8) \quad \begin{array}{ccccccc} v_{j+1} & \rightarrow & v_j & \rightarrow & v_{j-1} & \rightarrow & \cdots \\ & \searrow & & \searrow & & \searrow & \\ & & w_j & & w_{j-1} & & \cdots \end{array}$$

Es ist dann $v_m \in V_m$ für $m \leq j$ die beste Approximation von v_{j+1} durch ein Element aus V_m ,

$$\|v_{j+1} - v_m\| = \min_{v \in V_m} \|v_{j+1} - v\|.$$

Denn die w_k sind untereinander orthogonal und es gilt $w_k \perp V_m$ für $k \geq m$. Für beliebiges $v \in V_m$ folgt daher wegen $v_m - v \in V_m$ und

$$v_{j+1} - v = w_j + w_{j-1} + \cdots + w_m + (v_m - v)$$

sofort

$$\|v_{j+1} - v\|^2 = \|w_j\|^2 + \cdots + \|w_m\|^2 + \|v_m - v\|^2 \geq \|v_{j+1} - v_m\|^2.$$

Bevor wir beschreiben, wie man für ein gegebenes $v_{j+1} \in V_{j+1}$ die Orthogonalzerlegung $v_{j+1} = v_j + w_j$ berechnet, benötigen wir das wichtige Hilfsmittel der *dualen Funktion* $\tilde{\Phi}$ der Skalierungsfunktion Φ . Sie besitzt die folgenden Eigenschaften:

$$(2.4.6.9) \quad \langle \Phi_{0,k}, \tilde{\Phi} \rangle = \int_{-\infty}^{\infty} \Phi(x-k) \overline{\tilde{\Phi}(x)} dx = \delta_{k,0}, \quad k \in \mathbb{Z}.$$

Mit ihrer Hilfe kann man die Koeffizienten c_k der Reihendarstellung (2.4.6.2) von $f = \sum_{l \in \mathbb{Z}} c_l \Phi_{0,l}$ einer Funktion $f \in V_0$ berechnen. Es gilt nämlich

$$\begin{aligned} \langle f(x), \tilde{\Phi}(x-k) \rangle &= \sum_l c_l \int_{-\infty}^{\infty} \Phi(x-l) \overline{\tilde{\Phi}(x-k)} dx \\ &= \sum_l c_l \int_{-\infty}^{\infty} \Phi(x-l+k) \overline{\tilde{\Phi}(x)} dx = c_k. \end{aligned}$$

Da für jedes $j \in \mathbb{Z}$ die Funktionen $\tilde{\Phi}_{j,k}(x) := 2^{j/2} \tilde{\Phi}(2^j x - k)$, $k \in \mathbb{Z}$, die Eigenschaften

$$\begin{aligned} \langle \Phi_{j,k}, \tilde{\Phi}_{j,l} \rangle &= 2^j \int_{-\infty}^{\infty} \Phi(2^j x - k) \overline{\tilde{\Phi}(2^j x - l)} dx \\ (2.4.6.10) \quad &= \int_{-\infty}^{\infty} \Phi(x - k + l) \overline{\tilde{\Phi}(x)} dx \\ &= \delta_{k-l,0}, \quad k, l \in \mathbb{Z}, \end{aligned}$$

besitzen, kann man mit Hilfe von $\tilde{\Phi}$ auch die Koeffizienten $c_{j,l}$ einer Funktion $f = \sum_{k \in \mathbb{Z}} c_{j,k} \Phi_{j,k}$ aus V_j berechnen:

$$(2.4.6.11) \quad \langle f, \tilde{\Phi}_{j,l} \rangle = \sum_k c_{j,k} \langle \Phi_{j,k}, \tilde{\Phi}_{j,l} \rangle = c_{j,l}.$$

Die Existenz dualer Funktionen ist durch folgenden Satz gesichert:

(2.4.6.12) **Satz:** *Zu jeder Skalierungsfunktion Φ existiert genau eine duale Funktion $\tilde{\Phi} \in V_0$.*

Beweis: Weil die $\Phi_{0,k}$, $k \in \mathbb{Z}$, eine Riesz-Basis von V_0 bilden, ist $\Phi_{0,0} = \Phi$ nicht in dem Teilraum

$$V := \overline{\text{span}\{\Phi_{0,k} \mid |k| \geq 1\}}$$

von V_0 enthalten. Es gibt also genau eine Funktion $g = \Phi - u \neq 0$ mit $u \in V$, so daß

$$\|g\| = \min\{\|\Phi - v\| \mid v \in V\}.$$

u ist die Orthogonalprojektion von Φ auf V , es ist daher $g \perp V$, d. h. $\langle v, g \rangle = 0$ für alle $v \in V$, also insbesondere

$$\langle \Phi_{0,k}, g \rangle = 0 \quad \text{für alle } |k| \geq 1,$$

sowie $0 < \|g\|^2 = \langle \Phi - u, \Phi - u \rangle = \langle \Phi - u, g \rangle = \langle \Phi, g \rangle$. Die Funktion $\tilde{\Phi} := g / \langle \Phi, g \rangle$ leistet das Verlangte. $\square$

Beispiel: Die Haar-Funktion (2.4.6.4) ist selbstdual, $\tilde{\Phi} = \Phi$. Dies folgt aus der Orthonormalitätseigenschaft $\langle \Phi, \Phi_{0,k} \rangle = \delta_{k,0}$, $k \in \mathbb{Z}$.

Mit Hilfe der dualen Funktion $\tilde{\Phi}$ kann man die beste Approximation $v_j \in V_j$ für ein gegebenes $v_{j+1} \in V_{j+1}$ berechnen. Wir nehmen dazu an, daß $v_{j+1} \in V_{j+1}$ durch seine Reihenentwicklung $v_{j+1} = \sum_{k \in \mathbb{Z}} c_{j+1,k} \Phi_{j+1,k}$ gegeben ist. Wegen $v_j \in V_j$ besitzt die gesuchte Funktion v_j die Form $v_j = \sum_{k \in \mathbb{Z}} c_{j,k} \Phi_{j,k}$. Die Koeffizienten $c_{j,k}$ sind so zu bestimmen, daß $v_{j+1} - v_j \perp V_j$ gilt, d. h.

$$\langle v_j, v \rangle = \langle v_{j+1}, v \rangle \quad \text{für alle } v \in V_j.$$

Nun gehören alle Funktionen $\tilde{\Phi}_{j,k}$, $k \in \mathbb{Z}$, wegen $\tilde{\Phi} \in V_0$ zu V_j , also gilt wegen (2.4.6.10)

$$\begin{aligned} c_{j,l} &= \langle v_j, \tilde{\Phi}_{j,l} \rangle = \langle v_{j+1}, \tilde{\Phi}_{j,l} \rangle \\ &= \sum_{k \in \mathbb{Z}} c_{j+1,k} \langle \Phi_{j+1,k}, \tilde{\Phi}_{j,l} \rangle \\ &= \sum_{k \in \mathbb{Z}} c_{j+1,k} 2^{j+1/2} \int_{-\infty}^{\infty} \Phi(2^{j+1}x - k) \overline{\tilde{\Phi}(2^jx - l)} dx \\ &= \sum_{k \in \mathbb{Z}} c_{j+1,k} \sqrt{2} \int_{-\infty}^{\infty} \Phi(2x + 2l - k) \overline{\tilde{\Phi}(x)} dx. \end{aligned}$$

Dies führt zu folgendem Verfahren zur Bestimmung der $c_{j,k}$ aus den $c_{j+1,k}$: Als erstes berechnet man die (von j unabhängigen) Zahlen

$$(2.4.6.13) \quad \gamma_i := \sqrt{2} \int_{-\infty}^{\infty} \Phi(2x + i) \overline{\tilde{\Phi}(x)} dx, \quad i \in \mathbb{Z}.$$

Die Koeffizienten $c_{j,l}$ erhält man dann mittels der Formel

$$(2.4.6.14) \quad c_{j,l} = \sum_{k \in \mathbb{Z}} c_{j+1,k} \gamma_{2l-k}, \quad l \in \mathbb{Z}.$$

Beispiel: Für die Haar-Funktion sind wegen $\tilde{\Phi} = \Phi$ die γ_i gegeben durch

$$\gamma_i := \begin{cases} 1/\sqrt{2} & \text{für } i = 0, -1, \\ 0 & \text{sonst.} \end{cases}$$

Wegen der Kompaktheit des Trägers von Φ sind nur endlich viele der γ_i von 0 verschieden, so daß auch die Summen (2.4.6.14) in diesem Fall endlich sind:

$$c_{j,l} = \frac{1}{\sqrt{2}} (c_{j+1,2l} + c_{j+1,2l+1}), \quad l \in \mathbb{Z}.$$

Da die Summen in (2.4.6.14) i. allg. unendliche Summen sind, die man durch endliche Summen (Abbruch nach endlich vielen Gliedern) approximiert, hängt die Effizienz des Verfahrens davon ab, wie schnell die Zahlen γ_i für $|i| \rightarrow \infty$ gegen 0 konvergieren.

Man kann das Verfahren entsprechend dem Schema (2.4.6.8) wiederholen. Man beachte dabei, daß man die γ_i nur einmal berechnen muß, weil sie von j unabhängig sind. Man erhält so folgendes Multi-Resolutions-Verfahren zur Bestimmung der Koeffizienten $c_{m,k}$, $k \in \mathbb{Z}$, von $v_m = \sum_{k \in \mathbb{Z}} c_{m,k} \Phi_{m,k}$ für alle $m \leq j$:

(2.4.6.15) **Algorithmus:**

Gegeben: $c_{j+1,k}$, $k \in \mathbb{Z}$, und γ_i , $i \in \mathbb{Z}$, s. (2.4.6.13).

Für $m = j, j-1, \dots$

für $l \in \mathbb{Z}$

$$c_{m,l} := \sum_{k \in \mathbb{Z}} c_{m+1,k} \gamma_{2l-k}.$$

Wir haben gesehen, daß bei der Haar-Funktion als Skalierungsfunktion besonders einfache Verhältnisse vorliegen.

Wir betrachten nun Skalierungsfunktionen, die durch B-Splines höherer Ordnung geliefert werden, $\Phi(x) = \Phi_r(x) := M_r(x)$, $r > 1$. Der Einfachheit halber behandeln wir nur den hinreichend typischen Fall $r = 2$. Da die Funktion $M_2(x)$ und die Hut-Funktion $H(x) = M_2(x+1)$ als Skalierungsfunktionen die gleichen Räume V_j , $j \in \mathbb{Z}$, erzeugen, genügt die Untersuchung von $\Phi(x) := H(x)$.

Wir zeigen als erstes die Eigenschaft (S1), $V_j \subset V_{j+1}$, für die linearen Räume, die von $\Phi(x) = H(x)$ und den zugehörigen Funktionen $\Phi_{j,k}(x) = 2^{j/2} \Phi(2^j x - k)$, $j, k \in \mathbb{Z}$, erzeugt werden. Dies folgt sofort aus der Zwei-Stufen-Formel für $H(x)$,

$$H(x) = \frac{1}{2} (H(2x+1) + 2H(2x) + H(2x-1)),$$

die man anhand der Definition von $H(x)$ (2.4.6.6) bestätigt. Der Nachweis, daß $H(x)$ auch die übrigen Eigenschaften einer Skalierungsfunktion erfüllt, sei dem Leser überlassen (s. Übungsaufgabe 32).

Die Funktionen $f \in V_j$ haben eine anschauliche Bedeutung: Sie sind auf $\mathbb{R}$ stetige Funktionen, die bezüglich der Intervallunterteilung (ein Raster der Feinheit 2^{-j})

$$(2.4.6.16) \quad \Delta^j := \{k \cdot 2^{-j} \mid k \in \mathbb{Z}\}$$

der reellen Zahlen stückweise linear sind. Die Koeffizienten $c_{j,k}$ ihrer Darstellung $f = \sum_{k \in \mathbb{Z}} c_{j,k} \Phi_{j,k}$ sind bis auf einen Faktor durch die Funktionswerte von f auf Δ^j gegeben:

$$(2.4.6.17) \quad c_{j,k} = 2^{-j/2} f(k \cdot 2^{-j}), \quad k \in \mathbb{Z}.$$

Leider bilden die Funktionen $\Phi_{0,k}(x) = H(x - k)$, $k \in \mathbb{Z}$, kein Orthogonalsystem: Durch Ausrechnen findet man

$$(2.4.6.18) \quad \int_{-\infty}^{\infty} H(x - j)H(x) dx = \begin{cases} 2/3 & \text{für } j = 0, \\ 1/6 & \text{für } |j| = 1, \\ 0 & \text{sonst,} \end{cases}$$

so daß

$$\langle \Phi_{0,k}, \Phi_{0,l} \rangle = \int_{-\infty}^{\infty} H(x - k + l)H(x) dx = \begin{cases} 2/3 & \text{für } k = l, \\ 1/6 & \text{für } |k - l| = 1, \\ 0 & \text{sonst.} \end{cases}$$

Die duale Funktion $\tilde{H}$ ist also von H verschieden, wir wollen sie berechnen. Nach dem Beweis von Satz (2.4.6.12) ist $\tilde{H}$ ein skalares Vielfaches der Funktion

$$g(x) = H(x) - \sum_{|k| \geq 1} a_k H(x - k),$$

wobei die Folge $(a_k)_{|k| \geq 1}$ die eindeutig bestimmte Lösung der folgenden Gleichungen mit $\sum_k |a_k|^2 < \infty$ ist:

$$\langle g, \Phi_{0,k} \rangle = \langle H(x) - \sum_{|l| \geq 1} a_l H(x - l), H(x - k) \rangle = 0 \quad \text{für alle } |k| \geq 1.$$

Wegen (2.4.6.18) führt dies für $k \geq 1$ auf die Gleichungen

$$(2.4.6.19) \quad \begin{aligned} 4a_1 + a_2 &= 1, & (k = 1), \\ a_{k-1} + 4a_k + a_{k+1} &= 0, & (k \geq 2), \end{aligned}$$

und für $k \leq -1$ auf

$$\begin{aligned} 4a_{-1} + a_{-2} &= 1, & (k = -1), \\ a_{k-1} + 4a_k + a_{k+1} &= 0, & (k \leq -2). \end{aligned}$$

Man sieht, daß mit der Folge (a_k) auch die Folge (a_{-k}) Lösung dieser Gleichungen ist, so daß wegen der Eindeutigkeit der Lösung $a_k = a_{-k}$ für alle $|k| \geq 1$ gilt. Es genügt deshalb, die Lösung a_k , $k \geq 1$, der Gleichungen (2.4.6.19) zu bestimmen.

Nach diesen Gleichungen ist die Folge $(a_k)_{k \geq 1}$, Lösung der homogenen linearen Differenzengleichung

$$c_{k-1} + 4c_k + c_{k+1} = 0, \quad k = 2, 3, \dots$$

Durch Einsetzen bestätigt man, daß die Folge $c_k := \theta^k$, $k \geq 1$, eine Lösung dieser Gleichungen ist, wenn θ eine Nullstelle des Polynoms $x^2 + 4x + 1 = 0$ ist. Nun besitzt dieses Polynom die beiden Nullstellen

$$\lambda := -2 + \sqrt{3} = \frac{-1}{2 + \sqrt{3}}, \quad \mu := -2 - \sqrt{3} = 1/\lambda$$

mit $|\lambda| < 1 < |\mu|$. Die allgemeine Lösung der Differenzengleichung ist eine beliebige Linearkombination der speziellen Lösungen $(\lambda^k)_{k \geq 1}$ und $(\mu^k)_{k \geq 1}$, d. h. die gesuchten a_k haben die Form $a_k = C\lambda^k + D\mu^k$, $k \geq 1$, mit geeignet zu wählenden Konstanten C, D . Da $\sum_k |a_k|^2 < \infty$ gelten muß, folgt $D = 0$ wegen $|\mu| > 1$. Die Konstante C ist so zu wählen, daß auch die erste Gleichung (2.4.6.19), $4a_1 + a_2 = 1$, erfüllt ist, d. h.

$$1 = C\lambda(4 + \lambda) = C\lambda(2 + \sqrt{3}) = -C.$$

Also ist $a_k = a_{-k} = -\lambda^k = -(-1)^k(2 + \sqrt{3})^{-k}$ für $k \geq 1$ und daher

$$g(x) = H(x) + \sum_{k \geq 1} (-1)^k (2 + \sqrt{3})^{-k} (H(x+k) + H(x-k)).$$

Die gesuchte duale Funktion $\tilde{H}(x) = \gamma g(x)$ ist ein skalares Vielfaches von g , wobei γ so zu wählen ist, daß $\langle H, \tilde{H} \rangle = 1$ gilt. Diese Bedingung führt wegen (2.4.6.18) auf

$$\begin{aligned} \frac{1}{\gamma} &= \langle H, H \rangle - (2 + \sqrt{3})^{-1} (\langle H(x), H(x-1) \rangle + \langle H(x), H(x+1) \rangle) \\ &= \frac{2}{3} - \frac{1}{3(2 + \sqrt{3})} = \frac{1}{\sqrt{3}}. \end{aligned}$$

Die duale Funktion $\tilde{H}(x)$ ist also durch die Reihenentwicklung

$$\tilde{H}(x) = \sum_{k \in \mathbb{Z}} b_k H(x-k)$$

mit den Koeffizienten

$$b_k := \frac{(-1)^k \sqrt{3}}{(2 + \sqrt{3})^{|k|}}, \quad k \in \mathbb{Z},$$

gegeben. Die Berechnung der Zahlen γ_i (2.4.6.13) für das Multi-Resolutionsverfahren (2.4.6.15) führt auf einfache endliche Summen mit bekannten Termen

$$\begin{aligned} \gamma_i &= \sqrt{2} \langle H(2x+i), \tilde{H}(x) \rangle \\ &= \sqrt{2} \sum_{k \in \mathbb{Z}} b_k \langle H(2x+i), H(x-k) \rangle \\ (2.4.6.20) \quad &= \sqrt{2} \sum_{k \in \mathbb{Z}} b_k \langle H(2x+i+2k), H(x) \rangle \\ &= \sqrt{2} \sum_{k: |2k+i| \leq 2} b_k \langle H(2x+i+2k), H(x) \rangle. \end{aligned}$$

Eine elementare Rechnung zeigt nämlich

$$\langle H(2x + j), H(x) \rangle = \begin{cases} 5/12 & \text{für } j = 0, \\ 1/4 & \text{für } |j| = 1, \\ 1/24 & \text{für } |j| = 2, \\ 0 & \text{sonst.} \end{cases}$$

Wegen $2 + \sqrt{3} = 3.73 \dots$ konvergieren die Zahlen $b_k = O((2 + \sqrt{3})^{-|k|})$ und deshalb auch die Zahlen γ_k für $|k| \rightarrow \infty$ einigermaßen rasch gegen 0. Die Summen (2.4.6.14) des Multi-Resolutions-Verfahrens kann man deshalb noch recht gut durch nicht zu große endliche Summen approximieren.

Beispiel: Für kleines i findet man folgende Werte der γ_i :

i	γ_i
0	0.96592 58262
1	0.44828 77361
2	-0.16408 46996
3	-0.12011 83369
4	0.04396 63628
5	0.03218 56114
6	-0.01178 07514
7	-0.00862 41086
8	0.00315 66428
9	0.00231 08229
10	-0.00084 58199

Übrigens gilt $\gamma_{-i} = \gamma_i$ für alle $i \in \mathbb{Z}$ (s. Übungsaufgabe 33).

Das Multi-Resolutions-Verfahren kann einfach interpretiert werden: Eine Funktion $f = \sum_{k \in \mathbb{Z}} c_{j+1,k} \Phi_{j+1,k} \in V_{j+1}$, also eine stetige Funktion, die bzgl. der Intervallunterteilung $\Delta^{j+1} = \{k \cdot 2^{-(j+1)} \mid k \in \mathbb{Z}\}$ stückweise linear ist, mit (s. (2.4.6.17))

$$c_{j+1,k} = 2^{-(j+1)/2} f(k \cdot 2^{-(j+1)}), \quad k \in \mathbb{Z},$$

wird durch eine stetige Funktion $\hat{f} = \sum_{k \in \mathbb{Z}} c_{j,k} \Phi_{j,k}$, die bzgl. des größeren Rasters $\Delta^j = \{l \cdot 2^{-j} \mid l \in \mathbb{Z}\}$ stückweise linear ist, optimal approximiert, wenn man für $l \in \mathbb{Z}$ setzt

$$\begin{aligned} \hat{f}(l \cdot 2^{-j}) &= 2^{j/2} c_{j,l} = 2^{j/2} \sum_{k \in \mathbb{Z}} c_{j+1,k} \gamma_{2l-k} \\ &= \frac{1}{\sqrt{2}} \sum_{k \in \mathbb{Z}} \gamma_{2l-k} f(k \cdot 2^{-(j+1)}). \end{aligned}$$

Die Zahlen γ_i haben deshalb folgende anschauliche Bedeutung: Die stetige und bzgl. des Rasters $\Delta^0 = \{l \mid l \in \mathbb{Z}\}$ stückweise lineare Funktion $\hat{f}(x)$ mit $\hat{f}(l) :=$

$\gamma_{2l}/\sqrt{2}$, $l \in \mathbb{Z}$, ist die optimale Approximation in V_0 an die gestauchte Hutfunktion $f(x) := H(2x) \in V_1$. Die verschobene Funktion $f_1(x) := H(2x - 1) \in V_1$ wird durch die Funktion $\hat{f}_1 \in V_0$ mit $\hat{f}_1(l) := \gamma_{2l-1}/\sqrt{2}$, $l \in \mathbb{Z}$, optimal approximiert (s. Figur 4).




Fig. 4. Die Funktionen f und $\hat{f}$

Wir kehren zu allgemeinen Skalierungsfunktionen zurück. Im Rahmen des Multi-Resolutions-Verfahrens haben wir wesentlich verwandt, daß die Räume V_j die Funktionen $\Phi_{j,k}$, $k \in \mathbb{Z}$, als Riesz-Basis besitzen. Genau so wichtig ist es, daß auch die Orthogonalräume W_j der V_j in V_{j+1} ähnlich einfache Riesz-Basen besitzen: Man kann zeigen (Beweise findet man z. B. in Daubechies (1992), Louis et al. (1994)), daß es zu jeder Skalierungsfunktion Φ , die die Räume V_j einer MRA erzeugt, eine Funktion $\Psi \in W_0$ mit folgenden Eigenschaften gibt:

a) Die Funktionen $\Psi_{0,k}(x) := \Psi(x - k)$, $k \in \mathbb{Z}$, bilden eine Riesz-Basis (s. (2.4.6.1)) von W_0 ; also sind für jedes $j \in \mathbb{Z}$ die Funktionen $\Psi_{j,k}(x) := 2^{j/2}\Psi(2^j x - k)$, $k \in \mathbb{Z}$, eine Riesz-Basis von W_j .

b) Alle $\Psi_{j,k}$, $j, k \in \mathbb{Z}$, bilden eine Riesz-Basis von $L_2(\mathbb{R})$.

Jede Funktion mit diesen Eigenschaften heißt ein *Wavelet* zur Skalierungsfunktion Φ (Wavelets sind nicht eindeutig durch Φ bestimmt). Ψ heißt *orthonormales Wavelet*, wenn die $\Psi_{0,k}$, $k \in \mathbb{Z}$, eine Orthonormalbasis von W_0 bilden, $\langle \Psi_{0,k}, \Psi_{0,l} \rangle = \delta_{k,l}$. Dann bilden alle $\Psi_{j,k}$, $j, k \in \mathbb{Z}$, eine Orthonormalbasis von $L_2(\mathbb{R})$,

$$\langle \Psi_{j,k}, \Psi_{l,m} \rangle = \delta_{j,l} \delta_{k,m}.$$

Beispiel: Zur Haar-Funktion Φ (2.4.6.4) gehört das *Haar-Wavelet*

$$\Psi(x) := \begin{cases} 1, & \text{für } 0 \leq x < 1/2, \\ -1, & \text{für } 1/2 \leq x < 1, \\ 0, & \text{sonst.} \end{cases}$$

Aus $\Psi(x) = \Phi(2x) - \Phi(2x - 1)$ folgt nämlich zunächst $\Psi_{0,k} \in V_1$ für alle $k \in \mathbb{Z}$; aus der Orthogonalitätseigenschaft

$$\langle \Psi_{0,k}, \Phi_{0,l} \rangle = 0 \quad \text{für alle } k, l \in \mathbb{Z}$$

folgt weiter $\Psi_{0,k} \in W_0$ für alle $k \in \mathbb{Z}$. Schließlich liefert

$$\Phi_{1,k}(x) = \frac{1}{\sqrt{2}}(\Phi_{0,k}(x) + \Psi_{0,k}(x)), \quad k \in \mathbb{Z},$$

die Gleichung $V_1 = V_0 \oplus W_0$. Wegen $\langle \Psi, \Psi_{0,k} \rangle = \delta_{k,0}$ ist das Haar-Wavelet orthonormal.

Man kann zeigen, daß jede orthonormale Skalierungsfunktion Φ ein orthonormales Wavelet besitzt, das man sogar mit Hilfe der Zwei-Stufen-Formel von Φ explizit angeben kann (s. die angegebene Literatur). Für nichtorthonormales Φ ist es aber im allgemeinen sehr schwierig, ein zugehöriges Wavelet zu bestimmen. Für die Skalierungsfunktionen $\Phi = \Phi_r := M_r$, die durch B-Splines gegeben werden, ist die Situation besser. Hier kennt man sogar Formeln für die speziellen Wavelets Ψ_r , die unter allen Wavelets einen minimalen kompakten Träger (nämlich das Intervall $[0, 2r - 1]$) besitzen: Sie lassen sich als eine endliche Summe der Form

$$\Psi_r(x) = \sum_{k=0}^{3r-2} q_k M_r(2x - k)$$

schreiben. Diese Wavelets sind für $r > 1$ sicher nicht orthonormal, man kennt aber die zugehörigen dualen Funktionen $\tilde{\Psi}_r \in W_0$ mit den üblichen Eigenschaften $\langle \Psi_r(x - k), \tilde{\Psi}_r(x) \rangle = \delta_{k,0}$ für $k \in \mathbb{Z}$ (s. Chui (1992) für eine zusammenfassende Darstellung).

Das Beispiel der Haar-Funktion zeigt, wie einfach die Verhältnisse werden, wenn die Skalierungsfunktion Φ und das Wavelet Ψ orthonormal sind und beide Funktionen einen kompakten Träger besitzen. Nachteil der Haar-Funktion ist ihre fehlende Glattheit. Andererseits wächst für die B-Splines M_r mit r die Glattheit der Skalierungsfunktion $\Phi_r = M_r$ und der zugehörigen Wavelets Ψ_r . Ferner haben sowohl Φ_r als auch die oben angegebenen zugehörigen Wavelets Ψ_r für alle $r \geq 1$ kompakte Träger, aber leider sind weder Φ_r noch Ψ_r für $r > 1$ orthonormal.

Umso bemerkenswerter ist ein tiefes Resultat von Daubechies: Sie gab erstmals Skalierungsfunktionen und zugehörige Wavelets beliebig hoher Differenzierbarkeitsordnung an, die orthonormal sind und kompakte Träger

besitzen. Für eine eingehende Darstellung dieser wichtigen Resultate und ihrer Anwendungen sei auf die einschlägige Literatur verwiesen, z.B. auf Louis et al. (1994), Mallat (1997), und insbesondere auf Daubechies (1992).

Übungsaufgaben zu Kapitel 2

1. Zu den verschiedenen Stützstellen $x_0, \dots, x_n$ seien $L_i(x)$ die Lagrange-Polynome aus (2.1.1.3) und $c_i := L_i(0)$. Man zeige:

$$\sum_{i=0}^n c_i x_i^j = \begin{cases} 1 & \text{für } j = 0, \\ 0 & \text{für } j = 1, 2, \dots, n, \\ (-1)^n x_0 x_1 \dots x_n & \text{für } j = n + 1, \end{cases}$$

$$\sum_{i=0}^n L_i(x) \equiv 1.$$

2. Die Funktion $\ln(x)$ werde quadratisch interpoliert, Stützstellen seien $x = 10, 11, 12$.
 - a) Man schätze den Interpolationsfehler für $x = 11.1$ ab!
 - b) Wie hängt das Vorzeichen dieses Fehlers von x ab?
3. Die auf $I = [-1, 1]$ zweimal stetig differenzierbare Funktion f werde durch ein lineares Polynom an den Stellen $(x_i, f(x_i))$, $i = 0, 1$, mit $x_0, x_1 \in I$ interpoliert. Dann ist

$$\alpha = \frac{1}{2} \max_{\xi \in I} |f''(\xi)| \max_{x \in I} |(x - x_0)(x - x_1)|$$

eine obere Schranke für den absoluten Interpolationsfehler auf I . Wie hat man x_0, x_1 zu wählen, damit α möglichst klein wird? Welcher Zusammenhang besteht zwischen $(x - x_0)(x - x_1)$ und $\cos(2 \arccos x)$?

4. Eine Funktion $f(x)$ werde auf dem Intervall $[a, b]$ durch ein Polynom $P_n(x)$ höchstens n -ten Grades interpoliert, Stützstellen seien $x_0, \dots, x_n$ mit $a \leq x_0 < x_1 < \dots < x_n \leq b$. f sei auf $[a, b]$ beliebig oft differenzierbar und es gelte $|f^{(i)}(x)| \leq M$ für $i = 0, 1, \dots$ und alle $x \in [a, b]$. Konvergiert $P_n(x)$ für $n \rightarrow \infty$ (ohne weitere Voraussetzung über die Lage der Stützstellen) gleichmäßig auf $[a, b]$ gegen $f(x)$?
5. a) Die Besselsche Funktion nullter Ordnung

$$J_0(x) = \frac{1}{\pi} \int_0^\pi \cos(x \sin t) dt$$

soll an äquidistanten Stellen $x_i = x_0 + ih$, $i = 0, 1, 2, \dots$ tabelliert werden. Welche Schrittweite h ist zu wählen, wenn bei linearer Interpolation mit Hilfe dieser Tafel der Interpolationsfehler kleiner als 10^{-6} ausfallen soll?

- b) Wie verhält sich der Interpolationsfehler

$$\max_{0 \leq x \leq 1} |P_n(x) - J_0(x)|$$

für $n \rightarrow \infty$, wenn $P_n \in \Pi_n$ die Funktion $J_0(x)$ an den Stellen $x = x_i^{(n)} := i/n$, $i = 0, 1, \dots, n$, interpoliert.

Hinweis: Es genügt $|J_0^{(k)}(x)| \leq 1$ für $k = 0, 1, \dots$ zu zeigen.

- c) Man vergleiche dieses Resultat mit dem Verhalten des Fehlers

$$\max_{0 \leq x \leq 1} |S_{t_n}(x) - J_0(x)|$$

für $n \rightarrow \infty$, wo S_{t_n} die interpolierende Splinefunktion zur Zerlegung $t_n = \{x_i^{(n)}\}$ von $[0, 1]$ mit $S'_{t_n}(x) = J'_0(x)$ für $x = 0, 1$ bezeichnet.

6. *Interpolation auf Produktträumen:* Für die Funktionen $\varphi_0, \varphi_1, \dots, \varphi_n$ sei jedes lineare Interpolationsproblem eindeutig lösbar, d. h. zu gegebenen Abszissen $x_0, \dots, x_n$, mit $x_i \neq x_j$, $i \neq j$, und Stützwerten $f_0, \dots, f_n$, existiere eindeutig eine Linearkombination

$$\Phi(x) = \sum_{i=0}^n \alpha_i \varphi_i(x)$$

mit $\Phi(x_k) = f_k$, $k = 0, \dots, n$. Man zeige: Ist auch für die Funktionen $\psi_0, \dots, \psi_m$ jedes lineare Interpolationsproblem eindeutig lösbar, so existiert für jede Wahl von Abszissen

$$\begin{aligned} x_0, x_1, \dots, x_n, & \quad x_i \neq x_j, \quad i \neq j, \\ y_0, y_1, \dots, y_m, & \quad y_i \neq y_j, \quad i \neq j, \end{aligned}$$

und Stützwerten

$$f_{ik}, \quad i = 0, \dots, n, \quad k = 0, \dots, m,$$

eindeutig eine Funktion der Form

$$\Phi(x, y) = \sum_{v=0}^n \sum_{\mu=0}^m \alpha_{v\mu} \varphi_v(x) \psi_\mu(y)$$

mit $\Phi(x_i, y_k) = f_{ik}$, $i = 0, \dots, n$, $k = 0, \dots, m$.

7. Welche Aussage folgt daraus im Spezialfall der Polynominterpolation? Man stelle $\Phi(x, y)$ in diesem Fall explizit dar.
8. Gegeben seien die Abszissen

$$y_0, y_1, \dots, y_m, \quad y_i \neq y_j, \quad i \neq j,$$

sowie für $k = 0, \dots, m$ die Zahlen

$$x_0^{(k)}, x_1^{(k)}, \dots, x_{n_k}^{(k)}, \quad x_i^{(k)} \neq x_j^{(k)}, \quad i \neq j,$$

und die Stützwerte

$$f_{ik}, \quad i = 0, \dots, n_k, \quad k = 0, \dots, m.$$

O. E. d. A. seien die y_k bereits so numeriert, daß gilt

$$n_0 \geq n_1 \geq \dots \geq n_m.$$

Man zeige durch Induktion über m , daß es genau ein Polynom

$$P(x, y) \equiv \sum_{\mu=0}^m \sum_{\nu=0}^{n_\mu} \alpha_{\nu\mu} x^\nu y^\mu$$

gibt mit der Eigenschaft

$$P(x_i^{(k)}, y_k) = f_{ik}, \quad i = 0, \dots, n_k, \quad k = 0, \dots, m.$$

9. Kann das Interpolationsproblem in Aufgabe 8 auch durch andere Polynome

$$P(x, y) = \sum_{\mu=0}^M \sum_{\nu=0}^{N_\mu} \alpha_{\nu\mu} x^\nu y^\mu$$

gelöst werden, für die lediglich die Anzahl der Parameter $\alpha_{\nu\mu}$ mit der Anzahl der Stützpunkte übereinstimmt, d. h.

$$\sum_{\mu=0}^m (n_\mu + 1) = \sum_{\mu=0}^M (N_\mu + 1) ?$$

Hinweis: Man untersuche einfache Beispiele.

10. Man berechne für die Stützpunkte

$$\begin{array}{cccccc} x_i : & 0 & 1 & -1 & 2 & -2 \\ f_i : & 1 & 3 & 3/5 & 3 & 3/5 \end{array}$$

die inversen oder reziproken Differenzen und bestimme damit den rationalen Ausdruck $\Phi^{2,2}(x)$ (mit quadratischem Zähler und Nenner) mit $\Phi^{2,2}(x_i) = f_i$ in der Form eines Kettenbruches. Man gebe auch das Zähler- und das Nennerpolynom an.

11. $\Phi^{m,n}$ sei die rationale Funktion, die für gegebene Stützpunkte (x_k, f_k) , $k = 0, 1, \dots, m+n$, Lösung des Systems $S^{m,n}$ ist:

$$(a_0 + a_1 x_k + \dots + a_m x_k^m) - f_k (b_0 + b_1 x_k + \dots + b_n x_k^n) = 0, \\ k = 0, 1, \dots, m+n.$$

Man zeige, daß sich $\Phi^{m,n}(x)$ durch Determinanten darstellen läßt:

$$\Phi^{m,n}(x) = \frac{|f_k, x_k - x, \dots, (x_k - x)^m, (x_k - x) f_k, \dots, (x_k - x)^n f_k|_{k=0}^{m+n}}{|1, x_k - x, \dots, (x_k - x)^m, (x_k - x) f_k, \dots, (x_k - x)^n f_k|_{k=0}^{m+n}}$$

Dabei steht $|\alpha_k, \dots, \zeta_k|_{k=0}^{m+n}$ zur Abkürzung für

$$\det \begin{bmatrix} \alpha_0 & \cdot & \cdot & \cdot & \zeta_0 \\ \alpha_1 & \cdot & \cdot & \cdot & \zeta_1 \\ \cdot & & & & \cdot \\ \cdot & & & & \cdot \\ \alpha_{m+n} & \cdot & \cdot & \cdot & \zeta_{m+n} \end{bmatrix}.$$

12. Man verallgemeinere Satz (2.3.1.12):

a) Zu $2n + 1$ Stützstellen x_k mit

$$a \leq x_0 < x_1 < \cdots < x_{2n} < a + 2\pi$$

und Stützwerten $y_0, \dots, y_{2n}$ existiert eindeutig ein trigonometrisches Polynom

$$T(x) = \frac{1}{2}a_0 + \sum_{j=1}^n (a_j \cos jx + b_j \sin jx)$$

mit $T(x_k) = y_k$ für $k = 0, 1, \dots, 2n$.

b) Sind $y_0, \dots, y_{2n}$ reell, dann auch die Koeffizienten a_j, b_j .

Hinweis: Man führe a) durch eine Umformung $T(x) = \sum_{j=-n}^n c_j e^{ijx}$ auf die (komplexe) Polynominterpolation zurück. Für b) ist $c_{-j} = \bar{c}_j$ zu zeigen.

13. a) Man zeige, daß für reelle $x_1, \dots, x_{2n}$ die Funktion

$$t(x) = \prod_{k=1}^{2n} \sin \frac{x - x_k}{2}$$

ein trigonometrisches Polynom der Form

$$\frac{1}{2}a_0 + \sum_{j=1}^n (a_j \cos jx + b_j \sin jx)$$

mit reellen, a_j, b_j ist.

Hinweis: Man verwende $\sin \varphi = (1/2i)(e^{i\varphi} - e^{-i\varphi})$.

b) Man zeige mit Hilfe von a), daß das interpolierende trigonometrische Polynom zu den Stützstellen x_k

$$0 \leq x_0 < x_1 < \cdots < x_{2n} < 2\pi$$

und den Stützwerten $y_0, \dots, y_{2n}$ identisch mit

$$T(x) = \sum_{j=0}^{2n} y_j t_j(x)$$

ist, wobei

$$t_j(x) := \prod_{\substack{k=0 \\ k \neq j}}^{2n} \sin \frac{x - x_k}{2} \bigg/ \prod_{\substack{k=0 \\ k \neq j}}^{2n} \sin \frac{x_j - x_k}{2}.$$

14. Man zeige, daß zu $n + 1$ Stützstellen x_k mit

$$a \leq x_0 < x_1 < \dots < x_n < a + \pi$$

und Werten $y_0, \dots, y_n$ eindeutig ein „Cosinus-Polynom“

$$C(x) = \sum_{j=0}^n a_j \cos jx$$

existiert mit

$$C(x_k) = y_k, \quad k = 0, 1, \dots, n.$$

Hinweis: s. Aufgabe 12.

15. a) Man zeige für ganzes j und $x_k := 2\pi k/(2m + 1)$, $k = 0, 1, \dots, 2m$,

$$\sum_{k=0}^{2m} \cos jx_k = (2m + 1) h(j), \quad \sum_{k=0}^{2m} \sin jx_k = 0.$$

Dabei ist

$$h(j) := \begin{cases} 1 & \text{für } j = 0 \bmod 2m + 1, \\ 0 & \text{sonst.} \end{cases}$$

- b) Man leite damit für ganzzahlige j, k folgende Orthogonalitätsrelationen her:

$$\sum_{i=0}^{2m} \sin jx_i \sin kx_i = \frac{2m+1}{2} [h(j-k) - h(j+k)],$$

$$\sum_{i=0}^{2m} \cos jx_i \cos kx_i = \frac{2m+1}{2} [h(j-k) + h(j+k)],$$

$$\sum_{i=0}^{2m} \cos jx_i \sin kx_i = 0.$$

16. Die Funktion $f: \mathbb{R} \rightarrow \mathbb{R}$ mit der Periode 2π besitze eine absolut konvergente Fourierreihe

$$f(x) = \frac{1}{2}a_0 + \sum_{j=1}^{\infty} (a_j \cos jx + b_j \sin jx).$$

Für den trigonometrischen Ausdruck

$$\Psi(x) = \frac{1}{2}A_0 + \sum_{j=1}^m (A_j \cos jx + B_j \sin jx)$$

gelte für $k = 0, 1, \dots, 2m$

$$\Psi(x_k) = f(x_k) \text{ mit } x_k = \frac{2\pi k}{2m+1}.$$

Man zeige:

$$A_k = a_k + \sum_{p=1}^{\infty} [a_{p(2m+1)+k} + a_{p(2m+1)-k}], \quad 0 \leq k \leq m,$$

$$B_k = b_k + \sum_{p=1}^{\infty} [b_{p(2m+1)+k} - b_{p(2m+1)-k}], \quad 1 \leq k \leq m.$$

17. Man gebe eine Cooley-Tukey Methode für den Fall an, daß der Vektor $\tilde{\beta}[\cdot]$ mit $\tilde{\beta}[j] = f_j$ für alle j initiiert wird.

Hinweis: Man bestimme die Abbildung $\sigma = \sigma(m, r, j)$ mit (2.3.2.7) und $\sigma(0, r, 0) = r$ statt (2.3.2.8).

18. Für $N = 2^n$ betrachte man die Vektoren

$$f := [f_0, \dots, f_{N-1}]^T, \quad \beta = [\beta_0, \dots, \beta_{N-1}]^T.$$

(2.3.2.1) beschreibt eine lineare Abbildung zwischen f und β , $\beta = (1/N)Tf$, mit der Matrix

$$T = [t_{jk}], \quad t_{jk} := e^{-2\pi i j k / N}.$$

- a) Man zeige, daß T wie folgt faktorisiert werden kann:

$$T = QSP(D_{n-1}SP) \cdots (D_1SP),$$

mit der $N \times N$ -Matrix S

$$S = \begin{bmatrix} 1 & & & & 1 \\ & 1 & & & -1 \\ & & & & \\ & & & \ddots & \\ & & & & 1 & 1 \\ & & & & 1 & -1 \end{bmatrix},$$

der Diagonalmatrix $D_l = \text{diag}(1, \delta_1^{(l)}, 1, \delta_3^{(l)}, \dots, 1, \delta_{N-1}^{(l)})$, $l = 1, \dots, n-1$, mit $\delta_r^l = \exp(-2\pi i \tilde{r} / 2^{n-l-1})$, $\tilde{r} = [r/2^l]$, r ungerade, der Permutationsmatrix Q , die zur Bitumkehrabbildung ϱ (2.3.2.9) gehört, und der Permutationsmatrix P , die zur zyklischen Bit-Permutation ζ gehört:

$$\zeta(\alpha_0 + \alpha_1 \cdot 2 + \dots + \alpha_{n-1} 2^{n-1}) := \alpha_{n-1} + \alpha_0 \cdot 2 + \alpha_1 \cdot 4 + \dots + \alpha_{n-2} 2^{n-1}.$$

- b) Man zeige, daß man die Sande-Tukey Methode erhält, wenn man den Vektor f von links mit den Matrizen der Faktorisierung von T multipliziert.
c) Welche Faktorisierung von T entspricht der Cooley-Tukey Methode?
Hinweis: T^H unterscheidet sich von T durch eine Permutation.

19. Man untersuche die numerische Stabilität der Methoden der schnellen Fouriertransformation aus Abschnitt 2.3.2.

Hinweis: Die Faktoren von T aus Aufgabe 18 sind fast orthogonal.

20. Gegeben seien eine Zerlegung $\mathbf{t} = \{x_0 < x_1 < \dots < x_n\}$ und Werte $Y := \{y_0, \dots, y_n\}$. Man zeige unabhängig von Satz (2.4.1.5) die Eindeutigkeit der

Splinefunktion $S_t(Y; \cdot)$ mit der Eigenschaft $S_t''(Y; x_0) = S_t''(Y; x_n) = 0$.

Hinweis: Die Annahme der Existenz von 2 verschiedenen derartigen Funktionen S_t und $\tilde{S}_t$ führt zu einem Widerspruch, was die Zahl der Nullstellen von $S_t'' - \tilde{S}_t''$ betrifft.

21. Die Existenz von $S_t(Y; \cdot)$ in den Fällen a), b), c) (2.4.1.2) läßt sich auch ohne die in 2.4.2 durchgeführte explizite Berechnung von $S_t(Y; \cdot)$ beweisen:
- Der Ansatz (2.4.2.4) enthält die $4n$ Parameter $\alpha_j, \beta_j, \gamma_j, \delta_j$. Man zeige, daß man aus ihm in jedem der Fälle a), b), c) ein System von $4n$ linearen Gleichungen für diese Parameter erhält ($n + 1 = \text{Anzahl der Knoten}$).
 - Man zeige, daß aus der Eindeutigkeit (Aufgabe 20) von $S_t(Y; \cdot)$ folgt, daß die Matrix dieses Gleichungssystems nichtsingulär ist, womit die Existenz von $S_t(Y; \cdot)$ gesichert ist.
22. Für die in (2.4.2.6), (2.4.2.8) eingeführten Größen d_j gilt

$$d_j = 3f''(x_j) + O(\|t\|), \quad j = 0, 1, \dots, n,$$

bei äquidistanter Unterteilung sogar

$$d_j = 3f''(x_j) + O(\|t\|^2), \quad j = 1, 2, \dots, n-1.$$

23. Man zeige im Anschluß an Satz (2.4.1.4): Ist die Zerlegung t' von $[a, b]$ eine Verfeinerung von t , $t' \supset t$, so gilt in jedem der Fälle a), b), c)

$$\|f\| \geq \|S_{t'}(Y'; \cdot)\| \geq \|S_t(Y; \cdot)\|.$$

24. Es sei $f \in \mathcal{K}^4(a, b)$ und $S_t(x)$ eine Splinefunktion auf

$$t = \{a = x_0 < x_1 < \dots < x_n = b\}$$

mit $S_t(x_i) = f(x_i)$, $i = 0, 1, \dots, n$. Man beweise

$$\|f - S_t\|^2 = \int_a^b (f(x) - S_t(x)) f^{(4)}(x) dx,$$

falls zusätzlich eine der folgenden Bedingungen erfüllt ist:

- $f'(x) = S_t'(x)$ für $x = a, b$.
 - $f''(x) = S_t''(x)$ für $x = a, b$.
 - S_Δ ist periodisch und $f \in \mathcal{K}_p^4(a, b)$.
25. Für die Größen p_k , $k = 1, \dots, n$, des Eliminationsverfahrens (2.4.2.15) gilt $p_k > 1$. Alle Divisionen sind also ausführbar.
26. Zu den äquidistanten Knoten $x_i = a + ih$, $h > 0$, $i = 0, \dots, n$, seien die Splinefunktionen S_j definiert durch $S_j(x_k) = \delta_{jk}$, $j, k = 0, \dots, n$, $S_j''(x_0) = S_j''(x_n) = 0$. Man zeige für die Momente $M_1, \dots, M_{n-1}$ von S_j :

$$M_i = -\frac{1}{\rho_i} M_{i+1}, \quad i = 1, \dots, j-2,$$

$$M_i = -\frac{1}{\rho_{n-i}} M_{i-1}, \quad i = j+2, \dots, n-1,$$

$$\left. \begin{aligned} M_j &= \frac{-6}{h^2} \cdot \frac{2 + 1/\rho_{j-1} + 1/\rho_{n-j-1}}{4 - 1/\rho_{j-1} - 1/\rho_{n-j-1}} \\ M_{j-1} &= \frac{1}{\rho_{j-1}} (6h^{-2} - M_j) \\ M_{j+1} &= \frac{1}{\rho_{n-j-1}} (6h^{-2} - M_j) \end{aligned} \right\} \quad \text{falls } j \neq 0, 1, n-1, n,$$

wobei die Zahlen ρ_i durch $\rho_1 := 4$ und $\rho_i := 4 - 1/\rho_{i-1}$ für $i = 2, 3, \dots$ erklärt sind. Wie man leicht nachprüft, erfüllen sie die Ungleichungen

$$4 = \rho_1 > \rho_2 > \dots > \rho_i > \rho_{i+1} > 2 + \sqrt{3} > 3.7, \quad 0.25 < 1/\rho_i < 0.3.$$

27. Man zeige unter den gleichen Voraussetzungen wie in Aufgabe 26: Für $j = 2, 3, \dots, n-2$ und $x \in [x_i, x_{i+1}]$, $j+1 \leq i \leq n-1$ oder $x \in [x_{i-1}, x_i]$, $1 \leq i \leq j-1$ gilt

$$|S_j(x)| \leq \frac{h^2}{8} |M_i|.$$

28. $S_{t,f}$ bezeichne die Splinefunktion, die f an den Stellen $x \in t$ interpoliert und für die gilt

$$S''_{t,f}(x_0) = S''_{t,f}(x_n) = 0.$$

Die Zuordnung $f \rightarrow S_{t,f}$ ist linear, d. h.

$$S_{t,f+g} = S_{t,f} + S_{t,g}, \quad S_{t,\alpha f} = \alpha S_{t,f}.$$

Die Wirkung einer Änderung eines Wertes $f(x_j)$ auf $S_{t,f}$ hängt deshalb nur vom Verlauf der speziellen Splinefunktion S_j ab, die in Aufgabe 26 definiert wurde. Man weise nach, daß die Störung von $S_{t,f}$ in den benachbarten Intervallen rasch „abklingt“. Man setze dazu wieder eine äquidistante Zerlegung t voraus und verwende die Resultate der Aufgaben 26 und 27.

Zum Vergleich: Wie verhalten sich interpolierende Polynome in dieser Hinsicht? Man betrachte dazu die analog definierten Lagrange-Polynome L_i in (2.1.1.2).

29. Es sei $t = \{x_0 < x_1 < \dots < x_n\}$.

a) Man zeige: Eine Splinefunktion S_t mit den Randbedingungen

$$(*) \quad S_t^{(k)}(x_0) = S_t^{(k)}(x_n) = 0, \quad k = 0, 1, 2,$$

verschwindet für $n < 4$ identisch.

- b) Für $n = 4$ existiert zu jedem Wert c eindeutig eine Splinefunktion S_t mit (*) und der Normierungsbedingung

$$S_t(x_2) = c.$$

Hinweis: Man beweise zunächst die Eindeutigkeit von S_t für $c = 0$ durch Abschätzung der Zahl der Nullstellen von S_t'' in (x_0, x_4) . Daraus folgt die Existenz von S_t wie in Aufgabe 21.

- c) Man berechne S_t explizit für folgenden Spezialfall von b):

$$x_i := -2, -1, 0, 1, 2, \quad c := 1.$$

30. $\mathcal{S}$ sei der Raum aller Splinefunktionen S_t zu $\mathbf{t} = \{x_0 < x_1 < \dots < x_n\}$ mit $S_t''(x_0) = S_t''(x_n) = 0$. $S_0, \dots, S_n$ seien wie in Aufgabe 26 definiert. Man zeige, daß für $Y := \{y_0, \dots, y_n\}$ gilt

$$S_t(Y; x) \equiv \sum_{j=0}^n y_j S_j(x).$$

Welche Dimension hat $\mathcal{S}$?




Fig. 5. Vergleich von Splinefunktionen

31. $E_{t,f}(x)$ bezeichne diejenige Spline-ähnliche Funktion $y \in \mathcal{K}^2(a, b)$ mit $y(x_i) = f(x_i)$, $y'(x) = f'(x)$ für $x = a, b$, die zu gegebenen λ_i das Funktional

$$E[y] = \sum_{i=0}^{N-1} \int_{x_i}^{x_{i+1}} \left[\left(y''(x) \right)^2 + \lambda_i^2 \left(y'(x) \right)^2 \right] dx$$

über $\mathcal{K}^2(a, b)$ minimiert (vgl. Satz (2.4.1.5), c)).

- a) Man zeige:

$E_{t,f}$ hat für $x_i \leq x \leq x_{i+1}$, $i = 0, 1, \dots, N-1$ die Darstellung:

$$E_{t,f} = \alpha_i + \beta_i(x - x_i) + \gamma_i \psi_i(x - x_i) + \delta_i \varphi_i(x - x_i)$$

mit

$$\psi_i(x) = \frac{2}{\lambda_i^2} [\cosh(\lambda_i x) - 1], \quad \varphi_i(x) = \frac{6}{\lambda_i^3} [\sinh(\lambda_i x) - \lambda_i x],$$

und Integrationskonstanten $\alpha_i, \beta_i, \gamma_i, \delta_i$.

$E_{t,f}$ bezeichnet man auch als *Exponentialspline*.

- b) Was erhält man im Grenzfall $\lambda_i \rightarrow 0$?
 - c) Figur 5 zeigt das qualitative Verhalten von kubischen Splines und Exponentialsplines.
32. Man weise für die Hut-Funktion $H(x)$ (2.4.6.6) alle Eigenschaften einer Skalierungsfunktion nach (Def. (2.4.6.1)).
33. Für die durch (2.4.6.20) definierten Zahlen γ_k zeige man
- a) $\gamma_k = \gamma_{-k}$ für alle $k \in \mathbb{Z}$,
 - b) $\sum_{k \in \mathbb{Z}} \gamma_k = \sqrt{2}$,
 - c) $\gamma_{2k-1} + 2\gamma_{2k} + \gamma_{2k+1} = 0$ für alle $k \in \mathbb{Z}$, $k \neq 0$.
- Hinweis:* Man nutze aus, daß das Multi-Resolutions-Verfahren (2.4.6.8) jede Funktion $v_1 \in V_1$ mit $v_1 \in V_0$ durch sich selbst approximiert, $v_0 = v_1 \in V_0$.

Literatur zu Kapitel 2

- Achieser, N. I. (1953): *Vorlesungen über Approximationstheorie*. Berlin: Akademie-Verlag.
- Ahlberg, J., Nilson, E., Walsh, J. (1967): *The theory of splines and their applications*. New York: Academic Press.
- Bloomfield, P. (1976): *Fourier analysis of time series*. New York: Wiley.
- Böhm, E. O. (1974): *Spline-Funktionen*. Stuttgart: Teubner.
- Brigham, E. O. (1974): *The fast Fourier transform*. Englewood Cliffs, N.J.: Prentice-Hall.
- Bulirsch, R., Rutishauser, H. (1968): Interpolation und genäherte Quadratur. In: Sauer, Szabó.
- Bulirsch, R., Stoer, J. (1968): Darstellung von Funktionen in Rechenautomaten. In: Sauer, Szabó.
- Chui, C. K. (1992): *An Introduction to Wavelets*. San Diego, CA: Academic Press.
- Ciarlet, P. G., Schultz, M. H., Varga, R. S. (1967): Numerical methods of high-order accuracy for nonlinear boundary value problems I. One dimensional problems. *Numer. Math.* **9**, 294–430.
- Cooley, J. W., Tukey, J. W. (1965): An algorithm for the machine calculation of complex Fourier series. *Math. Comput.* **19**, 297–301.
- Curry, H. B., Schoenberg, I. J. (1966): On Polya frequency functions, IV: The fundamental spline functions and their limits. *J. d'Analyse Math.* **17**, 73–82.
- Daubechies, I. (1992): *Ten Lectures on Wavelets*. CBMS-NSF Regional Conference Series in Applied Mathematics. Philadelphia: SIAM.
- Davis, P. J. (1965): *Interpolation and approximation*. 2. Auflage. New York: Blaisdell.

- de Boor, C. (1972): On calculating with B-splines. *J. Approximation Theory* **6**, 50–62.
- de Boor, C. (1978): *A practical guide to splines*. Berlin-Heidelberg-New York: Springer.
- de Boor, C., Pinkus, A. (1977): Backward error analysis for totally positive linear systems. *Numer. Math.* **27**, 485–490.
- Gautschi, W. (1972): Attenuation factors in practical Fourier analysis. *Numer. Math.* **18**, 373–400.
- Gentleman, W. M., Sande, G. (1966): Fast Fourier transforms – For fun and profit. In: *Proc. AFIPS 1966 Fall Joint Computer Conference*, **29**, 503–578. Washington, D.C.: Spartan Books.
- Goertzel, G. (1958): An algorithm for the evaluation of finite trigonometric series. *Amer. Math. Monthly* **65**, 34–35.
- Greville, T. N. E. (1969): Introduction to spline functions. In: *Theory and Applications of Spline Functions*. Edited by T. N. E. Greville. New York: Academic Press.
- Hall, C. A., Meyer, W. W. (1976): Optimal error bounds for cubic spline interpolation. *J. Approximation Theory* **16**, 105–122.
- Herriot, J. G., Reinsch, C. (1971): ALGOL 60 procedures for the calculation of interpolating natural spline functions. Technical Report STAN-CS-71-200, Computer Science Department, Stanford University, CA.
- Karlin, S. (1968): *Total positivity*, Vol. 1. Stanford: Stanford University Press.
- Kuntzmann, J. (1959): *Méthodes numériques, interpolation – dérivées*. Paris: Dunod.
- Louis, A., Maaß, P., Rieder, A. (1994): *Wavelets*. Stuttgart: Teubner.
- Maehly, H., Witzgall, Ch. (1960): Tschebyscheff-Approximationen in kleinen Intervallen II. *Numer. Math.* **2**, 293–307.
- Mallat, St. (1997): *A Wavelet Tour of Signal Processing*. San Diego, CA.: Academic Press.
- Milne, E. W. (1950): *Numerical calculus*. 2. Auflage. Princeton, N.J.: Princeton University Press.
- Milne-Thomson, L. M. (1951): *The calculus of finite differences*. Neuauflage. London: Macmillan.
- Reinsch, C.: Unpublished manuscript.
- Sauer, R., Szabó, I. (Eds.) (1968): *Mathematische Hilfsmittel des Ingenieurs*, Part III. Berlin-Heidelberg-New York: Springer.
- Schoenberg, I. J., Whitney, A. (1953): On Polya frequency functions, III: The positivity of translation determinants with an application to the interpolation problem by spline curves. *Trans. Amer. Math. Soc.* **74**, 246–259.
- Schultz, M. H. (1973): *Spline Analysis*. Englewood Cliffs, N.J.: Prentice-Hall.
- Singleton, R. C. (1967): On computing the fast Fourier transform. *Comm. ACM* **10**, 647–654.
- Singleton, R. C. (1968): Algorithm 338: ALGOL procedures for the fast Fourier transform. Algorithm 339: An ALGOL procedure for the fast Fourier transform with arbitrary factors. *Comm. ACM* **11**, 773–779.

3 Integration von Funktionen

Die Berechnung des bestimmten Integrals

$$\int_a^b f(x) dx$$

einer gegebenen reellen Funktion ist ein klassisches Problem. Für einige einfache Integranden $f(x)$ kann man das unbestimmte Integral

$$\int f(x) dx = F(x), \quad F'(x) = f(x),$$

in geschlossener Form durch algebraische Funktionen von x und bekannten transzendenten Funktionen von x ausdrücken. Es ist dann natürlich

$$\int_a^b f(x) dx = F(b) - F(a).$$

Eine umfangreiche Sammlung von unbestimmten Integralen und vieler wichtiger bestimmter Integrale findet man in Gröbner und Hofreiter (1961), Gradshteyn und Ryzhik (1980).

In der Regel muß man jedoch bestimmte Integrale mittels Diskretisierungsmethoden berechnen, die das Integral entsprechend einer Partitionierung des Integrationsintervalls $[a, b]$ durch eine endliche Summe approximieren („numerische Quadratur“). Ein typischer Vertreter dieser Klasse von Methoden ist die sog. Simpson-Regel, die noch immer die am besten bekannte und meistbenutzte Integrationsmethode ist. Sie wird in Abschnitt 3.1 zusammen mit einigen anderen elementaren Integrationsverfahren beschrieben. Abschnitt 3.2 enthält die elegante und systematische Darstellung der Approximationsfehler von Integrationsregeln, die von Peano stammt.

Die nähere Untersuchung der Trapezsummen in Abschnitt 3.3 zeigt, daß ihr Integrationsfehler eine asymptotische Entwicklung nach Potenzen des Diskretisierungsparameters h besitzt, die der klassischen Summationsformel von Euler und Maclaurin entspricht. Derartige asymptotische Entwicklungen werden systematisch in den sog. „Extrapolationsverfahren“ ausgenutzt, um

die Genauigkeit von Diskretisierungsverfahren zu steigern. Die Anwendung dieser Extrapolationsmethoden auf die Integration („Romberg-Integration“) wird in Abschnitt 3.4 studiert. Allgemeine Extrapolationsmethoden werden in 3.5 behandelt.

Eine Beschreibung der Gaußschen Integrationsmethode folgt in Abschnitt 3.6. Das Kapitel schließt mit einigen Bemerkungen zur Integration von Funktionen mit Singularitäten.

Eine eingehende Behandlung der Integration von Funktionen findet man in Davis und Rabinowitz (1975); numerische Details zu vielen modernen Integrationsmethoden und FORTRAN-Programme werden in Piessens et al. (1983) beschrieben.

3.1 Elementare Integrationsformeln. Fehlerabschätzungen

Die Integrationsformeln von Newton und Cotes erhält man, wenn man den Integranden f durch ein passendes interpolierendes Polynom P ersetzt und $\int_a^b P(x)dx$ als Näherungswert für $\int_a^b f(x)dx$ nimmt. Wir betrachten dazu eine äquidistante Intervalleinteilung von $[a, b]$

$$x_i = a + i h, \quad i = 0, \dots, n,$$

zur Schrittweite $h := (b - a)/n$, $n > 0$ ganz, und sei $P_n \in \Pi_n$ (s. Abschnitt 2.1.1) dasjenige interpolierende Polynom von Grad $\leq n$ mit

$$P_n(x_i) = f_i := f(x_i) \quad \text{für } i = 0, 1, \dots, n.$$

Dann gilt wegen der Interpolationsformel von Lagrange (2.1.1.4)

$$P_n(x) = \sum_{i=0}^n f_i L_i(x), \quad L_i(x) = \prod_{\substack{k=0 \\ k \neq i}}^n \frac{x - x_k}{x_i - x_k}.$$

Mit $x = a + ht$ und t als neuer Variablen erhält man

$$L_i(x) = \varphi_i(t) := \prod_{\substack{k=0 \\ k \neq i}}^n \frac{t - k}{i - k}.$$

Die Integration von P_n ergibt

$$\begin{aligned}
\int_a^b P_n(x) dx &= \sum_{i=0}^n f_i \int_a^b L_i(x) dx \\
&= h \sum_{i=0}^n f_i \int_0^n \varphi_i(t) dt \\
&= h \sum_{i=0}^n f_i \alpha_i.
\end{aligned}$$

Dabei hängen die Koeffizienten („Gewichte“)

$$\alpha_i := \int_0^n \varphi_i(t) dt$$

nur von n ab und nicht von der zu integrierenden Funktion f oder den Intervallgrenzen a, b .

Zum Beispiel erhält man für $n = 2$

$$\begin{aligned}
\alpha_0 &= \int_0^2 \frac{t-1}{0-1} \cdot \frac{t-2}{0-2} dt = \frac{1}{2} \int_0^2 (t^2 - 3t + 2) dt = \frac{1}{2} \left(\frac{8}{3} - \frac{12}{2} + 4 \right) = \frac{1}{3}, \\
\alpha_1 &= \int_0^2 \frac{t-0}{1-0} \cdot \frac{t-2}{1-2} dt = - \int_0^2 (t^2 - 2t) dt = - \left(\frac{8}{3} - 4 \right) = \frac{4}{3}, \\
\alpha_2 &= \int_0^2 \frac{t-0}{2-0} \cdot \frac{t-1}{2-1} dt = \frac{1}{2} \int_0^2 (t^2 - t) dt = \frac{1}{2} \left(\frac{8}{3} - \frac{4}{2} \right) = \frac{1}{3}.
\end{aligned}$$

Man erhält den Näherungswert

$$\int_a^b P_2(x) dx = \frac{h}{3} (f_0 + 4f_1 + f_2)$$

für das Integral $\int_a^b f(x) dx$. Dies ist gerade die *Simpsonsche Regel*. Allgemein erhält man für alle natürlichen Zahlen n zur näherungsweise Berechnung von $\int_a^b f(x) dx$ Integrationsformeln der Form

$$(3.1.1) \quad \int_a^b P_n(x) dx = h \sum_{i=0}^n f_i \alpha_i, \quad f_i := f(a + ih), \quad h := \frac{b-a}{n},$$

die sogenannten *Newton-Cotes-Formeln*. Die Gewichte α_i liegen tabelliert vor. Es sind rationale Zahlen mit der Eigenschaft

$$(3.1.2) \quad \sum_{i=0}^n \alpha_i = n.$$

Dies folgt aus (3.1.1) mit $f(x) \equiv 1$ also $P_n(x) \equiv 1$ wegen der Eindeutigkeit der Polynominterpolation. Wählt man s als Hauptnenner der rationalen Zahlen α_i so werden die Zahlen

$$\sigma_i := s \alpha_i, \quad i = 0, 1, \dots, n,$$

ganzzahlig und man erhält aus (3.1.1)

$$(3.1.3) \quad \int_a^b P_n(x) dx = h \sum_{i=0}^n f_i \alpha_i = \frac{b-a}{ns} \sum_{i=0}^n \sigma_i f_i.$$

Man kann zeigen, daß der Approximationsfehler eine Darstellung der Form

$$(3.1.4) \quad \int_a^b P_n(x) dx - \int_a^b f(x) dx = h^{p+1} \cdot K \cdot f^{(p)}(\xi), \quad \xi \in (a, b),$$

besitzt (s. Steffensen (1950)), falls f auf $[a, b]$ genügend oft differenzierbar ist. Hierbei hängen p und K natürlich von n aber nicht von f ab.

Wir sagen, daß ein Verfahren die *Ordnung* p besitzt, wenn p die größte ganze Zahl ist, für die das Verfahren alle Polynome kleineren Grads als p exakt integriert.

Für $n = 1, 2, \dots, 6$ erhält man die folgenden Newton-Cotes-Formeln:

n	σ_i					ns	Fehler	Name		
1	1	1				2	$h^3 \frac{1}{12} f^{(2)}(\xi)$	Trapezregel		
2	1	4	1				6	$h^5 \frac{1}{90} f^{(4)}(\xi)$	Simpson-Regel	
3	1	3	3	1			8	$h^5 \frac{3}{80} f^{(4)}(\xi)$	3/8-Regel	
4	7	32	12	32	7		90	$h^7 \frac{8}{945} f^{(6)}(\xi)$	Milne-Regel	
5	19	75	50	50	75	19	288	$h^7 \frac{275}{12096} f^{(6)}(\xi)$	—	
6	41	216	27	272	27	216	41	840	$h^9 \frac{9}{1400} f^{(8)}(\xi)$	Weddle-Regel

Für größere Werte von n treten leider negative Gewichte σ_i auf und die Formeln werden numerisch unbrauchbar, weil sich kleine Änderungen $f \rightarrow f + \Delta f$ des Integranden,

$$\max_{x \in (a, b)} |\Delta f(x)| \leq \alpha \max_{x \in (a, b)} |f(x)|, \quad \alpha \text{ klein,}$$

weniger stark auf das Integral $\int_a^b f(x) dx$ als auf die Summe (3.1.3) auswirken.

Weitere Integrationsregeln erhält man, wenn man bei der Approximation des Integranden f durch Polynome $P_n \in \Pi_n$ vom Grad $\leq n$ Hermite-Interpolation benutzt. Im einfachsten Fall ersetzt man $f(x)$ durch ein Polynom $P \in \Pi_3$ mit

$$P(\xi) = f(\xi), \quad P'(\xi) = f'(\xi) \quad \text{für} \quad \xi = a, b.$$

Man erhält für P im Spezialfall $a = 0, b = 1$ aus der verallgemeinerten Lagrangeformel (2.1.5.3)

$$\begin{aligned} P(t) = f(0)[(t-1)^2 + 2t(t-1)^2] + f(1)[t^2 - 2t^2(t-1)] \\ + f'(0)t(t-1)^2 + f'(1)t^2(t-1). \end{aligned}$$

Die Integration von P ergibt

$$\int_0^1 P(t)dt = \frac{1}{2}(f(0) + f(1)) + \frac{1}{12}(f'(0) - f'(1)).$$

Durch Variablentransformation erhält man daraus für allgemeines $a < b$ mit $h := b - a$ die Regel

$$(3.1.5) \quad \int_a^b f(x)dx \approx M(h) := \frac{h}{2}(f(a) + f(b)) + \frac{h^2}{12}(f'(a) - f'(b)).$$

Für den Approximationsfehler dieser Regel kann man mit der Methode von Abschnitt (3.2) für $f \in C^4[a, b]$ zeigen:

$$(3.1.6) \quad M(h) - \int_a^b f(x)dx = \frac{-h^5}{720} f^{(4)}(\xi), \quad \xi \in (a, b).$$

Wenn man bei der Interpolation des Integranden $f(x)$ in $\int_a^b f(x)dx$ auf die Äquidistanz der Stützabszissen $x_i, i = 0, \dots, n$, in $[a, b]$ verzichtet, erhält man weitere Integrationsregeln, darunter auch eine von Gauß angegebene: Sie wird in Abschnitt 3.6 näher beschrieben.

Gewöhnlich benutzt man die Newton-Cotes-Formeln oder ähnliche Formeln nicht für das gesamte Intervall $[a, b]$, sondern man unterteilt das Intervall $[a, b]$ in eine Reihe kleinerer Intervalle, wendet die Formel auf jedes der Teilintervalle an und addiert die so erhaltenen Näherungswerte für die Teilintegrale. Man spricht dann von *wiederholter Anwendung* der betreffenden Formel.

Für die Trapezregel ($n = 1$) erhält man beispielsweise für das Teilintervall $[x_i, x_{i+1}]$ der Unterteilung $x_i = a + ih, i = 0, 1, \dots, N, h := (b-a)/N$, den Näherungswert

$$I_i := \frac{h}{2}[f(x_i) + f(x_{i+1})].$$

Für das gesamte Intervall $[a, b]$ ergibt sich so der Näherungswert
(3.1.7)

$$T(h) := \sum_{i=0}^{N-1} I_i \\ = h \cdot \left[\frac{f(a)}{2} + f(a+h) + f(a+2h) + \cdots + f(b-h) + \frac{f(b)}{2} \right],$$

die *Trapezsumme* zur Schrittweite h .

Für jedes Teilintervall $[x_i, x_{i+1}]$ läßt sich der Fehler angeben zu

$$I_i - \int_{x_i}^{x_{i+1}} f(x) dx = \frac{h^3}{12} f^{(2)}(\xi_i), \quad \xi_i \in (x_i, x_{i+1}).$$

Es ist daher für $f \in C^2[a, b]$

$$T(h) - \int_a^b f(x) dx = \frac{h^2}{12} (b-a) \cdot \sum_{i=0}^{N-1} \frac{1}{N} f^{(2)}(\xi_i) \\ = \frac{h^2(b-a)}{12} f^{(2)}(\xi) \quad \text{für ein } \xi \in (a, b),$$

da

$$\min_i f^{(2)}(\xi_i) \leq \frac{1}{N} \sum_{i=0}^{N-1} f^{(2)}(\xi_i) \leq \max_i f^{(2)}(\xi_i)$$

und es deshalb für stetiges $f^{(2)}$ ein $\xi \in \left(\min_i \xi_i, \max_i \xi_i \right) \subset (a, b)$ geben muß mit

$$f^{(2)}(\xi) = \frac{1}{N} \sum_{i=0}^{N-1} f^{(2)}(\xi_i).$$

Bei der Trapezsumme handelt es sich um ein Verfahren zweiter Ordnung, da sie alle Polynome kleineren Grades als zwei exakt integriert. Gleichzeitig sieht man, daß ihr Integrationsfehler bei einer Verkleinerung der Teilintervalle von $[a, b]$, d. h. Vergrößerung von N , mit h^2 gegen 0 geht.

Ist N gerade, kann man die Simpsonregel auf jedes der $N/2$ Teilintervalle $[x_{2i}, x_{2i+2}]$, $i = 0, 1, \dots, (N/2) - 1$, anwenden. Sie liefert dort den Näherungswert $I_i = \frac{h}{3} (f(x_{2i}) + 4f(x_{2i+1}) + f(x_{2i+2}))$. Durch Summation erhält man als Näherungswert für das Integral über das gesamte Intervall

$$S(h) := \frac{h}{3} [f(a) + 4f(a+h) + 2f(a+2h) + 4f(a+3h) + \cdots \\ \cdots + 2f(b-2h) + 4f(b-h) + f(b)].$$

Wie für die Trapezsumme zeigt man unter Benutzung des Fehlergliedes für die Simpsonregel für den Fehler von $S(h)$ die Formel

$$S(h) - \int_a^b f(x)dx = \frac{b-a}{180} h^4 f^{(4)}(\xi), \quad \xi \in (a, b),$$

sofern $f \in C^4[a, b]$. Man hat also ein Verfahren 4. Ordnung vor sich.

Die wiederholte Anwendung der Regel $M(h)$ (3.1.5) ist besonders bemerkenswert, weil sich bei der Summation der Näherungswerte für die Teilintegrale $\int_{x_i}^{x_{i+1}} f(x)dx$ für $i = 0, 1, \dots, N-1$ alle *inneren* Ableitungen $f'(x_i)$, $0 < i < n$, herausheben. Man erhält für $\int_a^b f(x)dx$ den Näherungswert:

$$\begin{aligned} U(h) &:= h \left[\frac{f(a)}{2} + f(a+h) + \dots + f(b-h) + \frac{f(b)}{2} \right] \\ &\quad + \frac{h^2}{12} [f'(a) - f'(b)] \\ &= T(h) + \frac{h^2}{12} [f'(a) - f'(b)]. \end{aligned}$$

Diese Formel kann man als eine Korrektur der Trapezsumme $T(h)$ ansehen; sie hängt eng mit der Euler-Maclaurinschen Summenformel zusammen, die eingehend in Abschnitt 3.3 untersucht wird. Mit Hilfe von (3.1.6) zeigt man wie eben für den Fehler von $U(h)$:

$$(3.1.8) \quad U(h) - \int_a^b f(x)dx = -\frac{b-a}{720} h^4 f^{(4)}(\xi), \quad \xi \in (a, b),$$

falls $f \in C^4[a, b]$. Verglichen mit dem Fehler der Trapezsumme $T(h)$ hat sich die Ordnung des Verfahrens um 2 erhöht, und dies praktisch ohne Mehraufwand: Man hat nur $f'(a)$ und $f'(b)$ zusätzlich zu berechnen. Ersetzt man $f'(a)$, $f'(b)$ durch Differenzenquotienten hinreichend hoher Fehlerordnung, so erhält man einfache Modifikationen der Trapezsumme („Randkorrekturen“ (s. Henrici (1964))) mit höherer Ordnung als zwei. So ergibt bereits folgende Variante der Trapezsumme ein Verfahren 3. Ordnung.

$$\begin{aligned} \hat{T}(h) &:= h \left[\frac{5}{12} f(a) + \frac{13}{12} f(a+h) + f(a+2h) + \dots + f(b-2h) \right. \\ &\quad \left. + \frac{13}{12} f(b-h) + \frac{5}{12} f(b) \right]. \end{aligned}$$

Für eine Beschreibung weiterer Integrationsverfahren und ihre systematische Untersuchung sei auf die Spezialliteratur verwiesen z. B. Davis, Rabinowitz (1975).

3.2 Die Peanosche Fehlerdarstellung

Die bisherigen Formeln für die Approximation von $I(f) = \int_a^b f(x)dx$ haben alle die Gestalt

$$(3.2.1) \quad \tilde{I}(f) := \sum_{k=0}^{m_0} a_{k0} f(x_{k0}) + \sum_{k=0}^{m_1} a_{k1} f'(x_{k1}) + \cdots + \sum_{k=0}^{m_n} a_{kn} f^{(n)}(x_{kn}).$$

Den Integrationsfehler

$$(3.2.2) \quad R(f) := \tilde{I}(f) - \int_a^b f(x)dx$$

kann man als *lineares Funktional* auffassen, das auf einem gewissen linearen Vektorraum V von Funktionen jeder Funktion $f \in V$ eine Zahl, nämlich den Integrationsfehler $R(f)$ zuordnet. Als V kann man dabei beliebige Vektorräume von Funktionen f wählen, für die $R(f)$ definiert ist, z. B. $V = \Pi_n$, die Menge aller Polynome P vom Grad $\leq n$, oder $V = C^n[a, b]$, die Menge aller n -mal stetig differenzierbaren reellen Funktionen auf $[a, b]$ usw. Offensichtlich ist R auf solchen Räumen linear:

$$R(\alpha f + \beta g) = \alpha R(f) + \beta R(g) \quad \text{für } f, g \in V, \quad \alpha, \beta \in \mathbb{R}.$$

Von Peano stammt folgende elegante Integraldarstellung von $R(f)$:

(3.2.3) **Satz:** Für alle Polynome $P \in \Pi_n$ gelte $R(P) = 0$, d. h. alle Polynome P vom Grad $\leq n$ werden durch $\tilde{I}(\cdot)$ exakt integriert. Dann gilt für alle Funktionen $f \in C^{n+1}[a, b]$

$$R(f) = \int_a^b f^{(n+1)}(t) K(t) dt$$

mit

$$K(t) := \frac{1}{n!} R_x[(x-t)_+^n], \quad (x-t)_+^n := \begin{cases} (x-t)^n & \text{für } x \geq t, \\ 0 & \text{für } x < t. \end{cases}$$

Dabei bedeutet $R_x(x-t)_+^n$, daß das Funktional R auf $(x-t)_+^n$ aufgefäßt als Funktion von x anzuwenden ist. $K(t)$ heißt *Peano-Kern* des Funktional R .

Beweis: Die Taylorentwicklung von $f(x)$ um $x = a$ ergibt

$$(3.2.4) \quad f(x) = f(a) + f'(a)(x-a) + \cdots + \frac{f^{(n)}(a)}{n!} (x-a)^n + r_n(x),$$

wobei das Restglied

$$r_n(x) = \frac{1}{n!} \int_a^x f^{(n+1)}(t)(x-t)^n dt,$$

nach Definition von $(x-t)_+^n$ auch in der Form

$$(3.2.5) \quad r_n(x) = \frac{1}{n!} \int_a^b f^{(n+1)}(t)(x-t)_+^n dt$$

geschrieben werden kann. Wendet man das Funktional R auf (3.2.4) an, so folgt wegen $R(P) = 0$ für $P \in \Pi_n$ sofort

$$(3.2.6) \quad R(f) = R(r_n) = \frac{1}{n!} R_x \left(\int_a^b f^{(n+1)}(t)(x-t)_+^n dt \right).$$

Nun ist der Integrand in $r_n(x)$ eine $(n-1)$ mal stetig differenzierbare Funktion von x . Nach bekannten Sätzen der Analysis über die Vertauschbarkeit von Limiten gilt daher

$$\int_a^b \left[\int_a^b f^{(n+1)}(t)(x-t)_+^n dt \right] dx = \int_a^b f^{(n+1)}(t) \left[\int_a^b (x-t)_+^n dx \right] dt$$

sowie für $k < n$

$$\frac{d^k}{dx^k} \left[\int_a^b f^{(n+1)}(t)(x-t)_+^n dt \right] = \int_a^b f^{(n+1)}(t) \left[\frac{d^k}{dx^k} [(x-t)_+^n] \right] dt,$$

weil $(x-t)_+^n$ bezüglich x $(n-1)$ mal stetig differenzierbar ist.

Letztere Beziehung bleibt auch noch für $k = n$ richtig wegen:

$$\begin{aligned} \frac{d^n}{dx^n} \left[\int_a^b f^{(n+1)}(t)(x-t)_+^n dt \right] &= \frac{d}{dx} \left[\frac{d^{n-1}}{dx^{n-1}} \int_a^b f^{(n+1)}(t)(x-t)_+^n dt \right] \\ &= \frac{d}{dx} \left[\int_a^b f^{(n+1)}(t) \frac{d^{n-1}}{dx^{n-1}} (x-t)_+^n dt \right] = \frac{d}{dx} n! \int_a^x f^{(n+1)}(t)(x-t) dt \\ &= n! f^{(n+1)}(x)(x-x) + n! \int_a^x f^{(n+1)}(t) dt \\ &= \int_a^b f^{(n+1)}(t) \left[\frac{d^n}{dx^n} (x-t)_+^n \right] dt. \end{aligned}$$

Wegen der Struktur von R (3.2.2) kann man daher in (3.2.6) das Funktional R_x mit dem Integral vertauschen,

$$R(f) = \frac{1}{n!} \int_a^b f^{(n+1)}(t) R_x((x-t)_+^n) dt = \int_a^b f^{(n+1)}(t) K(t) dt$$

was zu zeigen war. □

Anmerkung: Die Integraldarstellung von Peano ist nicht auf Funktionale R der Form (3.2.1) beschränkt. Sie gilt für alle linearen Funktionale R , für die man in (3.2.6) den Operator R_x mit dem Integral vertauschen kann.

Bei vielen Anwendungen besitzt der Peano-Kern K auf $[a, b]$ ein konstantes Vorzeichen. Dann läßt sich der Mittelwertsatz der Integralrechnung anwenden und man findet die Darstellung

$$(3.2.7) \quad R(f) = f^{(n+1)}(\xi) \int_a^b K(t) dt \quad \text{für ein } \xi \in (a, b).$$

Das Integral über K hängt nicht von f ab, man kann es deshalb durch Anwendung von (3.2.7) auf $f(x) := x^{n+1}$ berechnen. Dies liefert für $f \in C^{n+1}[a, b]$ die Darstellung

$$(3.2.8) \quad R(f) = \frac{R(x^{n+1})}{(n+1)!} f^{(n+1)}(\xi) \quad \text{für ein } \xi \in (a, b).$$

Beispiel: Wir wollen Satz 3.2.3 auf das Restglied der Simpson-Regel

$$R(f) = \frac{1}{3}f(-1) + \frac{4}{3}f(0) + \frac{1}{3}f(1) - \int_{-1}^1 f(x) dx$$

anwenden. Wir benutzen zunächst, daß diese Regel jedes Polynom $P \in \Pi_3$ exakt integriert. Um dies zu zeigen, sei $Q \in \Pi_2$ das Polynom mit $Q(-1) = P(-1)$, $Q(0) = P(0)$, $Q(1) = P(1)$. Für $S(x) := P(x) - Q(x)$ gilt dann $R(P) = R(S)$. Da das Polynom S höchstens den Grad 3 und mindestens die drei Nullstellen $-1, 0, 1$ besitzt, muß $S(x)$ die Form $S(x) = a(x^2 - 1)x$ haben. Es folgt daher

$$R(P) = R(S) = -a \int_{-1}^1 x(x^2 - 1) dx = 0.$$

Also kann man Satz 3.2.3 mit $n = 3$ anwenden, und man erhält den Peano-Kern

$$\begin{aligned} K(t) &= \frac{1}{6} R_x[(x-t)_+^3] \\ &= \frac{1}{6} \left[\frac{1}{3}(-1-t)_+^3 + \frac{4}{3}(0-t)_+^3 + \frac{1}{3}(1-t)_+^3 - \int_{-1}^1 (x-t)_+^3 dx \right]. \end{aligned}$$

Berücksichtigt man die Definition von $(x-t)_+^3$, so folgt für $-1 \leq t \leq 1$

$$\int_{-1}^1 (x-t)_+^3 dx = \int_t^1 (x-t)^3 dx = \frac{(1-t)^4}{4},$$

$$(-1-t)_+^3 = 0, \quad (1-t)_+^3 = (1-t)^3, \quad (-t)_+^3 = \begin{cases} 0 & \text{für } t \geq 0, \\ -t^3 & \text{für } t < 0. \end{cases}$$

Der Peano-Kern der Simpson-Regel für das Intervall $[-1, 1]$ ist daher

$$K(t) = \begin{cases} \frac{1}{72}(1-t)^3(1+3t) & \text{für } 0 \leq t \leq 1, \\ K(-t) & \text{für } -1 \leq t \leq 0. \end{cases}$$

Wir sehen, daß K auf $[-1, 1]$ konstantes Vorzeichen hat, $K(t) \geq 0$ für $-1 \leq t \leq 1$; (3.2.8) ist daher anwendbar und liefert wegen

$$\frac{R(x^4)}{4!} = \frac{1}{24} \left(\frac{1}{3} \cdot 1 + \frac{4}{3} \cdot 0 + \frac{1}{3} \cdot 1 - \int_{-1}^1 x^4 dx \right) = \frac{1}{90}$$

das Restglied der Simpson-Regel

$$\frac{1}{3}f(-1) + \frac{4}{3}f(0) + \frac{1}{3}f(1) - \int_{-1}^1 f(t)dt = \frac{1}{90}f^{(4)}(\xi), \quad \xi \in (a, b).$$

Es gilt generell, daß die Newton-Cotes-Formel zum Grad n für ungerades n alle Polynome $P \in \Pi_n$ und für gerades n sogar alle Polynome $P \in \Pi_{n+1}$ exakt integriert (s. Übungsaufgabe 2). Ferner kann man zeigen [s. Steffensen (1950)], daß die Peano-Kerne $R = R_n$ der n -ten Newton-Cotes-Formeln konstante Vorzeichen besitzen, so daß aus (3.2.8) die Fehlerglieder von Abschnitt (3.1) folgen

$$R_n(f) = \begin{cases} \frac{R_n(x^{n+1})}{(n+1)!} f^{(n+1)}(\xi), & \text{für ungerades } n, \\ \frac{R_n(x^{n+2})}{(n+2)!} f^{(n+2)}(\xi), & \text{für gerades } n. \end{cases} \quad \xi \in (a, b),$$

Schließlich kann man aus (3.2.8) auch die Fehlerformel (3.1.6) für die Regel (3.1.5) herleiten: Ihr Fehler

$$R(f) = \frac{h}{2}(f(a) + f(b)) + \frac{h^2}{12}(f'(a) - f'(b)) - \int_b^a f(x)dx, \quad h := b - a,$$

verschwindet für alle Polynome $P \in \Pi_3$. Für $n = 3$ erhält man aus (3.2.3) den Peanokern für $a \leq t \leq b$

$$\begin{aligned} K(t) &= \frac{1}{6}R_x((x-t)_+^3) \\ &= \frac{1}{6} \left[\frac{h}{2}((a-t)_+^3 + (b-t)_+^3) + \frac{h^2}{4}((a-t)_+^2 - (b-t)_+^2) - \int_a^b (x-t)_+^3 dx \right] \\ &= \frac{1}{6} \left[\frac{h}{2}(b-t)^3 - \frac{h^2}{4}(b-t)^2 - \frac{1}{4}(b-t)^4 \right] \\ &= -\frac{1}{24}(b-t)^2(a-t)^2. \end{aligned}$$

Wegen $K(t) \leq 0$ für $a \leq t \leq b$ ist (3.2.8) anwendbar. Für $a = 0$, $b = 1$ erhält man

$$\frac{R(x^4)}{4!} = \frac{1}{24} \left(\frac{1}{2} \cdot 1 + \frac{1}{12} \cdot (-4) - \frac{1}{5} \right) = -\frac{1}{720},$$

und es folgt für $f \in C^4[a, b]$

$$R(f) = -\frac{1}{24} \int_a^b f^{(4)}(t)(b-t)^2(a-t)^2 dt = -\frac{(b-a)^5}{720} f^{(4)}(\xi), \quad \xi \in (a, b),$$

was mit (3.1.6) übereinstimmt.

3.3 Die Euler–Maclaurinsche Summenformel

Die Fehlerformeln (3.1.6), (3.1.8) sind Spezialfälle der berühmten *Euler–Maclaurinschen Summenformel*, die für $g \in C^{2m+2}[0, 1]$ in ihrer einfachsten Form lautet:

$$(3.3.1) \quad \int_0^1 g(t) dt = \frac{g(0)}{2} + \frac{g(1)}{2} + \sum_{k=1}^m \frac{B_{2k}}{(2k)!} (g^{(2k-1)}(0) - g^{(2k-1)}(1)) \\ - \frac{B_{2m+2}}{(2m+2)!} g^{(2m+2)}(\xi), \quad 0 < \xi < 1.$$

Hier sind die B_k die Bernoullizahlen

$$(3.3.2) \quad B_2 = \frac{1}{6}, \quad B_4 = -\frac{1}{30}, \quad B_6 = \frac{1}{42}, \quad B_8 = -\frac{1}{30}, \dots,$$

deren allgemeine Definition weiter unten gegeben wird. Bei wiederholter Anwendung von (3.3.1) auf die Integrale $\int_i^{i+1} g(t) dt$ und Summation über i , erhält man wie in Abschnitt 3.1 für $g \in C^{2m+2}[0, N]$, $N \geq 1$ ganz, die übliche Form dieser Summenformel

$$(3.3.3) \quad \frac{g(0)}{2} + g(1) \cdots + g(N-1) + \frac{g(N)}{2} = \int_0^N g(t) dt \\ + \sum_{k=1}^m \frac{B_{2k}}{(2k)!} (g^{(2k-1)}(N) - g^{(2k-1)}(0)) \\ + \frac{B_{2m+2}}{(2m+2)!} N g^{(2m+2)}(\xi), \quad 0 < \xi < N.$$

Für ein beliebiges Intervall $[a, b]$ mit äquidistanten Teilpunkten $x_i = a + ih$, $i = 0, \dots, N$, $h = (b-a)/N$, erhält man aus (3.3.3) für $f \in C^{2m+2}[a, b]$ durch Variablentransformation

$$(3.3.4) \quad T(h) = \int_a^b f(t) dt + \sum_{k=1}^m h^{2k} \frac{B_{2k}}{(2k)!} (f^{(2k-1)}(b) - f^{(2k-1)}(a)) \\ + h^{2m+2} \frac{B_{2m+2}}{(2m+2)!} (b-a) f^{(2m+2)}(\xi), \quad a < \xi < b,$$

wobei $T(h)$ die Trapezsumme (3.1.7) zur Schrittweite h bedeutet

$$T(h) = h \left[\frac{f(a)}{2} + f(a+h) + \cdots + f(b-h) + \frac{f(b)}{2} \right].$$

Durch (3.3.4) wird eine Entwicklung der Trapezsumme $T(h)$ nach Potenzen von $h = (b-a)/N$ gegeben, die für die Anwendung von „Extrapolationsmethoden“ (s. 3.4., 3.5) zur Integration grundlegend ist.

Beweis von (3.3.1): Wir formen $\int_0^1 g(t)dt$ durch partielle Integration sukzessiv um, wobei beginnend mit $B_1(x) := x - \frac{1}{2}$ weitere Polynome $B_k(x)$ vom Grad k auftreten:

(3.3.5)

$$\begin{aligned} \int_0^1 g(t)dt &= B_1(t)g(t)\Big|_0^1 - \int_0^1 B_1(t)g'(t)dt, \\ \int_0^1 B_1(t)g'(t)dt &= \frac{1}{2}B_2(t)g'(t)\Big|_0^1 - \frac{1}{2}\int_0^1 B_2(t)g''(t)dt, \\ &\dots \\ \int_0^1 B_{k-1}(t)g^{(k-1)}(t)dt &= \frac{1}{k}B_k(t)g^{(k-1)}(t)\Big|_0^1 - \frac{1}{k}\int_0^1 B_k(t)g^{(k)}(t)dt, \end{aligned}$$

wobei

$$(3.3.6) \quad B'_{k+1}(x) = (k+1)B_k(x), \quad k = 1, 2, \dots$$

Es folgt aus (3.3.6), daß $B_k(x)$ ein Polynom vom Grad k der Form $B_k(x) = x^k + c_{k-1}x^{k-1} + \cdots + c_0$ ist. Für gegebenes $B_k(x)$ bestimmt (3.3.6) $B_{k+1}(x)$ bis auf eine additive Integrationskonstante. Wir wählen diese Konstanten so, daß

$$(3.3.7) \quad B_{2k+1}(0) = B_{2k+1}(1) = 0 \quad \text{für } k > 0$$

gilt. Dadurch sind alle $B_k(x)$ eindeutig bestimmt. Denn aus

$$B_{2k-1}(x) = x^{2k-1} + c_{2k-2}x^{2k-2} + \cdots + c_1x + c_0$$

folgt durch Integration mit den Integrationskonstanten c, d

$$B_{2k+1}(x) = x^{2k+1} + \frac{(2k+1)2k}{2k(2k-1)}c_{2k-2}x^{2k} + \cdots + (2k+1)cx + d.$$

Die Bedingungen $B_{2k+1}(0) = B_{2k+1}(1) = 0$ bestimmen c und d eindeutig. Die so definierten Polynome

$$B_0(x) \equiv 1, \quad B_1(x) \equiv x - \frac{1}{2}, \quad B_2(x) \equiv x^2 - x + \frac{1}{6},$$

$$B_3(x) \equiv x^3 - \frac{3}{2}x^2 + \frac{1}{2}x, \quad B_4(x) \equiv x^4 - 2x^3 + x^2 - \frac{1}{30}, \dots$$

heißen *Bernoulli-Polynome*, ihre konstanten Terme $B_k := B_k(0)$ *Bernoulli-Zahlen*. Die Polynome $B_k(x)$ genügen der Symmetriebeziehung

$$(3.3.8) \quad (-1)^k B_k(1-x) = B_k(x).$$

Dies folgt daraus, daß die Polynome $(-1)^k B_k(1-x)$ den gleichen Rekursionsformeln (3.3.6) und (3.3.7) wie $B_k(x)$ genügen und (3.3.8) für $k = 0, 1$ richtig ist.

Die weitere Beziehung

$$(3.3.9) \quad B_k(0) = B_k(1) = B_k \quad \text{für } k > 1,$$

die nach (3.3.7) für ungerades $k > 1$ gilt, ist wegen (3.3.8) auch für gerades k richtig. Daraus folgt:

$$(3.3.10) \quad \int_0^1 B_k(t) dt = \frac{1}{k+1} (B_{k+1}(1) - B_{k+1}(0)) = 0, \quad \text{für } k \geq 1.$$

Wegen (3.3.9) gilt nun in (3.3.5) für $k > 1$

$$\frac{1}{k} B_k(t) g^{(k-1)}(t) \Big|_0^1 = -\frac{B_k}{k} (g^{(k-1)}(0) - g^{(k-1)}(1)).$$

so daß wegen (3.3.7), $B_{2k+1} = 0$, aus (3.3.5) folgt

$$\int_0^1 g(t) dt = \frac{1}{2} (g(0) + g(1)) + \sum_{k=1}^m \frac{B_{2k}}{(2k)!} (g^{(2k-1)}(0) - g^{(2k-1)}(1)) + r_{m+1},$$

wobei für das Restglied r_{m+1} gilt

$$r_{m+1} := \frac{-1}{(2m+1)!} \int_0^1 B_{2m+1}(t) g^{(2m+1)}(t) dt.$$

Nochmalige partielle Integration führt zu

$$\begin{aligned} \int_0^1 B_{2m+1}(t) g^{(2m+1)}(t) dt &= \frac{1}{2m+2} (B_{2m+2}(t) - B_{2m+2}) g^{(2m+1)}(t) \Big|_0^1 \\ &\quad - \frac{1}{2m+2} \int_0^1 (B_{2m+2}(t) - B_{2m+2}) g^{(2m+2)}(t) dt. \end{aligned}$$

Hier verschwindet der erste Term wegen (3.3.9), so daß schließlich

$$(3.3.11) \quad r_{m+1} = \frac{1}{(2m+2)!} \int_0^1 (B_{2m+2}(t) - B_{2m+2}) g^{(2m+2)}(t) dt.$$

Um den Beweis von (3.3.1) zu vervollständigen, genügt es zu zeigen, daß $B_{2m+2}(t) - B_{2m+2}$ auf $[0, 1]$ das Vorzeichen nicht ändert. Denn dann folgt durch eine Anwendung des Mittelwertsatzes auf (3.3.11) sofort (3.3.1), wenn man $\int_0^1 B_{2m+2}(t)dt = 0$, (s. (3.3.10)) berücksichtigt. Wir zeigen etwas allgemeiner durch Induktion für $m \geq 1$

$$(3.3.12) \quad \begin{aligned} &\text{a) } (-1)^m B_{2m-1}(x) > 0 \quad \text{für } 0 < x < \frac{1}{2}, \\ &\text{b) } (-1)^m (B_{2m}(x) - B_{2m}) > 0 \quad \text{für } 0 < x < 1, \\ &\text{c) } (-1)^{m+1} B_{2m} > 0. \end{aligned}$$

Für $m = 1$ ist a) richtig. Sei nun a) für ein $m \geq 1$ bewiesen. Dann gilt für $0 < x \leq \frac{1}{2}$ wegen (3.3.6)

$$\frac{(-1)^m}{2m} (B_{2m}(x) - B_{2m}) = (-1)^m \int_0^x B_{2m-1}(t)dt > 0.$$

Wegen der Symmetrie (3.3.8) gilt dies auch für $\frac{1}{2} \leq x < 1$, also b) für den Index m . Zusammen mit (3.3.10) beweist dies ebenfalls Behauptung c) wegen

$$(-1)^{m+1} B_{2m} = (-1)^m \int_0^1 (B_{2m}(t) - B_{2m})dt > 0.$$

Wir zeigen nun a) für den Index $m + 1$: Es ist $B_{2m+1}(0) = B_{2m+1}(\frac{1}{2}) = 0$ wegen (3.3.7) und (3.3.8). Würde $B_{2m+1}(x)$ in $(0, \frac{1}{2})$ eine Nullstelle besitzen, so hätte $B_{2m+1}''(x)$, also $B_{2m-1}(x)$ eine Nullstelle $\tilde{x}$ in $(0, \frac{1}{2})$, im Widerspruch zur Induktionsvoraussetzung (3.3.12)a). Also besitzt $B_{2m+1}(x)$ auf $(0, \frac{1}{2})$ konstantes Vorzeichen, das durch das Vorzeichen von $B_{2m+1}'(0) = (2m+1)B_{2m}(0) = (2m+1)B_{2m}$ bestimmt ist, nämlich $(-1)^{m+1}$ wegen (3.3.12)c). Dies beweist (3.3.12) und (3.3.1). $\square$

3.4 Anwendung der Extrapolation auf die Integration

Für eine Funktion $f \in C^{2m+2}[a, b]$ liefert (3.3.4) eine Entwicklung von $T(h)$ nach Potenzen von $h = (b-a)/n$ der Form

$$(3.4.1) \quad T(h) = \tau_0 + \tau_1 h^2 + \tau_2 h^4 + \cdots + \tau_m h^{2m} + \alpha_{m+1}(h) h^{2m+2}.$$

Hier ist $\tau_0 = \int_a^b f(x)dx$ das gesuchte Integral; die Koeffizienten

$$\tau_k := \frac{B_{2k}}{(2k)!} (f^{(2k-1)}(b) - f^{(2k-1)}(a)), \quad k = 1, 2, \dots, m,$$

sind von h unabhängig, und für $f \in C^{2m+2}[a, b]$ ist der Restgliedkoeffizient

$$\alpha_{m+1}(h) = \frac{B_{2m+2}}{(2m+2)!} (b-a) f^{(2m+2)}(\xi(h)), \quad a < \xi(h) < b$$

eine beschränkte Funktion von h : Es gibt eine von h unabhängige Konstante M_{m+1} , nämlich

$$M_{m+1} := \left| \frac{B_{2m+2}}{(2m+2)!} (b-a) \right| \max_{x \in [a, b]} |f^{(2m+2)}(x)|,$$

so daß

$$(3.4.2) \quad |\alpha_{m+1}(h)| \leq M_{m+1} \quad \text{für alle } h = (b-a)/n, \quad n = 1, 2, \dots$$

Entwicklungen der Form (3.4.1) heißen *asymptotische Entwicklungen* in h , wenn die Koeffizienten τ_k für $k \leq m$ von h unabhängig sind und für das Restglied (3.4.2) gilt. Man beachte, daß selbst für beliebig oft differenzierbare Funktionen $f \in C^\infty[a, b]$ die (3.4.1) für $m = \infty$ formal entsprechende unendliche Reihe

$$\tau_0 + \tau_1 h^2 + \tau_2 h^4 + \dots$$

für jedes $h \neq 0$ divergieren kann. Trotzdem behalten asymptotische Entwicklungen ihren Wert. So kann man wegen (3.4.2) für kleines h den Fehlerterm in (3.4.1) gegenüber den übrigen Termen vernachlässigen, so daß sich $T(h)$ für kleines h wie ein Polynom in h^2 verhält, dessen Wert an der Stelle $h = 0$ das Integral τ_0 liefert. Dies legt folgendes Verfahren zur Bestimmung von τ_0 nahe (diese Integrationsmethode, die sog. Romberg-Integration, wurde von Romberg (1955) eingeführt und von Bauer, Rutishauser und Stiefel (1963) näher untersucht):

Zu einer Reihe von Schrittweiten

$$h_0 = \frac{b-a}{n_0}, \quad h_1 = \frac{h_0}{n_1}, \quad \dots, \quad h_m = \frac{h_0}{n_m},$$

die zu einer Folge von ganzen Zahlen n_i mit $0 < n_0 < n_1 < \dots < n_m$ gehört, bestimme man die zugehörigen Trapezsummen

$$T_{i0} := T(h_i), \quad i = 0, 1, \dots, m,$$

und weiter durch Interpolation dasjenige Polynom

$$\tilde{T}_{mm}(h) := a_0 + a_1 h^2 + \dots + a_m h^{2m}$$

höchstens m -ten Grades in h^2 , für das gilt

$$\tilde{T}_{mm}(h_i) = T(h_i), \quad i = 0, 1, \dots, m.$$

Der „extrapolierte“ Wert $\tilde{T}_{mm}(0)$ wird dann in der Regel ein guter Näherungswert für das gesuchte Integral sein. Er läßt sich mittels des Neville Schemas wie folgt berechnen (siehe dazu 2.1.2): Für i, k mit $1 \leq k \leq i \leq m$ sei $\tilde{T}_{ik}(h)$ das Polynom vom Grad $\leq k$ in h^2 mit

$$\tilde{T}_{ik}(h_j) = T(h_j), \quad j = i - k, i - k + 1, \dots, i.$$

Es folgt für die extrapolierten Werte $T_{ik} := \tilde{T}_{ik}(0)$ nach (2.1.2.7) (dort ist $x_i = h_i^2$ zu setzen)

$$(3.4.3) \quad T_{ik} = T_{i,k-1} + \frac{T_{i,k-1} - T_{i-1,k-1}}{\left(\frac{h_{i-k}}{h_i}\right)^2 - 1}, \quad 1 \leq k \leq i \leq m.$$

Die T_{ik} werden wie in (2.1.2.4) zweckmäßig in einem Tableau angeordnet und nach (3.4.3) ausgehend von der ersten Spalte berechnet; jedes Element erhält man dabei aus seinen zwei linken Nachbarn.

$$(3.4.4) \quad \begin{array}{c|ccccccc} h_0^2 & T(h_0) = T_{00} & & & & & \\ & & & & T_{11} & & \\ h_1^2 & T(h_1) = T_{10} & & & & T_{22} & \\ & & & & T_{21} & \searrow & T_{33} \\ h_2^2 & T(h_2) = T_{20} & & & & & \vdots \\ & & \searrow & \nearrow & T_{32} & \nearrow & \\ & & & & & \vdots & \\ h_3^2 & T(h_3) = T_{30} & & \nearrow & & & \\ & & & & \vdots & & \\ \vdots & \vdots & & & & & \end{array}$$

Beispiel: Zur Berechnung des Integrals $\int_0^1 t^5 dt = 1/6$ erhält man bei Benutzung der Schrittweiten $h_0 = 1$, $h_1 = 1/2$, $h_2 = 1/4$ und 6-stelliger Rechnung folgendes Tableau (3.4.4) (in Klammern die exakten Werte):

$$\begin{array}{c|ccccccc} h_0^2 = 1 & T_{00} = 0.500\,000 (= \frac{1}{2}) & & & & & \\ & & & & T_{11} = 0.187\,500 (= \frac{3}{16}) & & \\ h_1^2 = \frac{1}{4} & T_{10} = 0.265\,625 (= \frac{17}{64}) & & & & T_{22} = 0.166\,667 (= \frac{1}{6}) & \\ & & & & T_{21} = 0.167\,969 (= \frac{43}{256}) & & \\ h_2^2 = \frac{1}{16} & T_{20} = 0.192\,383 (= \frac{197}{1024}) & & & & & \end{array}$$

Jedes T_{ik} im Tableau (3.4.4) stellt im übrigen eine lineare Integrationsregel zu einer Schrittweite $\tilde{h}_i = (b - a)/m_i$, $m_i > 0$ ganz, der folgenden Form dar

$$T_{ik} = \alpha_0 f(a) + \alpha_1 f(a + \tilde{h}_i) + \cdots + \alpha_{m_i-1} f(b - \tilde{h}_i) + \alpha_{m_i} f(b).$$

Einige davon (nicht alle) entsprechen gewissen Newton-Cotes Verfahren (s. Abschnitt 3.1). Beispielsweise erhält man für $h_1 = h_0/2 = (b-a)/2$ für T_{11} die Simpsonregel:

$$\begin{aligned} T_{00} &= (b-a) \left(\frac{1}{2} f(a) + \frac{1}{2} f(b) \right) \\ T_{10} &= \frac{1}{2} (b-a) \left(\frac{1}{2} f(a) + f\left(\frac{a+b}{2}\right) + \frac{1}{2} f(b) \right). \end{aligned}$$

so daß wegen (3.4.3)

$$\begin{aligned} T_{11} &= T_{10} + \frac{T_{10} - T_{00}}{3} = \frac{4}{3} T_{10} - \frac{1}{3} T_{00} \\ &= \frac{1}{2} (b-a) \left(\frac{1}{3} f(a) + \frac{4}{3} f\left(\frac{a+b}{2}\right) + \frac{1}{3} f(b) \right). \end{aligned}$$

Ganz analog erhält man für $h_2 = h_1/2 = h_0/4 = (b-a)/4$ als T_{22} die Milne-Regel, aber für $h_3 = h_2/2$ ist T_{33} keine Newton-Cotes Formel mehr (s. Aufgabe 9).

Gewöhnlich benutzt man bei dem beschriebenen Extrapolationsverfahren eine der Folgen

(3.4.5)

$$\text{a) } h_0 = b-a, \quad h_1 = \frac{h_0}{2}, \dots, \quad h_i = \frac{h_{i-1}}{2}, \quad i = 2, 3, \dots$$

$$\text{b) } h_0 = b-a, \quad h_1 = \frac{h_0}{2}, \quad h_2 = \frac{h_0}{3}, \dots, \quad h_i = \frac{h_{i-2}}{2}, \quad i = 3, 4, \dots$$

Die erste Folge wird im ursprünglichen Romberg-Verfahren verwandt (s. Romberg (1955)). Die Folge b), die von Bulirsch (1964) vorgeschlagen wurde, hat den Vorteil, daß bei ihr die Rechenarbeit für die Berechnung neuer $T(h_i)$ mit i nicht so rasch ansteigt wie bei a).

Bei der praktischen Durchführung beachte man, daß man bei der Berechnung von $T(h_{i+1})$ auf die schon für $T(h_i)$ berechneten Funktionswerte zurückgreifen kann. Zum Beispiel gilt für die Rombergfolge:

$$\begin{aligned} T(h_{i+1}) &= T\left(\frac{1}{2}h_i\right) \\ &= \frac{1}{2} T(h_i) + h_{i+1} [f(a + h_{i+1}) + f(a + 3h_{i+1}) + \cdots + f(b - h_{i+1})]. \end{aligned}$$

Im folgenden wird eine *ALGOL-Prozedur* angegeben, die für die Schrittweitenfolge (3.4.5a) das Tableau (3.4.4) berechnet. Es sei dazu $[a, b]$ das Integrationsintervall, f der Integrand und m die Zahl der gewünschten Intervallverfeinerungen. Um Speicherplatz zu sparen, wird dabei das Tableau

Schrägzeile für Schrägzeile berechnet und jeweils nur die letzte Schrägzeile in dem array $t[0 : m]$ gespeichert:

```

procedure romberg (a, b, f, m);
value a, b, m;
integer m;
real a, b;
real procedure f;
begin real h, s;
    integer i, k, n, q;
    array t[0 : m];
    h := b - a; n := 1;
    t[0] :=  $0.5 \times h \times (f(a) + f(b))$ ;
    for k := 1 step 1 until m do
        begin s := 0; h :=  $0.5 \times h$ ; n :=  $2 \times n$ ; q := 1;
            for i := 1 step 2 until n - 1 do
                s := s + f(a + i × h);
                t[k] :=  $0.5 \times t[k - 1] + s \times h$ ;
                print (t[k]);
                for i := k - 1 step -1 until 0 do
                    begin q := q × 4;
                        t[i] :=  $t[i + 1] + (t[i + 1] - t[i]) / (q - 1)$ ;
                        print (t[i])
                    end
                end
            end
        end;

```

Es sei betont, daß dieses Programm nur zur Illustration des beschriebenen Verfahrens dienen soll. Für den praktischen Gebrauch ist es weniger geeignet, da man z. B. gewöhnlich nicht weiß, wie groß man den Parameter m zu wählen hat. Statt m benutzt man daher in der Praxis einen Parameter ε , der die gewünschte Genauigkeit für das gesuchte Integral angibt, berechnet nur wenige Spalten des Tableaus, z.B. etwa sieben, und beendet die Rechnung, falls das erste Mal $|T_{i,6} - T_{i+1,6}| \leq \varepsilon s$ erfüllt ist; dabei nimmt man für s einen groben Näherungswert von $\int_a^b |f(x)| dx$, den man bei der Berechnung der $T(h)$ leicht mitgewinnen kann. Darüber hinaus benutzt man statt der Polynominterpolation besser rationale Interpolation und die Schrittweitenfolge (3.4.5b). Ein Programm, das alle diese Modifikationen berücksichtigt, findet man in Bulirsch und Stoer (1967).

Beim Arbeiten mit rationaler Interpolation (siehe 2.2) statt mit Polynominterpolation erhält man folgende Methode:

Für i, k mit $1 \leq k \leq i \leq m$ werde jetzt mit

$$\tilde{T}_{ik}(h) := \frac{p_0 + p_1 h_2 + \dots + p_\mu h^{2\mu}}{q_0 + q_1 h^2 + \dots + q_\nu h^{2\nu}}, \quad \mu + \nu = k, \quad \mu = \nu \quad \text{oder} \quad \mu = \nu - 1,$$

die interpolierende rationale Funktion bezeichnet, für die gilt

$$\tilde{T}_{ik}(h_j) = T(h_j), \quad j = i - k, i - k + 1, \dots, i.$$

Setzt man wieder $T_{i0} := T(h_i)$ für $i = 0, 1, \dots, m$, und definiert man formal $T_{i,-1} := 0$ für $i = 0, 1, \dots, m - 1$, so lassen sich die extrapolierten Werte $T_{ik} := \tilde{T}_{ik}(0)$ nach (2.2.3.8) wie folgt berechnen

(3.4.6)

$$T_{ik} = T_{i,k-1} + \frac{T_{i,k-1} - T_{i-1,k-1}}{\left[\frac{h_{i-k}}{h_i} \right]^2 \left[1 - \frac{T_{i,k-1} - T_{i-1,k-1}}{T_{i,k-1} - T_{i-1,k-2}} \right] - 1}, \quad 1 \leq k \leq i \leq m.$$

Dem entspricht das Tableau (2.2.3.9), in dem jedes Element aus drei linken Nachbarn berechnet wird.

In Abschnitt 3.5 leiten wir allgemeine Fehlerabschätzungen für Extrapolationsverfahren her, die sich auf asymptotische Entwicklungen der Form (3.4.1) stützen. Unter schwachen Voraussetzungen für die Schrittweitenfolge $h_0, h_1, h_2, \dots$ wird es sich für asymptotische Entwicklungen (3.4.1), die nur gerade Potenzen von h enthalten, zeigen, daß die Fehler von T_{i0} wie h_i^2 , die von T_{i1} wie $h_{i-1}^2 h_i^2$ und die von T_{ik} wie $h_{i-k}^2 h_{i-k+1}^2 \dots h_i^2$ für $i \rightarrow \infty$ gegen 0 konvergieren. Also approximieren für jedes feste k die T_{ik} für $i \rightarrow \infty$ das Integral τ_0 wie ein Verfahren der Ordnung $2k + 2$. Für die spezielle Folge (3.4.5a) kennt man ein schärferes Resultat:

(3.4.7)

$$T_{ik} - \int_a^b f(x) dx = (b-a) h_{i-k}^2 h_{i-k+1}^2 \dots h_i^2 \frac{(-1)^k B_{2k+2}}{(2k+2)!} f^{(2k+2)}(\xi),$$

für ein $\xi \in (a, b)$ falls $f \in C^{2k+2}[a, b]$ (s. Bauer, Rutishauser und Stiefel (1963), Bulirsch (1964)).

3.5 Allgemeines über Extrapolationsverfahren

Viele der Integrationsverfahren in diesem Kapitel sind Beispiele von *Diskretisierungsverfahren*: Hier wird das eigentlich zu lösende Problem diskretisiert und so durch ein Ersatzproblem approximiert (z.B. wird ein Integral durch eine endliche Summe approximiert). Die Feinheit und damit die Güte der Approximation wird gewöhnlich durch eine „Schrittweite“ $h \neq 0$ bestimmt. Zur Schrittweite $h \neq 0$ gehört eine Näherungslösung $T(h)$, die für

$h \rightarrow 0$ gegen die gesuchte Lösung des eigentlichen Problems konvergiert. Solche Diskretisierungsverfahren sind für viele Probleme bekannt, nicht nur für die Berechnung von Integralen. In vielen dieser Fälle besitzt das Resultat $T(h)$ des Diskretisierungsverfahren eine asymptotische Entwicklung der Form

$$(3.5.1) \quad T(h) = \tau_0 + \tau_1 h^{\gamma_1} + \tau_2 h^{\gamma_2} + \cdots + \tau_m h^{\gamma_m} + \alpha_{m+1}(h) h^{\gamma_{m+1}},$$

$$0 < \gamma_1 < \gamma_2 < \cdots < \gamma_{m+1},$$

wo die Exponenten γ_i nicht notwendig ganzzahlig sind. Hier sind die Koeffizienten τ_i von h unabhängig, $\alpha_{m+1}(h)$ ist eine Funktion von h , die für $h \rightarrow 0$ beschränkt bleibt, $|\alpha_{m+1}(h)| \leq M_{m+1}$ für $|h| \leq H$ (vgl. (3.4.2)), und $\tau_0 = \lim_{h \rightarrow 0} T(h)$ ist die exakte Lösung des eigentlichen Problems.

Beispiel: Bei der *numerischen Differentiation* liefert der *zentrale Differenzenquotient*

$$T(h) = \frac{f(x+h) - f(x-h)}{2h}$$

für $h \neq 0$ eine Approximation an $f'(x)$. Durch Taylorentwicklung um den Punkt x findet man für Funktionen $f \in C^{2m+3}[x-a, x+a]$ und $|h| \leq |a|$

$$\begin{aligned} T(h) &= \frac{1}{2h} \left\{ f(x) + hf'(x) + \frac{h^2}{2!} f''(x) + \cdots + \frac{h^{2m+3}}{(2m+3)!} [f^{(2m+3)}(x) + o(1)] \right. \\ &\quad \left. - f(x) + hf'(x) - \frac{h^2}{2!} f''(x) + \cdots + \frac{h^{2m+3}}{(2m+3)!} [f^{(2m+3)}(x) + o(1)] \right\} \\ &= \tau_0 + \tau_1 h^2 + \cdots + \tau_m h^{2m} + h^{2m+2} \alpha_{m+1}(h) \end{aligned}$$

mit $\tau_0 = f'(x)$, $\tau_k = f^{(2k+1)}(x)/(2k+1)!$, $k = 1, 2, \dots, m+1$, und $\alpha_{m+1}(h) = \tau_{m+1} + o(1)$.

Der *einseitige Differenzenquotient*

$$T(h) := \frac{f(x+h) - f(x)}{h}, \quad h \neq 0,$$

besitzt dagegen eine Entwicklung der Form

$$T(h) = \tau_0 + \tau_1 h + \tau_2 h^2 + \cdots + \tau_m h^m + h^{m+1}(\tau_{m+1} + o(1))$$

mit

$$\tau_k = \frac{f^{(k+1)}(x)}{(k+1)!}, \quad k = 0, 1, 2, \dots, m+1.$$

Es wird sich später zeigen, daß es aus Konvergenzgründen günstiger ist, zentrale Differenzen als Basis von Extrapolationsverfahren zu verwenden, weil in ihrer asymptotischen Entwicklung nur gerade Potenzen von h vorkommen.

Weitere wichtige Beispiele liefern bestimmte Diskretisierungsverfahren zur Lösung von gewöhnlichen Differentialgleichungen (s. Abschnitte 7.2.3 und 7.2.12).

Um ein Diskretisierungsverfahren im Rahmen eines Extrapolationsverfahrens zu verwenden, wählt man eine Folge von Schrittweiten

$$F = \{h_0, h_1, h_2, \dots\}, \quad h_0 > h_1 > h_2 > \dots > 0,$$

und berechnet die zugehörigen $T(h_i)$, $i = 0, 1, 2, \dots$

Für $i \geq k$ bezeichnen wir mit $\tilde{T}_{ik}(h)$ die interpolierenden „Polynome“ der Form (ihre Exponenten werden (3.5.1) entnommen)

$$\tilde{T}_{ik}(h) = b_0 + b_1 h^{\gamma_1} + \dots + b_k h^{\gamma_k},$$

mit

$$\tilde{T}_{ik}(h_j) = T(h_j), \quad j = i - k, i - k + 1, \dots, i,$$

und betrachten ihre Werte

$$T_{ik} := \tilde{T}_{ik}(0)$$

an der Stelle $h = 0$ als Näherungswerte für τ_0 .

Gewöhnlich sind die Exponenten γ_j ganzzahlig, etwa $\gamma_j = j$ oder $\gamma_j = 2j$. Es kommen jedoch auch nichtganzzahlige Exponenten vor (s. Abschnitt 3.7). Auch verwendet man häufig rationale Funktionen statt Polynome zur Extrapolation (s. Bulirsch und Stoer (1964)).

Wir beschränken uns im folgenden der Einfachheit halber auf den häufig vorkommenden Fall, daß die Exponenten γ_j nicht beliebig, sondern Vielfache einer festen Zahl $\gamma > 0$ sind, $\gamma_j = j\gamma$, $j = 1, 2, \dots$, und auf den Fall der Polynomextrapolation. Es sind dann die $\tilde{T}_{i,k}(h)$ Polynome vom Grad k in h^γ . Wir nehmen zunächst $i = k$ an und verwenden die Abkürzungen

$$z := h^\gamma, \quad z_j := h_j^\gamma, \quad j = 0, 1, \dots$$

Wendet man die Lagrangesche Interpolationsformel (2.1.1.3) auf das Polynom

$$\tilde{T}_{kk}(h) = P_k(z) = b_0 + b_1 z + b_2 z^2 + \dots + b_k z^k$$

für $z = 0$ an, so erhält man

$$T_{kk} = P_k(0) = \sum_{j=0}^k c_j P_k(z_j) = \sum_{j=0}^k c_j T(h_j)$$

mit

$$c_j := \prod_{\substack{s=0 \\ s \neq j}}^k \frac{z_s}{z_s - z_j}.$$

Nun gilt

$$(3.5.2) \quad \sum_{j=0}^k c_j z_j^\tau = \begin{cases} 1 & \text{für } \tau = 0, \\ 0 & \text{für } \tau = 1, 2, \dots, k, \\ (-1)^k z_0 z_1 \dots z_k & \text{für } \tau = k + 1. \end{cases}$$

Beweis: Wegen der Lagrangeschen Interpolationsformel und der Eindeutigkeit der Polynominterpolation gilt

$$p(0) = \sum_{j=0}^k c_j p(z_j)$$

für jedes Polynom $p(z)$ vom Grad $\leq k$. Man erhält (3.5.2), wenn man für $p(z)$ nacheinander folgende Polynome wählt:

$$z^\tau, \quad \tau = 0, 1, \dots, k, \quad \text{und } z^{k+1} - (z - z_0)(z - z_1) \cdots (z - z_k). \quad \square$$

Wenn die Schrittweiten h_j genügend stark gegen 0 konvergieren, etwa wenn

$$(3.5.3) \quad 0 < h_{j+1}/h_j \leq b < 1 \quad \text{für alle } j \geq 0,$$

kann (3.5.2) verschärft werden. Es existiert dann eine Konstante C_k , die nur von b abhängt, so daß

$$(3.5.4) \quad \sum_{j=0}^k |c_j| z_j^{k+1} \leq C_k z_0 z_1 \cdots z_k.$$

Wir zeigen dies für den Spezialfall einer geometrischen Folge $\{h_j\}$ mit

$$h_j = h_0 b^j, \quad 0 < b < 1, \quad j = 0, 1, \dots$$

(für den allgemeinen Fall s. Bulirsch und Stoer (1964)). Mit der Abkürzung $\theta := b^\gamma$ gilt

$$z_j^\tau = (h_0 b^j)^{\gamma\tau} = z_0^\tau \theta^{j\tau}.$$

Wegen (3.5.2) gilt für das Polynom

$$P_k(z) = \sum_{j=0}^k c_j z^j$$

die Beziehung

$$P_k(\theta^\tau) = \sum_{j=0}^k c_j \theta^{j\tau} = z_0^{-\tau} \sum_{j=0}^k c_j z_j^\tau = \begin{cases} 1 & \text{für } \tau = 0, \\ 0 & \text{für } \tau = 1, 2, \dots, k, \end{cases}$$

so daß P_k die k verschiedenen Nullstellen θ^τ , $\tau = 1, 2, \dots, k$, besitzt. Wegen $P_k(1) = 1$ folgt daher für $P_k(z)$ die Darstellung

$$P_k(z) = \prod_{l=1}^k \frac{z - \theta^l}{1 - \theta^l}.$$

Die Koeffizienten von $P_k(z)$ haben also alternierendes Vorzeichen, $c_j c_{j+1} < 0$, so daß

$$\begin{aligned} \sum_{j=0}^k |c_j| z_j^{k+1} &= z_0^{k+1} \sum_{j=0}^k |c_j| (\theta^{(k+1)})^j = z_0^{k+1} |P_k(-\theta^{k+1})| \\ &= z_0^{k+1} \prod_{l=1}^k \frac{\theta^{k+1} + \theta^l}{1 - \theta^l} \\ &= z_0^{k+1} \theta^{1+2+\dots+k} \prod_{l=1}^k \frac{1 + \theta^l}{1 - \theta^l} \\ &= C_k(\theta) z_0 z_1 \cdots z_k, \end{aligned}$$

mit

$$C_k = C_k(\theta) := \prod_{l=1}^k \frac{1 + \theta^l}{1 - \theta^l}.$$

Dies zeigt (3.5.4) für geometrische Folgen $\{h_j\}$.

Wir benutzen nun die asymptotische Entwicklung (3.5.1) für $k \leq m$ und finden wegen $z_j = h_j^\gamma$, $\gamma_j = j \gamma$

$$T_{kk} = \sum_{j=0}^k c_j T(h_j) = \sum_{j=0}^k c_j (\tau_0 + \tau_1 z_j + \tau_2 z_j^2 + \cdots + \tau_k z_j^k + \alpha_{k+1}(h_j) z_j^{k+1}),$$

wobei natürlich für $k < m$

$$\alpha_{k+1}(h_j) h_j^{\gamma_{k+1}} := \tau_{k+1} h_j^{\gamma_{k+1}} + \cdots + \tau_m h_j^{\gamma_m} + \alpha_{m+1} h_j^{\gamma_{m+1}}.$$

Aus (3.5.2) folgt daher sofort

$$(3.5.5) \quad T_{kk} = \tau_0 + \sum_{j=0}^k c_j \alpha_{k+1}(h_j) z_j^{k+1}.$$

Die Beziehungen (3.5.2) und die Abschätzungen (3.5.4) geben so schließlich für Schrittfolgen $\{h_j\}$ mit (3.5.3)

$$(3.5.6) \quad |T_{mm} - \tau_0| \leq M_{m+1} C_m z_0 z_1 \cdots z_m.$$

Für $k < m$ ist $\alpha_{k+1}(h_j) = \tau_{k+1} + O(h_j^\gamma)$. Es folgt daher aus (3.5.2)–(3.5.5)

$$(3.5.7) \quad T_{kk} - \tau_0 = (-1)^k z_0 z_1 \cdots z_k (\tau_{k+1} + O(h_0^\gamma)).$$

Im allgemeinen Fall $i \geq k$ erhält man entsprechende Abschätzungen für den Fehler von T_{ik} einfach dadurch, daß man in (3.5.6), (3.5.7) $z_0, z_1,$

$\dots, z_k$ durch $z_{i-k}, z_{i-k+1}, \dots, z_i$, und h_0 durch h_{i-k} ersetzt, weil T_{ik} durch Extrapolation aus $T(h_j)$, $j = i - k, i - k + 1, \dots, i$, gewonnen wird. Man erhält so unter Berücksichtigung von $z_j = h_j^\gamma$ allgemein für Schrittweitenfolgen $\{h_j\}$ mit (3.5.3), für $i \geq k$ und $k = m$

$$(3.5.8) \quad |T_{im} - \tau_0| \leq M_{m+1} C_m h_{i-m}^\gamma h_{i-m+1}^\gamma \cdots h_i^\gamma,$$

und für $k < m$

$$(3.5.9) \quad T_{ik} - \tau_0 = (-1)^k h_{i-k}^\gamma h_{i-k+1}^\gamma \cdots h_i^\gamma (\tau_{k+1} + O(h_{i-k}^\gamma)).$$

Also gilt für festes $k \leq m$ asymptotisch für $i \rightarrow \infty$

$$T_{ik} - \tau_0 = O(h_{i-k}^{(k+1)\gamma}),$$

d. h. die Elemente T_{ik} der $(k+1)$ -ten Spalte des (3.4.4) entsprechenden Tableaus konvergieren gegen τ_0 wie bei einem Verfahren der Ordnung $(k+1)\gamma$. Je größer also γ ist, desto bessere Resultate liefert der Extrapolationsalgorithmus. Darin liegt die Bedeutung derjenigen Diskretisierungsverfahren, deren asymptotische Entwicklung (3.5.1) nur gerade h -Potenzen enthält [wie z. B. die Entwicklung (3.4.1) der Trapezsumme oder des zentralen Differenzenquotienten in diesem Abschnitt].

Aus der Fehlerformel (3.5.9) kann man ferner schließen, daß der Fehler $T_{ik} = \tau_0$ für festes $k < m$ für genügend großes i konstantes Vorzeichen besitzt, falls $\tau_{k+1} \neq 0$, daß also T_{ik} schließlich für $i \rightarrow \infty$ monoton gegen τ_0 konvergiert. Für genügend großes i gilt dann wegen (3.5.9)

$$0 < \frac{T_{i+1,k} - \tau_0}{T_{i,k} - \tau_0} \approx \frac{h_{i+1}^\gamma}{h_{i-k}^\gamma} \leq b^{\gamma(k+1)}.$$

In vielen Fällen ist nun $b^{\gamma(k+1)} < \frac{1}{2}$. Für die Fehler der Größen

$$U_{ik} := 2T_{i+1,k} - T_{ik}$$

folgt

$$U_{ik} - \tau_0 = 2(T_{i+1,k} - \tau_0) - (T_{ik} - \tau_0)$$

und daher wegen $s := \text{sign}(T_{i+1,k} - \tau_0) = \text{sign}(T_{ik} - \tau_0)$ die Abschätzung

$$s(U_{ik} - \tau_0) = 2|T_{i+1,k} - \tau_0| - |T_{ik} - \tau_0| \approx -|T_{ik} - \tau_0| < 0.$$

Ein Vergleich der Fehler von T_{ik} und U_{ik} zeigt daher, daß für genügend großes i und festes k die Größen $T_{ik} - \tau_0$, $U_{ik} - \tau_0$ ungefähr gleich großen Betrag aber entgegengesetztes Vorzeichen haben, daß also T_{ik} und U_{ik} für genügend großes i des gesuchten Resultat τ_0 einschließen und von verschiedenen Seiten her monoton gegen τ_0 konvergieren. Man kann dieses Verhalten

der T_{ik} und U_{ik} benutzen, um die Größe des Fehlers $T_{ik} - \tau_0$ bzw. $U_{ik} - \tau_0$ abzuschätzen, und damit ein Abbruchkriterium gewinnen.

Beispiel: Der exakte Wert des Integrals

$$\int_0^{\pi/2} 5(e^\pi - 2)^{-1} e^{2x} \cos x \, dx$$

ist 1. Verwendet man als Polynom-Extrapolationsverfahren das Verfahren von Romberg (s. 3.4), so erhält man bei 12-stelliger Rechnung folgende T_{ik} , U_{ik} für $0 \leq i \leq k \leq 6$, $0 \leq k \leq 3$:

i	T_{i0}	T_{i1}	T_{i2}	T_{i3}
0	0.185 755 068 924			
1	0.724 727 335 089	0.904 384 757 145		
2	0.925 565 035 158	0.992 510 935 182	0.998 386 013 717	
3	0.981 021 630 069	0.999 507 161 706	0.999 973 576 808	0.999 998 776 222
4	0.995 232 017 388	0.999 968 813 161	0.999 999 589 925	1.000 000 002 83
5	0.998 806 537 974	0.999 998 044 836	0.999 999 993 614	1.000 000 000 02
6	0.999 701 542 775	0.999 999 877 709	0.999 999 999 901	1.000 000 000 00
i	U_{i0}	U_{i1}	U_{i2}	U_{i3}
0	1.263 699 601 26			
1	1.126 402 735 23	1.080 637 113 22		
2	1.036 478 224 98	1.006 503 388 23	1.001 561 139 90	
3	1.009 442 404 71	1.000 430 464 62	1.000 025 603 04	1.000 001 229 44
4	1.002 381 058 56	1.000 027 276 51	1.000 000 397 30	0.999 999 997 211
5	1.000 596 547 58	1.000 001 710 58	1.000 000 006 19	0.999 999 999 978
6	1.000 149 217 14	1.000 000 107 00	1.000 000 000 09	1.000 000 000 00

3.6 Die Gaußsche Integrationsmethode

In diesem Abschnitt betrachten wir allgemeiner als bisher Integrale der Form

$$I(f) = \int_a^b \omega(x) f(x) dx,$$

wobei $\omega(x)$ eine gegebene nichtnegative *Gewichtsfunktion* auf dem Intervall $[a, b]$ ist. Dabei lassen wir auch unendliche Intervalle wie $[0, \infty]$ oder $[-\infty, \infty]$ zu. Die Gewichtsfunktion soll folgende Voraussetzungen erfüllen

(3.6.1)

- $\omega(x) \geq 0$ ist auf $[a, b]$ nichtnegativ und meßbar.
- Alle Momente $\mu_k := \int_a^b x^k \omega(x) dx$, $k = 0, 1, \dots$, existieren und sind endlich.

c) Für jedes Polynom $s(x)$ mit $\int_a^b \omega(x)s(x)dx = 0$ und $s(x) \geq 0$ für $x \in [a, b]$ gilt $s(x) \equiv 0$.

Diese Voraussetzungen sind z. B. für Gewichtsfunktionen $\omega(x)$ erfüllt, die auf $[a, b]$ positiv und stetig sind. (3.6.1c) ist mit der Bedingung $\mu_0 > 0$ äquivalent (siehe Aufgabe 12).

Wir betrachten wieder Integrationsregeln der Form

$$(3.6.2) \quad \tilde{I}(f) := \sum_{i=1}^n w_i f(x_i)$$

Bereits die Formeln von Newton-Cotes (s. Abschnitt 3.1) hatten diese Gestalt, nur waren dort die Abszissen x_i in $[a, b]$ äquidistant gewählt. Wir wollen uns von dieser Einschränkung befreien und versuchen, die w_i und x_i so zu wählen, daß der Integrationsfehler

$$\tilde{I}(f) - I(f)$$

von $\tilde{I}$ für Polynome möglichst hohen Grades verschwindet, d. h. die Ordnung von $\tilde{I}$ möglichst groß ist. Dies ist möglich, und man erhält so die Gaußschen Integrationsmethoden oder die Gaußschen Quadraturformeln [s. z. B. Stroud und Secrest (1966)]. Wir werden sehen, daß diese Methoden eindeutig bestimmt sind, die Ordnung $2n - 1$ besitzen und $w_i > 0$ sowie $a < x_i < b$ für $i = 1, 2, \dots, n$ gilt. Um dies zu beweisen benötigen wir einige elementare Eigenschaften von orthogonalen Polynomen.

Sei zunächst

$$\bar{\Pi}_j := \{p \in \Pi_j \mid p(x) = x^j + a_1 x^{j-1} + \dots + a_j\}$$

die Menge aller *normierten* reellen Polynome vom Grad j und wie bisher Π_j der lineare Raum aller reellen Polynome vom Grad $\leq j$. Weiter führen wir das Skalarprodukt

$$(f, g) := \int_a^b \omega(x) f(x) g(x) dx$$

auf dem linearen Raum $L^2[a, b]$ aller reellen Funktionen f ein, für die das Integral

$$(f, f) = \int_a^b \omega(x) f(x)^2 dx$$

existiert und endlich ist. Die Funktionen $f, g \in L^2[a, b]$ heißen *orthogonal*, falls $(f, g) = 0$. Der folgende Satz zeigt die Existenz von *Orthogonalpolynomen* zur Gewichtsfunktion $\omega(x)$:

(3.6.3) **Satz:** Es gibt für $j = 0, 1, \dots$, eindeutig bestimmte Polynome $p_j \in \tilde{\Pi}_j$ mit

$$(3.6.4) \quad (p_i, p_k) = 0 \quad \text{für } i \neq k.$$

Diese Polynome genügen der Rekursionsformel

$$(3.6.5) \quad \begin{aligned} a) \quad & p_0(x) \equiv 1, \\ b) \quad & p_{i+1}(x) \equiv (x - \delta_{i+1})p_i(x) - \gamma_{i+1}^2 p_{i-1}(x) \quad \text{für } i \geq 0, \end{aligned}$$

wobei $p_{-1}(x) \equiv 0$ und⁸

$$(3.6.6) \quad \begin{aligned} a) \quad & \delta_{i+1} := (x p_i, p_i) / (p_i, p_i) \quad \text{für } i \geq 0, \\ b) \quad & \gamma_{i+1}^2 := \begin{cases} 1 & \text{für } i = 0, \\ (p_i, p_i) / (p_{i-1}, p_{i-1}) & \text{für } i \geq 1. \end{cases} \end{aligned}$$

Beweis: Die Polynome können mit Hilfe des Schmidtschen Orthogonalisierungsverfahrens rekursiv konstruiert werden. Offensichtlich ist $p_0(x) \equiv 1$. Wir nehmen induktiv an, daß bereits eindeutig bestimmte Polynome $p_j \in \tilde{\Pi}_j$ für alle $j \leq i$ mit den angegebenen Eigenschaften existieren. Wir haben zu zeigen, daß es dann ein eindeutig bestimmtes Polynom $p_{i+1} \in \tilde{\Pi}_{i+1}$ gibt mit

$$(3.6.7) \quad (p_{i+1}, p_j) = 0 \quad \text{für } j \leq i$$

und daß dieses Polynom der Beziehung (3.6.5b) genügt. Wegen der Normierungsbedingung für die Polynome aus $\tilde{\Pi}_j$, läßt sich jedes Polynom $p_{i+1} \in \tilde{\Pi}_{i+1}$ in der Form

$$p_{i+1}(x) \equiv (x - \delta_{i+1})p_i(x) + c_{i-1}p_{i-1}(x) + c_{i-2}p_{i-2}(x) + \dots + c_0p_0(x)$$

mit eindeutig bestimmten Koeffizienten $\delta_{i+1}, c_k, k \leq i-1$, schreiben. Wegen $(p_j, p_k) = 0$ für alle $j \neq k, j, k \leq i$, gilt (3.6.7) genau dann, wenn

$$(3.6.8) \quad \begin{aligned} a) \quad & (p_{i+1}, p_i) = (x p_i, p_i) - \delta_{i+1}(p_i, p_i) = 0, \\ b) \quad & (p_{i+1}, p_{j-1}) = (x p_{j-1}, p_i) + c_{j-1}(p_{j-1}, p_{j-1}) = 0 \quad \text{für } j \leq i. \end{aligned}$$

Diese Gleichungen sind nach δ_{i+1}, c_{j-1} auflösbar, weil $p_i \neq 0, p_{j-1} \neq 0$ und daher wegen (3.6.1) auch $(p_i, p_i) > 0, (p_{j-1}, p_{j-1}) > 0$ gilt. Aus (3.6.8a) folgt sofort die Formel (3.6.6a) für δ_{i+1} . Weiter ist für $j \leq i$ nach Induktionsvoraussetzung

$$p_j(x) \equiv (x - \delta_j)p_{j-1}(x) - \gamma_j^2 p_{j-2}(x)$$

⁸ $(x p_i, p_i)$ steht für $\int_a^b \omega(x) x p_i^2(x) dx$.

und es folgt durch Auflösen nach x $p_{j-1}(x)$ sofort

$$(xp_{j-1}, p_i) = (p_j, p_i) \quad \text{für } j \leq i.$$

(3.6.8)b) ergibt damit

$$c_{j-1} = -\frac{(p_j, p_i)}{(p_{j-1}, p_{j-1})} = \begin{cases} -\gamma_{i+1}^2 & \text{für } j = i, \\ 0 & \text{für } j < i. \end{cases}$$

Damit ist (3.6.3) bewiesen. $\square$

Da sich jedes Polynom $p \in \Pi_k$ als Linearkombination der p_i , $i \leq k$, schreiben läßt, folgt

(3.6.9) **Korollar:** Es ist $(p, p_n) = 0$ für alle $p \in \Pi_{n-1}$.

(3.6.10) **Satz:** Die Nullstellen x_i , $i = 1, \dots, n$, von p_n sind reell, einfach und liegen alle im offenen Intervall (a, b) .

Beweis: Es seien $a < x_1 < \dots < x_l < b$ die Nullstellen von p_n in (a, b) , an denen p_n sein Vorzeichen wechselt, d.h. die reellen Nullstellen ungerader Vielfachheit in (a, b) . Wir zeigen $l = n$. Andernfalls hätte das Polynom $q(x) := \prod_{j=1}^l (x - x_j) \in \tilde{\Pi}_l$ den Grad $l < n$, so daß wegen (3.6.9) $(p_n, q) = 0$ gilt. Nun ändert $p_n(x)q(x)$ auf (a, b) nach Definition von q sein Vorzeichen nicht, so daß $(p_n, q) = \int_a^b \omega(x) p_n(x) q(x) dx \neq 0$ gilt, im Widerspruch zu $(p_n, q) = 0$. Also ist $l = n$, d.h. alle Nullstellen von p_n sind reell, einfach und liegen in (a, b) . $\square$

Ferner hat man den

(3.6.11) **Satz:** Für beliebige t_i mit $t_1 < t_2 < \dots < t_n$ ist die $n \times n$ -Matrix

$$A := \begin{bmatrix} p_0(t_1) & \dots & p_0(t_n) \\ \vdots & & \vdots \\ p_{n-1}(t_1) & \dots & p_{n-1}(t_n) \end{bmatrix}$$

nichtsingulär.

Beweis: Wäre A singulär, so gäbe es einen Vektor $c^T = (c_0, \dots, c_{n-1})$, $c \neq 0$, mit $c^T A = 0$, d.h. das Polynom

$$q(x) := \sum_{i=0}^{n-1} c_i p_i(x)$$

vom Grad $q \leq n-1$ hätte $t_1, \dots, t_n$ als n verschiedene Nullstellen, also müßte $q(x)$ identisch verschwinden. Da die $p_i(\cdot)$ linear unabhängig sind, folgt aus $q(x) \equiv 0$ sofort der Widerspruch $c = 0$. $\square$

Satz (3.6.11) ist übrigens damit äquivalent, daß die Interpolationsaufgabe, eine Funktion p der Form

$$p(x) \equiv \sum_{i=0}^{n-1} c_i p_i(x)$$

mit $p(t_i) = f_i$, $i = 1, 2, \dots, n$, zu finden, stets eindeutig lösbar ist. Funktionssysteme mit dieser Eigenschaft, wie hier $p_0, p_1, \dots$, heißen *Tschebyscheff-Systeme*, die Bedingung des Satzes *Haar-Bedingung*.

Wir kommen nun zu dem Hauptresultat:

(3.6.12) **Satz:** 1) Es seien $x_1, \dots, x_n$ die Nullstellen von p_n und $w_1, \dots, w_n$ die Lösung des linearen Gleichungssystems

$$(3.6.13) \quad \sum_{i=1}^n p_k(x_i) w_i = \begin{cases} (p_0, p_0) & \text{falls } k = 0, \\ 0 & \text{falls } k = 1, 2, \dots, n-1. \end{cases}$$

Dann gilt $w_i > 0$ für $i = 1, 2, \dots, n$, sowie

$$(3.6.14) \quad \int_a^b \omega(x) p(x) dx = \sum_{i=1}^n w_i p(x_i)$$

für alle Polynome $p \in \Pi_{2n-1}$. Die Zahlen w_i heißen „Gewichte“.

2) Ist umgekehrt für gewisse reelle Zahlen w_i, x_i , $i = 1, \dots, n$, (3.6.14) für alle $p \in \Pi_{2n-1}$ richtig, so sind die x_i die Nullstellen von p_n und die w_i erfüllen (3.6.13).

3) Es gibt keine reellen Zahlen x_i, w_i , $i = 1, \dots, n$, so daß (3.6.14) für alle Polynome $p \in \Pi_{2n}$ gilt.

Beweis: 1) Nach Satz (3.6.10) sind die Nullstellen x_i , $i = 1, \dots, n$, von p_n verschiedene reelle Zahlen in (a, b) , so daß nach (3.6.11) die Matrix

$$(3.6.15) \quad A := \begin{bmatrix} p_0(x_1) & \dots & p_0(x_n) \\ \vdots & & \vdots \\ p_{n-1}(x_1) & \dots & p_{n-1}(x_n) \end{bmatrix}$$

nichtsingulär ist und deshalb das Gleichungssystem (3.6.13) genau eine Lösung w besitzt. Sei nun $p \in \Pi_{2n-1}$ beliebig. Dann läßt sich p in der Form

$$(3.6.16) \quad p(x) \equiv p_n(x)q(x) + r(x)$$

schreiben, wobei q, r Polynome aus Π_{n-1} sind und daher die Gestalt

$$q(x) \equiv \sum_{k=0}^{n-1} \alpha_k p_k(x), \quad r(x) \equiv \sum_{k=0}^{n-1} \beta_k p_k(x)$$

haben. Es folgt wegen (3.6.9) und $p_0(x) \equiv 1$,

$$\int_a^b \omega(x) p(x) dx = (p_n, q) + (r, p_0) = \beta_0(p_0, p_0).$$

Andererseits ist wegen (3.6.16), $p_n(x_i) = 0$, und wegen (3.6.13)

$$\sum_{i=1}^n w_i p(x_i) = \sum_{i=1}^n w_i r(x_i) = \sum_{k=0}^{n-1} \beta_k \left(\sum_{i=1}^n w_i p_k(x_i) \right) = \beta_0(p_0, p_0),$$

d. h. (3.6.14) ist erfüllt.

Setzt man die speziellen Polynome

$$(3.6.17) \quad \tilde{p}_i(x) := \prod_{\substack{j=1 \\ j \neq i}}^n (x - x_j)^2 \in \Pi_{2n-2}, \quad i = 1, \dots, n,$$

in (3.6.14) ein, folgt sofort $w_i > 0$ für $i = 1, \dots, n$. Damit ist Teil 1) bewiesen.

Wir zeigen als nächstes 3). Die Annahme, daß es Zahlen $w_i, x_i, i = 1, \dots, n$, gibt, so daß (3.6.14) auch für alle $p \in \Pi_{2n}$ richtig ist, führt mit $\bar{p}(x) := \prod_{j=1}^n (x - x_j)^2 \in \Pi_{2n}$ sofort zu einem Widerspruch zu (3.6.1),

$$0 < \int_a^b \omega(x) \bar{p}(x) dx = \sum_{i=1}^n w_i \bar{p}(x_i) = 0.$$

Zum Beweis von 2) wenden wir (3.6.14) auf $p = p_k, k = 0, 1, \dots, n-1$, an und finden

$$\begin{aligned} \sum_{i=1}^n w_i p_k(x_i) &= \int_a^b \omega(x) p_k(x) dx \\ &= (p_k, p_0) = \begin{cases} (p_0, p_0), & \text{falls } k = 0, \\ 0, & \text{falls } 1 \leq k \leq n-1, \end{cases} \end{aligned}$$

d. h. die w_i müssen (3.6.13) erfüllen.

Wählt man $p(x) := p_k(x) p_n(x), k = 0, \dots, n-1$, in (3.6.14), so folgt

$$0 = (p_k, p_n) = \sum_{i=1}^n w_i p_n(x_i) p_k(x_i), \quad k = 0, \dots, n-1,$$

d. h., der Vektor $c := (w_1 p_n(x_1), \dots, w_n p_n(x_n))^T$ erfüllt das Gleichungssystem

$$Ac = 0,$$

wobei A die Matrix (3.6.15) ist. Aus 3) folgt sofort $x_1 < \dots < x_n$; damit ist nach (3.6.11) A nichtsingulär, also muß $c = 0$ sein, d. h.

$$w_i p_n(x_i) = 0 \quad \text{für } i = 1, \dots, n.$$

Wie eben folgt $w_i > 0$ durch Einsetzen von $p = \bar{p}_i$ (3.6.17) in (3.6.14), und daher schließlich $p_n(x_i) = 0$, $i = 1, \dots, n$. Damit ist auch Teil 2) bewiesen. $\square$

Für die in der Praxis wichtigste Gewichtsfunktion $\omega(x) \equiv 1$ und das Intervall $[-1, 1]$ stammen die Resultate des letzten Satzes von Gauß. Die zugehörigen Orthogonalpolynome

$$(3.6.18) \quad p_k(x) := \frac{k!}{(2k)!} \frac{d^k}{dx^k} (x^2 - 1)^k, \quad k = 0, 1, \dots,$$

sind bis auf einen Normierungsfaktor gerade die *Legendre-Polynome*. (Für diese p_k ist offensichtlich $p_k \in \bar{\Pi}_k$ und durch partielle Integration verifiziert man sofort $(p_i, p_k) = 0$ für $i \neq k$). Im folgenden sind einige w_i , x_i für diesen Spezialfall tabelliert [für weitere Werte siehe Abramowitz and Stegun (1964), *Handbook of mathematical functions*]:

n	w_i	x_i
1	$w_1 = 2$	$x_1 = 0$
2	$w_1 = w_2 = 1$	$x_2 = -x_1 = 0.577\ 350\ 2692 \dots$
3	$w_1 = w_3 = \frac{5}{9}$ $w_2 = \frac{8}{9}$	$x_3 = -x_1 = 0.774\ 596\ 6692 \dots$ $x_2 = 0$
4	$w_1 = w_4 = 0.347\ 854\ 8451 \dots$ $w_2 = w_3 = 0.652\ 145\ 1549 \dots$	$x_4 = -x_1 = 0.861\ 136\ 3116 \dots$ $x_3 = -x_2 = 0.339\ 981\ 0436 \dots$
5	$w_1 = w_5 = 0.236\ 926\ 8851 \dots$ $w_2 = w_4 = 0.478\ 628\ 6705 \dots$ $w_3 = \frac{128}{225} = 0.568\ 888\ 8889 \dots$	$x_5 = -x_1 = 0.906\ 179\ 8459 \dots$ $x_4 = -x_2 = 0.538\ 469\ 3101 \dots$ $x_3 = 0$

Weitere für die Gewinnung von Integrationsformeln praktisch wichtige Beispiele sind in folgender Tabelle ausgeführt:

$[a, b]$	$\omega(x)$	Name der Orthogonalpolynome
$[-1, 1]$	$(1 - x^2)^{-1/2}$	$T_n(x)$, Tschebyscheff-Polynome
$[0, \infty]$	e^{-x}	$L_n(x)$, Laguerre-Polynome
$[-\infty, \infty]$	e^{-x^2}	$H_n(x)$, Hermite-Polynome

Es bleibt die Frage, wie man im allgemeinen Fall die Zahlen w_i , x_i bestimmt. Wir wollen dieses Problem unter der Voraussetzung betrachten, daß die Koeffizienten δ_i , γ_i der Rekursionsformel (3.6.5) bekannt sind (eine Bestimmung der δ_i , γ_i ist im übrigen ein numerisch recht schwieriges Problem. Methoden dazu findet man in Golub und Welsch (1969) und in Gautschi (1968, 1970)).

Die Theorie der Orthogonalpolynome ist eng mit reellen Tridiagonalmatrizen

$$(3.6.19) \quad J_n = \begin{bmatrix} \delta_1 & \gamma_2 & & & \\ \gamma_2 & \delta_2 & \cdot & & \\ & \cdot & \cdot & \cdot & \\ & & \cdot & \cdot & \gamma_n \\ & & & \gamma_n & \delta_n \end{bmatrix}$$

und ihren Hauptuntermatrizen

$$J_j := \begin{bmatrix} \delta_1 & \gamma_2 & & & \\ \gamma_2 & \delta_2 & \cdot & & \\ & \cdot & \cdot & \cdot & \\ & & \cdot & \cdot & \gamma_j \\ & & & \gamma_j & \delta_j \end{bmatrix}$$

verknüpft. Solche Matrizen werden in den Abschnitten 5.5, 5.6 und 6.6.1 näher studiert. In 5.5 wird gezeigt, daß die charakteristischen Polynome $p_j(x) \equiv \det(J_j - xI)$ der J_j den Rekursionsformeln (3.6.5) mit den Koeffizienten δ_j , γ_j genügen. Insbesondere ist p_n das charakteristische Polynom von J_n , und es gilt

(3.6.20) **Satz:** Die Nullstellen x_i , $i = 1, 2, \dots, n$, des n -ten Orthogonalpolynoms p_n sind die Eigenwerte der Tridiagonalmatrix J_n (3.6.19).

Eigenwerte von Tridiagonalmatrizen können z.B. mit der Bisektionsmethode von Abschnitt 5.6 oder mit dem QR -Verfahren (s. Abschnitte 6.6.4, 6.6.5) berechnet werden. Für die Gewichte w_i gilt [s. Szegő (1959), Golub und Welsch (1969)]:

(3.6.21) **Satz:** Es ist

$$w_k = (v_1^{(k)})^2, \quad k = 1, \dots, n,$$

wenn $v^{(k)} = (v_1^{(k)}, \dots, v_n^{(k)})^T$ Eigenvektor zum Eigenwert x_k von J_n (3.6.19),

$$J_n v^{(k)} = x_k v^{(k)},$$

mit der Normierung $(v^{(k)})^T v^{(k)} = (p_0, p_0) = \int_a^b \omega(x) dx$ ist.

Beweis: Man bestätigt leicht, daß der Vektor von Polynomen

$$\tilde{v}(x) := (\rho_0 p_0(x), \rho_1 p_1(x), \dots, \rho_{n-1} p_{n-1}(x))^T$$

mit (wegen (3.6.6) gilt $\gamma_j \neq 0$)

$$\rho_j := 1/(\gamma_1 \gamma_2 \dots \gamma_{j+1}) \quad \text{für } j = 0, 1, \dots, n-1,$$

wegen (3.6.5) folgender Gleichung genügt

$$(J_n - xI)\tilde{v}(x) \equiv -\rho_{n-1} p_n(x) e_n, \quad e_n := (0, \dots, 0, 1)^T \in \mathbb{R}^n.$$

Beispielsweise ist wegen $\gamma_n \rho_{n-2} = \gamma_n^2 \rho_{n-1}$ die letzte dieser n Gleichungen äquivalent mit

$$\begin{aligned} & \gamma_n \rho_{n-2} p_{n-2}(x) + (\delta_n - x) \rho_{n-1} p_{n-1}(x) \\ & \equiv \rho_{n-1} [\gamma_n^2 p_{n-2}(x) + (\delta_n - x) p_{n-1}(x)] \\ & \equiv -\rho_{n-1} p_n(x), \end{aligned}$$

die sofort aus (3.6.5) für $i = n-1$ folgt. Setzt man für x die Nullstellen x_k , $k = 1, 2, \dots, n$, von $p_n(x)$ ein, so folgt sofort, daß die Vektoren

$$\tilde{v}^{(k)} := \tilde{v}(x_k), \quad k = 1, \dots, n$$

nicht verschwinden (wegen $\rho_0 = 1$, $p_0(x) \equiv 1$ gilt $\tilde{v}_1(x) \equiv 1$) und Eigenvektoren von J_n zum Eigenwert x_k sind, $J_n \tilde{v}^{(k)} = x_k \tilde{v}^{(k)}$.

Ferner ist das Gleichungssystem (3.6.13) für die w_i wegen $\rho_j \neq 0$, $j = 0, 1, \dots, n-1$, äquivalent mit

$$(3.6.22) \quad (\tilde{v}^{(1)}, \tilde{v}^{(2)}, \dots, \tilde{v}^{(n)})w = (p_0, p_0) \cdot e_1,$$

wobei $w := (w_1, w_2, \dots, w_n)^T$, $e_1 := (1, 0, \dots, 0)^T$.

Eigenvektoren von symmetrischen Matrizen zu verschiedenen Eigenwerten sind orthogonal zueinander. Wegen $x_i \neq x_k$ für $i \neq k$ folgt daher aus (3.6.22) durch Linksmultiplikation mit $\tilde{v}^{(k)T}$

$$(3.6.23) \quad (\tilde{v}^{(k)T} \tilde{v}^{(k)})w_k = (p_0, p_0) \tilde{v}^{(k)T} e_1 = (p_0, p_0),$$

da $\tilde{v}^{(k)T} e_1 = \tilde{v}_1^{(k)} = 1$.

Wegen $\tilde{v}_1^{(k)} = 1$ folgt $v_1^{(k)} \tilde{v}^{(k)} = v^{(k)}$ für den normierten Eigenvektor $v^{(k)}$. Multipliziert man (3.6.23) mit $(v_1^{(k)})^2$, so erhält man daher

$$v^{(k)T} v^{(k)} w_k = (v_1^{(k)})^2 (p_0, p_0),$$

also $w_k = (v_1^{(k)})^2$ wegen $v^{(k)T} v^{(k)} = (p_0, p_0)$. □

Die interessierende erste Komponente $v_1^{(k)}$ des Eigenvektors $v^{(k)}$ und damit auch w_k kann bei dem QR -Verfahren zur Bestimmung der Eigenwerte leicht mitberechnet werden [s. Golub, Welsch (1969)].

Wir wollen schließlich noch eine Abschätzung für den Fehler der Gaußschen Integrationsmethode angeben:

(3.6.24) **Satz:** Für $f \in C^{2n}[a, b]$ gilt

$$\int_a^b \omega(x) f(x) dx - \sum_{i=1}^n w_i f(x_i) = \frac{f^{(2n)}(\xi)}{(2n)!} (p_n, p_n)$$

mit einem ξ aus (a, b) .

Beweis: Man betrachte die Lösung $h \in \Pi_{2n-1}$ des Hermiteschen Interpolationsproblems (s. Abschnitt 2.1.5)

$$h(x_i) = f(x_i), \quad h'(x_i) = f'(x_i), \quad i = 1, 2, \dots, n.$$

Wegen $\text{Grad } h < 2n$ und Satz 3.6.12 folgt

$$\int_a^b \omega(x) h(x) dx = \sum_{i=1}^n w_i h(x_i) = \sum_{i=1}^n w_i f(x_i).$$

Also besitzt der Integrationsfehler die Integraldarstellung

$$\int_a^b \omega(x) f(x) dx - \sum_{i=1}^n w_i f(x_i) = \int_a^b \omega(x) (f(x) - h(x)) dx.$$

Wegen Satz 2.1.5.9 und weil die x_k die Nullstellen von p_n sind, gilt

$$f(x) - h(x) = \frac{f^{(2n)}(\zeta)}{(2n)!} (x - x_1)^2 \cdots (x - x_n)^2 = \frac{f^{(2n)}(\zeta)}{(2n)!} p_n^2(x)$$

für ein $\zeta = \zeta(x)$ in dem kleinsten Intervall $I[x, x_1, \dots, x_n]$, das x und alle x_k enthält. Weiter ist die Funktion

$$\frac{f^{(2n)}(\zeta(x))}{(2n)!} = \frac{f(x) - h(x)}{p_n^2(x)}$$

stetig auf $[a, b]$; der Mittelwertsatz der Integralrechnung ergibt daher

$$\begin{aligned} \int_a^b \omega(x) (f(x) - h(x)) dx &= \frac{1}{(2n)!} \int_a^b \omega(x) f^{(2n)}(\zeta(x)) p_n^2(x) dx \\ &= \frac{f^{(2n)}(\xi)}{(2n)!} (p_n, p_n) \end{aligned}$$

für ein $\xi \in (a, b)$. □

Vergleicht man die verschiedenen Integrationsmethoden (Newton-Cotes-Formeln, Extrapolationsverfahren, Gaußsche Methode) miteinander, so stellt man zunächst fest, daß bei gleichem Rechenaufwand (gemessen an der Zahl der Funktionsauswertungen) die Gaußsche Methode die höchste Ordnung besitzt und vermutlich deshalb die genauesten Resultate liefert. Wenn man zu einer gewünschten Genauigkeit ε wüßte, welches n man zu nehmen hätte, um mit der Gauß-Formel zum Index n ein bestimmtes Integral $\int_a^b f(x)dx$ mit der Genauigkeit ε zu approximieren, wäre die Gauß-Methode sicherlich den anderen Methoden überlegen. Leider ist es aber meistens unmöglich, etwa mittels der Fehlerformel in Satz 3.6.24 ein passendes n zu finden, da es in der Regel sehr schwierig ist, eine vernünftige Abschätzung für $f^{(2n)}(\xi)$, $a \leq \xi \leq b$, anzugeben. Deshalb wendet man gewöhnlich die Gauß-Formeln für wachsende Werte n so lange an, bis die Näherungswerte für das Integral mit der gewünschten Genauigkeit übereinstimmen. Dabei ist es sehr nachteilig, daß anders als bei Extrapolationsverfahren die für ein n berechneten Funktionswerte nicht für $n + 1$ wiederverwendet werden können, so daß die theoretischen Vorteile der Gauß-Integration bald verloren gehen. Es gibt jedoch Verfahren [s. z. B. Kronrod (1965)], bei denen diese Nachteile des Gauß-Verfahrens weitgehend vermieden werden. In Piessens et al. (1983) findet man eine Sammlung von FORTRAN-Programmen zur Integration von Funktionen.

3.7 Integrale mit Singularitäten

Die bisher behandelten Integrationsmethoden zur Berechnung von Integralen

$$\int_a^b f(x)dx$$

setzen gewöhnlich voraus, daß der Integrand auf dem abgeschlossenen Intervall $[a, b]$ genügend oft differenzierbar ist. Nun gibt es in der Praxis oft Probleme, bei denen der Integrand an den Intervallenden oder an isolierten Punkten im Inneren des Intervalls $[a, b]$ diese Voraussetzung nicht erfüllt. Häufig kann man sich dann folgendermaßen helfen:

1) $f(x)$ sei eine auf den Teilintervallen $[a_i, a_{i+1}]$, $i = 1, \dots, m$, mit $a = a_1 < a_2 < a_3 \dots < a_{m+1} = b$ hinreichend oft stetig differenzierbare Funktion. Setzt man $f_i(x) := f(x)$ für $x \in [a_i, a_{i+1}]$ und definiert man die Ableitungen von f_i für a_i als rechts- bzw. für a_{i+1} als linksseitige Grenzwerte der Ableitungen von f , so erfüllt f_i auf $[a_i, a_{i+1}]$ die üblichen Differenzierbarkeitsvoraussetzungen. Man sollte deshalb die f_i separat integrieren und die Teilintegrale summieren

$$\int_a^b f(x) dx = \sum_{i=1}^m \int_{a_i}^{a_{i+1}} f_i(x) dx.$$

2) Für ein $\tilde{x} \in [a, b]$ mögen auch die einseitigen Grenzwerte der Ableitungen von $f(x)$ nicht existieren, z. B. $f(x) = \sqrt{x} \sin x$, $\tilde{x} = a = 0$, $b > 0$. Hier läßt sich $f''(0)$ für $\tilde{x} = 0$ nicht einmal einseitig stetig erklären. Es führt dann oft eine Substitution zum Ziel; in unserem Falle ergibt sich mit $t := \sqrt{x}$

$$\int_0^b \sqrt{x} \sin x \, dx = \int_0^{\sqrt{b}} 2t^2 \sin t^2 \, dt.$$

Der neue Integrand ist jetzt auf $[0, \sqrt{b}]$ beliebig oft differenzierbar.

3) Eine andere Möglichkeit, diesen Fall zu behandeln, besteht in einer Aufspaltung des Integrals:

$$\int_0^b \sqrt{x} \sin x \, dx = \int_0^\varepsilon \sqrt{x} \sin x \, dx + \int_\varepsilon^b \sqrt{x} \sin x \, dx, \quad \varepsilon > 0.$$

Der zweite Integrand ist beliebig oft in $[\varepsilon, b]$ differenzierbar und das erste Integral läßt sich in eine Reihe entwickeln, die wegen ihrer gleichmäßigen Konvergenz gliedweise integriert werden darf

$$\begin{aligned} \int_0^\varepsilon \sqrt{x} \sin x \, dx &= \int_0^\varepsilon \sqrt{x} \left(x - \frac{x^3}{3!} \pm \dots \right) dx \\ &= \sum_{\nu=0}^{\infty} (-1)^\nu \frac{\varepsilon^{2\nu+5/2}}{(2\nu+1)!(2\nu+5/2)}. \end{aligned}$$

Für genügend kleines ε kann man diese Reihe nach wenigen Schritten abbrechen, ohne einen großen Fehler zu begehen. Die Schwierigkeit liegt in der Wahl von ε : Wählt man ε zu klein, so wirkt sich bei der Berechnung von $\int_\varepsilon^b \sqrt{x} \sin x \, dx$ die Singularität bei $x = 0$ sehr störend auf die Konvergenzgeschwindigkeit des benutzten Verfahrens aus.

4) Eine mit 3) verwandte Möglichkeit besteht darin, von $f(x)$ eine Funktion zu subtrahieren, die dieselbe Singularität wie $f(x)$ besitzt und deren Stammfunktion bekannt ist. In dem obigen Beispiel leistet das die Funktion $x\sqrt{x}$:

$$\begin{aligned} \int_0^b \sqrt{x} \sin x \, dx &= \int_0^b (\sqrt{x} \sin x - \sqrt{x} x) dx + \int_0^b \sqrt{x} x \, dx \\ &= \int_0^b \sqrt{x} (\sin x - x) dx + \frac{2}{5} b^{5/2}. \end{aligned}$$

Der neue Integrand ist dreimal stetig differenzierbar. Wie man jedoch sieht, tritt aber wegen $x \approx \sin x$ für x nahe bei 0 bei der Berechnung des Integranden die Gefahr der Auslöschung auf. Zur Berechnung der Differenz $\sin x - x$ sollte man deshalb für kleines x z. B. die Potenzreihe benutzen

$$\sin x - x = -x^3 \left[\frac{1}{3!} - \frac{1}{5!}x^2 \pm \dots \right].$$

5) Für gewisse Typen von Integralen mit Singularitäten, etwa für

$$I = \int_0^b x^\alpha f(x) dx, \quad \alpha > 0.$$

wo f eine genügend oft auf $[0, b]$ stetig differenzierbare Funktion ist, weiß man, daß die Trapezsumme $T(h)$ statt der in (3.4.1) angegebenen Entwicklung eine asymptotische Entwicklung der Form (3.5.1)

$$T(h) \sim \tau_0 + \tau_1 h^{\gamma_1} + \tau_2 h^{\gamma_2} + \dots$$

mit

$$\{\gamma_i\} = \{1 + \alpha, 2, 2 + \alpha, 4, 4 + \alpha, 6, 6 + \alpha, \dots\}$$

besitzt [s. Bulirsch (1964)]. Statt der in 3.4 beschriebenen Extrapolationsalgorithmen, die auf die „normale“ Folge $\{\gamma_i\} = \{2, 4, 6, \dots\}$ abgestellt sind, könnte man in diesem Fall andere Extrapolationsalgorithmen verwenden, die die geänderte Exponentenfolge berücksichtigen [s. Bulirsch und Stoer (1964)].

6) Folgende Methode führt häufig zu überraschend guten Resultaten: Wenn etwa ein Integral $I = \int_a^b f(x) dx$ zu berechnen ist und der Integrand nur für $x = a$ nicht oder nicht genügend oft differenzierbar ist, so betrachte man für eine monoton fallende Folge, etwa $a_j := a + (b - a)/j$, $j = 1, 2, \dots$, die Teilungale

$$I_j := \int_{a_{j+1}}^{a_j} f(x) dx.$$

Jedes dieser Integrale kann dann mit den Standardmethoden schnell und genau berechnet werden, da f auf $[a_{j+1}, a_j]$ nach Voraussetzung genügend oft differenzierbar ist. Nun ist

$$I = I_1 + I_2 + I_3 + \dots$$

Die Konvergenz dieser unendlichen Reihe kann häufig mittels eines konvergenzbeschleunigenden Verfahrens (etwa Aitkens Δ^2 -Algorithmus, s. 5.10) so stark beschleunigt werden, daß man nur wenige I_j berechnen muß.

Ähnlich kann man auch bei uneigentlichen Integralen vorgehen, indem man eine geeignete divergente monoton wachsende Folge a_j wählt und setzt

$$I = \int_0^{\infty} f(x) dx = \sum_{j=1}^{\infty} I_j, \quad I_j := \int_{a_j}^{a_{j+1}} f(x) dx.$$

7) Allgemein läßt sich bei uneigentlichen Integralen das Integrationsintervall durch eine geeignete Substitution endlich machen. Zum Beispiel gilt mit der Substitution $x = 1/t$

$$\int_1^{\infty} f(x) dx = \int_0^1 \frac{1}{t^2} f\left(\frac{1}{t}\right) dt.$$

Wenn der neue Integrand am Intervallende 0 jetzt eine Singularität besitzt, so wende man eine der vorher besprochenen Methoden an.

Man beachte, daß man mit Hilfe der Gauß-Integration (s. Abschnitt 3.6) bei Verwendung von Laguerre- oder Hermite-Polynomen uneigentliche Integrale der Form

$$\int_0^{\infty} e^{-x} f(x) dx, \quad \int_{-\infty}^{\infty} e^{-x^2} f(x) dx,$$

für genügend oft differenzierbares f direkt berechnen kann.

Übungsaufgaben zu Kapitel 3

1. Sei durch $a \leq x_0 < x_1 < x_2 < \dots < x_n \leq b$ eine beliebige Unterteilung des Intervalls $[a, b]$ gegeben. Man zeige, daß es eindeutig bestimmte Zahlen $\gamma_0, \gamma_1, \dots, \gamma_n$ gibt mit

$$\sum_{i=0}^n \gamma_i P(x_i) = \int_a^b P(x) dx$$

für alle Polynome $P(x)$ vom Grad $\leq n$.

Hinweis: Wähle $P(x) \equiv 1, x, \dots, x^n$ und studiere die entstehenden linearen Gleichungen für die γ_i .

2. Die n -te Newton-Cotes-Formel ist so konstruiert, daß sie Polynome vom Grad $\leq n$ exakt integriert. Man zeige, daß sie für gerades n sogar Polynome $(n+1)$ -ten Grades exakt integriert.

Hinweis: Betrachte den Integranden x^{2k+1} auf dem Intervall $[-k, k]$.

3. Für $f \in C^2[a, b]$ läßt sich für die Trapezregel zeigen:

$$\int_a^b f(x) dx - \frac{1}{2}(b-a)(f(a) + f(b)) = -\frac{(b-a)^3}{12} f''(\tilde{x}), \quad \tilde{x} \in (a, b).$$

Hinweis: Man benutze Satz 2.1.4.1 und zeige, daß dort $f''(\xi(x))$ stetig von x abhängt.

4. Man beweise (3.1.6) mit Hilfe von Satz 2.1.5.9. *Hinweis:* Siehe Aufgabe 3.

5. Sei $f \in C^6[-1, 1]$ und $P \in \Pi_5$ Lösung der Hermiteschen Interpolationsaufgabe $P(x_i) = f(x_i)$, $P'(x_i) = f'(x_i)$, $x_i = -1, 0, 1$.
a) Man zeige

$$\int_{-1}^1 P(t) dt = \frac{7}{15} f(-1) + \frac{16}{15} f(0) + \frac{7}{15} f(1) + \frac{1}{15} f'(-1) - \frac{1}{15} f'(1).$$

- b) Diese Integrationsregel ist für alle Polynome $p \in \Pi_5$ exakt. Man zeige, daß sie nicht mehr für alle $p \in \Pi_6$ exakt ist.
c) Man leite mit Hilfe von Satz 2.1.5.9 eine Fehlerformel für die Integrationsregel aus a) ab.
6. Sei $\Delta = \{a = x_0 < \dots < x_n = b\}$ eine Partition des Intervalls $[a, b]$. Man leite eine Integrationsregel zur Berechnung von $\int_a^b f(t) dt$ her, indem man f durch die natürliche Splinefunktion S_Δ mit $S_\Delta(x_i) = f(x_i)$, $i = 0, \dots, n$, und (2.4.1.2a) ersetzt.
7. Betrachte die Integrationsregel von Aufgabe 5.
a) Zeige, daß ihr Peanokern auf $[-1, 1]$ konstantes Vorzeichen besitzt.
b) Bestimme eine Fehlerformel mittels (3.2.8).
8. Zeige mit Hilfe der Euler-Maclaurinschen Summenformel

$$\sum_{k=0}^n k^3 = \left(\frac{n(n+1)}{2} \right)^2.$$

9. Die Romberg-Integration über das Intervall $[0, 1]$ liefert das Tableau (3.4.4) von Näherungswerten T_{ik} . In 3.4 wurde gezeigt, daß T_{11} der Simpsonregel entspricht.
a) Man zeige, daß T_{22} die Milne-Regel liefert.
b) T_{33} entspricht *nicht* der Newton-Cotes Formel für $n = 8$.
10. Für die Schrittweiten $h_0 := b - a$, $h_1 := h_0/3$ liefert T_{11} in (3.4.4) gerade die 3/8-Regel.
11. Es soll die Zahl e mittels eines Extrapolationsverfahrens näherungsweise berechnet werden.
a) Man zeige: $T(h) := (1 + h)^{1/h}$, $h \neq 0$, $|h| < 1$, besitzt eine für alle h , $|h| < 1$, konvergente Entwicklung

$$T(h) = e + \sum_{i=1}^{\infty} \tau_i h^i.$$

- b) Wie ist $T(h)$ abzuändern, damit Extrapolation für $h = 0$ einen Näherungswert für e^x , x fest, liefert?
12. Betrachte eine Gewichtsfunktion $\omega(x) \geq 0$, die (3.6.1) a) und b) erfüllt. Man zeige, daß dann (3.6.1) c) zu $\mu_0 = \int_a^b \omega(x) dx > 0$ äquivalent ist.
Hinweis: Wende den Mittelwertsatz der Integralrechnung für geeignete Teilintervalle von $[a, b]$ an.
13. Für Funktionen $f, g \in C[-1, 1]$ definiere man das Skalarprodukt

$$(f, g) := \int_{-1}^1 f(x)g(x)dx.$$

Man zeige: Sind $f(x)$, $g(x)$ Polynome vom Grade $\leq n$, x_i , $i = 1, 2, \dots, n$, die Nullstellen des n -ten Legendrepolynoms (3.6.18) und

$$\gamma_i := \int_{-1}^1 L_i(x)dx \quad \text{mit} \quad L_i(x) := \prod_{\substack{k \neq i \\ k=1}}^n \frac{x - x_k}{x_i - x_k}, \quad i = 1, 2, \dots, n,$$

so gilt

$$(f, g) = \sum_{i=1}^n \gamma_i f(x_i)g(x_i).$$

14. Betrachte die durch (3.6.18) definierten Legendrepolynome $p_j(x)$.
- Zeige, daß der höchste Koeffizient von $p_j(x)$ gleich 1 ist.
 - Verifiziere die Orthogonalität dieser Polynome, $(p_i, p_j) = 0$ für $i < j$.
Hinweis: Partielle Integration, unter Verwendung von

$$\frac{d^{2i+1}}{dx^{2i+1}}(x^2 - 1)^i \equiv 0$$

und der Teilbarkeit der Polynome

$$\frac{d^l}{dx^l}(x^2 - 1)^k$$

für $l < k$ durch $x^2 - 1$.

15. Betrachte die Gauß-Integration, $[a, b] = [-1, 1]$, $\omega(x) \equiv 1$.
- Zeige $\delta_i = 0$ für $i > 0$ in der Rekursion (3.6.5) für die zugehörigen Orthogonalpolynome $p_j(x)$. Hinweis: Es gilt $p_j(x) \equiv (-1)^{j+1} p_j(-x)$.
 - Zeige mittels partieller Integration

$$\int_{-1}^1 (x^2 - 1)^j dx = \frac{(-1)^j 2^{2j+1}}{\binom{2j}{j}(2j+1)}.$$

- Berechne (p_j, p_j) unter Verwendung von b) und Aufgabe 14. Zeige so für $j > 0$

$$\gamma_j^2 = \frac{j^2}{(2j+1)(2j-1)}$$

für die Konstanten γ_j in (3.6.5).

16. Man betrachte die Gauß-Integration auf dem Intervall $[-1, +1]$ zur Gewichtsfunktion $\omega(x) := (1 - x^2)^{-1/2}$. In diesem Fall sind die Orthogonalpolynome $p_j(x)$ bis auf einen konstanten Faktor gerade die Tschebyscheff-Polynome $T_0(x) \equiv 1$, $T_1(x) \equiv x$, $T_{j+1}(x) \equiv 2xT_j(x) - T_{j-1}(x)$ für $j \geq 1$.
- Zeige $p_j(x) = (1/2^{j-1})T_j(x)$ für $j \geq 1$. Bestimme die Tridiagonalmatrix (3.6.19).

- b) Stelle für $n = 3$ das Gleichungssystem (3.6.13) auf und zeige $w_1 = w_2 = w_3 = \pi/3$. (Im Tschebyscheff-Fall sind die Gewichte $w_1, \dots, w_n$ für jedes n gleich).
17. $T(f; h)$ sei die Trapezsumme zur Schrittweite h für das Integral $\int_0^1 f(x) dx$. Es läßt sich zeigen, daß für $\alpha > 1$, $T(x^\alpha; h)$ folgende asymptotische Entwicklung besitzt

$$T(x^\alpha; h) \sim \int_0^1 x^\alpha dx + a_1 h^{1+\alpha} + a_2 h^2 + a_4 h^4 + a_6 h^6 + \dots$$

Man zeige, daß zu jeder Funktion $f(x)$, die für $|x| < r$, $r > 1$, analytisch ist, dann folgende asymptotische Entwicklung gilt

$$T(x^\alpha f(x); h) \sim \int_0^1 x^\alpha f(x) dx + b_1 h^{1+\alpha} + b_2 h^{2+\alpha} + b_3 h^{3+\alpha} + \dots \\ + c_2 h^2 + c_4 h^4 + c_6 h^6 + \dots$$

Hinweis: Entwickle f in eine Taylorreihe und verwende

$$T(\varphi + \psi; h) = T(\varphi; h) + T(\psi; h).$$

Literatur zu Kapitel 3

- Abramowitz, M., Stegun, I.A. (1964): *Handbook of mathematical functions*. National Bureau of Standards, Applied Mathematics Series 55, Washington, D.C.: US Government Printing Office, 6. Aufl. 1967.
- Bauer, F.L., Rutishauser, H., Stiefel, E. (1963): New aspects in numerical quadrature. Proc. of Symposia in Applied Mathematics **15**, 199–218, Amer. Math. Soc.
- Bulirsch, R. (1964): Bemerkungen zur Romberg-Integration. Numer. Math. **6**, 6–16.
- Bulirsch, R., Stoer, J. (1964): Fehlerabschätzungen und Extrapolation mit rationalen Funktionen bei Verfahren vom Richardson- Typus. Numer. Math. **6**, 413–427.
- Bulirsch, R., Stoer, J. (1967): Numerical quadrature by extrapolation. Numer. Math. **9**, 271–278.
- Davis, Ph.J. (1963): *Interpolation and approximation*. New York: Blaisdell, 2. Aufl. 1965.
- Davis, Ph.J., Rabinowitz, P. (1975): *Methods of numerical integrations*. New York: Academic Press.
- Erdelyi, A. (1956): *Asymptotic Expansions*. New York: Dover.
- Gautschi, W. (1968): Construction of Gauss-Christoffel quadrature formulas. Math. Comp. **22**, 251–270.
- Gautschi, W. (1970): On the Construction of Gaussian quadrature rules from modified moments. Math. Comp. **24**, 245–260.

- Golub, G.H., Welsch, J.H. (1969): Calculation of Gauss quadrature rules. *Math. Comp.* **23**, 221–230.
- Gradshteyn, I.S., Ryzhik, I.M. (1980): *Table of Integrals, Series and Products*. New York: Academic Press.
- Gröbner, W., Hofreiter, N. (1961): *Integraltafel*, 2 Bde. Berlin-Heidelberg-New York: Springer.
- Henrici, P. (1964): *Elements of numerical analysis*. New York: Wiley.
- Kronrod, A.S. (1965): *Nodes and weights of quadrature formulas*. Übersetzung aus dem Russischen. New York: Consultants Bureau.
- Olver, F.W.J. (1974): *Asymptotics and special functions*. New York: Academic Press.
- Piessens, R., de Doncker, E., Überhuber, C.W., Kahaner, D.K. (1983): *Quadpack. A subroutine package for automatic integration*. Berlin-Heidelberg-New York: Springer.
- Romberg, W. (1955): Vereinfachte numerische Integration. Det. Kong. Norske Videnskabers Selskab Forhandling **28**, Nr. 7, Trondheim.
- Schoenberg, I.J. (1969): Monosplines and quadrature formulae. In: *Theory and applications of spline functions*. Ed. by T.N.E. Greville. 157–207. New York: Academic Press.
- Steffensen, J.F. (1950): *Interpolation*, 2. Aufl., New York: Chelsea, 1. Aufl. 1927.
- Stroud, A.H., Secrest, D. (1966): *Gaussian quadrature formulas*. Englewood Cliffs, NJ: Prentice Hall.
- Szegő, G. (1959): *Orthogonal Polynomials*. New York: Amer. Math. Soc.

4 Lineare Gleichungssysteme

In diesem Abschnitt werden direkte Methoden zur Lösung von linearen Gleichungssystemen

$$Ax = b, \quad A = \begin{bmatrix} a_{11} & \cdot & \cdot & \cdot & a_{1n} \\ \cdot & & & & \cdot \\ \cdot & & & & \cdot \\ \cdot & & & & \cdot \\ a_{n1} & \cdot & \cdot & \cdot & a_{nn} \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \cdot \\ \cdot \\ \cdot \\ b_n \end{bmatrix}$$

dargestellt. Hier ist A eine gegebene $n \times n$ -Matrix, $b \in \mathbb{R}^n$ ein gegebener Vektor. Wir nehmen zusätzlich an, daß A und b reell sind, obwohl diese Einschränkung bei den meisten Verfahren unwesentlich ist. Im Gegensatz zu den iterativen Methoden (Kapitel 8), liefern die hier besprochenen direkten Verfahren die Lösung in endlich vielen Schritten, rundungsfehlerfreie Rechnung vorausgesetzt.

Das gestellte Problem ist eng damit verwandt, die Inverse A^{-1} der Matrix A zu berechnen, sofern diese existiert. Kennt man nämlich A^{-1} , so erhält man die Lösung x von $Ax = b$ als Ergebnis einer Matrixmultiplikation $x = A^{-1}b$; umgekehrt ist die i -te Spalte $\bar{a}_i$ von $A^{-1} = (\bar{a}_1, \dots, \bar{a}_n)$ Lösung $x = \bar{a}_i$ des linearen Gleichungssystems

$$Ax = e_i,$$

wobei $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T$ der i -te Achsenvektor ist.

Allgemeine Einführungen in das Rechnen mit Matrizen findet man bei Golub und Van Loan (1983) und Stewart (1973), ALGOL-Programme in Wilkinson und Reinsch (1971) und FORTRAN-Programme in Dongarra et al. (1979) und Andersen et al. (1992).

4.1 Gauß-Elimination. Dreieckszerlegung einer Matrix

Beim Gaußschen Eliminationsverfahren zur Lösung eines Gleichungssystems

$$(4.1.1) \quad Ax = b,$$

A eine $n \times n$ -Matrix, $b \in \mathbb{R}^n$, wird das gegebene System (4.1.1) durch geeignete Vertauschungen und Linearkombinationen von Gleichungen schrittweise in ein Gleichungssystem der Form

$$Rx = c, \quad R = \begin{bmatrix} r_{11} & \cdots & r_{1n} \\ & \ddots & \vdots \\ 0 & & r_{nn} \end{bmatrix}$$

transformiert, das dieselben Lösungen wie (4.1.1) besitzt. R ist eine obere Dreiecksmatrix, $Rx = c$ also ein „gestaffeltes“ Gleichungssystem, das man leicht lösen kann (sofern $r_{ii} \neq 0$, $i = 1, \dots, n$):

$$x_i := \left(c_i - \sum_{k=i+1}^n r_{ik} x_k \right) / r_{ii} \text{ für } i = n, n-1, \dots, 1.$$

Im ersten Schritt des Algorithmus subtrahiert man ein geeignetes Vielfaches der ersten Gleichung von den übrigen Gleichungen, derart, daß die Koeffizienten von x_1 in diesen Gleichungen verschwinden, also die Variable x_1 nur noch in der ersten Gleichung vorkommt. Dies ist natürlich nur dann möglich, wenn $a_{11} \neq 0$ ist, was man ggf. durch Vertauschen der Gleichungen erreichen kann, sofern überhaupt ein $a_{i1} \neq 0$ ist. Statt mit den Gleichungen (4.1.1) selbst zu arbeiten, führt man diese Operationen an der (4.1.1) entsprechenden Matrix

$$(A, b) = \begin{bmatrix} a_{11} & \cdots & a_{1n} & b_1 \\ \vdots & & \vdots & \vdots \\ a_{n1} & \cdots & a_{nn} & b_n \end{bmatrix}$$

aus. Der erste Schritt des Gaußschen Eliminationsverfahrens führt zu einer Matrix (A', b') der Form

$$(4.1.2) \quad (A', b') = \begin{bmatrix} a'_{11} & a'_{12} & \cdots & a'_{1n} & b'_1 \\ 0 & a'_{22} & \cdots & a'_{2n} & b'_2 \\ \vdots & \vdots & & \vdots & \vdots \\ 0 & a'_{n2} & \cdots & a'_{nn} & b'_n \end{bmatrix},$$

und kann formal so beschrieben werden:

(4.1.3)

- a) Bestimme ein Element $a_{r1} \neq 0$ und fahre mit b) fort; falls kein solches r existiert, setze $(A', b') := (A, b)$, A ist singulär, stop.
 b) Vertausche die Zeilen r und 1 von (A, b) . Das Resultat ist die Matrix $(\bar{A}, \bar{b})$.
 c) Subtrahiere für $i = 2, 3, \dots, n$, das l_{i1} -fache,

$$l_{i1} := \bar{a}_{i1}/\bar{a}_{11},$$

der ersten Zeile der Matrix $(\bar{A}, \bar{b})$ von Zeile i . Als Resultat erhält man die gesuchte Matrix (A', b') .

Formal kann man den Übergang $(A, b) \rightarrow (\bar{A}, \bar{b}) \rightarrow (A', b')$ mit Hilfe von Matrixmultiplikationen beschreiben. Es ist

$$(4.1.4) \quad (\bar{A}, \bar{b}) = P_1(A, b), \quad (A', b') = G_1(\bar{A}, \bar{b}) = G_1 P_1(A, b),$$

wobei P_1 eine Permutationsmatrix und G_1 eine untere Dreiecksmatrix ist,

$$(4.1.5) \quad P_1 := \begin{bmatrix} 0 & & & 1 & & 0 \\ & 1 & & & & \\ & & \ddots & & & \\ & & & 1 & & \\ 1 & & & 0 & & \\ & & & & 1 & \\ & & & & & \ddots \\ & & & & & & 1 \end{bmatrix} \leftarrow r, \quad G_1 := \begin{bmatrix} 1 & & & 0 \\ -l_{21} & 1 & & \\ \vdots & & \ddots & \\ -l_{n1} & 0 & \cdots & 1 \end{bmatrix}.$$

Matrizen wie G_1 , die höchstens in einer Spalte von einer Einheitsmatrix verschieden sind, heißen *Frobeniusmatrizen*. Beide Matrizen P_1 und G_1 sind nichtsingulär, es ist

$$P_1^{-1} = P_1, \quad G_1^{-1} = \begin{bmatrix} 1 & & & 0 \\ l_{21} & 1 & & \\ \vdots & & \ddots & \\ l_{n1} & 0 & \cdots & 1 \end{bmatrix}.$$

Aus diesem Grunde besitzen die Gleichungssysteme $Ax = b$ und $A'x = b'$ die gleichen Lösungen: Aus $Ax = b$ folgt $A'x = G_1 P_1 Ax = G_1 P_1 b = b'$ und aus $A'x = b'$ folgt $Ax = P_1^{-1} G_1^{-1} A'x = P_1^{-1} G_1^{-1} b' = b$.

Das Element $a_{r1} = \bar{a}_{11}$, das in a) bestimmt wird, heißt *Pivotelement*, Teilschritt a) selbst *Pivotsuche*. Bei der Pivotsuche kann man theoretisch jedes $a_{r1} \neq 0$ als Pivotelement wählen. Aus Gründen des gutartigen Verhaltens (s. 4.5) empfiehlt es sich, nicht irgend ein $a_{r1} \neq 0$ zu nehmen. Gewöhnlich trifft man folgende Wahl

$$|a_{r1}| = \max_i |a_{i1}|,$$

man wählt unter den in Betracht kommenden Elementen der ersten Spalte das betragsgrößte. (Bei dieser Methode wird jedoch vorausgesetzt, s. Abschnitt 4.5, daß die Matrix A „equilibriert“ ist, d. h., daß die Größenordnung der Elemente von A „ungefähr gleich“ ist.) Diese Art der Pivotsuche heißt auch *Teilpivotsuche* oder *Spaltenpivotsuche*, im Gegensatz zur *Totalpivotsuche*, bei der man die Pivotsuche nicht auf die erste Spalte beschränkt: in (4.1.3) werden hier a) und b) durch a') bzw. b') ersetzt:

a') Bestimme r und s , so daß

$$|a_{rs}| = \max_{i,j} |a_{ij}|$$

und fahre fort mit b'), falls $a_{rs} \neq 0$. Andernfalls stop: setze $(A', b') := (A, b)$, A ist singulär.

b') Vertausche die Zeilen r und 1 sowie die Spalten s und 1 von (A, b) . Das Resultat sei die Matrix $(\tilde{A}, \tilde{b})$.

Als Resultat des ersten Eliminationsschritts erhält man eine Matrix (A', b') der Form (4.1.2):

$$(A', b') = \left[\begin{array}{c|c|c} a'_{11} & a'^T & b'_1 \\ \hline 0 & \tilde{A} & \tilde{b} \end{array} \right]$$

mit einer $(n-1)$ -reihigen Matrix $\tilde{A}$. Der nächste Eliminationsschritt besteht einfach darin, daß man die Elimination (4.1.3) statt auf (A, b) auf die kleinere Matrix $(\tilde{A}, \tilde{b})$ anwendet. Man erhält so eine Kette von Matrizen

$$(A, b) := (A^{(0)}, b^{(0)}) \rightarrow (A^{(1)}, b^{(1)}) \rightarrow \dots \rightarrow (A^{(n-1)}, b^{(n-1)}) =: (R, c),$$

die mit der gegebenen Matrix (A, b) (4.1.1) beginnt und mit der gesuchten Matrix (R, c) endet. Dabei hat die j -te Zwischenmatrix $(A^{(j)}, b^{(j)})$ die Gestalt

$$(A^{(j)}, b^{(j)}) = \left[\begin{array}{c|c|c} * & \dots & * & * & \dots & * & * \\ & \ddots & \vdots & \vdots & & \vdots & \vdots \\ 0 & & * & * & \dots & * & * \\ \hline 0 & \dots & 0 & * & \dots & * & * \\ \vdots & & \vdots & \vdots & & \vdots & \vdots \\ 0 & \dots & 0 & * & \dots & * & * \end{array} \right] = \left[\begin{array}{c|c|c} A_{11}^{(j)} & A_{12}^{(j)} & b_1^{(j)} \\ \hline 0 & A_{22}^{(j)} & b_2^{(j)} \end{array} \right]$$

mit einer j -reihigen oberen Dreiecksmatrix $A_{11}^{(j)}$. Der Schritt $(A^{(j)}, b^{(j)}) \rightarrow (A^{(j+1)}, b^{(j+1)})$ besteht in der Anwendung von (4.1.3) auf die $(n-j) \times (n-j+1)$ -Matrix $(A_{22}^{(j)}, b_2^{(j)})$. Die Elemente von $A_{11}^{(j)}, A_{12}^{(j)}, b_1^{(j)}$ ändern sich dabei (und in den folgenden Schritten) nicht mehr und stimmen daher bereits mit den entsprechenden Elementen von (R, c) überein. Wie der erste Schritt (4.1.4), (4.1.5) können auch die weiteren Schritte mit Hilfe von Matrixmultiplikationen beschrieben werden. Man bestätigt sofort

$$(4.1.7) \quad \begin{aligned} (A^{(j)}, b^{(j)}) &= G_j P_j (A^{(j-1)}, b^{(j-1)}) \\ (R, c) &= G_{n-1} P_{n-1} G_{n-2} P_{n-2} \cdots G_1 P_1 (A, b) \end{aligned}$$

mit Permutationsmatrizen P_j und nichtsingulären Frobeniusmatrizen G_j der Form

$$(4.1.8) \quad G_j = \begin{bmatrix} 1 & & & & & & 0 \\ & \ddots & & & & & \\ & & 1 & & & & \\ & & -l_{j+1,j} & 1 & & & \\ & & \vdots & \vdots & \ddots & & \\ 0 & & -l_{n,j} & 0 & & 1 \end{bmatrix}.$$

Im j -ten Eliminationsschritt $(A^{(j-1)}, b^{(j-1)}) \rightarrow (A^{(j)}, b^{(j)})$ werden in der j -ten Spalte die Elemente unterhalb der Diagonale annulliert. Den so freiwerdenden Platz benutzt man bei der Realisierung des Algorithmus auf einer Rechenanlage zum Abspeichern der wesentlichen Elemente l_{ij} , $i \geq j+1$ von G_j , d. h. man arbeitet mit Matrizen der Form

$$T^{(j)} = \left[\begin{array}{cccc|cccc} r_{11} & r_{12} & \cdots & r_{1j} & r_{1,j+1} & \cdots & r_{1n} & c_1 \\ \lambda_{21} & r_{22} & \cdots & r_{2j} & \vdots & & \vdots & \vdots \\ \lambda_{31} & \lambda_{32} & & \vdots & \vdots & & \vdots & \vdots \\ \vdots & \vdots & & r_{jj} & r_{j,j+1} & \cdots & r_{j,n} & c_j \\ \vdots & \vdots & & \lambda_{j+1,j} & a_{j+1,j+1}^{(j)} & \cdots & a_{j+1,n}^{(j)} & b_{j+1}^{(j)} \\ \vdots & \vdots & & \vdots & \vdots & & \vdots & \vdots \\ \lambda_{n1} & \lambda_{n2} & \cdots & \lambda_{n1} & a_{n,j+1}^{(j)} & \cdots & a_{n,n}^{(j)} & b_n^{(j)} \end{array} \right]$$

Dabei sind die Subdiagonal-Elemente $\lambda_{k+1,k}, \lambda_{k+2,k}, \dots, \lambda_{nk}$ der k -ten Spalte eine Permutation der wesentlichen Elemente $l_{k+1,k}, \dots, l_{n,k}$ von G_k (4.1.8). Beim Start des Verfahrens ist $T^{(0)} := (A, b)$.

Mit Hilfe dieser Matrizen läßt sich der j -te Schritt $T^{(j-1)} \rightarrow T^{(j)}$ folgendermaßen beschreiben. Der Einfachheit halber bezeichnen wir dabei die Elemente von $T^{(j-1)}$ mit t_{ik} , die von $T^{(j)}$ mit t'_{ik} :

a) *Spaltenpivotsuche*: Bestimme r , so daß

$$|t_{rj}| = \max_{i \geq j} |t_{ij}|.$$

Falls $t_{rj} = 0$, setze $T^{(j)} := T^{(j-1)}$, stop: A ist singulär;
andernfalls fahre fort mit b).

b) Vertausche die Zeilen r und j von $T^{(j-1)}$ und bezeichne das Ergebnis mit $\bar{T} = (\bar{t}_{ik})$.

c) Setze

$$t'_{ij} := l_{ij} := \bar{t}_{ij} / \bar{t}_{jj} \quad \text{für } i = j+1, j+2, \dots, n,$$

$$t'_{ik} := \bar{t}_{ik} - l_{ij} \bar{t}_{jk} \quad \text{für } i = j+1, \dots, n \quad \text{und } k = j+1, \dots, n+1.$$

$$t'_{ik} = \bar{t}_{ik} \quad \text{sonst.}$$

Man beachte, daß die wesentlichen Elemente $l_{j+1,j}, \dots, l_{nj}$ von G_j in Schritt c) zunächst in ihrer natürlichen Reihenfolge als $t'_{j+1,j}, \dots, t'_{nj}$ abgespeichert werden. Diese Reihenfolge wird jedoch in den folgenden Eliminationsschritten $T^{(k)} \rightarrow T^{(k+1)}$, $k \geq j$, eventuell verändert, weil in Schritt b) die Zeilen der gesamten Matrix $T^{(k)}$ vertauscht werden. Dies hat folgenden Effekt: Die Dreiecksmatrizen L und R

$$L := \begin{bmatrix} 1 & & & 0 \\ t_{21} & 1 & & \\ \vdots & \ddots & \ddots & \\ t_{n1} & \cdots & t_{n,n-1} & 1 \end{bmatrix}, \quad R := \begin{bmatrix} t_{11} & \cdots & \cdots & t_{1n} \\ & \ddots & & \vdots \\ & & \ddots & \vdots \\ 0 & & & t_{nn} \end{bmatrix}$$

die man aus der Endmatrix $T^{(n-1)} = (t_{ik})$ erhält, liefern eine *Dreieckszerlegung* der Matrix PA :

$$(4.1.9) \quad LR = PA.$$

Dabei ist P gerade das Produkt

$$P = P_{n-1} P_{n-2} \cdots P_1$$

aller in (4.1.7) auftretenden Permutationen. Wir wollen dies nur für den Fall zeigen, daß im Laufe des Eliminationsverfahrens keine Zeilenumtauschungen nötig waren, $P_1 = \cdots = P_{n-1} = P = I$. In diesem Fall ist natürlich

$$L = \begin{bmatrix} 1 & & & 0 \\ l_{21} & 1 & & \\ \vdots & \ddots & \ddots & \\ l_{n1} & \cdots & l_{n,n-1} & 1 \end{bmatrix},$$

da in allen Teilschritten b) nichts vertauscht wurde. Nun ist wegen (4.1.7)

$$R = G_{n-1} \cdots G_1 A,$$

also

$$(4.1.10) \quad G_1^{-1} \cdots G_{n-1}^{-1} R = A.$$

Mit Hilfe von

$$G_j^{-1} = \begin{bmatrix} 1 & & & & 0 \\ & \ddots & & & \\ & & 1 & & \\ & & l_{j+1,j} & 1 & \\ & & \vdots & & \ddots \\ 0 & & l_{n,j} & & 1 \end{bmatrix}$$

verifiziert man sofort

$$G_1^{-1} \cdots G_{n-1}^{-1} = \begin{bmatrix} 1 & & & 0 \\ l_{21} & 1 & & \\ \vdots & \ddots & \ddots & \\ l_{n1} & \cdots & l_{n,n-1} & 1 \end{bmatrix} = L.$$

Aus (4.1.10) folgt dann die Behauptung.

Beispiel:

$$\begin{bmatrix} 3 & 1 & 6 \\ 2 & 1 & 3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 7 \\ 4 \end{bmatrix}$$

$$\left[\begin{array}{ccc|c} 3^* & 1 & 6 & 2 \\ 2 & 1 & 3 & 7 \\ 1 & 1 & 1 & 4 \end{array} \right] \rightarrow \left[\begin{array}{ccc|c} 3 & 1 & 6 & 2 \\ \frac{2}{3} & \frac{1}{3} & -1 & \frac{17}{3} \\ \frac{1}{3} & \frac{2}{3}^* & -1 & \frac{10}{3} \end{array} \right] \rightarrow \left[\begin{array}{ccc|c} 3 & 1 & 6 & 2 \\ \frac{1}{3} & \frac{2}{3} & -1 & \frac{10}{3} \\ \frac{2}{3} & \frac{1}{2} & -\frac{1}{2}^* & 4 \end{array} \right]$$

Die Pivotelemente sind markiert. Das gestaffelte Gleichungssystem lautet

$$\begin{bmatrix} 3 & 1 & 6 \\ 0 & \frac{2}{3} & -1 \\ 0 & 0 & -\frac{1}{2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ \frac{10}{3} \\ 4 \end{bmatrix}.$$

Seine Lösung ist

$$\begin{aligned}x_3 &= -8 \\x_2 &= \frac{3}{2}\left(\frac{10}{3} + x_3\right) = -7 \\x_1 &= \frac{1}{3}(2 - x_2 - 6x_3) = 19.\end{aligned}$$

Ferner ist

$$P = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix}, \quad PA = \begin{bmatrix} 3 & 1 & 6 \\ 1 & 1 & 1 \\ 2 & 1 & 3 \end{bmatrix},$$

und die Matrix PA besitzt die Dreieckszerlegung $PA = LR$ mit

$$L = \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{3} & 1 & 0 \\ \frac{2}{3} & \frac{1}{2} & 1 \end{bmatrix}, \quad R = \begin{bmatrix} 3 & 1 & 6 \\ 0 & \frac{2}{3} & -1 \\ 0 & 0 & -\frac{1}{2} \end{bmatrix}.$$

Dreieckszerlegungen (4.1.9) sind für die Praxis der Gleichungsauflösung sehr wichtig. Kennt man für eine Matrix A die Zerlegung (4.1.9), d. h. die Matrizen L , R , P , kann sofort jedes Gleichungssystem $Ax = b$ mit beliebiger rechter Seite b gelöst werden: Es folgt nämlich

$$PAx = LRx = Pb,$$

so daß x durch Lösen der beiden gestaffelten Gleichungssysteme

$$Lu = Pb, \quad Rx = u$$

gefunden werden kann (sofern alle $r_{ii} \neq 0$ sind).

Mit Hilfe des Gaußschen Algorithmus ist also konstruktiv gezeigt, daß jede quadratische nichtsinguläre Matrix A eine Dreieckszerlegung der Form (4.1.9) besitzt. Dagegen muß nicht jede Matrix A eine Dreieckszerlegung in engerem Sinne $A = LR$ besitzen, wie das Beispiel

$$A = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$$

zeigt. Im allgemeinen hat man vorher die Zeilen von A geeignet zu permutieren.

Die Dreieckszerlegung (4.1.9) läßt sich auch direkt berechnen, ohne die Zwischenmatrizen $T^{(j)}$ zu bilden. Wir zeigen dies der Einfachheit halber unter der zusätzlichen Annahme, daß die Zeilen von A nicht permutiert werden müssen, damit eine Dreieckszerlegung $A = LR$ existiert. Dazu fasse man die Gleichung $A = LR$ als n^2 Bestimmungsgleichungen für die n^2 unbekannten Größen

$$r_{ik}, \quad i \leq k,$$

$$l_{ik}, \quad i \geq k \quad (l_{ii} = 1),$$

auf:

$$(4.1.11) \quad a_{ik} = \sum_{j=1}^{\min(i,k)} l_{ij} r_{jk} \quad (l_{ii} = 1).$$

Dabei bleibt offen, in welcher Reihenfolge die l_{ij} , r_{jk} berechnet werden. Folgende Varianten sind üblich:

Nach Crout wird die $n \times n$ -Matrix $A = LR$ in folgender Weise parkettiert

					1
					3
					5
					7
2	4	6	8	9	

und die Zeilen von R bzw. die Spalten von L in der entsprechenden Reihenfolge berechnet.

In Einzelschritten: mit $l_{ii} = 1$

1. $a_{1i} = \sum_{j=1}^1 l_{1j} r_{ji}, \quad r_{1i} := a_{1i}, \quad i = 1, 2, \dots, n,$
2. $a_{i1} = \sum_{j=1}^1 l_{ij} r_{j1}, \quad l_{i1} := a_{i1}/r_{11}, \quad i = 2, 3, \dots, n,$
3. $a_{2i} = \sum_{j=1}^2 l_{2j} r_{ji}, \quad r_{2i} := a_{2i} - l_{21} r_{1i}, \quad i = 2, 3, \dots, n, \quad \text{usw.}$

Allgemein für $i = 1, 2, \dots, n$:

$$(4.1.12) \quad r_{ik} := a_{ik} - \sum_{j=1}^{i-1} l_{ij} r_{jk}, \quad k = i, i+1, \dots, n,$$

$$l_{ki} := \left(a_{ki} - \sum_{j=1}^{i-1} l_{kj} r_{ji} \right) / r_{ii}, \quad k = i+1, i+2, \dots, n.$$

Nach Banachiewicz verwendet man die Parkettierung

		1
2		3
4		5
6		7
8		9

d. h. L und R werden zeilenweise berechnet.

Obige Formeln gelten nur, wenn keine Pivotsuche durchgeführt wird. Die Dreieckszerlegung nach Crout bzw. Banachiewicz mit Pivotsuche führt zu einem komplexeren Algorithmus, der bei Wilkinson (1965) angegeben ist.

Gaußelimination und direkte Dreieckszerlegung unterscheiden sich nur in der Reihenfolge der Operationen. Beide Algorithmen sind theoretisch und numerisch völlig äquivalent:

Durch die j -ten Partialsummen

$$(4.1.13) \quad a_{ik}^{(j)} := a_{ik} - \sum_{s=1}^j l_{is} r_{sk}$$

von (4.1.12) werden nämlich gerade die Elemente der Matrix $A^{(j)}$ (4.1.6) geliefert, wie man sich leicht überzeugen kann. Bei der Gaußelimination werden daher die Skalarprodukte (4.1.12) nur stückweise, unter zeitweiliger Abspeicherung der Zwischenresultate, bei der direkten Dreieckszerlegung dagegen in einem Zuge gebildet. Deshalb verdient die direkte Dreieckszerlegung nur in den Fällen aus numerischen Gründen den Vorzug, wenn zur Reduktion der Rundungsfehler diese Skalarprodukte in doppelter Genauigkeit akkumuliert werden sollen (keine Zwischenspeicherung von doppelt genauen Zahlen!). Im übrigen benötigt man bei der Dreieckszerlegung ca. $n^3/3$ Operationen (1 Operation = 1 Multiplikation + 1 Addition). Sie bietet damit auch eine einfache Möglichkeit, die *Determinante* einer Matrix A zu bestimmen: Aus (4.1.9) folgt nämlich wegen $\det(P) = \pm 1$, $\det(L) = 1$

$$\det(PA) = \pm \det(A) = \det(R) = r_{11} r_{22} \cdots r_{nn}.$$

Bis auf ein Vorzeichen ist $\det(A)$ gerade das Produkt der Pivotelemente. (Man beachte, daß die direkte Auswertung der Formel

$$\det(A) = \sum_{\substack{\mu_1, \dots, \mu_n = 1 \\ \mu_i \neq \mu_k \text{ für } i \neq k}}^n \text{sign}(\mu_1, \dots, \mu_n) a_{1\mu_1} a_{2\mu_2} \cdots a_{n\mu_n}$$

$n! \gg n^3/3$ Operationen erfordert!)

Für den Fall $P = I$ sind die Pivotelemente r_{ii} als Quotienten der Hauptabschnittsdeterminanten von A darstellbar. Partitioniert man nämlich in der Darstellung $LR = A$ die Matrizen entsprechend

$$\begin{bmatrix} L_{11} & 0 \\ L_{21} & L_{22} \end{bmatrix} \begin{bmatrix} R_{11} & R_{12} \\ 0 & R_{22} \end{bmatrix} = \begin{bmatrix} A_{11} & A_{21} \\ A_{12} & A_{22} \end{bmatrix},$$

so findet man $L_{11}R_{11} = A_{11}$, also $\det(R_{11}) = \det(A_{11})$, d. h.

$$r_{11} \cdots r_{ii} = \det(A_{11}),$$

falls A_{11} eine $i \times i$ -Matrix ist. Bezeichnet man allgemein mit A_i die i -te Hauptabschnittsmatrix von A , so folgt die Formel

$$r_{ii} = \det(A_i) / \det(A_{i-1}), \quad i \geq 2,$$

$$r_{11} = \det(A_1).$$

Eine weitere praktisch wichtige Eigenschaft der Dreieckszerlegungsmethode ist es, daß für *Bandmatrizen* der Bandbreite m

$$A = \begin{bmatrix} * & \cdots & * & & 0 \\ \vdots & \ddots & & \ddots & \\ * & & \ddots & & \\ & \ddots & & \ddots & \\ 0 & & & \underbrace{* \cdots *}_m \end{bmatrix}, \quad a_{ij} = 0 \text{ für } |i - j| \geq m,$$

die Matrizen L und R der Dreieckszerlegung $LR = PA$ von A wieder „dünn“ besetzt sind: R ist Bandmatrix der Breite $2m - 1$

$$R = \begin{bmatrix} * & \cdots & * & 0 & \cdots & 0 \\ & \ddots & & \ddots & & \vdots \\ & & \ddots & & \ddots & 0 \\ & & & \ddots & & * \\ & & & & \ddots & \vdots \\ 0 & & & & & * \end{bmatrix}, \quad \left. \begin{matrix} * \\ \vdots \\ * \end{matrix} \right\} 2m-1$$

und in jeder Spalte von L sind höchstens m Elemente von 0 verschieden. Dagegen sind die Inversen A^{-1} von Bandmatrizen gewöhnlich voll besetzt. Dies bringt natürlich für $m \ll n$ eine erhebliche Einsparung an Speicherplatz und Rechenoperationen. Zusätzliche Einsparungen sind aufgrund der

Symmetrie von A möglich, wenn A eine positiv definitive Matrix ist (s. Abschnitte 4.3 und 4.12).

4.2 Der Gauß-Jordan-Algorithmus

Mit Hilfe des Gauß-Jordan-Algorithmus kann man die Inverse A^{-1} einer nichtsingulären $n \times n$ -Matrix A berechnen. Dies ist eine in der Praxis überraschend seltene Aufgabe, die man im Prinzip und mit sogar dem gleichen Aufwand auch mit Hilfe der Dreieckszerlegung (4.1.9), $PA = LR$, lösen kann: man erhält die i -te Spalte $\bar{a}_i$ von A^{-1} leicht als Lösung des Systems

$$(4.2.1) \quad LR\bar{a}_i = Pe_i,$$

wobei e_i der i -te Achsenvektor ist. Bei Berücksichtigung der einfachen Struktur der rechten Seite Pe_i von (4.2.1) kann man die n Gleichungssysteme (4.2.1) ($i = 1, \dots, n$) mit ca. $\frac{2}{3}n^3$ Operationen lösen und damit A^{-1} mit einem Gesamtaufwand von n^3 Operationen bestimmen. Das Gauß-Jordan-Verfahren erfordert den gleichen Aufwand und bietet im Grunde nur Vorteile organisatorischer Natur. Man erhält dieses Verfahren, wenn man versucht, die durch die Matrix A vermittelte Abbildung $x \mapsto Ax = y$, $x \in \mathbb{R}^n$, $y \in \mathbb{R}^n$ auf systematische Weise umzukehren. Dazu betrachten wir das System $Ax = y$:

$$(4.2.2) \quad \begin{array}{c} a_{11}x_1 + \cdots + a_{1n}x_n = y_1, \\ \vdots \\ a_{n1}x_1 + \cdots + a_{nn}x_n = y_n. \end{array}$$

Im ersten Schritt des Gauß-Jordan-Verfahrens tauscht man die Variable x_1 gegen eine der Variablen y_r aus. Dazu sucht man ein $a_{r1} \neq 0$, etwa (Spaltenpivotsuche!)

$$|a_{r1}| = \max_i |a_{i1}|,$$

und vertauscht die Gleichungen r und 1 von (4.2.2). Man erhält so ein System

$$(4.2.3) \quad \begin{array}{c} \bar{a}_{11}x_1 + \cdots + \bar{a}_{1n}x_n = \bar{y}_1, \\ \vdots \\ \bar{a}_{n1}x_1 + \cdots + \bar{a}_{nn}x_n = \bar{y}_n. \end{array}$$

wobei die Variablen $\bar{y}_1, \dots, \bar{y}_n$ eine Permutation der $y_1, \dots, y_n$ sind und $\bar{a}_{11} = a_{r1}$, $\bar{y}_1 = y_r$ gilt. Nun ist $\bar{a}_{11} \neq 0$, denn andernfalls wäre $a_{i1} = 0$ für alle i und damit A entgegen der Voraussetzung singular. Durch Auflösen der ersten Gleichung (4.2.3) nach x_1 und Einsetzen des Resultats in die übrigen Gleichungen erhält man das System

$$(4.2.4) \quad \begin{aligned} a'_{11}\bar{y}_1 + a'_{12}x_2 + \dots + a'_{1n}x_n &= x_1 \\ a'_{21}\bar{y}_1 + a'_{22}x_2 + \dots + a'_{2n}x_n &= \bar{y}_2 \\ &\vdots \\ a'_{n1}\bar{y}_1 + a'_{n2}x_2 + \dots + a'_{nn}x_n &= \bar{y}_n \end{aligned}$$

mit

$$(4.2.5) \quad \begin{aligned} a'_{11} &:= \frac{1}{\bar{a}_{11}}, & a'_{1k} &:= -\frac{\bar{a}_{1k}}{\bar{a}_{11}}, & a'_{i1} &:= \frac{\bar{a}_{i1}}{\bar{a}_{11}} \\ a'_{ik} &:= \bar{a}_{ik} - \frac{\bar{a}_{i1}\bar{a}_{1k}}{\bar{a}_{11}} \text{ für } i, k = 2, 3, \dots, n. \end{aligned}$$

Im nächsten Schritt versucht man die Variable x_2 gegen eine der Variablen $\bar{y}_2, \dots, \bar{y}_n$ zu tauschen, dann x_3 gegen eine der noch nicht getauschten y -Variablen usw. Stellt man die sukzessiven Gleichungssysteme (4.2.2), (4.2.4) durch ihre Matrizen dar, so erhält man ausgehend von der Matrix $A^{(0)} := A$ eine Sequenz von Matrizen

$$A^{(0)} \rightarrow A^{(1)} \rightarrow \dots \rightarrow A^{(n)}.$$

Die Matrix $A^{(j)} = (a_{ik}^{(j)})$ steht für ein „gemischtes Gleichungssystem“ der Form

$$(4.2.6) \quad \begin{aligned} a_{11}^{(j)}\tilde{y}_1 + \dots + a_{1j}^{(j)}\tilde{y}_j + a_{1,j+1}^{(j)}x_{j+1} + \dots + a_{1n}^{(j)}x_n &= x_1, \\ &\vdots \\ a_{j1}^{(j)}\tilde{y}_1 + \dots + a_{jj}^{(j)}\tilde{y}_j + a_{j,j+1}^{(j)}x_{j+1} + \dots + a_{jn}^{(j)}x_n &= x_j, \\ a_{j+1,1}^{(j)}\tilde{y}_1 + \dots + a_{j+1,j}^{(j)}\tilde{y}_j + a_{j+1,j+1}^{(j)}x_{j+1} + \dots + a_{j+1,n}^{(j)}x_n &= \tilde{y}_{j+1}, \\ &\vdots \\ a_{n1}^{(j)}\tilde{y}_1 + \dots + a_{nj}^{(j)}\tilde{y}_j + a_{n,j+1}^{(j)}x_{j+1} + \dots + a_{nn}^{(j)}x_n &= \tilde{y}_n. \end{aligned}$$

Dabei ist $(\tilde{y}_1, \dots, \tilde{y}_j, \tilde{y}_{j+1}, \dots, \tilde{y}_n)$ eine gewisse Permutation der ursprünglichen Variablen $(y_1, \dots, y_n)$. Beim Übergang $A^{(j-1)} \rightarrow A^{(j)}$ wurde die Variable x_j gegen $\tilde{y}_j$ getauscht. Man erhält deshalb $A^{(j)}$ aus $A^{(j-1)}$ nach den folgenden Regeln. Dabei werden der Einfachheit halber die Elemente von $A^{(j-1)}$ mit a_{ik} , die von $A^{(j)}$ mit a'_{ik} bezeichnet:

(4.2.7)

a) *Spaltenpivotsuche: Bestimme r , so daß*

$$|a_{rj}| = \max_{i \geq j} |a_{ij}|.$$

Falls $a_{rj} = 0$, stop: die Matrix ist singulär.

b) *Vertausche die Zeilen r und j von $A^{(j-1)}$ und nenne das Resultat $\bar{A} = (\bar{a}_{ik})$.*

c) *Berechne $A^{(j)} = (a'_{ik})$ nach den Formeln (vgl. (4.2.5))*

$$a'_{jj} := 1/\bar{a}_{jj},$$

$$a'_{jk} = -\frac{\bar{a}_{jk}}{\bar{a}_{jj}}, \quad a'_{ij} = \frac{\bar{a}_{ij}}{\bar{a}_{jj}} \text{ für } i, k \neq j,$$

$$a'_{ik} = \bar{a}_{ik} - \frac{\bar{a}_{ij}\bar{a}_{jk}}{\bar{a}_{jj}}.$$

Wegen (4.2.6) gilt

$$(4.2.8) \quad A^{(n)}\hat{y} = x, \quad \hat{y} = (\hat{y}_1, \dots, \hat{y}_n)^T,$$

wobei $\hat{y}_1, \dots, \hat{y}_n$ eine gewisse Permutation der ursprünglichen Variablen $y_1, \dots, y_n$ ist, $\hat{y} = Py$, die entsprechend den Vertauschungsschritten (4.2.7),

b) leicht bestimmt werden kann. Aus (4.2.8) folgt sofort

$$(A^{(n)}P)y = x,$$

und daher wegen $Ax = y$

$$A^{-1} = A^{(n)}P.$$

Beispiel:

$$\begin{aligned} A = A^{(0)} &:= \begin{bmatrix} 1^* & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 6 \end{bmatrix} \rightarrow A^{(1)} = \begin{bmatrix} 1 & -1 & -1 \\ 1 & 1^* & 2 \\ 1 & 2 & 5 \end{bmatrix} \\ \rightarrow A^{(2)} &= \begin{bmatrix} 2 & -1 & 1 \\ -1 & 1 & -2 \\ -1 & 2 & 1^* \end{bmatrix} \rightarrow A^{(3)} = \begin{bmatrix} 3 & -3 & 1 \\ -3 & 5 & -2 \\ 1 & -2 & 1 \end{bmatrix} = A^{-1}. \end{aligned}$$

Die Pivotelemente sind markiert.

Folgendes ALGOL-Programm ist eine Formulierung des Gauß-Jordan-Verfahrens mit Spaltenpivotsuche. Die $n \times n$ -Matrix A wird mit der Inversen von A überschrieben. Das Feld $p[i]$ dient zur Speicherung der Information über die vorgenommenen Zeilenpermutationen.

```

for  $j := 1$  step 1 until  $n$  do  $p[j] := j$ ;
for  $j := 1$  step 1 until  $n$  do
begin
  pivotsuche:
   $max := abs(a[j, j]); r := j$ ;
  for  $i := j + 1$  step 1 until  $n$  do
    if  $abs(a[i, j])$  greater  $max$  then
      begin  $max := abs(a[i, j]);$ 
         $r := i$ ;
      end;
  if  $max = 0$  then goto singulär;
  zeilentausch:
  if  $r > j$  then
    begin for  $k := 1$  step 1 until  $n$  do
      begin
         $hr := a[j, k]; a[j, k] := a[r, k];$ 
         $a[r, k] := hr$ ;
      end;
       $hi := p[j]; p[j] := p[r]; p[r] := hi$ ;
    end;
    transformation:
     $hr := 1/a[j, j]$ ;
    for  $i := 1$  step 1 until  $n$  do  $a[i, j] := hr \times a[i, j]$ ;
     $a[j, j] := hr$ ;
    for  $k := 1$  step 1 until  $j - 1$ ,  $j + 1$  step 1 until  $n$  do
      begin
        for  $i := 1$  step 1 until  $j - 1$ ,  $j + 1$  step 1 until  $n$  do
           $a[i, k] := a[i, k] - a[i, j] \times a[j, k];$ 
           $a[j, k] := -hr \times a[j, k];$ 
        end  $k$ ;
      end  $j$ ;
    spaltentausch:
    for  $i := 1$  step 1 until  $n$  do
      begin
        for  $k := 1$  step 1 until  $n$  do  $hv[p[k]] := a[i, k];$ 
        for  $k := 1$  step 1 until  $n$  do  $a[i, k] := hv[k];$ 
      end;
    end;

```


4.3 Das Cholesky-Verfahren

Die bisher besprochenen Verfahren zur Gleichungsauflösung können versagen, wenn man keine Pivotsuche durchführt und versucht, sich auf die starre Diagonalphivotreihenfolge zu beschränken. Darüber hinaus wird es sich in den nächsten Abschnitten zeigen, daß auch aus Gründen der numerischen Stabilität eine Pivotsuche ratsam ist. Es gibt jedoch eine wichtige Klasse von Matrizen, für die eine Pivotsuche unnötig ist. Eine beliebige Diagonalphivotwahl führt hier stets zu nicht verschwindenden Pivotelementen. Darüber hinaus ist das Verfahren bei dieser Pivotwahl numerisch stabil. Es handelt sich um die Klasse der positiv definiten Matrizen:

(4.3.1) **Def:** Eine (komplexe) $n \times n$ -Matrix A heißt positiv definit, falls gilt:

- a) $A = A^H$, d. h. A ist eine hermitesche Matrix,
- b) $x^H A x > 0$ für alle $x \in \mathbb{C}^n$, $x \neq 0$.

$A = A^H$ heißt positiv semi-definit, falls $x^H A x \geq 0$ für alle $x \in \mathbb{C}^n$.

Wir zeigen zunächst

(4.3.2) **Satz:** Für positiv definite Matrizen A existiert A^{-1} und A^{-1} ist wieder positiv definit. Alle Hauptuntermatrizen einer positiv definiten Matrix sind positiv definit und alle Hauptminoren einer positiv definiten Matrix sind positiv.

Beweis: Es existiert die Inverse einer positiven definiten Matrix A : Wäre dies nicht der Fall, so existierte ein $x \neq 0$ mit $Ax = 0$ und $x^H A x = 0$, im Widerspruch zur Definitheit von A . A^{-1} ist wieder positiv definit: Es ist $(A^{-1})^H = (A^H)^{-1} = A^{-1}$ und für $y \neq 0$ gilt $x = A^{-1}y \neq 0$. Daher gilt auch $y^H A^{-1}y = x^H A^H A^{-1}Ax = x^H A x > 0$. Wir zeigen weiter, daß jede Hauptuntermatrix

$$\tilde{A} = \begin{bmatrix} a_{i_1 i_1} & \cdots & a_{i_1 i_k} \\ \vdots & & \vdots \\ a_{i_k i_1} & \cdots & a_{i_k i_k} \end{bmatrix}$$

einer positiv definiten Matrix A wieder positiv definit ist: Offensichtlich ist $\tilde{A}^H = \tilde{A}$. Außerdem läßt sich jeder Vektor

$$\tilde{x} = \begin{bmatrix} \tilde{x}_1 \\ \vdots \\ \tilde{x}_k \end{bmatrix} \in \mathbb{C}^k, \quad \tilde{x} \neq 0,$$

zu einem Vektor

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} \in \mathbb{C}^n, \quad x \neq 0, \quad x_\mu := \begin{cases} \tilde{x}_j & \text{falls } \mu = i_j, \quad j = 1, \dots, k, \\ 0 & \text{sonst,} \end{cases}$$

erweitern und es gilt

$$\tilde{x}^H \tilde{A} \tilde{x} = x^H A x > 0.$$

Um (4.3.2) zu beweisen, genügt es daher zu zeigen, daß $\det(A) > 0$ für positiv definite Matrizen A gilt. Dies beweisen wir durch vollständige Induktion nach n .

Für $n = 1$ ist dies wegen (4.3.1), b) richtig. Nehmen wir nun an, daß der Satz für $n - 1$ -reihige positiv definite Matrizen richtig ist, und sei A eine n -reihige positiv definite Matrix. Nach dem bereits Bewiesenen ist

$$A^{-1} =: \begin{bmatrix} \alpha_{11} & \cdots & \alpha_{1n} \\ \vdots & & \vdots \\ \alpha_{n1} & \cdots & \alpha_{nn} \end{bmatrix}$$

wieder positiv definit und daher auch $\alpha_{11} > 0$. Nun gilt nach einer bekannten Formel

$$\alpha_{11} = \det \left(\begin{bmatrix} a_{22} & \cdots & a_{2n} \\ \vdots & & \vdots \\ a_{n2} & \cdots & a_{nn} \end{bmatrix} \right) / \det(A).$$

Nach Induktionsvoraussetzung ist aber

$$\det \left(\begin{bmatrix} a_{22} & \cdots & a_{2n} \\ \vdots & & \vdots \\ a_{n2} & \cdots & a_{nn} \end{bmatrix} \right) > 0,$$

und daher $\det(A) > 0$ wegen $\alpha_{11} > 0$. □

Man zeigt nun leicht

(4.3.3) Satz: Zu jeder positiv definiten $n \times n$ -Matrix A gibt es genau eine untere $n \times n$ -Dreiecksmatrix L , $l_{ik} = 0$ für $k > i$, mit $l_{ii} > 0$, $i = 1, 2, \dots, n$, so daß $A = LL^H$. Für reelles A ist auch L reell.

Man beachte, daß $l_{ii} = 1$ nicht gefordert wird!

Beweis: Den Beweis führt man durch Induktion nach n . Für $n = 1$ ist der Satz trivial: Eine positive definite 1×1 -Matrix $A = (\alpha)$ ist eine positive Zahl $\alpha > 0$, die eindeutig in der Form

$$\alpha = l_{11} \bar{l}_{11}, \quad l_{11} = +\sqrt{\alpha},$$

geschrieben werden kann. Wir nehmen nun an, daß der Satz für $(n - 1)$ -reihige positive definite Matrizen gültig ist. Eine positiv definite $n \times n$ -Matrix A kann man so partitionieren

$$A = \begin{bmatrix} A_{n-1} & b \\ b^H & a_{nn} \end{bmatrix},$$

daß $b \in \mathbb{C}^{n-1}$ gilt und A_{n-1} eine positiv definite $(n-1)$ -reihige Matrix (4.3.2) ist. Nach Induktionsannahme gibt es genau eine $(n-1)$ -reihige Matrix L_{n-1} mit

$$A_{n-1} = L_{n-1} L_{n-1}^H, \quad l_{ik} = 0 \text{ für } k > i, \quad l_{ii} > 0.$$

Wir setzen nun die gesuchte Matrix L in der Form

$$L = \begin{bmatrix} L_{n-1} & 0 \\ c^H & \alpha \end{bmatrix}$$

an und versuchen $c \in \mathbb{C}^{n-1}$, $\alpha > 0$ so zu bestimmen, daß

$$(4.3.4) \quad \begin{bmatrix} L_{n-1} & 0 \\ c^H & \alpha \end{bmatrix} \begin{bmatrix} L_{n-1}^H & c \\ 0 & \alpha \end{bmatrix} = \begin{bmatrix} A_{n-1} & b \\ b^H & a_{nn} \end{bmatrix} = A$$

gilt. Dazu muß zunächst gelten

$$\begin{aligned} L_{n-1}c &= b, \\ c^H c + \alpha^2 &= a_{nn}. \end{aligned}$$

Die erste dieser Gleichungen besitzt genau eine Lösung $c = L_{n-1}^{-1}b$, denn als Dreiecksmatrix mit positiven Diagonalelementen ist L_{n-1} nichtsingulär und es gilt $\det(L_{n-1}) > 0$, so daß (4.3.4) für jedes $\alpha \in \mathbb{C}$ mit $\alpha^2 := a_{nn} - c^H c$ erfüllt ist.

Damit folgt aus (4.3.4) sofort $\alpha^2 > 0$ wegen

$$\det(A) = |\det(L_{n-1})|^2 \alpha^2,$$

$\det(A) > 0$ (4.3.2) und $\det(L_{n-1}) > 0$. Deshalb existiert genau ein $\alpha > 0$ mit $LL^H = A$, nämlich

$$\alpha = +\sqrt{a_{nn} - c^H c}. \quad \square$$

Die Zerlegung $A = LL^H$ bestimmt man ähnlich wie in Abschnitt 4.1. Nimmt man an, daß alle l_{ij} mit $j \leq k-1$ bereits bekannt sind, so folgen aus $A = LL^H$ für l_{kk} und l_{ik} , $i \geq k+1$, die Bestimmungsgleichungen

$$(4.3.5) \quad \begin{aligned} a_{kk} &= |l_{k1}|^2 + |l_{k2}|^2 + \cdots + |l_{kk}|^2, & l_{kk} &> 0, \\ a_{ik} &= l_{i1}\bar{l}_{k1} + l_{i2}\bar{l}_{k2} + \cdots + l_{ik}\bar{l}_{kk}. \end{aligned}$$

Für reelles A erhält man so folgenden Algorithmus:

```

for  $i := 1$  step 1 until  $n$  do
  for  $k := i$  step 1 until  $n$  do
    begin  $x := a[i, k]$ ;
      for  $j := i - 1$  step  $-1$  until 1 do
         $x := x - a[k, j] \times a[i, j]$ ;
      if  $i = k$  then
        begin if  $x \leq 0$  then goto fail;
           $p[i] := 1/\text{sqrt}(x)$ ;
        end else
           $a[k, i] := x \times p[i]$ ;
        end
      end  $i, k$ ;

```

Bei diesem Algorithmus wird nur die Information aus dem oberen Dreieck von A benutzt. Die untere Dreiecksmatrix L wird auf dem unteren Dreieck von A gespeichert mit Ausnahme der Diagonalelemente von L , deren reziproke Werte in p gespeichert sind.

Dieses Verfahren stammt von Cholesky. In seinem Verlauf müssen n Quadratwurzeln gezogen werden. Wegen Satz (4.3.3) ist sichergestellt, daß die Radikanden stets positiv sind. Eine Abschätzung ergibt, daß man außer n Quadratwurzeln noch ca. $n^3/6$ wesentliche Operationen (Multiplikationen und Additionen) benötigt. Für dünn besetzte positiv definite Matrizen sind weitere erhebliche Einsparungen möglich (s. Abschnitt 4.12).

Zum Schluß weisen wir auf eine wichtige Folgerung aus (4.3.5) hin. Es ist

$$(4.3.6) \quad |l_{kj}| \leq \sqrt{a_{kk}}, \quad j = 1, \dots, k, \quad k = 1, 2, \dots, n.$$

Die Elemente der Matrix L können nicht zu groß werden.

4.4 Fehlerabschätzungen

Bestimmt man mit einer der beschriebenen Methoden die Lösung eines linearen Gleichungssystems $Ax = b$, so erhält man in der Regel nur eine Näherungslösung $\tilde{x}$ für die wahre Lösung x und es erhebt sich die Frage, wie man die Genauigkeit von $\tilde{x}$ beurteilt. Um den Fehler

$$\tilde{x} - x$$

zu messen, muß man eine Möglichkeit haben, die „Größe“ eines Vektors $x \in \mathbb{C}^n$ zu messen. Dies geschieht durch die Einführung einer *Norm*

$$(4.4.1) \quad \|x\|$$

im $\mathbb{C}^n$. Man versteht darunter eine reellwertige Funktion

$$\|\cdot\|: \mathbb{C}^n \rightarrow \mathbb{R},$$

die jedem Vektor $x \in \mathbb{C}^n$ eine reelle Zahl $\|x\|$ zuordnet, die als Maß für die „Größe“ von x dienen soll. Diese Funktion soll die folgenden Eigenschaften besitzen:

(4.4.2) **Def:** Die Abbildung $\|\cdot\|: \mathbb{C}^n \rightarrow \mathbb{R}$ heißt eine Norm, wenn gilt

- a) $\|x\| > 0$ für alle $x \in \mathbb{C}^n$, $x \neq 0$ (Definitheit),
- b) $\|\alpha x\| = |\alpha| \|x\|$ für alle $\alpha \in \mathbb{C}$, $x \in \mathbb{C}^n$ (Homogenität),
- c) $\|x + y\| \leq \|x\| + \|y\|$ für alle $x, y \in \mathbb{C}^n$ (Dreiecksungleichung).

Wir benutzen im folgenden nur die Normen

$$(4.4.3) \quad \|x\|_2 := \sqrt{x^H x} = \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2} \quad (\text{„euklidische Norm“}),$$

$$\|x\|_\infty := \max_i |x_i| \quad (\text{„Maximumnorm“}).$$

Die Normeigenschaften a), b), c) bestätigt man hier leicht.

Für jede Norm $\|\cdot\|$ gilt

$$(4.4.4) \quad \|x - y\| \geq \left| \|x\| - \|y\| \right| \quad \text{für alle } x, y \in \mathbb{C}^n.$$

Aus (4.4.2), c) folgt nämlich:

$$\|x\| = \|(x - y) + y\| \leq \|x - y\| + \|y\|,$$

also $\|x - y\| \geq \|x\| - \|y\|$. Durch Vertauschen von x und y und wegen (4.4.2) b) folgt

$$\|x - y\| = \|y - x\| \geq \|y\| - \|x\|,$$

also (4.4.4).

Man zeigt leicht

(4.4.5) **Satz:** Jede Norm $\|\cdot\|$ auf dem $\mathbb{R}^n$ (bzw. $\mathbb{C}^n$) ist eine gleichmäßig stetige Funktion bezüglich der Metrik $\varrho(x, y) := \max_i |x_i - y_i|$ des $\mathbb{R}^n(\mathbb{C}^n)$.

Beweis: Aus (4.4.4) folgt

$$\left| \|x + h\| - \|x\| \right| \leq \|h\|.$$

Nun ist $h = \sum_{i=1}^n h_i e_i$, wenn $h = (h_1, \dots, h_n)^T$ und e_i die Achsenvektoren des $\mathbb{R}^n(\mathbb{C}^n)$ sind. Also gilt

$$\|h\| \leq \sum_{i=1}^n |h_i| \|e_i\| \leq \max_i |h_i| \sum_{j=1}^n \|e_j\| = M \max_i |h_i|$$

mit $M := \sum_{j=1}^n \|e_j\|$. Also gilt für jedes $\varepsilon > 0$ und alle h mit $\max_i |h_i| \leq \varepsilon/M$ die Ungleichung

$$\left| \|x + h\| - \|x\| \right| \leq \varepsilon,$$

d. h. $\|\cdot\|$ ist gleichmäßig stetig. $\square$

Mit Hilfe dieses Resultates beweisen wir

(4.4.6) Satz: *Alle Normen auf dem $\mathbb{R}^n(\mathbb{C}^n)$ sind äquivalent in folgendem Sinne: Für jedes Paar von Normen $p_1(x)$, $p_2(x)$ gibt es Konstanten $m > 0$ und $M > 0$, so daß für alle x gilt*

$$m p_2(x) \leq p_1(x) \leq M p_2(x).$$

Beweis: Wir beweisen dies nur für den Fall $p_2(x) := \|x\| := \max_i |x_i|$ und für den $\mathbb{C}^n$. Der allgemeine Fall folgt leicht aus diesem speziellen Resultat. Die Menge

$$S = \{x \in \mathbb{C}^n \mid \max_i |x_i| = 1\}$$

ist eine kompakte Menge des $\mathbb{C}^n$. Da $p_1(x)$ stetig ist (4.4.5), existieren $\max_{x \in S} p_1(x) = M > 0$ und $\min_{x \in S} p_1(x) = m > 0$. Es gilt daher für alle $y \neq 0$ wegen $y/\|y\| \in S$

$$m \leq p_1\left(\frac{y}{\|y\|}\right) = \frac{1}{\|y\|} p_1(y) \leq M,$$

und daher

$$m\|y\| \leq p_1(y) \leq M\|y\|. \quad \square$$

Auch für Matrizen $A \in M(m, n)$, d. h. für $m \times n$ -Matrizen, kann man Normen $\|A\|$ einführen. Man verlangt hier analog zu (4.4.2):

$$\|A\| > 0 \quad \text{für alle } A \neq 0, \quad A \in M(m, n)$$

$$\|\alpha A\| = |\alpha| \|A\|$$

$$\|A + B\| \leq \|A\| + \|B\|.$$

Die Matrixnorm $\|\cdot\|$ heißt mit den Vektornormen $\|\cdot\|_a$ auf dem $\mathbb{C}^n$ und $\|\cdot\|_b$ auf dem $\mathbb{C}^m$ *verträglich*, falls

$$\|Ax\|_b \leq \|A\| \|x\|_a \quad \text{für alle } x \in \mathbb{C}^n, \quad A \in M(m, n).$$

Eine Matrixnorm $\|\cdot\|$ für quadratische Matrizen $A \in M(n, n)$ nennt man *submultiplikativ* falls

$$\|AB\| \leq \|A\| \|B\| \quad \text{für alle } A, B \in M(n, n).$$

Häufig benutzte Matrixnormen sind

$$(4.4.7a) \quad \|A\| = \max_i \sum_{k=1}^n |a_{ik}| \quad (\text{Zeilensummennorm}),$$

$$(4.4.7b) \quad \|A\| = \left(\sum_{i,k=1}^n |a_{ik}|^2 \right)^{1/2} \quad (\text{Schur-Norm}),$$

$$(4.4.7c) \quad \|A\| = \max_{i,k} |a_{ik}|.$$

a) und b) sind submultiplikativ, c) nicht, b) ist mit der euklidischen Vektornorm verträglich.

Zu einer Vektornorm $\|x\|$ kann man eine zugehörige Matrixnorm für quadratische Matrizen, die *Grenznorm*, definieren durch

$$(4.4.8) \quad \text{lub}(A) := \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}.$$

Eine solche Matrixnorm ist verträglich mit der zugrunde liegenden Vektornorm $\|\cdot\|$:

$$(4.4.9) \quad \|Ax\| \leq \text{lub}(A) \|x\|$$

Offensichtlich ist $\text{lub}(A)$ unter allen mit einer Vektornorm $\|x\|$ verträglichen Matrixnormen $\|A\|$ die kleinste Matrixnorm,

$$\|Ax\| \leq \|A\| \|x\| \quad \text{für alle } x \Rightarrow \text{lub}(A) \leq \|A\|.$$

Jede Grenznorm $\text{lub}(\cdot)$ ist submultiplikativ:

$$\begin{aligned} \text{lub}(AB) &= \max_{x \neq 0} \frac{\|ABx\|}{\|x\|} \leq \max_{x \neq 0} \text{lub}(A) \frac{\|Bx\|}{\|x\|} \\ &= \text{lub}(A) \text{lub}(B), \end{aligned}$$

und es gilt $\text{lub}(I) = 1$.

(4.4.9) zeigt, daß $\text{lub}(A)$ als größte *Abbildungsdehnung* von A verstanden werden kann. Sie gibt an, um wieviel $\|Ax\|$, die Norm des Bildes, größer als die Norm $\|x\|$ des Urbildes sein kann.

Beispiel:

a) Zur Maximumnorm $\|x\|_\infty = \max_v |x_v|$ gehört die Grenznorm

$$\text{lub}_\infty(A) = \max_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_{x \neq 0} \left\{ \frac{\max_i |\sum_{k=1}^n a_{ik} x_k|}{\max_k |x_k|} \right\} = \max_i \sum_{k=1}^n |a_{ik}|.$$

b) Zur euklidischen Norm $\|x\|_2 = \sqrt{x^H x}$ gehört die Grenznorm

$$\text{lub}_2(A) = \max_{x \neq 0} \sqrt{\frac{x^H A^H A x}{x^H x}} = \sqrt{\lambda_{\max}(A^H A)},$$

die man mit Hilfe des größten Eigenwertes $\lambda_{\max}(A^H A)$ der Matrix $A^H A$ ausdrücken kann. Für diese Grenznorm merken wir an, daß für unitäre Matrizen U , die durch $U^H U = I$ definiert sind, gilt

$$(4.4.10) \quad \text{lub}_2(U) = 1.$$

Wir nehmen für das folgende an, daß $\|x\|$ eine beliebige Vektornorm und $\|A\|$ eine damit verträgliche submultiplikative Matrixnorm mit $\|I\| = 1$ ist. Speziell kann man für die Matrixnorm $\|A\|$ stets die Grenznorm $\text{lub}(A)$ nehmen, wenn man besonders gute Abschätzungen erhalten will. Wir wollen diese Normen verwenden, um bei einem linearen Gleichungssystem

$$Ax = b$$

den Einfluß von Änderungen von A und b auf die Lösung x abzuschätzen. Gehört zur rechten Seite $b + \Delta b$ die Lösung $x + \Delta x$,

$$A(x + \Delta x) = b + \Delta b,$$

so folgt aus $A\Delta x = \Delta b$ die Beziehung

$$\Delta x = A^{-1} \Delta b$$

und die Abschätzung:

$$(4.4.11) \quad \|\Delta x\| \leq \|A^{-1}\| \|\Delta b\|.$$

Für die relative Änderung $\|\Delta x\|/\|x\|$ folgt wegen $\|b\| = \|Ax\| \leq \|A\| \|x\|$ die (i.a. schlechte) Abschätzung:

$$(4.4.12) \quad \frac{\|\Delta x\|}{\|x\|} \leq \|A\| \|A^{-1}\| \frac{\|\Delta b\|}{\|b\|} = \text{cond}(A) \frac{\|\Delta b\|}{\|b\|}.$$

Dabei bezeichnet $\text{cond}(A) := \|A\| \|A^{-1}\|$, im speziellen Fall $\text{cond}(A) := \text{lub}(A) \text{lub}(A^{-1})$, die sog. *Kondition* von A . $\text{cond}(A)$ ist ein Maß für die Empfindlichkeit des relativen Fehlers der Lösung x gegenüber Änderungen der rechten Seite b . Für $\text{cond}(A)$ gilt wegen $AA^{-1} = I$

$$\text{lub}(I) = 1 \leq \text{lub}(A) \text{lub}(A^{-1}) \leq \|A\| \|A^{-1}\| = \text{cond}(A).$$

Die Abschätzung (4.4.11) läßt sich auch folgendermaßen interpretieren: Ist $\tilde{x}$ eine Näherungslösung von $Ax = b$ mit dem *Residuum*

$$r(\tilde{x}) := b - A\tilde{x} = A(x - \tilde{x}),$$

so ist $\tilde{x}$ exakte Lösung von

$$A\tilde{x} = b - r(\tilde{x})$$

und es gilt für den Fehler $\Delta x = \tilde{x} - x$ die Abschätzung:

$$(4.4.13) \quad \|\Delta x\| \leq \|A^{-1}\| \|r(\tilde{x})\|.$$

Wir wollen nun den Einfluß von Änderungen der Matrix A auf die Lösung x von $Ax = b$ untersuchen. Wir zeigen zunächst den

(4.4.14) **Hilfssatz:** *Ist F eine $n \times n$ -Matrix mit $\|F\| < 1$, so existiert $(I + F)^{-1}$ und es gilt*

$$\|(I + F)^{-1}\| \leq \frac{1}{1 - \|F\|}.$$

Beweis: Wegen (4.4.4) gilt für alle x die Ungleichung

$$\|(I + F)x\| = \|x + Fx\| \geq \|x\| - \|Fx\| \geq (1 - \|F\|) \|x\|.$$

Wegen $1 - \|F\| > 0$ folgt $\|(I + F)x\| > 0$ für $x \neq 0$, d. h. $(I + F)x = 0$ hat nur die triviale Lösung $x = 0$ und $I + F$ ist nichtsingulär.

Mit der Abkürzung $C := (I + F)^{-1}$ folgt

$$\begin{aligned} 1 = \|I\| &= \|(I + F)C\| = \|C + FC\| \\ &\geq \|C\| - \|C\| \|F\| \\ &= \|C\| (1 - \|F\|) > 0 \end{aligned}$$

und daher das Resultat von (4.4.14)

$$\|(I + F)^{-1}\| \leq \frac{1}{1 - \|F\|}. \quad \square$$

Man kann nun zeigen

(4.4.15) **Satz:** *Sei A eine nichtsinguläre $n \times n$ -Matrix, $B = A(I + F)$, $\|F\| < 1$ und x und Δx definiert durch $Ax = b$, $B(x + \Delta x) = b$. Dann gilt*

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|F\|}{1 - \|F\|},$$

sowie, falls $\text{cond}(A) \cdot \|B - A\|/\|A\| < 1$,

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \text{cond}(A) \frac{\|B-A\|}{\|A\|}} \frac{\|B-A\|}{\|A\|}.$$

Beweis: Wegen (4.4.14) existiert B^{-1} und es gilt

$$\begin{aligned} \Delta x &= B^{-1}b - A^{-1}b = B^{-1}(A - B)A^{-1}b, \quad x = A^{-1}b, \\ \frac{\|\Delta x\|}{\|x\|} &\leq \|B^{-1}(A - B)\| = \|(I + F)^{-1}A^{-1}AF\| \\ &\leq \|(I + F)^{-1}\| \|F\| \leq \frac{\|F\|}{1 - \|F\|}. \end{aligned}$$

Wegen $F = A^{-1}(B - A)$ und $\|F\| \leq \|A^{-1}\| \|A\| \|B - A\|/\|A\|$ folgt sofort der Rest des Satzes. $\square$

Nach Satz (4.4.15) mißt $\text{cond}(A)$ auch die Störempfindlichkeit der Lösung x von $Ax = b$ gegenüber Änderungen der Matrix A .

Berücksichtigt man die Beziehungen

$$C = (I + F)^{-1} = B^{-1}A, \quad F = A^{-1}B - I,$$

so folgt aus (4.4.14)

$$\|B^{-1}A\| \leq \frac{1}{1 - \|I - A^{-1}B\|}.$$

Vertauscht man nun A und B , so folgt aus $A^{-1} = A^{-1}BB^{-1}$ sofort:

$$(4.4.16) \quad \|A^{-1}\| \leq \|A^{-1}B\| \|B^{-1}\| \leq \frac{\|B^{-1}\|}{1 - \|I - B^{-1}A\|}.$$

Insbesondere folgt aus der Residuenabschätzung (4.4.13) die Abschätzung von Collatz:

$$(4.4.17) \quad \|\tilde{x} - x\| \leq \frac{\|B^{-1}\|}{1 - \|I - B^{-1}A\|} \|r(\tilde{x})\|, \quad r(\tilde{x}) = b - A\tilde{x},$$

wobei B^{-1} eine „näherungsweise“ Inverse von A ist: $\|I - B^{-1}A\| < 1$.

Alle diese Ungleichungen zeigen die Bedeutung der Zahl $\text{cond}(A)$ für den Einfluß von Änderungen der Eingangsdaten auf die Lösung. Die Abschätzungen geben Schranken für den Fehler $\tilde{x} - x$ an, und für die Auswertung der Schranken muß man zumindest näherungsweise die Inverse A^{-1} von A kennen. Die nun zu besprechenden Abschätzungen von Prager und Oettli (1964) beruhen auf einem anderen Prinzip und benötigen nicht die Kenntnis von A^{-1} .

Man kommt zu den Resultaten durch folgende Überlegung:

Gewöhnlich sind die Ausgangsdaten A_0, b_0 eines Gleichungssystems $A_0x = b_0$ ungenau, z. B. mit Meßfehlern $\Delta A, \Delta b$ behaftet. Es ist daher sinnvoll, eine näherungsweise Lösung $\tilde{x}$ des Systems $A_0x = b_0$ als „richtig“ zu akzeptieren, wenn $\tilde{x}$ exakte Lösung eines „benachbarten“ Gleichungssystems

$$A\tilde{x} = b$$

mit

$$(4.4.18) \quad \begin{aligned} A &\in \mathcal{A} := \{ A \mid |A - A_0| \leq \Delta A \} \\ b &\in \mathcal{B} := \{ b \mid |b - b_0| \leq \Delta b \} \end{aligned}$$

ist. Hier bedeuten

$$\begin{aligned} |A| &= (|\alpha_{ik}|), \quad \text{falls } A = (\alpha_{ik}) \\ |b| &= (|\beta_1|, \dots, |\beta_n|)^T, \quad \text{falls } b = (\beta_1, \dots, \beta_n)^T, \end{aligned}$$

und das Zeichen $\leq$ zwischen Vektoren, Matrizen usw. ist komponentenweise zu verstehen. Prager und Oettli bewiesen den folgenden

(4.4.19) **Satz:** Sei $\Delta A \geq 0, \Delta b \geq 0$ und $\mathcal{A}, \mathcal{B}$ durch (4.4.18) definiert. Zu einer näherungsweisen Lösung $\tilde{x}$ des Gleichungssystems $A_0x = b_0$ gibt es genau dann eine Matrix $A \in \mathcal{A}$ und einen Vektor $b \in \mathcal{B}$ mit

$$A\tilde{x} = b,$$

wenn gilt

$$|r(\tilde{x})| \leq \Delta A |\tilde{x}| + \Delta b.$$

Hier ist $r(\tilde{x}) := b_0 - A_0\tilde{x}$ das Residuum von $\tilde{x}$.

Beweis: 1) Wir nehmen zunächst an, daß für ein $A \in \mathcal{A}, b \in \mathcal{B}$ gilt

$$A\tilde{x} = b.$$

Dann folgt aus

$$\begin{aligned} A &= A_0 + \delta A, \quad \text{mit } |\delta A| \leq \Delta A, \\ b &= b_0 + \delta b, \quad \text{mit } |\delta b| \leq \Delta b, \end{aligned}$$

sofort

$$\begin{aligned} |r(\tilde{x})| &= |b_0 - A_0\tilde{x}| = |b - \delta b - (A - \delta A)\tilde{x}| \\ &= |-\delta b + (\delta A)\tilde{x}| \leq |\delta b| + |\delta A| |\tilde{x}| \\ &\leq \Delta b + \Delta A |\tilde{x}|. \end{aligned}$$

2) Sei nun umgekehrt

$$(4.4.20) \quad |r(\tilde{x})| \leq \Delta b + \Delta A |\tilde{x}|.$$

Mit den Bezeichnungen

$$\begin{aligned} \tilde{x} &:= (\xi_1, \dots, \xi_n)^T, & b_0 &:= (\beta_1, \dots, \beta_n)^T, \\ r &:= r(\tilde{x}) = (\rho_1, \dots, \rho_n)^T, \\ s &:= \Delta b + \Delta A |\tilde{x}| \geq 0, & s &:= (\sigma_1, \dots, \sigma_n)^T, \end{aligned}$$

setze man

$$\delta A := (\delta \alpha_{ij}), \quad \delta b := \begin{bmatrix} \delta \beta_1 \\ \vdots \\ \delta \beta_n \end{bmatrix},$$

$$\delta \alpha_{ij} := \rho_i \Delta \alpha_{ij} \operatorname{sign}(\xi_j) / \sigma_i,$$

$$\delta \beta_i := -\rho_i \Delta \beta_i / \sigma_i, \quad \text{mit} \quad \rho_i / \sigma_i := 0, \quad \text{falls} \quad \sigma_i = 0.$$

Aus (4.4.20) folgt sofort $|\rho_i / \sigma_i| \leq 1$ und daher

$$A = A_0 + \delta A \in \mathcal{A}, \quad b = b_0 + \delta b \in \mathcal{B},$$

sowie für $i = 1, 2, \dots, n$:

$$\begin{aligned} \rho_i &= \beta_i - \sum_{j=1}^n \alpha_{ij} \xi_j = \left(\Delta \beta_i + \sum_{j=1}^n \Delta \alpha_{ij} |\xi_j| \right) \frac{\rho_i}{\sigma_i} \\ &= -\delta \beta_i + \sum_{j=1}^n \delta \alpha_{ij} \xi_j \end{aligned}$$

oder

$$\sum_{j=1}^n (\alpha_{ij} + \delta \alpha_{ij}) \xi_j = \beta_i + \delta \beta_i,$$

d. h. $A \tilde{x} = b$, was zu beweisen war. $\square$

Das Kriterium von Satz (4.4.19) erlaubt es, aus der Kleinheit des Residuums auf die Brauchbarkeit einer Lösung zu schließen. Besitzen z. B. alle Komponenten von A_0 und b_0 dieselbe relative Genauigkeit ε ,

$$\Delta A = \varepsilon |A_0|, \quad \Delta b = \varepsilon |b_0|,$$

so ist (4.4.19) erfüllt, falls gilt

$$|A_0 \tilde{x} - b_0| \leq \varepsilon (|b_0| + |A_0| |\tilde{x}|).$$

Aus dieser Ungleichung kann man sofort das kleinste ε berechnen, für welches ein gegebenes $\tilde{x}$ noch als brauchbare Lösung akzeptiert werden kann.

4.5 Rundungsfehleranalyse der Gaußschen Eliminationsmethode

Bei der Diskussion der Verfahren zur Gleichungsauflösung spielte die Pivotsuche bisher nur folgende Rolle: Sie stellt sicher, daß bei nichtsingulären Matrizen A der Algorithmus nicht vorzeitig abbricht, weil ein Pivotelement verschwindet. Wir werden nun zeigen, daß auch die Gutartigkeit der Gleichungsauflösung von der rechten Pivotwahl abhängt. Um dies zu illustrieren, betrachten wir folgendes einfache Beispiel. Gegeben sei das Problem, die Lösung des Gleichungssystems

$$(4.5.1) \quad \begin{bmatrix} 0.005 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0.5 \\ 1 \end{bmatrix}$$

mit Hilfe der Gaußschen Eliminationsmethode zu berechnen. Seine exakte Lösung ist $x = 5000/9950 = 0.503\dots$, $y = 4950/9950 = 0.497\dots$. Nimmt man das Element $a_{11} = 0.005$ im ersten Schritt als Pivotelement, so erhält man bei 2-stelliger Gleitpunktrechnung folgende Resultate

$$\begin{bmatrix} 0.005 & 1 \\ 0 & -200 \end{bmatrix} \begin{bmatrix} \tilde{x} \\ \tilde{y} \end{bmatrix} = \begin{bmatrix} 0.5 \\ -99 \end{bmatrix}, \quad \tilde{y} = 0.5, \quad \tilde{x} = 0.$$

Wählt man im ersten Schritt $a_{21} = 1$ als Pivotelement, so erhält man bei 2-stelliger Rechnung

$$\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \tilde{x} \\ \tilde{y} \end{bmatrix} = \begin{bmatrix} 1 \\ 0.5 \end{bmatrix}, \quad \tilde{y} = 0.50, \quad \tilde{x} = 0.50.$$

Im zweiten Fall ist die Genauigkeit des Resultats erheblich größer. Dies könnte den Eindruck erwecken, daß in jedem Fall das betragsgrößte Element einer Spalte als Pivot die numerisch günstigsten Ergebnisse liefert. Eine einfache Überlegung zeigt aber, daß dies nur bedingt richtig sein kann. Multipliziert man etwa die erste Zeile des Gleichungssystems (4.5.1) mit 200, so erhält man das System

$$(4.5.2) \quad \begin{bmatrix} 1 & 200 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 100 \\ 1 \end{bmatrix},$$

das dieselbe Lösung wie (4.5.1) besitzt. Das Element $\tilde{a}_{11} = 1$ ist jetzt ebenso groß wie $\tilde{a}_{21} = 1$. Die Wahl von $\tilde{a}_{11}$ als Pivotelement führt jedoch zu

demselben ungenauen Resultat wie vorher. Bei der betrachteten Operation hat man die Matrix A von (4.5.1) durch $\tilde{A} = DA$ ersetzt, wobei D die Diagonalmatrix

$$D = \begin{bmatrix} 200 & 0 \\ 0 & 1 \end{bmatrix}$$

ist. Offensichtlich kann man auch die Spalten von A umnormieren, d.h. A durch $\tilde{A} = AD$, D eine Diagonalmatrix ersetzen, ohne die Lösung von $Ax = b$ wesentlich zu ändern: Ist x Lösung von $Ax = b$, so ist $y = D^{-1}x$ Lösung von $\tilde{A}y = (AD)(D^{-1}x) = b$. Allgemein spricht man von einer *Skalierung* einer Matrix A , wenn man A durch D_1AD_2 , D_1, D_2 Diagonalmatrizen, ersetzt. Das Beispiel zeigt, daß es nicht sinnvoll ist, eine bestimmte Pivotsuche ohne Voraussetzungen über die Skalierung einer Matrix zu empfehlen. Leider ist es bisher nicht befriedigend geklärt, wie man eine Matrix A skalieren muß, damit etwa die Teilpivotsuche zu einem gutartigen Algorithmus führt. Praktische Erfahrungen legen jedoch für die Teilpivotsuche folgende Skalierung nahe: Man wähle D_1 und D_2 so, daß für $\tilde{A} = D_1AD_2$ näherungsweise

$$\sum_{k=1}^n |\tilde{a}_{ik}| \approx \sum_{j=1}^n |\tilde{a}_{jl}|$$

für alle $i, l = 1, 2, \dots, n$ gilt: Die Summe der Beträge der Elemente in den Zeilen bzw. Spalten von $\tilde{A}$ sollten ungefähr die gleiche Größenordnung haben. Man nennt solche Matrizen $\tilde{A}$ *equilibriert*.

Leider ist es i.a. recht schwierig D_1 und D_2 so zu bestimmen, daß D_1AD_2 equilibriert ist. Gewöhnlich behilft man sich auf folgende Weise: Man wählt $D_2 = I$, $D_1 = \text{diag}(s_1, \dots, s_n)$ mit

$$s_i := \frac{1}{\sum_{k=1}^n |a_{ik}|}.$$

Es gilt dann jedenfalls für $\tilde{A} = D_1AD_2$

$$\sum_{k=1}^n |\tilde{a}_{ik}| = 1 \text{ für } i = 1, 2, \dots, n.$$

Statt nun A durch $\tilde{A}$ zu ersetzen, d.h. die Skalierung wirklich durchzuführen, bevor man auf $\tilde{A}$ den Eliminationsalgorithmus mit Teilpivotsuche anwendet, ersetzt man, um die explizite Skalierung von A zu vermeiden, die Pivotsuche im j -ten Eliminationsschritt $A^{(j-1)} \rightarrow A^{(j)}$ durch die Regel

(4.5.3) Bestimme $r \geq j$ so, daß

$$|a_{rj}^{(j-1)}| s_r = \max_{i \geq j} |a_{ij}^{(j-1)}| s_i \neq 0.$$

$a_{rj}^{(j-1)}$ wird dann als Pivotelement genommen.

Obiges Beispiel zeigt auch, daß es i.a. nicht genügt, die Matrix A vor einer Teilpivotsuche so zu skalieren, daß die betragsgrößten Elemente in jeder Zeile und Spalte von A ungefähr den gleichen Betrag haben:

$$(4.5.4) \quad \max_k |a_{ik}| \approx \max_j |a_{jl}| \quad \text{für alle } i, l = 1, 2, \dots, n.$$

Wählt man nämlich die Skalierungsmatrizen

$$D_1 = \begin{bmatrix} 200 & 0 \\ 0 & 1 \end{bmatrix}, \quad D_2 = \begin{bmatrix} 1 & 0 \\ 0 & 0.005 \end{bmatrix}$$

so wird die Matrix A aus dem Beispiel (4.5.1) zu

$$\tilde{A} = D_1 A D_2 = \begin{bmatrix} 1 & 1 \\ 1 & 0.005 \end{bmatrix},$$

die die Normierungsbedingung (4.5.4) erfüllt und für die trotzdem $\tilde{a}_{11} = 1$ betragsgrößtes Element in der ersten Spalte ist.

Wir wollen nun den Einfluß der Rundungsfehler, die bei der Gauß-Elimination bzw. Dreieckszerlegung (s. 4.1) auftreten, im Detail studieren. Dabei setzen wir voraus, daß die Zeilen der $n \times n$ -Matrix A bereits so geordnet sind, daß A eine Dreieckszerlegung der Form $A = LR$ besitzt. L und R können dann mittels der Formeln (4.1.12) berechnet werden. Dabei hat man im Grunde nur Formeln des Typs

$$b_n := \text{gl} \left(\frac{c - a_1 b_1 - \dots - a_{n-1} b_{n-1}}{a_n} \right)$$

auszuwerten, wie sie in (1.4.4)-(1.4.11) analysiert wurden. Statt der exakten Dreieckszerlegung $LR = A$ erhält man bei Verwendung von Gleitpunktarithmetik aus (4.1.12) Matrizen $\bar{L} = (\bar{l}_{ik})$, $\bar{R} = (\bar{r}_{ik})$ für die das Residuum $F := (f_{ik}) = A - \bar{L}\bar{R}$ i.a. nicht verschwindet. Da nach (4.1.13) die j -ten Partialsummen

$$\bar{a}_{ik}^{(j)} = \text{gl} \left(a_{ik} - \sum_{s=1}^j \bar{l}_{is} \bar{r}_{sk} \right)$$

gerade die Elemente der Matrix $\bar{A}^{(j)}$ sind, die man statt $A^{(j)}$ (4.1.6) bei der Durchführung der Gauß-Elimination in Gleitpunktarithmetik nach dem j -ten Eliminationsschritt erhält, ergeben die Abschätzungen (1.4.7) angewandt auf (4.1.12) sofort mit $\text{eps}' := \text{eps}/(1 - \text{eps})$

(4.5.5)

$$|f_{ik}| = \left| a_{ik} - \sum_{j=1}^i \bar{l}_{ij} \bar{r}_{jk} \right| \leq \text{eps}' \sum_{j=1}^{i-1} (|\bar{a}_{ik}^{(j)}| + |\bar{l}_{ij}| |\bar{r}_{jk}|), \quad k \geq i,$$

$$|f_{ki}| = \left| a_{ki} - \sum_{j=1}^i \bar{l}_{kj} \bar{r}_{ji} \right| \leq \text{eps}' \left[|\bar{a}_{ki}^{(i-1)}| + \sum_{j=1}^{i-1} (|\bar{a}_{ki}^{(j)}| + |\bar{l}_{kj}| |\bar{r}_{ji}|) \right], \quad k > i.$$

Ferner ist

$$(4.5.6) \quad \bar{r}_{ik} = \bar{a}_{ik}^{(i-1)} \text{ für } i \leq k,$$

da sich die ersten $j + 1$ Zeilen von $\bar{A}^{(j)}$ (bzw. $A^{(j)}$, s.(4.1.6)) in den folgenden Eliminationsschritten nicht mehr ändern und so schon mit den entsprechenden Zeilen von $\bar{R}$ übereinstimmen. Wir setzen nun zusätzlich $|\bar{l}_{ik}| \leq 1$ für alle i, k voraus (z. B. erfüllt, falls Teil- oder Totalpivotsuche vorgenommen wurde). Mit

$$a_j := \max_{i,k} |\bar{a}_{ik}^{(j)}|, \quad a := \max_{0 \leq i \leq n-1} a_i,$$

folgen sofort aus (4.5.5) und (4.5.6) die Abschätzungen

$$(4.5.7) \quad \begin{aligned} |f_{ik}| &\leq \frac{\text{eps}}{1 - \text{eps}} (a_0 + 2a_1 + 2a_2 + \cdots + 2a_{i-2} + a_{i-1}) \\ &\leq 2(i-1)a \frac{\text{eps}}{1 - \text{eps}} \text{ für } k \geq i, \\ |f_{ik}| &\leq \frac{\text{eps}}{1 - \text{eps}} (a_0 + 2a_1 + \cdots + 2a_{k-2} + 2a_{k-1}) \\ &\leq 2ka \frac{\text{eps}}{1 - \text{eps}} \text{ für } k < i. \end{aligned}$$

Für die Matrix F gilt daher die Ungleichung

$$(4.5.8) \quad |F| \leq 2a \frac{\text{eps}}{1 - \text{eps}} \begin{bmatrix} 0 & 0 & 0 & \cdots & 0 & 0 \\ 1 & 1 & 1 & \cdots & 1 & 1 \\ 1 & 2 & 2 & \cdots & 2 & 2 \\ 1 & 2 & 3 & \cdots & 3 & 3 \\ \vdots & \vdots & \vdots & & \vdots & \vdots \\ 1 & 2 & 3 & \cdots & n-1 & n-1 \end{bmatrix}$$

mit $|F| := (|f_{jk}|)$. Besitzt a die gleiche Größenordnung wie a_0 , d. h. wachsen die Matrizen $\bar{A}^{(j)}$ nicht zu sehr an, so ist das Produkt $\bar{L}\bar{R}$ der berechneten Matrizen die exakte Dreieckszerlegung der Matrix $A - F$, die sich nur wenig von A unterscheidet: Die Gauß-Elimination ist in diesem fall gutartig.

Die Größe a kann man mit Hilfe von $a_0 = \max_{r,s} |a_{rs}|$ abschätzen. Bei Teilpivotsuche kann man sofort

$$a_{k-1} \leq 2^k a_0$$

zeigen, also $a \leq 2^{n-1} a_0$. Diese Schranke ist jedoch in den meisten Fällen viel zu pessimistisch, sie kann jedoch erreicht werden, etwa bei der Dreieckszerlegung der Matrix

$$A = \begin{bmatrix} 1 & 0 & \dots & 0 & 1 \\ -1 & \ddots & \ddots & \vdots & \vdots \\ \vdots & \ddots & \ddots & 0 & \vdots \\ \vdots & & \ddots & 1 & 1 \\ -1 & \dots & \dots & -1 & 1 \end{bmatrix}.$$

Für spezielle Typen von Matrizen gibt es bessere Abschätzungen, so z.B. bei *Hessenberg-Matrizen*, das sind Matrizen der Form

$$A = \begin{bmatrix} x & \dots & \dots & x \\ x & \ddots & & \vdots \\ & \ddots & \ddots & \vdots \\ 0 & & x & x \end{bmatrix},$$

für die man sofort $a \leq (n-1)a_0$ zeigen kann. Hessenberg-Matrizen treten im Zusammenhang mit Eigenwertproblemen auf.

Für Tridiagonalmatrizen

$$A = \begin{bmatrix} \alpha_1 & \beta_2 & & 0 \\ \gamma_2 & \ddots & \ddots & \\ \vdots & \ddots & \ddots & \ddots \\ \vdots & & \ddots & \ddots & \beta_n \\ 0 & & & \gamma_n & \alpha_n \end{bmatrix}$$

kann man sogar zeigen, daß bei Teilpivotsuche folgende Abschätzung gilt

$$a = \max_k |a_k| \leq 2a_0.$$

Der Gaußsche Algorithmus ist also in diesem Fall besonders gutartig.

Für die Totalpivotsuche zeigte Wilkinson (1965) die Ungleichung

$$a_{k-1} \leq f(k)a_0$$

mit der Funktion

$$f(k) := k^{1/2} [2^1 3^{1/2} 4^{1/3} \dots k^{1/(k-1)}]^{1/2},$$

die mit k relativ langsam wächst,

k	10	20	50	100
$f(k)$	19	67	530	3300

Aber auch diese Abschätzung ist sehr pessimistisch: In der Regel gelten bei Totalpivotsuche die Beziehungen

$$a_k \leq (k+1)a_0, \quad k = 1, 2, \dots, n-1,$$

für die man erst vor kurzem Ausnahmen gefunden hat. Dies zeigt, daß gewöhnlich die Gauß-Elimination mit Totalpivotsuche ein gutartiger Prozeß ist. Trotzdem zieht man in der Rechenpraxis meistens die Teilpivotsuche aus folgenden Gründen vor:

1. Die Totalpivotsuche ist aufwendiger als die Teilpivotsuche: zur Berechnung von $A^{(i)}$ muß das Maximum von $(n-i+1)^2$ Elementen bestimmt werden gegenüber $n-i+1$ Elementen bei der Teilpivotsuche.

2. Spezielle Strukturen einer Matrix, z. B. die Bandstruktur einer Tridiagonalmatrix, werden bei Totalpivotsuche zerstört, bei Teilpivotsuche nicht.

Benutzt man statt (1.4.7) die schwächeren Abschätzungen (1.4.11), so erhält man statt (4.5.5) für die f_{ik} die Schranken

$$|f_{ik}| \leq \frac{\text{eps}}{1 - n \cdot \text{eps}} \left[\sum_{j=1}^i j |\bar{l}_{ij}| |\bar{r}_{jk}| - |\bar{r}_{ik}| \right], \quad k \geq i,$$

$$|f_{ki}| \leq \frac{\text{eps}}{1 - n \cdot \text{eps}} \left[\sum_{j=1}^i j |\bar{l}_{kj}| |\bar{r}_{ji}| \right], \quad k \geq i+1,$$

oder

$$(4.5.9) \quad |F| \leq \frac{\text{eps}}{1 - n \cdot \text{eps}} \left[|\bar{L}| D |\bar{R}| - |\bar{R}| \right],$$

mit

$$D := \begin{bmatrix} 1 & & & 0 \\ & 2 & & \\ & & \ddots & \\ 0 & & & n \end{bmatrix}.$$

4.6 Rundungsfehlereinfluß bei der Auflösung von gestaffelten Gleichungssystemen

Als Resultat der Gauß-Elimination einer Matrix A erhält man eine untere Dreiecksmatrix $\bar{L}$ und eine obere Dreiecksmatrix $\bar{R}$, deren Produkt $\bar{L}\bar{R}$ näherungsweise A ist. Die Lösung eines Gleichungssystems $Ax = b$ wird damit auf die Lösung der beiden gestaffelten Gleichungssysteme

$$\bar{L}y = b, \quad \bar{R}x = y$$

zurückgeführt. Wir wollen nun den Einfluß der Rundungsfehler auf die Lösung solcher Gleichungssysteme untersuchen. Bezeichnet man mit $\bar{y}$ die Lösung, die man bei Gleitpunktrechnung der Genauigkeit eps erhält, so gilt nach Definition von $\bar{y}$

$$(4.6.1) \quad \bar{y}_r = \text{gl}((-\bar{l}_{r1}\bar{y}_1 - \bar{l}_{r2}\bar{y}_2 - \cdots - \bar{l}_{r,r-1}\bar{y}_{r-1} + b_r)/\bar{l}_{rr}).$$

Aus (1.4.10), (1.4.11) folgt sofort

$$\left| b_r - \sum_{j=1}^r \bar{l}_{rj}\bar{y}_j \right| \leq \frac{\text{eps}}{1 - n \text{eps}} \left[\sum_{j=1}^r j |\bar{l}_{rj}| |\bar{y}_j| - |\bar{y}_r| \right]$$

oder

$$(4.6.2) \quad |b - \bar{L}\bar{y}| \leq \frac{\text{eps}}{1 - n \text{eps}} (|\bar{L}|D - I)|\bar{y}|, \quad D := \begin{bmatrix} 1 & & & 0 \\ & 2 & & \\ & & \ddots & \\ 0 & & & n \end{bmatrix}.$$

Es gibt also eine Matrix $\Delta\bar{L}$ mit

$$(4.6.3) \quad (\bar{L} + \Delta\bar{L})\bar{y} = b, \quad |\Delta\bar{L}| \leq \frac{\text{eps}}{1 - n \text{eps}} (|\bar{L}|D - I).$$

Die berechnete Lösung läßt sich also als exakte Lösung eines nur leicht abgeänderten Problems interpretieren, so daß das Auflösen gestaffelter Gleichungssysteme gutartig ist. Analog findet man für die berechnete Lösung $\bar{x}$ von $\bar{R}x = \bar{y}$ die Schranken

$$(4.6.4) \quad |\bar{y} - \bar{R}\bar{x}| \leq \frac{\text{eps}}{1 - n \text{eps}} |\bar{R}| E |\bar{x}|, \quad E := \begin{bmatrix} n & & & 0 \\ & \ddots & & \\ & & 2 & \\ 0 & & & 1 \end{bmatrix},$$

$$(\bar{R} + \Delta\bar{R})\bar{x} = \bar{y}, \quad |\Delta\bar{R}| \leq \frac{\text{eps}}{1 - n \text{eps}} |\bar{R}| E.$$

Durch Zusammenfassung der Abschätzungen (4.5.9), (4.6.3) und (4.6.4) zeigt man nun leicht folgendes von Sautter (1971) stammende Resultat für die Näherungslösung $\bar{x}$ eines linearen Gleichungssystems $Ax = b$, die man bei Gleitpunktrechnung erhält:

$$(4.6.5) \quad |b - A\bar{x}| \leq \frac{2(n+1)\text{eps}}{1 - n\text{eps}} |\bar{L}||\bar{R}||\bar{x}|, \quad \text{falls } n\text{eps} \leq \frac{1}{2}.$$

Beweis: Mit $\varepsilon := \text{eps}/(1 - n\text{eps})$ folgt wegen (4.5.9), (4.6.3) und (4.6.4)

$$\begin{aligned} |b - A\bar{x}| &= |b - (\bar{L}\bar{R} + F)\bar{x}| = |-F\bar{x} + b - \bar{L}(\bar{y} - \Delta\bar{R}\bar{x})| \\ &= |(-F + \Delta\bar{L}(\bar{R} + \Delta\bar{R}) + \bar{L}\Delta\bar{R})\bar{x}| \\ &\leq \varepsilon [2(|\bar{L}|D - I)|\bar{R}| + |\bar{L}||\bar{R}|E + \varepsilon(|\bar{L}|D - I)|\bar{R}|E]|\bar{x}|. \end{aligned}$$

Die (i, k) -Komponente der Matrix [...] der letzten Zeile hat die Form

$$\sum_{j=1}^{\min(i,k)} |\bar{l}_{ij}| (2j - 2\delta_{ij} + n + 1 - k + \varepsilon(j - \delta_{ij} + n + 1 - k)) |\bar{r}_{jk}|,$$

$$\delta_{ij} := \begin{cases} 1 & \text{für } i = j, \\ 0 & \text{für } i \neq j. \end{cases}$$

Nun bestätigt man leicht, daß für alle $j \leq \min(i, k)$, $1 \leq i, k \leq n$ gilt

$$\begin{aligned} &2j - 2\delta_{ij} + n + 1 - k + \varepsilon(j - \delta_{ij} + n + 1 - k) \\ &\leq \begin{cases} 2n - 1 + \varepsilon \cdot n, & \text{falls } j \leq i \leq k, \\ 2n + \varepsilon(n + 1), & \text{falls } j \leq k < i, \end{cases} \\ &\leq 2n + 2, \end{aligned}$$

wegen $\varepsilon \cdot n \leq 2n\text{eps} \leq 1$. Damit ist (4.6.5) bewiesen. $\square$

Ein Vergleich von (4.6.5) mit dem Satz (4.4.19) von Prager und Oettli zeigt schließlich, daß die berechnete Lösung $\bar{x}$ als exakte Lösung eines nur leicht abgeänderten Gleichungssystems interpretiert werden kann, wenn die Matrix $n|\bar{L}||\bar{R}|$ dieselbe Größenordnung wie $|A|$ besitzt. In diesen Fällen ist die Gauß-Elimination ein gutartiger Algorithmus.

4.7 Orthogonalisierungsverfahren. Die Verfahren von Householder und Schmidt

Die bisherigen Methoden, ein Gleichungssystem

$$(4.7.1) \quad Ax = b$$

zu lösen, bestanden darin, Gleichung (4.7.1) mit geeigneten Matrizen P_j , $j = 1, \dots, n$, von links zu multiplizieren, so daß das schließlich entstehende System

$$A^{(n)}x = b^{(n)}$$

direkt gelöst werden kann. Nun wird die Empfindlichkeit des Resultates x gegenüber Änderungen in den Daten $A^{(j)}$, $b^{(j)}$ des Zwischensystems

$$A^{(j)}x = b^{(j)}, \quad [A^{(j)}, b^{(j)}] = P_j[A^{(j-1)}, b^{(j-1)}],$$

gemessen durch

$$\text{cond}(A^{(j)}) = \text{lub}(A^{(j)}) \text{lub}((A^{(j)})^{-1}).$$

Bezeichnet man mit $\varepsilon^{(j)}$ die Rundungsfehler, die man beim Übergang $[A^{(j-1)}, b^{(j-1)}]$ nach $[A^{(j)}, b^{(j)}]$ begeht, so wirken sich diese Rundungsfehler mit dem Faktor $\text{cond}(A^{(j)})$ verstärkt auf das Endresultat x aus und es gilt (s. (4.4.12), (4.4.15))

$$\frac{\|\Delta x\|}{\|x\|} \leq \sum_{j=0}^{n-1} \varepsilon^{(j)} \text{cond}(A^{(j)}),$$

wobei $\varepsilon^{(0)}$ Fehler in den Eingangsdaten A, b bedeuten. Wenn es ein $A^{(j)}$ mit

$$\text{cond}(A^{(j)}) \gg \text{cond}(A^{(0)})$$

gibt, ist der Rechenprozeß nicht gutartig: Der Rundungsfehler $\varepsilon^{(j)}$ wirkt sich stärker auf das Endresultat aus als der Eingangsfehler $\varepsilon^{(0)}$.

Man wird daher bestrebt sein, die Matrizen P_j so zu wählen, daß die Konditionen $\text{cond}(A^{(j)})$ nicht wachsen. Für eine beliebige Vektornorm ist dies ein schwieriges Problem. Für die euklidische Norm

$$\|x\| = \sqrt{x^H x},$$

und die damit verträgliche Grenznorm

$$\text{lub}(A) = \max_{x \neq 0} \sqrt{\frac{x^H A^H A x}{x^H x}}$$

sind die Verhältnisse jedoch übersichtlicher. Deshalb werden in diesem Abschnitt nur diese Normen benutzt. Wenn U eine unitäre Matrix ist, $U^H U = I$, so gilt für diese Norm

$$\begin{aligned}\text{lub}(A) &= \text{lub}(U^H U A) \leq \text{lub}(U^H) \text{lub}(U A) = \text{lub}(U A) \\ &\leq \text{lub}(U) \text{lub}(A) = \text{lub}(A),\end{aligned}$$

also

$$\text{lub}(U A) = \text{lub}(A)$$

und ebenso $\text{lub}(A U) = \text{lub}(A)$.

Insbesondere folgt für unitäres U

$$\text{cond}(A) = \text{lub}(A) \text{lub}(A^{-1}) = \text{cond}(U A).$$

Wählt man also die Transformationsmatrizen P_j unitär, so ist man sicher, daß die Kondition der Gleichungssysteme $A^{(j)}x = b^{(j)}$ sich nicht ändert, also sich nicht verschlechtern kann. Gleichzeitig sollen natürlich die P_j so gewählt werden, daß die Matrizen $A^{(j)}$ einfacher werden. Nach Householder kann man das in der folgenden Weise erreichen.

Man wählt die unitäre Matrix P

$$P := I - 2ww^H \text{ mit } w^H w = 1, w \in \mathbb{C}^n.$$

Diese Matrix ist hermitesch,

$$P^H = I^H - (2ww^H)^H = I - 2ww^H = P,$$

unitär,

$$\begin{aligned}P^H P &= P P = P^2 = (I - 2ww^H)(I - 2ww^H) \\ &= I - 2ww^H - 2ww^H + 4ww^H ww^H \\ &= I,\end{aligned}$$

und daher involutorisch, $P^2 = I$. Die Abbildung $x \mapsto y = Px = x - 2(w^H x)w$ beschreibt eine Spiegelung an der Ebene $\{z \mid w^H z = 0\}$. Es gilt für $y = Px$

$$(4.7.2) \quad y^H y = x^H P^H P x = x^H x,$$

$$(4.7.3) \quad x^H y = x^H P x = (x^H P x)^H,$$

so daß $x^H y$ eine reelle Zahl ist. Wir versuchen nun einen Vektor w und damit P so zu bestimmen, daß ein gegebenes

$$x = (x_1, \dots, x_n)^T$$

in ein Vielfaches des ersten Achsenvektors e_1 transformiert wird,

$$k e_1 = P x.$$

Aus (4.7.2) folgt sofort für k

$$|k|^2 = \|x\|^2 = x^H x$$

und, weil $k x^H e_1$ nach (4.7.3) reell ist,

$$k = \mp e^{i\alpha} \sigma, \quad \sigma := \sqrt{x^H x},$$

wenn $x_1 = e^{i\alpha} |x_1|$. Dabei kann das Vorzeichen in k noch beliebig gewählt werden. Ferner folgt aus

$$P x = x - 2(w^H x)w = k e_1$$

und der Bedingung $w^H w = 1$,

$$w = \frac{x - k e_1}{\|x - k e_1\|}.$$

Nun ist wegen $x_1 = e^{i\alpha} |x_1|$

$$\begin{aligned} \|x - k e_1\| &= \|x \pm \sigma e^{i\alpha} e_1\| = \sqrt{|x_1 \pm \sigma e^{i\alpha}|^2 + |x_2|^2 + \cdots + |x_n|^2} \\ &= \sqrt{(|x_1| \pm \sigma)^2 + |x_2|^2 + \cdots + |x_n|^2}. \end{aligned}$$

Damit bei der Berechnung von $|x_1| \pm \sigma$ keine Auslöschung auftritt, wählt man bei der Definition von k das obere Vorzeichen,

$$k = -\sigma e^{i\alpha},$$

und erhält

$$(4.7.4) \quad |x_1 - k|^2 = |x_1 + \sigma e^{i\alpha}|^2 = |\sigma + |x_1||^2 = \sigma^2 + 2\sigma |x_1| + |x_1|^2.$$

Es folgt:

$$\|x - k e_1\|^2 = 2\sigma^2 + 2\sigma |x_1|, \quad 2w w^H = 2 \frac{(x - k e_1)(x - k e_1)^H}{\|x - k e_1\|^2}.$$

Die Matrix $P = I - 2w w^H$ läßt sich dann in der Form schreiben

$$P = I - \beta u u^H$$

mit

$$(4.7.5) \quad \sigma = \sqrt{\sum_{i=1}^n |x_i|^2}, \quad x_1 = e^{i\alpha} |x_1|, \quad k = -\sigma e^{i\alpha}$$

$$u = x - k e_1 = \begin{bmatrix} e^{i\alpha}(|x_1| + \sigma) \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, \quad \beta = (\sigma(\sigma + |x_1|))^{-1}.$$

Diese sog. *Householdertransformationen* bzw. die so konstruierten Matrizen P , die sog. *Householder-Matrizen*, kann man nun benutzen, um eine Matrix $A \equiv A^{(0)}$ schrittweise mit orthogonalen Matrizen P_j ,

$$A^{(j)} = P_j A^{(j-1)},$$

in eine obere Dreiecksmatrix

$$A^{(n-1)} = R = \begin{bmatrix} r_{11} & \cdots & r_{1n} \\ & \ddots & \vdots \\ 0 & & r_{nn} \end{bmatrix}$$

zu transformieren. Dazu bestimmt man nach (4.7.5) die unitäre $n \times n$ -Matrix P_1 derart, daß gilt

$$P_1 a_1^{(0)} = k e_1.$$

Dabei ist $a_1^{(0)}$ die erste Spalte von $A^{(0)}$.

Hat man nach $j-1$ Schritten eine Matrix $A^{(j-1)}$ der Gestalt:

$$(4.7.6) \quad A^{(j-1)} = \left[\begin{array}{ccc|ccc} x & \cdots & x & x & \cdots & x \\ & & \vdots & \vdots & & \vdots \\ & & \ddots & \vdots & & \vdots \\ 0 & & x & x & \cdots & x \\ \hline & & & a_{jj}^{(j-1)} & \cdots & a_{jn}^{(j-1)} \\ & & & \vdots & & \vdots \\ 0 & & & a_{nj}^{(j-1)} & \cdots & a_{nn}^{(j-1)} \end{array} \right] \begin{matrix} \left. \vphantom{\begin{matrix} x & \cdots & x \\ & & \vdots \\ & & \ddots \\ 0 & & x \end{matrix}} \right\}^{j-1} \\ \left. \vphantom{\begin{matrix} a_{jj}^{(j-1)} & \cdots & a_{jn}^{(j-1)} \\ \vdots & & \vdots \\ a_{nj}^{(j-1)} & \cdots & a_{nn}^{(j-1)} \end{matrix}} \right\}^{n-j+1} \end{matrix} = \begin{bmatrix} D & B \\ 0 & \tilde{A}^{(j-1)} \end{bmatrix},$$

so bestimmt man nach (4.7.5) die unitäre $(n-j+1)$ -reihige Matrix $\tilde{P}_j$ derart, daß

$$\tilde{P}_j \begin{bmatrix} a_{jj}^{(j-1)} \\ \vdots \\ a_{nj}^{(j-1)} \end{bmatrix} = k \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \in \mathbb{C}^{n-j+1},$$

und erweitert $\tilde{P}_j$ zu einer ebenfalls unitären $n \times n$ -Matrix

$$P_j = \left[\begin{array}{cc} I_{j-1} & 0 \\ 0 & \tilde{P}_j \end{array} \right]_{j-1}^{n-j+1}.$$

Bildet man nun $A^{(j)} = P_j A^{(j-1)}$, so sieht man, daß die Elemente $a_{ij}^{(j)}$ für $i > j$ verschwinden und daß die in (4.7.6) mit x bezeichneten Elemente unverändert bleiben. Man erhält so nach $n-1$ Schritten eine obere Dreiecksmatrix

$$R := A^{(n-1)}.$$

Bei der praktischen Durchführung der Householdertransformation beachte man, daß die in der j -ten Spalte von $A^{(j)}$ freiwerdenden Stellen unterhalb der Diagonalen benutzt werden können, um den Vektor u und damit die wichtigste Information über die Householdermatrix P zu speichern. Da der Vektor u , der zu $\tilde{P}_j$ gehört, $n-j+1$ wesentliche Komponenten besitzt, aber in $A^{(j)}$ nur $n-j$ Plätze frei werden, schafft man für u dadurch Platz, indem man die Diagonalelemente der Matrizen $A^{(j)}$ in einem besonderen Vektor d abspeichert.

Die Transformation mit der Matrix

$$\tilde{P}_j = I - \beta_j u_j u_j^H$$

führt man aus wie folgt

$$\tilde{P}_j \tilde{A}^{(j-1)} = \tilde{A}^{(j-1)} - u_j y_j^H \text{ mit } y_j^H = \beta_j u_j^H \tilde{A}^{(j-1)},$$

indem man zunächst den Vektor y_j berechnet und dann $\tilde{A}^{(j-1)}$ entsprechend modifiziert.

Das folgende ALGOL-Programm enthält den wesentlichen Teil der Householdertransformation einer gegebenen reellen Matrix, die auf dem Feld a gespeichert ist.

```

for  $j := 1$  step 1 until  $n$  do
begin
   $\sigma := 0$ ;
  for  $i := j$  step 1 until  $n$  do  $\sigma := \sigma + a[i, j] \uparrow 2$ ;
  if  $\sigma = 0$  then goto singular;
   $s := d[j] = \text{if } a[j, j] < 0 \text{ then } \sqrt{\sigma} \text{ else } -\sqrt{\sigma}$ ;
   $\beta := 1/(s \times a[j, j] - \sigma)$ ;  $a[j, j] := a[j, j] - s$ ;
  for  $k := j + 1$  step 1 until  $n$  do
    begin
       $\text{sum} := 0$ ;
      for  $i := j$  step 1 until  $n$  do
         $\text{sum} := \text{sum} + a[i, j] \times a[i, k]$ ;
       $\text{sum} := \beta \times \text{sum}$ ;
      for  $i := j$  step 1 until  $n$  do
         $a[i, k] := a[i, k] + a[i, j] \times \text{sum}$ ;
    end;
  end;

```

Die Householderreduktion einer Matrix auf Dreiecksgestalt benötigt etwa $2n^3/3$ Operationen.

Bei diesem Verfahren wird eine unitäre $n \times n$ -Matrix $P = P_{n-1} \cdots P_1$ als Produkt von Householder-Matrizen P_i und eine obere $n \times n$ -Dreiecksmatrix R bestimmt, so daß

$$PA = R$$

oder

$$(4.7.7) \quad A = P^{-1}R = QR, \quad Q := P^{-1} = P^H,$$

gilt. Wir haben $A = QR$ als Produkt einer unitären Matrix Q und einer oberen Dreiecksmatrix R dargestellt. Sie heißt *QR-Zerlegung* von A . Eine solche Zerlegung kann man aber auch direkt durch die Anwendung des Gram-Schmidtschen *Orthonormalisierungsverfahrens* auf die Spalten a_i von $A = (a_1, \dots, a_n)$ erhalten. Die Gleichung $A = QR$, $Q = (q_1, \dots, q_n)$, besagt gerade, daß die k -te Spalte a_k von A

$$a_k = \sum_{i=1}^k r_{ik} q_i, \quad k = 1, \dots, n,$$

eine Linearkombination der orthonormalen Vektoren $q_1, q_2, \dots, q_k$ ist, so daß auch umgekehrt q_k Linearkombination der ersten k Spalten $a_1, \dots, a_k$ von A ist. Die Spalten von Q und R können deshalb mit dem Gram-Schmidt-Verfahren rekursiv bestimmt werden: Zum Start hat man zu setzen

$$r_{11} := \|a_1\|, \quad q_1 := a_1/r_{11}.$$

Kennt man bereits die orthonormalen Vektoren $q_1, \dots, q_{k-1}$ und die Elemente r_{ij} mit $j \leq k-1$ von R , so werden die Zahlen $r_{1k}, \dots, r_{k-1,k}$ so bestimmt, daß der Vektor

$$(4.7.8) \quad b_k := a_k - r_{1k}q_1 - \dots - r_{k-1,k}q_{k-1}$$

zu allen $q_i, i = 1, \dots, k-1$ orthogonal wird. Wegen

$$q_i^H q_j = \begin{cases} 1 & \text{für } i = j \\ 0 & \text{sonst} \end{cases} \quad \text{für } 1 \leq i, j \leq k-1,$$

führen die Bedingungen $q_i^H b_k = 0$ sofort zu

$$(4.7.9) \quad r_{ik} := q_i^H a_k, \quad i = 1, \dots, k-1.$$

Nachdem man die $r_{ik}, i \leq k-1$, und damit b_k bestimmt hat, setzt man schließlich

$$(4.7.10) \quad r_{kk} := \|b_k\|, \quad q_k := b_k/r_{kk},$$

so daß (4.7.8) äquivalent ist mit

$$a_k = \sum_{i=1}^k r_{ik} q_i$$

und überdies nach Konstruktion für alle $1 \leq i, j \leq k$ gilt

$$q_i^H q_j = \begin{cases} 1 & \text{für } i = j, \\ 0 & \text{sonst} \end{cases}$$

In dieser Form hat der letzte Algorithmus einen schwerwiegenden Nachteil: Er ist nicht gutartig in den Fällen, in denen die Spalten der Matrix A nahezu linear abhängig sind. In diesem Fall ist der Vektor $\bar{b}_k$, den man unter dem Einfluß von Rundungsfehlern statt des Vektors b_k aus den Formeln (4.7.8), (4.7.9) erhält, nicht mehr orthogonal zu den Vektoren $q_1, \dots, q_{k-1}$. Kleinste Rundungsfehler bei der Bestimmung der r_{ik} aus (4.7.9) zerstören mehr oder weniger die Orthogonalität. Wir wollen dies an folgendem speziellen Fall diskutieren, der dem Fall $k=1$ in (4.7.8) entspricht. Gegeben seien zwei reelle Vektoren a und q , die wir der Einfachheit halber als normiert voraussetzen $\|a\| = \|q\| = 1$. Für ihr Skalarprodukt $\rho_0 := q^T a$ gilt dann $|\rho_0| \leq 1$. Wir nehmen an, daß $|\rho_0| < 1$ gilt, daß also a und q linear unabhängig sind. Der Vektor

$$b = b(\rho) := a - \rho q$$

ist dann für $\rho = \rho_0$ orthogonal zu q . Allgemein gilt jedoch für den Winkel $\alpha(\rho)$ zwischen $b(\rho)$ und q :

$$f(\rho) := \cos \alpha(\rho) = \frac{q^T b(\rho)}{\|b(\rho)\|} = \frac{q^T a - \rho}{\|a - \rho q\|},$$

$$\alpha(\rho_0) = \pi/2, \quad f(\rho_0) = 0.$$

Durch Differentiation nach ρ findet man

$$f'(\rho_0) = \frac{-1}{\|a - \rho_0 q\|} = \frac{-1}{\sqrt{1 - \rho_0^2}}$$

$$\alpha'(\rho_0) = \frac{1}{\sqrt{1 - \rho_0^2}}$$

wegen

$$\|a - \rho_0 q\|^2 = a^T a - 2\rho_0 a^T q + \rho_0^2 q^T q = 1 - \rho_0^2.$$

In erster Näherung gilt also für kleines $\Delta\rho_0$

$$\alpha(\rho_0 + \Delta\rho_0) \doteq \frac{\pi}{2} + \frac{\Delta\rho_0}{\sqrt{1 - \rho_0^2}}.$$

Je näher $|\rho_0|$ bei 1 liegt, d. h. je linear abhängiger a und q sind, desto mehr zerstören selbst kleine Fehler $\Delta\rho_0$, insbesondere die Rundungsfehler, die man bei der Berechnung von $\rho_0 = q^T a$ begeht, die Orthogonalität von $b(\rho)$ und q .

Da gerade die Orthogonalität der Vektoren q_i für das Verfahren wesentlich ist, hilft man sich in der Rechenpraxis mit folgendem Trick. Man führt für die Vektoren $\tilde{b}_k$, die man bei der Auswertung von (4.7.8), (4.7.9) statt der exakten b_k gefunden hat, eine *Nachorthogonalisierung* durch, d. h. man berechnet einen Vektor $\tilde{b}_k$ und Δr_{ik} aus

$$\tilde{b}_k = \bar{b}_k - \Delta r_{1k} q_1 - \cdots - \Delta r_{k-1,k} q_{k-1}$$

mit

$$\Delta r_{ik} := q_i^T \bar{b}_k, \quad i = 1, \dots, k-1,$$

so daß bei exakter Rechnung $\tilde{b}_k^T q_i = 0$, $i = 1, \dots, k-1$. Da $\bar{b}_k$ zumindest näherungsweise orthogonal zu den q_i ist, sind die Δr_{ik} kleine Zahlen und nach der eben beschriebenen Theorie haben die Rundungsfehler, die man bei der Berechnung von Δr_{ik} begeht, nur einen geringen Einfluß auf die Orthogonalität von $\tilde{b}_k$ und q_i , so daß im Rahmen der Maschinengenauigkeit der Vektor

$$q_k := \tilde{b}_k / \tilde{r}_{kk}, \quad \tilde{r}_{kk} := \|\tilde{b}_k\|,$$

orthogonal zu den bereits bekannten Vektoren $q_1, \dots, q_{k-1}$ ist. Die Werte $\tilde{r}_{ik}$, die man bei der Auswertung von (4.7.9) gefunden hat, korrigiert man entsprechend, man setzt

$$r_{ik} := \tilde{r}_{ik} + \Delta r_{ik}.$$

Natürlich bedeutet die Nachorthogonalisierung eine Verdopplung des Rechenaufwands!

4.8 Ausgleichsrechnung

Bei vielen wissenschaftlichen Beobachtungen geht es darum, die Werte gewisser Konstanten

$$x_1, x_2, \dots, x_n$$

zu bestimmen. Häufig ist es jedoch nicht oder nur schwer möglich, die interessierenden Größen x_i direkt zu messen. Man geht dann auf folgende indirekte Weise vor: Statt der x_i mißt man eine andere leichter der Messung zugängliche Größe y , die auf eine bekannte gesetzmäßige Weise von den x_i und von weiteren kontrollierbaren „Versuchsbedingungen“, die wir durch die Variable z symbolisieren wollen, abhängt:

$$y = f(z; x_1, \dots, x_n).$$

Um die x_i zu bestimmen, führt man unter m verschiedenen Versuchsbedingungen $z_1, \dots, z_m$ Experimente durch, mißt die zugehörigen Resultate

$$(4.8.0.1) \quad y_k = f(z_k; x_1, \dots, x_n), \quad k = 1, 2, \dots, m,$$

und versucht durch Rechnung die Größen $x_1, \dots, x_n$ so zu bestimmen, daß die Gleichungen (4.8.0.1) erfüllt sind. Natürlich muß man i.a. mindestens m Experimente, $m \geq n$ durchführen, damit durch (4.8.0.1) die x_i eindeutig bestimmt sind. Für $m > n$ ist (4.8.0.1) aber ein überbestimmtes Gleichungssystem für die unbekannten Parameter $x_1, \dots, x_n$, das gewöhnlich keine Lösung besitzt, weil die y_i als Meßresultate mit unvermeidlichen Meßfehlern behaftet sind. Es stellt sich damit das Problem, (4.8.0.1) wenn schon nicht exakt, so doch „möglichst gut“ zu lösen. Als „möglichst gute“ Lösungen von (4.8.0.1) bezeichnet man gewöhnlich entweder solche, die den Ausdruck

$$(4.8.0.2) \quad \sum_{k=1}^m (y_k - f_k(x_1, \dots, x_n))^2,$$

oder den Ausdruck

$$(4.8.0.3) \quad \max_{1 \leq k \leq m} |y_k - f_k(x_1, \dots, x_n)|$$

minimieren. Hier bedeutet

$$f_k(x_1, \dots, x_n) := f(z_k; x_1, \dots, x_n).$$

Im ersten Fall wird die euklidische Norm des Fehlers minimiert und man hat ein Problem der Ausgleichsrechnung im engeren Sinne vor sich, das bereits von Gauß („Methode der kleinsten Quadrate“) studiert wurde. In der mathematischen Statistik (siehe z.B. G. Guest (1961)) wird gezeigt, daß die so erhaltene Lösung x besonders einfache statistische Eigenschaften besitzt. Neuerdings werden jedoch auch die Lösungen x betrachtet, die die Maximumnorm (4.8.0.3) des Fehlers minimieren („diskretes Tschebyscheff-Problem“). Da die Berechnung der besten Lösung x in diesem Fall schwieriger ist als bei der Methode der kleinsten Quadrate, wollen wir im folgenden nicht näher darauf eingehen.

Wenn die Funktionen $f_k(x_1, \dots, x_n)$ stetige partielle Ableitungen nach allen Variablen x_i besitzen, läßt sich sofort eine notwendige Bedingung dafür angeben, daß $x = (x_1, \dots, x_n)^T$ (4.8.0.2) minimiert.

$$(4.8.0.4) \quad \frac{\partial}{\partial x_i} \sum_{k=1}^m (y_k - f_k(x_1, \dots, x_n))^2 = 0, \quad i = 1, \dots, n.$$

Dies sind die sog. *Normalgleichungen* für x .

Ein wichtiger Spezialfall, das *lineare Ausgleichsproblem*, liegt vor, wenn die Funktionen $f_k(x_1, \dots, x_n)$ lineare Funktionen der x_i sind: Es gibt dann eine $m \times n$ -Matrix A mit

$$\begin{bmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{bmatrix} = Ax.$$

In diesem Fall reduzieren sich die Normalgleichungen (4.8.0.4) auf ein lineares Gleichungssystem

$$\text{grad}_x((y - Ax)^T(y - Ax)) = 2A^T Ax - 2A^T y = 0$$

oder

$$(4.8.0.5) \quad A^T Ax = A^T y.$$

Wir werden uns in den folgenden Abschnitten (4.8.1–4.8.3) mit Methoden zur Lösung des linearen Ausgleichsproblems befassen und insbesondere zeigen, daß es gutartigere Methoden gibt, als die Lösung mittels der Normalgleichungen.

Eine eingehende Behandlung von Ausgleichsproblemen findet man bei Björck (1990) und in dem Buch von Lawson und Hanson (1974), das auch FORTRAN-Programme enthält. ALGOL-Programme findet man bei Wilkinson und Reinsch (1971).

4.8.1 Das lineare Ausgleichsproblem.

Die Normalgleichungen

In den folgenden Abschnitten sei $\|x\| := \sqrt{x^T x}$ stets die euklidische Norm. Gegeben sei eine $m \times n$ -Matrix A und ein Vektor $y \in \mathbb{R}^m$, gesucht wird ein Vektor $x \in \mathbb{R}^n$, der die Funktion

$$(4.8.1.1) \quad \|y - Ax\|^2 = (y - Ax)^T (y - Ax)$$

minimiert. Wir wollen zeigen, daß $x \in \mathbb{R}^n$ genau dann Lösung der Normalgleichungen

$$(4.8.1.2) \quad A^T A x = A^T y$$

ist, wenn x auch Optimallösung von (4.8.1.1) ist. Es gilt nämlich

(4.8.1.3) **Satz:** *Das lineare Ausgleichsproblem*

$$\min_{x \in \mathbb{R}^n} \|y - Ax\|$$

besitzt mindestens eine Lösung x_0 . Ist x_1 eine weitere Lösung, so gilt $Ax_0 = Ax_1$. Das Residuum $r := y - Ax_0$ ist eindeutig bestimmt und genügt der Gleichung $A^T r = 0$. Jede Lösung x_0 ist auch Lösung der Normalgleichungen (4.8.1.2) und umgekehrt.

Beweis: Sei $L \subseteq \mathbb{R}^m$ der lineare Teilraum

$$L = \{Ax \mid x \in \mathbb{R}^n\},$$

der von den Spalten von A aufgespannt wird und $L^\perp$ der zugehörige Orthogonalraum

$$L^\perp := \{r \mid r^T z = 0 \text{ für alle } z \in L\} = \{r \mid r^T A = 0\}.$$

Wegen $\mathbb{R}^m = L \oplus L^\perp$ läßt sich der Vektor $y \in \mathbb{R}^m$ eindeutig in der Form

$$(4.8.1.4) \quad y = s + r, \quad s \in L, \quad r \in L^\perp,$$

schreiben, so daß es mindestens ein x_0 mit $Ax_0 = s$ gibt. Wegen $A^T r = 0$ gilt für x_0

$$A^T y = A^T s = A^T A x_0,$$

d.h. x_0 ist Lösung der Normalgleichungen. Umgekehrt entspricht jeder Lösung x_1 der Normalgleichungen die Zerlegung (4.8.1.4)

$$y = s + r, \quad s := Ax_1, \quad r := y - Ax_1, \quad s \in L, \quad r \in L^\perp.$$

Wegen der Eindeutigkeit der Zerlegung (4.8.1.4) gilt damit $Ax_0 = Ax_1$ für alle Lösungen x_0, x_1 der Normalgleichungen. Darüber hinaus ist jede Lösung x_0 der Normalgleichungen Optimallösung von

$$\min_{x \in \mathbb{R}^n} \|y - Ax\|.$$

Ist nämlich x beliebig und setzt man

$$z = Ax - Ax_0, \quad r := y - Ax_0,$$

so gilt wegen $r^T z = 0$

$$\|y - Ax\|^2 = \|r - z\|^2 = \|r\|^2 + \|z\|^2 \geq \|r\|^2 = \|y - Ax_0\|^2,$$

d.h. x_0 ist Optimallösung: Damit ist Satz (4.8.1.3) bewiesen. $\square$

Sind die Spalten von A linear unabhängig, d.h. folgt aus $x \neq 0$ auch $Ax \neq 0$, so ist die Matrix $A^T A$ nichtsingulär (und positiv definit). Andernfalls gäbe es ein $x \neq 0$ mit $A^T Ax = 0$ und es wäre sowohl $Ax \neq 0$ als auch im Widerspruch dazu

$$0 = x^T A^T Ax = \|Ax\|^2.$$

In diesem Fall besitzen die Normalgleichungen

$$A^T Ax = A^T y$$

eine eindeutig bestimmte Lösung $x = (A^T A)^{-1} A^T y$, die man mit den Methoden von Abschnitt 4.3 (Cholesky-Zerlegung von $A^T A$) bestimmen kann. Wir werden jedoch in den folgenden Abschnitten sehen, daß es gutartigere Methoden zur Lösung des linearen Ausgleichsproblems gibt.

An dieser Stelle wollen wir noch kurz auf die statistische Bedeutung der Matrix $(A^T A)^{-1}$ eingehen. Dazu nehmen wir an, daß die Komponenten von $y_i, i = 1, \dots, m$, unabhängige Zufallsvariable mit dem Mittelwert μ_i und gleicher Streuung σ^2 sind, d.h. mit dem Erwartungswertoperator $E[\cdot]$ gilt

$$E[y_i] = \mu_i,$$

$$E[(y_i - \mu_i)(y_k - \mu_k)] = \begin{cases} \sigma^2 & \text{für } i = k, \\ 0 & \text{sonst.} \end{cases}$$

Setzt man $\mu := (\mu_1, \dots, \mu_m)^T$, so ist dies gleichbedeutend mit

$$(4.8.1.5) \quad E[y] = \mu, \quad E[(y - \mu)(y - \mu)^T] = \sigma^2 I.$$

Die Kovarianzmatrix des Zufallsvektors y ist also gleich $\sigma^2 I$. Mit y ist natürlich auch die Optimallösung $x = (A^T A)^{-1} A^T y$ des linearen Ausgleichsproblems ein Zufallsvektor. Sein Mittelwert ist

$$\begin{aligned} E[x] &= E[(A^T A)^{-1} A^T y] \\ &= (A^T A)^{-1} A^T E[y] \\ &= (A^T A)^{-1} A^T \mu, \end{aligned}$$

seine Kovarianzmatrix:

$$\begin{aligned} E[(x - E(x))(x - E(x))^T] &= E[(A^T A)^{-1} A^T (y - \mu)(y - \mu)^T A (A^T A)^{-1}] \\ &= (A^T A)^{-1} A^T E[(y - \mu)(y - \mu)^T] A (A^T A)^{-1} = \sigma^2 (A^T A)^{-1}. \end{aligned}$$

4.8.2 Orthogonalisierungsverfahren zur Lösung des linearen Ausgleichsproblems

Das Ausgleichsproblem, ein $x \in \mathbb{R}^n$ zu bestimmen, das

$$\|y - Ax\|, \quad (A \in M(m, n), m \geq n)$$

minimiert, kann man mit dem in 4.7 besprochenen Orthogonalisierungsverfahren lösen. Dazu transformiert man die Matrix $A \equiv: A^{(0)}$ und den Vektor $y \equiv: y^{(0)}$ durch eine Sequenz von n Householdertransformationen P_i , $A^{(i)} = P_i A^{(i-1)}$, $y^{(i)} = P_i y^{(i-1)}$. Die Endmatrix $A^{(n)}$ besitzt wegen $m \geq n$ folgende Form:

$$(4.8.2.1) \quad A^{(n)} = \begin{bmatrix} R \\ 0 \end{bmatrix}_{m-n}^n \quad \text{mit} \quad R = \begin{bmatrix} r_{11} & \cdots & r_{1n} \\ & \ddots & \vdots \\ 0 & & r_{nn} \end{bmatrix}.$$

Den Vektor $h := y^{(n)}$ partitioniert man entsprechend

$$(4.8.2.2) \quad h = \begin{bmatrix} h_1 \\ h_2 \end{bmatrix}, \quad h_1 \in \mathbb{R}^n, \quad h_2 \in \mathbb{R}^{m-n}.$$

Die Matrix $P = P_n \cdots P_1$ ist als Produkt unitärer Matrizen wieder unitär

$$P^H P = P_1^H \cdots P_n^H P_n \cdots P_1 = I$$

und es gilt

$$A^{(n)} = PA, \quad h = Py.$$

Nun läßt eine unitäre Transformation die Länge $\|u\|$ eines Vektors u invariant, $\|Pu\|^2 = u^H P^H Pu = u^H u = \|u\|^2$, so daß

$$\|y - Ax\| = \|P(y - Ax)\| = \|y^{(n)} - A^{(n)}x\|.$$

Nach (4.8.2.1) und (4.8.2.2) hat der Vektor $y^{(n)} - A^{(n)}x$ aber die Form

$$y^{(n)} - A^{(n)}x = \begin{bmatrix} h_1 - Rx \\ h_2 \end{bmatrix}.$$

Die Länge $\|y - Ax\|$ wird also minimal, wenn man x so wählt, daß gilt

$$(4.8.2.3) \quad h_1 = Rx.$$

Die Matrix R besitzt genau dann eine Inverse, falls die Spalten von A linear unabhängig sind. $Az = 0$ ist nämlich äquivalent mit

$$PAz = 0$$

und deshalb mit

$$Rz = 0.$$

Nehmen wir nun an, daß die Spalten von A linear unabhängig sind, so läßt sich die Gleichung

$$h_1 = Rx$$

eindeutig nach x auflösen (gestaffeltes Gleichungssystem) und die Lösung x des Ausgleichsproblems ist eindeutig bestimmt. (Sind die Spalten von A und damit die Spalten von R linear abhängig, so ist zwar $\min_z \|y - Az\|$ eindeutig bestimmt, es gibt jedoch mehrere minimierende Lösungen x).

Für den Fehler $\|y - Ax\|$ erhält man übrigens sofort

$$(4.8.2.4) \quad \|y - Ax\| = \|h_2\|.$$

Anstelle des Householderverfahrens kann auch das Gram-Schmidtsche Orthogonalisierungsverfahren, ggf. mit Nachorthogonalisierung, zur Lösung verwendet werden.

4.8.3 Die Kondition des linearen Ausgleichsproblems

Wir wollen in diesem Abschnitt zunächst untersuchen wie sich die Lösung x eines linearen Ausgleichsproblems

$$(4.8.3.1) \quad \min_x \|y - Ax\|$$

ändert, wenn man die Matrix A und den Vektor y stört. Wir setzen voraus, daß die Spalten von A linear unabhängig sind. Ersetzt man die Matrix A durch $A + \Delta A$ und y durch $y + \Delta y$, so ändert sich die Lösung $x = (A^T A)^{-1} A^T y$ von (4.8.3.1) in

$$x + \Delta x = ((A + \Delta A)^T (A + \Delta A))^{-1} (A + \Delta A)^T (y + \Delta y).$$

Ist die Störung ΔA genügend klein gegenüber A , so existiert die Matrix $((A + \Delta A)^T (A + \Delta A))^{-1}$ und es gilt in erster Näherung

$$\begin{aligned} ((A + \Delta A)^T (A + \Delta A))^{-1} &\doteq \\ &\doteq (A^T A (I + (A^T A)^{-1} [A^T \Delta A + \Delta A^T A]))^{-1} \\ &\doteq (I - (A^T A)^{-1} [A^T \Delta A + \Delta A^T A]) (A^T A)^{-1}. \end{aligned}$$

(Es gilt nämlich in erster Näherung $(I + F)^{-1} \doteq I - F$, sofern die Matrix F „klein“ gegenüber I ist.) Es folgt daher

(4.8.3.2)

$$\begin{aligned} x + \Delta x &\doteq (A^T A)^{-1} A^T y - (A^T A)^{-1} [A^T \Delta A + \Delta A^T A] (A^T A)^{-1} A^T y \\ &\quad + (A^T A)^{-1} \Delta A^T y + (A^T A)^{-1} A^T \Delta y. \end{aligned}$$

Berücksichtigt man

$$x = (A^T A)^{-1} A^T y$$

und führt man das Residuum

$$r := y - Ax$$

ein, so folgt aus (4.8.3.2) sofort

$$\Delta x \doteq -(A^T A)^{-1} A^T \Delta A x + (A^T A)^{-1} \Delta A^T r + (A^T A)^{-1} A^T \Delta y$$

und daher für die euklidische Norm $\|\cdot\|$ und die zugehörige Matrixnorm lub (man beachte, daß (4.4.8) auch für nichtquadratische Matrizen lub sinnvoll definiert).

$$\begin{aligned} \|\Delta x\| &\leq \text{lub}((A^T A)^{-1} A^T) \text{lub}(A) \frac{\text{lub}(\Delta A)}{\text{lub}(A)} \|x\| \\ (4.8.3.3) \quad &+ \text{lub}((A^T A)^{-1}) \text{lub}(A^T) \text{lub}(A) \frac{\text{lub}(\Delta A^T)}{\text{lub}(A^T)} \frac{\|r\|}{\|Ax\|} \|x\| \\ &+ \text{lub}((A^T A)^{-1} A^T) \text{lub}(A) \frac{\|y\|}{\|Ax\|} \frac{\|\Delta y\|}{\|y\|} \|x\|. \end{aligned}$$

Diese Abschätzung kann vereinfacht werden. Nach den Resultaten von Abschnitt 4.8.2 kann man eine unitäre Matrix P und eine obere Dreiecksmatrix R finden mit

$$PA = \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad A = P^T \begin{bmatrix} R \\ 0 \end{bmatrix}$$

und es folgt

$$(4.8.3.4) \quad \begin{aligned} A^T A &= R^T R, \\ (A^T A)^{-1} &= R^{-1} (R^T)^{-1}, \\ (A^T A)^{-1} A^T &= [R^{-1}, 0] P. \end{aligned}$$

Berücksichtigt man, daß für die euklidische Norm gilt

$$\begin{aligned} \text{lub}(C^T) &= \text{lub}(C) \\ \text{lub}(PC) &= \text{lub}(CP) = \text{lub}(C), \end{aligned}$$

falls P unitär ist, so folgt aus (4.8.3.3) und (4.8.3.4) das Resultat

$$\begin{aligned} \frac{\|\Delta x\|}{\|x\|} &\leq \text{cond}(R) \frac{\text{lub}(\Delta A)}{\text{lub}(A)} + \text{cond}(R)^2 \frac{\|r\|}{\|Ax\|} \frac{\text{lub}(\Delta A)}{\text{lub}(A)} \\ &\quad + \text{cond}(R) \frac{\|y\|}{\|Ax\|} \frac{\|\Delta y\|}{\|y\|}. \end{aligned}$$

Definiert man den Winkel φ durch

$$\tan \varphi = \frac{\|r\|}{\|Ax\|}, \quad 0 \leq \varphi < \frac{\pi}{2},$$

so gilt $\|y\|/\|Ax\| = (1 + \tan^2 \varphi)^{1/2}$ wegen $y = Ax + r$, $r \perp Ax$, und es folgt

$$(4.8.3.5) \quad \begin{aligned} \frac{\|\Delta x\|}{\|x\|} &\leq \text{cond}(R) \frac{\text{lub}(\Delta A)}{\text{lub}(A)} + \text{cond}(R)^2 \tan \varphi \frac{\text{lub}(\Delta A)}{\text{lub}(A)} \\ &\quad + \text{cond}(R) \sqrt{1 + \tan^2 \varphi} \frac{\|\Delta y\|}{\|y\|}. \end{aligned}$$

Die Kondition des Ausgleichsproblems hängt also von $\text{cond}(R)$ und dem Winkel φ ab: Für kleines φ , etwa falls $\text{cond}(R) \tan \varphi \leq 1$, wird die Kondition des Problems durch $\text{cond}(R)$ gemessen; mit wachsendem $\varphi \uparrow \pi/2$ wird die Kondition immer schlechter: sie wird dann durch die Zahl $\text{cond}(R)^2 \tan \varphi$ bestimmt.

Berechnet man nun die Optimallösung x des linearen Ausgleichsproblems mit Hilfe des in 4.8.2 beschriebenen Orthogonalisierungsverfahrens,

so erhält man bei exakter Rechnung eine unitäre Matrix P (als Produkt von Householdermatrizen), eine obere Dreiecksmatrix R , einen Vektor $h^T = (h_1^T, h_2^T)$ und die Lösung x des Problems mit

$$(4.8.3.6) \quad PA = \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad h = Py, \quad Rx = h_1.$$

Bei Verwendung eines Computers mit der relativen Maschinengenauigkeit eps wird weder die von der Maschine erhaltene Matrix P genau unitär sein, noch werden die gefundenen Werte von R, h, x die Beziehungen (4.8.3.6) genau erfüllen. Es wurde jedoch von Wilkinson (1965) gezeigt, daß es eine unitäre Matrix P' , Matrizen $\Delta A, \Delta R$ und einen Vektor Δy gibt mit

$$\begin{aligned} \text{lub}(P' - P) &\leq f(m)\text{eps}, \\ P'(A + \Delta A) &= \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad \text{lub}(\Delta A) \leq f(m)\text{eps} \text{lub}(A), \\ P'(y + \Delta y) &= h, \quad \|\Delta y\| \leq f(m)\text{eps}\|y\|, \\ (R + \Delta R)x &= h_1, \quad \text{lub}(\Delta R) \leq f(m)\text{eps} \text{lub}(R). \end{aligned}$$

Dabei ist $f(m)$ eine langsam wachsende Funktion von m , etwa $f(m) \approx O(m)$.

Bis auf Glieder höherer Ordnung ist nun

$$\text{lub}(R) \doteq \text{lub}(A),$$

und daher gilt wegen

$$F := \Delta A + P'^H \begin{bmatrix} \Delta R \\ 0 \end{bmatrix}$$

auch

$$P'(A + F) = \begin{bmatrix} R + \Delta R \\ 0 \end{bmatrix}, \quad \text{lub}(F) \leq 2f(m)\text{eps} \text{lub}(A).$$

Mit anderen Worten, die berechnete Lösung x läßt sich als exakte Lösung des folgenden linearen Ausgleichsproblems

$$(4.8.3.7) \quad \min_z \|(y + \Delta y) - (A + F)z\|$$

interpretieren, bei dem die Matrix $A + F$ und die rechte Seite $y + \Delta y$ nur leicht gegenüber A bzw. y abgeändert sind. Das Orthogonalisierungsverfahren ist daher gutartig.

Berechnet man dagegen die Lösung x über die Normalgleichungen

$$A^T A x = A^T y,$$

so kann eine andere Situation vorliegen. Aufgrund der Abschätzungen (s. auch Abschnitt 4.5) von Wilkinson (1965) weiß man, daß man bei Gleitpunktrechnung mit der relativen Maschinengenauigkeit eps als Lösung einen Vektor $\tilde{x}$ erhält mit

$$(4.8.3.8) \quad (A^T A + G)\tilde{x} = A^T y, \quad \text{lub}(G) \leq f(n)\text{eps} \text{lub}(A^T A),$$

selbst wenn man annimmt, daß $A^T A$ und $A^T y$ exakt berechnet werden. Ist $x = (A^T A)^{-1} A^T y$ die exakte Lösung, so gilt wegen (4.4.15) in 1. Näherung

$$(4.8.3.9) \quad \frac{\|\tilde{x} - x\|}{\|x\|} \leq \text{cond}(A^T A) \frac{\text{lub}(G)}{\text{lub}(A^T A)} = \text{cond}(R)^2 \frac{\text{lub}(G)}{\text{lub}(A^T A)} \\ \leq f(n)\text{eps} \text{cond}(R)^2$$

Die Rundungsfehler, durch die Matrix G repräsentiert, werden also in jedem Fall mit dem Faktor $\text{cond}(R)^2$ verstärkt.

Dies bewirkt, daß die zweite Methode jedenfalls dann nicht gutartig ist, wenn $\text{cond}(R) \gg 1$ groß ist und in Abschätzung (4.8.3.5) der erste Term überwiegt. Eine andere Situation liegt vor, wenn der zweite Term überwiegt: Wenn etwa gilt $\tan \varphi = \|r\|/\|Ax\| \geq 1$, wird auch die zweite Methode gutartig sein und mit der Orthogonalisierungsmethode vergleichbare Resultate liefern.

Beispiel: 1) (Läuchli) Für die 6×5 -Matrix

$$A = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ \varepsilon & & & & 0 \\ & \varepsilon & & & \\ & & \varepsilon & & \\ & & & \varepsilon & \\ 0 & & & & \varepsilon \end{bmatrix}$$

gilt

$$A^T A = \begin{bmatrix} 1 + \varepsilon^2 & 1 & 1 & 1 & 1 \\ 1 & 1 + \varepsilon^2 & 1 & 1 & 1 \\ 1 & 1 & 1 + \varepsilon^2 & 1 & 1 \\ 1 & 1 & 1 & 1 + \varepsilon^2 & 1 \\ 1 & 1 & 1 & 1 & 1 + \varepsilon^2 \end{bmatrix}.$$

Mit $\varepsilon = 0.5 \cdot 10^{-5}$ erhält man bei 10-stelliger Dezimalrechnung $\varepsilon^2 = 0.25 \cdot 10^{-10}$ und daher

$$\text{gl}(A^T A) = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{bmatrix}.$$

Diese Matrix hat den Rang 1 und besitzt keine Inverse. Das Normalgleichungssystem kann nicht gelöst werden, während das Orthogonalisierungsverfahren nach wie vor anwendbar ist. (Für $A^T A$ gilt: $\text{cond}(A^T A) = \text{cond}(R)^2 = (5 + \varepsilon^2)/\varepsilon^2$.)

2) Das folgende Rechenbeispiel soll einen Vergleich zwischen den beiden Methoden für die Ausgleichsrechnung geben.

(4.8.3.7) zeigt, daß für den Fehler der Lösung, die das Orthogonalisierungsverfahren liefert, (4.8.3.5) mit $\Delta A = F$ gilt, wobei

$$\text{lub}(\Delta A) \leq 2f(m)\text{eps} \text{lub}(A).$$

(4.8.3.9) zeigt, daß bei direkter Lösung der Normalgleichungen eine etwas andere Abschätzung gilt,

$$(A^T A + G)(x + \Delta x) = A^T y + \Delta b$$

mit $\|\Delta b\| \leq \text{eps} \text{lub}(A) \|y\|$, d. h. es gilt wegen (4.4.12), (4.4.15):

$$(4.8.3.10) \quad \frac{\|\Delta x\|_{\text{normal}}}{\|x\|} \leq \text{cond}(R)^2 \left(\frac{\text{lub}(G)}{\text{lub}(A^T A)} + \frac{\|\Delta b\|}{\|A^T y\|} \right).$$

Gegeben sei ein funktionaler Zusammenhang

$$(4.8.3.11) \quad y(s) := x_1 \frac{1}{s} + x_2 \frac{1}{s^2} + x_3 \frac{1}{s^3} \quad \text{mit } x_1 = x_2 = x_3 = 1$$

und folgende Serie von Meßwerten (aus (4.8.3.11) berechnet)

$$\{s_i, y(s_i)\}_{i=1, \dots, 10}.$$

a) Bestimme x_1, x_2, x_3 aus den Daten $\{s_i, y_i\}$. Werden für die $y_i = y(s_i)$ die exakten Funktionswerte benutzt, so gilt

$$r(x) = 0, \quad \tan \varphi = 0.$$

Die folgende Tabelle enthält die Rechenergebnisse zu diesem Beispiel. Gezeigt wird die Größe des Fehlers $\|\Delta x\|_{\text{orth}}$ bei der Orthogonalisierungsmethode und $\|\Delta x\|_{\text{normal}}$ bei Rechnung über die Normalgleichung, sowie eine untere Schranke für die Kondition von R . Das Beispiel wurde wiederholt mit den Stützwerten $s_i = s_0 + i$, $i = 1, \dots, 10$, gerechnet ($\text{eps} = 10^{-11}$).

s_0	$\text{cond}(R)$	$\ \Delta x\ _{\text{orth}}$	$\ \Delta x\ _{\text{normal}}$
10	$6.6 \cdot 10^3$	$8.0 \cdot 10^{-10}$	$8.8 \cdot 10^{-7}$
50	$1.3 \cdot 10^6$	$6.4 \cdot 10^{-7}$	$8.2 \cdot 10^{-5}$
100	$1.7 \cdot 10^7$	$3.3 \cdot 10^{-6}$	$4.2 \cdot 10^{-2}$
150	$8.0 \cdot 10^7$	$1.8 \cdot 10^{-5}$	$6.9 \cdot 10^{-1}$
200	$2.5 \cdot 10^8$	$1.8 \cdot 10^{-3}$	$2.7 \cdot 10^0$

b) Es soll eine künstliche Verfälschung der y_i Werte vorgenommen werden: y wird durch $y + \lambda v$ ersetzt, wobei v mit $A^T v = 0$ so gewählt wird, daß es keinen Einfluß auf die exakte Lösung x hat,

$$(A^T A)x = A^T (y + \lambda v) = A^T y.$$

Dann gilt für $\lambda \in \mathbb{R}$

$$r(x) = y + \lambda v - Ax = \lambda v, \quad \tan \varphi = \lambda \|v\| / \|y\|.$$

Die folgende Tabelle enthält wiederum die Fehler Δx für beide Rechenverfahren, sowie die Größe des Residuums $\|r(x)\|$ in Abhängigkeit von λ .

$$\begin{aligned} s_0 &= 10, \\ v &= (0.1331, -0.5184, 0.6591, -0.2744, 0, 0, 0, 0, 0)^T, \\ \text{lub}(A) &\approx 0.22, \text{ eps} = 10^{-11}. \end{aligned}$$

λ	$\ r(x)\ $	$\ \Delta x\ _{\text{orth}}$	$\ \Delta x\ _{\text{normal}}$
0	0	$8 \cdot 10^{-10}$	$8.8 \cdot 10^{-7}$
10^{-6}	$9 \cdot 10^{-7}$	$9.5 \cdot 10^{-9}$	$8.8 \cdot 10^{-7}$
10^{-4}	$9 \cdot 10^{-5}$	$6.2 \cdot 10^{-10}$	$4.6 \cdot 10^{-7}$
10^{-2}	$9 \cdot 10^{-3}$	$9.1 \cdot 10^{-9}$	$1.3 \cdot 10^{-6}$
10^0	$9 \cdot 10^{-1}$	$6.1 \cdot 10^{-7}$	$8.8 \cdot 10^{-7}$
10^{+2}	$9 \cdot 10^1$	$5.7 \cdot 10^{-5}$	$9.1 \cdot 10^{-6}$

4.8.4 Nichtlineare Ausgleichsprobleme

Nichtlineare Ausgleichsprobleme, etwa das Problem (4.8.0.2), zu gegebenen Funktionen $f_k(x)$ und Zahlen y_k , $k = 1, \dots, m$,

$$y = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}, \quad f(x) = \begin{bmatrix} f_1(x_1, \dots, x_n) \\ \vdots \\ f_m(x_1, \dots, x_n) \end{bmatrix},$$

dasjenige $x^* = (x_1^*, \dots, x_n^*)^T$ zu bestimmen, das

$$\|y - f(x)\|^2 = \sum_{k=1}^m (y_k - f_k(x_1, \dots, x_n))^2,$$

minimiert, können i.a. nur iterativ gelöst werden. Beispielsweise kann man dieses Problem durch Linearisierung (vgl. Abschnitt 5.1) auf eine Folge linearer Ausgleichsprobleme zurückführen. Ist etwa jedes f_k stetig differenzierbar und bezeichnet man mit

$$Df(\xi) = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}_{x=\xi}$$

die Funktionalmatrix an der Stelle $x = \xi$, so gilt

$$f(\bar{x}) = f(x) + Df(x)(\bar{x} - x) + h, \quad \|h\| = o(\|\bar{x} - x\|).$$

Ist daher x eine Näherung für die gesuchte Optimallösung, so erwartet man, daß die Optimallösung $\bar{x}$ des folgenden linearen Ausgleichsproblems (4.8.4.1)

$$\min_{z \in \mathbb{R}^n} \|y - f(x) - Df(x)(z - x)\|^2 = \|r(x) - Df(x)(\bar{x} - x)\|^2$$

$$r(x) := y - f(x),$$

eine bessere Lösung des nichtlinearen Ausgleichsproblems ist als x , d. h.

$$\|y - f(\bar{x})\|^2 < \|y - f(x)\|.$$

Diese Beziehung ist zwar in dieser Form nicht immer richtig. Jedoch kann man zeigen, daß für die *Richtung*, die durch den Vektor

$$s = s(x) := \bar{x} - x$$

gegeben ist, gilt:

Es gibt ein $\lambda > 0$, so daß die Funktion

$$\varphi(\tau) := \|y - f(x + \tau s)\|^2$$

für alle $0 \leq \tau \leq \lambda$ streng monoton fällt. Insbesondere gilt also

$$\varphi(\lambda) = \|y - f(x + \lambda s)\|^2 < \varphi(0) = \|y - f(x)\|^2.$$

Beweis: φ ist eine stetig differenzierbare Funktion von τ und es gilt

$$\begin{aligned} \varphi'(0) &= \frac{d}{d\tau} [(y - f(x + \tau s))^T (y - f(x + \tau s))]_{\tau=0} \\ &= -2(Df(x)s)^T (y - f(x)) = -2(Df(x)s)^T r(x). \end{aligned}$$

Nun ist nach Definition von $\bar{x}$, $s = \bar{x} - x$ Lösung der Normalgleichungen,

$$(4.8.4.2) \quad Df(x)^T Df(x)s = Df(x)^T r(x),$$

die zu dem linearen Ausgleichsproblem (4.8.4.1) gehören. Es folgt aus (4.8.4.2) sofort

$$\|Df(x)s\|^2 = s^T Df(x)^T Df(x)s = (Df(x)s)^T r(x)$$

und daher

$$\varphi'(0) = -2\|Df(x)s\|^2 < 0,$$

sofern $\text{Rang } Df(x) = n$ und $s \neq 0$ ist. Aus Stetigkeitsgründen folgt die Existenz eines $\lambda > 0$ mit $\varphi'(\tau) < 0$ für $0 \leq \tau \leq \lambda$ und damit die Behauptung. $\square$

Dieses Resultat legt folgenden Algorithmus, den sog. *Gauß-Newton-Algorithmus*, zur iterativen Lösung von nichtlinearen Ausgleichsproblemen nahe. Ausgehend von einem Startvektor $x^{(0)}$ bestimme man weitere Näherungen $x^{(i)}$, $i = 1, 2, \dots$, wie folgt:

1. Für $x^{(i)}$ berechne man die Lösung $s^{(i)}$ des linearen Ausgleichsproblems

$$\min_{s \in \mathbb{R}^n} \|r(x^{(i)}) - Df(x^{(i)})s\|^2.$$

2. Sei $\varphi(\tau) := \|y - f(x^{(i)} + \tau s^{(i)})\|^2$ und k die kleinste ganze Zahl $k \geq 0$ mit

$$\varphi(2^{-k}) < \varphi(0) = \|r(x^{(i)})\|^2.$$

3. Setze $x^{(i+1)} := x^{(i)} + 2^{-k}s^{(i)}$.

In Abschnitt 5.4 wird die Konvergenz von Algorithmen untersucht, die eng verwandt sind mit dem hier angegebenen Verfahren.

4.8.5 Die Pseudoinverse einer Matrix

Zu jeder (komplexen) $m \times n$ -Matrix A gibt es eine $n \times m$ -Matrix A^+ , die sog. *Pseudoinverse* oder auch *Moore-Penrose-Inverse*. Sie ist A auf natürliche Weise zugeordnet und stimmt für $m = n$ mit der Inversen A^{-1} von A überein, falls A nichtsingulär ist.

Wir betrachten dazu den Bildraum $R(A)$ und den Nullraum $N(A)$ von A ,

$$R(A) := \{Ax \in \mathbb{C}^m \mid x \in \mathbb{C}^n\},$$

$$N(A) := \{x \in \mathbb{C}^n \mid Ax = 0\},$$

und ihre Orthogonalräume $R(A)^\perp \subset \mathbb{C}^m$, $N(A)^\perp \subset \mathbb{C}^n$. Mit P bezeichnen wir die $n \times n$ -Matrix, die $\mathbb{C}^n$ auf $N(A)^\perp$ orthogonal projiziert, und mit $\bar{P}$ die $m \times m$ -Matrix, die $\mathbb{C}^m$ orthogonal auf $R(A)$ projiziert,

$$P = P^H = P^2, \quad Px = 0 \iff x \in N(A),$$

$$\bar{P} = \bar{P}^H = \bar{P}^2, \quad \bar{P}y = y \iff y \in R(A).$$

Zu jedem $y \in R(A)$ gibt es nun genau ein $x_1 \in N(A)^\perp$ mit $Ax_1 = y$, d. h. es gibt eine wohldefinierte lineare Abbildung $f : R(A) \rightarrow \mathbb{C}^n$ mit

$$Af(y) = y, \quad f(y) \in N(A)^\perp \quad \text{für alle } y \in R(A).$$

Denn zu jedem $y \in R(A)$ gibt es zunächst ein x mit $y = Ax$. Wegen $(I - P)x \in N(A)$ folgt $y = A(Px + (I - P)x) = APx = Ax_1$ mit $x_1 := Px \in N(A)^\perp$. Der Vektor x_1 ist eindeutig durch y bestimmt, denn aus $x_1, x_2 \in N(A)^\perp$, $Ax_1 = Ax_2 = y$ folgt

$$x_1 - x_2 \in N(A) \cap N(A)^\perp = \{0\},$$

also $x_1 = x_2$. f ist offensichtlich linear.

Die zusammengesetzte Abbildung $f \circ \bar{P} : y \in \mathbb{C}^m \rightarrow f(\bar{P}(y)) \in \mathbb{C}^n$ ist wegen $\bar{P}y \in R(A)$ wohldefiniert und linear. Sie wird deshalb durch eine $n \times m$ -Matrix dargestellt, die *Pseudoinverse* A^+ von A : $A^+y = f(\bar{P}(y))$ für alle $y \in \mathbb{C}^m$.

(4.8.5.1) Satz: Die Pseudoinverse A^+ einer $m \times n$ -Matrix A ist eine $n \times m$ -Matrix mit folgenden Eigenschaften:

- 1) $A^+A = P$ ist die Orthogonalprojektion $P : \mathbb{C}^n \rightarrow N(A)^\perp$ und $AA^+ = \bar{P}$ die Orthogonalprojektion $\bar{P} : \mathbb{C}^m \rightarrow R(A)$.
- 2) Es gilt
 - a) $A^+A = (A^+A)^H$,
 - b) $AA^+ = (AA^+)^H$,
 - c) $AA^+A = A$,
 - d) $A^+AA^+ = A^+$.

Beweis: : Nach Definition von A^+ ist für alle x

$$A^+Ax = f(\bar{P}(Ax)) = f(Ax) = Px,$$

so daß $A^+A = P$. Wegen $P^H = P$ folgt dann a). Ebenso folgt aus der Definition von f

$$AA^+ = A(f(\bar{P}(y))) = \bar{P}y,$$

also $AA^+ = \bar{P} = \bar{P}^H$, und damit b). Schließlich gilt für alle $x \in \mathbb{C}^n$

$$(AA^+)Ax = \bar{P}Ax = Ax$$

nach Definition von $\bar{P}$, und für alle $y \in \mathbb{C}^m$

$$A^+(AA^+)y = A^+\bar{P}y = f(\bar{P}^2y) = f(\bar{P}y) = A^+y.$$

Dies zeigt c) und d). □

Die Eigenschaften 2a)–2d) von Satz (4.8.5.1) charakterisieren A^+ eindeutig:

4.8.5.2 Satz: Ist Z eine $n \times m$ -Matrix mit

$$a') \quad ZA = (ZA)^H,$$

$$b') \quad AZ = (AZ)^H,$$

$$c') \quad AZA = A,$$

$$d') \quad ZAZ = Z,$$

dann gilt $Z = A^+$.

Beweis: Aus a)–d) und a')–d') erhält man der Reihe nach folgende Gleichungen

$$\begin{aligned} Z &= ZAZ = Z(AA^+A)A^+(AA^+A)Z && \text{wegen d'), c)} \\ &= (A^H Z^H A^H A^{+H})A^+(A^{+H} A^H Z^H A^H) && \text{wegen a), a'), b), b')} \\ &= (A^H A^{+H})A^+(A^{+H} A^H) && \text{wegen c')} \\ &= (A^+A)A^+(AA^+) && \text{wegen a), b)} \\ &= A^+AA^+ = A^+ && \text{wegen d').} \quad \square \end{aligned}$$

Als Korollar notieren wir

(4.8.5.3) Korollar: Für alle Matrizen A gilt $A^{++} = A$, $(A^+)^H = (A^H)^+$.

Denn $Z := A$ (bzw. $Z := (A^+)^H$) hat die Eigenschaften (4.8.5.2) von $(A^+)^+$ (bzw. von $(A^H)^+$). $\square$

Mit Hilfe der Pseudoinversen A^+ kann man eine elegante Darstellung der Lösung des linearen Ausgleichsproblems

$$\min_x \|Ax - y\|_2$$

angeben:

(4.8.5.4) Satz: Der Vektor $\bar{x} := A^+y$ hat die Eigenschaften

$$a) \quad \|Ax - y\|_2 \geq \|A\bar{x} - y\|_2 \text{ für alle } x \in \mathbb{C}^n.$$

$$b) \quad \text{Aus } \|Ax - y\|_2 = \|A\bar{x} - y\|_2, \quad x \neq \bar{x} \text{ folgt } \|x\|_2 > \|\bar{x}\|_2.$$

Mit anderen Worten, $\bar{x} = A^+y$ ist eine Lösung des Ausgleichsproblems und zwar diejenige, die die kleinste euklidische Norm besitzt, falls das Ausgleichsproblem nicht eindeutig lösbar ist.

Beweis: : Wegen (4.8.5.1) ist AA^+ die Orthogonalprojektion auf $R(A)$. Also gilt für alle $x \in \mathbb{C}^n$

$$Ax - y = u - v$$

$$u := A(x - A^+y) \in R(A), \quad v := (I - AA^+)y = y - A\bar{x} \in R(A)^\perp,$$

und deshalb

$$\|Ax - y\|_2^2 = \|u\|_2^2 + \|v\|_2^2 \geq \|v\|_2^2 = \|A\bar{x} - y\|_2^2.$$

Dabei gilt $\|Ax - y\|_2 = \|A\bar{x} - y\|_2$ genau dann, wenn $u = 0$, d. h.

$$Ax = AA^+y.$$

Nun ist A^+A die Orthogonalprojektion auf $N(A)^\perp$. Also gilt für alle x mit $Ax = AA^+y$

$$\begin{aligned} x &= u_1 + v_1, \quad u_1 := A^+Ax = A^+AA^+y = A^+y = \bar{x} \in N(A)^\perp, \\ v_1 &:= x - u_1 = x - \bar{x} \in N(A), \end{aligned}$$

so daß $\|x\|_2^2 > \|\bar{x}\|_2^2$ für alle $x \neq \bar{x}$ mit $\|Ax - y\|_2 = \|A\bar{x} - y\|_2$. $\square$

Für $m \times n$ -Matrizen A , $m \geq n$, von maximalem Rang $A = n$ kann man A^+ sofort explizit angeben: Für die Matrix $Z := (A^HA)^{-1}A^H$ verifiziert man sofort die Eigenschaften von (4.8.5.2), also gilt

$$A^+ = (A^HA)^{-1}A^H.$$

Mit Hilfe der Orthogonalzerlegung (4.7.7) $A = QR$, läßt sich der Ausdruck für A^+ umformen in

$$A^+ = (R^HQ^HQ R)^{-1}R^HQ^H = R^{-1}Q^H.$$

In der Form $A^+ = R^{-1}Q^H$ läßt sich A^+ numerisch stabiler berechnen. Falls $m < n$ und $\text{Rang } A = m$, erhält man wegen $(A^+)^H = (A^H)^+$ die Matrix A^+ in der Form

$$A^+ = Q(R^H)^{-1},$$

wenn $A^H = QR$ eine Zerlegung (4.7.7) von A^H ist. Für beliebige $m \times n$ -Matrizen A läßt sich A^+ explizit mit Hilfe der singulären Werte einer Matrix angeben (s. (6.4.13)).

4.9 Modifikationstechniken

Die Gaußelimination (s. (4.1.7)) liefert zu jeder $n \times n$ -Matrix A eine obere $n \times n$ -Dreiecksmatrix R und eine nichtsinguläre $n \times n$ -Matrix mit der Eigenschaft

$$FA = R.$$

Hier ist $F = G_{n-1}P_{n-1} \dots G_1P_1$ ein Produkt von Frobeniusmatrizen G_j (4.1.8) und Permutationsmatrizen P_j . Ebenso liefern die Orthogonalisierungsalgorithmen aus 4.7 unitäre $n \times n$ -Matrizen P , Q und eine obere Dreiecksmatrix R mit (vgl. (4.7.7))

$$PA = R \quad \text{bzw.} \quad A = QR.$$

Diese Algorithmen können auch auf rechteckige $m \times n$ -Matrizen A , $m \geq n$ angewandt werden. Sie geben dann nichtsinguläre $m \times m$ -Matrizen F bzw. unitäre $m \times m$ -Matrizen P , $m \times n$ -Matrizen Q mit orthonormalen Spalten und obere $n \times n$ -Dreiecksmatrizen R mit

$$(4.9.1) \quad FA = \begin{bmatrix} R \\ 0 \end{bmatrix} \begin{matrix} \}^n \\ \}_{m-n} \end{matrix}$$

bzw.

$$(4.9.2a) \quad PA = \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad P^H P = P P^H = I_m$$

$$(4.9.2b) \quad A = QR, \quad Q^H Q = I_n.$$

Wir sahen, daß im Falle $m = n$ die praktische Bedeutung dieser Zerlegungen darin liegt, daß man mit ihrer Hilfe die Lösung von Gleichungssystemen der Form

$$(4.9.3) \quad Ax = y \quad \text{bzw.} \quad A^T x = y$$

sofort auf die Lösung gestaffelter Gleichungssysteme und Matrixmultiplikationen zurückführen kann. Für $m > n$ gestatten es die orthogonalen Zerlegungen (4.9.2), die Lösung $\bar{x}$ von linearen Ausgleichsproblemen zu berechnen wegen

$$(4.9.4) \quad \min_x \|Ax - y\| = \min_x \left\| \begin{bmatrix} R \\ 0 \end{bmatrix} x - Py \right\|, \quad R\bar{x} = Q^H y.$$

Insbesondere kann man so lineare Gleichungssysteme (4.9.3) und Ausgleichsprobleme (4.9.4) bei fester Matrix A für verschiedene „rechte Seiten“ y sehr effektiv lösen.

Nun kommt es in der Praxis recht häufig vor, daß man nach der Lösung eines Problems für eine Matrix A das Problem auch für eine geänderte Matrix $\bar{A}$ lösen will. Es ist deshalb wichtig, daß man für bestimmte „leichte“ Änderungen von $A \rightarrow \bar{A}$ die zu $\bar{A}$ gehörigen Zerlegungen (4.9.1), (4.9.2) verhältnismäßig einfach aus den zu A gehörigen Zerlegungen berechnen und sich so die Anwendung der aufwendigen Algorithmen der Abschnitte 4.1, 4.7 auf $\bar{A}$ ersparen kann.

Folgende „leichte“ Änderungen einer $m \times n$ -Matrix A , $m \geq n$ werden betrachtet

- (1) Änderung einer Zeile oder Spalte von A ,
- (2) Streichen einer Spalte von A ,
- (3) Erweiterung von A um eine Spalte,
- (4) Erweiterung von A um eine Zeile,
- (5) Streichen einer Zeile von A .

(s. Gill, Golub, Murray und Saunders (1974), sowie Daniel, Gragg, Kaufman und Stewart (1976) für eine Beschreibung weiterer Modifikationstechniken für Matrixzerlegungen.)

Als Hauptwerkzeug verwenden wir gewisse einfache Eliminationsmatrizen E_{ij} . Dies sind nichtsinguläre m -reihige Matrizen, die sich von der m -reihigen Einheitsmatrix nur wenig in den Zeilen und Spalten i und j unterscheiden und folgende Gestalt haben

$$E_{ij} = \begin{bmatrix} 1 & & & & & & & & & 0 \\ & \ddots & & & & & & & & \\ & & 1 & & & & & & & \\ & & & a & & & b & & & \\ & & & & 1 & & & & & \\ & & & & & \ddots & & & & \\ & & & & & & 1 & & & \\ & & & c & & & & d & & \\ & & & & & & & & 1 & \\ & & & & & & & & & \ddots \\ 0 & & & & & & & & & & 1 \end{bmatrix} \begin{matrix} \\ \\ \\ \leftarrow i \\ \\ \\ \leftarrow j \\ \\ \\ \end{matrix}$$

Eine Matrixmultiplikation $y = E_{ij}x$ ändert nur die Komponenten x_i und x_j des Vektors $x = (x_1, \dots, x_m)^T \in \mathbb{R}^m$:

$$y_i = ax_i + bx_j,$$

$$y_j = cx_i + dx_j,$$

$$y_k = x_k \text{ für } k \neq i, j.$$

Man sagt deshalb, daß diese Matrizen in der i, j -Ebene operieren. Zu einem gegebenen Vektor x und Indizes $i \neq j$ kann man die 2×2 -Matrix

$$\hat{E} := \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

und damit E_{ij} auf verschiedene Weise so wählen, daß die j -te Komponente y_j des Bildes $y = E_{ij}x$ verschwindet und E_{ij} nichtsingulär ist:

$$\begin{bmatrix} y_i \\ y_j \end{bmatrix} \stackrel{!}{=} \begin{bmatrix} y_i \\ 0 \end{bmatrix} = \hat{E} \begin{bmatrix} x_i \\ x_j \end{bmatrix}.$$

Aus numerischen Gründen wird man $\hat{E}$ so wählen, daß zusätzlich die Kondition $\text{cond}(E_{ij})$ nicht zu groß wird. Die einfachste Möglichkeit, die bei Zerlegungen des Typs (4.9.1) verwandt wird, sind gewisse Gaußeliminationen (s.(4.1.8)): Man wählt dazu

$$(4.9.5) \quad \hat{E} = \begin{cases} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} & \text{falls } x_j = 0, \\ \begin{bmatrix} 1 & 0 \\ -x_j/x_i & 1 \end{bmatrix} & \text{falls } |x_i| \geq |x_j| > 0, \\ \begin{bmatrix} 0 & 1 \\ 1 & -x_i/x_j \end{bmatrix} & \text{falls } |x_i| < |x_j|. \end{cases}$$

Im Falle der orthogonalen Zerlegungen (4.9.2) wählt man $\hat{E}$ und damit E_{ij} als unitäre Matrizen, die man in diesem Fall auch als *Givens-Matrizen* bezeichnet. Eine erste Möglichkeit bietet der folgende Ansatz für $\hat{E}$:

$$(4.9.6) \quad \hat{E} = \begin{bmatrix} c & s \\ s & -c \end{bmatrix}, \quad c := \cos \varphi, \quad s := \sin \varphi.$$

$\hat{E}$ und E_{ij} sind hermitesch, unitär und es ist $\det(\hat{E}) = -1$. Wegen der Unitarität von $\hat{E}$ folgt aus der Forderung

$$\begin{bmatrix} c & s \\ s & -c \end{bmatrix} \cdot \begin{bmatrix} x_i \\ x_j \end{bmatrix} \stackrel{!}{=} \begin{bmatrix} y_i \\ 0 \end{bmatrix}$$

sofort $y_i = k = \pm \sqrt{x_i^2 + x_j^2}$; sie wird durch folgende Wahl erfüllt

$$c := 1, \quad s := 0 \quad \text{falls } x_i = x_j = 0,$$

bzw. falls $\mu := \max\{|x_i|, |x_j|\} > 0$ durch

$$c := x_i/k, \quad s := x_j/k,$$

wobei $|k|$ in der folgenden Form berechnet wird

$$|k| = \mu \sqrt{(x_i/\mu)^2 + (x_j/\mu)^2},$$

und das Vorzeichen von k noch beliebig ist. Diese Berechnung von $|k|$ vermeidet Probleme, die durch Exponentenüber- oder -Unterlauf bei extremen Komponenten x_i, x_j entstehen. Aus numerischen Gründen wird das Vorzeichen von k so gewählt

$$k = |k| \operatorname{sign}(x_i), \quad \operatorname{sign}(x_i) := \begin{cases} 1, & \text{falls } x_i \geq 0, \\ -1, & \text{falls } x_i < 0, \end{cases}$$

so daß bei der Berechnung der Hilfsgröße

$$v := s/(1+c)$$

keine Auslöschung auftritt: Mit Hilfe von v lassen sich die wesentlichen Komponenten z_i, z_j des Bildes $z := E_{ij}u$ eines Vektors $u \in \mathbb{R}^n$ etwas effizienter (eine Multiplikation wird durch eine Addition ersetzt) in der folgenden Form berechnen:

$$z_i := cu_i + su_j,$$

$$z_j := v(u_i + z_i) - u_j.$$

Statt der Matrizen $\hat{E}$ (4.9.6), die man zusammen mit den zugehörigen E_{ij} auch genauer *Givens-Reflexionen* nennt, kann man genau so gut Matrizen $\hat{E}$ der Form

$$\hat{E} = \begin{bmatrix} c & s \\ -s & c \end{bmatrix}, \quad c = \cos \varphi, \quad s = \sin \varphi,$$

benutzen, die man wie die zugehörigen E_{ij} auch *Givens-Rotationen* nennt: $\hat{E}$ und E_{ij} sind dann orthogonale Matrizen, die *eigentliche* Drehungen des $\mathbb{R}^m$ „in der (i, j) -Ebene“ um den Winkel φ beschreiben, $\det(\hat{E}) = 1$. Wir werden im folgenden aber nur Givens-Reflexionen verwenden.

Da sich die Modifikationstechniken für die Zerlegung (4.9.1) von denen für (4.9.2a) nur dadurch unterscheiden, daß statt der Givens-Matrizen (4.9.6) Eliminationsmatrizen $\hat{E}$ des Typs (4.9.5) genommen werden, wollen wir nur die orthogonalen Zerlegungen (4.9.2a) studieren. Die Techniken für Zerlegungen des Typs (4.9.2b) sind zwar ähnlich, aber doch etwas komplizierter als vom Typ (4.9.2a). Die entsprechenden Verfahren für (4.9.2b) findet man bei Daniel, Gragg, Kaufman und Stewart (1976).

Im folgenden sei A eine reelle $m \times n$ -Matrix mit $m \geq n$ und

$$PA = \begin{bmatrix} R \\ 0 \end{bmatrix}$$

eine Zerlegung vom Typ (4.9.2a).

(1) Ändert man eine Zeile oder Spalte von A , oder allgemeiner, ersetzt man A durch $\bar{A} := A + vu^T$, wobei $v \in \mathbb{R}^m$, $u \in \mathbb{R}^n$ gegebene Vektoren sind, so ist wegen (4.9.2a)

$$(4.9.7) \quad P\bar{A} = \begin{bmatrix} R \\ 0 \end{bmatrix} + wu^T, \quad w := Pv \in \mathbb{R}^m.$$

In einem ersten Teilschritt annulliert man sukzessive die Komponenten $m, m-1, \dots, 2$ des Vektors w mit geeigneten Givens-Matrizen des Typs $G_{m-1,m}, G_{m-2,m-1}, \dots, G_{12}$, so daß

$$\tilde{w} = ke_1 = G_{12}G_{23} \cdots G_{m-1,m}w = (k, 0, \dots, 0)^T \in \mathbb{R}^m,$$

$$k = \pm \|w\| = \pm \|v\|.$$

Eine Skizze für $m = 4$ möge die Wirkung der sukzessiven Transformationen mit den $G_{i,i+1}$ verdeutlichen. Wir bezeichnen hier und in den weiteren Skizzen Elemente, die sich in der jeweiligen Teiltransformation geändert haben, mit einem *:

$$w = \begin{bmatrix} x \\ x \\ x \\ x \end{bmatrix} \xrightarrow{G_{34}} \begin{bmatrix} x \\ x \\ * \\ 0 \end{bmatrix} \xrightarrow{G_{23}} \begin{bmatrix} x \\ * \\ 0 \\ 0 \end{bmatrix} \xrightarrow{G_{12}} \begin{bmatrix} * \\ 0 \\ 0 \\ 0 \end{bmatrix} = \tilde{w}.$$

Multipliziert man auch (4.9.7) von links der Reihe nach mit $G_{m-1,m}, \dots, G_{12}$, so erhält man

$$(4.9.8) \quad \tilde{P}\tilde{A} = R' + ke_1u^T =: \tilde{R},$$

wobei

$$\tilde{P} := GP, \quad R' := G \begin{bmatrix} R \\ 0 \end{bmatrix}, \quad G := G_{12}G_{23} \cdots G_{m-1,m}.$$

Dabei ist $\tilde{P}$ mit G und P wieder unitär; die obere Dreiecksmatrix $\begin{bmatrix} R \\ 0 \end{bmatrix}$ geht schrittweise in eine obere *Hessenberg-Matrix* $R' = G \begin{bmatrix} R \\ 0 \end{bmatrix}$ über, d. h. eine Matrix mit $(R')_{ik} = 0$ für $i > k + 1$.

Skizze für $m = 4, n = 3$:

$$\begin{bmatrix} R \\ 0 \end{bmatrix} = \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & x \\ 0 & 0 & 0 \end{bmatrix} \xrightarrow{G_{34}} \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & * \\ 0 & 0 & * \end{bmatrix} \xrightarrow{G_{23}} \begin{bmatrix} x & x & x \\ 0 & * & * \\ 0 & * & * \\ 0 & 0 & x \end{bmatrix} \xrightarrow{G_{12}} \begin{bmatrix} * & * & * \\ 0 & * & * \\ 0 & x & x \\ 0 & 0 & x \end{bmatrix}$$

$$= G \begin{bmatrix} R \\ 0 \end{bmatrix} = R'.$$

Mit R' ist auch $\tilde{R} = R' + ke_1u^T$ (4.9.8) eine obere Hessenberg-Matrix, da sich durch diese Addition nur die erste Zeile von R' ändert. In einem zweiten Teilschritt annulliert man nun der Reihe nach die Subdiagonalelemente $(\tilde{R})_{i+1,i}, i = 1, 2, \dots, n-1$ von $\tilde{R}$ mittels geeigneter Given-Matrizen $H_{12}, H_{23}, \dots, H_{\mu,\mu+1}$, so daß (vgl. (4.9.8))

$$H \bar{P} \bar{A} = H \tilde{R} =: \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}, \quad H := H_{\mu, \mu+1} \cdots H_{23} H_{12},$$

wobei $\tilde{R}$ wieder eine obere $n \times n$ -Dreiecksmatrix und $\bar{P} := H \tilde{P}$ eine unitäre $m \times m$ -Matrix ist, die eine Zerlegung von $\bar{A}$ im Sinne von (4.9.2a) liefern:

$$\bar{P} \bar{A} = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}.$$

Die Transformationskette $\tilde{R} \rightarrow H_{12} \tilde{R} \rightarrow H_{23} (H_{12} \tilde{R}) \rightarrow \cdots \rightarrow H \tilde{R}$ wird wieder für $m = 4$, $n = 3$ skizziert:

$$\begin{aligned} \tilde{R} &= \begin{bmatrix} x & x & x \\ x & x & x \\ 0 & x & x \\ 0 & 0 & x \end{bmatrix} \xrightarrow{H_{12}} \begin{bmatrix} * & * & * \\ 0 & * & * \\ 0 & x & x \\ 0 & 0 & x \end{bmatrix} \xrightarrow{H_{23}} \begin{bmatrix} x & x & x \\ 0 & * & * \\ 0 & 0 & * \\ 0 & 0 & x \end{bmatrix} \xrightarrow{H_{34}} \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & * \\ 0 & 0 & 0 \end{bmatrix} \\ &= \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}. \end{aligned}$$

(2) *Streichen einer Spalte von A*: Erhält man $\bar{A}$ durch Streichen der k -ten Spalte von A , so ist wegen (4.9.2a) die Matrix $\tilde{R} := P \bar{A}$ eine obere Hessenberg-Matrix der folgenden Form (skizziert für $m = 4$, $n = 4$, $k = 2$)

$$\tilde{R} := P \bar{A} = \begin{bmatrix} x & x & x \\ & x & x \\ & x & x \\ & & x \end{bmatrix}.$$

Die Subdiagonalelemente von $\tilde{R}$ annulliert man wie eben mittels geeigneter Givens-Matrizen $H_{k,k+1}$, $H_{k+1,k+2}$, $\dots$, $H_{n-1,n}$. Die Zerlegung (4.9.2a) von $\bar{A}$ ist

$$\begin{aligned} \bar{P} \bar{A} &= \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}, \quad \bar{P} := H P, \\ \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix} &:= H \begin{bmatrix} \tilde{R} \\ 0 \end{bmatrix}, \quad H := H_{n-1,n} H_{n-2,n-1} \cdots H_{k,k+1}. \end{aligned}$$

(3) *Erweiterung um eine Spalte*: Ist $\bar{A} = (A, a)$, $a \in \mathbb{R}^m$, und A eine $m \times n$ -Matrix mit $m > n$, so folgt aus (4.9.2a):

$$P \bar{A} = \left[\begin{array}{c|c} R & Pa \end{array} \right] =: \tilde{R} = \begin{bmatrix} x & \dots & x & x \\ & \ddots & \vdots & \vdots \\ & & x & x \\ & & & x \\ 0 & & & x \end{bmatrix}.$$

Die einzigen Subdiagonalelemente (in der letzten Spalte) von $\tilde{R}$ annulliert man mittels einer einzigen Householdertransformation H (4.7.5):

$$H\tilde{R} = \begin{bmatrix} x & \dots & x & x \\ & \ddots & \vdots & \vdots \\ & & x & x \\ & & & * \\ 0 & & & 0 \\ & & & \vdots \\ & & & 0 \end{bmatrix} = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}.$$

$\bar{P} := HP$ und $\bar{R}$ liefert die Zerlegung (4.9.2a) von $\bar{A}$:

$$\bar{P}\bar{A} = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}.$$

(4) *Erweiterung um eine Zeile:* Ist

$$\bar{A} = \begin{bmatrix} A \\ a^T \end{bmatrix}, \quad a \in \mathbb{R}^n,$$

so gibt es eine $m+1$ -reihige Permutationsmatrix Π mit

$$\Pi\bar{A} = \begin{bmatrix} a^T \\ A \end{bmatrix}.$$

Für die unitäre $(m+1)$ -reihige Matrix

$$\tilde{P} := \begin{bmatrix} 1 & 0 \\ 0 & P \end{bmatrix} \Pi$$

gilt dann wegen (4.9.2a)

$$\tilde{P}\bar{A} = \begin{bmatrix} 1 & 0 \\ 0 & P \end{bmatrix} \begin{bmatrix} a^T \\ A \end{bmatrix} = \begin{bmatrix} a^T \\ PA \end{bmatrix} = \begin{bmatrix} a^T \\ R \\ 0 \end{bmatrix} =: \tilde{R} = \begin{bmatrix} x & \dots & x \\ x & \dots & x \\ & \ddots & \vdots \\ 0 & & x \\ \hline & & & 0 \end{bmatrix}.$$

$\tilde{R}$ ist obere Hessenberg-Matrix, deren Subdiagonalelemente, wie oben beschrieben, mittels geeigneter Givens-Matrizen $H_{12}, \dots, H_{n,n+1}$ annulliert werden können:

$$\bar{P} = H\tilde{P}, \quad \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix} = H\tilde{R}, \quad H = H_{n,n+1} \cdots H_{23}H_{12}$$

liefern die Zerlegung von $\bar{A}$,

$$\bar{P}\bar{A} = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}.$$

(5) *Streichen einer Zeile von A:* Sei A eine $m \times n$ -Matrix mit $m > n$. Wir nehmen o. B. d. A. an, daß die letzte Zeile a^T von A gestrichen werden soll:

$$A = \begin{bmatrix} \bar{A} \\ a^T \end{bmatrix}.$$

Wir partitionieren die Matrix $P = [\tilde{P}, p]$, $p \in \mathbb{R}^m$, entsprechend und erhalten wegen (4.9.2a)

$$(4.9.9) \quad [\tilde{P}, p] \begin{bmatrix} \bar{A} \\ a^T \end{bmatrix} = \begin{bmatrix} R \\ 0 \end{bmatrix}.$$

Wir wählen nun Givens-Matrizen der Typen $H_{m,m-1}, H_{m,m-2}, \dots, H_{m1}$, um sukzessive die Komponenten $m-1, m-2, \dots, 1$ von p zu annullieren:
 $H_{m1} H_{m2} \dots H_{m,m-1} p = (0, \dots, 0, \pi)^T$ (Skizze für $m=4$)

$$(4.9.10) \quad p = \begin{bmatrix} x \\ x \\ x \\ x \end{bmatrix} \xrightarrow{H_{43}} \begin{bmatrix} x \\ x \\ 0 \\ * \end{bmatrix} \xrightarrow{H_{42}} \begin{bmatrix} x \\ 0 \\ 0 \\ * \end{bmatrix} \xrightarrow{H_{41}} \begin{bmatrix} 0 \\ 0 \\ 0 \\ * \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \pi \end{bmatrix}.$$

Nun ist P unitär, also $\|p\| = |\pi| = 1$. Die transformierte Matrix HP , $H := H_{m1} H_{m2} \cdots H_{m,m-1}$, hat also die Gestalt

$$(4.9.11) \quad HP = \begin{bmatrix} \bar{P} & 0 \\ q & \pi \end{bmatrix} = \begin{bmatrix} \bar{P} & 0 \\ 0 & \pi \end{bmatrix}, \quad \pi = \pm 1,$$

weil wegen der Unitarität von HP aus $|\pi| = 1$ auch $q = 0$ folgt. Folglich ist $\tilde{P}$ eine unitäre $(m-1)$ -reihige Matrix. Andererseits transformieren die H_{mi} die obere Dreiecksmatrix $\begin{bmatrix} R \\ 0 \end{bmatrix}$ mit Ausnahme der letzten Zeile wieder in eine obere Dreiecksmatrix

$$H \begin{bmatrix} R \\ 0 \end{bmatrix} = H_{m1} H_{m2} \dots H_{m,m-1} \begin{bmatrix} R \\ 0 \end{bmatrix} = \begin{bmatrix} \bar{R} \\ 0 \\ z^T \end{bmatrix}_{1}^{n-m-n-1}.$$

Skizze für $m = 4, n = 3$:

$$\begin{aligned} \begin{bmatrix} R \\ 0 \end{bmatrix} &= \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & x \\ 0 & 0 & 0 \end{bmatrix} \xrightarrow{H_{43}} \begin{bmatrix} x & x & x \\ 0 & x & x \\ 0 & 0 & * \\ 0 & 0 & * \end{bmatrix} \xrightarrow{H_{42}} \begin{bmatrix} x & x & x \\ 0 & * & * \\ 0 & 0 & x \\ 0 & * & * \end{bmatrix} \xrightarrow{H_{41}} \begin{bmatrix} * & * & * \\ 0 & x & x \\ 0 & 0 & x \\ * & * & * \end{bmatrix} \\ &= \begin{bmatrix} \bar{R} \\ z^T \end{bmatrix}. \end{aligned}$$

Es folgt also aus (4.9.9), (4.9.11):

$$HP \begin{bmatrix} \bar{A} \\ a^T \end{bmatrix} = \begin{bmatrix} \bar{P} & 0 \\ 0 & \pi \end{bmatrix} \begin{bmatrix} \bar{A} \\ a^T \end{bmatrix} = \begin{bmatrix} \bar{R} \\ 0 \\ z^T \end{bmatrix},$$

also

$$\bar{P}\bar{A} = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}$$

für die unitäre $(m-1)$ -reihige Matrix $\bar{P}$ und die n -reihige obere Dreiecksmatrix $\bar{R}$. Damit ist eine Zerlegung (4.9.2a) für $\bar{A}$ gefunden.

Man kann zeigen, daß die Techniken dieses Abschnitts numerisch stabil in folgendem Sinne sind: Seien P und R gegebene Matrizen mit der folgenden Eigenschaft: Es ist $PA = \begin{bmatrix} R \\ 0 \end{bmatrix}$ und es gibt eine exakt unitäre Matrix P' und eine Matrix A' , so daß

$$P'A' = \begin{bmatrix} R \\ 0 \end{bmatrix}$$

eine exakte Zerlegung (4.9.2a) von A' ist und die Differenzen $\|P - P'\|$, $\|A - A'\|$ „klein“ sind. Dann liefern die Methoden dieses Abschnitts bei Verwendung von Gleitpunktarithmetik der Genauigkeit ϵ aus P , R Matrizen $\bar{P}$, $\bar{R}$ zu denen es ebenfalls eine exakt unitäre Matrix $\bar{P}'$, und eine Matrix $\bar{A}'$ gibt, so daß wieder $\|\bar{P} - \bar{P}'\|$, $\|\bar{A} - \bar{A}'\|$ „klein“ sind und

$$\bar{P}'\bar{A}' = \begin{bmatrix} \bar{R} \\ 0 \end{bmatrix}$$

exakte Zerlegung (4.9.2a) der leicht gestörten Matrix $\bar{A}'$ ist. Als „klein“ gelten dabei Differenzen mit $\|\Delta P\|$, $\|\Delta A\|/\|A\| = O(m^\alpha \epsilon)$ und kleinem α , etwa $\alpha = \frac{3}{2}$.

4.10 Lineare Minimierungsprobleme. Die Simplexmethode

Die Methoden der linearen Algebra lassen sich sehr schön im Rahmen der Simplexmethode zur Lösung von linearen Minimierungsproblemen anwenden. Probleme dieser Art kommen in der Praxis, insbesondere in der Wirtschaft, sehr häufig vor. Im Rahmen dieser Einführung können wir nur die wichtigsten Aspekte dieser Probleme behandeln. Für eine eingehendere Darstellung sei auf die Spezialliteratur verwiesen (s. etwa Dantzig (1963), Gass (1969), Murty (1976), Schrijver (1986)).

Unter einem allgemeinen linearen Minimierungsproblem, oder einem *linearen Programm*, versteht man ein Problem der folgenden Form:

$$(4.10.1) \quad \text{minimiere} \quad c_1 x_1 + c_2 x_2 + \cdots + c_n x_n \equiv c^T x$$

unter allen $x \in \mathbb{R}^n$, die endlich viele Nebenbedingungen der Form

$$(4.10.2) \quad \begin{aligned} a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n &\leq b_i, & i = 1, 2, \dots, m_1, \\ a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n &= b_i, & i = m_1 + 1, m_1 + 2, \dots, m, \end{aligned}$$

erfüllen. Die Zahlen c_k , a_{ik} , b_i sind gegebene reelle Zahlen. Die zu minimierende Funktion $c^T x$ heißt *Zielfunktion*, jedes $x \in \mathbb{R}^n$, das alle Bedingungen (4.10.2) erfüllt, heißt *zulässige Lösung* des linearen Programms. Durch Einführung von zusätzlichen Variablen und Gleichungen läßt sich das lineare Programm (4.10.1), (4.10.2) in eine Form bringen, in der als Nebenbedingungen nur Gleichungen und *elementare* Ungleichungen, d. h. Ungleichungen der Form $x_i \geq 0$, auftreten. Ferner ist es aus bestimmten Gründen nützlich zu verlangen, daß die Zielfunktion $c^T x$ die Form $c^T x \equiv -x_p$ besitzt. Um ein lineares Programm in diese Form zu bringen, ersetze man in (4.10.2) jede nichtelementare Ungleichung

$$a_{i1}x_1 + \cdots + a_{in}x_n \leq b_i$$

mit Hilfe einer *Schlupfvariablen* x_{n+i} durch eine Gleichung und eine elementare Ungleichung

$$a_{i1}x_1 + \cdots + a_{in}x_n + x_{n+i} = b_i, \quad x_{n+i} \geq 0.$$

Ist die Zielfunktion $c_1 x_1 + \cdots + c_n x_n$ nicht elementar, führe man eine weitere zusätzliche Variable x_{n+m_1+1} mit Hilfe einer weiteren Gleichung

$$c_1 x_1 + \cdots + c_n x_n + x_{n+m_1+1} = 0$$

ein, die man zu den übrigen Nebenbedingungen (4.10.2) hinzunimmt: die Minimierung von $c^T x$ ist dann zur Maximierung von x_p unter den so erweiterten Nebenbedingungen äquivalent.

Wir können also o. B. d. A. annehmen, daß das lineare Programm bereits in folgender *Standardform* vorliegt:

$$(4.10.3) \quad \begin{aligned} LP(I, p) : \quad & \text{maximiere} \quad x_p \\ & x \in \mathbb{R}^n : \quad Ax = b, \\ & x_i \geq 0 \text{ für } i \in I. \end{aligned}$$

Dabei sind $I \not\subseteq N := \{1, 2, \dots, n\}$ eine evtl. leere Indexmenge, p ein fester Index mit $p \in N \setminus I$, $A = (a_1, a_2, \dots, a_n)$ eine reelle $m \times n$ -Matrix mit den Spalten a_i und $b \in \mathbb{R}^m$ ein gegebener Vektor. Die Variablen x_i mit $i \in I$ bzw. $i \notin I$ heißen *vorzeichenbeschränkte* bzw. *freie* Variable. Mit

$$P := \{x \in \mathbb{R}^n \mid Ax = b \text{ \& } x_i \geq 0 \text{ f\"ur alle } i \in I\}$$

bezeichnen wir die Menge der zulässigen Lösungen von $LP(I, p)$. Ein Vektor $\bar{x} \in P$ heißt *Optimallösung* von $LP(I, p)$, wenn $\bar{x}_p = \max\{x_p \mid x \in P\}$.

Zur Illustration verwenden wir folgendes Beispiel:

$$\begin{array}{ll} \text{minimiere} & -x_1 - 2x_2 \\ x: & -x_1 + x_2 \leq 2 \\ & x_1 + x_2 \leq 4 \\ & x_1 \geq 0, \quad x_2 \geq 0. \end{array}$$

Nach Einführung der Schlupfvariablen x_3, x_4 und der Zielfunktionsvariablen x_5 erhält man das Problem in der Standardform $LP(I, p)$ mit $p = 5, I = \{1, 2, 3, 4\}$:

$$\begin{array}{llll} \text{maximiere} & x_5 & & \\ x: & -x_1 + x_2 + x_3 & = & 2 \\ & x_1 + x_2 & + x_4 & = 4 \\ & -x_1 - x_2 & & + x_5 = 0 \\ & x_i & \geq & 0 \text{ f\"ur } i \leq 4. \end{array}$$

Es läßt sich graphisch im $\mathbb{R}^2$ darstellen. Die Menge P (in Fig. 6 schraffiert) ist ein Polyeder.

Wir betrachten zunächst das lineare Gleichungssystem $Ax = b$ von $LP(I, p)$. Für einen Indexvektor $J = (j_1, \dots, j_r)$, $j_i \in N$, bezeichnen wir mit $A_J := (a_{j_1}, \dots, a_{j_r})$ die Untermatrix von A mit den Spalten a_{j_i} ; x_J bezeichnet den Vektor $(x_{j_1}, \dots, x_{j_r})^T$. Der Einfachheit halber bezeichnen wir auch die Menge $\{j_i \mid i = 1, 2, \dots, r\}$ der Komponenten von J wieder mit J und schreiben z. B. $p \in J$, falls es ein t gibt mit $p = j_t$. Wir definieren

(4.10.4) **Def:** Ein Indexvektor $J = (j_1, \dots, j_m)$ von m verschiedenen Indizes $j_i \in N$ heißt *Basis* von $Ax = b$ bzw. von $LP(I, p)$, wenn A_J nichtsingulär ist.

Natürlich besitzt A genau dann eine Basis, wenn die Zeilen von A linear unabhängig sind. Mit J nennt man auch A_J Basis; die Variablen x_i mit $i \in J$ heißen *Basisvariable*, die übrigen Variablen x_k (Indizes k) mit $k \notin J$ *Nichtbasisvariable* (Nichtbasisindizes). Falls ein Indexvektor $K = (k_1, \dots, k_{n-m})$ genau alle Nichtbasisindizes enthält, schreiben wir kurz $J \oplus K = N$.

Im Beispiel sind $J_A := (3, 4, 5)$, $J_B := (4, 5, 2)$ Basen.

Zu einer Basis J , $J \oplus K = N$, gehört eine eindeutig bestimmte Lösung $\bar{x} = \bar{x}(J)$ von $Ax = b$, die sog. *Basislösung*, mit der Eigenschaft $\bar{x}_K = 0$. Wegen




Fig. 6. Zulässiges Gebiet und Zielfunktion

$$A\bar{x} = A_J\bar{x}_J + A_K\bar{x}_K = A_J\bar{x}_J = b$$

ist $\bar{x}$ gegeben durch

$$(4.10.5) \quad \bar{x}_J := \bar{b}, \quad \bar{x}_K := 0 \text{ mit } \bar{b} := A_J^{-1}b.$$

Ferner ist für eine Basis J jede Lösung x von $Ax = b$ durch ihren Nicht-basisanteil x_K und die Basislösung $\bar{x}$ eindeutig bestimmt: Dies folgt aus der Multiplikation von $Ax = A_Jx_J + A_Kx_K = b$ mit A_J^{-1} und (4.10.5):

$$(4.10.6) \quad \begin{aligned} x_J &= \bar{b} - A_J^{-1}A_Kx_K \\ &= \bar{x}_J - A_J^{-1}A_Kx_K. \end{aligned}$$

Wählt man $x_K \in \mathbb{R}^{n-m}$ beliebig und definiert x_J und damit x durch (4.10.6), so ist x Lösung von $Ax = b$. (4.10.6) liefert also eine bestimmte Parametrisierung der Lösungsmenge $\{x \mid Ax = b\}$ mittels der Parameter $x_K \in \mathbb{R}^{n-m}$.

Ist die Basislösung $\bar{x}$ zur Basis J von $Ax = b$ eine zulässige Lösung von $LP(I, p)$, $\bar{x} \in P$, d. h. es gilt wegen $\bar{x}_K = 0$

$$(4.10.7) \quad \bar{x}_i \geq 0 \text{ für alle } i \in I \cap J,$$

so heißt J *zulässige Basis* von $LP(I, p)$ und $\bar{x}$ *zulässige Basislösung*. Schließlich nennt man eine zulässige Basis *nicht entartet*, wenn statt (4.10.7) schärfer gilt

$$(4.10.8) \quad \bar{x}_i > 0 \text{ für alle } i \in I \cap J.$$

Das lineare Programm $LP(I, p)$ heißt nicht entartet, falls alle zulässigen Basen J von $LP(I, p)$ nicht entartet sind.

Geometrisch entsprechen die zulässigen Basislösungen der verschiedenen Basen von $LP(I, p)$ den Ecken des Polyeders P der zulässigen Lösungen, falls P überhaupt Ecken besitzt. Im Beispiel (s. Fig. 6) gehört die Ecke $A \in P$ zur zulässigen Basis $J_A = (3, 4, 5)$, weil A durch $x_1 = x_2 = 0$ bestimmt ist und $\{1, 2\}$ die Komplementärmenge von J_A ist bzgl. $N = \{1, 2, 3, 4, 5\}$; zu B gehört $J_B = (4, 5, 2)$, zu C die Basis $J_C = (1, 2, 5)$ usw. Die Basis $J_E = (1, 4, 5)$ ist nicht zulässig, weil die zugehörige Basislösung E nicht zulässig ist, $E \notin P$.

Die Simplexmethode zur Lösung von linearen Programmen, die von G.B. Dantzig stammt, ist ein Verfahren, das ausgehend von einer zulässigen Basis J_0 von $LP(I, p)$ mit $p \in J_0$ rekursiv mittels einzelner *Simplexschritte*

$$J_i \rightarrow J_{i+1}$$

eine Folge $\{J_i\}$ weiterer zulässiger Basen J_i von $LP(I, p)$ mit $p \in J_i$ und der folgenden Eigenschaft erzeugt: Die Zielfunktionswerte $\bar{x}(J_i)_p$ der zu J_i gehörigen zulässigen Basislösungen $\bar{x}(J_i)$ sind nicht fallend

$$\bar{x}(J_i)_p \leq \bar{x}(J_{i+1})_p \text{ für alle } i \geq 0.$$

Falls die Basen J_i nichtentartet sind und $LP(I, p)$ überhaupt eine Optimallösung besitzt, bricht die Folge $\{J_i\}$ nach endlich vielen Schritten mit einer Basis J_M ab, deren Basislösung $\bar{x}(J_M)$ Optimallösung von $LP(I, p)$ ist, und es gilt sogar

$$\bar{x}(J_i)_p < \bar{x}(J_{i+1})_p \text{ für alle } 0 \leq i \leq M-1.$$

Überdies sind je zwei aufeinander folgende Basen $J = (j_1, \dots, j_m)$ und $\tilde{J} = (\tilde{j}_1, \dots, \tilde{j}_m)$ auch in folgendem Sinne *benachbart*: J und $\tilde{J}$ besitzen genau $m-1$ gemeinsame Komponenten. J und $\tilde{J}$ gehen dann durch einen Indextausch auseinander hervor: Es gibt genau zwei Indizes $q, s \in N$ mit $q \in J, s \notin J$ und $q \notin \tilde{J}, s \in \tilde{J}$, d. h. $\tilde{J} = (J \cup \{s\}) \setminus \{q\}$.

Bei nichtentarteten Problemen entsprechen benachbarte zulässige Basen geometrisch benachbarten Ecken von P . Im Beispiel (s. Fig. 6) sind $J_A = (3, 4, 5)$ und $J_B = (4, 5, 2)$ benachbarte Basen, A und B benachbarte Ecken.

Die Simplexmethode, genauer „Phase II“ der Simplexmethode, setzt voraus, daß man bereits eine zulässige Basis J von $LP(I, p)$ mit $p \in J$

kennt. Eine solche zulässige Basis kann man mit Hilfe einer Variante der Simplexmethode, der sog. „Phase I“, bestimmen, sofern $LP(I, p)$ überhaupt eine zulässige Lösung besitzt. Wir beschreiben zunächst einen typischen Schritt von Phase II, der von einer zulässigen Basis J zu einer zulässigen Nachbarbasis $\tilde{J}$ von $LP(I, p)$ führt:

(4.10.9) Simplexschritt: *Voraussetzung:* $J = (j_1, \dots, j_m)$ ist eine zulässige Basis von $LP(I, p)$ mit $p = j_t \in J$, $J \oplus K = N$.

1) *Berechne den Vektor*

$$\bar{b} := A_J^{-1}b$$

und damit die zu J gehörige Basislösung $\bar{x}$ mit $\bar{x}_J := \bar{b}$, $\bar{x}_K := 0$.

2) *Berechne den Zeilenvektor*

$$\pi := e_t^T A_J^{-1},$$

wobei $e_t = (0, \dots, 1, \dots, 0)^T \in \mathbb{R}^m$ der t -te Achsenvektor des $\mathbb{R}^m$ ist. Bestimme mit Hilfe von π die Zahlen

$$c_k := \pi a_k, \quad k \in K.$$

3) *Prüfe, ob*

$$(4.10.10) \quad \begin{aligned} c_k &\geq 0 \quad \text{für alle } k \in K \cap I \\ \text{und } c_k &= 0 \quad \text{für alle } k \in K \setminus I \end{aligned}$$

gilt.

a) *Falls ja, stop: die Basislösung $\bar{x}$ ist Optimallösung von $LP(I, p)$.*

b) *Falls nein, bestimme ein $s \in K$ mit*

$$c_s < 0, \quad s \in K \cap I \quad \text{oder} \quad |c_s| \neq 0, \quad s \in K \setminus I$$

und setze $\sigma := -\text{sign } c_s$.

4) *Berechne den Vektor*

$$\bar{a} := (\bar{\alpha}_1, \bar{\alpha}_2, \dots, \bar{\alpha}_m)^T := A_J^{-1}a_s.$$

5) *Falls*

$$(4.10.11) \quad \sigma \bar{\alpha}_i \leq 0 \quad \text{für alle } i \text{ mit } j_i \in I,$$

stop: $LP(I, p)$ besitzt kein endliches Optimum. Andernfalls,

6) bestimme einen Index r mit $j_r \in I$, $\sigma \bar{\alpha}_r > 0$ und

$$\frac{\bar{b}_r}{\sigma \bar{\alpha}_r} = \min \left\{ \frac{\bar{b}_i}{\sigma \bar{\alpha}_i} \mid i : j_i \in I \text{ \& } \sigma \bar{\alpha}_i > 0 \right\}.$$

7) Nimm als $\tilde{J}$ irgendeinen passenden Indexvektor mit

$$\tilde{J} := (J \cup \{s\}) \setminus \{j_r\},$$

zum Beispiel

$$\tilde{J} := (j_1, \dots, j_{r-1}, s, j_{r+1}, \dots, j_m)$$

oder

$$\tilde{J} := (j_1, \dots, j_{r-1}, j_{r+1}, \dots, j_m, s).$$

Wir wollen diese Regeln begründen und nehmen dazu an, daß $J = (j_1, \dots, j_m)$ eine zulässige Basis von $LP(I, p)$ mit $p = j_i \in J$ ist und $J \oplus K = N$ gilt. Schritt 1 von (4.10.9) liefert wegen (4.10.5) die zugehörige Basislösung $\bar{x} = \bar{x}(J)$. Da sich alle Lösungen von $Ax = b$ in der Form (4.10.6) darstellen lassen, gilt wegen $p = j_i$ für die Zielfunktion

$$\begin{aligned} x_p &= e_i^T x_J = \bar{x}_p - e_i^T A_J^{-1} A_K x_K \\ (4.10.12) \quad &= \bar{x}_p - \pi A_K x_K \\ &= \bar{x}_p - c_K x_K, \end{aligned}$$

wenn man den Zeilenvektor π und die Komponenten c_k des Zeilenvektors c_K , $c_K^T \in \mathbb{R}^{n-m}$, wie in Schritt 2 von (4.10.9) definiert. c_K heißt Vektor der *reduzierten Kosten*: Wegen (4.10.12) gibt c_k für $k \in K$ den Betrag an, um den sich die Zielfunktion x_p vermindert, wenn man x_k um eine Einheit vergrößert. Ist deshalb die Bedingung (4.10.10) erfüllt (s. Schritt 3), so folgt aus (4.10.12) für jede zulässige Lösung x von $LP(I, p)$ wegen $x_i \geq 0$ für $i \in I$ sofort

$$x_p = \bar{x}_p - \sum_{k \in K \cap I} c_k x_k \leq \bar{x}_p,$$

d. h., die Basislösung $\bar{x}$ ist Optimallösung von $LP(I, p)$. Dies motiviert den Test (4.10.10) und die Aussage a) von Schritt 3. Falls (4.10.10) nicht erfüllt ist, gibt es einen Index $s \in K$ für den entweder

$$(4.10.13) \quad c_s < 0, \quad s \in K \cap I,$$

oder

$$(4.10.14) \quad |c_s| \neq 0, \quad s \in K \setminus I,$$

gilt. Sei s ein solcher Index. Wir setzen $\sigma := -\text{sign } c_s$. Da wegen (4.10.12) eine Vergrößerung von σx_s zu einer Vergrößerung der Zielfunktion x_p führt, betrachten wir folgende Schar von Vektoren $x(\theta) \in \mathbb{R}^n$, $\theta \in \mathbb{R}$,

$$(4.10.15) \quad \begin{aligned} x(\theta)_J &:= \bar{b} - \theta \sigma A_J^{-1} a_s = \bar{b} - \theta \sigma \bar{a}, \\ x(\theta)_s &:= \theta \sigma, \\ x(\theta)_k &:= 0 \quad \text{für } k \in K, \quad k \neq s. \end{aligned}$$

Hier ist $\bar{a} := A_J^{-1} a_s$ wie in Schritt 4 von (4.10.9) definiert.

In unserem Beispiel ist $I = \{1, 2, 3, 4\}$ und $J_0 = J_A = (3, 4, 5)$ eine zulässige Basis, $K_0 = (1, 2)$, $p = 5 \in J_0$, $t_0 = 3$. (4.10.9) liefert zu J_0 :

$$A_{J_0} = \begin{bmatrix} 1 & & \\ & 1 & \\ & & 1 \end{bmatrix}, \quad \bar{b} = \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix}$$

$\bar{x}(J_0) = (0, 0, 2, 4, 0)^T (\hat{=}$ Punkt A in Fig. 6) und $\pi A_{J_0} = e_{t_0}^T \Rightarrow \pi = (0, 0, 1)$. Die reduzierten Kosten sind $c_1 = \pi a_1 = -1$, $c_2 = \pi a_2 = -2$. Also ist J_0 nicht optimal. Wählt man in (4.10.9), 3b) den Index $s = 2$, so wird

$$\bar{a} = A_{J_0}^{-1} a_2 = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}.$$

Die Lösungsschar $x(\theta)$ ist gegeben durch

$$x(\theta) = (0, \theta, 2 - \theta, 4 - \theta, 2\theta)^T.$$

Geometrisch beschreibt $x(\theta)$, $\theta \geq 0$ in Fig. 6 einen Strahl, der längs einer Kante des Polyeders P von der Ecke A ($\theta = 0$) in Richtung der Nachbarecke B ($\theta = 2$) läuft.

Wegen (4.10.6) gilt $Ax(\theta) = b$ für alle $\theta \in \mathbb{R}$. Insbesondere gilt wegen (4.10.12), $\bar{x} = x(0)$ und der Wahl von σ

$$(4.10.16) \quad x(\theta)_p = \bar{x}_p - c_s x(\theta)_s = \bar{x}_p + \theta |c_s|,$$

so daß die Zielfunktion längs des Strahls $x(\theta)$ mit θ streng monoton wächst. Es liegt daher nahe, unter den Lösungen $x(\theta)$ von $Ax = b$ die beste *zulässige* Lösung zu suchen; d. h. wir suchen das größte $\theta \geq 0$ mit

$$x(\theta)_l \geq 0 \quad \text{für alle } l \in I.$$

Wegen (4.10.15) ist dies äquivalent damit, das größte $\theta \geq 0$ mit

$$(4.10.17) \quad x(\theta)_{j_i} = \bar{b}_i - \theta \sigma \bar{a}_i \geq 0 \quad \text{für alle } i \text{ mit } j_i \in I$$

zu finden, weil $x(\theta)_k \geq 0$ für alle $k \in K \cap I$, $\theta \geq 0$ wegen (4.10.15) automatisch erfüllt ist. Wenn nun $\sigma \bar{a}_i \leq 0$ für alle $j_i \in I$ gilt (vgl. Schritt 5

von (4.10.9)), ist wegen (4.10.17) $x(\theta)$ für alle $\theta \geq 0$ eine zulässige Lösung von $LP(I, p)$ mit $\sup\{x(\theta)_p \mid \theta \geq 0\} = +\infty : LP(I, p)$ besitzt dann kein endliches Optimum. Dies rechtfertigt Schritt 5 von (4.10.9). Andernfalls gibt es ein größtes $\theta =: \bar{\theta}$ für das (4.10.17) gilt:

$$\bar{\theta} = \frac{\bar{b}_r}{\sigma \bar{\alpha}_r} = \min \left\{ \frac{\bar{b}_i}{\sigma \bar{\alpha}_i} \mid i : j_i \in I \text{ \& } \sigma \bar{\alpha}_i > 0 \right\}.$$

Dies bestimmt einen Index r mit $j_r \in I$, $\sigma \bar{\alpha}_r > 0$ und

$$(4.10.18) \quad x(\bar{\theta})_{j_r} = \bar{b}_r - \bar{\theta} \sigma \bar{\alpha}_r = 0, \quad x(\bar{\theta}) \text{ ist zulässige Lösung.}$$

Im Beispiel ist

$$\bar{\theta} = 2 = \frac{\bar{b}_1}{\bar{\alpha}_1} = \min \left\{ \frac{\bar{b}_1}{\bar{\alpha}_1}, \frac{\bar{b}_2}{\bar{\alpha}_2} \right\}, \quad r = 1.$$

$x(\bar{\theta}) = (0, 2, 0, 2, 4)^T$ entspricht der Ecke B von Fig. 6).

Wegen der Zulässigkeit von J ist $\bar{\theta} \geq 0$ und es folgt aus (4.10.16)

$$x(\bar{\theta})_p \geq \bar{x}_p.$$

Wenn J nicht entartet (4.10.8) ist, gilt schärfer $\bar{\theta} > 0$ und damit

$$x(\bar{\theta})_p > \bar{x}_p.$$

Wegen (4.10.6), (4.10.15), (4.10.18) ist $x = x(\theta)$ die eindeutig bestimmte Lösung von $Ax = b$ mit der zusätzlichen Eigenschaft

$$x_{j_r} = 0, \quad x_k = 0 \quad \text{für } k \in K, \quad k \neq s,$$

d. h. mit $x_{\tilde{K}} = 0$, $\tilde{K} := (K \cup \{j_r\}) \setminus \{s\}$. Aus der Eindeutigkeit von x folgt die Nichtsingularität von $A_{\tilde{J}}$, $\tilde{J} := (J \cup \{s\}) \setminus \{j_r\}$; $x(\theta) = \bar{x}(\tilde{J})$ ist also Basislösung zur benachbarten zulässigen Basis $\tilde{J}$ und es gilt

$$(4.10.19) \quad \begin{aligned} \bar{x}(\tilde{J})_p &> \bar{x}(J)_p, & \text{falls } J \text{ nicht entartet ist,} \\ \bar{x}(\tilde{J})_p &\geq \bar{x}(J)_p, & \text{sonst.} \end{aligned}$$

Im Beispiel erhält man als neue Basis

$$J_1 = (2, 4, 5) = J_B, \quad K_1 = (1, 3),$$

die der Ecke B von Fig. 6 entspricht. Im Sinne der Zielfunktion x_5 ist B besser als $A : \bar{x}(J_B)_5 = 4 > \bar{x}(J_A)_5 = 0$.

Da nach Definition von r stets $j_r \in I$ gilt, folgt

$$J \setminus I \subset \tilde{J} \setminus I,$$

d. h. bei dem Übergang $J \rightarrow \tilde{J}$ verlassen höchstens vorzeichenbeschränkte Variable x_{j_r} , $j_r \in I$ die Basis; sobald eine freie Variable x_s , $s \notin I$, Basisvariable geworden ist, bleibt sie bei allen weiteren Simplexschritten Basisvariable. Insbesondere folgt $p \in \tilde{J}$ wegen $p \in J$ und $p \notin I$. Die neue Basis $\tilde{J}$ erfüllt also wieder die Voraussetzung von (4.10.9), so daß (4.10.9) auch auf $\tilde{J}$ angewandt werden kann. Ausgehend von einer ersten zulässigen Basis J_0 von $LP(I, p)$ mit $p \in J_0$ erhält man so eine Folge

$$J_0 \rightarrow J_1 \rightarrow J_2 \rightarrow \dots$$

von zulässigen Basen J_i von $LP(I, p)$ mit $p \in J_i$, für die im Falle der Nichtentartung aller J_i gilt

$$\bar{x}(J_0)_p < \bar{x}(J_1)_p < \bar{x}(J_2)_p < \dots$$

Eine Wiederholung der J_i kann also in diesem Fall nicht eintreten. Da es nur endlich viele verschiedene Indexvektoren J gibt, muß das Verfahren nach endlich vielen Schritten abbrechen. Wir haben damit für das eben beschriebene Verfahren, die *Simplexmethode*, folgenden Satz gezeigt:

(4.10.20) Satz: Sei J_0 zulässige Basis von $LP(I, p)$ mit $p \in J_0$. Wenn $LP(I, p)$ nicht entartet ist, erzeugt die Simplexmethode ausgehend von J_0 eine endliche Folge von zulässigen Basen J_i von $LP(I, p)$ mit $p \in J_i$ und $\bar{x}(J_i)_p < \bar{x}(J_{i+1})_p$. Die letzte Basislösung ist entweder eine Optimallösung von $LP(I, p)$ oder $LP(I, p)$ besitzt kein endliches Optimum.

Wir setzen das Beispiel fort: Als Resultat des ersten Simplexschritts haben wir die neue zulässige Basis $J_1 = (2, 4, 5) = J_B$ erhalten, $K_1 = (1, 3)$, $t_1 = 3$, so daß

$$A_{J_1} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ -2 & 0 & 1 \end{bmatrix}, \quad \bar{b} = \begin{bmatrix} 2 \\ 2 \\ 4 \end{bmatrix}, \quad \bar{x}(J_1) = (0, 2, 0, 2, 4)^T (\triangleq \text{Ecke } B),$$

$$\pi A_{J_1} = e_{t_1}^T \Rightarrow \pi = (2, 0, 1).$$

Die reduzierten Kosten sind $c_1 = \pi a_1 = -3$, $c_3 = \pi a_3 = 2$, also ist J_1 nicht optimal:

$$s = 1, \quad \bar{a} = A_{J_1}^{-1} a_1 \Rightarrow \bar{a} = \begin{bmatrix} -1 \\ 2 \\ -3 \end{bmatrix} \Rightarrow r = 2.$$

Also

$$J_2 = (2, 1, 5) = J_C, \quad K_2 = (3, 4), \quad t_2 = 3$$

$$A_{J_2} = \begin{bmatrix} 1 & -1 & 0 \\ 1 & 1 & 0 \\ -2 & -1 & 1 \end{bmatrix}, \quad \bar{b} = \begin{bmatrix} 3 \\ 1 \\ 7 \end{bmatrix},$$

$$\bar{x}(J_2) = (1, 3, 0, 0, 7) \quad (\hat{=} \text{Ecke } C)$$

$$\pi A_{J_2} = e_{t_2}^T \Rightarrow \pi = (\frac{1}{2}, \frac{3}{2}, 1)$$

Die reduzierten Kosten sind $c_3 = \pi a_3 = \frac{1}{2} > 0$, $c_4 = \pi a_4 = \frac{3}{2} > 0$.

Das Optimalitätskriterium ist erfüllt, also ist $\bar{x}(J_2)$ optimal, d. h. $\bar{x}_1 = 1$, $\bar{x}_2 = 3$, $\bar{x}_3 = 0$, $\bar{x}_4 = 0$, $\bar{x}_5 = 7$. Der Optimalwert der Zielfunktion x_5 ist $\bar{x}_5 = 7$.

Bei der praktischen Durchführung der Simplexmethode hat man pro Simplexschritt $J \rightarrow \tilde{J}$ (4.10.9) drei lineare Gleichungssysteme mit der Matrix A_J zu lösen

$$(4.10.21) \quad \begin{aligned} A_J \bar{b} &= b \Rightarrow \bar{b} && \text{(Schritt 1),} \\ \pi A_J &= e_t^T \Rightarrow \pi && \text{(Schritt 2),} \\ A_J \bar{a} &= a_s \Rightarrow \bar{a} && \text{(Schritt 4).} \end{aligned}$$

Die dazu erforderliche Rechenarbeit für die sukzessiven Basen $J \rightarrow \tilde{J} \rightarrow \dots$ kann man erheblich reduzieren, wenn man berücksichtigt, daß aufeinanderfolgende Basen $J \rightarrow \tilde{J}$ benachbart sind: man erhält ja die neue Basismatrix $A_{\tilde{J}}$ aus A_J dadurch, daß man eine Spalte von A_J durch eine andere Spalte von A ersetzt. Dies kann man z. B. bei Verwendung von Zerlegungen der Basismatrix A_J des Typs (4.9.1)

$$FA_J = R, \quad F \text{ nichtsingulär, } R \text{ obere Dreiecksmatrix,}$$

ausnutzen (s. Abschnitt 4.9). Mit Hilfe einer solchen Zerlegung von A_J kann man die Gleichungssysteme (4.10.21) leicht lösen:

$$\begin{aligned} R\bar{b} &= Fb \Rightarrow \bar{b}, \\ R^T z &= e_t \Rightarrow z \Rightarrow \pi = z^T F, \\ R\bar{a} &= Fa_s \Rightarrow \bar{a}. \end{aligned}$$

Mit den Techniken von Abschnitt 4.9 kann man weiter aus einer Zerlegung $FA_J = R$ von A_J in jedem Simplexschritt eine analoge Zerlegung $\tilde{F}A_{\tilde{J}} = \tilde{R}$ für die Nachbarbasis $\tilde{J} = (j_1, \dots, j_{r-1}, j_{r+1}, \dots, j_m, s)$ (vgl. Schritt 7 von (4.10.9)) herrechnen: Die Matrix $\tilde{F}A_{\tilde{J}}$ ist eine obere Hessenberg-Matrix der Form (skizziert für $m = 4$, $r = 2$)

$$FA_J = \begin{bmatrix} x & x & x & x \\ & x & x & x \\ & & x & x \\ & & & x \end{bmatrix} =: R'$$

deren Subdiagonalelemente man leicht mit Matrizen $E_{r,r+1}$, $E_{r+1,r+2}$, $\dots$, $E_{m-1,m}$ des Typs (4.9.5) annullieren, und R' so in eine obere Dreiecksmatrix $\tilde{R}$ transformieren kann:

$$\tilde{F}A_J = \tilde{R}, \quad \tilde{F} := EF, \quad \tilde{R} := ER', \quad E := E_{m-1,m}E_{m-2,m-1} \dots E_{r,r+1}.$$

Es liegt also nahe, die Simplexmethode in der Weise praktisch zu realisieren, daß man in jedem Simplexschritt $J \rightarrow \tilde{J}$ ein 4-Tupel $\mathcal{M} = \{J; t; F, R\}$ mit der Eigenschaft

$$j_t = p, \quad FA_J = R,$$

in ein analoges 4-Tupel $\tilde{\mathcal{M}} = \{\tilde{J}; \tilde{t}; \tilde{F}, \tilde{R}\}$ transformiert. Zum Start dieser Variante der Simplexmethode hat man sich neben einer zulässigen Basis J_0 mit $p \in J_0$ von $LP(I, p)$ auch eine Zerlegung $F_0A_{J_0} = R_0$ des Typs (4.9.1) von A_{J_0} zu verschaffen. ALGOL-Programme für diese Realisierung der Simplexmethode findet man in Wilkinson, Reinsch (1971), eine Untersuchung des Rundungsfehlerverhaltens in Bartels (1971).

Die üblicheren Realisierungen der Simplexmethode benutzen statt der Zerlegungen $FA_J = R$ (4.9.1) andere Größen, die es gestatten, die Gleichungssysteme (4.10.21) effizient zu lösen. So werden bei der „Inverse-Basis-Methode“ 5-Tupel der Form

$$\mathcal{M} = \{J; t; B, \bar{b}, \pi\}$$

mit

$$j_t = p, \quad B := A_J^{-1}, \quad \bar{b} = A_J^{-1}b, \quad \pi := e_t^T A_J^{-1},$$

benutzt, bei einer anderen Variante 5-Tupel

$$\mathcal{M} = \{J; t; \bar{A}, \bar{b}, \pi\}$$

mit

$$j_t = p, \quad \bar{A} := A_J^{-1}A_K, \quad \bar{b} := A_J^{-1}b, \quad \pi := e_t^T A_J^{-1}, \quad J \oplus K = N.$$

Man nutzt hier bei dem Übergang $J \rightarrow \tilde{J}$ rechen sparend aus, daß man für benachbarte Basen $J, \tilde{J}$ die Inverse $A_{\tilde{J}}^{-1}$ durch Multiplikation von A_J^{-1} mit einer geeigneten Frobeniusmatrix G berechnen kann (s. Aufgabe 4 von Kapitel 4): $A_{\tilde{J}}^{-1} = GA_J^{-1}$. Bei diesen Verfahren ist sogar die Rechenarbeit etwas geringer als bei der Verwendung der Zerlegung $FA_J = R$ (4.9.1). Ihr Hauptnachteil liegt in ihrer numerischen Instabilität: Ist eine Basismatrix A_{J_i}

schlecht konditioniert, so pflanzt sich die zwangsläufig große Ungenauigkeit von $A_{J_i}^{-1}$, $A_{J_i}^{-1} A_{K_i}$ bei $\mathcal{M}_i$ und $\mathcal{M}_i$ auf alle folgenden 5-Tupel $\mathcal{M}_j$, $\mathcal{M}_j$, $j > i$ fort.

Das folgende praktische Beispiel illustriert den Gewinn an numerischer Stabilität, den man erhält, wenn man statt der üblichen „Inverse-Basis-Methode“ die Dreieckszerlegung (4.9.1) zur Realisierung der Simplexmethode benutzt. Gegeben sei ein lineares Programm mit Nebenbedingungen der Form (die Zielfunktion ist für die folgenden Überlegungen irrelevant)

$$(4.10.22) \quad \begin{aligned} Ax &= b, & A &= (A1, A2), \\ x &\geq 0. \end{aligned}$$

Als Matrix A wählen wir die 5×10 -Matrix, die durch die 5×5 -Untermatrizen $A1$, $A2$

$$A1 = (a1_{ik}), \quad a1_{ik} := 1/(i+k), \quad i, k = 1, \dots, 5,$$

$$A2 := I_5 = 5\text{-reihige Einheitsmatrix,}$$

gegeben ist. $A1$ ist sehr schlecht, $A2$ sehr gut konditioniert. Als rechte Seite wird der Vektor $b := A1 \cdot e$, $e := (1, 1, 1, 1, 1)^T$, gewählt,

$$b_i := \sum_{k=1}^5 \frac{1}{i+k},$$

so daß die Basen $J_1 := (1, 2, 3, 4, 5)$, $J_2 := (6, 7, 8, 9, 10)$ beide für (4.10.22) zulässig sind und die Basislösungen

$$(4.10.23) \quad \begin{aligned} \bar{x}(J_1) &:= \begin{bmatrix} \bar{b}_1 \\ 0 \end{bmatrix}, & \bar{b}_1 &:= A_{J_1}^{-1} b = A1^{-1} b = e, \\ \bar{x}(J_2) &:= \begin{bmatrix} 0 \\ \bar{b}_2 \end{bmatrix}, & \bar{b}_2 &:= A_{J_2}^{-1} b = A2^{-1} b = b, \end{aligned}$$

besitzen.

Wir wählen als Startbasis $J_2 = (6, 7, 8, 9, 10)$ und transformieren sie mit der Inverse-Basis-Methode bzw. der Dreieckszerlegungsmethode mittels einzelner Austauschschritte in die neue Basis J_1 und kehren anschließend mittels einer anderen Sequenz von Austauschschritten wieder zur Startbasis J_2 zurück:

$$J_2 \rightarrow \dots \rightarrow J_1 \rightarrow \dots \rightarrow J_2.$$

Für die entsprechenden Basislösungen (4.10.23) erhält man bei diesem Kreisprozeß folgende Resultate (Maschinengenauigkeit $\text{eps} \approx 10^{-11}$, ungenaue Stellen sind unterstrichen)

Basis	exakte Basislösung	Inverse-Basis- Methode	Dreiecks- zerlegungsmethode
$J_2 \quad \bar{b}_2 =$	1.4500000000 ₁₀ 0	1.4500000000 ₁₀ 0	1.4500000000 ₁₀ 0
	1.0928571428 ₁₀ 0	1.0928571428 ₁₀ 0	1.0928571428 ₁₀ 0
	8.8452380952 ₁₀ -1	8.8452380952 ₁₀ -1	8.8452380952 ₁₀ 0
	7.4563492063 ₁₀ -1	7.4563492063 ₁₀ -1	7.4563492063 ₁₀ -1
	6.4563492063 ₁₀ -1	6.4563492063 ₁₀ -1	6.4563492063 ₁₀ -1
$J_1 \quad \bar{b}_1 =$	1	1.0000000182 ₁₀ 0	1.0000000786 ₁₀ 0
	1	9.9999984079 ₁₀ -1	9.9999916035 ₁₀ -1
	1	1.0000004372 ₁₀ 0	1.0000027212 ₁₀ 0
	1	9.9999952118 ₁₀ -1	9.9999956491 ₁₀ -1
	1	1.0000001826 ₁₀ 0	1.0000014837 ₁₀ 0
$J_2 \quad \bar{b}_2 =$	1.4500000000 ₁₀ 0	1.4500010511 ₁₀ 0	1.4500000000 ₁₀ 0
	1.0928571428 ₁₀ 0	1.0928579972 ₁₀ 0	1.0928571427 ₁₀ 0
	8.8452380952 ₁₀ -1	8.8452453057 ₁₀ -1	8.8452380950 ₁₀ -1
	7.4563492063 ₁₀ -1	7.4563554473 ₁₀ -1	7.4563492060 ₁₀ -1
	6.4563492063 ₁₀ -1	6.4563547103 ₁₀ -1	6.4563492059 ₁₀ -1

Man findet folgendes Resultat: Wegen $A_{J_2} = I_5$ liefern beide Methoden anfangs die exakte Lösung; für die Basis J_1 liefern beide gleich ungenaue Resultate: Diese Ungenauigkeit spiegelt die schlechte Kondition von A_{J_1} wieder; sie läßt sich bei keiner Methode vermeiden, es sei denn, man führt die Rechnung mit höherer Genauigkeit durch. Nach dem Durchgang durch die schlecht konditionierte Basismatrix A_{J_1} ändert sich die Situation drastisch zugunsten der Dreieckszerlegungsmethode: Diese Methode liefert die Basislösung zu J_2 mit praktisch der vollen Maschinengenauigkeit, während die Inverse-Basis-Methode die Lösung nur mit derselben Ungenauigkeit wie bei der vorausgegangenen Basis J_1 reproduziert. Bei der Inverse-Basis-Methode vererbt sich der Einfluß der schlechten Kondition einer Basismatrix A_J auf alle weiteren Basen, nicht aber bei der Dreieckszerlegungsmethode.

Sehr große lineare Programme besitzen in der Regel eine spezielle Struktur, z.B. ist die Matrix A oft sehr dünn besetzt (nur relativ wenige Komponenten von A sind von Null verschieden). Um solche Probleme mit der Simplexmethode überhaupt lösen zu können, ist es von größter Wichtigkeit, diese Strukturen zur Reduzierung der Anzahl der Rechenoperationen und des Speicherbedarfs auszunutzen, ohne dabei die numerische Stabilität zu vernachlässigen.

Ebenso wichtig ist es, die Simplexmethode selbst zu optimieren, um durch eine gute Wahl der Indizes s und r (Schritte 3) und 6) in (4.10.6)) die Zahl der Simplexschritte möglichst klein zu halten.

Ein leistungsfähiges modernes Programm, das alle diese Probleme berücksichtigt, ist CPLEX, das von Bixby (1990) stammt.

4.11 Phase I der Simplexmethode

Zum Start von Phase II der Simplexmethode benötigt man eine zulässige Basis J_0 von $LP(I, p)$ mit $p = j_{t_0} \in J_0$ bzw. ein zugehöriges 4- Tupel $\mathcal{M}_0 = \{J_0; t_0; F_0, R_0\}$, in dem die nichtsinguläre Matrix F_0 und die nicht-singuläre obere Dreiecksmatrix R_0 eine Zerlegung $F_0 A_{J_0} = R_0$ (4.9.1) der Basismatrix A_{J_0} angeben.

In einigen Spezialfällen kann man leicht eine zulässige Basis $J_0(\mathcal{M}_0)$ finden, z. B. dann, wenn ein lineares Programm folgender Gestalt vorliegt:

$$\begin{aligned} &\text{minimiere} \quad c_1 x_1 + \cdots + c_n x_n \\ &x \in \mathbb{R}^n : \quad a_{i1} x_1 + \cdots + a_{in} x_n \leq b_i, \quad i = 1, 2, \dots, m \\ &\quad \quad \quad x_i \geq 0 \quad \text{für } i \in I_1 \subset \{1, 2, \dots, n\}, \end{aligned}$$

wobei $b_i \geq 0$ für $i = 1, 2, \dots, m$. Nach Einführung von Schlupfvariablen erhält man das äquivalente Problem

$$\begin{aligned} &\text{maximiere} \quad x_{n+m+1} \\ &x \in \mathbb{R}^{n+m+1} : \quad a_{i1} x_1 + \cdots + a_{in} x_n + x_{n+i} = b_i, \quad i = 1, 2, \dots, m \\ &\quad \quad \quad c_1 x_1 + \cdots + c_n x_n + x_{n+m+1} = 0, \\ &\quad \quad \quad x_i \geq 0 \quad \text{für } i \in I_1 \cup \{n+1, n+2, \dots, n+m\}, \end{aligned}$$

das die Standardform $LP(I, p)$ des letzten Abschnitts mit

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} & 1 & & \\ \vdots & & \vdots & & \ddots & \\ a_{m1} & \cdots & a_{mn} & & & 1 \\ c_1 & \cdots & c_n & & & 1 \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ \vdots \\ b_m \\ b_m \\ 0 \end{bmatrix},$$

$$p := n + m + 1, \quad I := I_1 \cup \{n+1, n+2, \dots, n+m\},$$

besitzt. $J_0 := (n+1, n+2, \dots, n+m+1)$ ist wegen $b_i \geq 0$ eine zulässige Basis mit $p = j_t \in J_0$, $t := m+1$. Ein entsprechendes $\mathcal{M}_0 = (J_0; t_0; F_0, R_0)$ ist gegeben durch $t_0 := m+1$, $F_0 := R_0 := I_{m+1}$, die $m+1$ -reihige Einheitsmatrix.

Für allgemeine lineare Programme (P) leistet die sog. „Phase I der Simplexmethode“ das Verlangte. Man versteht darunter allgemein Techniken,

bei denen Phase II der Simplexmethode auf ein modifiziertes lineares Programm ($\tilde{P}$) angewandt wird. Dabei ist ($\tilde{P}$) so beschaffen, daß für ($\tilde{P}$) eine zulässige Startbasis bekannt ist (also ($\tilde{P}$) mittels Phase II der Simplexmethode gelöst werden kann) und jede Optimalbasis von ($\tilde{P}$) eine zulässige Startbasis für (P) liefert. Es soll hier nur eine dieser Techniken beschrieben werden. Bezüglich anderer Starttechniken sei auf die Spezialliteratur über lineare Programmierung verwiesen, z. B. Dantzig (1963), Gass (1969), Hadley (1962) und Murty (1976).

Wir betrachten ein allgemeines lineares Programm, das bereits auf folgende Form gebracht worden sei:

$$(4.11.2) \quad \begin{array}{ll} \text{minimiere} & c_1 x_1 + \cdots + c_n x_n \\ x \in \mathbb{R}^n : & a_{j1} x_1 + \cdots + a_{jn} x_n = b_j, \quad j = 1, 2, \dots, m \\ & x_i \geq 0 \text{ für } i \in I \subseteq \{1, 2, \dots, n\}, \end{array}$$

wobei wir o. B. d. A. annehmen, daß $b_j \geq 0$ für alle j gilt (multipliziere die j -te Nebenbedingung mit -1 , falls $b_j < 0$).

Wir erweitern als erstes die Nebenbedingungen, indem wir sog. *künstliche Variable* $x_{n+1}, \dots, x_{n+m}$ einführen,

$$(4.11.3) \quad \begin{array}{ccccccc} a_{11}x_1 & + \cdots + & a_{1n}x_n & + x_{n+1} & & & = b_1 \\ \vdots & & \vdots & & \ddots & & \vdots \\ a_{m1}x_1 & + \cdots + & a_{mn}x_n & & & + x_{n+m} & = b_m \end{array}$$

Natürlich sind die zulässigen Lösungen von (4.11.2) eindeutig den zulässigen Lösungen von (4.11.3) zugeordnet, für die die künstlichen Variablen verschwinden.

$$(4.11.4) \quad x_{n+1} = x_{n+2} = \cdots = x_{n+m} = 0.$$

Wir stellen nun ein Maximierungsproblem mit den Nebenbedingungen (4.11.3) auf, dessen Optimallösungen (4.11.4) erfüllen, sofern (4.11.2) überhaupt zulässige Lösungen besitzt. Dazu betrachten wir

 $LP(\hat{I}, \hat{p}):$

$$\begin{array}{llll} \text{maximiere} & x_{n+m+1} & & \\ x : & a_{11}x_1 + \cdots + a_{1n}x_n + x_{n+1} & & = b_1 \\ & \vdots & & \vdots \\ & a_{m1}x_1 + \cdots + a_{mn}x_n & + x_{n+m} & = b_m \\ & & x_{n+1} + \cdots + x_{n+m} + x_{n+m+1} & = 0 \\ & x_i \geq 0 \text{ f\"ur } i \in \hat{I} := I \cup \{n+1, \dots, n+m\}, \hat{p} := n+m+1 & & \end{array}$$

Als Startbasis können wir für dieses Problem $\hat{J}_0 := (n+1, \dots, n+m+1)$ wählen. Sie ist zulässig, weil die zugehörige Basislösung $\bar{x}$,

$$\bar{x}_j = 0, \quad \bar{x}_{n+i} = b_i, \quad \bar{x}_{n+m+1} = -\sum_{i=1}^m b_i, \quad \text{für } 1 \leq j \leq n, 1 \leq i \leq m,$$

wegen $b_j \geq 0$ zulässig ist.

Ein zu $\hat{J}_0$ gehöriges 4-Tupel $\mathcal{M}_0 = \{\hat{J}_0; \hat{t}_0; \hat{F}_0, \hat{R}_0\}$ ist gegeben durch

$$\hat{t}_0 := m+1, \quad \hat{F}_0 := \begin{bmatrix} 1 & & & 0 \\ \vdots & \ddots & & \\ 0 & \dots & 1 & \\ -1 & \dots & -1 & 1 \end{bmatrix}, \quad \hat{R}_0 := \begin{bmatrix} 1 & & 0 \\ & \ddots & \\ 0 & & 1 \end{bmatrix}.$$

Damit kann Phase II der Simplexmethode zur Lösung von $LP(\hat{I}, \hat{p})$ unmittelbar gestartet werden. Weil $LP(\hat{I}, \hat{p})$ wegen $x_{n+m+1} = -\sum_{i=1}^m x_{n+i} \leq 0$ einen endlichen Maximalwert besitzt, liefert sie schließlich eine Optimalbasis $\bar{J}$ und die zugehörige Basislösung $\bar{x} = \bar{x}(\bar{J})$, die Optimallösung von $LP(\hat{I}, \hat{p})$ ist. Es können nun drei Fälle vorliegen:

- 1) $\bar{x}_{n+m+1} < 0$, d. h. (4.11.4) gilt nicht für $\bar{x}$,
- 2) $\bar{x}_{n+m+1} = 0$ und keine künstliche Variable ist Basisvariable,
- 3) $\bar{x}_{n+m+1} = 0$ und es gibt eine künstliche Variable in $\bar{J}$.

In Fall 1) ist (4.11.2) unlösbar, denn jede zulässige Lösung entspricht einer zulässigen Lösung von $LP(\hat{I}, \hat{p})$ mit $x_{n+m+1} = 0$. Im Fall 2) liefert die Optimalbasis $\bar{J}$ von $LP(\hat{I}, \hat{p})$ sofort eine zulässige Startbasis für Phase II der Simplexmethode zur Lösung von (4.11.2).

Im Fall 3) liegt ein entartetes Problem vor, weil die künstlichen Variablen in der Basis $\bar{J}$ verschwinden. Wenn nötig kann man es durch eine Umnummerierung der Gleichungen und der künstlichen Variablen erreichen, daß die künstlichen Variablen, die sich noch in der Basis $\bar{J}$ befinden, gerade die Variablen $x_{n+1}, x_{n+2}, \dots, x_{n+k}$ sind. Wir streichen dann in $LP(\hat{I}, \hat{p})$ die übrigen künstlichen Variablen, die nicht zur Basis $\bar{J}$ gehören, und führen statt x_{n+m+1} eine neue Variable $x_{n+k+1} := -x_{n+1} - \dots - x_{n+k}$ und eine neue Zielfunktionsvariable x_{n+k+2} ein. Die optimale Basis $\bar{J}$ von $LP(\hat{I}, \hat{p})$ liefert dann eine zulässige Startbasis $\tilde{J} \cup \{x_{n+k+2}\}$ für das zu (4.11.2) äquivalente Problem

maximiere x_{n+k+2}

$$\begin{array}{llll} x : & a_{11}x_1 + \dots + & a_{1n}x_n + x_{n+1} & = b_1 \\ & \vdots & \vdots & \vdots \\ & a_{k1}x_1 + \dots + & a_{kn}x_n & + x_{n+k} = b_k \end{array}$$

$$\begin{array}{rcl}
& x_{n+1} + \cdots + x_{n+k} + x_{n+k+1} & = 0 \\
a_{k+1,1}x_1 + \cdots + a_{k+1,n}x_n & & = b_{k+1} \\
\vdots & \vdots & \vdots \\
a_{m1}x_1 + \cdots + a_{mn}x_n & & = b_m \\
c_1x_1 + \cdots + c_nx_n & & + x_{n+k+2} = 0 \\
x_i \geq 0 \text{ für } i \in I \cup \{n+1, \dots, n+k+1\}.
\end{array}$$

4.12 Exkurs: Eliminationsverfahren für dünn besetzte Matrizen

Bei vielen praktischen Anwendungen stößt man auf lineare Gleichungssysteme $Ax = b$, deren Matrix $A = (a_{ik})_{i,k=1,\dots,n}$ zwar sehr groß, aber nur dünn besetzt ist: nur ein kleiner Bruchteil der Komponenten a_{ik} von A ist von 0 verschieden. Auf solche Probleme führt z. B. die Lösung von partiellen Differentialgleichungen mit Hilfe von Diskretisierungsverfahren (s. Abschnitte 7.4, 7.5, 8.4), Netzwerkprobleme und die Strukturplanung in den Ingenieurwissenschaften. Dünn besetzte lineare Gleichungen werden häufig iterativ gelöst (s. Kapitel 8), insbesondere wenn sie von partiellen Differentialgleichungen herrühren. In diesem Abschnitt behandeln wir nur Eliminationsverfahren, speziell das Cholesky-Verfahren (s. 4.3) zur Lösung linearer Systeme mit positiv definiter Matrix A und erklären in diesem Zusammenhang einige elementare Techniken, die dünne Struktur zu berücksichtigen. Für weitergehende Resultate sei auf die Literatur verwiesen, z. B. Reid (1971), Rose und Willoughby (1972), Tewarson (1973), Barker (1974). Eine systematische Behandlung positiv definiter Systeme findet man in George und Liu (1981), und von allgemeinen linearen Systemen in Duff, Erisman und Reid (1986).

Wir erläutern zunächst einige allgemeine Techniken zur Speicherung dünner Matrizen anhand der Matrix

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 & -2 \\ 3 & 0 & 2 & 0 & 1 \\ 0 & -4 & 0 & 7 & 0 \\ 0 & -5 & 0 & 0 & 0 \\ 0 & -6 & 0 & 0 & 6 \end{bmatrix}$$

Bei einer Art der zeilenweisen Speicherung benötigt man 3 Vektoren, etwa a , ja , ip . Die Komponenten $a[k]$, $k = 1, 2, \dots$, geben die Werte der (möglicherweise) von 0 verschiedenen Elemente von A , $ja[k]$ gibt den Spaltenindex der in $a[k]$ gespeicherten Matrixkomponente. Der Vektor ip enthält *Zeiger*: Falls $ip[i] = p$ und $ip[i+1] = q (\geq p)$, dann beginnen die von 0 verschiedenen Elemente der i -ten Zeile

von A mit $a[p]$ und enden mit $a[q - 1]$. Falls $ip[i] = ip[i + 1]$, ist die i -te Zeile von A gleich Null. Die angegebene Matrix kann deshalb so gespeichert werden:

$i =$	1	2	3	4	5	6	7	8	9	10	11
$ip[i] =$	1	3	6	8	9	11					
$ja[i] =$	5	1	1	3	5	4	2	2	2	5	
$a[i] =$	-2	1	3	2	1	7	-4	-5	-6	6	

Das Ende der Matrix wird durch $ip[6] = 11$ angezeigt.

Natürlich sind für symmetrische Matrizen weitere Einsparungen möglich, man hat hier nur die Elemente $a_{ik} \neq 0$ mit $i \geq k$ zu speichern.

Bei dieser Art der Speicherung ist es schwierig, zusätzliche Komponenten $\neq 0$ in den einzelnen Zeilen unterzubringen, die etwa bei der Durchführung von Eliminationsverfahren erzeugt werden. Dieser Nachteil wird vermieden, wenn man die Zeilen von A in der Form *verketteter Listen* speichert. Hier wird ein weiterer Vektor *next* benötigt, der angibt, an welcher Position von a man das nächste Element der jeweiligen Liste findet: Falls $a[k]$ ein Element der i -ten Zeile von A enthält, findet man das „nächste“ Element $\neq 0$ der i -ten Zeile in $a[next[k]]$, falls $next[k] \neq 0$. Falls $next[k] = 0$, war $a[k]$ das „letzte“ Element $\neq 0$ von Zeile i .

Die obige Matrix könnte man dann so speichern:

$i =$	1	2	3	4	5	6	7	8	9	10
$ip[i] =$	6	4	5	10	9					
$ja[i] =$	2	3	5	1	4	1	5	5	2	2
$a[i] =$	-4	2	-2	3	7	1	1	6	-6	-5
$next[i] =$	0	7	0	2	1	3	0	0	8	0

Es ist hier leicht, ein neues Element, zum Beispiel a_{31} unterzubringen: Man verlängere a , ja und $next$ um eine Komponente $a[11]$, $ja[11]$, $next[11]$ und setze etwa $a[11] := a_{31}$, $ip[3] := 11$, $ja[11] := 1$ und $next[11] := ip[3](= 5)$. Andererseits enthält der Vektor ip jetzt keine Informationen mehr über die Anzahl der von 0 verschiedenen Elemente einer Zeile von A .

Speichertechniken dieser oder ähnlicher Art sind auch für die Durchführung von Iterationsverfahren (s. Kapitel 8) zur Lösung von großen linearen Gleichungssystemen nötig. Bei der Anwendung von Eliminationsverfahren treten aber neue typische Schwierigkeiten auf, wenn man den Speicherplatz (die Datenstruktur) für A auch zur Speicherung der Faktoren der Dreieckszerlegung von A (s. 4.1, 4.3) verwenden will, weil diese Faktoren sehr viel mehr Elemente $\neq 0$ besitzen können. Insbesondere hängt die Anzahl der zusätzlichen von Null verschiedenen Elemente (die

„Auffüllung“, „fill-in“ von A), die während der Elimination erzeugt werden, sehr empfindlich von der Wahl der Pivotelemente ab. Eine schlechte Pivotwahl kann also nicht nur zu numerischen Instabilitäten führen (s. 4.5), sie kann auch die dünne Struktur von A zerstören. Es ist deshalb wichtig, die Pivots so zu wählen, daß zusätzlich zur numerischen Stabilität auch garantiert wird, daß sich die Auffüllung von A in Grenzen hält. Im Fall des Cholesky-Verfahrens für positiv definite Matrizen A (s. 4.3) ist die Situation einfacher, weil hier keine Pivotwahl nötig ist, um die numerische Stabilität zu garantieren. So kann man ohne Verlust an numerischer Stabilität (s. (4.3.6)) die Diagonalelemente statt in ihrer natürlichen Reihenfolge in einer beliebigen Reihenfolge als Pivots wählen. Man kann deshalb diese Reihenfolge so wählen, daß die Auffüllung von A während des Eliminationsverfahrens minimiert wird. Dies läuft auf die Wahl einer Permutation P hinaus, für die der Choleskyfaktor L der permutierten Matrix $PAP^T = LL^T$ möglichst dünn besetzt ist.

Daß die Wahl von P einen großen Einfluß auf den Besetzungsgrad der unteren Dreiecksmatrix L hat, zeigt das folgende drastische Beispiel (x bedeuten Elemente $\neq 0$, die Diagonalelemente sind durchnummeriert, um ihre Anordnung bei einer Permutation anzugeben). Der Choleskyfaktor L einer positiv definiten Matrix

$$A = \begin{bmatrix} 1 & x & x & x & x \\ x & 2 & & & \\ x & & 3 & & \\ x & & & 4 & \\ x & & & & 5 \end{bmatrix} = LL^T, \quad L = \begin{bmatrix} x & & & & \\ x & x & & & \\ x & x & x & & \\ x & x & x & x & \\ x & x & x & x & x \end{bmatrix}$$

ist i.a. voll besetzt, während die permutierte Matrix

$$PAP^T = \begin{bmatrix} 5 & & & x \\ & 2 & & x \\ & & 3 & x \\ & & & 4 & x \\ x & x & x & x & 1 \end{bmatrix} = LL^T, \quad L = \begin{bmatrix} x & & & & \\ & x & & & \\ & & x & & \\ & & & x & \\ x & x & x & x & x \end{bmatrix}$$

die durch Vertauschen der ersten und letzten Zeile und der ersten und letzten Spalte von A entsteht, eine dünn besetzte Matrix L als Choleskyfaktor besitzt.

Effiziente Eliminationsverfahren zur Lösung von dünn besetzten positiv definiten Systemen bestehen daher aus drei Teilen:

- 1) *Wahl der Permutation P , für die der Speicherbedarf für den Choleskyfaktor L von $PAP^T = LL^T$ möglichst klein wird, und Bestimmung der Struktur von L (welche Komponenten von L können $\neq 0$ sein).*
- 2) *Numerische Berechnung von L .*
- 3) *Bestimmung der Lösung x von $Ax = b$, d.h. von $(PAP^T)Px = LL^T Px = Pb$ durch Lösung der gestaffelten Gleichungssysteme $Lz = Pb$, $L^T u = z$, $x = P^T u$.*

In Schritt 1 wird lediglich die Struktur von A , d. h. nur die Indexmenge

$$\text{Nonz}(A) := \{(i, j) \mid j < i \text{ und } a_{ij} \neq 0\}$$

verwandt, um $\text{Nonz}(L)$ zu bestimmen, nicht dagegen die numerischen Werte der Komponenten von L : In diesem Schritt wird die Matrix PAP^T „symbolisch faktorisiert“, während sie in Schritt 2) „numerisch faktorisiert“ wird.

Es ist zweckmäßig, die Struktur einer symmetrischen $(n \times n)$ -Matrix A , d. h. die Menge $\text{Nonz}(A)$, mit Hilfe eines *ungerichteten Graphen* $G^A = (V^A, E^A)$ mit einer endlichen Menge $V^A = \{v_1, v_2, \dots, v_n\}$ von Knoten und einer endlichen Menge


$$E^A = \{\{v_i, v_j\} \mid (i, j) \in \text{Nonz}(A)\}$$

von „ungerichteten Kanten“ $\{v_i, v_j\}$ zwischen den Knoten v_i und $v_j \neq v_i$ zu beschreiben (Eine Kante ist deshalb eine zweielementige Teilmenge von V^A): der Spalte i , d. h. auch dem Diagonalelement a_{ii} von A , ist der Knoten v_i zugeordnet, und die Knoten $v_i \neq v_j$ werden durch eine ungerichtete Kante in G^A genau dann verbunden, wenn $a_{ij} \neq 0$.

Beispiel 1: Zur Matrix

$$\begin{bmatrix} 1 & x & & & & & \\ x & 2 & & & & & \\ & & 3 & & x & x & \\ x & & & 4 & x & & \\ & & x & x & 5 & & x \\ & & x & & & 6 & x \\ & & & & x & x & 7 \end{bmatrix}$$

gehört der Graph G_A



Wir führen einige Begriffe aus der Graphentheorie ein: Ist $G = (V, E)$ ein ungerichteter Graph und $S \subset V$ eine Teilmenge seiner Knoten, so bezeichnet $\text{Adj}_G(S)$ oder kürzer

$$\text{Adj}(S) := \{v \in V \setminus S \mid \{s, v\} \in E \text{ für ein } s \in S\}$$

die Menge aller Knoten $v \in V \setminus S$, die mit einem Knoten aus S durch eine Kante verbunden sind. Die Anzahl $\deg v := |\text{Adj}(\{v\})|$ der Nachbarn eines Knoten $v \in V$ heißt *Grad* von v . Schließlich heißt eine Teilmenge $M \subset V$ der Knoten von G eine *Clique* in G , falls jeder Knoten $x \in M$ mit jedem anderen Knoten $y \in M$ durch eine Kante verbunden ist.

Wir kehren wieder zu Eliminationsverfahren zurück. Als erstes versuchen wir eine Permutationsmatrix P so zu bestimmen, daß die Anzahl der von 0 verschiedenen Elemente des Choleskyfaktors L von $PAP^T = LL^T$ möglichst klein wird. Leider läßt sich ein optimales P nur mit sehr hohem Aufwand berechnen, aber es gibt ein relativ einfaches heuristisches Verfahren, um den Speicheraufwand für L näherungsweise zu minimieren, den *Minimalgradalgorithmus* von Rose (1972). Seine Grundidee ist es, im Choleskyverfahren unter den in Betracht kommenden Diagonalelementen das nächste Pivotelement so auszuwählen, daß voraussichtlich im anstehenden Eliminationsschritt möglichst wenige 0-Elemente zerstört werden.

Wir analysieren dazu nur den ersten Schritt des Choleskyverfahrens, in dem die erste Spalte des Choleskyfaktors L von $A = LL^T$ berechnet wird: Dieser Schritt ist typisch für den allgemeinen Fall. Partitioniert man die $n \times n$ -Matrizen A und L in der folgenden Form

$$\begin{bmatrix} d & a^T \\ a & \tilde{A} \end{bmatrix} = \begin{bmatrix} \alpha & 0 \\ l & \bar{L} \end{bmatrix} \cdot \begin{bmatrix} \alpha & l^T \\ 0 & \bar{L}^T \end{bmatrix} = LL^T, \quad a^T = (a_2, a_3, \dots, a_n),$$

wobei $d = a_{11}$ und (d, a^T) die erste Zeile von A ist, so findet man folgende Formeln

$$\alpha = \sqrt{d}, \quad l = a/\sqrt{d}, \quad \bar{L}\bar{L}^T = \bar{A} := \tilde{A} - ll^T,$$

d. h. die erste Spalte L_1 von L (bzw. die erste Zeile L_1^T von L^T) ist gegeben durch

$$L_1 = \begin{pmatrix} \sqrt{d} \\ a/\sqrt{d} \end{pmatrix},$$

und die Bestimmung der restlichen Spalten von L , also der Spalten von $\bar{L}$, läuft auf die Choleskyzerlegung $\bar{A} = \bar{L}\bar{L}^T$ der $(n-1)$ -reihigen Matrix $\bar{A} = (\bar{a}_{ik})_{i,k=2}^n$ hinaus:

$$\bar{A} = \tilde{A} - ll^T = \tilde{A} - \frac{aa^T}{d} \quad (4.12.1)$$

$$\bar{a}_{ik} = a_{ik} - \frac{a_i a_k}{d} \quad \text{für alle } i, k \geq 2.$$

Wenn wir von dem Entartungsfall absehen, daß die numerischen Werte von $a_{ik} \neq 0$ und $a_i a_k = a_{1i} a_{1k} \neq 0$ gerade so beschaffen sind, daß sich $\bar{a}_{ik} = 0$ ergibt, gilt für die Komponenten von $\bar{A}$

$$(4.12.2) \quad \bar{a}_{ik} \neq 0 \iff a_{ik} \neq 0 \quad \text{oder} \quad a_{1i} a_{1k} \neq 0.$$


Also wird der Eliminationsschritt mit Pivot $d = a_{11}$ eine Zahl von neuen Elementen $\neq 0$ erzeugen, die ungefähr proportional der Anzahl der von Null verschiedenen Elemente des Vektors $a^T = (a_2, \dots, a_n) = (a_{12}, \dots, a_{1n})$ ist.

Den Eliminationsschritt $A \rightarrow \bar{A}$ kann man anhand der Graphen $G = (V, E) := G_A$ und $\bar{G} = (\bar{V}, \bar{E}) := G^{\bar{A}}$ zu den Matrizen A und $\bar{A}$ beschreiben: Den Diagonalelementen von A ($\bar{A}$) entsprechen die Knoten $1, 2, \dots, n$ (bzw. $2, 3, \dots, n$) von $G = G^A$ (bzw. $G^{\bar{A}}$), zum Pivot a_{11} gehört der *Pivotknoten* 1 von G . (4.12.2) bedeutet, daß die Knoten $i \neq k, i, k \geq 2$, in $\bar{G}$ durch eine Kante genau dann verbunden werden, wenn sie schon in G verbunden sind ($a_{ik} \neq 0$) oder wenn beide Knoten i und k Nachbarn des Pivotknoten 1 in G sind ($a_{1i}a_{1k} \neq 0, i, k \in Adj_G(1)$). Die Anzahl der Elemente $a_{1i} \neq 0$ mit $i \geq 2$ in der ersten Zeile von A stimmt mit dem Grad $\deg_G(1)$ des Knotens 1 in G überein: die Wahl von $d = a_{11}$ als Pivot ist deshalb vermutlich dann günstig, wenn Knoten 1 unter allen Knoten von G den kleinsten Grad besitzt. Die Menge $Adj_G(1)$ der Nachbarn von Knoten 1 gibt im übrigen an, welche Elemente der ersten Zeile von L^T bzw. der ersten Spalte von L nicht verschwinden.

Beispiel 2: Die Wahl des Pivotelements a_{11} in der folgenden Matrix A führt zur Auffüllung von $\bar{A}$ an der Stelle $\otimes$:

$$A = \begin{bmatrix} 1 & x & & x & & \\ x & 2 & x & x & & x \\ & x & 3 & & & x \\ & x & & 4 & x & x \\ x & & & x & 5 & \\ & x & x & x & & 6 \end{bmatrix} \Rightarrow \bar{A} = \begin{bmatrix} 2 & x & x & \otimes & x \\ x & 3 & & & x \\ x & & 4 & x & x \\ \otimes & & x & 5 & \\ x & x & x & & 6 \end{bmatrix}.$$

Die zugehörigen Graphen sind:



Allgemein entspricht die Wahl eines Diagonalspivots in A der Wahl eines Knotens $x \in V$ (Pivotknoten) in dem Graphen $G = (V, E) = G^A$, und dem Eliminationsschritt $A \rightarrow \bar{A}$ mit diesem Pivot eine Transformation des Graphen $G (= G^A)$ in einen Graphen $\bar{G} = (\bar{V}, \bar{E}) (= G^{\bar{A}})$, den man auch mit G_x bezeichnet und der durch folgende Regeln gegeben ist:

- 1) $\bar{V} := V \setminus \{x\}$.
- 2) *Verbinde die Knoten $y \neq z, y, z \in \bar{V}$, genau dann durch eine ungerichtete Kante ($\{y, z\} \in \bar{E}$) in $\bar{G}$, wenn y und z schon in G durch eine Kante verbunden sind, oder falls y und z Nachbarn von x in G sind ($y, z \in Adj_G(x)$).*

Wir sagen dann, daß der Graph G_x durch „Elimination des Knotens x “ aus G entstanden ist.

Es gilt also in G_x für alle $y \in \bar{V} = V \setminus \{x\}$

(4.12.3)

$$Adj_{G_x}(y) = \begin{cases} Adj_G(y) & \text{falls } y \notin Adj_G(x) \\ (Adj_G(x) \cup Adj_G(y)) \setminus \{x, y\} & \text{sonst.} \end{cases}$$

Die Knoten aus $Adj_G(x)$ sind in G_x paarweise untereinander durch eine Kante verbunden, sie bilden eine Clique in G_x , die sog. *Pivotclique*; sie geben an, welche Nichtdiagonalelemente der Zeile von L^T bzw. Spalte von L , die dem Pivotknoten x entspricht, von 0 verschieden sein können.

Wir haben gesehen, daß in einem Eliminationsschritt wahrscheinlich nur wenig neue Elemente $\neq 0$ erzeugt werden, wenn der Grad des Pivotknotens klein ist. Dies motiviert den Minimalgradalgorithmus von Rose (1972) zur Bestimmung einer zweckmäßigen Pivotreihenfolge:

(4.12.4) **Minimalgradalgorithmus:** Sei A eine positiv definite $n \times n$ -Matrix.

0) Setze $G^0 = (V^0, E^0) := G^A$

Für $i = 1, 2, \dots, n$:

1) Bestimme einen Knoten $x_i \in V^{i-1}$ minimalen Grades in G^{i-1} .


2) Setze $G^i := G_{x_i}^{i-1}$.

Anmerkung: Die Knoten x_i minimalen Grades müssen nicht eindeutig bestimmt sein.

Beispiel 3: In dem Graphen $G =: G^0$ der Matrix A von Beispiel 2 besitzen die Knoten 1, 3 und 5 minimalen Grad. Wählt man den Knoten 1 als Pivotknoten x_1 , so erhält man als nächsten Graphen $G^1 := G_1^0 = \bar{G}$ den Graphen $\bar{G}$ von Beispiel 2. Zu dem Pivotknoten $x_1 = 1$ gehört die Pivotclique

$$Adj_{G^0}(1) = \{2, 5\}.$$

Setzt man das Verfahren (4.12.4) fort, so kann man als nächsten Pivotknoten x_2 den Knoten 5 wählen, der (neben dem Knoten 3) in $G^1 = \bar{G}$ minimalen Grad besitzt. Zu ihm gehört die Pivotclique $Adj_{G^1}(5) = \{2, 4\}$. Insgesamt liefert das Verfahren (1, 5, 4, 2, 3, 6) als eine mögliche Pivotreihenfolge und folgende Graphen ($G^0 := G$, $G^1 := \bar{G}$, s. Beispiel 2, und G^6 ist der leere Graph):



Die Pivotknoten sind markiert. Zu Ihnen gehören die folgenden Pivotcliquen:

Pivot	1	5	4	2	3	6
Clique	{2, 5}	{2, 4}	{2, 6}	{3, 6}	{6}	∅

Die entsprechend permutierte Matrix $PAP^T = LL^T$ und ihr Choleskyfaktor L haben die folgende Struktur, die sich aus den Pivotcliquen ergibt (die Stellen, an denen 0-Elemente von A bei der Elimination zerstört werden, sind wieder mit $\otimes$ bezeichnet):

$$PAP^T = \begin{bmatrix} 1 & x & & & & \\ x & 5 & x & & & \\ & x & 4 & x & & \\ x & & x & 2 & x & x \\ & & & x & 3 & x \\ & & x & x & x & 6 \end{bmatrix} = LL^T, \quad L^T = \begin{bmatrix} 1 & x & & & & \\ & 5 & x & \otimes & & \\ & & 4 & x & & x \\ & & & 2 & x & x \\ & & & & 3 & x \\ & & & & & 6 \end{bmatrix}.$$

Zum Beispiel sind die von Null verschiedenen Nichtdiagonalelemente der dritten Zeile von L^T , die zum Pivotknoten $x_3 = 4$ gehört, durch die Pivotclique $\{2, 6\} = Adj_{G^2}(4)$ dieses Knotens gegeben.

Für die praktische Durchführung von (4.12.4) für große Probleme kommt es darauf an, wie man die ebenfalls großen Eliminationsgraphen G^i darstellt und wie schnell man die Gradfunktion deg_{G^i} der Graphen $G^i = G_{x_i}^{i-1}$, $i = 1, 2, \dots, n-1$, berechnen kann. Zum Beispiel wird man ausnutzen, daß wegen (4.12.3)

$$Adj_{G_x}(y) = Adj_G(y), \quad deg_{G_x}(y) = deg_G(y)$$

für alle Knoten $y \neq x$ mit $y \notin Adj_G(x)$ gilt.

Dazu gibt es verschiedene Vorschläge in der Literatur (s. z. B. George und Liu (1989)). Als zweckmäßig hat sich die Beschreibung eines Graphen $G = (V, E)$ durch eine endliche Menge $M = \{K_1, K_2, \dots, K_q\}$ von Cliquen von G erwiesen, die hinreichend groß ist, daß jede Kante in mindestens einer Clique $K_i \in M$ enthalten ist. Dann kann man die Kantenmenge E von G aus M wiedergewinnen:

$$E = \{\{x, y\} \mid x \neq y \text{ und } \exists i : x, y \in K_i\}.$$

Man nennt dann M eine *Cliquenbeschreibung* von G . Eine solche Beschreibung läßt sich immer finden, z. B. $M = E$, denn jede Kante $\{x, y\} \in E$ ist eine Clique von G .

Beispiel 4: Eine Cliquenbeschreibung des Graphen $G = G^A$ aus Beispiel 2 ist z. B.

$$\{\{1, 5\}, \{4, 5\}, \{1, 2\}, \{2, 3, 6\}, \{2, 4, 6\}\}.$$

Der Grad $\deg_G(x)$ und die Mengen $\text{Adj}_G(x)$, $x \in V$, sind durch eine Cliquesbeschreibung M bestimmt

$$\text{Adj}_G(x) = \bigcup_{i: x \in K_i} K_i \setminus \{x\}, \quad \deg_G(x) = |\text{Adj}_G(x)|.$$

Zu gegebenem $x \in V$ kann man wegen (4.12.3) eine Cliquesbeschreibung des Graphen G_x aus einer Cliquesbeschreibung $M = \{K_1, \dots, K_q\}$ von $G = (V, E)$ wie folgt gewinnen: Sei $\{K_{s_1}, \dots, K_{s_t}\}$ die Menge aller Cliques aus M , die x enthalten, sowie $K := \bigcup_{i=1}^t K_{s_i} \setminus \{x\}$. Dann ist

$$M_x = \{K_1, \dots, K_q, K\} \setminus \{K_{s_1}, \dots, K_{s_t}\}$$

eine Cliquesbeschreibung von G_x .

Nimmt man an, daß die Cliques als Listen ihrer Elemente gespeichert werden, benötigt man zur Speicherung von M_x wegen $|K| < \sum_{j=1}^t |K_{s_j}|$ weniger Platz als für M .

Der weitere Ablauf ist nun der folgende: Nachdem man mit Hilfe von (4.12.4) eine geeignete Pivotsequenz und damit eine Permutation P und die Besetzungsstruktur $\text{Nonz}(L)$ des Choleskyfaktors L von $PAP^T = LL^T$ bestimmt hat, kann man eine Datenstruktur zur Speicherung von L aufbauen. Z. B. kann man wie eingangs beschrieben die Elemente $\neq 0$ von L^T zeilenweise (dies entspricht einer spaltenweisen Speicherung von L) (ggf. mittels verketteter Listen) mit Hilfe von 3 (bzw. 4) linearen arrays ip , ja , a (*next*) speichern.

Die Diagonalelemente von L , die ohnehin bei Eliminationsverfahren eine Sonderrolle spielen, speichert man separat in einem weiteren array $diag$ ab, $diag[i] = l_{ii}$, $i = 1, \dots, n$.

Wegen $\text{Nonz}(L) \supset \text{Nonz}(PAP^T)$ kann man diese Datenstruktur für L^T zunächst für die zeilenweise Speicherung von A verwenden und die arrays a , $diag$ entsprechend besetzen.

Als nächstes folgt die *numerische Faktorisierung* von $PAP^T = LL^T$. Hier ist es wichtig, die Berechnung von L^T zeilenweise vorzunehmen, d. h. den array a schrittweise durch die entsprechenden Zeilen von L^T zu überschreiben. Außerdem lassen sich die Programme zur Auflösung der gestaffelten Gleichungssysteme

$$Lz = Pb, \quad L^T u = z$$

nach z bzw. u ebenfalls so schreiben, daß die Matrix L^T unter Berücksichtigung der angegebenen Datenstruktur zeilenweise aufgerufen wird, und zwar jede Zeile genau einmal bei der Berechnung von z und ein zweites Mal bei der Berechnung von u . Die Lösung x von $Ax = b$ erhält man schließlich als $x = P^T u$.

Bezüglich weiterer Einzelheiten zur Lösung von Gleichungssystemen mit dünn besetzten Matrizen sei auf einschlägige Lehrbücher verwiesen, z. B. Duff, Erisman und Reid (1986), George und Liu (1981), wo man auch zahlreiche FORTRAN-Programme findet. Große Programmpakete sind das Harwell-Paket MA27 (s. Duff und Reid (1982)), YSMP (Yale sparse matrix package, s. Eisenstat et al. (1982)) und SPARSEPAK (s. George, Liu und Ng (1980)).

Übungsaufgaben zu Kapitel 4

1. Gegeben seien folgende Vektornormen in $\mathbb{C}^n$ bzw. $\mathbb{R}^n$.

$$\|x\|_{\infty} := \max_{1 \leq i \leq n} |x_i|;$$

$$\|x\|_2 := \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2};$$

$$\|x\|_1 := \sum_{i=1}^n |x_i|.$$

Man zeige für sie

- die Normeigenschaften;
- $\|x\|_{\infty} \leq \|x\|_2 \leq \|x\|_1$;
- $\|x\|_2 \leq \sqrt{n} \|x\|_{\infty}$, $\|x\|_1 \leq \sqrt{n} \|x\|_2$
Ist in b), c) die Gleichheit möglich?
- Man bestimme $\text{lub}(A)$ bezüglich der Norm $\|\cdot\|_1$.
- Ausgehend von der Definition von

$$\text{lub}(A) = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}$$

zeige man für nichtsinguläres A :

$$\frac{1}{\text{lub}(A^{-1})} = \min_{y \neq 0} \frac{\|Ay\|}{\|y\|}.$$

2. Man betrachte die Klasse der Normen in $\mathbb{C}^n$

$$\|x\|_D := \|Dx\|,$$

wobei $\|\cdot\|$ eine feste Vektornorm ist und D die Klasse der nichtsingulären Matrizen durchläuft.

Man zeige:

- $\|\cdot\|_D$ ist eine Norm.
- Es gilt:

$$m\|x\| \leq \|x\|_D \leq M\|x\|$$

mit

$$m = 1/\text{lub}(D^{-1}), \quad M = \text{lub}(D),$$

wobei $\text{lub}(D)$ bzgl. der Norm $\|\cdot\|$ zu nehmen ist.

- c) Man drücke $\text{lub}_D(A)$ mit Hilfe der zu $\|\cdot\|$ gehörigen lub -Norm aus.
 d) Für eine nichtsinguläre Matrix A ist $\text{cond}(A)$ von der Wahl der zugrundeliegenden Vektornorm abhängig. Man zeige, daß $\text{cond}_D(A)$ zur Vektornorm $\|\cdot\|_D$ bei geeigneter Wahl von D beliebig groß werden kann. Man gebe eine Abschätzung mit Hilfe von m, M .
 e) Wie stark unterscheiden sich höchstens $\text{cond}(A)$ bezüglich $\|\cdot\|_\infty$ und $\|\cdot\|_2$. (Man benutze die Ergebnisse von Aufgabe 1.b)–c)).
 3. Man zeige für eine nichtsinguläre $n \times n$ -Matrix A und Vektoren $u, v \in \mathbb{R}^n$:
 a) Ist $v^T A^{-1} u \neq -1$, so gilt

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^T A^{-1}}{1 + v^T A^{-1}u}.$$

- b) Ist $v^T A^{-1} u = -1$, so ist $(A + uv^T)$ singulär.
 (Hinweis: Man finde einen Vektor $z \neq 0$ mit $(A + uv^T)z = 0$)
 4. $A = (a_1, \dots, a_n)$ sei eine nichtsinguläre $n \times n$ -Matrix mit den Spalten a_i .
 a) $\tilde{A} = (a_1, \dots, a_{i-1}, b, a_{i+1}, \dots, a_n)$, $b \in \mathbb{R}^n$ sei die Matrix in der die i -te Spalte a_i durch b ersetzt wird.
 Man untersuche mit Hilfe der Formel aus Aufgabe 3.a) unter welchen Bedingungen $\tilde{A}^{-1}$ existiert und zeige, daß dann $\tilde{A}^{-1} = F A^{-1}$ gilt, wobei F eine Frobeniusmatrix ist.
 b) $A = (a_{ik})$ sei eine nichtsinguläre $n \times n$ -Matrix, A_α entstehe aus A dadurch, daß ein einziges Element a_{ik} zu $a_{ik} + \alpha$ abgeändert wird. Für welche α existiert A_α^{-1} ?
 5. Für diese Aufgabe benutze man folgenden Satz [vgl. (6.4.10)]:
A sei eine reelle, nichtsinguläre $n \times n$ -Matrix, dann gibt es zwei reelle, orthogonale Matrizen U, V , so daß

$$U^T A V = D$$

gilt, wobei $D = \text{diag}(\mu_1, \dots, \mu_n)$ und

$$\mu_1 \geq \mu_2 \geq \dots \geq \mu_n > 0.$$

Ferner sei $\|\cdot\|$ die euklidische Norm.

- a) Drücke $\text{cond}(A)$ durch die μ_i aus.
 b) Man gebe mit Hilfe von U diejenigen Vektoren b bzw. Δb an, die in den Abschätzungen (4.4.11), (4.4.12) und

$$\|b\| \leq \text{lub}(A)\|x\|$$

Gleichheit ergeben.

- c) Gibt es ein b , so daß für alle Δb in (4.4.12) gilt:

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\|\Delta b\|}{\|b\|} ?$$

Man bestimme solche Vektoren b mit Hilfe von U . (Man betrachte Vektoren b mit $\text{lub}(A^{-1})\|b\| = \|x\|$.)

6. Gegeben sei das Gleichungssystem $Ax = b$ mit

$$A = \begin{bmatrix} 0.780 & 0.563 \\ 0.913 & 0.659 \end{bmatrix} \text{ und } b = \begin{bmatrix} 0.217 \\ 0.254 \end{bmatrix}.$$

Die exakte Lösung ist $x^T = (1, -1)$. Gegeben seien die beiden Näherungslösungen

$$x_1^T = (0.999, -1.001)$$

$$x_2^T = (0.341, -0.087);$$

- Man berechne die Residuen $r(x_1)$, $r(x_2)$. Hat die genauere Lösung x_1 das kleinere Residuum?
 - Man bestimme die exakte Inverse A^{-1} und berechne $\text{cond}(A)$ bezüglich der Maximumnorm.
 - Man drücke $\tilde{x} - x = \Delta x$ mit Hilfe von $r(\tilde{x})$ aus, dem Residuum zu $\tilde{x}$. Gibt es eine Erklärung der Diskrepanz, die in a) festgestellt wurde (vergleiche Aufgabe 5)?
7. Man zeige:
- die betragsgrößten Elemente einer positiv definiten Matrix treten in der Diagonale auf und sind positiv.
 - Sind alle führenden Hauptminoren einer hermiteschen $n \times n$ -Matrix $A = (a_{ik})$ positiv, d. h. gilt

$$\det \left(\begin{bmatrix} a_{11} & \dots & a_{1i} \\ \vdots & & \vdots \\ a_{i1} & \dots & a_{ii} \end{bmatrix} \right) > 0 \text{ für } i = 1, \dots, n,$$

so ist A positiv definit.

(Hinweis: S. den Induktionsbeweis zu Satz (4.3.3).)

8. Gegeben sei die reelle, positiv definite $n \times n$ -Matrix A' , die in folgender Weise partitioniert sei:

$$A' = \begin{bmatrix} A & B \\ B^T & C \end{bmatrix},$$

wobei A eine $m \times m$ Matrix ist.

Man zeige zunächst:

- $C - B^T A^{-1} B$ ist positiv definit.

[Hinweis: Man partitioniere x entsprechend,

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad x_1 \in \mathbb{R}^m, \quad x_2 \in \mathbb{R}^{n-m},$$

und bestimme bei festem x_2 ein geeignetes x_1 mit

$$x^T A' x = x_2^T (C - B^T A^{-1} B) x_2.]$$

Nach Satz (4.3.3) gibt es für A' eine Zerlegung

$$A' = R^T R,$$

wobei R eine obere Dreiecksmatrix ist, die zu A' entsprechend partitioniert sei,

$$R = \begin{bmatrix} R_{11} & R_{12} \\ 0 & R_{22} \end{bmatrix}.$$

Man zeige weiter:

- b) Jede Matrix $M = N^T N$, wobei N eine nichtsinguläre Matrix ist, ist positiv definit.
 c) $R_{22}^T R_{22} = C - B^T A^{-1} B$.
 d) Aus a) ergibt sich die Schlußfolgerung

$$r_{ii}^2 > 0, \quad i = 1, \dots, n,$$

wobei r_{ii} ein beliebiges Diagonalelement von R ist.

- e) Für $\text{lub}(R^{-1})$ bezüglich der euklidischen Norm gilt

$$r_{ii}^2 \geq \min_{x \neq 0} \frac{x^T A' x}{x^T x} = \frac{1}{\text{lub}(R^{-1})^2}$$

für $i = 1, \dots, n$.

(Hinweis: Aufgabe 1e)).

- f) Bezüglich der euklidischen Norm gilt

$$\text{lub}(R)^2 = \max_{x \neq 0} \frac{x^T A' x}{x^T x} \geq r_{ii}^2 \quad \text{für } i = 1, \dots, n.$$

- g) Es gilt

$$\text{cond}(R) \geq \max_{1 \leq i, k \leq n} \left| \frac{r_{ii}}{r_{kk}} \right|.$$

9. Eine Folge A_n komplexer oder reeller $r \times r$ -Matrizen konvergiert genau dann komponentenweise gegen eine Matrix A , wenn die A_n eine Cauchyfolge bilden, d. h., wenn für eine beliebige Vektornorm $\|\cdot\|$ und beliebiges $\varepsilon > 0$ gilt: $\text{lub}(A_n - A_m) < \varepsilon$ für genügend großes n und m .

Man zeige: Ist $\text{lub}(A) < 1$, so konvergieren die Folge A^n und die Reihe $\sum_{n=0}^{\infty} A^n$, $I - A$ ist nichtsingulär und es gilt

$$(I - A)^{-1} = \sum_{n=0}^{\infty} A^n.$$

Man benutze diese Beziehung, um (4.4.14) zu beweisen.

10. Die Inverse einer $n \times n$ -Matrix A soll mit der Gauß-Jordan-Methode und Teilpivotsuche gefunden werden.

Man zeige, daß die Spalten von A linear abhängig sind, wenn man bei der Teilpivotsuche (und rundungsfehlerfreier Rechnung) kein von Null verschiedenes Pivotelement findet.

11. Sei A eine positiv definite $n \times n$ -Matrix. Auf A werde das Gaußsche Eliminationsverfahren angewandt (ohne Pivotsuche). Nach k Eliminationen ist A auf die Form

$$A^{(k)} = \begin{bmatrix} A_{11}^{(k)} & A_{12}^{(k)} \\ 0 & A_{22}^{(k)} \end{bmatrix}$$

mit $A_{22}^{(k)}$ eine $(n - k) \times (n - k)$ Matrix, reduziert. Man zeige durch Induktion

- a) $A_{22}^{(k)}$ ist wieder positiv definit,
b) $a_{ii}^{(k)} \leq a_{ii}^{(k-1)}$ für $k \leq i \leq n, k = 1, 2, \dots, n-1$.
12. Bei der Fehleranalyse des Gaußschen Eliminationsverfahrens in 4.5 wurden Abschätzungen des Wachstums der maximalen Elemente der Matrizen $A^{(i)}$ verwendet.
Sei

$$a_i := \max_{r,s} |a_{rs}^{(i)}|, \quad A^{(i)} := (a_{rs}^{(i)}).$$

Man zeige, daß bei Teilpivotsuche gilt:

- a) $a_k \leq 2^k a_0, k = 1, \dots, n-1$ für beliebiges A .
b) $a_k \leq k a_0, k = 1, \dots, n-1$ für Hessenberg Matrizen A .
c) $a = \max_{1 \leq k \leq n-1} a_k \leq 2 a_0$ für Tridiagonalmatrizen A .
13. Folgende Zerlegung einer positiv definiten Matrix A

$$A = SDS^H,$$

wobei S eine untere Dreiecksmatrix mit $s_{ii} = 1$ und D eine Diagonalmatrix $D = \text{diag}(d_i)$ sind, ergibt eine Variante des Cholesky-Verfahrens.

Man zeige, daß

- a) eine solche Zerlegung möglich ist (Satz 4.3.3),
b) $d_i = (l_{ii})^2$, wobei $A = LL^H, L$ eine untere Dreiecksmatrix ist,
c) gegenüber dem Cholesky-Verfahren (4.3.4) die Berechnung der n Quadratwurzeln eingespart wird.
14. Es liege folgendes mathematische Modell vor

$$y = x_1 z + x_2,$$

mit zwei unbekannten Parametern x_1, x_2 . Ferner sei ein Satz von Meßdaten gegeben:

$$\{y_l, z_l\}_{l=1, \dots, m} \text{ mit } z_l = l.$$

Man versuche mittels linearer Ausgleichsrechnung die Parameter x_1, x_2 aus den Meßdaten zu bestimmen.

- a) Wie lautet die Normalgleichung für das lineare Ausgleichsproblem?
b) Man führe die Choleskyzerlegung der Matrix der Normalgleichung $B = A^T A = LL^T$ durch.
c) Man gebe eine Abschätzung für $\text{cond}(L)$ bezüglich der euklidischen Norm. (Hinweis: Man benutze die Abschätzung für $\text{cond}(L)$ aus Aufgabe 8g.)
d) Wie steigt die Kondition mit der Anzahl der Meßpunkte m an? (Siehe Schwarz, Rutishauser, Stiefel (1968).)
15. Zu den Meßwerten

$$\begin{array}{c|cccccc} x_i & -2 & -1 & 0 & 1 & 2 \\ \hline y_i & 0.5 & 0.5 & 2 & 3.5 & 3.5 \end{array}$$

soll eine Gerade

$$y(x) = \alpha + \beta x$$

so bestimmt werden, daß

$$\sum_i [y(x_i) - y_i]^2$$

minimal wird. Man bestimme die optimalen Parameter α und β .

Literatur zu Kapitel 4

- Andersen, E., Bai, Z., Bischof, C., Demmel, J., Dongarra, J.J., DuCroz, J., Greenbaum, A., Hammarling, S., McKenney, A., Ostrouchov, A., Sorensen, D. (1992): *LAPACK users guide*. Philadelphia: SIAM Publications.
- Barker, V.A. (Ed.) (1977): *Sparse matrix techniques*. Lecture Notes in Mathematics 572. Berlin-Heidelberg-New York: Springer.
- Bartels, R.H. (1971): A stabilization of the simplex method. *Numer. Math.* **16**, 414-434.
- Bauer, F.L. (1966): Genauigkeitsfragen bei der Lösung linearer Gleichungssysteme. *ZAMM* **46**, 409-421.
- Bixby, R.E. (1990): Implementing the simplex method: The initial basis. Techn. Rep. TR 90-32, Department of Mathematical Sciences, Rice University, Houston, Texas.
- Björck, Å. (1990): Least squares methods. In: Ciarlet, Lions, Eds. (1990), 465-647.
- Businger, P., Golub, G.H. (1965): Linear least squares solutions by Householder transformations. *Numer. Math.* **7**, 269-276.
- Ciarlet, P.G., Lions, J.L. (Ed.) (1990): *Handbook of numerical analysis*, Vol. 1. Finite difference methods (Part 1), Solution of equations in $\mathbb{R}^n$ (Part 1). Amsterdam: North Holland.
- Collatz, L. (1968): Funktionalanalysis und numerische Mathematik. Die Grundlehren der mathematischen Wissenschaften in Einzeldarstellungen, Bd. 120. Berlin-Heidelberg-New York: Springer.
- Daniel, J.W., Gragg, W.B., Kaufmann, L., Stewart, G.W. (1976): Reorthogonalization and stable algorithms for updating the Gram-Schmidt *QR* factorization. *Math. Comp.* **30**, 772-795.
- Dantzig, G.B. (1963): *Linear programming and extensions*. Princeton, N.J.: Princeton University Press.
- Dongarra, J.J., Bunch, J.R., Moler, C.B., Stewart, G.W. (1979): *LINPACK users guide*. Philadelphia: SIAM Publications.
- Duff, I.S., Erisman, A.M., Reid, J.K. (1986): *Direct methods for sparse matrices*. Oxford: Oxford University Press.
- , Reid, J.K. (1982): MA27: A set of FORTRAN subroutines for solving sparse symmetric sets of linear equations. Techn. Rep. AERE R 10533, Harwell, U.K.
- Eisenstat, S.C., Gursky, M.C., Schultz, M.H., Sherman, A.H. (1982): The Yale sparse matrix package. I. The symmetric codes. *Internat. J. Numer. Methods Engrg.* **18**, 1145-1151.
- Forsythe, G.E., Moler, C.B. (1967): *Computer solution of linear algebraic systems*. Series in automatic computation. Englewood Cliffs, N.J.: Prentice-Hall.
- Gass, S.T. (1969): *Linear programming*. 3d edition. New York: McGraw-Hill.
- George, J.A., Liu, J.W. (1981): *Computer solution of large sparse positive definite systems*. Englewood Cliffs, N.J.: Prentice-Hall.
- , ——— (1989): The evolution of the minimum degree ordering algorithm. *SIAM Review* **31**, 1-19.
- , ———, Ng, E.G. (1980): Users guide for SPARSEPACK: Waterloo sparse linear equations package. Tech. Rep. CS-78-30, Dept. of Computer Science, University of Waterloo, Waterloo.

- Gill, P.E., Golub, G.H., Murray, W., Saunders, M.A. (1974): Methods for modifying matrix factorizations. *Math. Comp.* **28**, 505-535.
- Golub, G.H., van Loan, C.F. (1983): *Matrix computations*. Baltimore: The John Hopkins University Press.
- Grossmann, W. (1969): *Grundzüge der Ausgleichsrechnung*. 3. Aufl. Berlin-Heidelberg-New York: Springer.
- Guest, P.G. (1961): *Numerical methods of curve fitting*. Cambridge: University Press.
- Hadley, G. (1962): *Linear programming*. Reading, MA: Addison-Wesley.
- Householder, A.S. (1964): *The theory of matrices in numerical analysis*. New York: Blaisdell.
- Lawson, C.L., Hanson, H.J. (1974): *Solving least squares problems*. Englewood Cliffs, N.J.: Prentice-Hall.
- Murty, K.G. (1976): *Linear and combinatorial programming*. New York: Wiley.
- Prager, W., Oettli, W. (1964): Compatibility of approximate solution of linear equations with given error bounds for coefficients and right hand sides. *Num. Math.* **6**, 405-409.
- Reid, J.K. (Ed) (1971): *Large sparse sets of linear equations*. London, New York: Academic Press.
- Rose, D.J. (1972): A graph-theoretic study of the numerical solution of sparse positive definite systems of linear equations, pp. 183-217. In: *Graph theory and computing*, R.C. Read, ed., New York: Academic Press.
- , Willoughby, R.A. (Eds.) (1972): *Sparse matrices and their applications*. New York: Plenum Press.
- Sautter, W. (1971): Dissertation TU München.
- Schrijver, A. (1986): *Theory of linear and integer programming*. Wiley, Chichester.
- Schwarz, H.R., Rutishauser, H., Stiefel, E. (1968): *Numerik symmetrischer Matrizen*. Leitfäden der angewandten Mathematik, Bd. 11. Stuttgart: Teubner.
- Seber, G.A.F. (1977): *Linear regression analysis*. New York: Wiley.
- Stewart, G.W. (1973): *Introduction to matrix computations*. New York: Academic Press.
- Tewarson, R.P. (1973): *Sparse matrices*. New York: Academic Press.
- Wilkinson, J.H. (1965): *The algebraic eigenvalue problem*. Monographs on Numerical Analysis, Oxford: Clarendon Press.
- , Reinsch, Ch. (1971): *Linear algebra*. Handbook for Automatic Computation, Vol. II. Grundlehren der mathematischen Wissenschaften in Einzeldarstellungen, Bd. 186. Berlin-Heidelberg-New York: Springer.

5 Verfahren zur Nullstellenbestimmung. Minimierungsmethoden

Ein wichtiges Problem ist die Bestimmung der Nullstellen ξ einer gegebenen Funktion $f: f(\xi) = 0$. Man denke dabei nicht nur an das klassische Problem, die Nullstellen (Wurzeln) eines Polynoms

$$p(x) = a_0x^n + a_1x^{n-1} + \dots + a_n$$

zu finden. Je nach Definition der Funktion $f: E \rightarrow F$ und der Mengen E und F kann man sehr allgemeine Probleme als Nullstellenprobleme auffassen. Z. B. wird für $E = F = \mathbb{R}^n$ die Funktion f durch n reelle Funktionen $f_i(x^1, \dots, x^n)$ von n reellen Variablen $x^1, \dots, x^n$ beschrieben:⁹

$$f(x) = \begin{bmatrix} f_1(x^1, \dots, x^n) \\ \vdots \\ f_n(x^1, \dots, x^n) \end{bmatrix}, \quad x^T = (x^1, \dots, x^n).$$

Das Problem $f(x) = 0$ zu lösen bedeutet dann, eine Lösung des Systems von Gleichungen

$$(5.0.1) \quad f_i(x^1, \dots, x^n) = 0, \quad i = 1, \dots, n,$$

zu finden. Noch allgemeinere Probleme erhält man, wenn man als E und F unendlich dimensionale lineare Vektorräume wählt, etwa Räume von Funktionen.

Nullstellensprobleme sind eng verwandt mit *Minimierungsproblemen* des Typs:

$$(5.0.2) \quad \text{Bestimme } \min_{x \in \mathbb{R}^n} h(x)$$

für eine reelle Funktion h von n Variablen, $h(x) = h(x^1, x^2, \dots, x^n)$. Ist nämlich h differenzierbar und $g(x) := (\partial h / \partial x^1, \dots, \partial h / \partial x^n)^T$ der Gradient

⁹ Wir bezeichnen in diesem Abschnitt die Komponenten von Vektoren $x \in \mathbb{R}^n$, $n > 1$, mit oberen Indizes: x^k , $k = 1, 2, \dots, n$, und mit unteren Indizes x_i , $i = 1, 2, \dots$ einzelne Vektoren aus einer Menge oder Folge von Vektoren.

von h , so ist jedes Minimum $\bar{x}$ von $h(x)$ Nullstelle des Gradienten, $g(\bar{x}) = 0$. Umgekehrt ist jede Nullstelle ξ von $f(x) = 0$ auch Minimum einer Funktion h , etwa $h(x) := \|f(x)\|^2$.

(5.0.2) ist ein typisches Minimierungsproblem ohne Nebenbedingungen, allgemeiner sind Minimierungsprobleme mit Nebenbedingungen:

$$\text{Minimiere } h(x)$$

unter allen $x \in \mathbb{R}^n$ mit

$$h_i(x) \leq 0 \quad \text{für } i = 1, 2, \dots, m_1,$$

$$h_i(x) = 0 \quad \text{für } i = m_1 + 1, m_1 + 2, \dots, m.$$

Die Lösung von Minimierungsproblemen gehört zu den für die Praxis wichtigsten Aufgaben der Angewandten Mathematik. In diesem Rahmen behandeln wir nur Probleme ohne Nebenbedingungen. *Lineare Minimierungsprobleme*, bei denen alle Funktionen $h, h_i: \mathbb{R}^n \rightarrow \mathbb{R}$ lineare, genauer affine Funktionen sind, wurden bereits in den Abschnitten 4.10, 4.11 betrachtet.

Für eine eingehende Behandlung von Nullstellenproblemen sei auf die umfangreiche Spezialliteratur verwiesen, etwa Ortega, Rheinboldt (1970), Traub (1964), Henrici (1974), und für Optimierungsprobleme auf Luenberger (1973), Himmelblau (1972), Collatz, Wetterling (1971), Fletcher (1980/81), Spellucci (1993).

5.1 Entwicklung von Iterationsverfahren

Da man nur in den seltensten Fällen eine Nullstelle ξ einer Funktion $f: E \rightarrow F$, $f(\xi) = 0$, in endlich vielen Schritten explizit berechnen kann, ist man in der Regel auf Näherungsmethoden angewiesen. Diese Verfahren sind gewöhnlich Iterationsmethoden folgender Form: Ausgehend von einem „Startwert“ x_0 berechnet man weitere Näherungswerte x_i , $i = 1, 2, \dots$ für ξ mit Hilfe einer *Iterationsfunktion* $\Phi: E \rightarrow E$.

$$x_{i+1} := \Phi(x_i), \quad i = 0, 1, 2, \dots$$

Wenn ξ Fixpunkt von Φ ist, $\Phi(\xi) = \xi$, alle Fixpunkte von Φ auch Nullstellen von f sind und Φ (in einer Umgebung jedes Fixpunktes ξ) stetig ist, ist ein Limes ξ der Folge der x_i , $i = 0, 1, 2, \dots$, Fixpunkt von Φ und damit auch Nullstelle von f .

Es stellen sich in diesem Zusammenhang folgende Fragen:

1. Wie findet man passende Iterationsfunktionen Φ ?
2. Unter welchen Bedingungen konvergiert die Folge der x_i ?

3. Wie schnell konvergiert die Folge der x_i ?

Wir werden diese Frage nicht unter den allgemeinsten Voraussetzungen betrachten und uns auf den endlich dimensionalen Fall $E = F = \mathbb{R}^n$ beschränken.

Wir betrachten zunächst die Frage, wie man Iterationsfunktionen Φ gewinnen kann. Sehr häufig sind solche Funktionen bereits mit der Formulierung des Problems gegeben. Ist z. B. die Gleichung $x - \cos x = 0$ zu lösen, so liegt es nahe, die Iterationsvorschrift

$$x_{i+1} = \cos x_i, \quad i = 0, 1, 2, \dots,$$

zu verwenden, $\Phi(x) := \cos x$.

Auf systematischere Weise erhält man Iterationsfunktionen Φ folgendermaßen: Ist etwa ξ die Nullstelle einer Funktion $f : \mathbb{R} \rightarrow \mathbb{R}$ und ist f in einer Umgebung $U(\xi)$ genügend oft differenzierbar, so erhält man durch Taylorentwicklung von f um einen Punkt $x_0 \in U(\xi)$

$$\begin{aligned} f(\xi) = 0 &= f(x_0) + (\xi - x_0)f'(x_0) + \frac{(\xi - x_0)^2}{2!}f''(x_0) + \dots \\ &+ \frac{(\xi - x_0)^k}{k!}f^{(k)}(x_0 + \vartheta(\xi - x_0)), \quad 0 < \vartheta < 1. \end{aligned}$$

Durch Vernachlässigung höherer Potenzen $(\xi - x_0)^v$ erhält man Gleichungen, denen bei gegebenem x_0 die Nullstelle ξ näherungsweise genügt, etwa

$$(5.1.1) \quad 0 = f(x_0) + (\bar{\xi} - x_0)f'(x_0),$$

$$(5.1.2) \quad 0 = f(x_0) + (\bar{\bar{\xi}} - x_0)f'(x_0) + \frac{(\bar{\bar{\xi}} - x_0)^2}{2!}f''(x_0).$$

Ihre Lösungen

$$\bar{\xi} = x_0 - \frac{f(x_0)}{f'(x_0)},$$

bzw.

$$\bar{\bar{\xi}} = x_0 - \frac{f(x_0) \pm \sqrt{(f'(x_0))^2 - 2f(x_0)f''(x_0)}}{f''(x_0)}$$

sind im allgemeinen wieder nur Näherungswerte für ξ , zu denen man nach demselben Schema weitere Näherungswerte bestimmen kann. Man erhält so die Iterationsverfahren

(5.1.3)

$$x_{i+1} := \Phi(x_i), \quad \Phi(x) := x - \frac{f(x)}{f'(x)},$$

$$x_{i+1} := \Phi_{\pm}(x_i), \quad \Phi_{\pm}(x) := x - \frac{f'(x) \pm \sqrt{(f'(x))^2 - 2f(x)f''(x)}}{f''(x)}.$$

Das erste Verfahren ist das klassische *Newton-Raphson-Verfahren*, das zweite eine naheliegende Modifikation. Allgemein spricht man von einem Verfahren ν -ten Grades, wenn man die Taylorentwicklung von f nach dem Glied $(\xi - x_0)^\nu$ abbricht. Geometrisch laufen diese Verfahren darauf hinaus, daß man die Funktion f durch ein Polynom ν -ten Grades $P_\nu(x)$, $\nu = 1, 2, \dots$, ersetzt, das mit f an der Stelle x_0 dieselben Ableitungen $f^{(k)}(x_0)$, $k = 0, 1, 2, \dots, \nu$, besitzt (s. Fig. 7).




Fig. 7. Verschiedene Newton-Raphson-Methoden

Das Newton-Raphson Verfahren ersten Grades erhält man durch *Linearisierung* von f . Durch Linearisierung lassen sich auch Iterationsverfahren zur Lösung von Gleichungssystemen der Form

$$(5.1.4) \quad f(x) = \begin{bmatrix} f_1(x^1, \dots, x^n) \\ \vdots \\ f_n(x^1, \dots, x^n) \end{bmatrix} = 0$$

gewinnen. Nimmt man an, daß $x = \xi$ Nullstelle von f , x_0 Näherungswert für ξ und f für $x = x_0$ differenzierbar ist, so gilt in erster Näherung

$$0 = f(\xi) \approx f(x_0) + Df(x_0)(\xi - x_0)$$

mit

$$(5.1.5) \quad Df(x_0) = \begin{bmatrix} \frac{\partial f_1}{\partial x^1} & \cdots & \frac{\partial f_1}{\partial x^n} \\ \vdots & & \vdots \\ \frac{\partial f_n}{\partial x^1} & \cdots & \frac{\partial f_n}{\partial x^n} \end{bmatrix}_{x=x_0}, \quad \xi - x_0 = \begin{bmatrix} \xi^1 - x_0^1 \\ \vdots \\ \xi^n - x_0^n \end{bmatrix}.$$

Falls die Funktionalmatrix $Df(x_0)$ nichtsingulär ist, kann man die Gleichung

$$f(x_0) + Df(x_0)(x_1 - x_0) = 0$$

nach x_1 auflösen,

$$x_1 = x_0 - (Df(x_0))^{-1} f(x_0),$$

und erhält so einen weiteren Näherungswert x_1 für die Nullstelle ξ . Das allgemeine *Newton-Verfahren* zur Lösung des Systems von Gleichungen (5.1.4) ist deshalb gegeben durch

$$(5.1.6) \quad x_{i+1} = x_i - (Df(x_i))^{-1} f(x_i), \quad i = 0, 1, 2, \dots$$

Neben dem Newton-Verfahren gibt es weitere allgemeine Iterationsmethoden, so Verallgemeinerungen des *Sekantenverfahrens* (s. (5.9.7)) und der in Kapitel 8 für lineare Gleichungssysteme beschriebenen Iterationsverfahren. Eine gute Übersicht findet man in Ortega, Rheinboldt (1970).

5.2 Allgemeine Konvergenzsätze

Wir wollen in diesem Abschnitt das Konvergenzverhalten der durch eine Iterationsfunktion $\Phi : E \rightarrow E$ erzeugten Folge x_i ,

$$x_{i+1} := \Phi(x_i), \quad i = 0, 1, 2, \dots,$$

in der Nähe eines Fixpunktes ξ von Φ untersuchen. Wir werden im folgenden nicht allgemeine normierte lineare Vektorräume betrachten, sondern uns auf den Fall $E = \mathbb{R}^n$ beschränken. Mit Hilfe einer Norm $\|\cdot\|$ auf dem $\mathbb{R}^n$ kann man den Abstand zweier Vektoren $x, y \in \mathbb{R}^n$ durch $\|x - y\|$ erklären: Eine Folge von Vektoren $x_i \in \mathbb{R}^n$ konvergiert gegen einen Vektor x , falls es zu jedem $\varepsilon > 0$ ein $N(\varepsilon)$ gibt mit

$$\|x_l - x\| < \varepsilon \quad \text{für alle } l \geq N(\varepsilon).$$

Man kann zeigen, daß die so definierte Konvergenz von Vektoren im $\mathbb{R}^n$ von der Wahl der Norm unabhängig ist (s. Satz (4.4.6)). Schließlich ist bekannt, daß der $\mathbb{R}^n$ in dem Sinne *vollständig* ist, daß das *Cauchysche Konvergenzkriterium* gilt:

Eine Folge von Vektoren $x_l \in \mathbb{R}^n$ ist genau dann konvergent, wenn zu jedem $\varepsilon > 0$ ein $N(\varepsilon)$ existiert, so daß $\|x_l - x_m\| < \varepsilon$ für alle $l, m \geq N(\varepsilon)$ gilt.

Wir wollen die *Konvergenzgeschwindigkeit* einer konvergenten Folge $\{x_i\}$, $\lim x_i = x$, näher charakterisieren: Man sagt, daß die Folge *mindestens mit der Ordnung* $p \geq 1$ gegen x konvergiert, falls es ein $C \geq 0$ (mit $C < 1$ für $p = 1$) und ein N gibt, so daß für alle $i \geq N$

$$\|x_{i+1} - x\| \leq C \|x_i - x\|^p.$$

Für $p = 1$ spricht man von *linearer Konvergenz*, für $p = 2$ von *quadratischer Konvergenz*.

Im Falle linearer Konvergenz wird der Fehler $e_i = \|x_i - x\|$ in jedem Schritt mindestens um den Faktor $C < 1$ verkleinert, die Konvergenz ist umso schneller, je kleiner der *Konvergenzfaktor* C ist. Eine typische Fehlerfolge für $C = 0.1$ ist z. B.

$$e_0 = 1, \quad e_1 = 10^{-1}, \quad e_2 = 10^{-2}, \quad e_3 = 10^{-3}, \dots$$

Im Falle quadratischer Konvergenz ist das Verhalten völlig anders: Z. B. würde man für $C = 1$ folgende Fehler beobachten

$$e_0 = 10^{-1}, \quad e_1 = 10^{-2}, \quad e_2 = 10^{-4}, \quad e_3 = 10^{-8}, \dots$$

Den folgenden Satz beweist man leicht:

(5.2.1) Satz: Sei $\Phi : \mathbb{R}^n \rightarrow \mathbb{R}^n$ eine Iterationsfunktion mit Fixpunkt ξ , und es gebe eine Umgebung $U(\xi)$, eine Zahl $p \geq 1$ und eine Konstante $C \geq 0$ (mit $C < 1$ für $p = 1$), so daß für alle $x \in U(\xi)$ gilt

$$\|\Phi(x) - \xi\| \leq C \|x - \xi\|^p.$$

Dann gibt es eine Umgebung $V(\xi) \subset U(\xi)$, so daß das zu Φ gehörige Iterationsverfahren für jeden Startpunkt $x_0 \in V(\xi)$ Iterierte x_i , $i \geq 0$, erzeugt, die mindestens mit der Ordnung p gegen ξ konvergieren.

Das Verfahren heißt dann *lokal konvergent* mit *Konvergenzbereich* $V(\xi)$. Falls $V(\xi) = \mathbb{R}^n$, heißt das Verfahren *global konvergent*.

Im eindimensionalen Fall, $E = \mathbb{R}$, kann man die Ordnung eines durch Φ erzeugten Iterationsverfahrens häufig leicht bestimmen, wenn $\Phi(x)$ in

einer Umgebung $U(\xi)$ von $x = \xi$ genügend oft differenzierbar ist. Ist etwa $x \in U(\xi)$ und gilt $\Phi^{(k)}(\xi) = 0$ für $k = 1, 2, \dots, p-1$, so folgt durch Taylorentwicklung

$$\Phi(x) - \xi = \Phi(x) - \Phi(\xi) = \frac{(x - \xi)^p}{p!} \Phi^{(p)}(\xi) + o(\|x - \xi\|^p),$$

$$\lim_{x \rightarrow \xi} \frac{\Phi(x) - \xi}{(x - \xi)^p} = \frac{\Phi^{(p)}(\xi)}{p!}.$$

Für $p = 2, 3, \dots$ liegt also dann ein Verfahren mindestens p -ter Ordnung vor, und ein Verfahren erster Ordnung, wenn $p = 1$ und $|\Phi'(\xi)| < 1$ gilt.

Im mehrdimensionalen Fall, $E = \mathbb{R}^n$, ist das Verfahren (mindestens) linear konvergent, wenn für die Jacobimatrix $\Phi'(x) = D\Phi(x)$ bzgl. einer geeigneten Norm $\text{lub}(\Phi'(\xi)) < 1$ gilt.

Beispiel 1: $E = \mathbb{R}$, Φ differenzierbar in Umgebung $U(\xi)$. Falls $0 < \Phi'(\xi) < 1$, so liegt lineare Konvergenz vor, die x_i konvergieren sogar monoton gegen ξ (s. Fig. 8). Für $-1 < \Phi'(\xi) < 0$ konvergieren die x_i alternierend gegen ξ (s. Fig. 9).




Fig. 8. Monotone Konvergenz

Beispiel 2: $E = \mathbb{R}$, $\Phi(x) = x - f(x)/f'(x)$ (Newton-Verfahren). f sei genügend oft stetig differenzierbar in einer Umgebung der einfachen Nullstelle ξ von f , $f'(\xi) \neq 0$. Es folgt

$$\Phi(\xi) = \xi, \quad \Phi'(\xi) = \frac{f(x)f''(x)}{(f'(x))^2} \Big|_{x=\xi} = 0, \quad \Phi''(\xi) = \frac{f''(\xi)}{f'(\xi)}.$$




Fig. 9. Alternierende Konvergenz

Das Newton-Verfahren ist also (lokal) mindestens quadratisch konvergent (*Verfahren zweiter Ordnung*).

Beispiel 3: Falls allgemeiner ξ eine m -fache Nullstelle von f ist, d. h.

$$f^{(v)}(\xi) = 0 \quad \text{für } v = 0, 1, \dots, m-1, \quad f^{(m)}(\xi) \neq 0,$$

so besitzen f und f' eine Darstellung der Form

$$f(x) = (x - \xi)^m g(x), \quad g(\xi) \neq 0,$$

$$f'(x) = m(x - \xi)^{m-1} g(x) + (x - \xi)^m g'(x)$$

mit einer differenzierbaren Funktion g . Es folgt nun

$$\Phi(x) \equiv x - \frac{f(x)}{f'(x)} \equiv x - \frac{(x - \xi)g(x)}{mg(x) + (x - \xi)g'(x)}$$

und daher

$$\Phi'(\xi) = 1 - \frac{1}{m},$$

d. h. für $m > 1$, also für mehrfache Nullstellen, ist das Newton-Verfahren nur noch linear konvergent. Das modifizierte Verfahren mit $\tilde{\Phi}(x) := x - mf(x)/f'(x)$ wäre dann immer noch quadratisch konvergent. Beide Verfahren sind aber für $m > 1$ numerisch instabil, weil $f(x)$ und $f'(x)$ für $x \rightarrow \xi$ durch Auslöschung klein werden und deshalb $\Phi(x)$ und $\tilde{\Phi}(x)$ sehr Rundungsfehlerempfindlich sind.

Die folgenden allgemeinen Konvergenzsätze zeigen, daß eine durch die Iterationsfunktion $\Phi: E \rightarrow E$ gegebene Folge x_k jedenfalls dann gegen

einen Fixpunkt ξ von Φ konvergiert, falls Φ eine *kontrahierende Abbildung* ist. Wir setzen voraus, daß durch $\|\cdot\|$ eine Norm im $\mathbb{R}^n$ gegeben ist.

(5.2.2) **Satz:** Die Funktion $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ besitze einen Fixpunkt ξ , $\Phi(\xi) = \xi$. Sei ferner $S_r(\xi) := \{z \mid \|z - \xi\| < r\}$ eine Umgebung von ξ , so daß Φ in $S_r(\xi)$ eine kontrahierende Abbildung ist, d. h. daß für ein $K < 1$

$$\|\Phi(x) - \Phi(y)\| \leq K\|x - y\|$$

für alle $x, y \in S_r(\xi)$ gilt. Dann besitzt für alle $x_0 \in S_r(\xi)$ die von ϕ erzeugte Folge $\{x_i\}$, $x_{i+1} := \Phi(x_i)$, $i = 0, 1, 2, \dots$, die Eigenschaften:

- a) $x_i \in S_r(\xi)$ für alle $i = 0, 1, \dots$,
- b) $\|x_{i+1} - \xi\| \leq K\|x_i - \xi\| \leq K^{i+1}\|x_0 - \xi\|$,

d. h. $\{x_i\}$ konvergiert mindestens linear gegen ξ .

Der Beweis folgt sofort aus der Kontraktionseigenschaft. Die Aussagen a) und b) sind richtig für $i = 0$. Nimmt man an, daß sie für $j \leq i$ richtig sind, so folgt sofort

$$\|x_{i+1} - \xi\| = \|\Phi(x_i) - \Phi(\xi)\| \leq K\|x_i - \xi\| \leq K^{i+1}\|x_0 - \xi\| < r. \quad \square$$

Der folgende Satz, der als Fixpunktsatz von Banach bekannt ist, gibt eine Verschärfung: Er setzt die Existenz eines Fixpunktes ξ nicht mehr voraus.

(5.2.3) **Satz:** Sei $\Phi: E \rightarrow E$, $E = \mathbb{R}^n$, eine Iterationsfunktion, $x_0 \in E$ ein Startvektor und $x_{i+1} := \Phi(x_i)$, $i = 0, 1, \dots$. Es gebe ferner eine Umgebung $S_r(x_0) := \{x \mid \|x - x_0\| < r\}$ von x_0 , und eine Konstante K , $0 < K < 1$, so daß

- a) $\|\Phi(x) - \Phi(y)\| \leq K\|x - y\|$ für alle x, y aus

$$\overline{S_r(x_0)} := \{x \mid \|x - x_0\| \leq r\},$$

- b) $\|x_1 - x_0\| = \|\Phi(x_0) - x_0\| \leq (1 - K)r < r$.

Dann gilt

- 1) $x_i \in S_r(x_0)$ für alle $i = 0, 1, \dots$,
- 2) Φ besitzt in $\overline{S_r(x_0)}$ genau einen Fixpunkt ξ , $\Phi(\xi) = \xi$, und es gilt

$$\lim_{i \rightarrow \infty} x_i = \xi, \quad \|x_{i+1} - \xi\| \leq K\|x_i - \xi\|,$$

sowie die Fehlerabschätzung

$$\|x_i - \xi\| \leq \frac{K^i}{1-K} \|x_1 - x_0\|.$$

Beweis: 1) Wir führen einen Induktionsbeweis. Wegen b) ist $x_1 \in S_r(x_0)$. Wenn nun $x_j \in S_r(x_0)$ für $j = 0, 1, \dots, i$ für ein $i \geq 1$ gilt, so folgt aus a)

$$(5.2.4) \quad \|x_{i+1} - x_i\| = \|\Phi(x_i) - \Phi(x_{i-1})\| \leq K \|x_i - x_{i-1}\| \leq K^i \|x_1 - x_0\|$$

und daher wegen der Dreiecksungleichung und b)

$$\begin{aligned} \|x_{i+1} - x_0\| &\leq \|x_{i+1} - x_i\| + \|x_i - x_{i-1}\| + \dots + \|x_1 - x_0\| \\ &\leq (K^i + K^{i-1} + \dots + 1) \|x_1 - x_0\| \\ &\leq (1 + K + \dots + K^i)(1-K)r = (1 - K^{i+1})r < r. \end{aligned}$$

2) Wir zeigen zunächst, daß $\{x_i\}$ eine Cauchyfolge ist. Aus (5.2.4) und Voraussetzung b) folgt nämlich für $m > l$

$$\begin{aligned} (5.2.5) \quad \|x_m - x_l\| &\leq \|x_m - x_{m-1}\| + \|x_{m-1} - x_{m-2}\| + \dots + \|x_{l+1} - x_l\| \\ &\leq K^l (1 + K + \dots + K^{m-l-1}) \|x_1 - x_0\| \\ &< \frac{K^l}{1-K} \|x_1 - x_0\| < K^l r. \end{aligned}$$

Wegen $0 < K < 1$ wird $K^l r < \varepsilon$ für genügend großes $l \geq N(\varepsilon)$. Also ist $\{x_i\}$ eine Cauchyfolge. Da nun $E = \mathbb{R}^n$ vollständig ist und daher alle Cauchyfolgen konvergent sind, existiert $\lim_i x_i = \xi$. Wegen $x_i \in S_r(x_0)$ muß $\xi \in \overline{S_r(x_0)}$ in der abgeschlossenen Hülle von $S_r(x_0)$ liegen. Ferner ist ξ Fixpunkt von Φ , denn es gilt für alle $i \geq 0$

$$\begin{aligned} \|\Phi(\xi) - \xi\| &\leq \|\Phi(\xi) - \Phi(x_i)\| + \|\Phi(x_i) - \xi\| \\ &\leq K \|\xi - x_i\| + \|x_{i+1} - \xi\|. \end{aligned}$$

Wegen $\lim_{i \rightarrow \infty} \|x_i - \xi\| = 0$ folgt sofort $\|\Phi(\xi) - \xi\| = 0$ und daher $\Phi(\xi) = \xi$. Wäre nun $\bar{\xi} \in \overline{S_r(x_0)}$ ein zweiter Fixpunkt von Φ , so folgt

$$\|\xi - \bar{\xi}\| = \|\Phi(\xi) - \Phi(\bar{\xi})\| \leq K \|\xi - \bar{\xi}\|$$

und daher $\|\xi - \bar{\xi}\| = 0$ wegen $0 < K < 1$. Schließlich folgt aus (5.2.5)

$$\|\xi - x_l\| = \lim_{m \rightarrow \infty} \|x_m - x_l\| \leq \frac{K^l}{1-K} \|x_1 - x_0\|$$

und

$$\|x_{i+1} - \xi\| = \|\Phi(x_i) - \Phi(\xi)\| \leq K \|x_i - \xi\|.$$

Damit ist Satz (5.2.3) vollständig bewiesen. □

5.3 Die Konvergenz des allgemeinen Newton-Verfahrens

Wir wollen nun die Konvergenz des Newton-Verfahrens zur Lösung eines Gleichungssystems $f(x) = 0$, $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$, untersuchen. Bekanntlich heißt eine solche Funktion im Punkt $x_0 \in \mathbb{R}^n$ *differenzierbar*, wenn eine $n \times n$ -Matrix A existiert, so daß gilt

$$\lim_{x \rightarrow x_0} \frac{\|f(x) - f(x_0) - A(x - x_0)\|}{\|x - x_0\|} = 0.$$

In diesem Fall stimmt A mit der Funktionalmatrix $Df(x_0)$ (s. (5.1.5)) überein.

Wir notieren als erstes den

(5.3.1) Hilfssatz: Wenn $Df(x)$ für alle $x \in C_0$ aus einem konvexen Gebiet $C_0 \subseteq \mathbb{R}^n$ existiert und es eine Konstante γ gibt mit

$$\|Df(x) - Df(y)\| \leq \gamma \|x - y\| \quad \text{für alle } x, y \in C_0,$$

so gilt für alle $x, y \in C_0$ die Abschätzung

$$\|f(x) - f(y) - Df(y)(x - y)\| \leq \frac{\gamma}{2} \|x - y\|^2.$$

Dabei heißt eine Menge $M \subseteq \mathbb{R}^n$ *konvex*, falls mit $x, y \in M$ auch die Verbindungsstrecke $[x, y] := \{z = \lambda x + (1 - \lambda)y \mid 0 \leq \lambda \leq 1\}$ zu M gehört, $[x, y] \subseteq M$.

Beweis: Die Funktion $\varphi: [0, 1] \rightarrow \mathbb{R}^n$,

$$\varphi(t) := f(y + t(x - y)),$$

ist differenzierbar für alle $0 \leq t \leq 1$, wobei $x, y \in C_0$ beliebig gewählt sind, und es gilt nach der Kettenregel

$$\varphi'(t) = Df(y + t(x - y))(x - y).$$

Es folgt daher für $0 \leq t \leq 1$ die Abschätzung

$$\begin{aligned} \|\varphi'(t) - \varphi'(0)\| &= \|(Df(y + t(x - y)) - Df(y))(x - y)\| \\ &\leq \|Df(y + t(x - y)) - Df(y)\| \|x - y\| \\ &\leq \gamma t \|x - y\|^2. \end{aligned}$$

Nun ist aber

$$\begin{aligned} \Delta &:= f(x) - f(y) - Df(y)(x - y) = \varphi(1) - \varphi(0) - \varphi'(0) \\ &= \int_0^1 (\varphi'(t) - \varphi'(0)) dt \end{aligned}$$

und daher wegen der obigen Abschätzung

$$\|\Delta\| \leq \int_0^1 \|\varphi'(t) - \varphi'(0)\| dt \leq \gamma \|x - y\|^2 \int_0^1 t dt = \frac{\gamma}{2} \|x - y\|^2.$$

Damit ist der Hilfssatz bewiesen. $\square$

Wir zeigen nun den folgenden Satz über die Konvergenz des Newton-Verfahrens.

(5.3.2) **Satz:** Es sei eine offene Menge $C \subseteq \mathbb{R}^n$ gegeben, ferner eine konvexe Menge C_0 mit $\bar{C}_0 \subseteq C$ und $f: C \rightarrow \mathbb{R}^n$ eine für $x \in C_0$ differenzierbare und für $x \in C$ stetige Funktion.

Für ein $x_0 \in C_0$ gebe es positive Konstanten $r, \alpha, \beta, \gamma, h$ mit den folgenden Eigenschaften

$$S_r(x_0) := \{x \mid \|x - x_0\| < r\} \subseteq C_0,$$

$$h := \alpha\beta\gamma/2 < 1,$$

$$r := \alpha/(1 - h).$$

$f(x)$ habe die Eigenschaften

- a) $\|Df(x) - Df(y)\| \leq \gamma \|x - y\|$ für alle $x, y \in C_0$,
- b) für alle $x \in C_0$ existiert $(Df(x))^{-1}$ und es gilt $\|(Df(x))^{-1}\| \leq \beta$,
- c) $\|(Df(x_0))^{-1} f(x_0)\| \leq \alpha$.

Dann gilt:

- 1) Ausgehend von x_0 ist jedes

$$x_{k+1} := x_k - Df(x_k)^{-1} f(x_k), \quad k = 0, 1, \dots,$$

wohldefiniert und es gilt $x_k \in S_r(x_0)$ für alle $k \geq 0$.

- 2) $\lim_{k \rightarrow \infty} x_k = \xi$ existiert und es gilt $\xi \in \overline{S_r(x_0)}$ und $f(\xi) = 0$.
- 3) Für alle $k \geq 0$ gilt

$$\|x_k - \xi\| \leq \alpha \frac{h^{2^k - 1}}{1 - h^{2^k}}.$$

Wegen $0 < h < 1$ ist also das Newton-Verfahren mindestens quadratisch konvergent.

Beweis: 1) Da $Df(x)^{-1}$ für $x \in C_0$ existiert, ist x_{k+1} für alle k dann wohldefiniert, wenn $x_k \in S_r(x_0)$ für alle $k \geq 0$. Dies ist richtig für $k = 0$ und $k = 1$ wegen Voraussetzung c). Wenn nun $x_j \in S_r(x_0)$ für $j = 0, 1, \dots, k$ für ein $k \geq 1$, so gilt zunächst wegen b)

$$\begin{aligned}\|x_{k+1} - x_k\| &= \| -Df(x_k)^{-1} f(x_k) \| \leq \beta \|f(x_k)\| \\ &= \beta \|f(x_k) - f(x_{k-1}) - Df(x_{k-1})(x_k - x_{k-1})\|,\end{aligned}$$

da nach Definition von x_k

$$f(x_{k-1}) + Df(x_{k-1})(x_k - x_{k-1}) = 0$$

gilt. Es folgt daher aus Hilfssatz (5.3.1)

$$(5.3.3) \quad \|x_{k+1} - x_k\| \leq \frac{\beta\gamma}{2} \|x_k - x_{k-1}\|^2$$

und daraus

$$(5.3.4) \quad \|x_{k+1} - x_k\| \leq \alpha h^{2^k-1}.$$

Die letzte Abschätzung ist zumindest für $k = 0$ wegen c) richtig. Ist sie für $k \geq 0$ richtig, so auch für $k + 1$, denn wegen (5.3.3) ist

$$\|x_{k+1} - x_k\| \leq \frac{\beta\gamma}{2} \|x_k - x_{k-1}\|^2 \leq \frac{\beta\gamma}{2} \alpha^2 h^{2^k-2} = \alpha h^{2^{k+1}-1}.$$

Nun folgt aus (5.3.4) weiter

$$\begin{aligned}\|x_{k+1} - x_0\| &\leq \|x_{k+1} - x_k\| + \|x_k - x_{k-1}\| + \cdots + \|x_1 - x_0\| \\ &\leq \alpha(1 + h + h^3 + h^7 + \cdots + h^{2^k-1}) < \alpha/(1 - h) = r\end{aligned}$$

und daher auch $x_{k+1} \in S_r(x_0)$.

2) Aus (5.3.4) folgt leicht, daß $\{x_k\}$ eine Cauchyfolge ist, denn für $m \geq n$ hat man

$$\begin{aligned}(5.3.5) \quad \|x_{m+1} - x_n\| &\leq \|x_{m+1} - x_m\| + \|x_m - x_{m-1}\| + \cdots + \|x_{n+1} - x_n\| \\ &\leq \alpha h^{2^n-1} (1 + h^{2^n} + (h^{2^n})^2 + \cdots) \\ &< \frac{\alpha h^{2^n-1}}{1 - h^{2^n}} < \varepsilon\end{aligned}$$

für genügend großes $n \geq N(\varepsilon)$, weil $0 < h < 1$. Also existiert

$$\lim_{k \rightarrow \infty} x_k = \xi \in \overline{S_r(x_0)},$$

da nach 1) $x_k \in S_r(x_0)$ für alle $k \geq 0$.

Durch Grenzübergang in (5.3.5) ($m \rightarrow \infty$) erhält man als Nebenresultat die Behauptung 3):

$$\lim_{m \rightarrow \infty} \|x_m - x_n\| = \|\xi - x_n\| \leq \frac{\alpha h^{2^n-1}}{1 - h^{2^n}}.$$

Wir müssen noch zeigen, daß ξ Nullstelle von f in $\overline{S_r(x_0)}$ ist. Nun gilt wegen a) und $x_k \in S_r(x_0)$ für alle $k \geq 0$

$$\|Df(x_k) - Df(x_0)\| \leq \gamma \|x_k - x_0\| < \gamma r$$

und daher

$$\|Df(x_k)\| \leq \gamma r + \|Df(x_0)\| =: K.$$

Es folgt aus der Gleichung

$$f(x_k) = -Df(x_k)(x_{k+1} - x_k)$$

die Abschätzung

$$\|f(x_k)\| \leq K \|x_{k+1} - x_k\|.$$

Also gilt

$$\lim_{k \rightarrow \infty} \|f(x_k)\| = 0$$

und, da f an der Stelle $\xi \in C$ noch stetig ist, $\lim \|f(x_k)\| = \|f(\xi)\| = 0$
d. h. ξ ist Nullstelle von f . $\square$

Unter etwas strengeren Voraussetzungen kann noch gezeigt werden, daß ξ die einzige Nullstelle in $S_r(x_0)$ ist.

(5.3.6) **Satz (Newton-Kantorovich):** Die Funktion $f: C \rightarrow \mathbb{R}^n$, $C \subset \mathbb{R}^n$, sei auf einer konvexen Teilmenge $C_0 \subset C$ von C stetig differenzierbar und erfülle für ein $x_0 \in C_0$ die Bedingungen

- a) $\|Df(x) - Df(y)\| \leq \gamma \|x - y\|$ für alle $x, y \in C_0$,
- b) $\|Df(x_0)^{-1}\| \leq \beta$,
- c) $\|Df(x_0)^{-1} f(x_0)\| \leq \alpha$,

Mit den Konstanten

$$h := \alpha\beta\gamma, \quad r_{1,2} := \frac{1 \mp \sqrt{1 - 2h}}{h} \alpha$$

gilt dann:

Falls $h \leq \frac{1}{2}$ und $\overline{S_{r_1}(x_0)} \subset C_0$, besitzt $f(x)$ genau eine Nullstelle ξ in $C_0 \cap S_{r_2}(x_0)$, die Folge $\{x_k\}$,

$$x_{k+1} := x_k - Df(x_k)^{-1} f(x_k), \quad k = 0, 1, \dots,$$

bleibt in $S_{r_1}(x_0)$ und konvergiert gegen ξ .

Bezüglich eines Beweises wird auf Ortega, Rheinboldt (1970) bzw. auf Collatz (1968) verwiesen.

5.4 Ein modifiziertes Newton-Verfahren

Satz (5.3.2) zeigt, daß das Newton-Verfahren konvergiert, wenn der Startwert x_0 der Iterationsfolge „hinreichend“ nahe bei der gesuchten Lösung ξ von

$$f(x) = 0, \quad f: \mathbb{R}^n \rightarrow \mathbb{R}^n,$$

liegt. Für schlecht gewählte Startwerte kann es divergieren, wie folgendes Beispiel zeigt:

Beispiel: Sei $f: \mathbb{R} \rightarrow \mathbb{R}$ gegeben durch $f(x) := \arctan(x)$. Die einzige Lösung von $f(x) = 0$ ist $\xi = 0$.

Die Newton-Iterationsfolge ist definiert durch

$$x_{k+1} := x_k - (1 + x_k^2) \arctan(x_k).$$

Für beliebige Startwerte x_0 mit

$$\arctan(|x_0|) \geq \frac{2|x_0|}{1 + x_0^2}$$

divergiert die Folge der $|x_k|$: $\lim_{k \rightarrow \infty} |x_k| = \infty$.

In diesem Abschnitt werden Iterationsverfahren beschrieben, die für eine große Klasse von Funktionen f global konvergieren. Diese Verfahren benutzen *Suchrichtungen* s_k und *Schrittweiten* λ_k zur Erzeugung der Folge

$$(5.4.0.1) \quad x_{k+1} := x_k - \lambda_k s_k,$$

wobei im Falle des Newtonverfahrens als s_k die *Newtonrichtung* $s_k := d_k := [Df(x_k)]^{-1} f(x_k)$ genommen wird. Die Schrittweiten λ_k werden dabei so gewählt, daß die Folge $\{h(x_k)\}$, $h(x) := f(x)^T f(x)$, streng monoton fällt und die x_k gegen ein Minimum von $h(x)$ konvergieren. (Ähnliche Techniken wurden bei der nichtlinearen Ausgleichsrechnung in Abschnitt 4.8.4 verwandt).

Wegen $h(x) \geq 0$ für alle x gilt

$$h(\bar{x}) = 0 \iff f(\bar{x}) = 0.$$

Jedes lokale Minimum $\bar{x}$ von h mit $h(\bar{x}) = 0$ ist auch globales Minimum von h und außerdem Nullstelle von f .

Im folgenden Abschnitt werden zunächst einige allgemeine Resultate über die Konvergenz von Verfahren zur Minimierung einer beliebigen Funktion $h(x)$ hergeleitet, die dann in Abschnitt 5.4.2 benutzt werden, um die Konvergenz eines modifizierten Newton-Verfahrens zu untersuchen.

5.4.1 Über die Konvergenz von Minimierungsverfahren

Sei $\|\cdot\|$ die euklidische Norm und $0 < \gamma \leq 1$. Wir betrachten die Menge

$$(5.4.1.1) \quad D(\gamma, x) := \{s \in \mathbb{R}^n \mid \|s\| = 1 \text{ mit } Dh(x)s \geq \gamma \|Dh(x)\|\}$$

aller Richtungen s , die einen nicht zu großen spitzen Winkel mit dem Gradienten $\nabla h(x)$, $\nabla h(x)^T = Dh(x) = (\partial h(x)/\partial x^1, \dots, \partial h(x)/\partial x^n)$, von $h(x) = h(x^1, \dots, x^n)$ bilden. Folgendes Lemma zeigt, unter welchen Bedingungen die Ungleichung $h(x - \mu s) < h(x)$ erfüllt werden kann.

(5.4.1.2) **Lemma:** Sei $h: \mathbb{R}^n \rightarrow \mathbb{R}$ eine Funktion, deren Gradient $Dh(x)$ für alle $x \in V(\bar{x})$ aus einer Umgebung $V(\bar{x})$ von $\bar{x}$ definiert und stetig ist. Sei ferner $Dh(\bar{x}) \neq 0$ und $0 < \gamma \leq 1$. Dann gibt es eine Umgebung $U(\bar{x}) \subseteq V(\bar{x})$ von $\bar{x}$ und eine Zahl $\lambda > 0$, so daß

$$h(x - \mu s) \leq h(x) - \frac{\mu\gamma}{4} \|Dh(\bar{x})\|$$

für alle $x \in U(\bar{x})$, $s \in D(\gamma, x)$ und $0 \leq \mu \leq \lambda$.

Beweis: Die Menge

$$U^1(\bar{x}) := \{x \in V(\bar{x}) \mid \|Dh(x) - Dh(\bar{x})\| \leq \frac{\gamma}{4} \|Dh(\bar{x})\|\}$$

ist wegen $Dh(\bar{x}) \neq 0$ und der Stetigkeit von $Dh(x)$ auf $V(\bar{x})$ eine Umgebung von $\bar{x}$. Für $x \in U^1(\bar{x})$ gilt

$$\|Dh(x)\| \geq \|Dh(\bar{x})\| - \frac{1}{4}\gamma \|Dh(\bar{x})\| \geq \frac{3}{4}\|Dh(\bar{x})\|,$$

so daß für $s \in D(\gamma, x)$

$$D(h(x))s \geq \gamma \|Dh(x)\| \geq \frac{3}{4}\gamma \|Dh(\bar{x})\|.$$

Wir wählen nun $\lambda > 0$, so daß

$$B_{2\lambda} := \{x \mid \|x - \bar{x}\| \leq 2\lambda\} \subset U^1(\bar{x})$$

und setzen

$$U(\bar{x}) := B_\lambda = \{x \mid \|x - \bar{x}\| \leq \lambda\}.$$

Dann gibt es für $x \in U(\bar{x})$, $0 \leq \mu \leq \lambda$, $s \in D(\gamma, x)$ ein $0 < \theta < 1$ mit

$$\begin{aligned} h(x) - h(x - \mu s) &= \mu Dh(x - \theta \mu s), \\ &= \mu ([Dh(x - \theta \mu s) - Dh(x)]s + Dh(x)s). \end{aligned}$$

Wegen $x \in U(\bar{x}) = B_\lambda$ gilt $x, x - \mu s, x - \theta \mu s \in B_{2\lambda} \subset U^1$, so daß

$$\|([Dh(x - \theta \mu s) - Dh(\bar{x})] + (Dh(\bar{x}) - Dh(x))s)\| \leq \frac{1}{2}\gamma \|Dh(\bar{x})\|.$$

Berücksichtigt man $D(h(x))s \geq \frac{3}{4}\gamma \|Dh(\bar{x})\|$, erhält man so schließlich

$$\begin{aligned} h(x) - h(x - \mu s) &\geq -\frac{\mu\gamma}{2} \|Dh(\bar{x})\| + \frac{3\mu\gamma}{4} \|Dh(\bar{x})\| \\ &= \frac{\mu\gamma}{4} \|Dh(\bar{x})\|, \end{aligned}$$

was zu zeigen war. $\square$

Wir betrachten nun folgendes Verfahren zur Minimierung einer differenzierbaren Funktion $h: \mathbb{R}^n \rightarrow \mathbb{R}$.

(5.4.1.3)

- a) Man wähle Zahlen $\gamma_k \leq 1$, σ_k , $k = 0, 1, \dots$, mit

$$\inf_k \gamma_k > 0, \quad \inf_k \sigma_k > 0$$

sowie einen Startwert $x_0 \in \mathbb{R}^n$.

- b) Für alle $k = 0, 1, \dots$, berechne man x_{k+1} aus x_k wie folgt: Man wähle einen Vektor $s_k \in D(\gamma_k, x_k)$ und setze

$$x_{k+1} := x_k - \lambda_k s_k$$

wobei $\lambda_k \in [0, \sigma_k \|Dh(x_k)\|]$ so gewählt wird, daß gilt

$$h(x_{k+1}) = \min_{\mu} \{h(x_k - \mu s_k) \mid 0 \leq \mu \leq \sigma_k \|Dh(x_k)\|\}.$$

In Schritt b) wird h längs eines Strahls $\{x - \mu s \mid \mu \geq 0\}$ minimiert. In ihm wird eine „Strahlminimierung“ („line search“) vorgenommen.

Für die Konvergenz dieses Verfahrens gilt:

(5.4.1.4) Satz: Sei $h: \mathbb{R}^n \rightarrow \mathbb{R}$ eine Funktion, die zusammen mit dem Startwert $x_0 \in \mathbb{R}^n$ folgende Eigenschaften besitzt:

- $K := \{x \mid h(x) \leq h(x_0)\}$ ist kompakt und
- h ist auf einer Umgebung von K stetig differenzierbar.

Dann gilt für jede Folge $\{x_k\}$, die durch ein Verfahren des Typs (5.4.1.3) geliefert wird:

- $x_k \in K$ für alle $k = 0, 1, \dots$ und $\{x_k\}$ besitzt mindestens einen Häufungspunkt $\bar{x}$ in K .
- Jeder Häufungspunkt $\bar{x}$ von $\{x_k\}$ ist stationärer Punkt von h , $Dh(\bar{x}) = 0$.

Beweis: 1. Aus der Definition der Folge $\{x_k\}$ folgt sofort, daß die $h(x_k)$ monoton fallen, $h(x_0) \geq h(x_1) \geq \dots$. Also gilt $x_k \in K$ für alle k . Da K kompakt ist, besitzt $\{x_k\}$ mindestens einen Häufungspunkt $\bar{x} \in K$.

2. Wir nehmen an, daß $\bar{x}$ Häufungspunkt der x_k aber kein stationärer Punkt ist,

$$(5.4.1.5) \quad Dh(\bar{x}) \neq 0.$$

Sei o. B. d. A. $\lim_{k \rightarrow \infty} x_k = \bar{x}$. Wir setzen

$$\gamma := \inf_k \gamma_k > 0, \quad \sigma := \inf_k \sigma_k > 0.$$

Nach Lemma (5.4.1.2) gibt es dann eine Umgebung $U(\bar{x})$ und eine Zahl $\lambda > 0$, so daß

$$(5.4.1.6) \quad h(x - \mu s) \leq h(x) - \mu \frac{\gamma}{4} \|Dh(\bar{x})\|$$

für alle $x \in U(\bar{x})$, $s \in D(\gamma, x)$ und $0 \leq \mu \leq \lambda$ gilt.

Wegen $\lim_{k \rightarrow \infty} x_k = \bar{x}$, der Stetigkeit von $Dh(x)$ und (5.4.1.5) gibt es ein k_0 , so daß für alle $k \geq k_0$ gilt

- a) $x_k \in U(\bar{x})$
- b) $\|Dh(x_k)\| \geq \frac{1}{2} \|Dh(\bar{x})\|$.

Sei nun $\Lambda := \min\{\lambda, \frac{1}{2}\sigma\|Dh(\bar{x})\|\}$, $\varepsilon := \Lambda \frac{\gamma}{4} \|Dh(\bar{x})\| > 0$. Wegen $\sigma_k \geq \sigma$ folgt $[0, \Lambda] \subseteq [0, \sigma_k \|Dh(x_k)\|]$ für alle $k \geq k_0$ und daher nach Definition von x_{k+1} ,

$$h(x_{k+1}) \leq \min_{\mu} \{h(x_k - \mu s_k) | 0 \leq \mu \leq \Lambda\}.$$

Also folgt aus (5.4.1.6) wegen $\Lambda \leq \lambda$, $x_k \in U(\bar{x})$, $s_k \in D(\gamma_k, x_k) \subseteq D(\gamma, x_k)$ die Ungleichung

$$h(x_{k+1}) \leq h(x_k) - \frac{\Lambda \gamma}{4} \|Dh(\bar{x})\| = h(x_k) - \varepsilon$$

für alle $k \geq k_0$. Daraus folgt aber sofort $\lim_{k \rightarrow \infty} h(x_k) = -\infty$ im Widerspruch zu $h(x_k) \geq h(x_{k+1}) \geq \dots \geq h(\bar{x})$. Also ist $\bar{x}$ stationärer Punkt von h . $\square$

So allgemein die durch (5.4.1.3) gegebene Methode auch ist, ihre praktische Brauchbarkeit ist wesentlich dadurch eingeschränkt, daß man zur Berechnung von x_{k+1} das exakte Minimum der Funktion

$$\varphi(\mu) := h(x_k - \mu s_k)$$

auf $[0, \sigma_k \|Dh(x_k)\|]$ bestimmen muß („exakte line search“). Dies ist i.a. nur näherungsweise und nur mit einem großen Rechenaufwand möglich. Die

Bedeutung der folgenden Variante von (5.4.1.3) liegt darin, daß diese Minimumsuche durch einen finiten Suchprozeß ersetzt werden kann („Armijo-line search“):

(5.4.1.7)

a) Man wähle Zahlen $\gamma_k \leq 1$, σ_k , $k = 0, 1, \dots$, mit

$$\inf_k \gamma_k > 0, \quad \inf_k \sigma_k > 0$$

und einen Startwert $x_0 \in \mathbb{R}^n$.

b) Für alle $k = 0, 1, \dots$, berechne man x_{k+1} aus x_k folgendermaßen:

α) Man wähle ein $s_k \in D(\gamma_k, x_k)$, definiere

$$\rho_k := \sigma_k \|Dh(x_k)\|, \quad h_k(\mu) := h(x_k - \mu s_k),$$

und bestimme die kleinste ganze Zahl $j \geq 0$ mit

$$h_k(\rho_k 2^{-j}) \leq h_k(0) - \rho_k 2^{-j} \frac{\gamma_k}{4} \|Dh(x_k)\|.$$

β) Man bestimme $\bar{i} \in \{0, 1, \dots, j\}$, so daß

$$h_k(\rho_k 2^{-\bar{i}}) = \min_{1 \leq i \leq j} h_k(\rho_k 2^{-i}),$$

und setze $\lambda_k := \rho_k 2^{-\bar{i}}$, $x_{k+1} := x_k - \lambda_k s_k$.

Man überzeugt sich leicht, daß ein $j \geq 0$ mit den in (5.4.1.7)b) α), angegebenen Eigenschaften existiert: Ist x_k stationärer Punkt, so ist $j = 0$. Ist x_k nicht stationär, so folgt die Existenz von j sofort aus Lemma (5.4.1.2) angewandt auf $\bar{x} := x_k$. In jedem Fall kann j (notfalls durch Ausprobieren für $j = 0, 1, \dots$) und damit auch λ_k in einem endlichen Suchprozeß bestimmt werden.

Für das modifizierte Verfahren (5.4.1.7) bleibt Satz (5.4.1.4) richtig:

(5.4.1.8) Satz: Unter den Voraussetzungen von Satz (5.4.1.4) gelten auch für jede Folge $\{x_k\}$, die von Verfahren des Typs (5.4.1.7) geliefert werden, die Aussagen von Satz (5.4.1.4).

Beweis: Wir nehmen an, daß $\bar{x}$ Häufungspunkt einer durch (5.4.1.7) gelieferten Folge $\{x_k\}$ ist, aber kein stationärer Punkt ist, $Dh(\bar{x}) \neq 0$. Sei wieder o. B. d. A. $\lim x_k = \bar{x}$, $\sigma := \inf_k \sigma_k > 0$, $\gamma := \inf_k \gamma_k > 0$. Nach Lemma (5.4.1.2) gibt es eine Umgebung $U(\bar{x})$ und eine Zahl $\lambda > 0$, so daß

$$(5.4.1.9) \quad h(x - \mu s) \leq h(x) - \mu \frac{\gamma}{4} \|Dh(\bar{x})\|$$

für alle $x \in U(\bar{x})$, $s \in D(\gamma, x)$, $0 \leq \mu \leq \lambda$. Wieder folgt aus $\lim_k x_k = \bar{x}$, der Stetigkeit von $Dh(x)$ und $Dh(\bar{x}) \neq 0$ die Existenz eines k_0 , so daß für alle $k \geq k_0$ gilt

$$(5.4.1.10) \quad \begin{aligned} a) & \quad x_k \in U(\bar{x}) \\ b) & \quad \|Dh(x_k)\| \geq \frac{1}{2} \|Dh(\bar{x})\|. \end{aligned}$$

Wir wollen wieder zeigen, daß es ein $\varepsilon > 0$ gibt, so daß

$$h(x_{k+1}) \leq h(x_k) - \varepsilon, \quad \text{für alle } k \geq k_0.$$

Wir bemerken zunächst, daß wegen (5.4.1.10) und $\gamma_k \geq \gamma$

$$\gamma_k \|Dh(x_k)\| \geq \frac{\gamma}{2} \|Dh(\bar{x})\|$$

für alle $k \geq k_0$ gilt. Es folgt daher nach Definition von x_{k+1} und j

$$(5.4.1.11) \quad \begin{aligned} h(x_{k+1}) &\leq h_k(\rho_k 2^{-j}) \leq h(x_k) - \rho_k 2^{-j} \frac{\gamma_k}{4} \|Dh(x_k)\| \\ &\leq h(x_k) - \rho_k 2^{-j} \frac{\gamma}{8} \|Dh(\bar{x})\|. \end{aligned}$$

Sei nun $\bar{j} \geq 0$ die kleinste ganze Zahl mit

$$(5.4.1.12) \quad h_k(\rho_k 2^{-\bar{j}}) \leq h(x_k) - \rho_k 2^{-\bar{j}} \frac{\gamma}{8} \|Dh(\bar{x})\|.$$

Wegen (5.4.1.11) ist $\bar{j} \leq j$ und nach Definition von x_{k+1} auch

$$(5.4.1.13) \quad h(x_{k+1}) \leq h_k(\rho_k 2^{-\bar{j}}).$$

Wir unterscheiden zwei Fälle:

1. Fall: $\bar{j} = 0$. Es ist dann wegen (5.4.1.12), (5.4.1.13) und wegen $\rho_k = \sigma_k \|Dh(x_k)\| \geq \sigma/2 \|Dh(\bar{x})\|$

$$\begin{aligned} h(x_{k+1}) &\leq h(x_k) - \rho_k \frac{\gamma}{8} \|Dh(\bar{x})\| \\ &\leq h(x_k) - \frac{\sigma \gamma}{16} \|Dh(\bar{x})\|^2 = h(x_k) - \varepsilon_1. \end{aligned}$$

mit einem von x_k unabhängigen $\varepsilon_1 > 0$.

2. Fall: $\bar{j} > 0$. Wegen der Minimalitätseigenschaft von $\bar{j}$ hat man

$$\begin{aligned} h_k(\rho_k 2^{-(\bar{j}-1)}) &> h(x_k) - \rho_k 2^{-(\bar{j}-1)} \frac{\gamma}{8} \|Dh(\bar{x})\| \\ &\geq h(x_k) - \rho_k 2^{-(\bar{j}-1)} \frac{\gamma}{4} \|Dh(\bar{x})\|. \end{aligned}$$

Wegen $x_k \in U(\bar{k})$, $s_k \in D(\gamma_k, x_k) \subseteq D(\gamma, x_k)$ folgt daher aus (5.4.1.9) sofort

$$\rho_k 2^{-(\bar{j}-1)} > \lambda.$$

Zusammen mit (5.4.1.12), (5.4.1.13) ergibt dies

$$h(x_{k+1}) \leq h_k(\rho_k 2^{-\bar{j}}) \leq h(x_k) - \frac{\lambda\gamma}{16} \|Dh(\bar{x})\| = h(x_k) - \varepsilon_2$$

mit einem von k unabhängigen $\varepsilon_2 > 0$.

Für $\varepsilon = \min(\varepsilon_1, \varepsilon_2)$ gilt daher für alle $k \geq k_0$

$$h(x_{k+1}) \leq h(x_k) - \varepsilon,$$

im Widerspruch zu $h(x_k) \geq h(\bar{x})$ für alle k . Deshalb ist $\bar{x}$ stationärer Punkt von h . $\square$

5.4.2 Anwendung auf das modifizierte Newton-Verfahren

Um die Gleichung $f(x) = 0$ zu lösen, setzen wir nun $h(x) := f(x)^T f(x)$ und wenden eines der Verfahren (5.4.1.3) oder (5.4.1.7) an, um $h(x)$ zu minimieren. Als Suchrichtung s_k im Punkt x_k wählen wir gerade die normierte Newtonrichtung

$$s_k = \frac{d_k}{\|d_k\|}, \quad d_k := Df(x_k)^{-1} f(x_k),$$

die jedenfalls dann definiert ist, wenn $Df(x_k)^{-1}$ existiert. Hier ist $\|\cdot\|$ die euklidische Norm. Um die Anwendung der Sätze des letzten Abschnitts vorzubereiten, zeigen wir zunächst, daß für jedes x , für das

$$d = d(x) := Df(x)^{-1} f(x), \quad s = s(x) = \frac{d}{\|d\|}$$

existiert [d. h. $Df(x)^{-1}$ existiert und $f(x) \neq 0$], gilt

$$(5.4.2.1) \quad s \in D(\gamma, x), \quad \text{für alle } 0 < \gamma \leq \bar{\gamma}(x), \quad \bar{\gamma}(x) := \frac{1}{\text{cond}(Df(x))}.$$

Hier sind $\|Df(x)\| := \text{lub}(Df(x))$, $\text{cond}(Df(x)) := \|Df(x)^{-1}\| \|Df(x)\|$ (s. 4.4) bzgl. der euklidischen Norm zu nehmen.

Beweis: Wegen $h(x) = f(x)^T f(x)$ erhält man

$$(5.4.2.2) \quad Dh(x) = 2f^T(x) Df(x).$$

Nun gelten die Abschätzungen

$$\begin{aligned}\|f^T(x)Df(x)\| &\leq \|Df(x)\| \|f(x)\|, \\ \|Df(x)^{-1}f(x)\| &\leq \|Df(x)^{-1}\| \|f(x)\|\end{aligned}$$

und daher

$$\frac{Dh(x)s}{\|Dh(x)\|} = \frac{f(x)^T Df(x) Df(x)^{-1} f(x)}{\|Df(x)^{-1} f(x)\| \|f^T(x) Df(x)\|} \geq \frac{1}{\text{cond}(Df(x))} > 0.$$

Für alle γ mit $0 < \gamma \leq 1/\text{cond}(Df(x))$ gilt also $s \in D(\gamma, x)$ nach Definition (5.4.1.1) von $D(\gamma, x)$. $\square$

Als Konsequenz von (5.4.2.2) notieren wir: Falls $Df(x)^{-1}$ existiert, gilt

$$(5.4.2.3) \quad Dh(x) = 0 \Leftrightarrow f(x) = 0,$$

x ist stationärer Punkt von h , genau dann, wenn x Nullstelle von f ist. Wir betrachten nun das folgende modifizierte Newton-Verfahren (vgl. (5.4.1.7)):

(5.4.2.4) **Algorithmus**

- a) Man wähle einen Startwert $x_0 \in \mathbb{R}^n$.
- b) Für alle $k = 0, 1, \dots$ bestimme man folgendermaßen x_{k+1} aus x_k :
 - α) Falls $f(x_k) = 0$, stop. Sonst berechne man

$$d_k := Df(x_k)^{-1} f(x_k), \quad \gamma_k := \frac{1}{\text{cond}(Df(x_k))},$$

und setze $h_k(\tau) := h(x_k - \tau d_k)$, $h(x) := f(x)^T f(x)$. Man bestimme die kleinste ganze Zahl $j \geq 0$ mit

$$h_k(2^{-j}) \leq h_k(0) - 2^{-j} \frac{\gamma_k}{4} \|d_k\| \|Dh(x_k)\|.$$

- β) Man bestimme λ_k und damit

$$x_{k+1} := x_k - \lambda_k d_k,$$

so daß gilt

$$h(x_{k+1}) = \min_{0 \leq i \leq j} h_k(2^{-i}).$$

Analog zu Satz (5.4.1.8.) hat man nun

(5.4.2.5) **Satz:** Gegeben sei eine Funktion $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ und ein Punkt $x_0 \in \mathbb{R}^n$ mit den folgenden Eigenschaften:

- a) Die Menge $K := \{x | h(x) \leq h(x_0)\}$, $h(x) := f(x)^T f(x)$, sei kompakt.
- b) f sei auf einer Umgebung von K stetig differenzierbar.
- c) Für alle $x \in K$ existiere $Df(x)^{-1}$.

Dann ist durch (5.4.2.4) die Folge $\{x_k\}$ wohldefiniert und es gilt

1. $x_k \in K$ für alle $k = 0, 1, \dots$, und $\{x_k\}$ besitzt mindestens einen Häufungspunkt $\bar{x} \in K$.
2. Jeder Häufungspunkt $\bar{x}$ von $\{x_k\}$ ist Nullstelle von f : $f(\bar{x}) = 0$.

Beweis: Nach Konstruktion ist $h(x_k)$ monoton fallend

$$h(x_0) \geq h(x_1) \geq \dots,$$

also gilt $x_k \in K$. Ferner sei $f(x_k) \neq 0$ für alle k . Wegen Voraussetzung c) sind d_k und γ_k wohldefiniert, wenn x_k definiert ist. Wegen (5.4.2.1) gilt für $s_k := d_k / \|d_k\|$

$$s_k \in D(\gamma_k, x_k).$$

Wie im Anschluß an (5.4.1.7) folgt dann, daß es ein $j \geq 0$ mit den in (5.4.2.4) angegebenen Eigenschaften gibt, d. h. x_{k+1} ist mit x_k definiert.

Nun wird Verfahren (5.4.2.4) formal mit dem Verfahren (5.4.1.7) identisch, wenn man

$$\sigma_k := \frac{\|d_k\|}{\|Dh(x_k)\|}$$

setzt. Der Rest des Satzes folgt daher aus Satz (5.4.1.8.), sobald gezeigt ist, daß

$$\inf_k \gamma_k > 0, \quad \inf_k \sigma_k > 0.$$

Nun ist nach Voraussetzung b), c), $Df(x)^{-1}$ auf der kompakten Menge K stetig, also auch $\text{cond}(Df(x))$. Damit existiert.

$$\gamma := \frac{1}{\max_{x \in K} \text{cond}(Df(x))} > 0.$$

Wir nehmen o. B. d. A. an, daß kein x_k stationärer Punkt von h und damit wegen Voraussetzung c) und (5.4.2.3) keine Nullstelle von f ist. Es ist dann wegen $x_k \in K$, $k = 0, 1, \dots$

$$\inf \gamma_k \geq \gamma > 0.$$

Andererseits folgt wegen $f(x_k) \neq 0$ und (5.4.2.2) aus den Abschätzungen

$$\|d_k\| = \|Df(x_k)^{-1} f(x_k)\| \geq \frac{1}{\|Df(x_k)\|} \|f(x_k)\|,$$

$$\|Dh(x_k)\| \leq 2 \cdot \|Df(x_k)\| \|f(x_k)\|$$

sofort

$$\sigma_k \geq \frac{1}{2 \cdot \|Df(x_k)\|^2} \geq \sigma > 0,$$

weil $\|Df(x)\|$ für $x \in K$ wegen der Kompaktheit von K nach oben beschränkt ist. Damit treffen alle Resultate von Satz (5.4.1.8) bzw. (5.4.1.4) auf die Folge $\{x_k\}$ zu. Da wegen Voraussetzung c) und (5.4.2.3) jeder stationäre Punkt $\bar{x}$ von h auch Nullstelle von f ist, ist Satz (5.4.2.5) bewiesen. $\square$

Das Verfahren (5.4.2.4) erfordert in jedem Iterationsschritt die Berechnung von γ_k , d. h. von $\text{cond}(Df(x_k))$, und von $\|Df(x_k)\|$.

Der Beweis zu (5.4.1.8) zeigt, daß es genügt, die γ_k durch eine beliebige kleine untere Schranke $\gamma > 0$, $\gamma_k \geq \gamma > 0$, zu ersetzen. Deshalb werden die λ_k in der Praxis so bestimmt, daß gilt:

$$h_k(2^{-j}) < h_k(0).$$

Da hierbei nur $\gamma_k > 0$ verlangt wird, läßt sich für diese Variante mit obigen Methoden nicht die Konvergenz zeigen.

Eine weitere Bemerkung gilt dem Verhalten des Verfahrens (5.4.2.4) in einer hinreichend kleinen Umgebung einer Nullstelle $\bar{x}$ mit nichtsingulärem $Df(\bar{x})$. Das Verfahren wählt dort automatisch $\lambda_k = 1$ und es wird daher wie das gewöhnliche Newton-Verfahren lokal quadratisch konvergieren: Wegen $\lim_{k \rightarrow \infty} x_k = \bar{x}$ und $f(\bar{x}) = 0$ gibt es nämlich eine Umgebung $V_1(\bar{x})$ von $\bar{x}$, in der für jeden Iterationsschritt $z_k \rightarrow z_{k+1}$ des gewöhnlichen Newton-Verfahrens die Bedingungen

$$(5.4.2.6) \quad \|z_{k+1} - \bar{x}\| \leq a \|z_k - \bar{x}\|^2$$

und

$$(5.4.2.7) \quad 32a^2c^2 \|z_k - \bar{x}\|^2 \leq 1, \quad c := \text{cond}(Df(\bar{x})),$$

gilt. Wegen

$$\|x - \bar{x}\| \|Df(\bar{x})^{-1}\| \leq \|Df(\bar{x})(x - \bar{x})\| \leq \|Df(\bar{x})\| \|x - \bar{x}\|$$

und der Taylorentwicklung von f um $\bar{x}$

$$f(x) = Df(\bar{x})(x - \bar{x}) + o(\|x - \bar{x}\|)$$

gibt es eine Umgebung $V_2(\bar{x})$ mit

$$\frac{1}{4} \|Df(\bar{x})^{-1}\|^{-2} \|x - \bar{x}\|^2 \leq h(x) \leq 4 \|Df(\bar{x})\|^2 \|x - \bar{x}\|^2$$

für alle $x \in V_2(\bar{x})$.

Man wähle nun eine Umgebung $U(\bar{x}) \subset V_1(\bar{x}) \cap V_2(\bar{x})$ und ein k_0 , so daß $x_k \in U(\bar{x})$ für $k \geq k_0$ gilt. Dies möglich wegen $\lim_{k \rightarrow \infty} x_k = \bar{x}$. Mit

$$x_{k+1} := x_k - Df(x_k)^{-1} f(x_k), \quad \text{d. h.} \quad \lambda_k = 1 \quad \text{in (5.4.2.4),}$$

und unter Verwendung von (5.4.2.6), (5.4.2.7) erhält man folgende Ungleichungen

$$\begin{aligned} h(x_{k+1}) &\leq 4 \|Df(\bar{x})\|^2 \|x_{k+1} - \bar{x}\|^2 \leq 16a^2 c^2 \|x_k - \bar{x}\|^2 h(x_k) \\ &\leq h(x_k) (1 - \tfrac{1}{2}). \end{aligned}$$

Wegen (5.4.2.4)b) α) gilt:

$$\gamma_k \|d_k\| \|Df(x_k)\| \leq 2\gamma_k \|Df(x_k)^{-1}\| \|Df(x_k)\| h(x_k) = 2h(x_k).$$

Damit erhält man die Abschätzung

$$h(x_{k+1}) \leq h(x_k) (1 - \tfrac{1}{2}) \leq h(x_k) - \frac{\gamma_k}{4} \|d_k\| \|Dh(x_k)\|,$$

d. h. es gibt ein k_0 , so daß für alle $k \geq k_0$ im Algorithmus (5.4.2.4) bei der Wahl von λ_k jeweils $j = 0$, $\lambda_k = 1$, gewählt wird. Das Verfahren (5.4.2.4) ist somit in einer hinreichend kleinen Umgebung von $\bar{x}$ mit dem gewöhnlichen Newton-Verfahren identisch und konvergiert lokal quadratisch.

Die Voraussetzungen a)–c) in Satz (5.4.2.5) beschreiben Funktionen, für die das Verfahren (5.4.2.4) anwendbar ist. In Aufgabe 15 werden zwei Beispiele von Funktionenklassen angegeben, die die Voraussetzungen a)–c) von (5.4.2.5) erfüllen.

5.4.3. Hinweise zur praktischen Realisierung des modifizierten Newton-Verfahrens. Ein Rang-1-Verfahren von Broyden

Das Newton-Verfahren zur Lösung des Gleichungssystems $f(x) = 0$, $f = \mathbb{R}^n \rightarrow \mathbb{R}^n$, ist auch in seiner modifizierten Form (5.4.2.4) noch recht aufwendig, weil man in jedem Iterationsschritt die Funktionalmatrix $Df(x_k)$ berechnen und das lineare System $Df(x_k)d = f(x_k)$ lösen muß. Meistens ist die Auswertung von expliziten Formeln für $Df(x)$ viel zu kompliziert, ja man hat häufig nicht einmal explizite Ausdrücke für $Df(x)$ zur Verfügung. In diesen Fällen liegt es nahe, die Matrix $Df(x) = (\partial f(x)/\partial x^1, \dots, \partial f(x)/\partial x^n)$ für ein gegebenes $x = x_k$ durch eine Matrix

$$(5.4.3.1) \quad \Delta f(x) = (\Delta_1 f, \dots, \Delta_n f)$$

mit

$$\begin{aligned}\Delta_i f(x) &:= \frac{f(x^1, \dots, x^i + h_i, \dots, x^n) - f(x^1, \dots, x^i, \dots, x^n)}{h_i} \\ &= \frac{f(x + h_i e_i) - f(x)}{h_i}\end{aligned}$$

zu ersetzen, d. h. man ersetzt die partiellen Ableitungen $\partial f / \partial x^i$ durch geeignete Differenzquotienten $\Delta_i f$. Nach Wahl der Schrittweiten h_i kann man so $\Delta f(x)$ mittels n weiterer Funktionsauswertungen von f berechnen. Bei der Wahl der h_i ergeben sich aber folgende Schwierigkeiten: Wenn h_i zu groß ist, ist $\Delta f(x)$ nur eine schlechte Approximation an $Df(x)$, so daß die Iteration

$$(5.4.3.2) \quad x_{k+1} = x_k - \lambda_k \Delta f(x_k)^{-1} f(x_k)$$

wesentlich schlechter konvergiert als (5.4.2.4), wenn sie überhaupt konvergiert. Wählt man h_i zu klein, so wird $f(x + h_i e_i) \approx f(x)$ und bei der Bildung von $\Delta_i f(x)$ tritt Auslöschung auf, so daß selbst kleine Fehler bei der Berechnung von $f(x + h_i e_i)$, $f(x)$ das Resultat stark verfälschen.

Folgender Kompromiß hat sich in der Praxis bewährt: Nimmt man an, daß man $f(x)$ mit einem relativen Fehler der Größenordnung der Maschinengenauigkeit eps berechnen kann, genügt es h_i so zu bemessen, daß $f(x)$ und $f(x + h_i e_i)$ bei t -stelliger Rechnung etwa die ersten $t/2$ Stellen gemeinsam haben,

$$|h_i| \|\Delta_i f(x)\| \approx \sqrt{\text{eps}} \|f(x)\|.$$

In diesem Fall ist der Einfluß der Auslöschung noch erträglich.

Bei komplizierten Funktionen $f(x)$ ist aber selbst die Berechnung von $\Delta f(x_k)$ in jedem Iterationsschritt $x_k \rightarrow x_{k+1}$ zu aufwendig, weil sie n zusätzliche Funktionsauswertungen erfordert. Man versucht deshalb, die Matrix $\Delta f(x_k)$ durch andere noch einfacher zu berechnende Matrizen B_k zu ersetzen. Geeignete Matrizen B_k erhält man mit Hilfe eines Resultates von Broyden (1965):

(5.4.3.3) **Satz:** A und B seien beliebige $n \times n$ -Matrizen, $b \in \mathbb{R}^n$ und $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ die affine Abbildung $F(u) := Au + b$. Ferner seien x und $x' \in \mathbb{R}^n$ zwei verschiedene Vektoren und p, q definiert durch

$$p := x' - x, \quad q := F(x') - F(x) = Ap.$$

Dann gilt für die $n \times n$ -Matrix B' ,

$$B' := B + \frac{1}{p^T p} (q - Bp) p^T,$$

bezüglich der euklidischen Norm die Abschätzung

$$\text{lub}_2(B' - A) \leq \text{lub}_2(B - A)$$

sowie die Gleichung $B'p = Ap = q$.

Beweis: Aus der Definition von B' folgt sofort $(B' - A)p = 0$. Jeder Vektor $u \in \mathbb{R}^n$ mit $\|u\|_2 = 1$ besitzt eine Orthogonalzerlegung der Form

$$u = \alpha p + v, \quad v^T p = 0, \quad \|v\|_2 \leq 1, \quad \alpha \in \mathbb{R}.$$

Es folgt daher nach Definition von B' für $\|u\|_2 = 1$:

$$\begin{aligned} \|(B' - A)u\|_2 &= \|(B' - A)v\|_2 = \|(B - A)v\|_2 \\ &\leq \text{lub}_2(B - A)\|v\|_2 \leq \text{lub}_2(B - A), \end{aligned}$$

und daher

$$\text{lub}_2(B' - A) = \sup_{\|u\|_2=1} \|(B' - A)u\|_2 \leq \text{lub}_2(B - A). \quad \square$$

Dieses Resultat besagt, daß die Funktionalmatrix $DF(x) \equiv A$ einer affinen Funktion F durch B' mindestens ebenso gut approximiert wird wie durch B , und daß darüber hinaus B' und $DF(x) \equiv A$ darin übereinstimmen, daß sie den Vektor p in denselben Vektor q abbilden. Da eine differenzierbare nichtlineare Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ in einer kleinen Umgebung einer Nullstelle $\bar{x}$ von $f(x) = 0$ durch eine affine Funktion approximiert werden kann, liegt es nahe, die Konstruktion von B' aus B auch im nichtlinearen Fall zu versuchen. Man erhält so statt (5.4.3.2), (5.4.2.4) eine Rekursionsvorschrift der Form

$$\begin{aligned} d_k &:= B_k^{-1} f(x_k), \\ x_{k+1} &:= x_k - \lambda_k d_k, \\ (5.4.3.4) \quad p_k &:= x_{k+1} - x_k, \quad q_k := f(x_{k+1}) - f(x_k), \\ B_{k+1} &:= B_k + \frac{1}{p_k^T p_k} (q_k - B_k p_k) p_k^T. \end{aligned}$$

Die Rekursionsformel für B_{k+1} stammt von Broyden; wegen $\text{Rang}(B_{k+1} - B_k) \leq 1$ heißt das Verfahren *Rang-1-Verfahren*. Die Schrittweiten λ_k bestimmt man durch näherungsweise Minimierung von $\|f(x)\|^2$,

$$\|f(x_{k+1})\|^2 \approx \min_{\lambda \geq 0} \|f(x_k - \lambda d_k)\|^2,$$

etwa durch ein endliches Suchverfahren wie in (5.4.2.4)

$$(5.4.3.5) \quad \lambda_k := 2^{-j}, \quad j := \min\{i \geq 0 \mid \|f(x_k - 2^{-i} d_k)\| < \|f(x_k)\|\}.$$

Eine gute Startmatrix B_0 kann man sich durch Differenzenbildung verschaffen, $B_0 = \Delta f(x_0)$. Es ist aber nicht sinnvoll, ausgehend von B_0 alle weiteren Matrizen B_k mit Hilfe von (5.4.3.4) rekursiv zu berechnen: Erfahrungsgemäß ist es besser, die Rekursionsformel (5.4.3.4) nur für die Schritte $x_k \rightarrow x_{k+1}$ anzuwenden, für die $0.5 \leq \lambda_k \leq 1$ gilt; andernfalls setzt man $B_{k+1} := \Delta f(x_{k+1})$ (Neustart des Verfahrens). Das Bisektionsverfahren (5.4.3.5) hat den Vorteil, automatisch $\lambda_k = 1$ zu wählen, wenn $\|f(x_{k+1})\| < \|f(x_k - d_k)\|$ gilt. In diesem Zusammenhang ist ein Resultat von Broyden, Dennis und Moré (1973) über das lokale Konvergenzverhalten des Verfahrens (5.4.3.4) mit $\lambda_k = 1$ für alle $k \geq 0$ in der Umgebung $U(\bar{x})$ einer Nullstelle $\bar{x}$ von $f(x) = 0$ bemerkenswert:

Unter den Voraussetzungen

- a) $Df(x)$ existiert für $x \in U(\bar{x})$ und ist stetig,
- b) $\|Df(x) - Df(\bar{x})\| \leq \Lambda \|x - \bar{x}\|$ für $x \in U(\bar{x})$,
- c) $Df(\bar{x})^{-1}$ existiert,

kann man folgendes zeigen: Das Verfahren (5.4.3.4) mit der Schrittweitenwahl $\lambda_k = 1$ für alle $k \geq 0$ existiert (d. h. alle B_k sind invertierbar) für alle Startwerte x_0, B_0 , für die $\|x_0 - \bar{x}\|$ und $\|B_0 - Df(\bar{x})\|$ genügend klein sind, und liefert eine Folge $\{x_k\}$, die *superlinear* gegen $\bar{x}$ konvergiert,

$$\lim_{k \rightarrow \infty} \|x_{k+1} - \bar{x}\| / \|x_k - \bar{x}\| = 0,$$

wenn $x_k \neq \bar{x}$ für alle $k \geq 0$.

Die Richtung $d_k = B_k^{-1} f(x_k)$ (5.4.3.4) berechnet man zweckmäßigerweise durch Lösen des linearen Gleichungssystems $B_k d_k = f(x_k)$, etwa mit Hilfe einer Zerlegung $F_k B_k = R_k$ von B_k des Typs (4.9.1). Dies ist vorteilhaft, weil man eine Zerlegung $F_k B_k = R_k$ von B_k leicht mit Hilfe der Techniken von Abschnitt 4.9 (Teilaufgabe 1) zu einer entsprechenden Zerlegung $F_{k+1} B_{k+1} = R_{k+1}$ der nächsten Matrix B_{k+1} modifizieren kann, da man B_{k+1} aus B_k durch Addition einer Matrix von Rang 1 erhält.

Für Minimierungsprobleme lassen sich ähnliche Überlegungen anstellen. Sei $h: \mathbb{R}^n \rightarrow \mathbb{R}$ eine Funktion. Die Minima von h sind Nullstellen des Gradienten $f(x) := \nabla h(x)$. Die Jacobi-Matrix $Df(x)$ ist die *Hesse-Matrix* $\nabla^2 h(x)$, die i. a. an einem strikt lokalen Minimum $\bar{x}$ von h positiv definit sein wird. Bei einer Verallgemeinerung des Newton-Verfahrens

$$x_{k+1} = x_k - \nabla^2 h(x_k) f(x_k)$$

wird man die Matrix $\nabla^2 h(x_k)$ durch leichter zu berechnende Matrizen B_k approximieren. Es liegt nahe, dazu positiv definite Matrizen B_k zu verwenden. Dementsprechend sollte man für die Berechnung von B_{k+1} aus

B_k statt (5.4.3.4) update Formeln verwenden, die eine positiv definite Matrix B_k wieder in eine positiv definite Matrix B_{k+1} transformieren. Es gibt eine Reihe solcher Formeln, die meisten sind *Rang-2-Verfahren*, die in zwei Rang-1-Stufen zerfallen

$$\begin{aligned} B_{k+1/2} &:= B_k + \alpha_k u_k u_k^T, & \alpha_k &> 0 \\ B_{k+1} &:= B_{k+1/2} - \beta_k v_k v_k^T, & \beta_k &> 0, \end{aligned}$$

mit geeigneten positiven Zahlen α_k, β_k und Vektoren u_k, v_k . Wegen der positiven Definitheit der $B_k, B_{k+1/2}, B_{k+1}$ liegt es nahe, Cholesky-Zerlegungen (s. 4.3) zum Lösen der Gleichungssysteme $B_k d = f(x_k)$ zu nehmen. Dabei kann man mit den Modifikationstechniken von Abschnitt 4.9. aus dem Choleskyfaktor von B_k rekursiv die Choleskyfaktoren von $B_{k+1/2}$ und B_{k+1} berechnen. Nähere Einzelheiten findet man in Gill, Golub, Murray und Saunders (1974). Rang-2-Verfahren zur Bestimmung von positiv definiten Approximationen H_k an die Inverse $(\nabla^2 h(x_k))^{-1}$ der Hesse-Matrix sind im Abschnitt 5.11 beschrieben.

5.5 Nullstellenbestimmung für Polynome. Das Newtonsche Verfahren

In den folgenden Abschnitten 5.5–5.8 beschäftigen wir uns mit Fragen der Nullstellenbestimmung bei Polynomen und einigen einschlägigen Verfahren. Es sei darauf hingewiesen, daß es neben den besprochenen Methoden noch eine Fülle weiterer Verfahren zur Berechnung von Polynomnullstellen gibt, z. B. Bauer (1956), Jenkins und Traub (1970), Nickel (1966), Henrici (1974).

Die praktische Bedeutung von Verfahren zur Nullstellenbestimmung von Polynomen wird häufig überschätzt. Bei den in der Praxis vorkommenden Polynomen handelt es sich in der Regel um charakteristische Polynome von Matrizen. Die gesuchten Nullstellen sind also Eigenwerte von Matrizen, die man besser mit den in Kapitel 6 beschriebenen Methoden direkt berechnet.

Wir wollen besprechen, wie das Newton-Verfahren zur Bestimmung der Nullstellen eines Polynoms $p(x)$ verwandt werden kann. In jedem Schritt des Newton-Verfahrens

$$x_{k+1} := x_k - \frac{p(x_k)}{p'(x_k)}$$

hat man den Wert des Polynoms p und seiner ersten Ableitung an der Stelle $x = x_k$ zu berechnen. Ist das Polynom p in der Form

$$p(x) = a_0x^n + \cdots + a_n$$

gegeben, so kann $p(x_k)$ und $p'(x_k)$ auf folgende Weise berechnet werden: Es ist für $x = \xi$

$$p(\xi) = (\cdots (a_0\xi + a_1)\xi + \cdots)\xi + a_n.$$

Für die Faktoren von ξ ergeben sich die Formeln

$$(5.5.1) \quad \begin{aligned} b_0 &:= a_0 \\ b_i &:= b_{i-1}\xi + a_i \quad \text{für } i = 1, 2, \dots, n. \end{aligned}$$

Der Wert des Polynoms p an der Stelle ξ ist dann

$$p(\xi) = b_n.$$

Der Algorithmus (5.5.1) heißt *Hornerschema*. Die Koeffizienten b_i erhält man auch, wenn man versucht, das Polynom $p(x)$ durch $(x - \xi)$ zu dividieren. Für das Polynom

$$p_1(x) := b_0x^{n-1} + b_1x^{n-2} + \cdots + b_{n-1}$$

gilt nämlich

$$(5.5.2) \quad p(x) = (x - \xi)p_1(x) + b_n,$$

wie man durch Koeffizientenvergleich sofort feststellt. Darüber hinaus folgt aus (5.5.2) durch Differentiation nach x für $x = \xi$

$$p'(\xi) = p_1(\xi),$$

d. h. die erste Ableitung $p'(\xi)$ kann ebenfalls mit Hilfe des Hornerschemas als Wert des Polynoms $p_1(x)$ für $x = \xi$ berechnet werden:

$$p'(\xi) = (\cdots (b_0\xi + b_1)\xi + \cdots)\xi + b_{n-1}.$$

Häufig ist jedoch das Polynom $p(x)$ nicht in der Form

$$p(x) = a_0x^n + \cdots + a_n$$

gegeben, sondern auf andere Weise. Besonders wichtig ist der Fall, daß $p(x)$ das charakteristische Polynom einer reellen symmetrischen Tridiagonalmatrix

$$J = \begin{bmatrix} \alpha_1 & \beta_2 & & 0 \\ \beta_2 & \cdot & \cdot & \\ & \cdot & \cdot & \cdot \\ & & \cdot & \cdot & \beta_n \\ 0 & & & \beta_n & \alpha_n \end{bmatrix}$$

ist. Bezeichnet man mit $p_i(x)$ das charakteristische Polynom

$$p_i(x) := \det \begin{bmatrix} \alpha_1 - x & \beta_2 & & 0 \\ & \beta_2 & \ddots & \\ & & \ddots & \ddots \\ 0 & & & \beta_i & \alpha_i - x \end{bmatrix}$$

der i -ten Hauptabschnittsmatrix von J , so gilt die Rekursionsformel

$$\begin{aligned} p_0(x) &:= 1, \\ p_1(x) &:= (\alpha_1 - x) \cdot 1, \\ (5.5.3) \quad p_i(x) &:= (\alpha_i - x)p_{i-1}(x) - \beta_i^2 p_{i-2}(x), \quad i = 2, 3, \dots, n, \\ p(x) &:= \det(J - xI) := p_n(x). \end{aligned}$$

Für jedes gegebene $x = \xi$ kann $p(\xi)$ mit (5.5.3) bei bekannten α_i, β_i berechnet werden. Für die Berechnung von $p'(\xi)$ erhält man durch Differentiation von (5.5.3) eine ähnliche Rekursionsformel

$$\begin{aligned} (5.5.4) \quad p'_0(x) &:= 0, \quad p'_1(x) := -1, \\ p'_i(x) &:= -p_{i-1}(x) + (\alpha_i - x)p'_{i-1}(x) - \beta_i^2 p'_{i-2}(x), \quad i = 2, 3, \dots, n, \\ p'_n(x) &:= p'_n(x), \end{aligned}$$

die zusammen mit (5.5.3) ausgewertet werden kann.

Wie sich bei der allgemeinen Diskussion des Newton-Verfahrens in 5.3 herausstellte, kann man i.a. nur dann die Konvergenz der x_k gegen eine Nullstelle ξ garantieren, wenn der Startwert x_0 genügend nahe bei ξ liegt. Bei unglücklicher Wahl von x_0 kann auch bei Polynomen p die Folge x_k divergieren. Ist z.B. p ein reelles Polynom ohne reelle Nullstellen (z.B. $p(x) = x^2 + 1$), so kann das Newton-Verfahren für keinen reellen Startwert x_0 konvergieren. Obwohl man bisher kein einfaches Rezept kennt, wie man bei einem beliebigen Polynom einen Startwert x_0 findet, der die Konvergenz des Newton-Verfahrens sichert, gibt es eine einfache Regel für die Wahl von x_0 in einem wichtigen Spezialfall. Dieser Fall liegt vor, wenn $p(x)$ ein reelles Polynom ist, dessen Nullstellen $\xi_i, i = 1, 2, \dots, n$, alle reell sind:

$$\xi_1 \geq \xi_2 \geq \dots \geq \xi_n.$$

In Abschnitt 5.6, Satz (5.6.5), wird gezeigt, daß z.B. die durch (5.5.3) gegebenen Polynome für reelle α_i, β_i diese Eigenschaft besitzen. In diesem Fall gilt der

(5.5.5) **Satz:** Ist $p(x)$ ein reelles Polynom n -ten Grades, $n \geq 2$, das nur reelle Nullstellen ξ_i mit

$$\xi_1 \geq \xi_2 \geq \cdots \geq \xi_n$$

besitzt, so liefert das Newton-Verfahren für alle Startwerte $x_0 > \xi_1$ eine gegen ξ_1 konvergente, streng monoton fallende Folge x_k von Näherungswerten.

Beweis: Sei o. B. d. A. $p(x_0) > 0$. Da $p(x)$ sein Vorzeichen für $x > \xi_1$ nicht ändert, gilt

$$p(x) = a_0 x^n + \cdots + a_n > 0$$

für $x > \xi_1$ und deshalb $a_0 > 0$. Nach dem Satz von Rolle besitzt p' mindestens $n - 1$ reelle Nullstellen α_i mit

$$\xi_1 \geq \alpha_1 \geq \xi_2 \geq \alpha_2 \geq \cdots \geq \alpha_{n-1} \geq \xi_n.$$

Wegen $\text{Grad } p' = n - 1 \geq 1$ sind dies sämtliche Nullstellen von p' und es folgt wegen $a_0 > 0$ auch $p'(x) > 0$ für $x > \alpha_1$. Durch nochmalige Anwendung des Satzes von Rolle folgt ebenso wegen $n \geq 2$

$$(5.5.6) \quad \begin{aligned} p''(x) &> 0 \quad \text{für } x > \alpha_1, \\ p'''(x) &\geq 0 \quad \text{für } x \geq \alpha_1. \end{aligned}$$

Für $x \geq \alpha_1$ sind also p und p' konvexe Funktionen.

Ist nun $x_k > \xi_1$ so folgt sofort wegen $p'(x_k) > 0$, $p(x_k) > 0$

$$x_{k+1} = x_k - \frac{p(x_k)}{p'(x_k)} < x_k.$$

Wir müssen noch $x_{k+1} > \xi_1$ zeigen: Wegen (5.5.6) und $x_k > \xi_1 \geq \alpha_1$ folgt durch Taylorentwicklung

$$\begin{aligned} 0 = p(\xi_1) &= p(x_k) + (\xi_1 - x_k)p'(x_k) + \frac{1}{2}(\xi_1 - x_k)^2 p''(\delta), \quad \xi_1 < \delta < x_k, \\ &> p(x_k) + (\xi_1 - x_k)p'(x_k), \end{aligned}$$

also wegen $p(x_k) = p'(x_k)(x_k - x_{k+1})$,

$$0 > p'(x_k)(x_k - x_{k+1} + \xi_1 - x_k) = p'(x_k)(\xi_1 - x_{k+1}).$$

Aus $p'(x_k) > 0$ folgt schließlich $x_{k+1} > \xi_1$ und damit die Behauptung des Satzes. $\square$

Für später halten wir als Konsequenz von (5.5.6) fest:

(5.5.7) **Lemma:** Ist $p(x) = a_0 x^n + \cdots + a_n$ ein reelles Polynom n -ten Grades mit $a_0 > 0$, $n \geq 2$, dessen Nullstellen sämtlich reell sind, so ist $p'''(x) \geq 0$ für $x \geq \alpha_1$, also $p'(x)$ für $x \geq \alpha_1$ eine konvexe Funktion. Hier ist α_1 die größte Nullstelle von $p'(x)$.

Es stellt sich nun das Problem, eine Zahl $x_0 > \xi_1$ zu finden. Zu diesem Zweck kann man folgende Abschätzungen für die Nullstellen eines Polynoms benutzen, die erst später im Abschnitt 6.9 teilweise bewiesen werden (siehe auch Householder (1970), weitere Abschätzungen findet man bei Marden (1949)).

(5.5.8) **Satz:** Für alle Nullstellen ξ_i eines beliebigen komplexen Polynoms

$$p(x) = a_0 x^n + \dots + a_n \quad \text{mit } a_0 \neq 0$$

gilt

$$|\xi_i| \leq \max \left\{ \left| \frac{a_n}{a_0} \right|, 1 + \left| \frac{a_{n-1}}{a_0} \right|, \dots, 1 + \left| \frac{a_1}{a_0} \right| \right\},$$

$$|\xi_i| \leq \max \left\{ 1, \sum_{j=1}^n \left| \frac{a_j}{a_0} \right| \right\},$$

$$|\xi_i| \leq \max \left\{ \left| \frac{a_n}{a_{n-1}} \right|, 2 \left| \frac{a_{n-1}}{a_{n-2}} \right|, \dots, 2 \left| \frac{a_1}{a_0} \right| \right\},$$

$$|\xi_i| \leq \sum_{j=0}^{n-1} \left| \frac{a_{j+1}}{a_j} \right|,$$

$$|\xi_i| \leq 2 \max \left\{ \left| \frac{a_1}{a_0} \right|, \sqrt{\left| \frac{a_2}{a_0} \right|}, \sqrt[3]{\left| \frac{a_3}{a_0} \right|}, \dots, \sqrt[n]{\left| \frac{a_n}{a_0} \right|} \right\}.$$

Es sei darauf hingewiesen, daß quadratische Konvergenz nicht unbedingt schnelle Konvergenz bedeutet. Falls der Startwert x_0 weit von einer Wurzel entfernt ist, kann das Newton-Verfahren zu Beginn sehr sehr langsam konvergieren, wenn etwa x_0 zu groß gewählt wurde. Für großes x_k gilt nämlich

$$x_{k+1} = x_k - \frac{x_k^n + \dots}{n x_k^{n-1} + \dots} \approx x_k \left(1 - \frac{1}{n} \right).$$

Diese Beobachtung führt zu der Idee, das einfache Newton-Verfahren durch ein *Doppelschritt-Verfahren* zu ersetzen:

$$x_{k+1} = x_k - 2 \frac{p(x_k)}{p'(x_k)}, \quad k = 0, 1, 2, \dots$$

Natürlich besteht bei dieser Methode die Gefahr, daß man in der Situation von Satz (5.5.5) mit x_{k+1} über ξ_1 hinausschießt, falls x_k nahe bei ξ_1 liegt. Infolge einiger merkwürdiger Eigenschaften von Polynomen kann man jedoch dieses Überschießen benutzen, um eine Zahl y mit $\xi_1 \geq y > \xi_2$

zu finden, die man als Startwert für anschließende Newtonschritte zur Berechnung von ξ_2 verwenden kann. Es gilt nämlich

(5.5.9) **Satz:** Sei $p(x)$ ein reelles Polynom n -ten Grades, $n \geq 2$, mit nur reellen Nullstellen $\xi_1 \geq \xi_2 \geq \dots \geq \xi_n$. α_1 sei die größte Nullstelle von $p'(x)$: $\xi_1 \geq \alpha_1 \geq \xi_2$. Für $n = 2$ sei zusätzlich $\xi_1 > \xi_2$ vorausgesetzt.

Dann sind für alle $z > \xi_1$ die Zahlen

$$z' := z - \frac{p(z)}{p'(z)}, \quad y := z - 2 \frac{p(z)}{p'(z)}, \quad y' := y - \frac{p(y)}{p'(y)},$$

(s. Fig. 10) wohldefiniert und es gilt

$$(5.5.10a) \quad \alpha_1 < y,$$

$$(5.5.10b) \quad \xi_1 \leq y' \leq z'.$$




Fig. 10. Geometrische Interpretation der Doppelschrittmethode

Im Fall $n = 2$, $\xi_1 = \xi_2$ verifiziert man leicht $y = \xi_1$ für alle $z > \xi_1$.

Beweis: Sei wieder o. B. d. A. $p(z) > 0$ und $z > \xi_1$. Man betrachte die Größen Δ_0 , Δ_1 (s. Fig. 11) mit

$$\Delta_0 := p(z') = p(z') - p(z) - (z' - z)p'(z) = \int_z^{z'} [p'(t) - p'(z)]dt,$$

$$\Delta_1 := p(z') - p(y) - (z' - y)p'(y) = \int_y^{z'} [p'(t) - p'(y)]dt.$$

Δ_0 und Δ_1 lassen sich als Fläche über bzw. unter der Kurve $p'(t)$ deuten (Fig. 11).




Fig. 11. Interpretation von Δ_0 und Δ_1 als Fläche

Nun ist nach (5.5.7) unter den Voraussetzungen des Satzes $p'(x)$ für $x \geq \alpha_1$ eine konvexe Funktion. Es gilt daher wegen $z' - y = z - z' (> 0)$ wegen Satz (5.5.5))

$$(5.5.11) \quad \Delta_1 \leq \Delta_0, \quad \text{falls } y \geq \alpha_1,$$

wobei Gleichheit $\Delta_1 = \Delta_0$ genau dann vorliegt, wenn $p'(t)$ eine lineare Funktion ist, also p ein Polynom höchstens zweiten Grades ist. Wir unterscheiden nun drei Fälle, $y > \xi_1$, $y = \xi_1$, $y < \xi_1$.

Für $y > \xi_1$ folgt die Aussage des Satzes sofort aus Satz (5.5.5). Für $y = \xi_1$ zeigen wir als erstes $\xi_1 > \alpha_1 > \xi_2$, d. h. ξ_1 ist einfache Nullstelle von p . Andernfalls wäre $y = \xi_1 = \xi_2 = \alpha_1$ eine mehrfache Nullstelle und deshalb nach Voraussetzung $n \geq 3$, und es wäre in (5.5.11) $\Delta_1 < \Delta_0$. Dies führt zu einem Widerspruch

$$p(z') = p(z') - p(\xi_1) - (z' - \xi_1)p'(\xi_1) = \Delta_1 < \Delta_0 = p(z').$$

Es bleibt der Fall $y < \xi_1$ zu betrachten. Falls zusätzlich $\alpha_1 < y$, so ist $p'(y) \neq 0$, also y' wohldefiniert, und es gilt wegen $p(z) > 0$, $\xi_2 < \alpha_1 < y < \xi_1$, auch $p(y) < 0$, $p'(y) > 0$. Deshalb und wegen $p(y) = (y - y')p'(y)$, $\Delta_1 \leq \Delta_0$ hat man

$$\Delta_0 - \Delta_1 = p(y) + (z' - y)p'(y) = p'(y)(z' - y') \geq 0,$$

also $z' \geq y'$. Schließlich folgt durch Taylorentwicklung

$$p(\xi_1) = 0 = p(y) + (\xi_1 - y)p'(y) + \frac{1}{2}(\xi_1 - y)^2 p''(\delta), \quad y < \delta < \xi_1,$$

also wegen $p''(x) \geq 0$ für $x \geq \alpha_1$, $p(y) = (y - y')p'(y)$, $p'(y) > 0$,

$$0 \geq p(y) + (\xi_1 - y)p'(y) = p'(y)(\xi_1 - y')$$

und damit $\xi_1 \leq y'$. Damit ist Satz (5.5.9) unter der zusätzlichen Annahme $\alpha_1 < y$ bewiesen. Es bleibt zu zeigen, daß für jedes $z > \xi_1$ für das zugehörige $y = y(z)$ gilt

$$(5.5.12) \quad y = y(z) > \alpha_1.$$

Dazu unterscheiden wir wieder zwei Fälle, $\xi_1 > \alpha_1 > \xi_2$ und $\xi_1 = \alpha_1 = \xi_2$. Im ersten Fall gilt (5.5.12) für alle

$$\xi_1 < z < \xi_1 + (\xi_1 - \alpha_1),$$

denn aus Satz (5.5.5) folgt $z > z' \geq \xi_1$ und daher nach Definition von $y = y(z)$

$$y - \alpha_1 = z' - (z - z') - \alpha_1 > \xi_1 - (\xi_1 - \alpha_1) - \alpha_1 = 0.$$

Also gibt es ein $z_0 > \xi_1$ mit $y(z_0) > \alpha_1$. Nun ist $y(z)$ für $z > \xi_1$ eine stetige Funktion von z . Aus der Annahme, daß es ein $z_1 > \xi_1$ mit $y(z_1) \leq \alpha_1$ gibt, folgt nach dem Mittelwertsatz für stetige Funktionen, daß auch ein $\bar{z} \in [z_0, z_1]$ existiert mit $\bar{y} = y(\bar{z}) = \alpha_1$. Aus (5.5.11) folgt dann für $z = \bar{z}$

$$\Delta_1 = p(\bar{z}') - p(\bar{y}) - (\bar{z}' - \bar{y})p'(\bar{y}) = p(z') - p(\bar{y}) \leq \Delta_0 = p(z'),$$

also $p(\bar{y}) = p(\alpha_1) \geq 0$. Andererseits gilt $p(\alpha_1) < 0$, weil ξ_1 einfache Nullstelle ist und deshalb $p(x)$ an $x = \xi_1$ das Vorzeichen wechselt. Dieser Widerspruch beweist (5.5.12).

Damit bleibt (5.5.12) nur noch für den Fall $\xi_1 = \alpha_1 = \xi_2$ zu zeigen. In diesem Fall ist aber nach Voraussetzung $n \geq 3$. Sei o. B. d. A.

$$p(x) = x^n + a_1 x^{n-1} + \dots + a_n.$$

Dann gilt für $z \rightarrow \infty$ asymptotisch

$$\begin{aligned} z' &= z - \frac{p(z)}{p'(z)} = z - \frac{z}{n} \frac{1 + \frac{a_1}{z} + \dots + \frac{a_n}{z^n}}{1 + \frac{n-1}{n} \frac{a_1}{z} + \dots + \frac{a_{n-1}}{nz^{n-1}}} \\ &= z - \frac{z}{n} \left(1 + O\left(\frac{1}{z}\right) \right), \end{aligned}$$

also

$$\begin{aligned} y = y(z) &= z + 2(z' - z) = z - \frac{2z}{n} \left(1 + O\left(\frac{1}{z}\right) \right) \\ &= z \left(1 - \frac{2}{n} \right) + O(1). \end{aligned}$$

Wegen $n \geq 3$ wächst $y(z)$ mit $z \rightarrow +\infty$ über alle Grenzen, so daß es ein $z_0 > \xi_1$ gibt mit $y_0 = y(z_0) > \alpha_1$. Wenn (5.5.12) nicht für alle $z > \xi_1$ zutrifft, kann man wie eben ein $\bar{z} > \xi_1$ finden, so daß $\bar{z} = y(\bar{z}) = \alpha_1$ gilt. Der Fall $\bar{y} = \alpha_1 = \xi_1 = \xi_2$ wurde aber schon oben zum Widerspruch geführt. Damit ist Satz (5.5.9) vollständig bewiesen. $\square$

Der Satz hat folgende praktische Bedeutung: Ist $x_0 > \xi_1$ so gilt für die Näherungswerte x_k des „Doppelschrittverfahrens“

$$x_{k+1} = x_k - 2 \frac{p(x_k)}{p'(x_k)}$$

entweder $x_0 \geq x_1 \geq \dots \geq x_k \geq x_{k+1} \geq \dots \geq \xi_1$ und $\lim x_k = \xi_1$. In diesem Fall ändern die $p(x_k)$ ihr Vorzeichen nicht

$$p(x_0)p(x_k) \geq 0, \quad \text{für alle } k,$$

und die x_k konvergieren schneller als im ursprünglichen Newton-Verfahren gegen ξ_1 .

Oder es gibt ein erstes $x_{k_0} := y$ mit

$$\begin{aligned} p(x_0)p(x_k) &> 0, \quad \text{für } 0 \leq k < k_0, \\ p(x_0)p(x_{k_0}) &< 0. \end{aligned}$$

Dann gilt nach dem letzten Satz

$$x_0 > x_1 > \dots > x_{k_0-1} > \xi_1 > y = x_{k_0} > \alpha_1 > \xi_2.$$

In diesem Falle setze man die Iteration mit dem einfachen Newton-Verfahren und dem Startwert $y_0 := y$ fort,

$$y_{k+1} = y_k - \frac{p(y_k)}{p'(y_k)}, \quad k = 0, 1, \dots,$$

für das dann gilt

$$y_1 \geq y_2 \geq \dots \geq \xi_1, \quad \lim_{k \rightarrow \infty} y_k = \xi_1.$$

Nachdem man die größte Nullstelle ξ_1 von p bestimmt hat, hat man das Problem, die weiteren Nullstellen $\xi_2, \xi_3, \dots, \xi_n$ zu bestimmen. Naheliegend

ist folgende Methode: Man „dividiere ξ_1 ab“, d. h. man bilde das Polynom $(n - 1)$ -ten Grades

$$p_1(x) := \frac{p(x)}{x - \xi_1},$$

dessen größte Nullstelle gerade ξ_2 ist und bestimme ξ_2 wieder mit Hilfe des Newton-Verfahrens. Dabei kann entweder ξ_1 oder besser die beim Überschießen gefundene Zahl $y = x_{k_0}$ als Startwert verwandt und die Iteration wieder mit Hilfe von Doppelschritten beschleunigt werden. So kann man schließlich alle Nullstellen bestimmen.

Dieses Abdividieren (*Deflation*) ist aber nicht ganz ungefährlich, weil man infolge von Rundungsfehlern weder ξ_1 noch $p_1(x)$ exakt bestimmen kann. Das tatsächlich berechnete Polynom p_1 besitzt deshalb nicht $\xi_2, \xi_3, \dots, \xi_n$, sondern etwas davon verschiedene Zahlen als Nullstellen, die wiederum nur näherungsweise gefunden werden können, so daß die zuletzt bestimmten Nullstellen recht ungenau sein können.

Man kann jedoch zeigen, daß das Abdividieren numerisch stabil ist, wenn die Koeffizienten von

$$p(x) = a'_0 x^{n-1} + a'_1 x^{n-2} + \dots + a'_{n-1}$$

in der richtigen Reihenfolge bestimmt werden: Die Reihenfolge $a'_0, a'_1, \dots, a'_{n-1}$ (*Vorwärtsdeflation*) ist numerisch stabil, falls die abdividierte Nullstelle ξ_1 die betragskleinste Nullstelle von p ist; die umgekehrte Reihenfolge (*Rückwärtsdeflation*) ist numerisch stabil, falls ξ_1 die betragsgrößte Nullstelle ist. Wieder andere Reihenfolgen sind für die Wurzeln mittleren Betrages günstiger: Details findet man bei Peters und Wilkinson (1971).

Durch einen Trick, der von Machly (1954) stammt, läßt sich das Abdividieren ganz vermeiden. Für das Polynom $p_1(x)$ gilt nämlich

$$p'_1(x) = \frac{p'(x)}{x - \xi_1} - \frac{p(x)}{(x - \xi_1)^2}$$

und als Newton-Iteration für p_1 findet man

$$x_{k+1} = x_k - \frac{p_1(x_k)}{p'_1(x_k)} = x_k - \frac{p(x_k)}{p'(x_k) - \frac{p(x_k)}{x_k - \xi_1}}.$$

Allgemein gilt für das Polynom $p_j(x) := p(x)/((x - \xi_1) \cdots (x - \xi_j))$

$$p'_j(x) = \frac{p'(x)}{(x - \xi_1) \cdots (x - \xi_j)} - \frac{p(x)}{(x - \xi_1) \cdots (x - \xi_j)} \cdot \sum_{i=1}^j \frac{1}{x - \xi_i}.$$

Das (einfache) Newton-Verfahren zur Berechnung von ξ_{j+1} lautet daher in der Machly-Form

$$(5.5.13) \quad x_{k+1} = \Phi_j(x_k) \quad \text{mit} \quad \Phi_j(x) := x - \frac{p(x)}{p'(x) - \sum_{i=1}^j \frac{p(x)}{x - \xi_i}}.$$

Der Vorteil dieser Formel liegt darin, daß das durch Φ_j gegebene Iterationsverfahren selbst dann *lokal* quadratisch gegen ξ_{j+1} konvergiert, wenn die Zahlen $\xi_1, \dots, \xi_j$, die in Φ_j eingehen, keine Nullstellen von p sind (man beachte, daß man nur noch lokale Konvergenz hat). Die Berechnung von ξ_{j+1} hängt deshalb nicht kritisch von der Genauigkeit ab, mit der man die früheren Wurzeln ξ_i , $i \leq j$, berechnet hat. Man spricht deshalb auch von Verfahren zur *Nullstellenunterdrückung* (s. Peters und Wilkinson (1971)).

Man beachte aber, daß $\Phi_j(x)$ nicht für die früher bestimmten Wurzeln $x = \xi_i$, $i = 1, 2, \dots, j$, definiert ist, so daß diese nicht als Startwerte der Iteration verwandt werden können. Stattdessen kann man die Werte nehmen, die man beim Überschießen der Doppelschrittmethode gefunden hat.

Folgendes Pseudo-ALGOL-Programm beschreibt dieses Verfahren. Die Funktionsprozeduren $p(z)$ bzw. $p'(z)$ liefern den Wert des Polynoms p bzw. dessen erste Ableitung, die Nullstellen sind ξ_i , $i = 1, 2, \dots, n$.

```

z0 := Startwert x0;
for j := 1 step 1 until n do
begin m := 2; zs := z0;
  Iteration: z := zs; s := 0;
    for i := 1 step 1 until j - 1 do
      s := s + 1/(z - xi_i);
    zs := p(z); zs := z - m * zs/(p'(z) - zs * s);
    if zs < z then goto Iteration;
    if m = 2 then
      begin zs := z; m := 1; goto Iteration; end;
    xi_j := z;
end;
```

Das folgende **Beispiel** illustriert die Vorteile des Verfahrens von Maehly. Die Koeffizienten a_i des Polynoms

$$p(x) := \prod_{j=0}^{13} (x - 2^{-j}) = \sum_{i=0}^{14} a_i x^{14-i}$$

werden bei Gleitpunktrechnung i.a. bestenfalls mit einem relativen Fehler der Größenordnung ε berechnet. Nach 5.8 sind die Nullstellen von $p(x)$ gut konditioniert. Die folgende Tabelle zeigt, daß das Newton-Maehly-Verfahren die Nullstellen bis auf absolute Fehler der Größenordnung 40ε ($\varepsilon = 10^{-12}$ die Maschinengenauigkeit) liefert. Bei expliziter Abdivision (und Vorwärtsdeflation) ist bereits die fünfte Nullstelle völlig falsch (die absoluten Fehler sind als Vielfache von ε angegeben).

$\xi_j = 2^{-j}$	(Absoluter Fehler) $\times 10^{12}$	
	Newton-Maehly	Abdivision
1.0	0	0
0.5	6.8	3.7×10^2
0.25	1.1	1.0×10^6
0.125	0.2	1.4×10^9
0.062 5	4.5	
0.031 25	4.0	
0.015 625	3.3	
0.007 812 5	39.8	$> 10^{12}$
0.003 906 25	10.0	
0.001 953 125	5.3	
0.000 976 562 5	0	
0.000 488 281 25	0	
0.000 244 140 625	0.4	
0.000 122 070 3125	0	

Das Polynom

$$p_1(x) := \frac{p(x)}{x-1} = \prod_{j=1}^{13} (x - 2^{-j})$$

besitzt die Nullstellen 2^{-j} , $j = 1, 2, \dots, 13$. Wird $\tilde{p}_1$ durch numerisches Abdividieren von $(x-1)$ aus $p(x)$ gewonnen,

$$\tilde{p}_1(x) := \text{gl}\left(\frac{p(x)}{x-1}\right),$$

so stimmen bereits nach einer Abdivision die meisten Nullstellen von $\tilde{p}_1(x)$ kaum noch mit den exakten Nullstellen von $p_1(x)$ überein.

Mit Newton-Maehly berechnete	
j	Nullstellen von $\tilde{p}_1(x)$
1	0.499
2	0.250
3	0.123
4	0.092
5	-0.098
6	-0.056
7	-0.64
8	+1.83
$\vdots$	$\vdots$

Dividiert man dagegen die Nullstellen (bei Vorwärtsdeflation) in der umgekehrten Reihenfolge beginnend mit der beitragskleinsten Nullstelle ab, so erhält man die

Nullstellen von $p(x)$ praktisch mit Maschinengenauigkeit (Wilkinson (1963), Peters und Wilkinson (1971)):

j	Reihenfolge der Abdivision der Nullstellen von $p(x)$.													
	13	12	11	10	9	8	7	6	5	4	3	2	1	0
Betrag des absoluten Fehlers ($\times 10^{12}$)	0.2	0.4	2	5	3	1	14	6	12	6	2	2	12	1

5.6 Sturmsche Ketten und Bisektionsverfahren

Sei $p(x)$ ein reelles Polynom n -ten Grades

$$p(x) = a_0x^n + a_1x^{n-1} + \dots + a_n, \quad a_0 \neq 0.$$

Es ist möglich (s. Henrici (1974) für eine systematische Behandlung dieser Fragen), die Anzahl der reellen Nullstellen von p in einem Intervall mit Hilfe der Zahl $w(a)$ der *Vorzeichenwechsel* einer Kette reeller Polynome $p_i(x)$, $i = 0, 1, \dots, m$, fallenden Grades an bestimmten Stellen $x = a$ zu berechnen: Zur Bestimmung von $w(a)$ streicht man zunächst in der Folge $p_0(a)$, $p_1(a)$, $\dots$, $p_m(a)$ alle verschwindenden Terme $p_i(a) = 0$ und zählt dann ab, wie oft aufeinander folgende Terme verschiedene Vorzeichen haben. Passende Ketten von Polynomen sind die sog. *Sturmschen Ketten*:

(5.6.1) **Def.:** Eine Folge

$$p(x) = p_0(x), p_1(x), \dots, p_m(x)$$

reeller Polynome, heißt eine *Sturmsche Kette* für $p(x)$, falls gilt:

- Alle reellen Wurzeln von $p_0(x)$ sind einfach.
- $\text{sign } p_1(\xi) = -\text{sign } p'_0(\xi)$ für alle reellen Wurzeln ξ von $p_0(x)$.
- Für $i = 1, 2, \dots, m-1$ gilt

$$p_{i+1}(\xi)p_{i-1}(\xi) < 0,$$

falls ξ reelle Nullstelle von $p_i(x)$ ist.

- Das letzte Polynom $p_m(x)$ besitzt keine reellen Wurzeln.

Es gilt dann der

(5.6.2) **Satz:** Die Anzahl der reellen Nullstellen von $p(x) \equiv p_0(x)$ im Intervall $a \leq x < b$ ist gleich $w(b) - w(a)$, wenn $w(x)$ die Anzahl der Vorzeichenwechsel einer Sturmschen Kette

$$p_0(x), \dots, p_m(x)$$

an der Stelle x ist.

Bevor wir diesen Satz beweisen, soll kurz gezeigt werden, wie man zu einem reellen Polynom $p(x)$ mit Hilfe des bekannten euklidischen Algorithmus eine Sturmsche Kette konstruieren kann, wenn die reellen Nullstellen von p einfach sind. Dazu setze man

$$p_0(x) := p(x), \quad p_1(x) := -p'_0(x) = -p'(x)$$

und bilde die restlichen $p_{i+1}(x)$ rekursiv, indem man $p_{i-1}(x)$ durch $p_i(x)$ mit Rest teilt:

$$(5.6.3) \quad p_{i-1}(x) = q_i(x)p_i(x) - c_i p_{i+1}(x), \quad i = 1, 2, \dots,$$

wobei $\text{Grad } p_i(x) > \text{Grad } p_{i+1}(x)$. Hier können $c_i > 0$ beliebige positive Konstanten sein. Da der Grad der Polynome p_i mit wachsendem i echt abnimmt, bricht die Kette nach spätestens $m \leq n$ Schritten ab,

$$p_{m-1}(x) = q_m(x)p_m(x), \quad p_m(x) \neq 0.$$

$p_m(x)$ ist dann bekanntlich der größte gemeinsame Teiler von $p(x)$ und $p_1(x) = -p'(x)$. Falls die reellen Nullstellen von $p(x)$ einfach sind, haben $p(x)$ und $p'(x)$ keine gemeinsamen reellen Nullstellen, so daß auch $p_m(x)$ keine reellen Nullstellen besitzt und deshalb (5.6.1d) gilt. Falls $p_i(\xi) = 0$ für ein $\xi \in \mathbb{R}$, folgt aus (5.6.3) $p_{i-1}(\xi) = -c_i p_{i+1}(\xi)$. Wenn nun auch $p_{i+1}(\xi) = 0$ wäre, dann folgte aus (5.6.3) $p_{i+1}(\xi) = \dots = p_m(\xi) = 0$, also $p_m(\xi) = 0$ im Widerspruch zu (5.6.1d). Also gilt (5.6.1c). Die restliche Bedingung (5.6.1b) ist trivial.

Beweis von Satz (5.6.2): Wir wollen untersuchen, wie sich die Zahl der Vorzeichenwechsel $w(a)$ in der Folge

$$p_0(a), p_1(a), \dots, p_m(a)$$

mit wachsendem $a \in \mathbb{R}$ ändert. Solange a keine Nullstelle eines der $p_i(x)$, $i = 0, 1, \dots, m$, passiert, kann sich $w(a)$ nicht ändern. Wir untersuchen nun das Verhalten von $w(a)$ an einer Nullstelle eines der Polynome $p_i(x)$ und unterscheiden die beiden Fälle $i > 0$ und $i = 0$.

Im ersten Fall ist $i < m$ wegen (5.6.1d) und $p_{i+1}(a) \neq 0$, $p_{i-1}(a) \neq 0$ wegen (5.6.1c). Die Vorzeichen der $p_j(a)$, $j = i-1, i, i+1$, zeigen daher für genügend kleines $h > 0$ ein Verhalten, das durch eines der vier folgenden Tableaus skizziert wird:

	$a-h$	a	$a+h$		$a-h$	a	$a+h$
$i-1$	—	—	—	$i-1$	+	+	+
i	—	0	$\pm$	i	—	0	$\pm$
$i+1$	+	+	+	$i+1$	—	—	—

	$a - h$	a	$a + h$		$a - h$	a	$a + h$
$i - 1$	—	—	—	$i - 1$	+	+	+
i	+	0	$\pm$	i	+	0	$\pm$
$i + 1$	+	+	+	$i + 1$	—	—	—

In jedem Fall ist $w(a - h) = w(a) = w(a + h)$ und die Zahl der Vorzeichenwechsel ändert sich beim Passieren von a nicht.

Im zweiten Fall, $i = 0$, kann das Verhalten wegen (5.6.1)a)b) durch eines der folgenden Tableaus beschrieben werden:

i	$a - h$	a	$a + h$	i	$a - h$	a	$a + h$
0	—	0	+	0	+	0	—
1	—	—	—	1	+	+	+

Jedenfalls ist

$$w(a - h) = w(a) = w(a + h) - 1$$

und beim Passieren einer Nullstelle a von $p_0(x) \equiv p(x)$ wird genau ein Zeichenwechsel gewonnen. Für $a < b$ und genügend kleines $h > 0$ gibt daher

$$w(b) - w(a) = w(b - h) - w(a - h)$$

die Anzahl der Nullstellen von $p(x)$ im Intervall $a - h < x < b - h$ an, d. h. der Nullstellen im Intervall $a \leq x < b$, da $h > 0$ beliebig klein gewählt werden kann. Damit ist Satz (5.6.2) bewiesen. $\square$

Die Resultate des letzten Satzes werden hauptsächlich dazu verwandt, um durch ein *Bisektionsverfahren* die Eigenwerte von reellen symmetrischen Tridiagonalmatrizen

$$J = \begin{bmatrix} \alpha_1 & \beta_2 & & & 0 \\ \beta_2 & \cdot & \cdot & & \\ & \cdot & \cdot & \cdot & \\ & & \cdot & \cdot & \cdot \\ & & & \cdot & \cdot & \beta_n \\ 0 & & & & \beta_n & \alpha_n \end{bmatrix}$$

zu bestimmen. Die charakteristischen Polynome der i -ten Hauptabschnittsmatrizen von $(J - xI)$ genügen der Rekursion (s. (5.5.3))

$$p_0(x) := 1, \quad p_1(x) := \alpha_1 - x,$$

$$p_i(x) := (\alpha_i - x)p_{i-1}(x) - \beta_i^2 p_{i-2}(x), \quad i = 2, 3, \dots, n,$$

und es ist $p_n(x) = \det(J - xI)$ das charakteristische Polynom von J , dessen Nullstellen gerade die Eigenwerte (s. 6.1) von J sind. Wir wollen zeigen, daß für $\beta_i \neq 0$, $i = 2, \dots, n$, die Polynome

$$(5.6.4) \quad p_n(x), p_{n-1}(x), \dots, p_0(x)$$

eine Sturmsche Kette für das charakteristische Polynom $p_n(x) = \det(J - xI)$ bilden (man beachte, daß sich die Numerierung der $p_i(x)$ von der in (5.6.1) unterscheidet). Dies ergibt sich aus folgendem

(5.6.5) **Satz:** Seien α_j, β_j reelle Zahlen mit $\beta_j \neq 0$ für $j = 2, \dots, n$, und seien die Polynome $p_i(x)$, $i = 0, \dots, n$, durch die Rekursion (5.5.3) definiert. Dann sind alle Nullstellen $x_k^{(i)}$, $k = 1, \dots, i$, von p_i , $i = 1, \dots, n$, reell und einfach,

$$x_1^{(i)} > x_2^{(i)} > \dots > x_i^{(i)},$$

und die Nullstellen von p_{i-1} und p_i trennen sich strikt,

$$(5.6.6) \quad x_1^{(i)} > x_1^{(i-1)} > x_2^{(i)} > x_2^{(i-1)} > \dots > x_{i-1}^{(i-1)} > x_i^{(i)}.$$

Beweis durch Induktion nach i . Der Satz ist für $i = 1$ trivial. Wir nehmen an, daß er für ein $i \geq 1$ richtig ist, d. h. die Nullstellen $x_k^{(i)}, x_k^{(i-1)}$, von p_i und p_{i-1} sind reell und es gilt (5.6.6). Wegen (5.5.3) hat p_j die Form $p_j(x) = (-1)^j x^j + \dots$, so daß p_j den Grad j besitzt. Also ändert $p_{i-1}(x)$ für $x > x_1^{(i-1)}$ sein Vorzeichen nicht, und (5.6.6) ergibt sofort

$$(5.6.7) \quad \text{sign } p_{i-1}(x_k^{(i)}) = (-1)^{i+k} \quad \text{für } k = 1, 2, \dots, i,$$

da die Nullstellen $x_k^{(i-1)}$ einfach sind. Ferner folgt aus (5.5.3)

$$p_{i+1}(x_k^{(i)}) = -\beta_{i+1}^2 p_{i-1}(x_k^{(i)}), \quad k = 1, 2, \dots, i.$$

Wegen $\beta_{i+1}^2 > 0$ erhält man

$$\begin{aligned} \text{sign } p_{i+1}(x_k^{(i)}) &= (-1)^{i+k+1}, \quad k = 1, 2, \dots, i, \\ \text{sign } p_{i+1}(+\infty) &= (-1)^{i+1}, \quad \text{sign } p_{i+1}(-\infty) = 1, \end{aligned}$$

so daß p_{i+1} in jedem der $i + 1$ offenen Intervalle $(x_1^{(i)}, +\infty)$, $(-\infty, x_i^{(i)})$, $(x_{k+1}^{(i)}, x_k^{(i)})$, $k = 1, \dots, i - 1$, sein Vorzeichen ändert, und deshalb p_{i+1} in jedem dieser Intervalle eine Nullstelle, also insgesamt mindestens $i + 1$ reelle verschiedene Nullstellen besitzt. Wegen $\text{Grad } p_{i+1} = i + 1$ sind daher alle Nullstellen von p_{i+1} reell und einfach, und sie trennen die Nullstellen $x_k^{(i)}$ von p_i strikt,

$$x_1^{(i+1)} > x_1^{(i)} > x_2^{(i+1)} > x_2^{(i)} > \dots > x_i^{(i)} > x_{i+1}^{(i+1)}.$$

□

Man zeigt nun leicht, daß die Polynome (5.6.4) eine Sturmsche Kette bilden: Wegen (5.6.5) besitzt $p_n(x)$ nur reelle einfache Nullstellen

$$\xi_1 > \xi_2 > \dots > \xi_n,$$

und wegen (5.6.7) gilt für $k = 1, 2, \dots, n$

$$\begin{aligned}\operatorname{sign} p_{n-1}(\xi_k) &= (-1)^{n+k}, \\ \operatorname{sign} p'_n(\xi_k) &= (-1)^{n+k+1} = -\operatorname{sign} p_{n-1}(\xi_k).\end{aligned}$$

Für $x = -\infty$ besitzt nun die Kette (5.6.4) die Vorzeichen

$$+, +, \dots, +,$$

also $w(-\infty) = 0$. Wegen Satz (5.6.2) gibt deshalb $w(\mu)$ gerade die Anzahl der Nullstellen ξ von $p_n(x)$ mit $\xi < \mu$ an:

$$w(\mu) \geq n + 1 - i \text{ gilt genau dann, wenn } \xi_i < \mu.$$

Das führt zu folgendem Bisektionsverfahren, um die i -te Nullstelle ξ_i von $p_n(x)$ zu bestimmen ($\xi_1 > \xi_2 > \dots > \xi_n$). Man startet mit einem Intervall

$$[a_0, b_0]$$

das ξ_i sicher enthält; z.B. wähle man $b_0 > \xi_1$, $\xi_n > a_0$. Dann halbiert man sukzessiv dieses Intervall und testet mit Hilfe der Sturmschen Kette, in welchem der beiden neuen Teilintervalle ξ_i liegt. D. h. man bildet für $j = 0, 1, 2, \dots$

$$\begin{aligned}\mu_j &:= (a_j + b_j)/2, \\ a_{j+1} &:= \begin{cases} a_j, & \text{falls } w(\mu_j) \geq n + 1 - i, \\ \mu_j, & \text{falls } w(\mu_j) < n + 1 - i, \end{cases} \\ b_{j+1} &:= \begin{cases} \mu_j, & \text{falls } w(\mu_j) \geq n + 1 - i, \\ b_j, & \text{falls } w(\mu_j) < n + 1 - i. \end{cases}\end{aligned}$$

Es gilt dann stets

$$\xi_i \in [a_{j+1}, b_{j+1}] \subset [a_j, b_j], \quad |a_{j+1} - b_{j+1}| = |a_j - b_j|/2,$$

und die a_j konvergieren monoton wachsend, die b_j monoton fallend gegen ξ_i . Die Konvergenz ist linear mit dem Konvergenzfaktor 0.5. Dieses Verfahren zur Bestimmung der Nullstellen eines reellen Polynoms mit lauter reellen Nullstellen ist zwar langsam aber sehr genau. Es hat außerdem den Vorteil, daß man jede beliebige Nullstelle unabhängig von den übrigen bestimmen kann.

5.7 Das Verfahren von Bairstow

Besitzt ein reelles Polynom konjugiert komplexe Nullstellen, so können diese mit Hilfe des gewöhnlichen Newton-Verfahrens nicht gefunden werden, solange man mit *reellen* Näherungswerten startet. Will man auch die komplexen Nullstellen bekommen, so muß man von komplexen Näherungswerten ausgehen. Beim Verfahren von Bairstow wird die komplexe Rechnung vermieden. Es geht von der Beobachtung aus, daß die Nullstellen des reellen quadratischen Polynoms

$$x^2 - rx - q$$

genau dann auch Nullstellen des gegebenen reellen Polynoms

$$p(x) = a_0 x^n + \dots + a_n, \quad a_0 \neq 0,$$

sind, wenn $p(x)$ durch $x^2 - rx - q$ ohne Rest teilbar ist. Nun ist allgemein

$$(5.7.1) \quad p(x) = p_1(x)(x^2 - rx - q) + Ax + B,$$

wobei $\text{Grad } p_1 = n - 2$ und $Ax + B$ der Rest ist, der bei Division von $p(x)$ durch $x^2 - rx - q$ auftritt. Die Koeffizienten A und B hängen natürlich von r und q ab,

$$A = A(r, q), \quad B = B(r, q),$$

und der Rest verschwindet genau dann, wenn (r, q) Lösung des Gleichungssystems

$$(5.7.2) \quad A(r, q) = 0, \quad B(r, q) = 0$$

ist. Das Verfahren von Bairstow ist nun nichts anderes, als das gewöhnliche Newton-Verfahren (5.1.6) zur iterativen Lösung von (5.7.2),

$$(5.7.3) \quad \begin{bmatrix} r_{i+1} \\ q_{i+1} \end{bmatrix} = \begin{bmatrix} r_i \\ q_i \end{bmatrix} - \begin{bmatrix} A_r & A_q \\ B_r & B_q \end{bmatrix}^{-1} \begin{bmatrix} A(r_i, q_i) \\ B(r_i, q_i) \end{bmatrix}.$$

Um (5.7.3) auszuführen, müssen natürlich zunächst die partiellen Ableitungen

$$A_r = \frac{\partial A}{\partial r}, \quad A_q = \frac{\partial A}{\partial q}, \quad B_r = \frac{\partial B}{\partial r}, \quad B_q = \frac{\partial B}{\partial q}$$

berechnet werden. Nun gilt (5.7.1) identisch in r , q und x . Also folgt durch Differentiation nach r und q

$$(5.7.4) \quad \begin{aligned} \frac{\partial}{\partial r} p(x) \equiv 0 &= (x^2 - rx - q) \frac{\partial p_1(x)}{\partial r} - x p_1(x) + A_r x + B_r, \\ \frac{\partial}{\partial q} p(x) \equiv 0 &= (x^2 - rx - q) \frac{\partial p_1(x)}{\partial q} - p_1(x) + A_q x + B_q. \end{aligned}$$

Durch nochmalige Division von $p_1(x)$ durch $(x^2 - rx - q)$ erhält man die Darstellung

$$(5.7.5) \quad p_1(x) = p_2(x)(x^2 - rx - q) + A_1x + B_1.$$

Setzt man nun voraus, daß $x^2 - rx - q = 0$ zwei verschiedene Nullstellen x_0, x_1 besitzt, so erhält man für $x = x_i, i = 0, 1$,

$$p_1(x_i) = A_1x_i + B_1,$$

und deshalb aus (5.7.4) für $x = x_i$ die Gleichungen

$$\left. \begin{aligned} -x_i(A_1x_i + B_1) + A_rx_i + B_r &= 0 \\ -(A_1x_i + B_1) + A_qx_i + B_q &= 0 \end{aligned} \right\}, \quad i = 0, 1.$$

Aus der zweiten dieser Gleichungen folgt wegen $x_0 \neq x_1$ sofort

$$(5.7.6) \quad A_q = A_1, \quad B_q = B_1,$$

und deshalb aus der ersten Gleichung

$$-x_i^2 A_q + x_i(A_r - B_q) + B_r = 0, \quad i = 0, 1.$$

Wegen $x_i^2 = rx_i + q$ folgt

$$x_i(A_r - B_q - A_q \cdot r) + B_r - A_q \cdot q = 0, \quad i = 0, 1,$$

und daher wegen $x_0 \neq x_1$,

$$\begin{aligned} A_r - B_q - A_q \cdot r &= 0, \\ B_r - A_q \cdot q &= 0. \end{aligned}$$

Zusammen mit (5.7.6) ergibt dies schließlich

$$\begin{aligned} A_q &= A_1, & B_q &= B_1, \\ A_r &= rA_1 + B_1, & B_r &= q \cdot A_1. \end{aligned}$$

Die Größen A, B bzw. A_1, B_1 können schließlich mit Hilfe eines hornerartigen Schemas gefunden werden. Mit $p(x) = a_0x^n + \dots + a_n$, $p_1(x) = b_0x^{n-2} + \dots + b_{n-2}$ erhält man aus (5.7.1) durch Koeffizientenvergleich folgende Rekursionsformeln für die b_i und A, B :

$$\begin{aligned} b_0 &:= a_0, \\ b_1 &:= b_0r + a_1, \\ b_i &:= b_{i-2}q + b_{i-1}r + a_i, \quad \text{für } i = 2, 3, \dots, n-2, \\ A &:= b_{n-3}q + b_{n-2}r + a_{n-1}, \\ B &:= b_{n-2}q + a_n. \end{aligned}$$

Auf ähnliche Weise kann man aus den b_i vermöge (5.7.5) auch A_1 und B_1 berechnen.

5.8 Die Empfindlichkeit der Nullstellen von Polynomen

Wir wollen zunächst die Kondition der Nullstellen eines Polynoms $p(x)$ untersuchen, d. h. den Einfluß kleiner Änderungen

$$p(x) \rightarrow p_\varepsilon(x) = p(x) + \varepsilon g(x),$$

$g(x) \not\equiv 0$ ein beliebiges Polynom, auf eine Nullstelle ξ von p . Es wird später gezeigt (Satz (6.9.8)), daß es zu einer einfachen Nullstelle ξ von p eine für kleines $|\varepsilon|$ analytische Funktion $\xi(\varepsilon)$ mit $\xi(0) = \xi$ gibt, die einfache Nullstelle von p_ε ist,

$$p(\xi(\varepsilon)) + \varepsilon g(\xi(\varepsilon)) \equiv 0$$

Durch Differentiation dieser Identität nach ε folgt für $k := d\xi(\varepsilon)/d\varepsilon|_{\varepsilon=0}$ die Beziehung

$$kp'(\xi(0)) + g(\xi(0)) = 0, \quad k = \frac{-g(\xi)}{p'(\xi)},$$

also in erster Näherung

$$(5.8.1) \quad \xi(\varepsilon) \doteq \xi - \varepsilon \frac{g(\xi)}{p'(\xi)}.$$

Für eine m -fache Nullstelle ξ von p kann man zeigen, daß p_ε eine Nullstelle der Form

$$\xi(\varepsilon) = \xi + h(\varepsilon^{1/m})$$

besitzt, wobei $h(t)$ eine für kleines $|t|$ analytische Funktion ist mit $h(0) = 0$. Wegen $p(\xi) = p'(\xi) = \dots = p^{(m-1)}(\xi) = 0$, $p^{(m)}(\xi) \neq 0$ findet man nach m -facher Differentiation von

$$0 \equiv p_\varepsilon(\xi(\varepsilon)) = p(\xi + h(t)) + t^m g(\xi + h(t)), \quad t^m = \varepsilon,$$

nach t sofort für $k := dh(t)/dt|_{t=0}$

$$p^{(m)}(\xi)k^m + m!g(\xi) = 0, \quad k = \left[-\frac{m!g(\xi)}{p^{(m)}(\xi)} \right]^{1/m},$$

also in erster Näherung

$$(5.8.2) \quad \xi(\varepsilon) \doteq \xi + \varepsilon^{1/m} \left[-\frac{m!g(\xi)}{p^{(m)}(\xi)} \right]^{1/m}.$$

Wir wollen nun annehmen, daß das Polynom $p(x)$ in der üblichen Form

$$p(x) = a_0 x^n + \cdots + a_n$$

durch seine Koeffizienten a_i gegeben ist. Für

$$g(x) := a_i x^{n-i}$$

ist $p_\varepsilon(x)$ jenes Polynom, das man bei Ersetzung von a_i in $p(x)$ durch $a_i(1 + \varepsilon)$ erhält. Nach (5.8.2) bewirkt ein relativer Fehler ε von a_i eine Änderung der Nullstelle ξ in der Größe

$$(5.8.3) \quad \xi(\varepsilon) - \xi \doteq \varepsilon^{1/m} \left[-\frac{m! a_i \xi^{n-i}}{p^{(m)}(\xi)} \right]^{1/m}.$$

Man sieht, daß für m -fache Nullstellen, $m > 1$, die Änderungen $\xi(\varepsilon) - \xi$ proportional zu $\varepsilon^{1/m}$, für einfache Nullstellen nur proportional zu ε sind. Mehrfache Nullstellen sind also stets schlecht konditioniert. Trotzdem können auch einfache Nullstellen schlecht konditioniert sein, nämlich dann, wenn der Faktor von ε in (5.8.3),

$$k(i, \xi) := \left| \frac{a_i \xi^{n-i}}{p'(\xi)} \right|,$$

groß gegenüber ξ ist. Dies kann selbst bei „harmlos“ aussehenden Polynomen der Fall sein.

Beispiel (Wilkinson (1959)): 1) Die Nullstellen $\xi_k = k$, $k = 1, 2, \dots, 20$, des Polynoms

$$p(x) = (x-1)(x-2)\cdots(x-20) = \sum_{i=0}^{20} a_i x^{20-i}$$

sind gut separiert. Ändert man a_1 in $a_1(1 + \varepsilon)$ ab, so hat man für $\xi_{20} = 20$ wegen

$$p'(20) = 19!, \quad -a_1 = 1 + 2 + \cdots + 20 = 210$$

die Abschätzung

$$\xi_{20}(\varepsilon) - \xi_{20} \doteq \varepsilon \frac{210 \cdot 20^{19}}{19!} \approx \varepsilon \cdot 0.9 \cdot 10^{10}.$$

Die größten Änderungen erhält man in $\xi_{16} = 16$ bei Änderungen von $a_5 \approx -10^{10}$:

$$\xi_{16}(\varepsilon) - \xi_{16} \doteq -\varepsilon a_5 \frac{16^{15}}{4! 15!} \approx \varepsilon \cdot 3.7 \cdot 10^{14}.$$

Die Nullstellen von p sind extrem schlecht konditioniert. Selbst bei 14-stelliger Rechnung muß man erwarten, daß bereits die erste Stelle von ξ_{16} nicht richtig bestimmt wird!

2) Dagegen sind die Nullstellen des Polynoms

$$p(x) = \sum_{i=0}^{20} a_i x^{20-i} := \prod_{j=1}^{20} (x - 2^{-j}), \quad \xi_j = 2^{-j},$$

gut konditioniert, obwohl seine Nullstellen nicht gut separiert sind, weil sie sich bei Null „häufen“. Wenn man z. B. $a_{20} = 2^{-1}2^{-2} \dots 2^{-20}$ in $a_{20}(1 + \varepsilon)$ ändert, so erhält man für $\xi_{20}(\varepsilon)$

$$\left| \frac{\xi_{20}(\varepsilon) - \xi_{20}}{\xi_{20}} \right| \doteq \left| \varepsilon \frac{1}{(2^{-1} - 1)(2^{-2} - 1) \dots (2^{-19} - 1)} \right| \leq 4|\varepsilon|.$$

Allgemein kann man für jede Wurzel ξ_j und Änderungen jedes Koeffizienten $a_i \rightarrow a_i(1 + \varepsilon)$ zeigen

$$\left| \frac{\xi_j(\varepsilon) - \xi_j}{\xi_j} \right| \leq 64|\varepsilon|.$$

Also sind alle Nullstellen gut konditioniert, wenn man nur kleine *relative* Änderungen der a_i betrachtet. Dies gilt nicht für kleine *absolute* Änderungen! Ersetzt man etwa $a_{20} = 2^{-210}$ durch $\bar{a}_{20} = a_{20} + \Delta a_{20}$, $\Delta a_{20} = 2^{-48} (\approx 10^{-14})$ – man kann dies als kleine absolute Änderung betrachten – so besitzt das geänderte Polynom Nullstellen $\bar{\xi}_i$ mit

$$\bar{\xi}_1 \dots \bar{\xi}_{20} = \bar{a}_{20} = 2^{-210} + 2^{-48} = (2^{162} + 1)(\xi_1 \dots \xi_{20}).$$

D. h. es gibt mindestens ein r mit $|\bar{\xi}_r/\xi_r| \geq (2^{162} + 1)^{1/20} > 2^8 = 256$.

Es sei darauf hingewiesen, daß die Konditionsaussagen von Formel (5.8.3) nur etwas über die Änderungen der Nullstellen bei Änderung der Koeffizienten a_i der Standarddarstellung

$$p(x) := \sum_{i=0}^n a_i x^{n-i}$$

eines Polynoms aussagen. Polynome können aber auch in anderer Form dargestellt werden, beispielsweise als charakteristische Polynome einer Tridiagonalmatrix durch die Koeffizienten dieser Matrix (s. (5.5.3)). Der Einfluß von Änderungen der Koeffizienten der neuen Darstellung auf die Nullstellen kann von einer völlig anderen Größenordnung sein, als der durch (5.8.3) beschriebene. Die Kondition von Nullstellen kann nur relativ zu einer bestimmten Darstellung des Polynoms definiert werden.

Beispiel: In Satz (6.9.7) wird gezeigt, daß für jede reelle symmetrische Tridiagonalmatrix

$$J = \begin{bmatrix} \alpha_1 & \beta_2 & & & \\ \beta_2 & \cdot & \cdot & & \\ & \cdot & \cdot & \cdot & \\ & & \cdot & \cdot & \beta_{20} \\ & & & \beta_{20} & \alpha_{20} \end{bmatrix}$$

mit dem charakteristischen Polynom $p(x) \equiv (x-1)(x-2)\cdots(x-20)$ kleine relative Änderungen der Koeffizienten α_i oder β_i ; nur kleine relative Änderungen der Nullstellen $\xi_j = j$ bewirken. Bezüglich dieser Darstellung sind also alle Nullstellen sehr gut konditioniert, bezüglich der Standarddarstellung (s.o.) aber sehr schlecht. (Siehe auch Peters und Wilkinson (1969) und Wilkinson (1965) für eine detaillierte Behandlung dieses Problemkreises.)

5.9 Interpolationsmethoden zur Bestimmung von Nullstellen

Die in diesem und dem folgenden Abschnitt zu besprechenden Interpolationsmethoden sind für die Nullstellenbestimmung von beliebigen Funktionen $f(x)$ einer Variablen sehr nützlich. Gegenüber dem Newton-Verfahren haben sie den für die Praxis wichtigen Vorteil, daß man keine Ableitungen von f berechnen muß, obwohl sie in einem noch zu präzisierenden Sinne sogar schneller als das Newton-Verfahren konvergieren.

Die einfachste Methode ist die sog. *regula falsi*, die Ähnlichkeiten mit Bisektionsverfahren besitzt und bei der in jedem Schritt zwei Zahlen x_i und a_i mit

$$(5.9.1) \quad f(x_i)f(a_i) < 0$$

so bestimmt werden, daß die x_i gegen eine Nullstelle von f konvergieren. Ist (5.9.1) erfüllt, enthält das Intervall $[x_i, a_i]$ mindestens eine Nullstelle von f . Um x_{i+1} , a_{i+1} zu bestimmen, berechnet man zunächst die Nullstelle μ_i der interpolierenden linearen Funktion

$$p(x) := f(x_i) + (x - x_i) \frac{f(x_i) - f(a_i)}{x_i - a_i}$$

mit $p(x_i) = f(x_i)$, $p(a_i) = f(a_i)$, nämlich

$$(5.9.2) \quad \mu_i = x_i - f(x_i) \frac{x_i - a_i}{f(x_i) - f(a_i)} = \frac{a_i f(x_i) - x_i f(a_i)}{f(x_i) - f(a_i)}.$$

Wegen $f(x_i)f(a_i) < 0$ ist μ_i wohldefiniert und es gilt entweder $x_i < \mu_i < a_i$ oder $a_i < \mu_i < x_i$. Es sind dann x_{i+1} und a_{i+1} folgendermaßen erklärt:

$$(5.9.3) \quad \left. \begin{array}{l} x_{i+1} := \mu_i \\ a_{i+1} := a_i \end{array} \right\} \quad \text{falls } f(\mu_i)f(x_i) > 0, \\ \left. \begin{array}{l} x_{i+1} := \mu_i \\ a_{i+1} := x_i \end{array} \right\} \quad \text{falls } f(\mu_i)f(x_i) < 0.$$

Falls $f(\mu_i) = 0$, wird das Verfahren abgebrochen, μ_i ist Nullstelle. Besser als (5.9.3) ist eine Variante dieses Verfahrens, die von Dekker stammt und von Peters und Wilkinson (1969) beschrieben wurde.

Um die Konvergenz der regula falsi zu diskutieren, nehmen wir der Einfachheit halber an, daß f'' existiert und es ein i gibt mit

$$(5.9.4) \quad \begin{aligned} &\text{a) } x_i < a_i, \\ &\text{b) } f(x_i) < 0 < f(a_i), \\ &\text{c) } f''(x) \geq 0 \quad \text{für alle } x \in [x_i, a_i]. \end{aligned}$$

Dann gilt entweder $f(\mu_i) = 0$ oder

$$f(\mu_i)f(x_i) > 0$$

und damit auch

$$x_i < x_{i+1} = \mu_i < a_{i+1} = a_i.$$

Beweis: Natürlich folgt aus (5.9.4) und der Definition von μ_i sofort

$$x_i < \mu_i < a_i.$$

Die Restgliedformel (2.1.4.1) der Polynominterpolation ergibt für den Interpolationsfehler an der Stelle $x \in [x_i, a_i]$ die Darstellung

$$f(x) - p(x) = (x - x_i)(x - a_i)f''(\delta)/2, \quad \delta \in [x_i, a_i],$$

also wegen (5.9.4)c) $f(x) - p(x) \leq 0$ für $x \in [x_i, a_i]$. Es folgt $f(\mu_i) \leq 0$ wegen $p(\mu_i) = 0$ und damit die Behauptung. $\square$

Also sind die Voraussetzungen (5.9.4) für alle $i \geq i_0$ erfüllt, wenn sie für ein i_0 gelten. Es folgt $a_i = a$ für alle $i \geq i_0$ und die x_i bilden eine monoton wachsende beschränkte Folge, so daß $\lim_{i \rightarrow \infty} x_i = \xi$ existiert. Aus der Stetigkeit von f , (5.9.4) und (5.9.2) folgen sofort

$$\begin{aligned} f(\xi) &\leq 0, \quad f(a) > 0, \\ \xi &= \frac{af(\xi) - \xi f(a)}{f(\xi) - f(a)}, \end{aligned}$$

also $(\xi - a)f(\xi) = 0$. Wegen $f(a) > 0 \geq f(\xi)$ ist aber $\xi \neq a$ und daher $f(\xi) = 0$. Die x_i konvergieren monoton gegen eine Nullstelle von f .

Unter der Voraussetzung (5.9.4) läßt sich das Verfahren der regula falsi auch in der Form

$$(5.9.5) \quad x_{i+1} = \Phi(x_i), \quad \Phi(x) := \frac{af(x) - xf(a)}{f(x) - f(a)}$$

schreiben. Wegen $f(\xi) = 0$ gilt

$$\Phi'(\xi) = \frac{-(af'(\xi) - f(a))f(a) + \xi f(a)f'(\xi)}{f(a)^2} = 1 - f'(\xi) \frac{\xi - a}{f(\xi) - f(a)}.$$

Nun existieren nach dem Mittelwertsatz η_1, η_2 mit

$$(5.9.6) \quad \begin{aligned} \frac{f(\xi) - f(a)}{\xi - a} &= f'(\eta_1), \quad \xi < \eta_1 < a, \\ \frac{f(x_i) - f(\xi)}{x_i - \xi} &= f'(\eta_2), \quad x_i < \eta_2 < \xi. \end{aligned}$$

Wegen $f''(x) \geq 0$ für $x \in [x_i, a]$ wächst $f'(x)$ monoton auf $[x_i, a]$. Also folgen aus (5.9.6), $x_i < \xi$ und $f(x_i) < 0$ sofort

$$0 < f'(\eta_2) \leq f'(\xi) \leq f'(\eta_1),$$

und daher

$$0 \leq \Phi'(\xi) < 1,$$

d. h. die regula falsi ist unter den Voraussetzungen (5.9.4) mindestens linear konvergent.

Diese Untersuchung betrifft im Grunde die Variante der regula falsi, die man erhält, wenn man nur die ersten beiden Rekursionsformeln (5.9.3) benutzt. Als *Sekantenmethode* bezeichnet man jene Variante, die nur die letzten zwei Formeln von (5.9.3) verwendet:

$$(5.9.7) \quad x_{i+1} = \frac{x_{i-1}f(x_i) - x_i f(x_{i-1})}{f(x_i) - f(x_{i-1})}, \quad i = 0, 1, \dots$$

Während das ursprüngliche Verfahren (5.9.3) wegen der Forderung $f(x_i)f(a_i) < 0$ numerisch stabil ist, ist dies bei der Sekantenmethode i. a. nicht der Fall: Wenn $f(x_i) \approx f(x_{i-1})$ gilt, tritt in (5.9.7) Auslöschung auf. Außerdem liegt x_{i+1} nicht mehr unbedingt in $[x_i, x_{i-1}]$ und das Sekantenverfahren konvergiert i. a. nur in einer hinreichend kleinen Umgebung von ξ . Wir wollen hier nur die lokale Konvergenz von (5.9.7) in der Umgebung einer Nullstelle ξ von $f(x) = 0$ untersuchen. Es wird sich herausstellen, daß das Verfahren (5.9.7) superlinear konvergiert und eine gebrochene Konvergenzordnung besitzt. Um dies zu zeigen, ziehen wir auf beiden Seiten von (5.9.7) ξ ab und erhalten unter Benutzung von dividierten Differenzen (2.1.3.5)

$$(5.9.8) \quad \begin{aligned} x_{i+1} - \xi &= (x_i - \xi) - f(x_i) \frac{x_i - x_{i-1}}{f(x_i) - f(x_{i-1})} \\ &= (x_i - \xi) - \frac{f(x_i)}{f[x_{i-1}, x_i]} = (x_i - \xi) \left(1 - \frac{f[x_i, \xi]}{f[x_{i-1}, x_i]} \right) \\ &= (x_i - \xi)(x_{i-1} - \xi) \frac{f[x_{i-1}, x_i, \xi]}{f[x_{i-1}, x_i]}. \end{aligned}$$

Wenn f zweimal stetig differenzierbar ist, gilt wegen (2.1.4.3)

$$(5.9.9) \quad \begin{aligned} f[x_{i-1}, x_i] &= f'(\eta_1), \quad \eta_1 \in I[x_{i-1}, x_i], \\ f[x_{i-1}, x_i, \xi] &= \frac{1}{2} f''(\eta_2), \quad \eta_2 \in I[x_{i-1}, x_i, \xi]. \end{aligned}$$

Ist daher ξ eine einfache Nullstelle von f , $f'(\xi) \neq 0$, so gibt es ein Intervall $J = \{x \mid |x - \xi| \leq \varepsilon\}$ und eine Schranke M mit

$$(5.9.10) \quad \left| \frac{1}{2} \frac{f''(\eta_2)}{f'(\eta_1)} \right| \leq M, \quad \text{für alle } \eta_1, \eta_2 \in J.$$

Sei nun $e_i := M|x_i - \xi|$ und $e_0, e_1 < \min\{1, \varepsilon M\}$, so daß $x_0, x_1 \in J$. Dann folgen wegen (5.9.8), (5.9.10) durch Induktion die Ungleichungen

$$(5.9.11) \quad e_{i+1} \leq e_i e_{i-1}, \quad e_i \leq \min\{1, \varepsilon M\}$$

und damit $x_i \in J$ für alle $i \geq 1$. Wir zeigen ebenfalls durch Induktion

$$(5.9.12) \quad e_i \leq K^{(q^i)} \quad \text{für alle } i = 0, 1, \dots$$

Hier ist $q = (1 + \sqrt{5})/2 = 1.618\dots$ die positive Wurzel der Gleichung $\mu^2 - \mu - 1 = 0$ und $K := \max\{e_0, \sqrt[3]{e_1}\} < 1$. Wegen der Wahl von K ist (5.9.12) für $i = 0$ und $i = 1$ trivial richtig. Ist (5.9.12) für $i - 1$ richtig, so folgt aus (5.9.11) wegen $q^2 = q + 1$ sofort

$$e_{i+1} \leq K^{q^i} K^{q^{i-1}} = K^{q^{i+1}}.$$

(5.9.12) zeigt, daß die Sekantenmethode mindestens so schnell wie ein Verfahren der Ordnung $q = 1.618\dots$ konvergiert. Da sie nur eine neue Funktionswertung pro Iteration erfordert, sind zwei Schritte dieses Verfahrens höchstens so aufwendig wie ein Schritt des Newton-Verfahrens. Wegen $K^{q^{i+2}} = (K^{q^i})^{q^2} = (K^{q^i})^{q+1}$ entsprechen aber zwei Schritte des Sekantenverfahrens einem Verfahren der Ordnung $q + 1 = 2.618\dots$. Bei gleichem Arbeitsaufwand konvergiert also das Sekantenverfahren lokal schneller als das Newton-Verfahren, das die Ordnung zwei besitzt.

Die Sekantenmethode legt folgende Verallgemeinerung nahe. Sind $r + 1$ verschiedene Näherungswerte $x_i, x_{i-1}, \dots, x_{i-r}$ für die zu berechnende Nullstelle ξ von $f(x)$ gegeben, so bestimme man ein interpolierendes Polynom $Q(x)$ r -ten Grades mit

$$Q(x_{i-j}) = f(x_{i-j}), \quad j = 0, 1, \dots, r,$$

und wähle x_{i+1} als diejenige Nullstelle von $Q(x) = 0$, die x_i am nächsten liegt. Für $r = 1$ ist dies die Sekantenmethode, für $r = 2$ erhält man das Verfahren von Muller. Die Verfahren mit $r \geq 3$ sind ungebräuchlich, weil

es keine oder nur komplizierte Formeln zur Bestimmung von Nullstellen von Polynomen r -ten Grades für $r \geq 3$ gibt.

Das Verfahren von Muller ist ein effizientes und i.a. sehr zuverlässiges Verfahren, mit dem man sogar die komplexen Nullstellen komplexer Funktionen $f: \mathbb{C} \rightarrow \mathbb{C}$ bestimmen kann, insbesondere auch (sogar mehrfache) komplexe Nullstellen von Polynomen. Die Näherungswerte x_i können aber komplex werden, selbst wenn die Startwerte x_1, x_2, x_3 reell sind und $f(x)$ ein reelles Polynom mit nur reellen Nullstellen ist. Unsere Darstellung verwendet dividierte Differenzen (s. 2.1.3) und folgt Traub (1964).

Die Newtonsche Interpolationsformel (2.1.3.8) liefert folgende Darstellung für das quadratische Polynom $Q_i(x)$, das f an den Stellen x_{i-2}, x_{i-1}, x_i interpoliert:

$$\begin{aligned} Q_i(x) &= f[x_i] + f[x_{i-1}, x_i](x - x_i) \\ &\quad + f[x_{i-2}, x_{i-1}, x_i](x - x_{i-1})(x - x_i) \\ &= a_i(x - x_i)^2 + 2b_i(x - x_i) + c_i, \end{aligned}$$

mit den Koeffizienten

$$\begin{aligned} a_i &:= f[x_{i-2}, x_{i-1}, x_i], \\ b_i &:= \frac{1}{2}(f[x_{i-1}, x_i] + f[x_{i-2}, x_{i-1}, x_i](x_i - x_{i-1})), \\ c_i &:= f[x_i]. \end{aligned}$$

Wenn h_i die betragskleinste Wurzel der quadratischen Gleichung $a_i h^2 + 2b_i h + c_i = 0$ ist, ist $x_{i+1} := x_i + h_i$ die Wurzel von $Q_i(x)$, die am nächsten bei x_i liegt. Sie kann folgendermaßen numerisch stabil berechnet werden (vgl. Beispiel 1 in Abschnitt 1.4):

$$(5.9.13) \quad x_{i+1} = x_i - \frac{c_i}{b_i \pm \sqrt{b_i^2 - a_i c_i}},$$

wobei das Vorzeichen der Quadratwurzel so zu wählen ist, daß der Betrag des Nenners maximal wird. Für $a_i = 0$ liegt lineare Interpolation wie bei der Sekantenmethode vor. Für $a_i = b_i = 0$ bricht das Verfahren zusammen: Es ist dann $f(x_{i-2}) = f(x_{i-1}) = f(x_i)$, und das Verfahren muß dann mit anderen Startwerten neu begonnen werden. Beim Lösen der quadratischen Gleichung muß man komplexe Arithmetik verwenden, selbst wenn a_i, b_i, c_i reell sind, weil $b_i^2 - a_i c_i$ negativ sein kann.

Nach der Berechnung von x_{i+1} bestimmt man $f(x_{i+1})$ und daraus die neuen dividierten Differenzen

$$\begin{aligned}
 f[x_{i+1}] &:= f(x_{i+1}), \\
 f[x_i, x_{i+1}] &:= \frac{f[x_{i+1}] - f[x_i]}{x_{i+1} - x_i}, \\
 f[x_{i-1}, x_i, x_{i+1}] &:= \frac{f[x_i, x_{i+1}] - f[x_{i-1}, x_i]}{x_{i+1} - x_{i-1}},
 \end{aligned}$$

aus denen man das nächste quadratische interpolierende Polynom $Q_{i+1}(x)$ berechnen kann.

Man kann zeigen, daß für die Fehler $\varepsilon_i := x_i - \xi$ des Verfahrens von Muller in der Nähe einer einfachen Nullstelle ξ von $f(x) = 0$ gilt
(5.9.14)

$$\varepsilon_{i+1} = \varepsilon_i \varepsilon_{i-1} \varepsilon_{i-2} \left(-\frac{f^{(3)}(\xi)}{6f'(\xi)} + O(\varepsilon) \right), \quad \varepsilon := \max(|\varepsilon_i|, |\varepsilon_{i-1}|, |\varepsilon_{i-2}|),$$

(vgl. (5.9.8)). Ähnlich wie bei der Sekantenmethode kann man zeigen, daß das Verfahren von Muller ein Verfahren mindestens der Ordnung $q = 1.84 \dots$ ist, wo q die größte Nullstelle der Gleichung $\mu^3 - \mu^2 - \mu - 1 = 0$ ist.

Die Sekantenmethode kann man in einer anderen Richtung verallgemeinern. Dazu seien wieder $r + 1$ Näherungswerte $x_i, x_{i-1}, \dots, x_{i-r}$ für die einfache Nullstelle ξ von $f(x) = 0$ gegeben. f besitzt dann in einer Umgebung von ξ eine Umkehrfunktion g ,

$$f(g(y)) = y, \quad g(f(x)) = x, \quad g(0) = \xi,$$

so daß eine Bestimmung von ξ auf die Berechnung von $g(0)$ hinausläuft. Wegen

$$g(f(x_j)) = x_j, \quad j = i, i-1, \dots, i-r,$$

liegt es nahe, ein interpolierendes Polynom $Q(y)$ vom Grad r mit $Q(f(x_j)) = x_j$, $j = i, i-1, \dots, i-r$ zu bestimmen und $g(0)$ durch $Q(0)$ zu approximieren. Diesen Näherungswert nimmt man als nächsten Näherungswert, $x_{i+1} := Q(0)$. Man erhält so das Verfahren der Nullstellenbestimmung mittels *inverser Interpolation* und für $r = 1$ wieder die Sekantenmethode. Bei der praktischen Durchführung der inversen Interpolation benutzt man vorteilhaft die Interpolationsformeln von Aitken ff und Neville (s. 2.1.2). Auch diese Verfahren sind lokal konvergent und besitzen eine gebrochene Konvergenzordnung. Details findet man bei Ostrowski (1966) und Brent (1973).

5.10 Die Δ^2 -Methode von Aitken

Die Δ^2 -Methode von Aitken gehört zu den Methoden zur *Konvergenzbeschleunigung* einer gegebenen konvergenten Folge $\{x_i\}$, $\lim_{i \rightarrow \infty} x_i = \xi$. Durch sie wird die Folge $\{x_i\}$ in eine andere Folge $\{x'_i\}$ transformiert, die i.a. schneller gegen ξ konvergiert als die ursprüngliche Folge. Man kann sie auch zur Nullstellenbestimmung von Funktionen benutzen, wenn man als $\{x_i\}$ eine Folge nimmt, die von irgendeinem anderen Verfahren zur Nullstellenbestimmung geliefert wird.

Um die Δ^2 -Methode herzuleiten, nehmen wir zunächst an, daß $\{x_i\}$ eine Folge ist, die wie eine *geometrische Folge* mit dem Faktor k , $|k| < 1$, gegen ξ konvergiert, d. h. es gilt

$$x_{i+1} - \xi = k(x_i - \xi), \quad i = 0, 1, \dots$$

Aus x_i, x_{i+1}, x_{i+2} kann man dann mit Hilfe der Gleichungen

$$(5.10.1) \quad x_{i+1} - \xi = k(x_i - \xi), \quad x_{i+2} - \xi = k(x_{i+1} - \xi)$$

k und ξ berechnen. Man findet zunächst durch Subtraktion der Gleichungen (5.10.1)

$$k = \frac{x_{i+2} - x_{i+1}}{x_{i+1} - x_i}$$

und daraus durch Einsetzen in die erste der Gleichungen wegen $k \neq 1$

$$\xi = \frac{(x_i x_{i+2} - x_{i+1}^2)}{(x_{i+2} - 2x_{i+1} + x_i)}.$$

Mit Hilfe des Differenzenoperators $\Delta x_i := x_{i+1} - x_i$ kann dies wegen $\Delta^2 x_i = \Delta x_{i+1} - \Delta x_i = x_{i+2} - 2x_{i+1} + x_i$ auch in der Form

$$(5.10.2) \quad \xi = x_i - \frac{(\Delta x_i)^2}{\Delta^2 x_i}$$

geschrieben werden. Diese Formel gibt der Methode den Namen. Es liegt nun die Vermutung nahe, daß (5.10.2) zumindest einen guten Näherungswert für den gesuchten Grenzwert ξ einer Folge x_i liefert, auch wenn die Voraussetzung, daß x_i eine geometrisch konvergente Folge ist, nicht zutrifft.

Die Δ^2 -Methode von Aitken besteht somit darin, zu einer gegebenen Folge $\{x_i\}$ die transformierte Folge

$$(5.10.3) \quad x'_i := x_i - \frac{(x_{i+1} - x_i)^2}{x_{i+2} - 2x_{i+1} + x_i}$$

zu berechnen. Der folgende Satz zeigt, daß die x'_i schneller gegen ξ konvergieren als die x_i , wenn die x_i sich asymptotisch wie eine geometrische Folge verhalten:

(5.10.4) **Satz:** Sei $|k| < 1$ und es gelte für die Folge $\{x_i\}$, $x_i \neq \xi$ und

$$x_{i+1} - \xi = (k + \delta_i)(x_i - \xi), \quad \lim_{i \rightarrow \infty} \delta_i = 0.$$

Dann existiert für genügend großes i die Folge x'_i (5.10.3) und es gilt

$$\lim_{i \rightarrow \infty} \frac{x'_i - \xi}{x_i - \xi} = 0.$$

Beweis: Für den Fehler $e_i := x_i - \xi$ gilt nach Voraussetzung $e_{i+1} = (k + \delta_i)e_i$. Es folgt

$$\begin{aligned} x_{i+2} - 2x_{i+1} + x_i &= e_{i+2} - 2e_{i+1} + e_i \\ &= e_i((k + \delta_{i+1})(k + \delta_i) - 2(k + \delta_i) + 1) \\ &= e_i((k - 1)^2 + \mu_i), \quad \text{wobei } \mu_i \rightarrow 0, \\ x_{i+1} - x_i &= e_{i+1} - e_i = e_i((k - 1) + \delta_i). \end{aligned} \quad (5.10.5)$$

Also ist wegen $e_i \neq 0$, $k \neq 1$ und $\mu_i \rightarrow 0$ für großes i auch

$$x_{i+2} - 2x_{i+1} + x_i \neq 0$$

und daher x'_i durch (5.10.3) wohldefiniert. Weiter folgt aus (5.10.3) und (5.10.5) für großes i

$$x'_i - \xi = e_i - e_i \frac{((k - 1) + \delta_i)^2}{(k - 1)^2 + \mu_i},$$

also

$$\lim_{i \rightarrow \infty} \frac{x'_i - \xi}{x_i - \xi} = \lim_{i \rightarrow \infty} \left\{ 1 - \frac{((k - 1) + \delta_i)^2}{(k - 1)^2 + \mu_i} \right\} = 0. \quad \square$$

Wir nehmen nun an, daß die Folge

$$(5.10.6) \quad x_{i+1} = \Phi(x_i), \quad i = 0, 1, 2, \dots$$

durch eine Iterationsfunktion $\Phi(x)$ (s. 5.1) mit dem Fixpunkt ξ erzeugt wird. Zwar kann man mittels (5.10.3) aus je drei Gliedern x_i , x_{i+1} , x_{i+2} der durch (5.10.6) definierten Folge das Element x'_i der transformierten Folge berechnen, doch ist es naheliegender, jeweils die neueste Information zu benutzen und folgendermaßen vorzugehen: Ausgehend von dem Startwert x_0 berechne man für $i = 0, 1, \dots$

$$(5.10.7) \quad \begin{aligned} y_i &:= \Phi(x_i), & z_i &:= \Phi(y_i), \\ x_{i+1} &:= x_i - \frac{(y_i - x_i)^2}{z_i - 2y_i + x_i}. \end{aligned}$$

Diese Methode stammt von Steffensen. Die Iteration (5.10.7) wird durch eine neue Iterationsfunktion Ψ beschrieben:

$$(5.10.8) \quad \begin{aligned} x_{i+1} &= \Psi(x_i), \\ \Psi(x) &:= \frac{x\Phi(\Phi(x)) - \Phi(x)^2}{\Phi(\Phi(x)) - 2\Phi(x) + x}. \end{aligned}$$

Wir wollen untersuchen, wie die Fixpunkte von Φ und Ψ zusammenhängen:

(5.10.9) **Satz:** *Aus $\Psi(\xi) = \xi$ folgt $\Phi(\xi) = \xi$. Umgekehrt gilt $\Psi(\xi) = \xi$, falls $\Phi(\xi) = \xi$ und $\Phi'(\xi) \neq 1$ existiert.*

Beweis: Aus der Definition (5.10.8) von Ψ erhält man leicht

$$(\xi - \Psi(\xi))(\Phi(\Phi(\xi)) - 2\Phi(\xi) + \xi) = (\xi - \Phi(\xi))^2.$$

Also folgt aus $\Psi(\xi) = \xi$ sofort $\Phi(\xi) = \xi$. Sei nun umgekehrt $\Phi(\xi) = \xi$, Φ für $x = \xi$ differenzierbar, sowie $\Phi'(\xi) \neq 1$. Dann gilt nach der L'Hospitalschen Regel angewandt auf (5.10.8)

$$\begin{aligned} \Psi(\xi) &= \frac{\Phi(\Phi(\xi)) + \xi\Phi'(\Phi(\xi))\Phi'(\xi) - 2\Phi(\xi)\Phi'(\xi)}{\Phi'(\Phi(\xi))\Phi'(\xi) - 2\Phi'(\xi) + 1} \\ &= \frac{\xi + \xi\Phi'(\xi)^2 - 2\xi\Phi'(\xi)}{1 + \Phi'(\xi)^2 - 2\Phi'(\xi)} = \xi. \quad \square \end{aligned}$$

Wir wollen nun das Konvergenzverhalten von Ψ in der Nähe eines Fixpunktes ξ von Ψ (und Φ) untersuchen und setzen dazu voraus, daß Φ in einer Umgebung von $x = \xi$ $(p+1)$ -mal stetig differenzierbar ist und sich dort wie ein Verfahren p -ter Ordnung verhält, d. h. (s. 5.2)

$$(5.10.10) \quad \Phi'(\xi) = \dots = \Phi^{(p-1)}(\xi) = 0, \quad \Phi^{(p)}(\xi) =: p!A \neq 0.$$

Für $p = 1$ sei wieder zusätzlich gefordert

$$(5.10.11) \quad A = \Phi'(\xi) \neq 1.$$

Sei nun o. B. d. A. $\xi = 0$. Dann gilt für kleines x

$$\Phi(x) = Ax^p + \frac{x^{p+1}}{(p+1)!} \Phi^{(p+1)}(\theta x), \quad 0 < \theta < 1,$$

also

$$\begin{aligned}
\Phi(x) &= Ax^p + O(x^{p+1}), \\
\Phi(\Phi(x)) &= A(Ax^p + O(x^{p+1}))^p + O((Ax^p + O(x^{p+1}))^{p+1}) \\
&= \begin{cases} O(x^{p^2}), & \text{falls } p > 1, \\ A^2x + O(x^2), & \text{falls } p = 1, \end{cases} \\
\Phi(x)^2 &= (Ax^p + O(x^{p+1}))^2 = A^2x^{2p} + O(x^{2p+1}).
\end{aligned}$$

Somit ist für $p > 1$ wegen (5.10.8)
(5.10.12)

$$\Psi(x) = \frac{O(x^{p^2+1}) - A^2x^{2p} + O(x^{2p+1})}{O(x^{p^2}) - 2Ax^p + O(x^{p+1}) + x} = -A^2x^{2p-1} + O(x^{2p}).$$

Für $p = 1$ hat man dagegen wegen $A \neq 1$

$$\Psi(x) = \frac{A^2x^2 + O(x^3) - A^2x^2 + O(x^3)}{A^2x + O(x^2) - 2Ax + O(x^2) + x} = O(x^2).$$

Damit ist folgender Satz gezeigt:

(5.10.13) **Satz:** *Durch die Iterationsfunktion Φ sei ein Verfahren p -ter Ordnung zur Bestimmung des Fixpunktes ξ von Φ gegeben. Dann ist für $p > 1$ das durch Ψ (5.10.8) bestimmte Iterationsverfahren ein Verfahren der Ordnung $2p - 1$ zur Bestimmung von ξ und falls $p = 1$, $\Phi'(\xi) \neq 1$, ein Verfahren von mindestens zweiter Ordnung.*

Man beachte, daß durch Ψ selbst dann ein Verfahren zweiter Ordnung und damit ein lokal quadratisch konvergentes Verfahren gegeben ist, falls $|\Phi'(\xi)| > 1$, d.h. falls das durch Φ gegebene Iterationsverfahren lokal divergiert (s. 5.2). Die Methode von Steffensen ist im übrigen nur für genau diesen Fall $p = 1$ interessant. Für $p > 1$ ist es besser, das ursprüngliche durch Φ gegebene Verfahren zu benutzen, wie man sofort sieht: Ist etwa $\varepsilon := x_i - \xi$, und $|\varepsilon|$ genügend klein, so ist bis auf Glieder höherer Ordnung

$$\begin{aligned}
\Phi(x_i) - \xi &\doteq A\varepsilon^p \\
\Phi(\Phi(x_i)) - \xi &\doteq A^{p+1}\varepsilon^{p^2},
\end{aligned}$$

während für $x_{i+1} - \xi$, $x_{i+1} := \Psi(x_i)$ wegen (5.10.12) gilt

$$x_{i+1} - \xi = -A^2\varepsilon^{2p-1}.$$

Nun ist für $p > 1$ und kleines $|\varepsilon|$ sicherlich

$$|A^{p+1}\varepsilon^{p^2}| \ll |A^2\varepsilon^{2p-1}|,$$

so daß $\Phi(\Phi(x_i))$ ein sehr viel besserer Näherungswert für ξ ist als $x_{i+1} = \Psi(x_i)$. Aus diesem Grunde sollte man die Methode von Steffensen nur für den Fall $p = 1$ anwenden.

Beispiel: Die Iterationsfunktion $\Phi(x) = x^2$ besitzt die Fixpunkte $\xi_1 = 0$, $\xi_2 = 1$, und es ist

$$\Phi'(\xi_1) = 0, \quad \Phi'(\xi_2) = 2 \quad \Phi''(\xi_1) = 2.$$

Für die Iteration $x_{i+1} = \Phi(x_i)$ erhält man für $|x_0| < 1$ quadratische Konvergenz gegen ξ_1 und für $|x_0| > 1$ eine divergente Folge $\{x_i\}$.

Die Transformation (5.10.8) liefert

$$\Psi(x) = \frac{x^3}{x^2 + x - 1} = \frac{x^3}{(x - r_1)(x - r_2)} \quad \text{mit} \quad r_{1,2} = \frac{-1 \pm \sqrt{5}}{2}.$$

Mit der Iteration $x_{i+1} = \Psi(x_i)$ erreicht man bei geeigneter Wahl des Startwertes x_0 beide Fixpunkte.

Für $|x| \leq 0.5$ ist nämlich $\Psi(x)$ kontrahierend. Mit einer Wahl $|x_0| \leq 0.5$ konvergiert $x_{i+1} = \Psi(x_i)$ gegen $\xi_1 = 0$. In hinreichender Nähe von ξ_1 verhält sich dabei die Iteration wie

$$x_{i+1} = \Psi(x_i) \approx x_i^3,$$

während die Iteration $x_{i+1} = \Phi(\Phi(x_i))$, die für $|x_0| < 1$ konvergiert (siehe oben), die Konvergenzordnung 4 besitzt,

$$x_{i+1} = \Phi(\Phi(x_i)) = x_i^4.$$

Für $|x_0| > r_1$ konvergiert $x_{i+1} = \Psi(x_i)$ gegen $\xi_2 = 1$. Man zeigt leicht

$$\Psi'(1) = 0, \quad \Psi''(1) \neq 0$$

und damit die quadratische Konvergenz. Andererseits liefert $\Phi(x)$ keine Folge, die lokal gegen $\xi_2 = 1$ konvergiert.

5.11 Minimierungsprobleme ohne Nebenbedingungen

Wir betrachten folgendes Minimierungsproblem für eine reelle Funktion $h: \mathbb{R}^n \rightarrow \mathbb{R}$ von n Variablen:

$$(5.11.1) \quad \text{bestimme } \min_{x \in \mathbb{R}^n} h(x).$$

Wir setzen voraus, daß h mindestens zweimal nach allen Variablen stetig differenzierbar ist, $h \in C^2(\mathbb{R}^n)$, und bezeichnen mit $g(x) = Dh(x)^T = (\partial h / \partial x^1, \dots, \partial h / \partial x^n)^T$ den Gradienten und mit

$$H(x) = \left(\frac{\partial^2 h}{\partial x^i \partial x^k} \right), \quad i, k = 1, \dots, n,$$

die Matrix der zweiten Ableitungen von h .

Fast alle Minimierungsverfahren erzeugen ausgehend von einem Startvektor $x_0 \in \mathbb{R}^n$ iterativ eine Folge von Punkten x_k , $k \geq 0$, die das gesuchte Minimum $\bar{x}$ approximieren. In jedem Iterationsschritt $x_k \rightarrow x_{k+1}$,

mit $g_k = g(x_k) \neq 0$ (vgl. (5.4.1.3)), bestimmt man mittels einer verfahrenstypischen Rechenvorschrift eine Suchrichtung s_k und den nächsten Punkt

$$x_{k+1} = x_k - \lambda_k s_k$$

mittels einer „linearen Minimierung“, d. h. die Schrittweite λ_k wird so bestimmt, daß für x_{k+1} zumindest näherungsweise

$$h(x_{k+1}) \approx \min_{\lambda} \varphi_k(\lambda), \quad \varphi_k(\lambda) := h(x_k - \lambda s_k),$$

gilt. Gewöhnlich wird die Richtung s_k als eine *Abstiegsrichtung* von h gewählt, d. h. eine Richtung mit

$$(5.11.2) \quad \varphi'_k(0) = -g_k^T s_k < 0,$$

so daß man sich bei der Minimierung von $\varphi_k(\lambda)$ auf positive λ beschränken kann.

In Abschnitt 5.4.1 wurden allgemeine Konvergenzsätze aufgestellt (Sätze (5.4.1.4), (5.4.1.8)), die mit geringen Einschränkungen auf alle Verfahren dieses Typs angewandt werden können (s. Spellucci (1993) für eine detaillierte Beschreibung). In diesem Abschnitt wollen wir einige spezielle Verfahren zur Wahl von s_k kennenlernen, die heute mit großem Erfolg in der Praxis zur Lösung von Minimierungsproblemen eingesetzt werden. Ein (lokales) Minimum $\bar{x}$ von h ist Nullstelle von $g(x)$, $g(\bar{x}) = 0$, so daß man zur Bestimmung von Minima alle Verfahren zur Bestimmung der Nullstellen des Systems $g(x) = 0$ verwenden kann. Das wichtigste dieser Verfahren ist das Newton-Verfahren (5.1.6), bei dem in jedem Schritt $x_k \rightarrow x_{k+1} = x_k - \lambda_k s_k$ als Suchrichtung s_k die *Newton-Richtung* $s_k := H(x_k)^{-1} g_k$ genommen wird. Dieses Verfahren, kombiniert mit der konstanten Schrittweitenwahl $\lambda_k = 1$, hat den Vorteil der lokal quadratischen Konvergenz (Satz (5.3.2)), aber den großen Nachteil, daß man in jedem Iterationsschritt die Matrix $H(x_k)$ der zweiten Ableitungen von h bestimmen muß, was in der Regel für größeres n und kompliziertere Funktionen h sehr viel Rechenaufwand erfordert. Man versucht deshalb (vgl. Abschnitt 5.4.3), die Matrizen $H(x_k)^{-1}$ durch geeignete einfacher zu berechnende Matrizen H_k zu ersetzen,

$$s_k := H_k g_k.$$

Man spricht von einem *Quasi-Newton-Verfahren*, wenn für alle $k \geq 0$ die Matrix H_{k+1} die sog. *Quasi-Newton-Gleichung*

$$(5.11.3) \quad H_{k+1}(g_{k+1} - g_k) = x_{k+1} - x_k$$

erfüllt. Diese Bedingung stellt sicher, daß sich H_{k+1} in der Richtung $x_{k+1} - x_k$ ähnlich wie die Newton-Matrix $H(x_{k+1})^{-1}$ verhält, für die gilt

$$g_{k+1} - g_k = H(x_{k+1})(x_{k+1} - x_k) + O(\|x_{k+1} - x_k\|^2).$$

Für quadratische Funktionen $h(x) = \frac{1}{2}x^T A x + b^T x + c$, A eine positiv definite $n \times n$ -Matrix, erfüllt die Newton-Matrix $H(x_{k+1})^{-1} \equiv A^{-1}$ die Beziehung (5.11.3) wegen $g(x) \equiv Ax + b$ sogar exakt. Ferner erscheint es sinnvoll, als H_k nur positiv definite Matrizen zu wählen: Dies garantiert, daß für $g_k \neq 0$ die Richtung $s_k = H_k g_k$ eine Abstiegsrichtung für h wird (s. 5.11.2):

$$g_k^T s_k = g_k^T H_k g_k > 0.$$

Diese Forderungen lassen sich erfüllen: In Verallgemeinerung früherer Ansätze von Davidon (1959), Fletcher und Powell (1963) und Broyden (1965, 1967) hat Broyden (1970) eine 1-parametrische Rekursionsformel für die Berechnung von H_{k+1} aus H_k mit den verlangten Eigenschaften gefunden: Mit den Abkürzungen

$$p_k := x_{k+1} - x_k, \quad q_k := g_{k+1} - g_k$$

und dem frei wählbaren Parameter $\theta_k \geq 0$ hat sie die Gestalt

$$(5.11.4) \quad H_{k+1} := \Psi(\theta_k, H_k, p_k, q_k),$$

$$\Psi(\theta, H, p, q) := H + \left(1 + \theta \frac{q^T H q}{p^T q}\right) \frac{p p^T}{p^T q} - \frac{(1 - \theta)}{q^T H q} H q \cdot q^T H$$

$$- \frac{\theta}{p^T q} (p q^T H + H q p^T).$$

Ersetzt man in (5.11.4) die Matrix H_k durch $\gamma_k H_k$, $\gamma_k > 0$ ein weiterer „Skalierungs-Parameter“, erhält man eine 2-parametrische Update-Formel

$$(5.11.5) \quad H_{k+1} := \Psi(\theta_k, \gamma_k H_k, p_k, q_k),$$

die von Oren und Luenberger (1974) vorgeschlagen wurde.

Die „Update-Funktion“ Ψ ist nur für $p^T q \neq 0$, $q^T H q \neq 0$ erklärt. Man beachte, daß man H_{k+1} aus H_k dadurch erhält, daß man zur Matrix H_k eine Korrekturmatrix vom Rang ≤ 2 addiert:

$$\text{Rang}(H_{k+1} - H_k) \leq 2.$$

Man nennt diese Verfahren deshalb auch *Rang-2-Verfahren*.

Folgende Spezialfälle sind in (5.11.4) enthalten:

- a) $\theta_k \equiv 0$: Verfahren von Davidon (1959), Fletcher und Powell (1963) („DFP-Verfahren“).
- b) $\theta_k \equiv 1$: Rang-2-Verfahren von Broyden, Fletcher, Goldfarb und Shanno („BFGS-Verfahren“) (s. etwa Broyden (1970)).

- c) $\theta_k = p_k^T q_k / (p_k^T q_k - p_k^T H_k q_k)$: Symmetrisches Rang-1-Verfahren von Broyden.

Letzteres Verfahren ist nur für $p_k^T q_k \neq q_k^T H_k q_k$ definiert; $\theta_k < 0$ ist möglich: In diesem Fall kann H_{k+1} indefinit werden, auch wenn H_k positiv definit ist (vgl. Satz (5.11.9)). Setzt man den angegebenen Wert von θ_k in (5.11.4) ein, erhält man für H_k die Rekursionsformel

$$H_{k+1} = h_k + \frac{z_k z_k^T}{\alpha_k}, \quad z_k := p_k - H_k q_k, \quad \alpha_k := p_k^T q_k - q_k^T H_k q_k,$$

die den Namen Rang-1-Verfahren erklärt.

Ein Minimierungsverfahren der Broyden-Klasse hat daher folgende Form:

(5.11.6)

- 0) *Start: Wähle als Startwert einen Vektor $x_0 \in \mathbb{R}^n$ und eine positiv definite $n \times n$ -Matrix H_0 , etwa $H_0 := I$, und setze $g_0 := g(x_0)$.*

Für $k = 0, 1, \dots$ berechne x_{k+1} , H_{k+1} aus x_k und H_k folgendermaßen:

- 1) Falls $g_k = 0$ stop: x_k ist zumindest stationärer Punkt von h . Andernfalls,
- 2) berechne $s_k := H_k g_k$.
- 3) Bestimme $x_{k+1} = x_k - \lambda_k s_k$ durch (näherungsweise) lineare Minimierung,

$$h(x_{k+1}) \approx \min\{h(x_k - \lambda s_k) \mid \lambda \geq 0\},$$

und setze $g_{k+1} := g(x_{k+1})$, $p_k := x_{k+1} - x_k$, $q_k := g_{k+1} - g_k$.

- 4) Wähle eine passende Konstante $\theta_k \geq 0$ und berechne H_{k+1} mittels (5.11.4), $H_{k+1} = \Psi(\theta_k, H_k, p_k, q_k)$.

Das Verfahren ist eindeutig durch die Wahl der Parameter θ_k und durch die lineare Minimierung in Schritt 3) fixiert. Die lineare Minimierung $x_k \rightarrow x_{k+1}$ und ihre Qualität kann man mit Hilfe eines Parameters μ_k beschreiben, der durch

$$(5.11.7) \quad g_{k+1}^T s_k = \mu_k g_k^T s_k = \mu_k g_k^T H_k g_k$$

definiert ist. Falls s_k Abstiegsrichtung ist, $g_k^T s_k > 0$, ist μ_k eindeutig durch x_{k+1} bestimmt. Bei exakter linearer Minimierung ist $\mu_k = 0$ wegen $g_{k+1}^T s_k = -\varphi'_k(\lambda_k) = 0$, $\varphi_k(\lambda) := h(x_k - \lambda s_k)$. Wir setzen für das folgende

$$(5.11.8) \quad \mu_k < 1$$

voraus: Falls $g_k \neq 0$ und H_k positiv definit ist, folgt aus (5.11.8) $\lambda_k > 0$ und deshalb

$$q_k^T p_k = -\lambda_k (g_{k+1} - g_k) s_k = \lambda_k (1 - \mu_k) g_k^T s_k = \lambda_k (1 - \mu_k) g_k^T H_k g_k > 0,$$

also auch $q_k \neq 0$, $q_k^T H_k q_k > 0$: Die Matrix H_{k+1} ist damit durch (5.11.4) wohldefiniert. Die Forderung (5.11.8) kann nur dann nicht erfüllt werden, wenn

$$\varphi'_k(\lambda) = -g(x_k - \lambda s_k)^T s_k \leq \varphi'_k(0) = -g_k^T s_k < 0$$

für alle $\lambda \geq 0$ gilt: dann ist aber

$$h(x_k - \lambda s_k) - h(x_k) = \int_0^\lambda \varphi'_k(\tau) d\tau \leq -\lambda g_k^T s_k < 0 \quad \text{für alle } \lambda \geq 0,$$

so daß $h(x_k - \lambda s_k)$ für $\lambda \rightarrow +\infty$ nicht nach unten beschränkt ist. Die Forderung (5.11.8) bedeutet also keine wesentliche Einschränkung. Damit ist bereits der erste Teil des folgenden Satzes gezeigt, der besagt, daß das Verfahren (5.11.6) die oben aufgestellten Forderungen erfüllt:

(5.11.9) **Satz:** Falls für ein $k \geq 0$ in (5.11.6) H_k positiv definit ist, $g_k \neq 0$ und für die lineare Minimierung in (5.11.6) $\mu_k < 1$ gilt, dann ist für alle $\theta_k \geq 0$ die Matrix $H_{k+1} = \Psi(\theta_k, H_k, p_k, q_k)$ wohldefiniert und wieder positiv definit. Die Matrix H_{k+1} erfüllt die Quasi-Newton-Gleichung $H_{k+1} q_k = p_k$.

Beweis: Es bleibt nur folgende Eigenschaft der Funktion Ψ (5.11.4) zu zeigen: Unter den Voraussetzungen

$$H \text{ positiv definit, } p^T q > 0, \quad p^T H q > 0, \quad \theta \geq 0,$$

ist auch $\bar{H} := \Psi(\theta, H, p, q)$ positiv definit.

Sei $y \in \mathbb{R}^n$, $y \neq 0$ ein beliebiger Vektor und $H = LL^T$ die Cholesky-Zerlegung von H (Satz 4.3.3). Mit Hilfe der Vektoren

$$u := L^T y, \quad v := L^T q$$

läßt sich $y^T \bar{H} y$ wegen (5.11.4) so schreiben:

$$\begin{aligned} y^T \bar{H} y &= u^T u + \left(1 + \theta \frac{v^T v}{p^T q}\right) \frac{(p^T y)^2}{p^T q} - \frac{(1 - \theta)}{v^T v} (v^T u)^2 \\ &\quad - \frac{2\theta}{p^T q} p^T y \cdot u^T v \\ &= \left(u^T u - \frac{(u^T v)^2}{v^T v}\right) + \frac{(p^T y)^2}{p^T q} + \theta \left[\sqrt{v^T v} \frac{p^T y}{p^T v} - \frac{v^T u}{\sqrt{v^T v}} \right]^2 \\ &\geq \left(u^T u - \frac{(u^T v)^2}{v^T v}\right) + \frac{(p^T y)^2}{p^T q}. \end{aligned}$$

Die Schwarzsche Ungleichung ergibt $u^T u - (u^T v)^2 / v^T v \geq 0$, mit Gleichheit genau dann, wenn $u = \alpha v$ für ein $\alpha \neq 0$ (wegen $y \neq 0$). Für $u \neq \alpha v$ ist

also $y^T \bar{H} y > 0$. Für $u = \alpha v$ folgt aus der Nichtsingularität von H und L auch $0 \neq y = \alpha q$, so daß

$$y^T \bar{H} y \geq \frac{(p^T y)^2}{p^T q} = \alpha^2 p^T q > 0.$$

Da $0 \neq y \in \mathbb{R}^n$ beliebig war, muß $\bar{H}$ positiv definit sein. Die Quasi-Newton-Gleichung $\bar{H}q = p$ verifiziert man sofort mittels (5.11.4). $\square$

Der folgende Satz besagt, daß das Verfahren (5.11.6) das Minimum quadratischer Funktionen $h : \mathbb{R}^n \rightarrow \mathbb{R}$ nach höchstens n Schritten liefert, wenn die linearen Minimierungen in (5.11.6) exakt sind. Da sich jede genügend oft differenzierbare Funktion h in der Nähe eines lokalen Minimums beliebig genau durch eine quadratische Funktion approximieren läßt, läßt dies erwarten, daß das Verfahren auch bei Anwendung auf nichtquadratische Funktionen rasch konvergiert.

(5.11.10) **Satz:** Sei $h(x) = \frac{1}{2}x^T A x + b^T x + c$ eine quadratische Funktion, A eine positiv definite $n \times n$ -Matrix. Sei ferner $x_0 \in \mathbb{R}^n$ und H_0 eine positiv definite $n \times n$ -Matrix. Wendet man das Verfahren (5.11.6) zur Minimierung von h mit den Startwerten x_0, H_0 an, wobei man die linearen Minimierungen exakt durchführt, $\mu_i = 0$ für alle $i \geq 0$, so liefert das Verfahren Folgen $x_i, H_i, g_i, p_i := x_{i+1} - x_i, q_i := g_{i+1} - g_i$ mit den Eigenschaften:

- Es gibt ein kleinstes $m \leq n$ mit $x_m = \bar{x} = -A^{-1}b$: $x_m = \bar{x}$ ist das Minimum von h , $g_m = 0$.
- $p_i^T q_k = p_i^T A p_k = 0$ für $0 \leq i \neq k \leq m-1$,
 $p_i^T q_i > 0$ für $0 \leq i \leq m-1$.
Die Vektoren p_i sind also A -konjugiert.
- $p_i^T g_k = 0$ für alle $0 \leq i < k \leq m$.
- $H_k q_i = p_i$ für $0 \leq i < k \leq m$.
- Für $m = n$ gilt zusätzlich $H_m = H_n = A^{-1}$.

Beweis: Zu einem beliebigen Index $l \geq 0$ führen wir folgende Bedingungen ein

- $$\begin{aligned} \alpha) \quad & p_i^T q_k = p_i^T A p_k = 0 \text{ für } 0 \leq i \neq k \leq l-1, \\ & p_i^T q_i > 0 \text{ für } 0 \leq i \leq l-1, \\ (A_l) \quad & H_l \text{ positiv definit;} \\ \beta) \quad & p_i^T g_k = 0 \text{ für alle } 0 \leq i < k \leq l; \\ \gamma) \quad & H_k q_i = p_i \text{ für } 0 \leq i < k \leq l. \end{aligned}$$

Wir zeigen, daß aus $g_l \neq 0$ und (A_l) die Aussage (A_{l+1}) folgt:

Zu α) : Da H_l positiv definit ist, folgt aus $g_l \neq 0$ sofort $s_l := H_l g_l \neq 0$ und $g_l^T H_l g_l > 0$. Weil exakt minimiert wird, ist λ_l Nullstelle von

$$0 = g_{l+1}^T s_l = (g_l - \lambda_l A s_l)^T s_l, \quad \lambda_l = \frac{g_l^T H_l g_l}{s_l^T A s_l} > 0,$$

also $p_l = -\lambda_l s_l \neq 0$ und

$$(5.11.11) \quad \begin{aligned} p_l^T g_{l+1} &= -\lambda_l s_l^T g_{l+1} = 0, \\ p_l^T q_l &= -\lambda_l s_l^T (g_{l+1} - g_l) = \lambda_l s_l^T g_l = \lambda_l g_l^T H_l g_l > 0. \end{aligned}$$

Also ist nach Satz (5.11.9) H_{l+1} positiv definit. Weiter ist für $i < l$ wegen $A p_k = q_k$ und $(A_l) \beta, \gamma$:

$$p_i^T q_l = p_i^T A p_l = q_i^T p_l = -\lambda_l q_i^T H_l g_l = -\lambda_l p_i^T g_l = 0.$$

Dies zeigt $(A_{l+1}) \alpha$.

Zu β) : Für $i < l + 1$ gilt

$$p_i^T g_{l+1} = p_i^T \left(g_{i+1} + \sum_{j=i+1}^l q_j \right) = 0$$

nach dem eben Bewiesenen, $(A_l) \beta$ und (5.11.11).

Zu γ) : Anhand von (5.11.4) verifiziert man sofort

$$H_{l+1} q_l = p_l.$$

Wegen $(A_{l+1}) \alpha, (A_l) \gamma$ hat man ferner für $i < l$

$$p_l^T q_i = 0, \quad q_l^T H_l q_i = q_l^T p_i = 0,$$

so daß für $i < l$ aus (5.11.4) folgt

$$H_{l+1} q_i = H_l q_i = p_i.$$

Damit ist (A_{l+1}) bewiesen.

Der restliche Beweis ist nun einfach. (A_0) gilt trivialerweise. Die Aussage (A_l) kann nur für $l \leq n$ richtig sein, da nach (A_l) die l Vektoren $p_0, \dots, p_{l-1}$ linear unabhängig sind: Aus $\sum_{i \leq l-1} \alpha_i p_i = 0$ folgt nämlich durch Multiplikation mit $p_k^T A, k = 0, \dots, l-1$, wegen $(A_l) \alpha$

$$\alpha_k p_k^T A p_k = 0 \implies \alpha_k = 0.$$

Da nach dem eben Bewiesenen aus $g_l \neq 0$ und (A_l) stets (A_{l+1}) folgt, muß es also einen ersten Index $m \leq n$ mit

$$g_m = 0, \quad x_m = -A^{-1} b,$$

geben, d. h. es gilt a).

Für den Fall $m = n$ gilt wegen d) zusätzlich $H_n Q = P$ für die Matrizen $P := (p_0, \dots, p_{n-1})$, $Q = (q_0, \dots, q_{n-1})$. Wegen $AP = Q$ folgt so schließlich aus der Nichtsingularität der Matrix P die Beziehung $H_n = A^{-1}$. Damit ist der Satz bewiesen. $\square$

Es stellt sich nun die Frage, wie man die Parameter θ_k wählen soll, um ein möglichst gutes Verfahren zu erhalten: Nach praktischen Erfahrungen (s. Dixon (1971)) zu urteilen, scheint sich die Wahl

$$\theta_k \equiv 1 \quad (\text{BFGS - Verfahren})$$

am besten zu bewähren.

Ein anderer Vorschlag stammt von Davidon (1975): Mit den Abkürzungen

$$\varepsilon := p_k^T H_k^{-1} p_k, \quad \sigma := p_k^T q_k, \quad \tau := q_k^T H_k q_k$$

konnte er für die Wahl

$$\theta_k := \begin{cases} \sigma(\varepsilon - \sigma)/(\varepsilon\tau - \sigma^2), & \text{falls } \sigma \leq 2\varepsilon\tau/(\varepsilon + \tau), \\ \sigma/(\sigma - \tau) & \text{sonst,} \end{cases}$$

zeigen, daß man eine Matrix $H_{k+1} = H_{k+1}(\theta_k)$ erhält, die den Quotienten $\lambda_{\max}/\lambda_{\min}$ des größten und kleinsten Eigenwertes des folgenden allgemeinen Eigenwertproblems minimiert: Bestimme $\lambda \in \mathbb{C}$, $y \neq 0$ mit $H_{k+1}y = \lambda H_k y$, $\det(H_k^{-1}H_{k+1} - \lambda I) = 0$.

Vorschläge für die optimale Wahl der Parameter γ_k , θ_k des Oren-Luenberger-Verfahrens (5.11.5) findet man bei Oren und Spedicato (1974).

Satz (5.11.10) läßt erwarten, daß die Verfahren des Typs (5.11.4) auch bei Anwendung auf nichtquadratische Funktionen h schnell konvergieren. Für einzelne Verfahren der Broyden-Klasse konnte man dies auch formell beweisen. Diese Resultate beziehen sich meistens auf das lokale Konvergenzverhalten in genügend kleinen Umgebungen $U(\bar{x})$ eines lokalen Minimums $\bar{x}$ und h unter den folgenden Voraussetzungen:

a) $H(\bar{x})$ ist positiv definit

(5.11.12) b) $H(x)$ ist für $x = \bar{x}$ Lipschitz-stetig: es gibt ein Λ mit

$$\|H(x) - H(\bar{x})\| \leq \Lambda \|x - \bar{x}\| \text{ für alle } x \in U(\bar{x}).$$

Ferner müssen einige einfache Forderungen an die lineare Minimierung gestellt werden wie:

(5.11.13) Zu gegebenen Konstanten $0 < c_1 < c_2 < 1$, $c_1 \leq \frac{1}{2}$, wird $x_{k+1} = x_k - \lambda_k s_k$ so gewählt, daß gilt

$$\begin{aligned} h(x_{k+1}) &\leq h(x_k) - c_1 \lambda_k g_k^T s_k, \\ g_{k+1}^T s_k &\leq c_2 g_k^T s_k, \end{aligned}$$

oder

$$(5.11.14) \quad \lambda_k = \min\{\lambda \geq 0 \mid g(x_k - \lambda s_k)^T s_k = \mu_k g_k^T s_k\}, \quad |\mu_k| < 1.$$

So konnte Powell (1975) unter den Voraussetzungen (5.11.12), (5.11.13) für das BFGS-Verfahren ($\theta_k \equiv 1$) folgendes zeigen: Es gibt eine Umgebung $V(\bar{x}) \subseteq U(\bar{x})$, so daß das Verfahren für alle positiv definiten Startmatrizen H_0 und alle $x_0 \in V(\bar{x})$ folgende Eigenschaft besitzt: Für alle genügend großen $k \geq 0$ erfüllt die konstante Schrittweite $\lambda_k = 1$ die Bedingung (5.11.13) und die Folge x_k konvergiert bei dieser Wahl der λ_k *superlinear* gegen $\bar{x}$:

$$\lim_{i \rightarrow \infty} \frac{\|x_{i+1} - \bar{x}\|}{\|x_i - \bar{x}\|} = 0,$$

sofern $x_i \neq \bar{x}$ für alle $i \geq 0$.

Ein anderes Konvergenzresultat bezieht sich auf die Teilklasse der Broyden-Verfahren (5.11.4) mit $0 \leq \theta_k \leq 1$. Man kann hier unter den Voraussetzungen (5.11.12), (5.11.14) und der zusätzlichen Forderung, daß die lineare Minimierung *asymptotisch exakt* wird, d. h.

$$|\mu_k| \leq c \|g_k\| \quad \text{für genügend großes } k,$$

folgendes zeigen (vgl. Stoer (1977), Baptist und Stoer (1977)): Alle Verfahren mit $0 \leq \theta_k \leq 1$ liefern für alle positiv definiten Startmatrizen H_0 und alle x_0 mit genügend kleinem $\|x_0 - \bar{x}\|$ eine Folge $\{x_k\}$ mit

$$\lim_k x_k = \bar{x}, \quad \|x_{k+n} - \bar{x}\| \leq \gamma \|x_k - \bar{x}\|^2 \quad \text{für alle } k \geq 0.$$

Die Beweise dieser Resultate sind schwierig.

Das folgende Beispiel möge das unterschiedliche Verhalten des BFGS-, des DFP- und des einfachen Gradienten-Verfahrens ($s_k := g(x_k)$ in jedem Iterationsschritt) illustrieren. Wir wählen als zu minimierende Funktion

$$h(x, y) := 100(y^2(3-x) - x^2(3+x))^2 + \frac{(2+x)^2}{1+(2+x)^2}$$

mit dem exakten Minimum

$$\bar{x} := -2, \quad \bar{y} := 0.894\,271\,9099\dots, \quad h(\bar{x}, \bar{y}) = 0,$$

und als Startwerte für jedes der Verfahren

$$x_0 := 0.1, \quad y_0 := 4.2,$$

und zusätzlich

$$H_0 := \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

für das BFGS- und DFP-Verfahren.

Bei Verwendung der gleichen Methode zur linearen Minimierung in den einzelnen Iterationsschritten, die hier nicht näher beschrieben werden soll, erhielt man auf einer Rechenanlage mit der Maschinengenauigkeit $\text{eps} = 10^{-11}$ folgende Ergebnisse:

	BFGS	DFP	Gradientenverfahren
N	54	47	201
F	374	568	1248
ε	$\leq 10^{-11}$	$\leq 10^{-11}$	0.7

Hier bedeuten N die Anzahl der Iterationsschritte (= Anzahl der Gradientenauswertungen) $(x_k, y_k) \rightarrow (x_{k+1}, x_{k+1})$, F die Anzahl der Funktionsauswertungen von h und $\varepsilon := \|g(x_N, y_N)\|$ die erreichte Endgenauigkeit. Das Gradientenverfahren ist völlig unterlegen, das BFGS-Verfahren dem DFP-Verfahren leicht überlegen. (Die „linearen Minimierungen“ waren im übrigen nicht sonderlich effizient, da sie pro Iterationsschritt mehr als 6 Funktionsauswertungen erforderten.)

Übungsaufgaben zu Kapitel 5

- Es sei die stetig differenzierbare Iterationsfunktion $\Phi: \mathbb{R}^n \rightarrow \mathbb{R}^n$ gegeben. Wenn

$$\text{lub}(D\Phi(x)) \leq K < 1 \quad \text{für alle } x \in \mathbb{R}^n,$$

sind die Voraussetzungen von Satz (5.2.2) für alle $x, y \in \mathbb{R}^n$ erfüllt.

- Man zeige, daß die Iteration

$$x_{k+1} = \cos(x_k)$$

für alle $x_0 \in \mathbb{R}^n$ gegen den einzigen Fixpunkt $\xi = \cos \xi$ konvergiert.

- Man gebe ein lokales Verfahren zur Bestimmung des Fixpunktes $\xi = \sqrt[3]{2}$ von $\Phi(x) := x^3 + x - 2$ an. (Man benutze nicht die Aitken-Transformation).
- Die Funktion $f(x) = x^3 - x^2 - x - 1$ besitzt bei $\xi = 1.839 \dots$ die einzige positive Nullstelle. Ohne Benutzung von $f'(x)$ konstruiere man eine Iterationsfunktion $\Phi(x)$ mit dem Fixpunkt $\xi = \Phi(\xi)$, so daß die Iteration für alle Startwerte $x_0 > 0$ konvergiert.
- Man zeige $\lim_i x_i = 2$ für

$$x_0 := 0, \quad x_{i+1} := \sqrt{2 + x_i}.$$

- Gegeben ist die Abbildung $f: \mathbb{R}^2 \rightarrow \mathbb{R}^2$ mit

$$f(z) = \begin{bmatrix} \exp(x^2 + y^2) - 3 \\ x + y - \sin(3(x + y)) \end{bmatrix}, \quad z = \begin{bmatrix} x \\ y \end{bmatrix}.$$

Man berechne die erste Ableitung $Df(z)$. Für welche z ist $Df(z)$ singulär?

7. Das Polynom $p_0(x) = x^4 - 8x^3 + 24x^2 - 32x + a_4$ hat für $a_4 = 16$ die vierfache Nullstelle $x = 2$. Wo liegen in erster Näherung die Nullstellen für $a_4 = 16 \pm 10^{-4}$?
8. Man betrachte die Folge $\{z_i\}$ mit $z_{i+1} = \Phi(z_i)$, $\Phi: \mathbb{R} \rightarrow \mathbb{R}$. Der Fixpunkt ξ von $\Phi(z)$ ist Nullstelle von $F(z) = z - \Phi(z)$. Man zeige: Wendet man auf $F(z)$ einen Iterationsschritt der regula falsi mit

$$a_i = z_i, \quad x_i = z_{i+1}$$

an, so erhält man die Methode von Steffensen bzw. Aitken zur Transformation der Folge $\{z_i\}$ in die Folge $\{\mu_i\}$.

9. $f: \mathbb{R} \rightarrow \mathbb{R}$ habe eine einfache Nullstelle. Man zeige: Benutzt man $\Phi(x) := x - f(x)$ und die Rekursion (5.10.7), so erhält man das sog. Quasi-Newton-Verfahren

$$x_{n+1} := x_n - \frac{f(x_n)^2}{f(x_n) - f(x_n - f(x_n))}, \quad n = 0, 1, \dots$$

Man zeige, daß die so gefundene Iteration für einfache Nullstellen mindestens quadratisch und für mehrfache Nullstellen linear konvergiert. (Hinweis: Satz (5.10.13)).

10. Man berechne iterativ $x = 1/a$ für ein gegebenes $a \neq 0$ ohne Division. Für welche Startwerte x_0 konvergiert das Verfahren?
11. Man gebe ein lokal konvergentes Iterationsverfahren zweiter Ordnung zur Berechnung von $\sqrt[n]{a}$, $a > 0$, an. (Man verwende nur die arithmetischen Grundoperationen.)
12. Gegeben sei die nichtsinguläre Matrix A und eine Folge von Matrizen $\{X_k\}_{k=0,1,\dots}$ mit

$$X_{k+1} := X_k + X_k(I - AX_k)$$

(Verfahren von Schulz).

- a) Man zeige, daß $\text{lub}(I - AX_0) < 1$ hinreichend für die Konvergenz von $\{X_k\}$ gegen A^{-1} ist. Für $E_k := I - AX_k$ gilt

$$E_{k+1} = E_k E_k.$$

- b) Man zeige, daß das Verfahren von Schulz lokal quadratisch konvergent ist.

c) Mit $AX_0 = X_0 A$ gilt auch $AX_k = X_k A$ für alle $k \geq 0$.

13. Die Funktion $f: \mathbb{R} \rightarrow \mathbb{R}$ sei für alle $x \in U(\xi) := \{x \mid |x - \xi| \leq r\}$ aus einer Umgebung der einfachen Nullstelle ξ von f zweimal stetig differenzierbar. Man zeige, daß das Iterationsverfahren

$$\begin{aligned} y &:= x_n - f'(x_n)^{-1} f(x_n), \\ x_{n+1} &:= y - f'(x_n)^{-1} f(y), \end{aligned} \quad n = 0, 1, \dots,$$

lokal gegen ξ konvergiert und mindestens die Ordnung 3 besitzt.

14. Die reellwertige Funktion $f \in C^2(\mathbb{R})$ habe die einfache Nullstelle ξ und erfülle $f'(x) \neq 0$ für alle x mit $|x - \xi| \leq r$. Definiere die Iteration $x_{k+1} := x_k - \frac{f(x_k)}{q(x_k)}$ mit $q(x) := (f(x) + f(x)) - f(x))/f(x)$ für $x \neq \xi$. Man zeige:
- a) Für alle x gilt

$$f(x + f(x)) - f(x) = f(x) \int_0^1 f'(x + tf(x)) dt.$$

- b) Die Funktion $q(x)$ läßt sich nach $x = \xi$ stetig differenzierbar fortsetzen vermöge

$$q(x) = \int_0^1 f'(x + tf(x)) dt.$$

- c) Die Funktion $q(x)$ genügt der Abschätzung $|q(x) - f'(x)| \leq c|f(x)|$ mit einem geeigneten c (Interpretation der Abschätzung?).
 d) Das Verfahren besitzt die Form $x_{k+1} = \Phi(x_k)$ mit einer differenzierbaren Iterationsfunktion Φ . Man gebe Φ an und zeige $\Phi(\xi) = \xi$, $\Phi'(\xi) = 0$, d. h. es handelt sich um ein Verfahren zweiter Ordnung mit Grenzwert ξ .
15. Die Funktion $f: \mathbb{R}^n \rightarrow \mathbb{R}^n$ genüge folgenden Voraussetzungen:
- 1) $f(x)$ sei für alle $x \in \mathbb{R}^n$ stetig differenzierbar,
 - 2) für alle $x \in \mathbb{R}^n$ existiere $Df(x)^{-1}$,
 - 3) es gelte $x^T f(x) \geq \gamma(|x|)||x||$ für alle $x \in \mathbb{R}^n$, wobei $\gamma(\rho)$ eine für $\rho \geq 0$ stetige Funktion mit $\gamma(\rho) \rightarrow +\infty$ für $\rho \rightarrow \infty$ ist.
 - 4) Für alle $x, h \in \mathbb{R}^n$ gelte

$$h^T Df(x)h \geq \mu(|x|)||h||^2,$$

mit $\mu(\rho)$ monoton wachsend in $\rho > 0$, $\mu(0) = 0$ und $\int_0^\infty \mu(\rho) d\rho = +\infty$. Dann sind unter den Voraussetzungen 1) 2) 3) oder 1) 2) 4) die Voraussetzungen a)–c) von Satz (5.4.2.5) erfüllt. Für 4) benutze man die Taylorentwicklung

$$f(x+h) - f(x) = \int_0^1 Df(x+th)h dt.$$

16. Man gebe die Rekursionsformeln zur Berechnung der Größen A_1, B_1 des Bairstow-Verfahrens an.
17. (Tornheim (1964)) Man betrachte eine skalare Funktion von $r+1$ Variablen $x_0, x_1, \dots, x_r \in \mathbb{R}$

$$\varphi(x_0, x_1, \dots, x_r)$$

und die zugehörige *Mehrschrittiteration*

$$y_{i+1} := \varphi(y_i, y_{i-1}, y_{i-2}, \dots, y_{i-r}), \quad i = 0, 1, \dots,$$

wobei $y_0, y_{-1}, \dots, y_{-r}$ vorgegeben seien. φ besitze stetige partielle Ableitungen von mindestens $r+1$ -ter Ordnung. y^* heißt Fixpunkt von φ , wenn für alle $k = 1, \dots, r$ und beliebige $x_i, i \neq k$ gilt:

$$(*) \quad y^* = \varphi(x_0, \dots, x_{k-1}, y^*, x_{k+1}, \dots, x_r).$$

Man zeige:

- a) Für die partiellen Ableitungen von φ

$$D^s \varphi(x_0, \dots, x_r) := \frac{\partial^{|s|} \varphi(x_0, \dots, x_r)}{\partial x_0^{s_0} \partial x_1^{s_1} \dots \partial x_r^{s_r}},$$

mit $s = (s_0, \dots, s_r)$, $|s| := \sum_{j=0}^r s_j$ gilt $D^s \varphi(y^*, \dots, y^*) = 0$, falls $s_j = 0$ für ein j , $0 \leq j \leq r$ ist. (Man beachte, daß $(*)$ für alle k identisch in $x_0, \dots, x_{k-1}, x_{k+1}, \dots, x_r$ gilt.)

- b) In einer hinreichend kleinen Umgebung von y^* gilt für $\varepsilon_i := |y_i - y^*|$, die Rekursion

$$(**) \quad \varepsilon_{i+1} \leq c \varepsilon_i \varepsilon_{i-1} \dots \varepsilon_{i-1}$$

mit einer geeigneten Konstante c .

- c) Man gebe eine obere Schranke für die Lösung der Rekursion $(**)$ und die lokale Konvergenzordnung der y_i an.

18. Man zeige (5.9.14).

Literatur zu Kapitel 5

- Baptist, P., Stoer, J. (1977): On the relation between quadratic termination and convergence properties of minimization algorithms. Part II. Applications. *Numer. Math.* **28**, 367–391.
- Bauer, F.L. (1956): Beiträge zur Entwicklung numerischer Verfahren für programmgesteuerte Rechenanlagen. II. Direkte Faktorisierung eines Polynoms. *Bayer. Akad. Wiss. Math. Natur. Kl. S.B.* 163–203.
- Brent, R.P. (1973): *Algorithms for Minimization without Derivatives*. Englewood Cliffs, N.J.: Prentice-Hall.
- Broyden, C.G. (1965): A class of methods for solving nonlinear simultaneous equations. *Math. Comput.* **19**, 577–593.
- Broyden, C.G. (1967): Quasi-Newton-methods and their application to function minimization. *Math. Comput.* **21**, 368–381.
- Broyden, C.G. (1970): The convergence of a class of double rank minimization algorithms. 1. General considerations, 2. The new algorithm. *J. Inst. Math. Appl.* **6**, 76–90, 222–231.
- Broyden, C.G., Dennis, J.E., Moré, J.J. (1970): On the local and superlinear convergence of quasi-Newton methods. *J. Inst. Math. Appl.* **12**, 223–245.
- Collatz, L. (1968): *Funktionalanalysis und numerische Mathematik*. Die Grundlehren der mathematischen Wissenschaften in Einzeldarstellungen. Bd. 120. Berlin-Heidelberg-New York: Springer.
- Collatz, L., Wetterling, W. (1971): *Optimierungsaufgaben*. Berlin-Heidelberg-New York: Springer.
- Davidon, W.C. (1959): Variable metric methods for minimization. Argonne National Laboratory Report ANL-5990.
- Davidon, W.C. (1975): Optimally conditioned optimization algorithms without line searches. *Math. Programming* **9**, 1–30.
- Dixon, L.C.W. (1971): The choice of step length, a crucial factor in the performance of variable metric algorithms. In: *Numerical Methods for Nonlinear Optimization*. F.A. Lootsma, ed., 149–170. New York: Academic Press.

- Fletcher, R., Powell, M.J.D. (1963): A rapidly convergent descent method for minimization. *Comput. J.* **6**, 163–168.
- Fletcher, R. (1980): *Unconstrained Optimization*. New York: Wiley.
- Fletcher, R. (1981): *Constrained Optimization*. New York: Wiley.
- Gill, P.E., Golub, G.H., Murray, W., Saunders, M.A. (1974): Methods for modifying matrix factorizations. *Math. Comput.* **28**, 505–535.
- Griewank, A. (2000): *Evaluation, Derivatives, Principles and Techniques of Algorithmic Differentiation*. Frontiers in Appl. Math., Number 19. Philadelphia: SIAM.
- Henrici, P. (1974): *Applied and Computational Complex Analysis*. Vol. 1. New York: Wiley.
- Himmelblau, D.M. (1972): *Applied Nonlinear Programming*. New York: McGraw-Hill.
- Householder, A.S. (1970): *The Numerical Treatment of a Single Non-linear Equation*. New York: McGraw-Hill.
- Jenkins, M.A., Traub, J.F. (1970): A three-stage variable-shift iteration for polynomial zeros and its relation to generalized Rayleigh iteration. *Numer. Math.* **14**, 252–263.
- Luenberger, D.G. (1973): *Introduction to Linear and Nonlinear Programming*. Reading, Mass.: Addison-Wesley.
- Maehly, H. (1954): Zur iterativen Auflösung algebraischer Gleichungen. *Z. Angew. Math. Physik* **5**, 260–263.
- Marden, M. (1966): *Geometry of Polynomials*. Providence, R.I.: Amer. Math. Soc.
- Nickel, K. (1966): Die numerische Berechnung der Wurzeln eines Polynoms. *Numer. Math.* **9**, 80–98.
- Oren, S.S., Luenberger, D.G. (1974): Self-scaling variable metric (SSVM) algorithms. I. Criteria and sufficient conditions for scaling a class of algorithms. *Manage. Sci.* **20**, 845–862.
- Oren, S.S., Spedicato, E. (1974): Optimal conditioning of self-scaling variable metric algorithms. Stanford University Dept. of Engineering, Economic Systems Report ARG-MR 74–5.
- Ortega, J.M., Rheinboldt, W.C. (1970): *Iterative Solution of Non-linear Equations in Several Variables*. New York: Academic Press.
- Ostrowski, A.M. (1973): *Solution of Equations in Euclidean and Banach Spaces*. New York: Academic Press.
- Peters, G., Wilkinson, J.H. (1969): Eigenvalues of $Ax = \lambda Bx$ with band symmetric A and B . *Comput. J.* **12**, 398–404.
- Peters, G., Wilkinson, J.H. (1971): Practical problems arising in the solution of polynomial equations. *J. Inst. Math. Appl.* **8**, 16–35.
- Powell, M.J.D. (1975): Some global convergence properties of a variable metric algorithm for minimization without exact line searches. In: *Proc. AMS Symposium on Nonlinear Programming 1975*. Amer. Math. Soc.
- Spellucci, P. (1993): *Numerische Verfahren der nichtlinearen Optimierung*. Basel: Birkhäuser.

- Stoer, J. (1975): On the convergence rate of imperfect minimization algorithms in Broyden's β -class. *Math. Programming* **9**, 313–335.
- Stoer, J. (1977): On the relation between quadratic termination and convergence properties of minimization algorithms. Part I. Theory. *Numer. Math.* **28**, 343–366.
- Tornheim, L. (1964): Convergence of multipoint methods. *J. Assoc. Comput. Mach.* **11**, 210–220.
- Traub, J.F. (1964): *Iterative Methods for the Solution of Equations*. Englewood Cliffs, NJ: Prentice-Hall.
- Wilkinson, J.H. (1959): The evaluation of the zeros of ill-conditioned polynomials. Part I. *Numer. Math.* **1**, 150–180.
- Wilkinson, J.H. (1969): *Rundungsfehler*. Heidelberger Taschenbücher, Bd. 44, Berlin-Heidelberg-New York: Springer.
- Wilkinson, J.H. (1965): *The Algebraic Eigenvalue Problem*. Oxford: Clarendon Press.

Namen- und Sachverzeichnis

- Abbildungsdehnung 220
Abbrechfehler 1
Abdivision eines Polynoms 338
Abminderungsfaktoren 99, 101
Abramowitz 186
absoluter Fehler 12
absolutstetig 99
Abstiegsrichtung 362 f.
Achieser 99
Äquivalenz von Normen 219
Ahlberg 106
Aitken 192, 356 ff., 371
–, Algorithmus von 47
–, Δ^2 -Methode 357 ff., 370
Algorithmus 9
–, zweistufig 19
Analogrechner 2
Andersen 199
Approximationsfehler 1
Armijo-line search 319
Ashenhurst 5
asymptotisch exakt 369
asymptotische Entwicklung 170
Auffüllung 286
Ausgleichsprobleme, lineare 243 ff.
–, nichtlineare 253 ff.
Ausgleichsrechnung 242 ff.
Auslöschung 8, 14
- backward-analysis 28
Bairstow, Verfahren von 346 ff.
Banachiewicz 207 f.
Banachscher Fixpunktsatz 309
Bandmatrix 209
Baptist 369
Barker 284
Bartels 278
- Basis 269
Basislösung 269
Basisvariable 269
Bauer 19, 21, 170, 174, 329
benachbarte Basen 271
Bernoulli-Polynome 168
Bernoullizahlen 166, 168
BFGS-Verfahren 363, 369 f.
Bisektionsverfahren 341 ff., 351
bit-reversal 91
Bit-Umkehrabbildung 91
Bixby 281
Björck 244
Bloomfield 88
Böhmer 104
Brent 356
Brigham 88
Broyden 325 ff., 363
Broyden-Klasse 364, 368
B-Splines 114, 119 ff.
Bulirsch 77, 97, 113, 172 ff., 176 f., 192
- Cauchysche Konvergenzkriterium 306
charakteristisches Polynom 329
Cholesky 217
Cholesky-Verfahren 214 ff., 284, 286
Cholesky-Zerlegung 245, 329
Chui 133, 142
Ciarlet 63
Clique 287
Cliquesbeschreibung 291
Collatz 223, 314
Cooley 88, 100
– -Tukey, Algorithmus von 88, 92 ff., 100
Cotes 156

- Crout 207 f.
- Curry 123

- Daniel 260, 262
- Dantzig 267, 271, 282
- Daubechies 141, 143
- Davidon 363, 368
- Davis 156, 161
- de Boor 104 f., 113, 130
- Deflation, eines Polynoms 338
- , Rückwärts- 338
- , Vorwärts- 338
- Dekker 352
- Dennis 328
- Determinante 208
- Dezimaldarstellung 2
- DFP-Verfahren 363, 369
- DFT-Verfahren 85
- Differentiation, numerische 175
- differentielle Fehleranalyse 12
- Differenzen
- , dividierte 49, 355
- -gleichung 138
- , inverse 68 ff.
- -operator 357
- -quotient 175
- , reziproke 68 ff.
- -schema 49
- , verallgemeinerte dividierte 60, 120
- differenzierbar 311
- Digitalrechner 2
- diskrete Fouriertransformation 85
- Diskretisierungsfehler 1
- Diskretisierungsverfahren 174
- Dixon 368
- Dongarra 199
- Doppelschritt-Verfahren 333 ff.
- 3/8-Regel 158
- Dreiecksungleichung 218
- Dreieckszerlegung 200 ff., 204
- duale Funktion 134
- Dualstellen 3
- Dualsystem 3
- dünn besetzte Matrizen 217, 284 ff.
- Duff 284, 293

- Eingangsfehler 1
- Eisenstat 293
- elementare Abbildung 10
- elementare Operation 9
- Eliminationsverfahren 200 ff., 284 ff.
- equilibrierte Matrizen 227
- Erismen 284, 293
- Erwartungswert 245
- euklidische Norm 218, 234
- euklidischer Algorithmus 342
- Euler-Maclaurinsche Summenformel 166
- Exponenten 4
- -unterlauf 6
- -überlauf 6
- Exponentialspline 152
- Exponentialsummen 42

- Faber 55
- Faktorisierung, numerische 287, 292
- , symbolische 287
- Faltung 85 f.
- Fast-Fourier-Transform 88
- Fehler
- -abschätzungen 217 ff.
- -analyse, differentielle 12
- -dämpfung 14, 30
- -fortpflanzung 9
- , unvermeidbare 19
- Festpunktdarstellung 3
- FFT-Verfahren 88
- fill-in 286
- Fixpunkt 302, 305
- -satz von Banach 309
- Fletcher 363
- Fourierintegrale 88
- Fourierkoeffizienten 99
- Fouriersynthese 85, 95
- Fourierttransformation, schnelle 88 ff.
- freie Variable 268
- Frobeniusmatrizen 201

- Gass 267
- Gautschi 102, 187
- Gauß 186, 243
- -Elimination 200
- -Integration 180 ff., 193
- -Jordan-Algorithmus 210 ff.
- -Newton-Algorithmus 255
- -Quadratur 180 ff.
- Gentleman 88
- geometrische Folge 357

George 284, 291, 293
gestaffelte Gleichungssysteme 200,
206, 232 ff., 247
Gewichtsfunktion 180
Gill 260, 329
Givens-Matrizen 261 f.
Givens-Reflexionen 262
Givens-Rotationen 262
Gleichverteilung 32
Gleitpunkt,
– -darstellung 4
– -operation 7
– -rechnung 5
globale Konvergenz 306
Goertzel 95 ff.
–, Algorithmus von 95 ff.
Goldfarb 363
Goldstein 7
Golub 187, 189, 199, 260, 329
Grad eines Knotens 287
Gradienten-Verfahren 369
Gradshteyn 155
Gragg 260, 262
Gram-Schmidtsches Orthogonalisie-
rungsverfahren 239, 247
Grenznorm 220
Greville 104 f., 113
Gröbner 155
größter gemeinsamer Teiler 342
Guest 243
gut konditioniertes Problem 13
Gutartigkeit eines Problems 19, 226

Haar,
– -Bedingung 184
– -Funktion 131
– -Wavelet 142
Hadley 282
halblogarithmische Schreibweise 4
Hall 118
Hanson 244
harmlose Rundungsfehler 19
Hauptabschnittsmatrix 331
Henrici 161, 329, 341
Hermite
– -Interpolation 56, 159
– -Polynome 186
Hermiteische Funktionen 62
Herriot 113

Hesse-Matrix 328
Hessenberg-Matrizen 230, 263, 277
Hofreiter 155
Holladay 106
Homogenität von Normen 218
Hornerschema 330
Householder 234 ff., 333
– -Matrizen 237
– -transformationen 237
Hut-Funktion 133

Integrale, mit Singularitäten 190 ff.
–, uneigentliche 192 f.
Interpolation 41 ff.
–, durch Polynome 41 ff.
–, rationale 42, 63 ff.
–, Spline- 42, 104 ff.
–, trigonometrische 41, 79 ff.
Interpolationsformel von Lagrange
43 f., 56 f., 156, 176
Intervallalgorithmen 30
Intervalloperationen 30
Intervallrechnung 29 ff.
Inverse-Basis-Methode 278
inverse Differenzen 68
inverse Interpolation 356
involutorische Abbildung 235

Jenkins 329

Karlin 129
Kaufman 260, 262
Kettenbruch 70
Klatte 31
Kondition, eines Problems 13
–, einer Matrix 221
–, von Ausgleichsproblemen 247 ff.
–, von Nullstellenproblemen 348 ff.
kontrahierende Abbildung 309
Konvergenz
– -bereich 306
– -beschleunigung 357
– -faktor 306
– -geschwindigkeit 306
– -ordnung 306
konvex 311
Kovarianzmatrix 246
Kronrod 190
künstliche Variable 282

- Kulisch 31
 Luchli 251
 Lagrangepolynome 43, 57
 Lagrangesche Interpolationsformel 43, 56 f., 176
 Laguerre-Polynome 186
 Lawson 244
 Legendre-Polynome 186, 195
 Leibniz Formel 125
 line search 317
 lineare Konvergenz 306
 lineare Minimierungsprobleme 267 ff.
 lineare Funktionale 162
 lineare Interpolationsprobleme 41
 lineare Programme 267 ff.
 Linearisierung 304
 Liu 284, 291, 293
 lokale Konvergenz 306
 Louis 143
 Luenberger 302, 363

 Machly 67, 339
 Mallat 143
 Mantissee 4
 Marden 333
 Maschinengenauigkeit 6
 Maschinenzahlen 5
 Matrixnorm 219 f.
 Maximumnorm 218
 Methode der kleinsten Quadrate 243
 Methode von Steffensen 360
 Metropolis 5
 Meyer 118
 Milne 67
 Milne-Regel 158
 Milne-Thompson 71
 Minimaleigenschaft von Splines 108
 Minimalgradalgorithmus 288, 290
 Minimierungsprobleme, allgemeine 301, 316 ff., 361
 –, lineare 267 ff.
 –, ohne Nebenbedingungen 361 ff.
 Minimum-Norm-Eigenschaft 107
 Mittelwert 32
 Modifikationstechniken 258 ff.
 modifiziertes Newton-Verfahren 315 ff., 321 ff.
 Momente 109

 Moore 31
 Moore-Penrose-Inverse 255
 Mor 328
 Muller 354
 Multi-Resolutions-Verfahren 130 ff.
 Murray 260, 329
 Murty 267, 282

 Nachorthogonalisierung 241
 naturliche Splinefunktionen 108
 Neville-Verfahren 356
 Newton-Cotes-Formel 156 f., 165
 Newton
 – -Interpolation 48 ff.
 – -Kantorovich, Satz von 314
 – -Raphson-Verfahren 304
 – -Richtung 315, 362
 – -Verfahren 305, 311 ff., 329 ff.
 Ng 293
 nicht entartete Basis 271
 Nichtbasisvariable 269
 nichtlineare Ausgleichsprobleme 253 ff.
 Nickel 329
 Nilson 106
 Norm(en) 218 ff.
 –, quivalenz von 219
 –, euklidische 218
 –, Grenzen- 220
 –, Matrix- 219 f.
 –, Maximum- 218
 –, Schur 220
 –, Zeilensummen- 220
 Normalgleichungen 243 f., 250
 normalisierte Zahldarstellung 4
 Nullstellenbestimmung 301 ff.
 –, fur Polynome 329 ff.
 –, Interpolationsmethoden 351 ff.
 Nullstellenunterdruckung 339
 numerisch stabil 18 f.
 numerische Differentiation 175
 numerische Faktorisierung 287, 292

 Oettli 223 f., 233
 Optimallosung 269
 Ordnung, von Integrationsmethoden 158, 181
 –, von Iterationsverfahren 306
 Oren 363, 368

- Oren-Luenberger-Klasse 363, 368
- Ortega 314
- Orthogonalisierungsverfahren 234 ff., 246 ff.
- Orthogonalitätsrelationen 82, 147
- Orthogonalpolynome 181
- orthonormales Wavelet 141
- Orthonormalisierungsverfahren 239
- Ostrowski 356

- PASCAL-XSC 31
- Peano 162
- , -Kern 162
- Peanosche Fehlerdarstellung 162 ff.
- periodische Splinefunktionen 105
- Peters 338 f., 341, 351 f.
- Phase I der Simplexmethode 272, 281 ff.
- Phase II der Simplexmethode 271 ff.
- Piessens 156, 190
- Pinkus 130
- Pivotclique 290
- Pivotelement 201
- Pivotknoten 289
- Pivotsuche 201, 226 ff.
- , Spalten- 202
- , Teil- 202
- , Total- 202
- Polynome, Nullstellenbestimmung 329 ff.
- Polynomfunktionen, stückweise 119 ff.
- Polynominterpolation 42 ff.
- , Methoden 43 ff.
- , Restglied der 53 ff., 62
- positiv definit 214
- positiv semidefinit 214
- Powell 363, 369
- Prager 223 f., 233
- Pseudoinverse 255 f.

- QR-Zerlegung 239
- quadratische Konvergenz 306
- Quasi-Newton-Verfahren 362

- Rabinowitz 156, 161
- Rademacher 32
- Rang-1-Verfahren 325 ff.
- Rang-2-Verfahren 329, 363
- rationale Funktionen 63, 65
- , Interpolation durch 63 ff.
- rationaler Ausdruck 65
- reduzierte Kosten 273
- regula falsi 351, 353, 371
- Reid 284, 293
- Reinsch 95, 97, 102, 113, 199, 244, 278
- relative Varianzen 34
- relativer Fehler 6, 12
- Residuum 27, 221
- Restabbildung 15
- Restglied, der Polynominterpolation 53 ff.
- , der Hermite-Interpolation 62
- , von Integrationsregeln 158 ff.
- reziproke Differenzen 71
- Rheinboldt 314
- Riesz-Basis 131
- Romberg 170, 172, 180
- , -Integration 170 ff.
- Rose 284, 288, 290
- Rückwärtsdeflation 338
- Rundung 5
- Rundungsfehler 1, 5
- -Abschätzung, statistische 29, 32 ff.
- -Analyse der Gauß-Elimination 226 ff.
- , harmlose 19
- Rutishauser 4, 77, 113, 170, 174
- Ryzhik 155

- Sande 88
- Sande-Tukey-Verfahren 88
- Satz von Rolle 54, 118, 332
- Saunders 260, 329
- Sautter 233
- Schlupfvariable 268
- Schmidtsches Orthogonalisierungsverfahren 182, 234
- schnelle Fouriertransformation 88 ff.
- Schoenberg 123, 129
- Schrijver 267
- Schrittweiten 315
- Schultz 63, 104
- Schur-Norm 220
- Secrest 181
- Sekantenmethode 305, 353 f.
- Seminorm 106
- Shanno 363

- Simplexmethode 267 ff., 271, 276
- , Phase I 281 ff.
- , Phase II 271 ff.
- Simplexschritt 271 f.,
- Simpson-Regel 157 f., 164
- singuläre Werte 258
- Skalierung von Matrizen 227
- Skalierungsfunktion 131
- Spaltenpivotsuche 202
- Spedicato 368
- Spellucci 362
- Spiegelung 235
- Spline
 - -funktionen 104 ff.
- , –, Konvergenzeigenschaften 114 ff.
- , –, natürliche 108
- , –, periodische 107
- Splineinterpolation 42, 104 ff.
- Standardform linearer Programme 268
- Steffensen 158, 165, 359 f., 371
- Stegun 186
- Sterbenz 2, 32
- Stewart 199, 260, 262
- Stiefel 170, 174
- Stoer 97, 173, 176 f., 192
- Strahlminimierung 317
- Streuung 32
- Stroud 181
- Sturmsche Kette 341 ff.
- stückweise Polynomfunktionen 119 ff.
- Stützabszissen 41
- Stützordinaten 41
- Stützpunkte 41
- submultiplikative Norm 219
- Suchrichtungen 315
- Summenformel von
 - Euler-Maclaurin 166 ff.
- superlineare Konvergenz 328
- symbolische Faktorisierung 287
- symmetrisches Rang-1-Verfahren 364
- Szegő 187
- Teilpivotsuche 202
- Tewarson 284
- Thielescher Kettenbruch 68, 72
- total positive Matrix 129
- Totalpivotsuche 202, 230
- translationsinvariant 102
- Trapezregel 158 f.
- Trapezsumme 160, 167
- Traub 329, 355
- Tridiagonalmatrizen 230, 330
- trigonometrische
 - Interpolation 41, 79 ff.
 - Polynome 79
- truncation error 1
- Tschebyscheff
 - -Polynome 186, 195
 - -Problem 243
 - -Systeme 184
- uneigentliche Integrale 192
- unerreichbare Punkte 65
- ungerichteter Graph 287
- unitäre Matrizen 221
- unvermeidbare Fehler 19
- Van Loan 199
- Varga 63
- Varianz 32
- , relative 34
- Verfahren von Schulz 371
- verkettete Listen 285
- verträgliche Normen 219
- vollständige Räume 306
- von Neumann 7
- Vorwärtsdeflation 338
- vorzeichenbeschränkte Variable 268
- Vorzeichenwechsel 341
- Walsh 106
- Wavelet 141
- Weddle-Regel 158
- Welsch 187, 189
- wesentliche Stellen 5
- Whitney 129
- Wilkinson 20, 199, 208, 230, 244, 250 f., 278, 338 f., 341, 349, 351 f.
- Willoughby 284
- Witzgall 67
- Wortlänge 3
- Zahldarstellung 2
- Zeiger 284
- Zeilensummennorm 220
- zentraler Differenzenquotient 175
- Zielfunktion 268
- Zufallsvariable 32

zulässige Basis 271
zulässige Lösung 268

Zwei-Stufen-Formel 131, 137
zweistufige Algorithmen 19 ff.